Chương 1

Giới thiệu

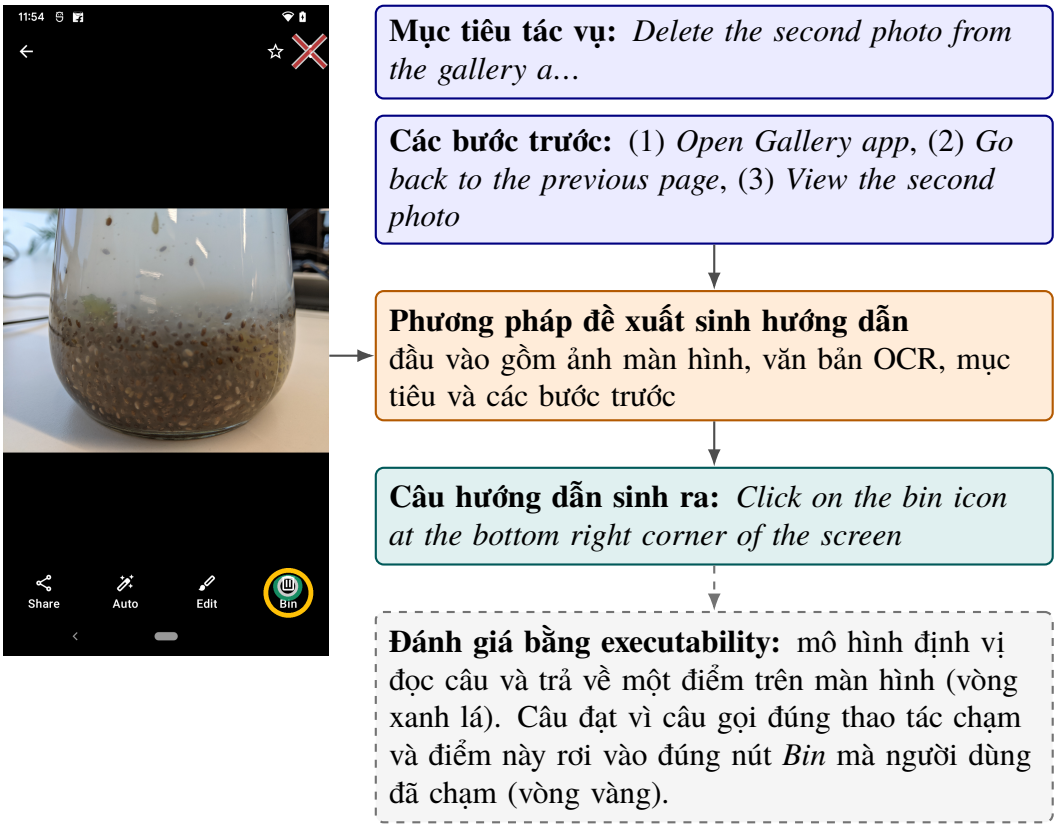
1.1 Đặt vấn đề

Khi thực hiện một tác vụ trên ứng dụng di động, người dùng có thể biết mục tiêu cần đạt nhưng chưa biết phải thao tác như thế nào trên giao diện hiện tại. Trong trường hợp này, một hướng dẫn hữu ích không chỉ cần nêu đúng thao tác, mà còn phải giúp người dùng xác định được phần tử cần tương tác. Chẳng hạn, thay vì chỉ yêu cầu "chia sẻ", hệ thống có thể hướng dẫn "Chạm vào biểu tượng chia sẻ ở góc trên bên phải màn hình".

Các nghiên cứu gần đây về tác tử giao diện người dùng (GUI agent), như SeeClick [3], OS-Atlas [4] và Aguvis [8], cũng giải quyết bài toán hiểu trạng thái giao diện và xác định hành động tiếp theo. Tuy nhiên, các hệ thống này chủ yếu hướng tới việc tự động thực hiện tác vụ: đầu ra thường gồm loại thao tác và vị trí trên màn hình, chẳng hạn `click(872,141)`. Biểu diễn này phù hợp với một tác tử phần mềm, nhưng không trực tiếp tạo ra hướng dẫn để người dùng đọc và làm theo.

Chúng tôi tập trung vào bài toán sinh hướng dẫn cho thao tác kế tiếp bằng ngôn ngữ tự nhiên. Tại mỗi thời điểm, mô hình nhận thông tin về mục tiêu của tác vụ, các thao tác đã được thực hiện trước đó và trạng thái giao diện hiện tại. Trạng thái giao diện được biểu diễn chủ yếu bằng ảnh chụp màn hình cùng phần văn bản đang hiển thị. Từ các thông tin này, mô hình cần sinh một câu hướng dẫn cho biết người dùng nên thực hiện thao tác nào và tương tác với phần tử nào để tiếp tục tác vụ. Hình 1.1 minh họa bài toán trên một bước của tập kiểm tra.

Khác với đầu ra dạng tọa độ, chất lượng của một câu hướng dẫn còn phụ thuộc vào



Hình 1.1: Bài toán sinh hướng dẫn cho thao tác kế tiếp và cách đánh giá bằng executability, minh họa trên một bước của tập kiểm tra. Vòng vàng là điểm người dùng đã chạm. Vòng xanh lá là điểm mà mô hình định vị trả về khi đọc câu do phương pháp đề xuất sinh ra. Dấu X đỏ là điểm trả về cho câu của mô hình gốc chưa tinh chỉnh (*Click on the three dots at the top right corner of the screen to access more options.*), nên câu đó không đạt. Mục tiêu tác vụ được giữ nguyên theo dữ liệu nguồn.

việc người dùng có nhận ra đúng phần tử cần tương tác hay không. Câu "Chạm vào biểu tượng tìm kiếm" vẫn có thể mơ hồ nếu màn hình có nhiều biểu tượng tương tự. Khi đó, hướng dẫn cần thêm thông tin như vị trí, nội dung hiển thị hoặc quan hệ với các thành phần xung quanh. Ở chiều ngược lại, cùng một thao tác có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn hoàn toàn hợp lệ.

Hai vấn đề chính cần giải quyết là đánh giá liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và thao tác cần thực hiện hay không, đồng thời phát triển phương pháp để nâng cao chất lượng hướng dẫn. Executability được xây dựng cho yêu cầu đánh giá này.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Về mặt khoa học, bài toán chúng tôi nghiên cứu có liên hệ gần với hướng sinh biểu thức quy chiếu (*referring expression generation*). Trong bài toán này, một mô tả được xem là hữu ích khi người tiếp nhận có thể dựa vào mô tả đó để nhận ra đúng đối tượng được nhắc tới. Mao và cộng sự [12] đánh giá chất lượng mô tả thông qua một mô hình *listener*. Mô hình nhận câu mô tả và lựa chọn đối tượng mà câu đó đề cập tới. Mô tả được xem là thành công nếu đối tượng được chọn chính là đối tượng mục tiêu. Các nghiên cứu sau đó tiếp tục đưa tín hiệu từ listener vào quá trình huấn luyện nhằm khuyến khích mô hình tạo ra những mô tả có khả năng phân biệt đối tượng tốt hơn [13, 14]. Cách tiếp cận này phù hợp với bài toán sinh hướng dẫn giao diện, bởi một câu hướng dẫn chỉ thực sự hữu ích khi nó giúp người dùng nhận ra đúng phần tử cần thao tác.

Trong miền giao diện người dùng, Widget Captioning [10] cũng xem xét việc mô tả các phần tử trên màn hình, bao gồm những trường hợp có nhiều phần tử giống hoặc gần giống nhau. Tuy nhiên, mục tiêu huấn luyện vẫn chủ yếu dựa trên mức độ phù hợp với câu chuẩn. Một hướng dẫn do mô hình tạo ra có thể gần với câu chuẩn về cách diễn đạt nhưng vẫn chưa đủ rõ để người dùng phân biệt đúng phần tử mục tiêu. Vì vậy, chúng tôi đánh giá thêm khả năng câu hướng dẫn giúp xác định đúng phần tử, thay vì chỉ dựa vào độ tương đồng về từ ngữ.

Khi dùng một mô hình định vị làm công cụ đánh giá, cần kiểm tra độ ổn định của kết quả trước những khác biệt về cách diễn đạt và công cụ đánh giá. ALOHa [15] cho thấy có thể đánh giá đầu ra sinh bằng cách đối chiếu với nguồn thông tin có cấu trúc, thay vì chỉ so sánh trực tiếp với một câu chuẩn. Jandial và cộng sự [18] cũng chỉ ra rằng khả năng định vị có thể thay đổi theo cách một đối tượng được diễn đạt bằng ngôn ngữ. Để tránh phụ thuộc vào một cấu hình đánh giá duy nhất, chúng tôi kiểm tra executability với các biến thể câu và nhiều mô hình định vị.

1.2.2 Động lực ứng dụng

Về mặt ứng dụng, nhu cầu hướng dẫn người dùng thao tác trực tiếp trên giao diện đã xuất hiện trong các hệ thống thực tế. GuideMe [19], chẳng hạn, hỗ trợ người cao tuổi sử dụng điện thoại thông minh bằng cách nhận câu hỏi cùng nội dung màn hình và trả về hướng dẫn cho các thao tác cần thực hiện. Hệ thống này sử dụng một mô hình thương mại cỡ lớn qua mạng và được đánh giá thông qua nghiên cứu người dùng với 18 người tham gia. Tuy nhiên, công trình chưa cung cấp một độ đo tự động để có thể so sánh định lượng các phương pháp sinh hướng dẫn trong quá trình phát triển hệ thống.

Một độ đo tự động có thể được dùng nhất quán qua nhiều lần thử nghiệm sẽ giúp việc so sánh các phương pháp thuận tiện hơn, đặc biệt khi việc thực hiện một nghiên cứu người dùng riêng cho từng thay đổi nhỏ của mô hình là khó khả thi. Bên cạnh đó, ảnh chụp màn hình điện thoại có thể chứa các thông tin nhạy cảm như tin nhắn, danh bạ hoặc dữ liệu tài chính. Mô hình có quy mô vừa phải và có khả năng triển khai cục bộ giúp hạn chế nhu cầu gửi dữ liệu màn hình tới dịch vụ bên ngoài. Trong nghiên cứu này, chúng tôi tập trung vào mô hình ngôn ngữ thị giác cỡ nhỏ thay vì đặt trọng tâm vào các mô hình lớn nhất hiện có.

1.3 Mục đích nghiên cứu

Mục tiêu tổng quát của chúng tôi là nâng cao chất lượng câu hướng dẫn cho thao tác kế tiếp trên giao diện di động, đặc biệt là khả năng giúp người dùng nhận ra đúng phần tử cần tương tác. Để thực hiện mục tiêu này, chúng tôi tập trung vào ba mục tiêu cụ thể:

1. Xây dựng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ, hướng tới câu hướng dẫn nêu rõ thao tác cần thực hiện và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình.

2. Xây dựng và đánh giá độ tin cậy của độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability, cho các bước có thao tác

chạm. Thay vì chỉ đo mức độ tương đồng giữa hướng dẫn do mô hình tạo ra và một câu chuẩn, độ đo này xem xét liệu thông tin trong câu hướng dẫn có giúp xác định đúng phần tử và đúng loại thao tác hay không.

3. Tự động xây dựng tập dữ liệu giám sát cho tác vụ sinh hướng dẫn từ AndroidControl [1], không yêu cầu gán nhãn thủ công bổ sung và không sử dụng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

1.4 Khoảng trống nghiên cứu và vị trí của đề tài

Các công trình trên cho thấy hai khoảng trống nghiên cứu liên quan trực tiếp đến đề tài. Phần lớn nghiên cứu về GUI agent tập trung vào dự đoán thao tác hoặc tọa độ cho tác tử phần mềm, thay vì sinh hướng dẫn để con người đọc và thực hiện. Đồng thời, các độ đo dựa trên câu chuẩn không trực tiếp cho biết hướng dẫn do mô hình tạo ra có đủ rõ để xác định đúng phần tử mục tiêu hay không. Chúng tôi giải quyết hai vấn đề này bằng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ (Chương 4) và executability để đánh giá liệu câu hướng dẫn có xác định đúng phần tử và đúng loại thao tác hay không (Chương 5). Kết quả được phân tích ở Chương 6.

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

Để thực hiện các mục tiêu đã nêu, chúng tôi triển khai bốn nhóm nội dung gồm xây dựng tập giám sát từ AndroidControl, xây dựng và đánh giá độ tin cậy của executability, phát triển phương pháp sinh hướng dẫn, và thực nghiệm so sánh cùng phân tích lỗi. Các phương án thiết kế không thuộc phương pháp cuối được trình bày ở Phụ lục A.

1.5.2 Phạm vi nghiên cứu

Về bài toán, chúng tôi chỉ xét việc sinh hướng dẫn cho thao tác kế tiếp tại trạng thái giao diện hiện tại. Việc lập kế hoạch cho toàn bộ tác vụ hoặc sinh đồng thời một chuỗi

nhiều thao tác không thuộc phạm vi của đề tài.

Về đánh giá, executability được áp dụng cho các bước có thao tác chạm và tập trung vào câu hỏi liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Các khía cạnh như độ trôi chảy, độ dài, mức dễ hiểu đối với từng nhóm người dùng và trải nghiệm tổng thể không phải mục tiêu trực tiếp của độ đo này.

Về dữ liệu, các thực nghiệm chính được thực hiện trên AndroidControl với giao diện và câu hướng dẫn bằng tiếng Anh. Khả năng khái quát được kiểm tra thêm theo hai hướng: các tác vụ AndroidControl không xuất hiện trong tập huấn luyện của S1 và bộ dữ liệu AitZ thuộc một phân phối khác. Các câu tiếng Việt xuất hiện trong phần trình bày chỉ được dùng để minh họa cho bài toán.

Về mô hình, hệ thống sinh được phát triển từ Qwen2.5-VL-3B-Instruct [34] và được tinh chỉnh bằng QLoRA [30] hoặc LoRA trong điều kiện một GPU. Việc giữ cố định mô hình nền giúp các thực nghiệm tập trung vào ảnh hưởng của dữ liệu và các chiến lược tinh chỉnh trong cùng một thiết lập tính toán.

1.6 Đóng góp chính

Chúng tôi tập trung vào ba đóng góp chính, gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích thực nghiệm các phương án thiết kế. Bên cạnh đó, quy trình xây dựng dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ toàn bộ quá trình huấn luyện và đánh giá.

Thứ nhất, chúng tôi đề xuất một phương pháp sinh hướng dẫn gồm hai thành phần nối tiếp trên nền Qwen2.5-VL-3B. Thành phần thứ nhất tiếp tục tối ưu mô hình đã được tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE. Thành phần thứ hai, ACE, sử dụng các câu ví dụ truy hồi để hiệu chỉnh câu hướng dẫn khi câu ứng viên đáp ứng các điều kiện lựa chọn. Thiết kế được trình bày ở Chương 4, còn kết quả thực nghiệm nằm ở Chương 6.

Trên 4.463 bước có thao tác chạm của tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202

1,03 điểm [+0,25; +1,83]. Lượt GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11%, bằng S1/101. GRPO-SPICE cao hơn nhánh này 1,55 điểm [+0,81; +2,30], nên mức tăng không xuất hiện khi điểm SPICE không còn gắn với đúng mẫu dù số bước huấn luyện được giữ nguyên.

Trên 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05], gần gấp ba mức 1,55 điểm trên tập kiểm tra chính. Lượt GRPO thứ hai tiếp tục cho cùng chiều với mức tăng 4,04 điểm [+2,66; +5,48]. Khi gộp tập này với tập kiểm tra chính, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99].

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 1,55 điểm dưới UGround, 1,55 điểm dưới UI-Venus, 0,78 điểm dưới Phi-Ground và 0,69 điểm dưới Phi-4. So với Qwen2.5-VL-7B chỉ dùng prompting, GRPO-SPICE trên mô hình 3B cao hơn 9,14 điểm executability. ACE đạt 60,68% executability trên tập kiểm tra chính, đồng thời tăng cả bảy thước dựa trên câu chuẩn. Với sáu thước có khoảng tin cậy, toàn bộ khoảng tăng đều nằm trên 0.

Khi lịch sử các bước trước do chính mô hình sinh, GRPO-SPICE vẫn cao hơn S1 1,48 điểm executability [+0,54; +2,43]. Trên AitZ, S1 cao hơn Base 3,29 điểm [+1,51; +5,03], còn GRPO-SPICE và S1 tương đương về executability với chênh lệch -0,51 điểm [-1,39; +0,36]. Mức cải thiện bổ sung của SPICE chưa xuất hiện rõ trong miền này, trong khi bước tinh chỉnh có giám sát vẫn giữ mức tăng so với mô hình gốc. Các kết quả và phép kiểm tương ứng được trình bày ở Chương 6.

Thứ hai, chúng tôi xây dựng executability cho các bước có thao tác chạm. Độ đo này sử dụng một mô hình định vị tách biệt để kiểm tra liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Chương 5 trình bày định nghĩa, độ tin cậy của cách đo và các kiểm tra độ ổn định trước khi executability được dùng để so sánh các mô hình sinh.

Thứ ba, chúng tôi phân tích nhiều phương án thiết kế đã được khảo sát trước khi lựa chọn phương pháp cuối cùng, gồm mô tả phần tử, học theo cặp ưu tiên, sử dụng thông tin tọa độ, chọn ứng viên và hiệu chỉnh câu theo vùng ảnh. Các phân tích cho thấy chất lượng của biểu diễn trung gian và chất lượng của câu hướng dẫn cuối không

luôn thay đổi cùng nhau. Vì vậy, phương pháp cuối cùng chuyển trọng tâm sang tối ưu trực tiếp câu hướng dẫn. Kết quả tổng hợp được trình bày ở Mục 6.11, còn thiết kế chi tiết nằm trong Phụ lục A.

Bên cạnh ba đóng góp chính, chúng tôi xây dựng một tập dữ liệu giám sát cho bài toán sinh hướng dẫn từ AndroidControl bằng quy trình tự động hợp nhất hai bản phân phối công khai, trong đó một bản chứa câu hướng dẫn và một bản chứa ảnh màn hình. Quy trình không yêu cầu gán nhãn thủ công bổ sung và có bước kiểm tra tính nhất quán sau hợp nhất bằng cách đối chiếu kết quả khi giữ đúng liên kết giữa hai nguồn và khi dịch liên kết đi một bước. Quy trình xây dựng dữ liệu được trình bày ở Chương 3.