Chương 1

Giới thiệu

1.1 Đặt vấn đề

Khi thực hiện một tác vụ trên ứng dụng di động, người dùng có thể biết mục tiêu cần đạt nhưng chưa biết phải thao tác như thế nào trên giao diện hiện tại. Trong trường hợp này, một hướng dẫn hữu ích không chỉ cần nêu đúng thao tác, mà còn phải giúp người dùng xác định được phần tử cần tương tác. Chẳng hạn, thay vì chỉ yêu cầu "chia sẻ", hệ thống có thể hướng dẫn "Chạm vào biểu tượng chia sẻ ở góc trên bên phải màn hình".

Các nghiên cứu gần đây về tác tử giao diện người dùng (GUI agent), như SeeClick [3], OS-Atlas [4] và Aguvis [7], cũng giải quyết bài toán hiểu trạng thái giao diện và xác định hành động tiếp theo. Tuy nhiên, các hệ thống này chủ yếu hướng tới việc tự động thực hiện tác vụ: đầu ra thường gồm loại thao tác và vị trí trên màn hình, chẳng hạn `click(872,141)`. Biểu diễn này phù hợp với một tác tử phần mềm, nhưng không trực tiếp tạo ra hướng dẫn để người dùng đọc và làm theo.

Luận văn này tập trung vào bài toán sinh hướng dẫn cho thao tác kế tiếp bằng ngôn ngữ tự nhiên. Tại mỗi thời điểm, mô hình nhận thông tin về mục tiêu của tác vụ, các thao tác đã được thực hiện trước đó và trạng thái giao diện hiện tại. Trạng thái giao diện được biểu diễn chủ yếu bằng ảnh chụp màn hình cùng phần văn bản đang hiển thị. Từ các thông tin này, mô hình cần sinh một câu hướng dẫn cho biết người dùng nên thực hiện thao tác nào và tương tác với phần tử nào để tiếp tục tác vụ.

Khác với đầu ra dạng tọa độ, chất lượng của một câu hướng dẫn còn phụ thuộc vào việc người dùng có nhận ra đúng phần tử cần tương tác hay không. Câu "Chạm vào

biểu tượng tìm kiếm" vẫn có thể mơ hồ nếu màn hình có nhiều biểu tượng tương tự; khi đó, hướng dẫn cần thêm thông tin như vị trí, nội dung hiển thị hoặc quan hệ với các thành phần xung quanh. Ở chiều ngược lại, cùng một thao tác có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn hoàn toàn hợp lệ.

Từ đó, luận văn tập trung vào hai vấn đề chính. Thứ nhất là đánh giá liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và thao tác cần thực hiện hay không; executability được sử dụng cho mục đích này. Thứ hai là phát triển phương pháp nhằm nâng cao chất lượng hướng dẫn.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Về mặt khoa học, bài toán của luận văn có liên hệ gần với hướng nghiên cứu sinh biểu thức quy chiếu (*referring expression generation*). Trong bài toán này, một mô tả được xem là hữu ích khi người tiếp nhận có thể dựa vào mô tả đó để nhận ra đúng đối tượng được nhắc tới. Mao và cộng sự [11] đánh giá chất lượng mô tả thông qua một mô hình *listener*: mô hình nhận câu mô tả và lựa chọn đối tượng mà câu đó đề cập tới; mô tả được xem là thành công nếu đối tượng được chọn trùng với đối tượng mục tiêu. Các nghiên cứu sau đó tiếp tục đưa tín hiệu từ listener vào quá trình huấn luyện nhằm khuyến khích mô hình tạo ra những mô tả có khả năng phân biệt đối tượng tốt hơn [12, 13]. Cách tiếp cận này phù hợp với bài toán sinh hướng dẫn giao diện, bởi một câu hướng dẫn chỉ thực sự hữu ích khi nó giúp người dùng nhận ra đúng phần tử cần thao tác.

Trong miền giao diện người dùng, Widget Captioning [9] cũng xem xét việc mô tả các phần tử trên màn hình, bao gồm những trường hợp có nhiều phần tử giống hoặc gần giống nhau. Tuy nhiên, mục tiêu huấn luyện vẫn chủ yếu dựa trên mức độ phù hợp với câu tham chiếu. Một hướng dẫn do mô hình tạo ra có thể gần với câu tham chiếu về cách diễn đạt nhưng vẫn chưa đủ rõ để người dùng phân biệt đúng phần tử mục tiêu. Đây là một trong những động lực chính để luận văn xem xét cách đánh giá chất lượng hướng dẫn dựa trên khả năng xác định đúng phần tử, thay vì chỉ dựa vào

độ tương đồng về từ ngữ.

Việc dùng một mô hình định vị làm công cụ đánh giá cũng đặt ra một vấn đề khác: kết quả đo phụ thuộc vào chính khả năng của mô hình đó. ALOHa [14] cho thấy có thể đánh giá đầu ra sinh bằng cách đối chiếu với nguồn thông tin có cấu trúc, thay vì chỉ so sánh trực tiếp với một câu tham chiếu. Tuy nhiên, khi thành phần dùng để đối chiếu cũng là một mô hình học máy, độ tin cậy của cách đo cũng cần được đánh giá. Jandial và cộng sự [17] cũng chỉ ra rằng khả năng định vị có thể thay đổi theo cách một đối tượng được diễn đạt bằng ngôn ngữ. Vì vậy, trước khi dùng mô hình định vị để so sánh các phương pháp sinh, cần kiểm tra xem kết quả có ổn định trước các biến đổi của câu và khi thay đổi mô hình đánh giá hay không.

1.2.2 Động lực ứng dụng

Về mặt ứng dụng, nhu cầu hướng dẫn người dùng thao tác trực tiếp trên giao diện đã xuất hiện trong các hệ thống thực tế. GuideMe [18], chẳng hạn, hỗ trợ người cao tuổi sử dụng điện thoại thông minh bằng cách nhận câu hỏi cùng nội dung màn hình và trả về hướng dẫn cho các thao tác cần thực hiện. Hệ thống này sử dụng một mô hình thương mại cỡ lớn qua mạng và được đánh giá thông qua nghiên cứu người dùng với 18 người tham gia. Tuy nhiên, công trình chưa cung cấp một độ đo tự động để có thể so sánh định lượng các phương pháp sinh hướng dẫn trong quá trình phát triển hệ thống.

Một độ đo tự động có thể được dùng nhất quán qua nhiều lần thử nghiệm sẽ giúp việc so sánh các phương pháp thuận tiện hơn, đặc biệt vì không thể tiến hành một nghiên cứu người dùng riêng cho mọi thay đổi của mô hình. Bên cạnh đó, ảnh chụp màn hình điện thoại có thể chứa các thông tin nhạy cảm như tin nhắn, danh bạ hoặc dữ liệu tài chính. Do đó, việc nghiên cứu các mô hình ngôn ngữ thị giác có quy mô vừa phải và có khả năng triển khai cục bộ có ý nghĩa thực tế, vì có thể hạn chế nhu cầu gửi dữ liệu màn hình tới dịch vụ bên ngoài. Đây là một trong những lý do luận văn tập trung vào mô hình ngôn ngữ thị giác cỡ nhỏ thay vì đặt trọng tâm vào các mô hình lớn nhất hiện có.

1.3 Mục đích nghiên cứu

Mục tiêu tổng quát của luận văn là nâng cao chất lượng câu hướng dẫn cho thao tác kế tiếp trên giao diện di động, đặc biệt là khả năng giúp người dùng nhận ra đúng phần tử cần tương tác. Để thực hiện mục tiêu này, luận văn tập trung vào ba mục tiêu cụ thể:

1. Xây dựng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ, hướng tới câu hướng dẫn nêu rõ thao tác cần thực hiện và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình.

2. Xây dựng và đánh giá độ tin cậy của độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability, cho các bước có thao tác chạm. Thay vì chỉ đo mức độ tương đồng giữa hướng dẫn do mô hình tạo ra và một câu tham chiếu, độ đo này xem xét liệu thông tin trong câu hướng dẫn có giúp xác định đúng phần tử và đúng loại thao tác hay không.

3. Tự động xây dựng tập dữ liệu giám sát cho tác vụ sinh hướng dẫn từ Android-Control [1], không yêu cầu gán nhãn thủ công bổ sung và không sử dụng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

1.4 Khoảng trống nghiên cứu và vị trí của đề tài

Từ các công trình trên, luận văn tập trung vào hai khoảng trống nghiên cứu. Thứ nhất, phần lớn nghiên cứu về GUI agent tập trung vào dự đoán thao tác hoặc tọa độ cho tác tử phần mềm, thay vì sinh hướng dẫn để con người đọc và thực hiện. Thứ hai, các độ đo dựa trên câu tham chiếu không trực tiếp cho biết hướng dẫn do mô hình tạo ra có đủ rõ để xác định đúng phần tử mục tiêu hay không. Luận văn giải quyết hai vấn đề này bằng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ (Chương 4) và executability để đánh giá liệu câu hướng dẫn có xác định đúng phần tử và đúng loại thao tác hay không (Chương 5); kết quả được phân tích ở Chương 6.

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

Để thực hiện các mục tiêu đã nêu, luận văn triển khai bốn nhóm nội dung: xây dựng tập giám sát từ AndroidControl; xây dựng và đánh giá độ tin cậy của executability; phát triển phương pháp sinh hướng dẫn; và thực nghiệm so sánh, phân tích lỗi. Các phương án thiết kế không thuộc phương pháp cuối được trình bày ở Phụ lục A.

1.5.2 Phạm vi nghiên cứu

Về bài toán, luận văn chỉ xét việc sinh hướng dẫn cho thao tác kế tiếp tại trạng thái giao diện hiện tại. Việc lập kế hoạch cho toàn bộ tác vụ hoặc sinh đồng thời một chuỗi nhiều thao tác không thuộc phạm vi của đề tài.

Về đánh giá, executability chỉ áp dụng cho các bước có thao tác chạm và chỉ phản ánh một khía cạnh của chất lượng hướng dẫn: câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Độ đo này không trực tiếp phản ánh các yếu tố khác như độ trôi chảy, độ dài, mức dễ hiểu đối với từng nhóm người dùng hay chất lượng trải nghiệm tổng thể.

Về dữ liệu, các thực nghiệm sử dụng AndroidControl với giao diện và câu hướng dẫn bằng tiếng Anh. Luận văn không xây dựng bộ dữ liệu tiếng Việt; các câu tiếng Việt xuất hiện trong phần trình bày chỉ được dùng để minh họa cho bài toán.

Về mô hình, hệ thống sinh được phát triển từ Qwen2.5-VL-3B-Instruct [33] và được tinh chỉnh bằng QLoRA [29] hoặc LoRA trong điều kiện một GPU. Luận văn không đặt mục tiêu huấn luyện mô hình nền từ đầu và cũng không thực hiện so sánh có hệ thống giữa nhiều mô hình nền khác nhau.

1.6 Đóng góp của luận văn

Luận văn có ba đóng góp chính, gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích thực nghiệm các phương án thiết kế. Bên cạnh đó, quy trình xây dựng

dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ toàn bộ quá trình huấn luyện và đánh giá.

Thứ nhất, luận văn đề xuất một phương pháp sinh hướng dẫn gồm hai thành phần nối tiếp trên nền Qwen2.5-VL-3B. Thành phần thứ nhất tiếp tục tối ưu mô hình đã được tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE. Thành phần thứ hai, ACE, sử dụng các câu ví dụ truy hồi để hiệu chỉnh câu hướng dẫn khi câu ứng viên đáp ứng các điều kiện lựa chọn. Thiết kế được trình bày ở Chương 4, còn kết quả thực nghiệm nằm ở Chương 6.

Thứ hai, luận văn xây dựng executability cho các bước có thao tác chạm. Độ đo này sử dụng một mô hình định vị tách biệt để kiểm tra liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Chương 5 trình bày định nghĩa, độ tin cậy của cách đo và các kiểm tra độ ổn định trước khi executability được dùng để so sánh các mô hình sinh.

Thứ ba, luận văn phân tích nhiều phương án thiết kế đã được khảo sát trước khi lựa chọn phương pháp cuối cùng, gồm mô tả phần tử, học theo cặp ưu tiên, sử dụng thông tin tọa độ, chọn ứng viên và hiệu chỉnh câu theo vùng ảnh. Kết quả cho thấy một biểu diễn trung gian tốt hơn chưa chắc tạo ra câu hướng dẫn tốt hơn. Phân tích này giúp giải thích vì sao các hướng trên không được giữ lại trong phương pháp cuối cùng. Kết quả tổng hợp được trình bày ở Mục 6.10, còn thiết kế chi tiết nằm trong Phụ lục A.

Bên cạnh ba đóng góp chính, luận văn xây dựng một tập dữ liệu giám sát cho bài toán sinh hướng dẫn từ AndroidControl bằng quy trình tự động hợp nhất hai bản phân phối công khai, trong đó một bản chứa câu hướng dẫn và một bản chứa ảnh màn hình. Quy trình không yêu cầu gán nhãn thủ công bổ sung và có bước kiểm tra tính nhất quán của dữ liệu sau hợp nhất bằng cách so sánh với dữ liệu cố ý ghép lệch một bước. Quy trình xây dựng dữ liệu được trình bày ở Chương 3.