Chương 2

Tổng quan

Chương này trình bày các khái niệm và công trình nền tảng trực tiếp liên quan đến luận văn. Các nội dung chính gồm mô hình ngôn ngữ thị giác, LoRA và QLoRA, GRPO và SPICE, định vị phần tử giao diện, bộ dữ liệu AndroidControl và hạn chế của các độ đo dựa trên một câu tham chiếu. Cấu hình cụ thể của mô hình và cách đánh giá được trình bày lần lượt ở Chương 4 và Chương 5.

2.1 Mô hình ngôn ngữ thị giác

Bài toán của luận văn yêu cầu mô hình xử lý đồng thời hai nguồn thông tin. Ảnh chụp màn hình cung cấp trạng thái trực quan của giao diện, trong khi phần văn bản mô tả mục tiêu của tác vụ, các thao tác đã thực hiện trước đó và nội dung chữ xuất hiện trên màn hình. Vì vậy, mô hình sinh không chỉ cần hiểu ngôn ngữ mà còn phải liên kết nội dung văn bản với các thành phần trực quan trên giao diện.

Mô hình ngôn ngữ thị giác (*vision-language model*, VLM) được thiết kế cho kiểu đầu vào này. Thông thường, ảnh được chuyển thành các đặc trưng hoặc token thị giác, sau đó được tích hợp với chuỗi token văn bản để mô hình có thể suy luận và sinh đầu ra dựa trên cả hai nguồn thông tin. Phần sinh ngôn ngữ thường dựa trên kiến trúc Transformer [31], trong đó cơ chế tự chú ý giúp mô hình học quan hệ giữa các phần tử trong chuỗi đầu vào.

Luận văn sử dụng Qwen2.5-VL-3B-Instruct [33] làm mô hình nền vì mô hình có trọng số mở, quy mô khoảng ba tỉ tham số phù hợp với điều kiện thử nghiệm và triển khai cục bộ, đồng thời hỗ trợ xử lý ảnh với độ phân giải động. Đặc điểm cuối phù hợp

với ảnh chụp màn hình điện thoại, vốn có tỉ lệ và kích thước thay đổi. Cấu hình sử dụng cụ thể của Qwen2.5-VL-3B-Instruct được trình bày ở Chương 4.

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA

Tinh chỉnh toàn bộ một mô hình ngôn ngữ thị giác đòi hỏi lượng bộ nhớ lớn vì quá trình huấn luyện không chỉ lưu trọng số mô hình mà còn cần gradient và trạng thái của bộ tối ưu. LoRA [28] giảm chi phí này bằng cách giữ cố định trọng số gốc và chỉ học một cập nhật có hạng thấp. Với ma trận trọng số $W \in \mathbb{R}^{d\times k}$, trọng số sau khi áp dụng LoRA được viết dưới dạng

$$W' = W + \frac{\alpha}{r}BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k), \tag{2.1}$$

trong đó r là hạng của cập nhật và α là hệ số tỉ lệ. Thay vì cập nhật toàn bộ dk tham số của ma trận W, LoRA chỉ cần học $r(d+k)$ tham số trong hai ma trận A và B.

QLoRA [29] tiếp tục giảm nhu cầu bộ nhớ bằng cách kết hợp LoRA với lượng tử hóa trọng số nền xuống 4 bit. Trong đó, định dạng NormalFloat (NF4) được thiết kế cho phân bố trọng số của mạng nơ-ron. Trong quá trình huấn luyện, trọng số nền vẫn được giữ cố định ở dạng lượng tử hóa, còn gradient chỉ cập nhật các tham số LoRA ở độ chính xác cao hơn. Cách làm này giúp tinh chỉnh các mô hình có kích thước lớn hơn trong điều kiện tài nguyên hạn chế. Trong luận văn, QLoRA được sử dụng cho các lượt tinh chỉnh trực tiếp từ Qwen2.5-VL-3B-Instruct; các giai đoạn học tiếp của phương pháp có cấu hình riêng ở Chương 4.

2.3 GRPO và phần thưởng dựa trên độ đo văn bản

Trong tinh chỉnh có giám sát, mô hình học bằng cách tăng xác suất của câu tham chiếu tương ứng với mỗi đầu vào. Cách huấn luyện này phù hợp để hình thành khả năng sinh ban đầu, nhưng không trực tiếp phân biệt chất lượng giữa nhiều câu mà mô hình có thể sinh cho cùng một trường hợp. Học tăng cường bổ sung tín hiệu này bằng cách

gán phần thưởng cho từng đầu ra và cập nhật mô hình dựa trên chất lượng tương đối giữa các đầu ra.

Tối ưu chính sách tương đối theo nhóm (*Group Relative Policy Optimization*, GRPO) được giới thiệu trong DeepSeekMath [40]. Với mỗi đầu vào x, mô hình sinh một nhóm gồm G đầu ra $y_1, \ldots, y_G$ và nhận các phần thưởng tương ứng $r_1, \ldots, r_G$. Lợi thế của đầu ra thứ i được xác định bằng cách chuẩn hóa phần thưởng trong cùng nhóm:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G})}, \tag{2.2}$$

sau đó chính sách được cập nhật dựa trên lợi thế tương đối này, đồng thời có số hạng kiểm soát mức sai lệch so với mô hình tham chiếu. Điểm đáng chú ý của GRPO là không cần huấn luyện thêm một mô hình ước lượng giá trị riêng. Mặt khác, nếu các đầu ra trong cùng nhóm nhận phần thưởng giống nhau thì nhóm đó không cung cấp tín hiệu phân biệt hữu ích cho bước cập nhật.

Trong luận văn, phần thưởng cho GRPO được xây dựng từ SPICE [23]. SPICE là một độ đo dựa trên câu tham chiếu, trong đó nội dung câu được biểu diễn thông qua các đối tượng, thuộc tính và quan hệ, sau đó so sánh các thành phần tương ứng bằng điểm F1. Zhao và cộng sự [36] đã sử dụng SPICE khi đánh giá mô hình sinh chỉ dẫn. SPICE được dùng làm tín hiệu phần thưởng ở mức nội dung cho câu hướng dẫn trong giai đoạn này. Cách xây dựng phần thưởng và quy trình huấn luyện GRPO được trình bày cụ thể ở Mục 4.5.

2.4 Định vị phần tử giao diện

Định vị phần tử giao diện (*GUI grounding*) là bài toán xác định vị trí của một phần tử trên màn hình từ ảnh giao diện và một mô tả bằng ngôn ngữ. Đầu ra thường được biểu diễn dưới dạng một điểm hoặc một khung bao quanh phần tử mục tiêu. Một số mô hình tiêu biểu cho hướng nghiên cứu này gồm SeeClick [3], OS-Atlas [4] và UGround [5].

Bài toán định vị giúp kiểm tra trực tiếp mối liên hệ giữa câu mô tả và phần tử mà câu đó hướng tới. Nếu câu hướng dẫn cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử khác trên màn hình, một mô hình định vị có thể được dùng để

suy ra phần tử mà câu đang mô tả. Mối liên hệ này là cơ sở cho executability trong luận văn. Chương 5 trình bày mô hình định vị được lựa chọn, tiêu chí xác định một dự đoán đúng và các bước kiểm tra độ tin cậy trước khi dùng mô hình này để đánh giá câu hướng dẫn.

2.5 Bộ dữ liệu AndroidControl

AndroidControl [1] là bộ dữ liệu do Google DeepMind công bố tại NeurIPS 2024 và phát hành theo giấy phép Apache 2.0. Bộ dữ liệu gồm 15.283 chuỗi thao tác do người thật thực hiện trên thiết bị Pixel trong khoảng một năm. Ở mỗi bước, dữ liệu lưu trạng thái màn hình, loại thao tác, tọa độ chạm khi có và trường `step_instructions`, tức câu hướng dẫn do người thực hiện viết cho thao tác tương ứng.

Trong công trình AndroidControl và các nghiên cứu về tác tử giao diện sử dụng bộ dữ liệu này, như Aguvis [7], câu hướng dẫn thường được đưa vào làm đầu vào để mô hình dự đoán thao tác cần thực hiện. Luận văn sử dụng dữ liệu theo chiều ngược lại: trạng thái tác vụ và giao diện được dùng làm đầu vào, còn câu hướng dẫn cho thao tác kế tiếp là đầu ra cần sinh. Nhờ đó, AndroidControl có thể được chuyển thành tập dữ liệu giám sát cho bài toán sinh hướng dẫn mà không cần thu thập lại toàn bộ dữ liệu từ đầu. Quy trình hợp nhất, làm sạch và phân chia dữ liệu được trình bày ở Chương 3.

2.6 Hạn chế của các độ đo dựa trên câu tham chiếu

Một thao tác trên giao diện có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn dẫn người dùng tới cùng một phần tử. Vì vậy, một câu tham chiếu chỉ phản ánh một trong nhiều cách mô tả có thể chấp nhận được. Các độ đo phụ thuộc nhiều vào mức trùng khớp từ vựng có thể đánh giá thấp một câu diễn đạt khác với tham chiếu dù nội dung hướng dẫn vẫn đúng. Chẳng hạn, cùng một phần tử có thể được mô tả là "more options button" trong một câu và "three-dot icon" trong một câu khác.

Các độ đo tương đồng ngữ nghĩa giảm bớt sự phụ thuộc vào từ ngữ cụ thể, nhưng vẫn không trực tiếp trả lời câu hỏi quan trọng đối với bài toán này: câu hướng dẫn có giúp xác định đúng phần tử cần thao tác hay không. Hai câu có thể gần nhau về nghĩa

nhưng lại quy chiếu tới hai phần tử khác nhau trên cùng màn hình, chẳng hạn "inbox" và "outbox". Ngược lại, hai cách diễn đạt khác nhau đáng kể vẫn có thể cùng quy chiếu tới một phần tử. Do đó, mức độ gần nhau trong không gian ngữ nghĩa không đồng nghĩa với khả năng dẫn tới cùng một đối tượng trên giao diện.

Từ hạn chế này, việc đánh giá câu hướng dẫn cần xem xét trực tiếp mối quan hệ giữa hướng dẫn do mô hình tạo ra và phần tử mà hướng dẫn đó mô tả, thay vì chỉ đo mức độ giống với một câu tham chiếu. Chương 5 phát triển executability theo hướng này và đánh giá độ tin cậy của cách đo trên nhiều tình huống khác nhau.