Chương 3

Xây dựng bộ dữ liệu

Chương này trình bày cách hợp nhất các nguồn dữ liệu, cách chia tập huấn luyện và tập kiểm tra, thông tin giao diện được sử dụng, cùng dữ liệu dành cho từng giai đoạn của phương pháp. Toàn bộ quá trình xây dựng dữ liệu được tự động hóa, không yêu cầu gán nhãn thủ công bổ sung và không dùng nhãn do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

3.1 Nguồn dữ liệu và cách hợp nhất

Để xây dựng dữ liệu, luận văn sử dụng câu hướng dẫn theo từng bước, ảnh chụp màn hình và cây trợ năng. Cây trợ năng chỉ cần thiết ở một số bước tiền xử lý. Tuy nhiên, không bản phân phối nào được sử dụng trong đề tài chứa đủ cả ba thành phần này. Vì vậy, luận văn kết hợp hai bản phân phối trên Hugging Face để ghép câu hướng dẫn với ảnh màn hình như trình bày ở Bảng 3.1. Cây trợ năng được lấy riêng từ bản phát hành gốc của AndroidControl.

Bảng 3.1: Hai bản phân phối trên Hugging Face dùng để ghép câu hướng dẫn với ảnh màn hình.

Bản phát hành	**Có**	**Thiếu**
`HarrytheOrange/parsed_AndroidControl`	câu hướng dẫn theo từng bước	không có ảnh
`ckg/AndroidControlParsedWithImages-20k`	ảnh màn hình	không có câu hướng dẫn theo bước

Hai bản được ghép theo cặp mã tác vụ và số thứ tự bước, `(episode_id, step_id)`. Cây trợ năng của 99.131 màn hình được lấy riêng từ bản phát hành gốc.

3.2 Kiểm tra tính nhất quán của dữ liệu sau hợp nhất

Rủi ro chính khi hợp nhất hai nguồn là ảnh và câu hướng dẫn bị ghép lệch bước. Lỗi ghép lệch không làm thay đổi số lượng bản ghi và cũng không nhất thiết khiến quá trình huấn luyện báo lỗi. Vì vậy, chỉ kiểm tra số lượng dữ liệu hoặc quá trình huấn luyện là chưa đủ để phát hiện lỗi này. Luận văn kiểm tra thêm mức độ phù hợp giữa nội dung ảnh và câu hướng dẫn.

Với mỗi bước có thao tác chạm, luận văn lấy phần văn bản OCR tại vị trí chạm và kiểm tra xem văn bản này có xuất hiện trong câu hướng dẫn hay không. Nếu ảnh và câu hướng dẫn được ghép đúng bước, văn bản tại vị trí chạm sẽ xuất hiện trong câu hướng dẫn thường xuyên hơn so với trường hợp cố ý ghép lệch một bước.

Trong 400 bước được kiểm tra, 193 bước có văn bản tại vị trí chạm xuất hiện trong câu hướng dẫn, tương ứng 48%. Với dữ liệu cố ý ghép lệch một bước, 311 trường hợp còn đủ dữ liệu để tạo cặp so sánh. Trong số này, 61 trường hợp khớp, tương ứng 20%. Tỉ lệ khớp của dữ liệu ghép đúng vì vậy cao khoảng 2,4 lần so với dữ liệu ghép lệch.

Kết quả kiểm tra không đủ để xác nhận từng bản ghi riêng lẻ, nhưng cho thấy cách ghép theo `(episode_id, step_id)` cho tỉ lệ khớp cao hơn rõ rệt so với trường hợp cố ý ghép lệch bước.

3.3 Quy mô và phân chia dữ liệu

Các kết quả executability ở Chương 5 và Chương 6 được tính trên nhóm bước có thao tác chạm trong Bảng 3.2; các loại bước còn lại được phân tích riêng khi cần.

Dữ liệu được chia theo tác vụ, nghĩa là tất cả các bước của cùng một tác vụ chỉ nằm trong một tập. Cách chia này tránh để các màn hình liên tiếp của cùng một chuỗi thao tác xuất hiện ở cả tập huấn luyện và tập kiểm tra. Đối chiếu mã tác vụ cho thấy không có tác vụ nào xuất hiện ở cả hai tập.

Bảng 3.2: Quy mô tập huấn luyện và tập kiểm tra.

	Tập huấn luyện	**Tập kiểm tra**
Số bước	64.567	6.958
Số bước có thao tác chạm	41.191 (63,8%)	4.463 (64,1%)
Số tác vụ	12.895	1.432
Độ phủ OCR	100%	100%

Tập kiểm định nội bộ. S1 ban đầu được huấn luyện trên toàn bộ tập huấn luyện ở Bảng 3.2. Sau khi giai đoạn này hoàn tất, 1.567 bước được tách theo tác vụ để tạo tập kiểm định nội bộ; nếu một tác vụ được chọn thì toàn bộ các bước của tác vụ đó đều được đưa vào tập này. 63.000 bước còn lại được dùng cho các giai đoạn sau. Tập kiểm định nội bộ chỉ dùng để xếp hạng checkpoint của mô hình học tăng cường với phần thưởng SPICE và lựa chọn điều kiện của ACE (Mục 4.5 và Mục 4.6). Do S1 đã được huấn luyện với 1.567 bước này trước khi tách, điểm trên tập kiểm định nội bộ không được dùng làm kết quả đánh giá chính của luận văn.

Quan hệ với cách chia chính thức của AndroidControl. Tập huấn luyện và tập kiểm tra của đề tài được lấy theo cách chia của bản phân phối có ảnh từ `ckg`, không theo cách chia chính thức của AndroidControl. Trong các tác vụ của tập kiểm tra, 1.287 tác vụ thuộc phần huấn luyện chính thức của AndroidControl, 131 thuộc phần kiểm tra và 14 thuộc phần kiểm định. Tuy vậy, tập huấn luyện và tập kiểm tra của đề tài vẫn không trùng nhau về tác vụ. Vì thế, hai tập này vẫn phù hợp để so sánh các mô hình theo cùng cách đánh giá trong luận văn, nhưng kết quả không tương đương với kết quả trên tập kiểm tra chính thức của AndroidControl. Trong các chương sau, tập này được gọi là *tập kiểm tra của đề tài*.

3.4 Xây dựng thông tin đầu vào từ giao diện

Ảnh màn hình và văn bản OCR là hai nguồn thông tin được đưa vào mô hình. Ảnh cung cấp thông tin thị giác, còn OCR bổ sung phần chữ hiển thị trên giao diện. Cây trợ năng chỉ được dùng khi xây dựng dữ liệu và thực hiện một số phân tích, không được

đưa vào mô hình khi suy luận ở Chương 4. Văn bản OCR được giữ nguyên từ dữ liệu nguồn, không được sửa thủ công theo từng màn hình.

3.5 Dữ liệu phục vụ phương pháp đề xuất

Dữ liệu được sử dụng cho bốn phần của phương pháp đề xuất: huấn luyện S1, học tăng cường, học thêm mô hình sinh câu ứng viên của ACE và xây dựng kho truy hồi ACE. Mục này làm rõ dữ liệu dùng cho từng phần; chi tiết huấn luyện, truy hồi và lựa chọn đầu ra được trình bày ở Chương 4.

Tập huấn luyện có giám sát cho S1. S1 được huấn luyện trên toàn bộ tập huấn luyện ở Bảng 3.2 để sinh câu hướng dẫn theo bước của AndroidControl. Trong tập này, 122 bản ghi (0,19%) có câu hướng dẫn rỗng ngay từ nguồn và vẫn được giữ trong dữ liệu ban đầu; 64.445 bản ghi còn lại có câu hướng dẫn không rỗng. S1 được dùng làm mô hình khởi tạo cho các giai đoạn tiếp theo của phương pháp đề xuất.

Dữ liệu cho giai đoạn học tăng cường với phần thưởng SPICE. Phần dữ liệu còn lại sau khi tách tập kiểm định nội bộ ở Mục 3.3 được dùng cho các giai đoạn huấn luyện tiếp theo. Giai đoạn học tăng cường sử dụng prompt và câu tham chiếu từ phần dữ liệu này; câu tham chiếu được dùng để tính phần thưởng SPICE. Cách lấy mẫu và số bước cập nhật được trình bày ở Mục 4.5.

Dữ liệu để học thêm mô hình sinh câu ứng viên của ACE. Ngoài kho truy hồi, ACE có một lượt tinh chỉnh có giám sát để mô hình học cách sử dụng khối ví dụ. Lượt này sử dụng 3.991 bước có ảnh đã được chuẩn bị cho giai đoạn huấn luyện. Quy mô 3.991 phản ánh phần dữ liệu ảnh khả dụng ở giai đoạn này, không phải một tiêu chí chọn mẫu của ACE. Thiết lập huấn luyện được trình bày ở Mục 4.6.

Kho truy hồi cho ACE. Kho truy hồi ACE được xây dựng từ cùng phần dữ liệu còn lại sau khi tách tập kiểm định nội bộ. Vì mỗi bản ghi trong kho cần một câu hướng dẫn để làm ví dụ, 120 bản ghi có `target_instruction` rỗng được loại. Hai bản ghi rỗng còn lại trong tổng số 122 bản ghi nêu trên nằm trong tập kiểm định nội bộ. Kho cuối cùng gồm 62.880 bước thuộc 12.542 tác vụ. Kho không chứa tác vụ nào của tập kiểm tra của đề tài, nên ACE không truy cập câu tham chiếu của bước đang được đánh giá. Cách truy hồi được trình bày ở Mục 4.6.

3.6 Đặc điểm dữ liệu ảnh hưởng đến diễn giải kết quả

Bên cạnh cách chia theo tác vụ, ba đặc điểm của dữ liệu cần được lưu ý khi đọc các kết quả ở Chương 6.

Mục tiêu tác vụ bị cắt ở nguồn. Trong dữ liệu nguồn, 99,0% mô tả mục tiêu tác vụ bị cắt giữa một cụm từ. Vì vậy, ở phần lớn đầu vào, mô hình không nhận được đầy đủ mô tả của mục tiêu tác vụ. Luận văn không đo riêng mức ảnh hưởng của phần thông tin bị mất này đến kết quả.

Trùng lặp cách diễn đạt. Luận văn so sánh toàn bộ câu tham chiếu của tập kiểm tra với 64.445 câu hướng dẫn không rỗng ở tập huấn luyện. Khi chỉ loại khoảng trắng ở đầu và cuối chuỗi, 45,5% câu kiểm tra xuất hiện nguyên văn ít nhất một lần trong tập huấn luyện. Khi xét các cụm bốn token liên tiếp, 77,7% câu kiểm tra có ít nhất một cụm đã xuất hiện trong tập huấn luyện. Đây là sự lặp lại về cách diễn đạt chứ không phải trùng tác vụ, vì hai tập không có mã tác vụ chung. Một phần tỉ lệ trùng cụm bốn token có thể đến từ các khuôn câu thường gặp trong hướng dẫn giao diện. Các số liệu này chỉ cho thấy mức độ lặp về cách diễn đạt giữa hai tập. Chúng chưa đủ để xác định ACE hay các mô hình khác được lợi bao nhiêu từ hiện tượng này.

Ứng dụng đã thấy và chưa thấy. Tên ứng dụng xác định được cho 45,0% số bước của tập kiểm tra. Trong số các bước này, 95,6% thuộc về ứng dụng đã xuất hiện trong tập huấn luyện; nếu tính theo số ứng dụng riêng biệt, tỉ lệ là 91,8%. Vì vậy, phần dữ liệu xác định được ứng dụng chủ yếu đánh giá các tác vụ mới trên những ứng dụng mô hình đã gặp trong tập huấn luyện, thay vì tập trung vào ứng dụng hoàn toàn mới. Các bước không xác định được tên ứng dụng mang nhãn "không biết" và không được xem là ứng dụng chưa thấy. Do đó, các phân tích theo ứng dụng đã thấy/chưa thấy ở Chương 6 chỉ sử dụng phần dữ liệu xác định được ứng dụng.

Các nhãn mô tả phần tử, tập cặp ưu tiên và danh sách ứng viên chỉ phục vụ các phương án đã khảo sát trước phương pháp cuối. Cách xây dựng và kiểm tra các dữ liệu này được trình bày cùng từng phương án ở Phụ lục A.