Chương 5

Độ đo khả năng thực hiện theo hướng dẫn

Chương này xây dựng và đánh giá độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability. Khác với các độ đo chỉ dựa trên mức độ tương đồng với một câu chuẩn, executability xem xét liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử cần thao tác và loại thao tác tương ứng hay không. Chương trước hết trình bày định nghĩa và tiêu chí xác định một dự đoán đúng, sau đó đánh giá độ tin cậy của công cụ định vị, thiết lập các mốc tham chiếu cho thang điểm và kiểm tra độ nhạy, độ ổn định của độ đo. Phần cuối trình bày phương pháp phân tích thống kê được sử dụng trong các chương thực nghiệm.

5.1 Định nghĩa

Với mỗi bước có thao tác chạm, độ đo sử dụng năm đại lượng. s là câu hướng dẫn cần đánh giá. Nếu một phương án đã thử sinh thêm dòng mô tả phần tử trước câu (Phụ lục A), phần này được loại bỏ trước khi tính điểm. I là ảnh màn hình và g là tọa độ chạm của người dùng. E là tập các phần tử cạnh tranh trên màn hình, được lấy từ cây trợ năng sau bước gộp. Các tâm nằm trong ngưỡng 24 dp quanh g được xem là cùng nhóm với phần tử đích, còn các tâm cạnh tranh cách nhau dưới 24 dp được gộp lại. Dp là đơn vị độ dài của Android, không phụ thuộc mật độ điểm ảnh. Trên thiết bị được sử dụng, 24 dp tương ứng 63 điểm ảnh. G là mô hình định vị phần tử. Mô hình nhận ảnh cùng câu hướng dẫn và trả về tọa độ $p = G(I, s)$ của phần tử được câu quy chiếu

tới. G tách biệt với mô hình sinh đang được đánh giá và không nhận g làm đầu vào.

Một bước được tính là đúng khi thoả cả ba điều kiện:

- **(i) Khớp loại thao tác.** Loại thao tác của s, sau khi chuẩn hoá, phải cùng loại với thao tác của câu chuẩn. Có năm loại gồm chạm, gõ, cuộn, nhấn giữ và quay lại. Mười hai động từ (*tap, click, press, select, choose, touch, open, launch, go, navigate, visit, view*) được xếp vào loại chạm.

  Trong cách chuẩn hoá ban đầu, động từ được dò từ trái sang phải. Vì vậy, một số cụm có từ *back* như *go back, navigate back* và *press the back button* được xếp vào nhóm chạm. Các bảng chính giữ quy tắc này để nhất quán giữa các lượt đánh giá. Mục 5.12 kiểm tra riêng ảnh hưởng của việc điều chỉnh quy tắc.

- **(ii) Không đảo nghĩa.** s và câu chuẩn không được gọi tên hai trạng thái ngược nhau của cùng một điều khiển, chẳng hạn nút "bật thông báo" và "tắt thông báo". Điều kiện (iii) không bắt được lỗi này vì hai trạng thái nằm cùng một chỗ. Danh sách lập thủ công gồm chín cặp từ trái nghĩa (*on/off, enable/disable, show/hide, mute/unmute, expand/collapse, check/uncheck, select/deselect, start/stop, enabled/disabled*).

- **(iii) Định vị đúng.** p nằm trong vùng dung sai quy ước quanh g, $|p_x - g_x| \le \tau W$ và $|p_y - g_y| \le \tau H$, với W, H là bề ngang và chiều cao màn hình và $\tau = 0{,}14$ theo [2]. Đồng thời, không phần tử nào khác có tâm gần p hơn chính g:

$$\|p - g\| \le \|p - c(e)\| \quad \forall e \in E, \tag{5.1}$$

với $c(e)$ là tâm của phần tử e. Vùng gồm mọi điểm thoả điều kiện này được gọi là ô Voronoi quy ước quanh điểm chạm g (Hình 5.1). Như vậy, điểm do mô hình định vị trả về phải nằm trong vùng mà g không xa hơn bất kỳ tâm cạnh tranh nào.

Điểm executability là tỉ lệ các bước có thao tác chạm thoả cả ba điều kiện.

Điều kiện (iii) có hai chi tiết cần làm rõ. Vùng dung sai là hình chữ nhật, không phải hình tròn. Trên màn 1080×2400, vùng rộng ± 151 điểm ảnh theo chiều ngang và ± 336 điểm ảnh theo chiều dọc. Ô Voronoi được dựng quanh điểm chạm g thay vì

tâm hộp của phần tử chứa g. Cách đánh giá chính dùng tâm các phần tử để xác định vùng cạnh tranh, còn các tiêu chí dựa trên hộp bao được phân tích riêng ở Mục 5.12.

Vai trò của mô hình định vị và phạm vi của độ đo. Tọa độ chạm của người dùng được dùng làm mốc đối chiếu. Mô hình G không được tinh chỉnh trong đề tài và chỉ có nhiệm vụ suy ra một tọa độ từ ảnh cùng câu hướng dẫn. Tọa độ này sau đó được so sánh với g theo các điều kiện ở trên. Executability tập trung vào một khía cạnh cụ thể của chất lượng hướng dẫn, đó là câu có cung cấp đủ thông tin để xác định đúng phần tử và đúng thao tác hay không. Các khía cạnh ngôn ngữ và trải nghiệm sử dụng được xem xét bằng các phân tích bổ sung thay vì được gộp vào cùng một điểm số.

5.2 Tiêu chí xác định dự đoán đúng và giới hạn của tiêu chí dung sai quy ước

Điều kiện ô Voronoi chặt hơn tiêu chí dung sai quy ước nhưng cũng phức tạp hơn. Vì vậy, chúng tôi so sánh hành vi của hai tiêu chí trên 250 bước có thao tác chạm (Bảng 5.1). Hai tình huống được dùng để phân biệt vai trò của tiêu chí: dự đoán chỉ lệch nhẹ so với điểm chạm và dự đoán bị chuyển sang phần tử lân cận sai.

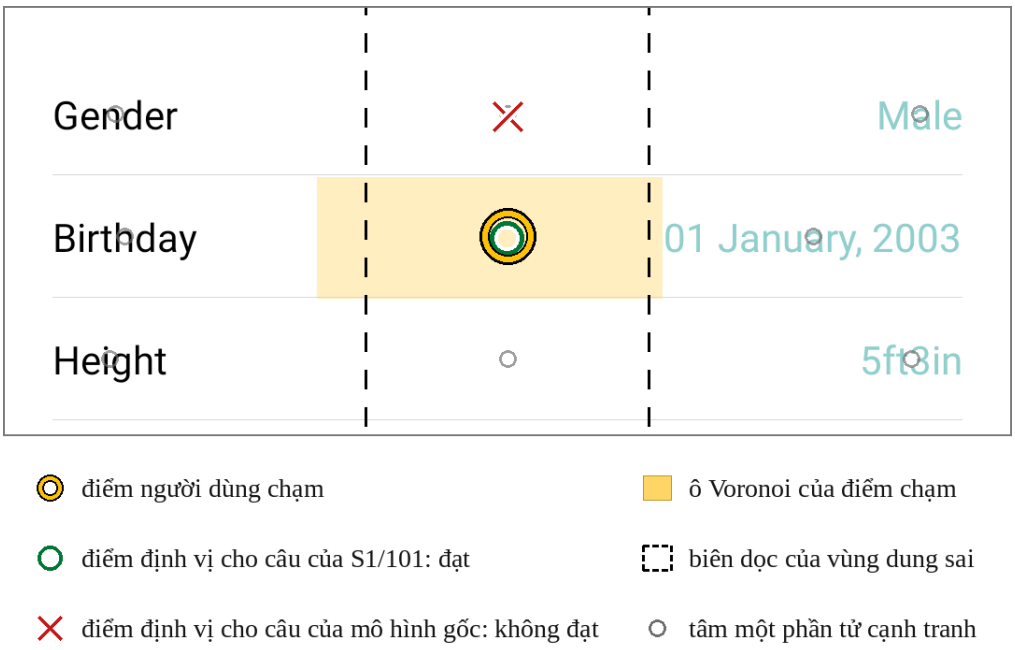
Bảng 5.1: So sánh các tiêu chí xác định dự đoán đúng trong hai tình huống tổng hợp: dự đoán lệch nhẹ và dự đoán bị chuyển sang phần tử lân cận sai. Mỗi tỉ lệ tính trên 1.000 lượt: 250 bước có thao tác chạm, mỗi bước dịch điểm dự đoán bốn lần theo hướng ngẫu nhiên. Cột "Khoảng phân tách" là chênh lệch giữa tỉ lệ chấp nhận hai tình huống.

Tiêu chí	Chấp nhận khi lệch 3%	Chấp nhận khi sai nút lân cận	Khoảng phân tách
Cửa sổ dung sai ± 14% theo từng trục	100,0%	84,3%	≈ 16 điểm
Ô Voronoi	99,7%	**2,8%**	≈ 97 điểm

Tiêu chí dung sai quy ước vẫn chấp nhận phần lớn dự đoán bị chuyển sang nút lân cận, vì 63,2% số bước có ít nhất một phần tử khác nằm trong vùng dung sai của phần tử cần chạm. Ngược lại, tiêu chí ô Voronoi chỉ chấp nhận 2,8% các dự đoán sai nút lân cận nhưng vẫn giữ tỉ lệ chấp nhận 99,7% khi điểm chỉ lệch 3%. Vì vậy tiêu chí ô

Voronoi được chọn làm tiêu chí chính.

Mức 2,8% áp dụng cho tình huống tổng hợp này, còn các điểm lệch nhẹ trong cùng vùng tương tác được xem xét riêng ở Mục 5.7. Cách gộp các tâm gần nhau chủ yếu loại các tâm cùng thuộc một phần tử. Trong 8,2% số bước, phép gộp cũng có thể hợp nhất các tâm thuộc những phần tử khác nhau. Chúng tôi báo cáo thêm tiêu chí dung sai và các tiêu chí dựa trên hộp phần tử để đối chiếu với kết quả chính.



Hình 5.1: Một bước mà hai tiêu chí đánh giá cho hai kết quả khác nhau. Người dùng chạm dòng *Birthday*. Câu của S1 dẫn mô hình định vị tới đúng dòng đó. Câu của mô hình gốc tả dòng *Gender* ngay phía trên, nên điểm trả về lệch 128 điểm ảnh, vẫn trong vùng dung sai quy ước. Tiêu chí dung sai vẫn xem dự đoán là đúng, còn tiêu chí ô Voronoi nhận ra câu đang quy chiếu sang một dòng khác. Hai đường nét đứt là biên trái và phải của vùng dung sai, biên trên và dưới nằm ngoài phần ảnh được cắt.

Kết quả trên điểm do mô hình định vị trả về cũng phù hợp với lựa chọn này. Trên 300 bước của Mục 5.4, khi nhận câu chuẩn, tiêu chí ô Voronoi cho điểm mọi bước có sai số định vị dưới 3% bề ngang màn ($n = 188$) và không cho điểm bước nào có sai số trên 14% ($n = 63$).

5.3 Mô hình định vị dùng làm công cụ đo

UGround-V1-2B [5] được chọn làm công cụ định vị chính vì mô hình có trọng số công khai, được phát triển cho bài toán GUI grounding và có thể trả về trực tiếp tọa độ phần tử từ ảnh cùng mô tả văn bản. Trước khi sử dụng cho executability, sai số định vị của mô hình được kiểm tra trong tương quan với khoảng cách giữa các phần tử trên màn hình ở Mục 5.4.

UGround được xây dựng trên Qwen2-VL và dữ liệu huấn luyện có sử dụng 47 nghìn phần tử được gán nhãn từ AndroidControl [5]. Do tập kiểm tra của đề tài được lấy từ một bản phân phối khác của AndroidControl, chúng tôi bổ sung các phép kiểm theo phần chia chính thức và đánh giá chéo bằng những công cụ khác ở Mục 5.9 và Mục 5.10. Các phép kiểm này được dùng để xem liệu thứ hạng và chiều của các chênh lệch chính có được giữ khi thay đổi công cụ đánh giá hay không.

Khi tách 4.463 bước có thao tác chạm theo phần chia chính thức của AndroidControl, điểm số giữa hai nhóm gần như giữ nguyên. Câu chuẩn đạt 75,9% trên phần huấn luyện chính thức và 74,0% trên phần kiểm tra cùng kiểm định, S1 đạt 59,1% và 59,3%, còn mô hình gốc đạt 47,7% và 46,7%. Khoảng tin cậy của hai phần chồng nhau ở cả ba loại câu, nên không xuất hiện mức tăng riêng trên phần huấn luyện chính thức. Phân tích này được dùng cùng các đánh giá chéo ở Mục 5.9 và Mục 5.10 để kiểm tra độ ổn định của kết luận. Prompt cung cấp cho G được giữ nguyên theo trang giới thiệu mô hình của nhóm tác giả.

5.4 Kiểm tra độ chính xác của công cụ đo

Vì độ tin cậy của executability phụ thuộc trực tiếp vào độ chính xác của mô hình định vị G, mô hình này được kiểm tra trước khi dùng làm công cụ đánh giá các mô hình sinh câu. Sai số định vị được xem xét trong tương quan với khoảng cách giữa các phần tử giao diện. Biên dung sai được định nghĩa là nửa khoảng cách từ điểm chạm g tới tâm phần tử cạnh tranh gần nhất sau khi gộp. Trên 1.496 bước có thao tác chạm, biên dung sai có trung vị 67 điểm ảnh (6,2% bề ngang) và phân vị thứ mười là 39 điểm ảnh (3,6%), nên sai số cỡ 3% bề ngang (khoảng 32 điểm ảnh) vẫn nhỏ hơn cả phân vị thứ

mười. Tọa độ chạm trong AndroidControl cũng phần lớn nằm rất gần tâm phần tử: 79,4% số điểm chạm cách một tâm không quá 1,5 điểm ảnh. Tỉ lệ loại nhầm là 0% ở mức sai số 3%, 7,5% ở mức 5%, 24,1% ở mức 8% và tăng mạnh lên 55% ở mức sai số 13%.

Kết quả đo. Trên 300 bước của tập kiểm tra, khi đầu vào là câu chuẩn, UGround-V1-2B có sai số trung vị bằng 0,7% bề ngang màn hình và 62,7% số bước có sai số dưới 3%. Các phân vị 25, 75 và 90 lần lượt là 0,2%, 8,8% và 36,3%. Phần lớn dự đoán vì vậy tập trung gần phần tử mục tiêu. Do công cụ định vị vẫn có một số trường hợp sai lệch lớn, điểm của câu chuẩn được sử dụng như mốc thực nghiệm của toàn bộ quy trình đánh giá, thay vì được xem là mức tối đa của chất lượng câu.

5.5 Mốc tham chiếu của thang điểm

Để có cơ sở diễn giải điểm executability, cùng một quy trình đánh giá được áp dụng cho một số loại câu có vai trò tham chiếu khác nhau. **Mốc tham chiếu** được xác định bằng câu hướng dẫn do người chú thích viết cho chính bước đang xét. Trên toàn bộ 4.463 bước có thao tác chạm, các câu này đạt 75,7% executability, với khoảng tin cậy 95% [74,1; 77,3] (Mục 5.13). Nếu dùng tiêu chí dung sai, điểm tương ứng là 84,3% [82,9; 85,6].

Điểm 75,7% được dùng như mốc thực nghiệm của câu do người chú thích viết khi đi qua cùng quy trình đánh giá. Có 148 bước mà câu chuẩn không đạt nhưng câu của mô hình gốc hoặc S1 lại đạt. Nếu xét cả ba loại câu, 3.527 bước, tương ứng 79,1%, đạt theo ít nhất một loại câu. Vì vậy, mốc 75,7% được dùng để đặt kết quả của các mô hình vào bối cảnh, không phải như một trần lý thuyết. Cách đối chiếu kết quả hệ thống với một mốc từ con người cũng được sử dụng trong nghiên cứu sinh chỉ dẫn điều hướng của Zhao và cộng sự [37].

Ở chiều ngược lại, **mốc tham chiếu dưới** được khảo sát bằng các câu mang rất ít hoặc không mang thông tin quy chiếu. Trên một mẫu ngẫu nhiên 800 bước, câu chuẩn đạt 74,9%, S1 đạt 58,8% và Base đạt 48,6%. Cùng mẫu này, câu chung chung "*Tap the button.*" chỉ đạt 12,0% [9,7; 14,4], còn câu chuẩn lấy từ một màn hình khác đạt 6,1% [4,5; 7,9].

Trường hợp	Câu đưa cho mô hình định vị	Điểm	KTC 95%
Câu chuẩn	câu của chính bước đang xét	74,9	-
S1	mô hình đã tinh chỉnh	58,8	-
Base	mô hình chưa tinh chỉnh	48,6	-
Câu chung chung	"*Tap the button.*"	12,0	[9,7; 14,4]
Câu của màn hình khác	câu chuẩn của một bước khác	6,1	[4,5; 7,9]

Hai mức 12,0% và 6,1% là các mốc thực nghiệm, được dùng để minh họa điểm số khi thông tin quy chiếu bị giảm đáng kể. Tỉ lệ 40,0% số bước mà câu chuẩn, S1 và Base cùng đạt không được dùng như một mức điểm nền vì khi nội dung quy chiếu bị loại bỏ hoặc thay bằng nội dung của màn hình khác, điểm giảm rõ rệt. Nếu dùng 12,0% như một mốc thực hành để chuẩn hoá dải 74,9–12,0 trên mẫu 800 bước, Base nằm ở 58,3% và S1 ở 74,4% dải này. Cách chuẩn hoá này chỉ phục vụ diễn giải và không thay đổi điểm executability gốc.

Executability tập trung vào khả năng xác định đúng phần tử và thao tác. Vì vậy, ở Chương 6, điểm này được trình bày cùng các độ đo dựa trên câu chuẩn để cung cấp thêm góc nhìn về chất lượng câu đầu ra.

5.6 Độ nhạy với thông tin quy chiếu

Các mốc dưới ở Mục 5.5 cho thấy câu chung chung hoặc câu đúng văn phong nhưng lấy từ màn hình khác nhận điểm thấp. Phần này xem xét trực tiếp hơn mức thay đổi của điểm số khi chỉ loại bỏ một phần thông tin quy chiếu khỏi câu chuẩn.

Vai trò của tên phần tử so với vị trí.

Hai biến đổi dưới đây được áp dụng cho các câu có thành phần tương ứng: biến đổi thứ nhất bỏ tên phần tử nhưng giữ mệnh đề vị trí, còn biến đổi thứ hai bỏ mệnh đề vị trí nhưng giữ tên phần tử. Hai nhóm bước có kích thước gần bằng nhau nên có thể đối chiếu trực tiếp.

Biến đổi	n	Trước → sau biến đổi	Chênh lệch
Bỏ tên phần tử, giữ vị trí	193	89,6 → 61,1	**−28,5**
Bỏ mệnh đề vị trí, giữ tên	198	89,4 → 85,9	**−3,5**

Khi bỏ tên phần tử, $b = 58$ bước chuyển từ đạt sang không đạt và $c = 3$ bước theo chiều ngược lại. Kiểm định McNemar (Mục 5.13) cho $\chi^2 = 47{,}8$, $p < 0{,}001$. Mức giảm do bỏ tên phần tử lớn gấp khoảng tám lần mức giảm do bỏ mệnh đề vị trí. Cùng với hai mốc thực nghiệm ở Mục 5.5, kết quả cho thấy độ đo phản ứng rõ với việc thay đổi thông tin quy chiếu, đặc biệt là tên phần tử.

Diễn giải kết quả trên tập con chịu tác động. Biến đổi bỏ tên phần tử áp dụng được cho 193 trong 800 bước (24,1%). Vì vậy, mức thay đổi được báo cáo trên chính nhóm câu thực sự chịu biến đổi, nơi điểm giảm 28,5 điểm. Cách báo cáo này cũng được áp dụng cho các phép biến đổi chỉ tác động lên một phần dữ liệu.

5.7 Kiểm tra bằng biến đổi lỗi có kiểm soát

Độ đo còn được kiểm tra bằng cách chủ động tạo các trường hợp đúng hoặc sai đã biết trước và xem kết quả đánh giá có thay đổi theo hướng mong đợi hay không [17]. Bảng 5.2 gồm mười kiểm tra. Các kiểm tra về diễn đạt, loại thao tác và vị trí được thực hiện trên một mẫu 398 bước có thao tác chạm. Các kiểm tra về nội dung nhập, hướng cuộn và phủ định được áp dụng trên toàn bộ những bước phù hợp trong tập kiểm tra. Vì vậy, số trường hợp n khác nhau giữa các dòng và có thể lớn hơn 398. Ba dòng đầu báo tỉ lệ loại nhầm trường hợp đúng, còn bảy dòng sau báo tỉ lệ phát hiện trường hợp sai.

Diễn giải kết quả. Một số biến đổi cho kết quả gần như xác định bởi chính cách tạo lỗi, chẳng hạn thay loại thao tác hoặc hướng. Hai trường hợp cần xem kỹ hơn là chuyển sang phần tử lân cận và phủ định câu, vì chúng kiểm tra trực tiếp khả năng phân biệt giữa các phần tử gần nhau và khả năng xử lý thay đổi ngữ nghĩa.

Phần tử kề gần. Tỉ lệ ở dòng này phản ánh trực tiếp quy tắc gộp các phần tử có tâm cách nhau dưới 24 dp (Mục 5.1). Ngưỡng này tương ứng khoảng 63 điểm ảnh,

Bảng 5.2: Kiểm tra độ đo bằng các biến đổi có kết quả mong đợi đã biết trước. Ba dòng đầu là tỉ lệ độ đo loại nhầm một câu vẫn đúng, nên càng thấp càng tốt. Các dòng còn lại là tỉ lệ độ đo phát hiện được một câu đã bị làm sai, nên càng cao càng tốt. Cặp trạng thái đối lập là cặp chưa có trong bảng ánh xạ.

Trường hợp kiểm tra	**Tỉ lệ**	**n**
Loại nhầm câu diễn đạt khác	0,0%	398
Loại nhầm ở điều kiện thao tác	0,0%	398
Loại nhầm ở phép đảo nghĩa	0,0%	398
Phát hiện sai phần tử kề gần	33,1%	121
Phát hiện sai phần tử kề xa	99,6%	233
Phát hiện sai phần tử ở rất xa	100,0%	397
Phát hiện cặp trạng thái đối lập chưa có trong bảng ánh xạ	0,0%	12
Phát hiện sai loại thao tác	100,0%	369
Phát hiện sai nội dung	91,1%	494
Phát hiện sai hướng	100,0%	755

gần với biên dung sai trung vị 67 điểm ảnh (Mục 5.4). Vì vậy, độ đo tập trung vào việc phân biệt các phần tử đủ tách biệt trên giao diện và không xem các sai lệch rất nhỏ bên trong cùng vùng tương tác là một lỗi định vị khác phần tử.

Các cặp trạng thái đối lập ngoài bảng. Điều kiện đảo nghĩa được xây dựng theo danh sách các cặp trạng thái định nghĩa trước. Vì vậy, 12 trường hợp thuộc các cặp chưa có trong danh sách không được nhận diện bởi điều kiện này. Ba trường hợp `enable` → `disable` không thuộc nhóm trên vì cặp `enable`/`disable` đã có trong bảng. Mười hai trường hợp này xác định rõ phạm vi của thành phần kiểm tra đảo nghĩa trong executability.

5.8 Độ ổn định trước các biến thể diễn đạt

Một độ đo phù hợp cần tương đối ổn định trước các biến thể diễn đạt giữ nguyên nội dung. Jandial và cộng sự [18] chỉ ra rằng mô hình định vị có thể nhạy với cách diễn đạt của câu. Vì vậy, chúng tôi xây dựng các biến thể của câu chuẩn và đánh giá lại executability trên mẫu 800 bước.

Bốn biến thể được xây dựng bằng tiêu chí xác định, không sử dụng mô hình ngôn ngữ. Ba biến thể đầu giữ nguyên nội dung chính gồm thay động từ thao tác (ví dụ *click* thành *tap*), đảo thứ tự hai mệnh đề và kết hợp hai biến đổi này. Biến thể cuối bỏ mệnh đề vị trí. Kết quả của biến thể này đã được phân tích ở Mục 5.6 và được đưa vào đây làm mốc đối chiếu với các thay đổi giữ nguyên nội dung.

Bảng 5.3: Điểm khi viết lại câu chuẩn theo bốn biến thể rồi đánh giá lại, tính trên phần bị tác động. Ở cột McNemar, *b* là số bước chuyển từ đạt sang không đạt sau khi viết lại, *c* là chiều ngược lại. Giá trị p in đậm là giá trị nhỏ hơn 0,05, chưa hiệu chỉnh cho bốn kiểm định.

Biến thể	Số câu viết lại	Trên phần bị tác động	McNemar
Đổi động từ thao tác	725 (90,6%)	76,8 → 77,0	b=13, c=14, p=1,000
Đảo trật tự mệnh đề	211 (26,4%)	89,6 → 90,0	b=0, c=1, p=1,000
Đổi động từ và đảo trật tự	203 (25,4%)	90,1 → 91,1	b=0, c=2, p=0,480
Bỏ mệnh đề vị trí	198 (24,8%)	89,4 → 85,9	b=8, c=1, **p=0,046**

Gộp ba biến thể giữ nguyên nghĩa (Bảng 5.3), 30 trong 1.139 câu viết lại (2,6%) làm thay đổi kết quả đánh giá. Hiệu ròng là +0,35 điểm, với khoảng tin cậy 95% [−0,59; +1,29]. So với mốc bỏ mệnh đề vị trí ở Mục 5.6, độ đo tương đối ổn định trước những thay đổi bề mặt được khảo sát nhưng vẫn phản ứng khi thông tin định vị bị loại bỏ.

Phạm vi của phép kiểm. Công cụ đo giữ kết quả ổn định trước việc thay động từ và đảo trật tự câu trong các biến đổi trên. Các cách viết lại này thay đổi bề mặt câu nhưng giữ nguyên phần mô tả phần tử và lớp thao tác. Vì vậy, phép kiểm tập trung vào độ ổn định trước các biến đổi này. Các dạng thay đổi trực tiếp tên gọi của phần tử nằm ngoài phạm vi của thí nghiệm tại mục này.

5.9 Đánh giá chéo bằng mô hình định vị thứ hai

Để kiểm tra độ ổn định của kết luận khi thay công cụ định vị, chúng tôi đánh giá lại một số chênh lệch bằng UI-Venus-Ground-7B [6]. Mô hình này có trọng số công khai và đạt kết quả tốt trên các bộ chuẩn định vị giao diện di động. So sánh được thực hiện trên 2.532 bước mà các mô hình sinh ra câu khác nhau. Những bước có đầu ra giống

nhau không ảnh hưởng đến chênh lệch giữa các mô hình.

Do hai công cụ sử dụng thang điểm khác nhau, phần này tập trung vào chênh lệch tương đối giữa các mô hình thay vì so sánh trực tiếp điểm tuyệt đối. Chênh lệch giữa S1 và mô hình gốc được dùng làm so sánh chính vì mức chênh tương đối lớn và mang dấu dương rõ ràng. Nếu công cụ thứ hai làm thu hẹp thang điểm đáng kể, chênh lệch này sẽ giảm tương ứng và các khác biệt nhỏ hơn sẽ trở nên khó diễn giải hơn.

Bảng 5.4: Chênh lệch giữa các mô hình trên cùng 2.532 bước, đánh giá bằng hai mô hình định vị khác nhau. Chênh lệch giữa mô hình mô tả phần tử (S2, một hướng đã thử ở Phụ lục A) và S1 được quy về mẫu số 4.463 để so sánh với các bảng khác. Hàng cuối là executability của câu chuẩn trên mẫu 300 bước dùng để kiểm tra mức trần của mỗi mô hình định vị, không phải trên toàn bộ 4.463 bước. Trong ngoặc vuông là khoảng tin cậy 95%.

So sánh	**UGround**	**UI-Venus**
S1 − mô hình gốc (Base), so sánh chính	+10,35 [+8,39; +12,40]	+9,68 [+7,60; +11,78]
Mô tả phần tử (S2) − S1	−1,93 [−3,06; −0,75]	−1,21 [−2,30; −0,12]
Câu chuẩn, mẫu 300 bước (điểm tuyệt đối)	70,0 [64,5; 75,3]	69,3 [63,8; 74,8]

So sánh S1 với Base. Chênh lệch giữa S1 và mô hình gốc là +10,35 điểm khi đánh giá bằng UGround và +9,68 điểm khi đánh giá bằng UI-Venus (Bảng 5.4). Việc chênh lệch gần như được bảo toàn sau khi thay công cụ đo cho thấy thứ hạng và độ lớn tương đối giữa hai mô hình khá ổn định trước lựa chọn mô hình định vị.

Kết quả trên một chênh lệch nhỏ. Chênh lệch giữa mô hình mô tả phần tử (S2) và S1 vẫn âm khi đánh giá bằng cả hai công cụ, và cận trên của khoảng tin cậy đều nhỏ hơn 0. Khi sử dụng UI-Venus, độ lớn của chênh lệch giảm so với UGround, phù hợp với việc thang điểm của UI-Venus thấp hơn trên cả ba mô hình. Kết quả đánh giá chéo vẫn giữ chiều của chênh lệch quan sát được.

Phương pháp đề xuất dưới UI-Venus. Phương pháp đề xuất, thành phần thứ nhất và hai lượt S1 được đánh giá thêm bằng UI-Venus trên đủ 4.463 bước. Mỗi cặp bước và câu chỉ được đánh giá một lần, nên các bước có câu giống nhau giữa hai mô hình cho cùng kết quả. GRPO-SPICE cao hơn S1/101 1,55 điểm và cao hơn S1/202 0,94 điểm. Sau ACE, các mức chênh tương ứng là 1,68 và 1,08 điểm. Khoảng tin cậy của cả bốn phép so đều nằm trên 0. Vì UI-Venus cũng được xây dựng trên họ Qwen, Mục 5.10 tiếp tục kiểm tra bằng một mô hình listener thuộc họ kiến trúc khác.

Bảng 5.5: Phương pháp đề xuất và hai lượt S1 khi đánh giá bằng UI-Venus trên 4.463 bước có thao tác chạm. Exec. là executability. Cột phải là chênh lệch ghép cặp, kèm khoảng tin cậy 95% bootstrap theo cụm (Mục 5.13).

Mô hình	Exec.	So sánh	Δ [KTC 95%]
S1/101	54,51	Phương pháp đề xuất − S1/101	+1,68 [+0,97; +2,42]
S1/202	55,12	Phương pháp đề xuất − S1/202	+1,08 [+0,28; +1,88]
GRPO-SPICE	56,06	Phương pháp đề xuất − GRPO-SPICE	+0,13 [−0,11; +0,39]
Phương pháp đề xuất	56,20	GRPO-SPICE − S1/101	+1,55 [+0,82; +2,30]
		GRPO-SPICE − S1/202	+0,94 [+0,14; +1,75]
		S1/202 − S1/101	+0,60 [−0,13; +1,34]

Bộ trỏ ngoài họ Qwen. Chúng tôi đánh giá thêm bằng Phi-Ground-4B [7], mô hình được xây dựng trên Phi-3.5-Vision. Theo báo cáo kỹ thuật, mô hình không dùng AndroidControl để huấn luyện. Dữ liệu được công bố gồm các tập con của OS-Atlas, SeeClick, E2ISynth, GUIAct, dữ liệu web và dữ liệu giao diện Windows/Office do người gán nhãn. Phi-Ground vì vậy cung cấp một phép kiểm bằng kiến trúc khác với UGround và UI-Venus. Ở nhánh Base, tệp dự đoán thiếu 7 trong 4.463 bước và các bước này được tính là không đạt. Kết quả định lượng được tổng hợp ở Chương 6.

5.10 Đánh giá chéo bằng mô hình listener thuộc họ kiến trúc khác

Các đánh giá ở những mục trước đều dựa trên bài toán định vị mở, trong đó mô hình nhận ảnh và câu hướng dẫn rồi trả về một tọa độ. Để kiểm tra độ ổn định của thứ hạng khi thay đổi cách đánh giá, chúng tôi sử dụng thêm Phi-4-multimodal-instruct [42], một mô hình ngôn ngữ thị giác không thuộc họ Qwen, làm listener theo dạng lựa chọn. Các phần tử tương tác được lấy từ cây trợ năng, khoanh vùng và đánh số theo phương pháp Set-of-Mark [43]. Mỗi màn hình có trung vị 15 phần tử. Phi-4 nhận câu hướng dẫn cùng ảnh đã đánh số và chọn phần tử mà câu hướng dẫn đề cập tới.

Listener không được cung cấp mục tiêu tác vụ hoặc lịch sử thao tác. Một dự đoán được tính là đúng khi phần tử được chọn chứa tọa độ chạm tham chiếu. Cách

đánh giá này gần với *comprehension accuracy* trong các nghiên cứu về sinh biểu thức quy chiếu [12, 13], nhưng được áp dụng cho bài toán lựa chọn phần tử giao diện như trong Mind2Web [9]. Chúng tôi không huấn luyện hoặc tinh chỉnh Phi-4 trên AndroidControl.

Bảng 5.6: Tỉ lệ Phi-4 chọn đúng phần tử trong số các phần tử được đánh số trên ảnh, trên 4.463 bước có thao tác chạm. Với S1/202, chỉ 1.652 bước có câu khác S1/101 được đánh giá lại, các bước còn lại dùng kết quả của S1/101. Dấu – cho biết KTC chưa được báo cáo cho nhánh tương ứng.

Câu đưa cho mô hình listener	**Chọn đúng**	**KTC 95%**
Câu chuẩn	54,94	–
S1/202	45,53	–
Phương pháp đề xuất	45,33	[43,57; 47,12]
GRPO-SPICE	45,33	[43,59; 47,11]
S1/101	44,63	[42,88; 46,37]
Mô hình gốc (Base)	38,23	[36,53; 39,93]

Trên đủ 4.463 bước (Bảng 5.6), mô hình gốc đạt 38,23% còn S1/101 đạt 44,63%, chênh +6,41 điểm. GRPO-SPICE đạt 45,33%, cao hơn S1/101 0,69 điểm [+0,02; +1,40]. ACE cũng đạt 45,33% và cho kết quả tương đương GRPO-SPICE. S1/202 đạt 45,53%, gần với hai cấu hình này. Listener ngoài họ Qwen vì vậy vẫn giữ chiều Base < S1/101 < GRPO-SPICE, trong khi chênh lệch giữa các mô hình đã tinh chỉnh nhỏ hơn đáng kể so với khoảng cách S1–Base.

Khi lặp lại đánh giá trên 200 bước, mô hình listener cho kết quả hoàn toàn nhất quán giữa các lần chạy. Mức đồng thuận theo từng bước giữa listener và UGround ở mức vừa phải (κ từ 0,25 đến 0,44 tùy mô hình). Hai công cụ vì thế có thể khác nhau ở từng bước cụ thể nhưng vẫn duy trì cùng thứ hạng giữa các hệ thống.

Phi-4 chỉ nhận câu hướng dẫn và ảnh đã đánh số, không có thêm mục tiêu tác vụ hay lịch sử thao tác như thiết lập executability. Vì vậy, listener này được dùng như một phép kiểm độc lập cho thứ hạng và chiều của các chênh lệch chính, còn executability vẫn là chỉ số chính.

5.11 So sánh với các độ đo dựa trên câu chuẩn

Để đối chiếu executability với các cách đánh giá dựa trên câu chuẩn ở Mục 2.6, chúng tôi khảo sát trực tiếp hai cách so sánh gồm so sánh chuỗi và độ tương đồng ngữ nghĩa. Với so sánh chuỗi, 97,5% các cách diễn đạt khác của cùng một nội dung trong tập khảo sát được xem là khác câu chuẩn.

Với độ tương đồng ngữ nghĩa, chúng tôi sử dụng 51 trường hợp viết tay: 25 cặp cùng phần tử nhưng khác cách gọi, 15 cặp khác phần tử có từ ngữ chồng lấn và 11 cặp khó liên quan đến trạng thái đối lập, số, hướng hoặc quan hệ cha–con. Phép thử dùng `bge-m3` [16] để tạo biểu diễn nhúng và độ tương đồng cosine để so sánh hai vế. Trong các cặp cùng phần tử, điểm cosine trung bình là 0,62. Ở 15 cặp khác phần tử có từ ngữ chồng lấn, trung bình là 0,67. Cặp `inbox` và `outbox`, dù là hai phần tử khác nhau, có điểm 0,76. Trong khi `search` và `magnifying glass`, hai cách gọi có thể quy chiếu cùng một phần tử, chỉ đạt 0,55. Các giá trị này cho thấy độ gần trong không gian nhúng không thay đổi theo cùng chiều với quan hệ quy chiếu trong tập khảo sát, nên không quan sát thấy một ngưỡng cosine có thể phân tách đáng tin cậy các cặp cùng phần tử và khác phần tử. Kết luận này chỉ áp dụng cho tập kiểm tra và mô hình nhúng nêu trên, không được dùng để suy rộng cho mọi mô hình nhúng ngữ nghĩa.

Hai phân tích trên cho thấy cách so sánh với một câu chuẩn và executability tập trung vào những khía cạnh khác nhau của câu đầu ra. Trên đầu ra thực tế của các mô hình, trong những câu được executability chấp nhận, 52,8% số câu của mô hình chưa tinh chỉnh có F1 trên các từ nội dung so với câu chuẩn dưới 0,5, so với 13,9% ở mô hình đã tinh chỉnh. Mức gần với câu chuẩn vì vậy chịu ảnh hưởng đáng kể bởi cách diễn đạt, còn executability tập trung vào phần tử và thao tác mà câu hướng tới.

Bảng 6.1 ở Chương 6 có thêm BLEU-4 [20], tính cho từng câu rồi lấy trung bình, và ROUGE-L [21], F1 của chuỗi con chung dài nhất. Với ba loại câu có chất lượng khác biệt rõ rệt (câu của mô hình gốc, của S1 và câu chuẩn), hai độ đo này và executability cho cùng thứ hạng. Vì vậy, các độ đo dựa trên câu chuẩn vẫn có thể phản ánh những khác biệt lớn giữa các mô hình.

Trong thiết lập này, các độ đo dựa trên câu chuẩn và executability bổ sung cho

nhau. Câu chuẩn đạt 100 điểm theo ROUGE-L và 96,1 điểm theo BLEU-4, trong khi executability của câu chuẩn là 75,7 và còn phân biệt được các bước đạt hoặc chưa đạt theo phần tử và thao tác. Với các mô hình đã tinh chỉnh có kết quả executability gần nhau, thứ hạng giữa các độ đo cũng có thể khác. Bảng 6.1 cho thấy executability, BLEU-4 và ROUGE-L không luôn xếp các cấu hình theo cùng thứ tự. Vì vậy, chúng tôi báo cáo song song các độ đo dựa trên câu chuẩn và executability, trong đó executability được dùng làm tiêu chí chính cho khả năng xác định phần tử và thao tác. Zhao và cộng sự [37] cũng thảo luận sự khác biệt giữa các độ đo khi đánh giá chỉ dẫn điều hướng có grounding và khuyến nghị SPICE khi có câu chuẩn.

5.12 Độ nhạy của kết luận theo tiêu chí đánh giá

5.12.1 Độ ổn định của thứ hạng và kết luận thống kê

Giá trị tuyệt đối của điểm số phụ thuộc vào tiêu chí dùng để xác định một dự đoán đúng. Khi đánh giá lại câu chuẩn, S1 và mô hình gốc trên 698 bước theo năm tiêu chí khác nhau, điểm tuyệt đối thay đổi tới 26 điểm (Bảng 5.7), nhưng thứ hạng giữa các mô hình vẫn được duy trì. Chênh lệch S1–Base dao động từ 9,5 đến 13,0 điểm và luôn lớn hơn đáng kể sai số chuẩn ghép cặp (Mục 5.13).

Bảng 5.7: Điểm của câu chuẩn và chênh lệch giữa S1 với mô hình gốc theo năm tiêu chí đánh giá (698 bước): đĩa Euclid, hình chữ nhật theo từng trục, ô Voronoi, ô Voronoi lấy hạt là tâm hộp chứa g, và hộp gần nhất. g là điểm chạm của người dùng.

	Đĩa	**Chữ nhật**	**Voronoi**	**Voronoi (hạt tâm hộp)**	**Hộp gần nhất**
Câu chuẩn	80,2	82,2	74,2	56,6	82,2
S1 − mô hình gốc (Base)	+12,6	+13,0	+11,7	+9,5	+13,0

Ảnh hưởng đến kết luận thống kê. Việc thay đổi tiêu chí đánh giá có thể dẫn tới kết luận thống kê khác nhau. Bảng 5.8 so sánh mô hình sau giai đoạn thưởng tọa độ (một hướng đã thử, Phụ lục A) với S1/101 theo ba tiêu chí, và kết luận thay đổi tùy tiêu chí.

Bảng 5.8: Kết luận thống kê theo ba tiêu chí cho cùng một phép so: mô hình sau giai đoạn thưởng tọa độ trừ S1/101, trên 4.463 bước có thao tác chạm. Cả ba tiêu chí đều yêu cầu đúng loại thao tác. Cột p là giá trị p trước hiệu chỉnh, cột cuối là kết luận sau khi hiệu chỉnh Holm cho ba kiểm định. Hàng vế khoảng cách AitW chỉ dùng điều kiện khoảng cách của tiêu chí AndroidInTheWild, không gồm điều kiện hộp phần tử, nên khác số AitW đầy đủ ở Bảng 6.7.

Tiêu chí	Δ	**p**	**Sau hiệu chỉnh Holm**
Cửa sổ $\pm$ 14% từng trục	+2,13	0,0003	còn ý nghĩa thống kê
Vế khoảng cách AitW	+1,99	0,0010	còn ý nghĩa thống kê
Ô Voronoi (executability)	+0,96	0,0860	không có ý nghĩa thống kê

Sự khác biệt giữa các kết luận phản ánh mức độ chặt khác nhau của từng tiêu chí. Executability yêu cầu câu dẫn tới đúng phần tử khi có các phần tử lân cận cạnh tranh, trong khi tiêu chí dung sai chấp nhận mọi điểm đủ gần tọa độ tham chiếu. Vì vậy, các câu chứa ít thông tin quy chiếu có xu hướng nhận điểm cao hơn theo tiêu chí dung sai. Chẳng hạn, câu chung chung "*Tap the button.*" đạt 12,00 với executability nhưng 20,50 theo tiêu chí dung sai. Vì vậy, chúng tôi trình bày song song các tiêu chí có tiền lệ trong công trình trước như các chỉ số bổ sung bên cạnh executability.

Ảnh hưởng của việc điều chỉnh quy tắc chuẩn hoá loại thao tác. Khi điều chỉnh riêng quy tắc nêu ở Mục 5.1, điểm của S1 giảm từ 59,12 xuống 58,81 và của Base từ 47,60 xuống 47,40. Chênh lệch S1–Base đổi từ 11,52 thành 11,41 điểm. Mức thay đổi nhỏ và không làm thay đổi kết luận của phép so sánh. Các bảng chính vẫn dùng quy tắc ban đầu để giữ nhất quán giữa toàn bộ lượt đánh giá.

5.12.2 Đối chiếu với các tiêu chí dùng trong bộ dữ liệu GUI

Tiêu chí hộp phần tử của AndroidControl. Phụ lục D.3 của bài gốc AndroidControl [1] coi một dự đoán là đúng khi tọa độ nằm trong hộp bao của phần tử cần chạm, vì chạm vào đâu trong phần tử thì phần tử cũng kích hoạt. Chúng tôi gọi cách đánh giá này là tiêu chí hộp phần tử. Hộp bao có sẵn trong nhãn của tập kiểm tra, nên tiêu chí này tính được từ các điểm mô hình định vị đã trả về (Bảng 5.9).

Thứ hạng giữa các mô hình không thay đổi, và chênh lệch giữa S1 với mô hình gốc là 11,9 điểm, gần tương đương mức chênh theo tiêu chí ô Voronoi. Trên mẫu 800

Bảng 5.9: Điểm theo tiêu chí hộp phần tử (Phụ lục D.3 của AndroidControl) trên 4.463 bước có thao tác chạm. Giai đoạn học ưu tiên và mô hình chọn ứng viên là hai hướng đã thử (Phụ lục A). Cột cuối yêu cầu thêm điều kiện điểm dự đoán nằm trong cửa sổ dung sai 14%. Hai hàng cuối là các mốc tham chiếu dưới, được tính trên mẫu 800 bước.

	Ô Voronoi	**Hộp phần tử**	**Hộp phần tử ∧ cửa sổ 14%**
Câu chuẩn	75,7	83,8	79,2
Giai đoạn học ưu tiên (MIN-DESC)	60,0	66,5	62,7
S1/101	59,1	65,5	61,7
Mô hình chọn ứng viên (Mục A.3.2)	56,1	62,4	58,6
Mô hình gốc (Base)	47,6	53,6	49,8
Câu chung chung (mốc dưới, mẫu 800)	12,0	14,1	12,1
Câu của màn hình khác (mốc dưới, mẫu 800)	6,1	8,6	6,6

bước, điểm của câu chuẩn tăng từ 74,9 lên 83,0 khi sử dụng tiêu chí hộp phần tử, trong khi các câu dùng làm mốc dưới tăng ít hơn. Khác biệt này liên quan đến việc dung sai phụ thuộc vào kích thước phần tử. Xét theo chiều dọc, chiều cao trung vị của hộp chỉ bằng 5,2% màn hình, chặt hơn đáng kể so với cửa sổ 14%.

Điểm 83,8 của câu chuẩn phản ánh cách tiêu chí hộp phần tử sử dụng hình học của hộp bao thay vì khoảng cách tới các tâm cạnh tranh. Phân tích cấu trúc hộp cho thấy khoảng 48% số bước sử dụng nút nhỏ nhất chứa điểm chạm, trong khi 78% mức tăng so với ô Voronoi tập trung ở các bước có hộp rộng hơn nửa màn hình. Trên các hàng danh sách, tiêu chí hộp cũng ít bị ảnh hưởng hơn bởi các mảnh chữ OCR nằm gần nhau. Vì vậy, kết quả theo hai tiêu chí được báo cáo song song để đối chiếu các mô hình dưới hai cách xác định phần tử khác nhau.

Tiêu chí AndroidInTheWild. Tiêu chí này được lấy từ mã đánh giá gốc của AndroidInTheWild [2], một bộ dữ liệu điều khiển thiết bị Android được sử dụng trong nhiều nghiên cứu về tác tử giao diện. Hai lần chạm được xem là tương ứng khi khoảng cách Euclid giữa hai điểm, trên hệ tọa độ chuẩn hoá về [0; 1], không vượt quá 0,14, hoặc khi cả hai điểm cùng nằm trong một khung phần tử được nới thêm 1,4 lần theo

cả chiều cao và chiều rộng. Chúng tôi bổ sung điều kiện đúng loại thao tác. Trong các bảng kết quả, biến thể gồm cả hai điều kiện này được gọi là *AitW đầy đủ*, còn phép đo chỉ dùng điều kiện khoảng cách được gọi là *về khoảng cách AitW*. Mã gốc xét mọi khung chú thích trên màn hình, trong khi dữ liệu chúng tôi sử dụng chỉ có khung của phần tử cần chạm, nên biến thể xấp xỉ này chỉ có thể cho điểm không cao hơn tiêu chí gốc. Trên mẫu 800 bước, khoảng điểm giữa câu chuẩn (90,8) và mốc dưới tương ứng là 64,9 điểm, rộng hơn mức 62,9 của executability. Tiêu chí này ít nhạy hơn với việc thiếu tên phần tử: câu bỏ tên nhưng giữ vị trí chỉ thấp hơn câu chuẩn 4,5 điểm, so với 6,9 điểm khi đánh giá bằng executability (Mục 5.6). Vì vậy, AitW đầy đủ được báo cáo song song với executability thay vì thay thế độ đo chính. Điểm của từng mô hình được trình bày ở Bảng 6.5.

Cận trên của AitW. Ở biến thể còn lại, việc xét khung được mở rộng tới mọi phần tử có thể chạm trên màn hình, lấy từ cây trợ năng và chỉ giữ các khung chiếm không quá nửa màn hình. Do đó tiêu chí gốc nằm giữa hai biến thể. Với biến thể cận trên, câu chuẩn đạt 96,2% nhưng câu chung chung cũng tăng lên 41,6% (mẫu 800 bước), nên khoảng phân tách chỉ còn 54,3 điểm, hẹp hơn cả executability. Vì vậy, kết quả AitW được trình bày cùng biến thể cận trên khi cần phân tích độ nhạy, còn AitW đầy đủ với hộp phần tử đích được dùng làm giá trị chính trong các bảng so sánh.

5.13 Phương pháp phân tích thống kê

Điểm. Điểm là tổng số bước đúng chia tổng số bước.

Khoảng tin cậy. Khoảng tin cậy của các phân tích chính được ước lượng bằng bootstrap phi tham số với 10.000 lần lấy mẫu theo cách gom cụm trình bày dưới đây. Ở mỗi lần lặp, các cụm được lấy mẫu lại có hoàn lại, sau đó điểm số được tính lại. Khoảng tin cậy được xác định từ các phân vị của phân bố thu được. Khi một phân tích sử dụng đơn vị gom cụm khác, cách tính được ghi rõ tại bảng tương ứng. Vì độ chính xác của bootstrap theo cụm phụ thuộc vào số lượng cụm [27], chúng tôi báo cáo cả số cụm cùng các khoảng tin cậy.

Tiêu chí gom cụm. Các bước xác định được ứng dụng được gom theo ứng dụng. Với những bước không xác định được ứng dụng, mỗi tác vụ được xem là một cụm riêng

để tránh gộp các tác vụ không liên quan chỉ vì cùng thiếu nhãn ứng dụng. Tổng cộng có 1.091 cụm, cụm lớn nhất gồm 58 bước. Số cụm hiệu dụng theo công thức Kish [28] là 454,3. Kết luận giữ ổn định khi thay cách gom cụm: khoảng tin cậy của mức chênh lệch giữa S1 và mô hình gốc là [+10,0; +13,1] với cách chính, cũng là [+10,0; +13,1] khi gom mọi bước theo tác vụ, và [+10,2; +13,8] khi dồn mọi bước không nhãn vào một cụm.

So sánh ghép cặp. Trong các so sánh executability chính, các mô hình được đánh giá trên cùng 4.463 bước có thao tác chạm nên các chênh lệch được phân tích theo cặp. Mỗi cặp mô hình được báo cáo bằng khoảng tin cậy ghép cặp và giá trị p của kiểm định McNemar (Mục 4.8), chỉ dựa trên các bước hai mô hình cho kết quả khác nhau, với b là số bước mô hình thứ nhất đạt còn mô hình thứ hai không đạt và c là chiều ngược lại. Hệ số nở do gom cụm, tức mức phóng to độ bất định do các bước cùng cụm tương quan, là 1,10 trong phép tính hiện tại. Như một minh hoạ cho lợi ích của ghép cặp, sai số chuẩn của hiệu S1–Base là 0,79 điểm, so với 1,05 điểm nếu tính như hai tỉ lệ độc lập. Mức dao động giữa các lượt huấn luyện không thuộc sai số của độ đo và được phân tích riêng ở Mục 6.7.