Chương 5

Độ đo khả năng thực hiện theo hướng dẫn

Chương này trình bày cách đánh giá câu hướng dẫn. Bên cạnh các độ đo dựa trên câu chuẩn, chúng tôi sử dụng executability để kiểm tra câu có cung cấp đủ thông tin cho một mô hình định vị độc lập xác định đúng phần tử và đúng thao tác hay không. Mục 5.1 giới thiệu ý tưởng và định nghĩa executability. Mục 5.2 và Mục 5.3 trình bày cách xác định phần tử và loại thao tác. Mục 5.4 mô tả các độ đo dựa trên câu chuẩn. Mục 5.5 đánh giá độ tin cậy của executability, còn Mục 5.6 trình bày phương pháp thống kê.

5.1 Ý tưởng và định nghĩa executability

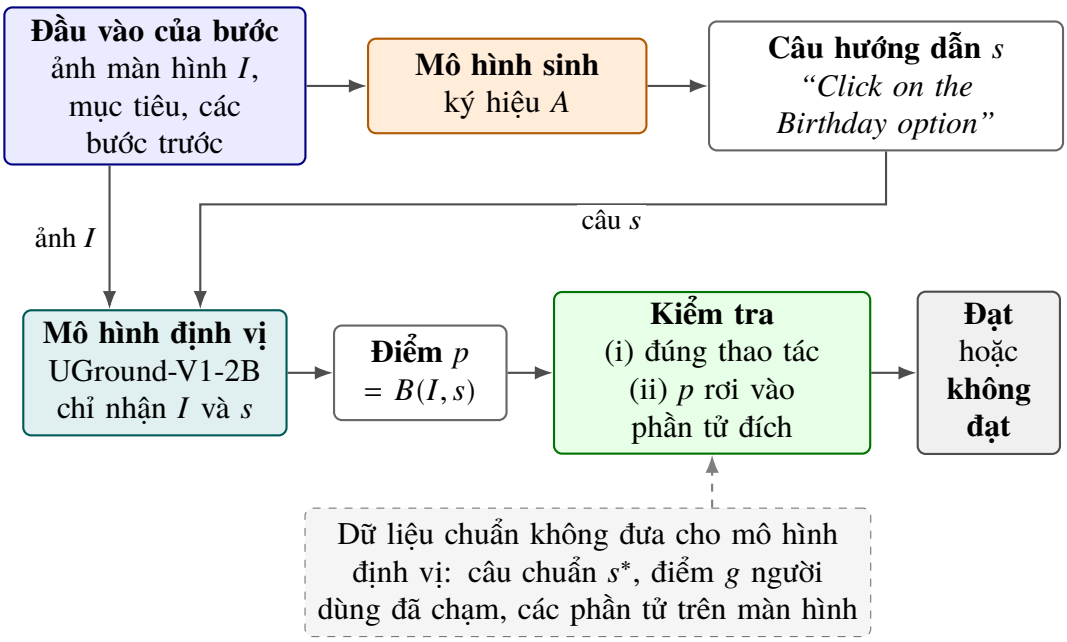
Các độ đo như BLEU hay ROUGE cho biết câu sinh giống câu chuẩn đến mức nào, nhưng chưa phản ánh đầy đủ việc câu có dẫn tới đúng phần tử trên giao diện hay không. Cùng một phần tử có thể được gọi bằng nhiều cách khác nhau, chẳng hạn *Click on the Birthday* và *Tap the date of birth row*. Ngược lại, hai câu có nhiều từ giống nhau vẫn có thể chỉ tới hai phần tử khác nhau. Ví dụ, *Click on the Not now button* và *Click on the Allow button* có cấu trúc gần giống nhau nhưng dẫn tới hai lựa chọn đối lập. Quan sát này cũng phù hợp với kết quả của Zhao và cộng sự [37] về hạn chế của các độ đo dựa trên cụm từ khi đánh giá chỉ dẫn điều hướng.

Executability tiếp cận bài toán theo hướng khác: thay vì chỉ so câu với câu chuẩn, câu hướng dẫn được đưa cho một mô hình định vị độc lập để kiểm tra phần tử mà câu

mô tả. Cách đánh giá này gần với các nghiên cứu sinh biểu thức quy chiếu, trong đó chất lượng câu được đánh giá qua khả năng một mô hình khác xác định đúng đối tượng được mô tả [12, 13]. Quy trình gồm hai mô hình:

- **Mô hình sinh**, ký hiệu A, là mô hình cần đánh giá, chẳng hạn Base, S1 hay phương pháp đề xuất (Chương 4). Ở mỗi bước, mô hình nhận ảnh màn hình cùng thông tin của tác vụ và sinh một câu hướng dẫn cho thao tác tiếp theo.
- **Mô hình định vị**, ký hiệu B, nhận ảnh màn hình và câu hướng dẫn rồi trả về tọa độ của phần tử mà câu đề cập tới. Mô hình định vị chính được sử dụng là UGround-V1-2B [5].

Mô hình định vị được tách khỏi quá trình sinh câu. Mô hình này không được tinh chỉnh trong luận văn, không tham gia vào phần thưởng GRPO hay điều kiện lựa chọn của ACE, và chỉ nhận ảnh cùng câu hướng dẫn. Mô hình định vị không biết mục tiêu tác vụ, lịch sử các bước hay tọa độ đáp án. Vì vậy, để xác định đúng phần tử, câu hướng dẫn phải tự chứa đủ thông tin quy chiếu cần thiết.



Hình 5.1: Quy trình đánh giá một câu hướng dẫn bằng executability.

Hình 5.1 tóm tắt quy trình. Ở mỗi bước, mô hình sinh tạo câu s. Mô hình định vị đọc s cùng ảnh I và trả về điểm $p = B(I, s)$. Điểm này được so với dữ liệu chuẩn của

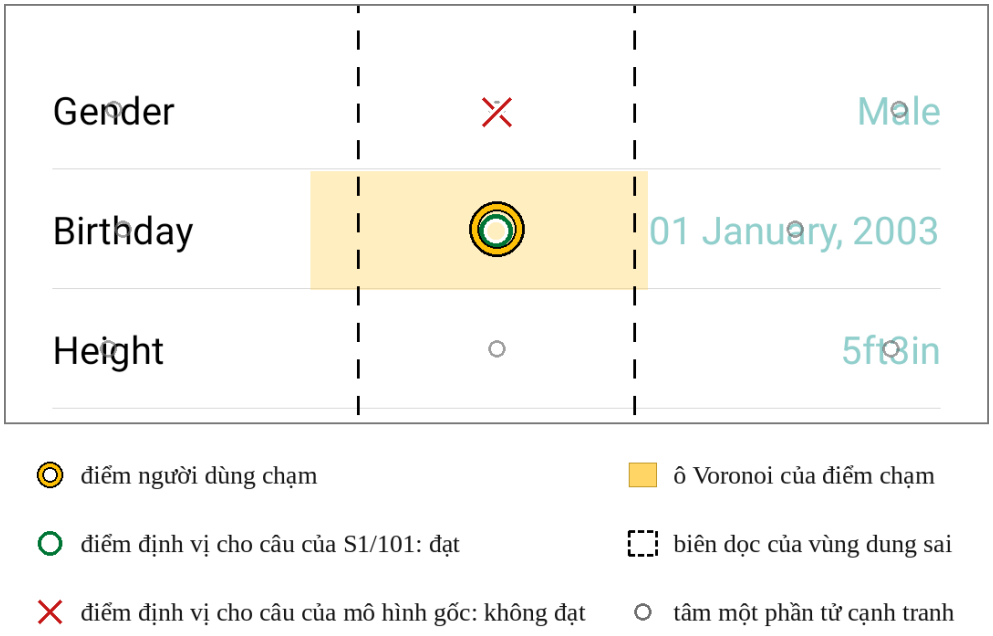
bước, gồm câu chuẩn s^* và điểm g mà người dùng đã chạm. Câu s được xem là thực hiện được khi thỏa cả hai điều kiện:

- **(i) Đúng thao tác.** s nêu cùng loại thao tác với câu chuẩn, trong năm loại chạm, gõ, cuộn, nhấn giữ và quay lại, và không gọi trạng thái ngược với câu chuẩn, chẳng hạn "bật thông báo" thay cho "tắt thông báo" (Mục 5.3).
- **(ii) Đúng phần tử.** p rơi vào phần tử mà người dùng đã chạm. Cụ thể, p nằm trong cửa sổ $\pm 14\%$ quanh g và không gần phần tử nào khác hơn chính g (Mục 5.2).

Điểm executability của một mô hình sinh là tỉ lệ câu thực hiện được trên N bước:

$$\text{Executability} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[\,\text{đúng thao tác}(s_i, s_i^*)\,] \cdot \mathbb{1}[\,B(I_i, s_i) \in V(g_i)\,], \qquad (5.1)$$

trong đó $\mathbb{1}[\cdot]$ bằng 1 khi điều kiện đúng và bằng 0 khi sai, còn $V(g_i)$ là vùng chấp nhận quanh điểm chạm, định nghĩa ở Mục 5.2.



Hình 5.2: Một bước được đánh giá: câu của S1 đạt, câu của Base dẫn tới dòng *Gender* nên không đạt.

Hình 5.2 minh họa một bước trên màn hình hồ sơ cá nhân. Người dùng đã chạm dòng *Birthday*, với câu chuẩn *Click on the Birthday*. S1 sinh câu *Click on the Birthday option*. Mô hình định vị chọn đúng dòng *Birthday*, nên câu đạt. Base sinh câu *Click on the "Gender" section to change it to "Male"*. Mô hình định vị chọn dòng *Gender* ngay phía trên, nên câu không đạt. Trường hợp này cũng cho thấy chỉ dùng cửa sổ 14% là chưa đủ, vì điểm dự đoán vẫn có thể nằm gần điểm chạm nhưng thuộc phần tử lân cận.

Executability được tính trên **4.463** bước có thao tác chạm hoặc nhấn giữ, vì đây là các bước có tọa độ phần tử đích. Các thao tác gõ chữ, cuộn và quay lại được phân tích riêng theo loại thao tác ở Mục 6.11. Câu không có nội dung được tính là không đạt. Các khía cạnh về cách diễn đạt được đánh giá riêng bằng các độ đo dựa trên câu chuẩn ở Mục 5.4.

5.2 Xác định điểm đúng phần tử

Dữ liệu cho biết điểm g mà người dùng đã chạm nhưng không cho biết chính xác ranh giới của phần tử được chạm. Điều kiện (ii) vì vậy được xác định bằng hai tiêu chí kết hợp.

Cửa sổ dung sai 14%. Theo quy ước của AndroidInTheWild [2], hai lần chạm được coi là tương đương khi sai lệch không quá 14% kích thước màn hình. Chúng tôi áp dụng ngưỡng này theo từng trục, $|p_x - g_x| \le 0{,}14\,W$ và $|p_y - g_y| \le 0{,}14\,H$. Tuy nhiên, chỉ dùng cửa sổ 14% có thể chấp nhận cả điểm nằm trên phần tử lân cận, như trường hợp dòng *Gender* trong Hình 5.2.

Ô Voronoi. Để tránh chấp nhận phần tử lân cận, chúng tôi bổ sung yêu cầu rằng phần tử đích phải là phần tử gần điểm dự đoán p nhất. Gọi E là tập các phần tử khác trên màn hình và $c(e)$ là tâm của phần tử e. Khi đó p phải thỏa

$$\|p - g\| \le \|p - c(e)\| \quad \forall e \in E. \tag{5.2}$$

Các điểm thỏa điều kiện này tạo thành ô Voronoi quanh điểm chạm g. Những tâm quá gần nhau được gộp để tránh tách một vùng tương tác thành nhiều phần tử khác

nhau. Vùng chấp nhận $V(g)$ trong công thức (5.1) là phần giao giữa cửa sổ 14% và ô Voronoi. Nhờ đó, điểm dự đoán vừa phải nằm gần thao tác thật, vừa phải gần phần tử đích hơn các phần tử khác.

Bảng 5.1 minh họa tác dụng của điều kiện Voronoi. Nếu chỉ dùng cửa sổ 14%, 84,3% dự đoán đã chuyển sang phần tử lân cận vẫn bị chấp nhận. Khi kết hợp thêm ô Voronoi, tỉ lệ này giảm còn **2,8%**, trong khi vẫn giữ **99,7%** các dự đoán chỉ lệch nhẹ khỏi điểm chạm. Kết quả này là cơ sở để dùng phép giao giữa hai điều kiện làm tiêu chí chính.

Bảng 5.1: Tỉ lệ chấp nhận khi dự đoán lệch nhẹ và khi dự đoán chuyển sang phần tử lân cận.

Tiêu chí	**Lệch 3%**	**Sang phần tử lân cận**
Cửa sổ dung sai $\pm$14% theo từng trục	100,0%	84,3%
Cửa sổ 14% và ô Voronoi (executability)	99,7%	**2,8%**

Phép gộp tâm 24 dp chủ yếu nhằm tránh xem các điểm rất gần nhau trong cùng một vùng tương tác là hai phần tử khác nhau. Phân tích độ nhạy theo khoảng cách giữa các phần tử được trình bày ở Phụ lục B.1. Với thiết kế này, executability tập trung vào việc phân biệt các phần tử tách biệt trên giao diện thay vì phạt các sai lệch nhỏ trong cùng vùng thao tác.

5.2.1 Các tiêu chí đánh giá bổ sung

Chương 6 báo thêm ba tiêu chí xác định vị trí có tiền lệ trong các bộ dữ liệu giao diện (Bảng 5.2). Các tiêu chí này giữ nguyên điều kiện về loại thao tác và chỉ thay cách xác định điểm đúng phần tử. Tất cả được tính lại từ cùng các dự đoán tọa độ của mô hình định vị.

Ba tiêu chí bổ sung cung cấp các cách nhìn khác nhau về cùng dự đoán tọa độ. Tiêu chí hộp phần tử kiểm tra điểm có nằm trong vùng của phần tử đích hay không, còn AitW đầy đủ sử dụng cách đánh giá của AndroidInTheWild. Các biến thể rộng hơn chỉ được dùng cho phân tích độ nhạy và không thay thế executability trong kết quả chính.

Bảng 5.2: Các tiêu chí xác định điểm đúng phần tử.

Tiêu chí	**Điểm p được tính là đúng khi**	**Nguồn**
Executability (chính)	p trong cửa sổ $\pm$14% quanh g và phần tử đích là phần tử gần p nhất	Mục 5.2
Hộp phần tử (D.3)	p nằm trong hộp bao của phần tử chứa g	AndroidControl, Phụ lục D.3 [1]
Hộp $\wedge$ 14%	p vừa nằm trong hộp phần tử vừa nằm trong cửa sổ 14%	kết hợp hai tiêu chí trên
AitW đầy đủ	p cách g không quá 0,14 trên tọa độ chuẩn hoá về $[0; 1]$, hoặc p và g cùng nằm trong hộp phần tử nới rộng 1,4 lần	mã đánh giá của AndroidInTheWild [2]

Bảng 5.3: Điểm theo executability và ba tiêu chí đánh giá bổ sung.

	Executability	**Hộp**	**Hộp $\wedge$ 14%**	**AitW đầy đủ**
4.463 bước				
Câu chuẩn	75,7	83,8	79,2	92,1
S1	59,1	65,5	61,7	74,4
Base	47,6	53,6	49,8	63,4
Mẫu 800 bước				
Câu chuẩn	74,9	83,0	78,8	90,8
Câu chung chung "*Tap the button.*"	12,0	14,1	12,1	25,9
Câu chuẩn của một màn hình khác	6,1	8,6	6,6	17,4
Dải phân tách (câu chuẩn − câu chung chung)	62,9	68,9	66,6	64,9

Thứ hạng câu chuẩn > S1 > Base được giữ dưới cả bốn tiêu chí trong Bảng 5.3. Executability được chọn làm tiêu chí chính vì yêu cầu đồng thời điểm dự đoán nằm gần thao tác thật và không gần một phần tử khác hơn phần tử đích. Các tiêu chí còn lại được dùng bổ sung để cho thấy kết luận không phụ thuộc vào một cách xác định vị trí duy nhất. Phụ lục B.3 mở rộng so sánh với năm cách xác định vị trí khác.

5.3 Loại thao tác

Điều kiện về thao tác gồm hai phần. Trước hết, câu sinh và câu chuẩn được quy về một trong năm loại: chạm, gõ, cuộn, nhấn giữ và quay lại. Việc quy loại dựa trên động từ thao tác trong câu, trong đó các cách diễn đạt như *tap*, *click*, *open* hay *select* cùng được xem là thao tác chạm. Một kiểm tra độ nhạy với cách quy loại chặt hơn chỉ làm chênh lệch S1 − Base thay đổi 0,11 điểm, nên kết luận chính không phụ thuộc vào chi tiết này.

Ngoài ra, câu sinh không được mô tả trạng thái ngược với câu chuẩn, chẳng hạn "bật thông báo" thay cho "tắt thông báo". Kiểm tra này cần thiết vì hai trạng thái đối lập có thể nằm tại cùng một vị trí trên màn hình và vì vậy không thể phân biệt chỉ bằng tọa độ. Các cặp trạng thái đối lập được xác định trước cho toàn bộ quá trình đánh giá.

5.4 Các độ đo dựa trên câu chuẩn

Bên cạnh executability, Chương 6 sử dụng bảy độ đo dựa trên câu chuẩn. Mỗi độ đo phản ánh một khía cạnh khác nhau của mức độ tương đồng giữa câu sinh và câu chuẩn:

- **BLEU-4** [20]: tỉ lệ cụm từ một đến bốn từ của câu sinh xuất hiện trong câu chuẩn, có phạt câu ngắn hơn câu chuẩn.
- **METEOR** [22]: so khớp từng từ giữa hai câu, tính cả từ cùng gốc và từ đồng nghĩa, có phạt khi các từ trùng nằm rời rạc thay vì thành cụm liên tiếp.
- **ROUGE-L** [21]: điểm F1 dựa trên chuỗi con chung dài nhất của hai câu.

- **CIDEr-D** [23]: độ tương đồng cosine giữa hai vectơ cụm từ có trọng số TF-IDF, nên cụm hiếm và mang thông tin được coi trọng hơn cụm phổ biến. Bản D có thêm thành phần phạt chênh lệch độ dài.
- **SPICE** [24]: phân tích câu thành các đối tượng, thuộc tính và quan hệ rồi tính F1 trên các thành phần này (Mục 2.3).
- **chrF** [25]: điểm F trên các cụm ký tự, nên ghi nhận cả những từ chỉ khác nhau ở dạng viết.
- **BERTScore** [26]: so khớp từng token của hai câu theo độ tương đồng biểu diễn ngữ cảnh của RoBERTa-large, rồi chuẩn hoá thang điểm theo mức nền.

Năm độ đo đầu được tính bằng bộ chấm chính thức của COCO. Cả bảy độ đo tính ở mức toàn tập, tức gộp thống kê của mọi câu rồi mới tính điểm, và câu không có nội dung nhận điểm 0. Công thức CIDEr-D có hệ số 10, nên điểm báo theo thang phần trăm có thể vượt 100.

Các độ đo dựa trên câu chuẩn và executability bổ sung cho nhau. Nhóm thứ nhất phản ánh mức tương đồng về cách diễn đạt hoặc nội dung, còn executability tập trung vào việc câu có xác định đúng phần tử và thao tác hay không. Hai khía cạnh này không hoàn toàn trùng nhau. Chẳng hạn, một câu vẫn có thể dẫn tới đúng phần tử dù cách gọi khác câu chuẩn. Vì vậy chúng tôi báo cả hai nhóm độ đo, trong đó executability được dùng làm độ đo chính cho khả năng xác định đúng phần tử và thao tác, còn SPICE được dùng làm phần thưởng cho GRPO ở Mục 4.3.

5.5 Đánh giá độ tin cậy của executability

Độ tin cậy của executability được kiểm tra theo nhiều hướng bổ sung nhau: so với câu chuẩn và các câu cố ý thiếu thông tin, thay đổi cách diễn đạt nhưng giữ nguyên nghĩa, lặp lại cùng đầu vào, và thay UGround bằng các mô hình đánh giá khác. Các kiểm tra này giúp xác định điểm số có phản ánh thông tin trong câu hay chỉ phụ thuộc vào một công cụ định vị cụ thể. Kết quả chính ở Chương 6 dùng đủ 4.463 bước. Những phân tích trên mẫu con đều ghi rõ cỡ mẫu tại chỗ.

5.5.1 Câu chuẩn và câu thiếu thông tin

Câu chuẩn. Khi đưa câu chuẩn qua cùng quy trình, executability trên 4.463 bước đạt **75,7%** [74,1; 77,3]. Đây là mốc cao nhất trong các câu được đánh giá và cho thấy mô hình định vị phản hồi tốt khi câu chứa đầy đủ thông tin cần thiết. Điểm này được dùng làm mốc diễn giải thay vì xem như trần lý thuyết.

Câu thiếu thông tin. Trên mẫu 800 bước, câu chung chung "*Tap the button.*" chỉ đạt **12,0%**, còn câu chuẩn lấy từ một màn hình khác đạt **6,1%**. Khoảng cách lớn so với câu chuẩn cho thấy executability phản ứng mạnh với việc câu có xác định đúng phần tử hay không, thay vì chỉ phản ánh văn phong.

Tên phần tử và mệnh đề vị trí. Khi bỏ tên phần tử khỏi câu chuẩn, executability giảm **28,5 điểm**, lớn hơn nhiều so với mức giảm 3,5 điểm khi bỏ riêng mệnh đề vị trí. Kết quả này phù hợp với mục tiêu của độ đo: thông tin giúp nhận diện phần tử có ảnh hưởng trực tiếp đến khả năng định vị.

Bảng 5.4: Mốc tham chiếu trên mẫu 800 bước. Hai hàng cuối chỉ tính trên các bước có thành phần bị bỏ.

Câu đưa cho mô hình định vị	Số bước	Executability (%)
Câu chuẩn	800	74,9
S1	800	58,8
Base	800	48,6
Câu chung chung "*Tap the button.*"	800	12,0 [9,7; 14,4]
Câu chuẩn của một màn hình khác	800	6,1 [4,5; 7,9]
Câu chuẩn bỏ tên phần tử, giữ vị trí	193	89,6 → 61,1
Câu chuẩn bỏ mệnh đề vị trí, giữ tên	198	89,4 → 85,9

5.5.2 Độ ổn định khi diễn đạt lại

Để kiểm tra độ nhạy với cách diễn đạt, câu chuẩn trên mẫu 800 bước được viết lại theo ba cách giữ nguyên nghĩa: đổi động từ thao tác, đảo thứ tự hai mệnh đề và kết hợp cả hai. Trong 1.139 câu được viết lại, chỉ **2,6%** làm thay đổi kết quả đánh giá. Hiệu

ròng là **+0,35 điểm** [−0,59; +1,29], với khoảng tin cậy bao gồm 0. Executability vì vậy ổn định trước các thay đổi cách viết không làm thay đổi phần tử được mô tả. Chi tiết được trình bày ở Phụ lục B.5.

5.5.3 Độ chính xác và tính nhất quán khi lặp lại

Độ chính xác. Trên 300 bước dùng câu chuẩn, sai số định vị của UGround có trung vị chỉ **0,7%** bề ngang màn hình và 62,7% dự đoán nằm trong khoảng 3% so với điểm chạm. Trong cùng mẫu, executability chấp nhận toàn bộ các trường hợp có sai số dưới 3% và loại toàn bộ các trường hợp có sai số trên 14%. Điều này cho thấy tiêu chí vị trí giữ được các sai lệch nhỏ nhưng loại các dự đoán đã lệch rõ khỏi phần tử đích.

Tính nhất quán khi lặp lại. Khi lặp lại đánh giá với thứ tự và cách gom dữ liệu khác nhau, cả **1.625/1.625** cặp câu và ảnh đều cho cùng kết quả. Vì vậy điểm executability không phụ thuộc vào cách tổ chức lượt chạy.

5.5.4 Đối chiếu bằng các mô hình đánh giá khác

Để kiểm tra kết quả có phụ thuộc riêng vào UGround hay không, chúng tôi đánh giá thêm bằng ba mô hình khác (Bảng 5.5). Các mô hình này được chọn để tạo ra những cách đánh giá khác nhau về kiến trúc, dữ liệu huấn luyện hoặc dạng đầu ra.

- **UI-Venus-Ground-7B** [6] dựng trên Qwen2.5-VL nhưng không dùng AndroidControl khi huấn luyện.
- **Phi-Ground-4B** [7] dựng trên Phi-3.5-Vision, ngoài họ Qwen. Theo báo cáo kỹ thuật, mô hình không dùng AndroidControl để huấn luyện.
- **Phi-4-multimodal-instruct** [42] là mô hình đa phương thức ngoài họ Qwen. Thay vì trả về tọa độ, Phi-4 chọn một phần tử đã được đánh số trên ảnh theo Set-of-Mark [43]. Cách đánh giá này kiểm tra cùng mục tiêu xác định đúng phần tử nhưng bằng một dạng đầu ra khác.

Dưới cả bốn mô hình đánh giá, S1 đều cao hơn Base. Chênh lệch đạt **+11,52 điểm** với UGround, **+9,68** [+7,60; +11,78] với UI-Venus, **+6,16** [+4,71; +7,64] với

Bảng 5.5: Điểm của ba loại câu dưới bốn mô hình đánh giá.

Mô hình đánh giá	Họ mô hình	Học AC	Trả lời	Số bước	Base	S1	Câu chuẩn
UGround-V1-2B	Qwen2-VL	có	tọa độ	4.463	47,6	59,1	75,7
UI-Venus-Ground-7B	Qwen2.5-VL	không	tọa độ	2.532	39,1	48,7	-
Phi-Ground-4B	Phi-3.5-Vision	không	tọa độ	4.463	40,8	47,0	-
Phi-4-multimodal	Phi-4	không	chọn số	4.463	38,2	44,6	54,9

Học AC: có dùng AndroidControl khi huấn luyện. UI-Venus được đánh giá trên mẫu 2.532 bước của thí nghiệm ban đầu nên các giá trị ở hàng này không dùng để so trực tiếp với điểm toàn tập. Với Phi-Ground, 7 bước Base không có dự đoán được tính là không đạt. Ô "-" là chưa đánh giá trên cùng mẫu.

Phi-Ground và **+6,41 điểm** với Phi-4 ($p < 0{,}001$). Ở những công cụ đã đánh giá câu chuẩn, câu chuẩn vẫn cho điểm cao nhất. Thứ hạng này được giữ khi thay đổi mô hình đánh giá, thay vì chỉ xuất hiện với UGround.

Các mô hình đánh giá có thang điểm tuyệt đối khác nhau, vì vậy chúng tôi dùng chúng để đối chiếu chiều của kết quả thay vì thay thế số chính từ UGround. Việc đánh giá lặp lại trên các mẫu kiểm tra cũng cho kết quả nhất quán. So sánh trực tiếp GRPO-SPICE và ACE với S1 dưới bốn công cụ được trình bày ở Mục 6.5.

5.5.5 Phạm vi của đánh giá tự động

UGround có sử dụng nhãn phần tử của AndroidControl trong huấn luyện [5], nên chúng tôi kiểm tra thêm kết quả bằng các mô hình không dùng AndroidControl và các mô hình ngoài họ Qwen. Thứ hạng giữa các loại câu vẫn được giữ trong các phép đối chiếu này. Khi tách dữ liệu theo phần chia chính thức của AndroidControl, điểm của câu chuẩn, S1 và Base cũng thay đổi rất ít. Vì vậy các kết luận so sánh không dựa vào riêng một mô hình định vị hay một phần chia dữ liệu. Executability vẫn là một phép đo tự động, nên phần thực nghiệm tập trung diễn giải chênh lệch giữa các mô hình dưới cùng điều kiện đánh giá thay vì xem điểm tuyệt đối là đánh giá trực tiếp của người dùng.

5.6 Phương pháp phân tích thống kê

Khoảng tin cậy. Các điểm số và chênh lệch được báo cùng khoảng tin cậy 95% (KTC), ước lượng bằng bootstrap theo cụm với 10.000 lần lấy mẫu lại. Cụm chính là ứng dụng, vì các bước trong cùng một ứng dụng có thể có mức độ khó tương tự nhau. Với những bước không xác định được ứng dụng, mỗi tác vụ được xem là một cụm riêng. Cách lấy mẫu theo cụm giúp tránh đánh giá quá thấp độ bất định khi nhiều bước đến từ cùng một ứng dụng. Thử thay đổi cách gom cụm làm KTC của chênh lệch S1 − Base thay đổi không quá 0,7 điểm.

So sánh ghép cặp. Các mô hình được đánh giá trên cùng 4.463 bước, vì vậy chênh lệch được tính trực tiếp theo từng bước thay vì xem hai điểm số là độc lập. Cách tính ghép cặp loại bớt ảnh hưởng của những bước vốn khó hoặc dễ cho tất cả mô hình và cho khoảng tin cậy hẹp hơn. Giá trị p được tính bằng kiểm định McNemar dạng chính xác trên các bước mà hai mô hình cho kết quả khác nhau.

Mức chênh lệch nhỏ nhất phát hiện được. Ngoài sai số của phép đo, kết quả còn có thể thay đổi khi huấn luyện lại với seed khác. Chúng tôi dùng mức chênh lệch nhỏ nhất phát hiện được (*minimum detectable effect*, MDE) để đặt các chênh lệch quan sát được trong bối cảnh của cả hai nguồn biến thiên. Với xác suất phát hiện 80% ở mức ý nghĩa 5%, MDE được ước lượng như sau:

$$\mathrm{MDE} = (z_{0,975} + z_{0,80})\sqrt{\mathrm{SE}^2 + 2\sigma^2} \approx 2{,}8 \times \sqrt{0{,}38^2 + 2 \times 0{,}46^2} \approx 2{,}11 \text{ điểm}, \quad (5.3)$$

trong đó $\mathrm{SE} \approx 0{,}38$ điểm là sai số chuẩn của phép so ghép cặp và $\sigma \approx 0{,}46$ điểm là ước lượng biến thiên giữa các lượt huấn luyện từ hai lượt S1. Kết quả cho MDE xấp xỉ **2,11 điểm**. Vì biến thiên giữa các lượt chỉ được ước từ một cặp huấn luyện, con số này được dùng như một mốc tham khảo thay vì ngưỡng tuyệt đối. Chương 6 vì vậy báo đồng thời KTC và kết quả của các lượt huấn luyện lặp khi diễn giải những chênh lệch nhỏ.