Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả thực nghiệm của phương pháp đề xuất. Sau kết quả tổng thể ở Mục 6.2, Mục 6.3 và Mục 6.4 phân tích riêng hai thành phần của phương pháp. Các mục tiếp theo đối chiếu nhiều nhóm độ đo, xem xét biến thiên giữa các lượt huấn luyện, rồi kiểm tra khả năng khái quát trên tác vụ mới, miền dữ liệu khác và lịch sử do mô hình tự sinh. Phần cuối phân tích các dạng lỗi còn lại và tóm tắt những phương án đã khảo sát trước khi hình thành phương pháp cuối cùng.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên cùng 4.463 bước có thao tác chạm của tập kiểm tra bằng cùng một quy trình đánh giá. Phương pháp đề xuất gồm mô hình học tăng cường với phần thưởng SPICE để sinh câu hướng dẫn ban đầu và ACE để quyết định có hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ hay không (Mục 4.4 đến Mục 4.6).

Ba mốc so sánh (Mục 4.7) gồm mô hình gốc (Base), mô hình tinh chỉnh có giám sát qua hai lượt với seed 101 và 202 (S1), và câu chuẩn được đưa trực tiếp vào quy trình đánh giá làm mốc tham chiếu để diễn giải thang điểm. Mọi bước trong tập kiểm tra đều được giữ trong mẫu số đánh giá.

6.2 Kết quả chính

Các hướng đã thử khác (mô-đun định vị, đưa vai trò và vùng của phần tử vào mô hình, làm nét ảnh, mở khoá phần thị giác) không xuất hiện trong bảng vì chỉ được đánh giá

Bảng 6.1: Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra. Exec. là executability, KTC 95% là khoảng tin cậy 95% của executability. Hộp phần tử là tiêu chí của AndroidControl, AitW đầy đủ là tiêu chí của AndroidInTheWild. BLEU-4 và ROUGE-L ở đây là trung bình theo câu: BLEU không làm mượt nên câu ngắn hơn bốn từ nhận 0 điểm và hàng câu chuẩn chỉ đạt 96,1, ROUGE-L tính theo F1. Hai cột này khác BLEU-4 và ROUGE-L của bộ công cụ COCO ở Bảng 6.3, 6.4 và 6.6. Số in đậm là số cao nhất của cột, không tính hàng câu chuẩn, và không hàm ý chênh lệch có ý nghĩa thống kê (xem Bảng 6.8). †Mô hình chọn ứng viên khác các mô hình còn lại ở ba yếu tố của thiết lập (Mục A.3.1), nên chỉ so sánh trực tiếp được với mô hình gốc (Mục A.3.2).

Mô hình	Exec.	KTC 95%	Hộp phần tử	AitW đầy đủ	BLEU-4 theo câu	ROUGE-L theo câu
Mốc so sánh						
Mô hình gốc (Base)	47,59	[45,9; 49,3]	53,60	63,39	9,9	40,4
Qwen2.5-VL-7B, chỉ prompting	51,51	[49,82; 53,15]	57,67	66,79	–	–
Tinh chỉnh có giám sát (S1/101)	59,11	[57,3; 60,8]	65,49	74,37	38,7	67,3
Tinh chỉnh có giám sát (S1/202)	59,62	[57,9; 61,3]	66,10	75,31	39,0	67,6
Nhánh đối chứng, điểm SPICE ghép ngẫu nhiên	59,11	–	65,58	74,59	–	–
Phương pháp đề xuất						
GRPO-SPICE, lượt 2	59,94	[58,13; 61,71]	66,55	76,23	–	–
GRPO-SPICE (thành phần thứ nhất)	**60,65**	[58,9; 62,4]	67,02	76,25	40,1	68,3
Phương pháp đề xuất (GRPO-SPICE + ACE)	**60,68**	[58,9; 62,4]	**67,11**	76,32	**41,2**	**69,1**
Các hướng đã thử (Phụ lục A)						
Mô tả phần tử (S2)	57,2	[55,4; 58,9]	63,6	73,4	36,4	65,9
Học thêm có giám sát (CE2-S2)	59,4	[57,7; 61,1]	66,0	76,1	38,1	68,6
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	[58,3; 61,8]	66,5	76,4	37,9	68,4
Thưởng tọa độ (giai đoạn ba)	60,1	[58,3; 61,8]	67,0	**77,3**	37,8	68,5
Chọn ứng viên†	56,1	[54,2; 58,0]	62,4	71,2	34,5	63,0
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	[58,5; 62,0]	66,4	76,1	40,1	68,4
Câu chuẩn (mốc tham chiếu)	75,7	[74,1; 77,3]	83,8	92,1	96,1	100,0

trên tập kiểm định nội bộ (Mục A.6).

Qwen2.5-VL-7B chỉ dùng prompting đạt 51,51% executability, cao hơn Base 3,92 điểm nhưng thấp hơn S1/101 7,60 điểm và thấp hơn GRPO-SPICE 9,14 điểm. Trong thiết lập này, mô hình 3B sau khi được tinh chỉnh cho kết quả cao hơn rõ rệt so với mô hình 7B chỉ dùng prompting. Phép so với 7B sử dụng cùng câu nhắc của Base và không tối ưu câu nhắc riêng cho mô hình 7B. Chúng tôi cũng không có phép kiểm độc lập để loại trừ khả năng mô hình nền 7B đã gặp AndroidControl trong giai đoạn tiền huấn luyện, nên phép so này chỉ được diễn giải trong thiết lập prompting đã thử.

GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm với khoảng tin cậy 95% [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Hướng tăng được giữ khi thay luật xác định điểm chạm: so với cả hai lượt S1, chênh lệch của GRPO-SPICE đều dương theo executability, tiêu chí hộp phần tử, tiêu chí hộp phần tử kết hợp cửa sổ 14% và AitW đầy đủ, với các khoảng tin cậy nằm trên 0. Lượt GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm và cao hơn 1,86 điểm theo AitW đầy đủ. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11% executability, đúng bằng S1/101, còn GRPO-SPICE cao hơn nhánh này 1,55 điểm [+0,81; +2,30]. Với cùng số bước huấn luyện, mức tăng chỉ xuất hiện khi tín hiệu SPICE giữ đúng quan hệ với mẫu.

Trên ACU, gồm các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48] (Mục 6.8.1). Sau ACE, executability trên tập kiểm tra chính đạt 60,68%, đồng thời cả bảy thước dựa trên câu chuẩn đều tăng (Mục 6.4). Bảng 6.2 tiếp tục phân rã executability theo ba điều kiện cấu thành.

Ở hàng câu chuẩn, đầu vào đánh giá chính là câu chuẩn nên điều kiện đúng loại thao tác luôn được thỏa mãn. Tỉ lệ đúng loại thao tác 98,9% của giai đoạn học theo cặp ưu tiên, mô hình học thêm có giám sát và giai đoạn thưởng tọa độ được tính trên các bước có thao tác chạm. Mô hình chọn ứng viên (†) chỉ được so sánh trực tiếp với mô hình gốc do khác thiết lập huấn luyện (Mục A.3.2).

Vị trí của S1 trên thang điểm. S1 cải thiện 11,5 điểm executability so với mô hình gốc. Đây là mức tăng lớn và ổn định, trong khi câu chuẩn đạt 75,7% và được dùng làm mốc tham chiếu của quy trình đánh giá. Các giai đoạn tiếp theo tiếp tục cải

Bảng 6.2: Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). Đạt đầy đủ: thoả cả ba điều kiện của executability. Chỉ ô Voronoi: điểm định vị nằm trong cửa sổ dung sai và trong ô Voronoi của phần tử cần chạm, chưa xét loại thao tác. Khớp thao tác: câu gọi đúng loại thao tác. Cửa sổ dung sai: điểm định vị nằm trong cửa sổ $\pm 14\%$ theo từng trục quanh điểm chạm chuẩn.

Mô hình	Đạt đầy đủ	Chỉ ô Voronoi	Khớp thao tác	Cửa sổ dung sai
Câu chuẩn (mốc tham chiếu)	75,7	75,8	100,0	84,3
Phương pháp đề xuất	60,7	61,5	96,0	70,4
GRPO-SPICE	60,7	61,4	96,0	70,3
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	61,0	96,6	70,1
Thưởng tọa độ (giai đoạn ba)	60,1	60,5	98,9	69,9
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	60,4	98,9	69,2
S1/202	59,6	60,7	94,6	69,8
Học thêm có giám sát (CE2-S2)	59,4	59,8	98,9	68,9
S1/101	59,1	60,2	94,4	69,2
Mô tả phần tử (S2)	57,2	58,1	94,8	67,4
Chọn ứng viên†	56,1	57,4	90,9	66,3
Mô hình gốc (Base)	47,6	48,9	96,5	57,6

thiện từ điểm xuất phát S1 (Mục 6.3 và Mục 6.4).

6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Mục này đánh giá độc lập thành phần thứ nhất (thiết kế ở Mục 4.5). Mô hình học tăng cường với phần thưởng SPICE học tiếp từ S1/101, nên được so sánh trực tiếp với cấu hình này.

Phân tích tín hiệu phần thưởng trên tập kiểm định nội bộ. Trước khi huấn luyện, S1 được dùng để sinh một câu bằng giải mã tham lam và tám câu bằng lấy mẫu cho mỗi bước. Nếu chọn câu có SPICE cao nhất so với câu chuẩn, executability cao hơn so với câu từ giải mã tham lam. Trong khi đó, việc chọn ngẫu nhiên một trong tám câu không tạo ra xu hướng tương tự. Executability cũng có xu hướng giảm ở những câu có thứ hạng SPICE thấp hơn trong cùng một nhóm. SPICE vì vậy cung cấp tín hiệu phân biệt hữu ích cho quá trình huấn luyện. Phân tích này được dùng để lựa chọn thiết kế trước khi đánh giá trên tập kiểm tra.

Lựa chọn số bước huấn luyện. Mô hình ở bước 250 và bước 500 được so sánh trên cùng tập kiểm định nội bộ. Executability tăng khi tiếp tục huấn luyện đến bước 500, và phần lớn các trường hợp đã được sửa đúng ở bước 250 vẫn được giữ. Vì vậy, mô hình sau 500 bước được chọn và cố định trước khi sinh câu trên tập kiểm tra.

6.3.1 Kết quả trên các bước có thao tác chạm

GRPO-SPICE đạt điểm cao hơn S1/101 trên cả mười ba độ đo trong Bảng 6.3. Với sáu độ đo dựa trên vị trí và cả sáu thước chữ có KTC, khoảng tin cậy của chênh lệch đều nằm hoàn toàn trên 0. Executability tăng 1,55 điểm, với $p = 1{,}6 \times 10^{-5}$ theo kiểm định McNemar (Mục 6.6). Phần thưởng huấn luyện chỉ sử dụng SPICE và không dùng mô hình định vị, nhưng mức tăng vẫn xuất hiện đồng thời ở các tiêu chí dựa trên vị trí và toàn bộ nhóm thước chữ có KTC. Lượt GRPO thứ hai tiếp tục giữ hướng cải thiện so với S1/101, như phân tích ở Mục 6.7.2.

Bảng 6.3: GRPO-SPICE so với S1/101, ghép cặp theo bước. Sáu hàng đầu là độ đo theo vị trí trên 4.463 bước có thao tác chạm, gồm cả tỉ lệ đúng loại thao tác. Bảy hàng cuối là độ đo so với câu chuẩn. Δ là điểm của GRPO-SPICE trừ điểm của S1/101. KTC 95% tính bằng bootstrap theo cụm (Mục 5.13). Với nhóm độ đo dựa trên câu chuẩn, BLEU-4, ROUGE-L, CIDEr-D, SPICE, chrF và BERTScore có KTC từ 2.000 lần lấy mẫu theo cùng các cụm. METEOR chỉ có điểm mức kho. Cột cuối không áp dụng cho nhóm này.

Độ đo	**S1/101**	**GRPO-SPICE**	**Δ**	**KTC 95%**	**Sai→Đúng / Đúng→Sai**
Executability	59,11	60,65	+1,55	[+0,80; +2,33]	159 / 90
Tiêu chí hộp phần tử	65,49	67,02	+1,52	[+0,77; +2,29]	165 / 97
AitW đầy đủ	74,37	76,25	+1,88	[+1,17; +2,63]	172 / 88
AitW cận trên	81,04	82,90	+1,86	[+1,17; +2,60]	163 / 80
$\pm$14% theo trục	67,24	68,90	+1,66	[+0,90; +2,46]	172 / 98
Đúng loại thao tác	94,35	95,97	+1,61	[+1,17; +2,08]	83 / 11
SPICE	44,37	45,79	+1,42	[+0,71; +2,16]	-
BLEU-4	51,56	52,36	+0,80	[+0,22; +1,60]	-
METEOR	36,79	37,92	+1,13	-	-
ROUGE-L	67,35	68,36	+1,01	[+0,55; +1,48]	-
CIDEr-D	416,12	430,05	+13,93	[+8,05; +19,91]	-
chrF	61,26	62,87	+1,61	[+1,10; +2,11]	-
BERTScore	66,33	67,07	+0,74	[+0,32; +1,15]	-

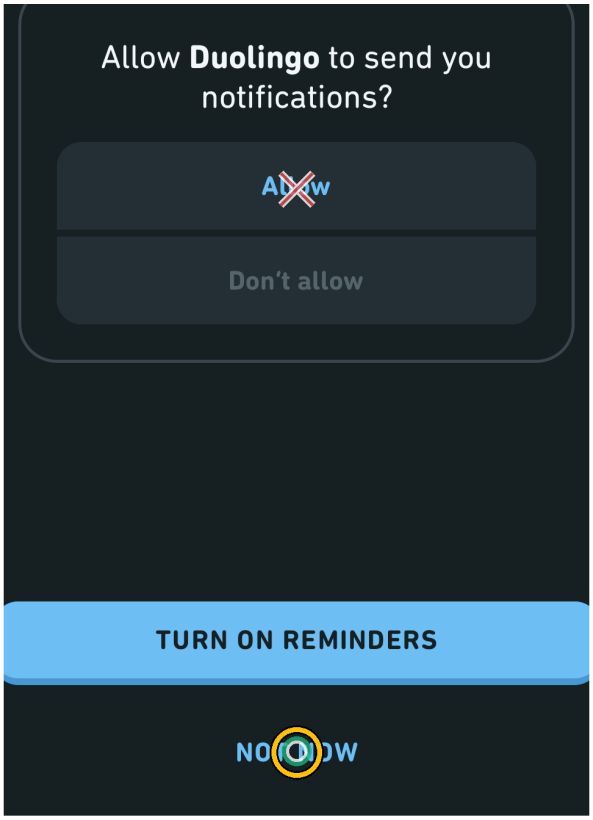
Phân rã nguồn gốc mức cải thiện. Trong 159 bước chuyển từ sai sang đúng, 36 bước là những trường hợp S1 dự đoán sai loại thao tác. Ở chiều ngược lại, trong 90 bước chuyển từ đúng sang sai, chỉ 8 bước xuất phát từ lỗi loại thao tác của mô hình học tăng cường. Việc sửa loại thao tác đóng góp ròng 28 bước, tương đương +0,63 điểm. Phần cải thiện còn lại đến từ 4.200 bước mà cả hai mô hình đều xác định đúng loại thao tác: trên nhóm này, executability tăng từ 62,62 lên 63,60, tương đương thêm 41 bước đúng (+0,92 điểm). Hơn một nửa mức cải thiện nằm ở khả năng xác định đúng phần tử cần chạm khi loại thao tác đã đúng. Hình 6.1 minh họa một bước thuộc nhóm này.

Thí nghiệm đối chứng với điểm SPICE ghép ngẫu nhiên. Nhánh này được huấn luyện thêm cùng 500 bước GRPO nhưng sử dụng điểm SPICE được ghép ngẫu nhiên giữa các mẫu. Executability đạt 59,11%, bằng S1/101, và cả sáu thước chữ có KTC cũng không khác S1/101. Ngược lại, GRPO-SPICE cao hơn nhánh này 1,55 điểm executability [+0,81; +2,30], đồng thời cao hơn ở cả sáu thước chữ có KTC. Sự khác biệt giữa hai nhánh tách rõ mức cải thiện do tín hiệu SPICE khỏi ảnh hưởng của việc tiếp tục cập nhật mô hình.

Ablation phần thưởng CIDEr-D. Khi thay SPICE bằng CIDEr-D trong một lượt GRPO 500 bước, executability thấp hơn GRPO-SPICE 0,69 điểm, với khoảng tin cậy 95% [−1,34; −0,02]. Kéo dài quá trình huấn luyện với CIDEr-D đến 1.000 bước không tạo thêm cải thiện đáng kể. Phân rã theo từng bước cho thấy CIDEr-D có lợi hơn ở loại thao tác nhưng thấp hơn ở khả năng chọn đúng phần tử. Mỗi cấu hình trong phép so này được chạy một lượt. Hai lượt còn khác về số câu nhắc dùng khi huấn luyện (1.000 so với 2.000) và môi trường tính toán (T4 fp16 so với A100 bf16). Vì vậy, kết quả được dùng để hỗ trợ lựa chọn SPICE trong thiết lập đã thử, không để kết luận ưu thế tổng quát của một thước phần thưởng.

So với S1, mô hình học tăng cường chỉ thay đổi một phần đầu ra: 2.795 trong 4.463 câu được giữ nguyên hoàn toàn, còn độ dài trung bình chỉ tăng từ 7,83 lên 7,96 từ. Vì vậy, mức cải thiện không thể giải thích đơn thuần bằng việc sinh câu dài hơn.

So sánh với các cấu hình khác. GRPO-SPICE cao hơn cả S1/101 và S1/202 trên executability, với mức tăng lần lượt 1,55 và 1,03 điểm. Lượt GRPO thứ hai cũng cao hơn điểm xuất phát S1/101 0,83 điểm. Cả hai lượt GRPO đều giữ hướng cải thiện so



Vòng vàng: điểm người dùng đã chạm
Câu tham chiếu: "Click on the Not now button to remove this pop up notification"
S1/101: "Click on the Allow button" → không đạt
GRPO-SPICE: "Click on the Not Now button at the bottom of the screen" → đạt

Hình 6.1: Một bước được GRPO-SPICE sửa đúng (ảnh chỉ giữ phần dưới màn hình). Cần chạm nút *Not now* ở cuối màn, trong khi một hộp thoại hỏi quyền gửi thông báo đang che màn hình. S1 gọi nút *Allow* trong hộp thoại nên mô hình định vị xác định sai phần tử. GRPO-SPICE gọi đúng nút *Not now* kèm vị trí, và mô hình định vị xác định đúng phần tử. Vòng vàng là điểm người dùng chạm. Dấu X đỏ và vòng xanh lá là điểm mà mô hình định vị trả về khi đọc câu của S1/101 và của GRPO-SPICE.

với điểm xuất phát, còn lượt được dùng trong phương pháp đề xuất cao hơn cả hai lượt S1. Trên nhóm thước chữ, GRPO-SPICE cao hơn S1/101 ở cả bảy thước, và cả sáu thước có KTC đều loại 0. Tín hiệu SPICE vì vậy đi cùng mức tăng ở cả executability và chất lượng câu so với câu chuẩn.

Phạm vi trên các bước không chạm. Các kết quả chính ở mục này được tính

trên các bước có thao tác chạm. Khi xét khả năng gọi đúng loại thao tác ở các bước không chạm, GRPO-SPICE chưa giữ được cùng chiều cải thiện: trên toàn bộ nhóm này, tỉ lệ giảm từ 85,97% ở S1 xuống 84,29%. Với thao tác cuộn, S1 đạt 83,97% còn GRPO-SPICE đạt 77,75%, chênh $-6{,}23$ điểm $[-8{,}30; -4{,}31]$. Với thao tác quay lại, mức chênh là $-5{,}93$ điểm. Trong 51 bước cuộn chuyển từ đúng ở S1 sang sai sau GRPO-SPICE, 47 câu chuyển sang dạng thao tác chạm. Phân tích này xác định một giới hạn của phần thưởng SPICE trong thiết lập hiện tại: mô hình có xu hướng lệch về câu thao tác chạm. Đây cũng là một động lực để ACE giữ thêm ràng buộc nhất quán loại thao tác ở thành phần thứ hai.

6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Trên tập kiểm tra, điều kiện đồng thuận của ACE (Mục 4.6) thay thế 402 trong 4.463 câu hướng dẫn ban đầu (9,0%). Bảng 6.4 so sánh ACE, tức phương pháp đề xuất, với câu hướng dẫn ban đầu và với mô hình sinh câu độc lập, trong đó đầu ra của mô hình sinh được sử dụng ở mọi bước.

Khả năng của kho truy hồi. Với mỗi bước có thao tác chạm trong tập kiểm tra, bốn câu chuẩn gần nhất được truy hồi từ tập huấn luyện theo quy trình ở Mục 4.6. Trong 15,8% số bước, ít nhất một câu ví dụ giống hoàn toàn với câu chuẩn của bước đang xét. Ở 9,8% số bước, điều này xảy ra đồng thời với việc câu hướng dẫn ban đầu của thành phần thứ nhất không đạt. Nếu luôn có thể nhận ra và chọn đúng câu ví dụ trong các trường hợp này, BLEU-4 tính trên toàn tập có thể tăng khoảng 5 điểm và CIDEr-D khoảng 65 điểm. Tuy nhiên, một chiến lược đơn giản như luôn lấy câu ví dụ đứng đầu lại làm BLEU-4 giảm từ 52,4 xuống 28,3. Kho truy hồi có chứa thông tin hữu ích, nhưng hiệu quả phụ thuộc vào cơ chế lựa chọn câu ví dụ. Phân tích này được dùng để giải thích vai trò của điều kiện đồng thuận, không thay thế kết quả đánh giá trực tiếp của ACE.

Kết quả. ACE nâng cả bảy thước dựa trên câu chuẩn và giữ executability ở cùng mức với GRPO-SPICE. Cả sáu thước có KTC đều tăng với khoảng tin cậy nằm hoàn toàn trên 0: BLEU-4 +1,11, ROUGE-L +0,74, CIDEr-D +11,97, SPICE +1,33, chrF

Bảng 6.4: ACE trên 4.463 bước có thao tác chạm, so với câu hướng dẫn ban đầu của GRPO-SPICE và với mô hình sinh câu độc lập. Ba độ đo theo vị trí có KTC 95% bootstrap theo cụm (Mục 5.13). Trong nhóm dựa trên câu chuẩn, BLEU-4, ROUGE-L, CIDEr-D, SPICE, chrF và BERTScore có KTC bootstrap với 2.000 lần lấy mẫu. METEOR chỉ có điểm mức kho.

Độ đo	Câu ban đầu	Mô hình sinh độc lập	ACE	ACE − câu ban đầu
Executability	60,65	59,40	60,68	+0,02 [−0,21; +0,26]
Tiêu chí hộp phần tử	67,02	65,81	67,11	+0,09 [−0,15; +0,33]
AitW đầy đủ	76,25	75,02	76,32	+0,07 [−0,15; +0,29]
BLEU-4	52,36	53,47	53,47	+1,11 [+0,78; +1,42]
METEOR	37,92	37,79	38,37	+0,45
ROUGE-L	68,36	68,67	69,11	+0,74 [+0,54; +0,94]
CIDEr-D	430,05	437,54	442,02	+11,97 [+8,24; +15,34]
SPICE	45,79	46,79	47,13	+1,33 [+0,92; +1,75]
chrF	62,87	62,65	63,44	+0,58 [+0,37; +0,80]
BERTScore	67,07	67,52	67,73	+0,66 [+0,46; +0,86]

+0,58 và BERTScore +0,66. METEOR cũng tăng 0,45 điểm nhưng chưa có KTC. Executability đạt 60,68%, chênh +0,02 điểm so với GRPO-SPICE [−0,21; +0,26]. Trong 402 câu được thay thế, có 15 bước chuyển từ sai sang đúng và 14 bước theo chiều ngược lại. ACE vì vậy đưa cách diễn đạt gần câu chuẩn hơn mà không làm giảm executability của GRPO-SPICE. Theo tiêu chí hộp phần tử và AitW đầy đủ, phương pháp hoàn chỉnh cao hơn S1/101 lần lượt 1,61 và 1,95 điểm, cả hai với $p < 0,001$.

Ảnh hưởng khi sử dụng mô hình sinh câu độc lập. Mô hình sinh câu độc lập đạt điểm cao hơn câu hướng dẫn ban đầu trên năm trong bảy độ đo dựa trên câu chuẩn, nhưng thấp hơn 1,25 điểm executability [−2,06; −0,44] ($p = 0,002$). Ở 19,1% số bước, mô hình lặp lại hoàn toàn một câu ví dụ. Trong nhóm này, 43,5% số câu giống hoàn toàn với câu chuẩn, gần gấp đôi tỉ lệ của câu hướng dẫn ban đầu (22,8%). Ngược lại, ở những bước mô hình tạo một câu mới, kết quả thấp hơn câu hướng dẫn ban đầu. Truy hồi có ích khi mô hình lựa chọn đúng câu ví dụ, còn việc thay câu hướng dẫn ban đầu cần đi kèm điều kiện lựa chọn.

Đóng góp của ràng buộc nhất quán loại thao tác. Nếu chỉ dùng điều kiện sao chép, ACE thay 453 câu và vẫn làm tăng cả bảy độ đo dựa trên câu chuẩn, nhưng

executability thấp hơn câu hướng dẫn ban đầu 0,11 điểm (24 bước chuyển từ sai sang đúng và 29 bước chuyển từ đúng sang sai). Ràng buộc loại thao tác loại 51 câu không nhất quán, nhờ đó ACE cao hơn biến thể chỉ dùng điều kiện sao chép 0,13 điểm executability và không thấp hơn ở độ đo nào trong Bảng 6.4.

Phạm vi cải thiện. Lợi ích của ACE thể hiện rõ nhất ở chất lượng câu đầu ra: cả bảy thước dựa trên câu chuẩn đều tăng, và cả sáu thước có KTC đều cho khoảng tăng nằm trên 0. Đồng thời, executability được giữ ở mức của GRPO-SPICE. METEOR chưa có KTC nên được dùng như kết quả bổ sung.

6.5 Đánh giá trên nhiều nhóm độ đo

Ngoài executability, chúng tôi trình bày thêm hai nhóm chỉ số: các độ đo dựa trên vị trí và các độ đo dựa trên câu chuẩn. Cả hai nhóm được tính lại từ bản ghi ở mức từng bước của các lượt đánh giá trong Bảng 6.1. Các bảng dưới đây đặt phương pháp đề xuất cạnh các mốc và những cấu hình đã khảo sát để cho thấy kết quả dưới từng nhóm tiêu chí.

Nhóm độ đo theo vị trí. Bảng 6.5 trình bày ba tiêu chí đánh giá chính cùng hai biến thể ở Mục 5.12. Thứ tự các mô hình theo AitW đầy đủ và hộp phần tử gần với thứ tự theo executability. Phương pháp đề xuất đạt 76,3% theo AitW đầy đủ và 67,1% theo hộp phần tử, cao hơn S1/101 lần lượt 1,95 và 1,61 điểm. Cả hai chênh lệch đều có $p < 0{,}001$. Giai đoạn thưởng tọa độ đạt giá trị cao nhất theo AitW đầy đủ (77,3%), nhưng phân tích ở Mục A.4.2 cho thấy phần lớn chênh lệch của cấu hình này gắn với việc dự đoán đúng loại thao tác, chưa cho thấy mức tăng tương ứng về khả năng xác định phần tử.

Sai số và kết luận theo ba tiêu chí. Bảng 6.7 trình bày khoảng tin cậy theo ba tiêu chí, được tính trên cùng các mẫu bootstrap nên có thể đối chiếu trực tiếp giữa các cột. Hình 6.2 biểu diễn các chênh lệch so với S1/101 cùng khoảng tin cậy, nên có thể thấy ngay phép so nào có khoảng tin cậy nằm hoàn toàn trên 0. Chênh lệch giữa S1/101 và mô hình gốc gần như không thay đổi giữa ba tiêu chí, đều với $p < 0{,}001$, và phương pháp đề xuất cao hơn S1 có ý nghĩa theo cả ba tiêu chí (Mục 6.4). Với các hướng đã thử, kết luận thay đổi tùy tiêu chí. Mô hình mô tả phần tử thấp hơn S1 có ý nghĩa theo

Bảng 6.5: Nhóm độ đo theo vị trí trên 4.463 bước có thao tác chạm, tính lại từ bản ghi từng bước mà không gọi lại mô hình định vị. AitW đầy đủ là biến thể sử dụng cả điều kiện khoảng cách và hộp phần tử của AndroidInTheWild, còn AitW cận trên mở rộng việc xét khung tới mọi phần tử có thể thao tác trên màn hình (Mục 5.12). Hộp phần tử là tiêu chí gốc của AndroidControl. Cột $\pm$14% trục dùng cửa sổ dung sai theo từng trục và có xét loại thao tác. Thao tác là tỉ lệ gọi đúng loại thao tác. Số in đậm là số cao nhất của cột, không tính câu chuẩn. *GRPO-SPICE là thành phần thứ nhất của phương pháp đề xuất. Số in đậm không hàm ý chênh lệch có ý nghĩa thống kê, các phép so có kiểm định nằm ở Bảng 6.7 và 6.8. TAGE là mô-đun hiệu chỉnh câu đặt sau GRPO-SPICE (Mục A.7.2). †Mô hình chọn ứng viên chỉ so sánh trực tiếp được với Base.

Mô hình	Exec.	Hộp phần tử	AitW đầy đủ	$\pm$14% trục	AitW cận trên	Thao tác
Base	47,6	53,6	63,4	55,9	73,4	96,5
S1/101	59,1	65,5	74,4	67,2	81,0	94,4
S1/202	59,6	66,1	75,3	67,9	81,9	94,6
S2	57,2	63,6	73,4	65,7	80,8	94,8
CE2-S2	59,4	66,0	76,1	68,5	83,9	**98,9**
MIN-DESC	60,0	66,5	76,4	68,7	84,4	**98,9**
Giai đoạn ba	60,1	67,0	**77,3**	**69,4**	**85,0**	**98,9**
GRPO-SPICE*	**60,7**	67,0	76,2	68,9	82,9	96,0
Phương pháp đề xuất	**60,7**	**67,1**	76,3	68,9	83,0	96,0
TAGE	60,2	66,4	76,1	68,7	82,7	96,6
Chọn ứng viên†	56,1	62,4	71,2	63,9	77,9	90,9
Câu chuẩn	75,7	83,8	92,1	84,2	96,2	100,0

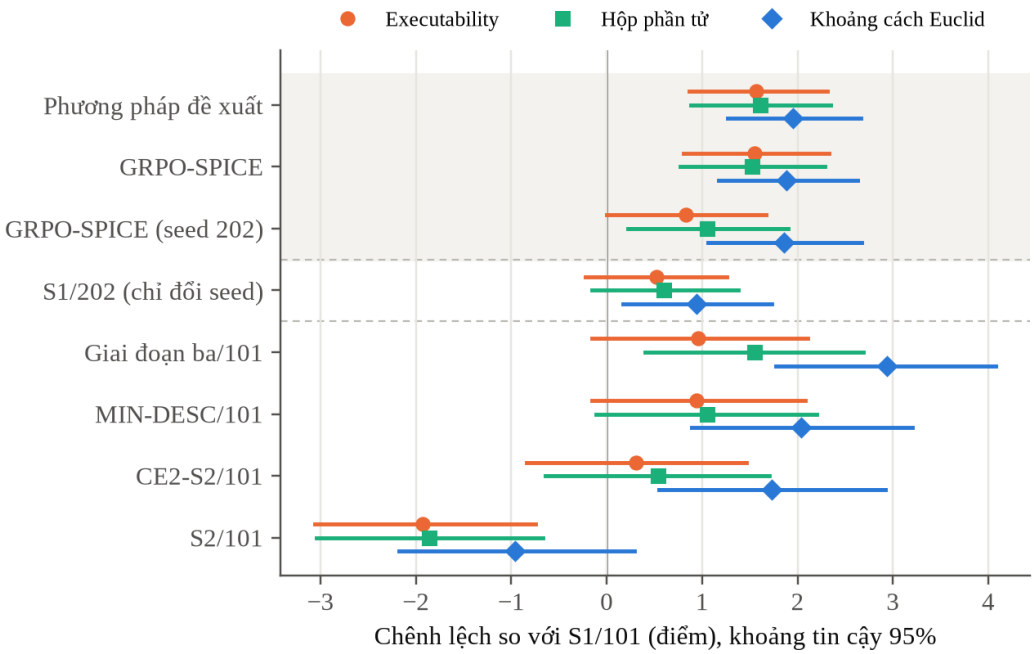
Bảng 6.6: Nhóm độ đo so với câu chuẩn trên 4.463 bước có thao tác chạm. BLEU-4, METEOR 1.5, ROUGE-L, CIDEr-D và SPICE được tính bằng bộ công cụ đánh giá chính thức của COCO Captions sau khi tách từ bằng PTBTokenizer. chrF được tính bằng sacreBLEU. BERTScore là F1 với roberta-large tầng 17, đã hiệu chỉnh theo đường cơ sở. Mỗi bước chỉ có một câu chuẩn. Số in đậm là số cao nhất của cột. Giai đoạn ba học tiếp từ MIN-DESC với phần thưởng đặt trên tọa độ trong dòng mô tả. *GRPO-SPICE là thành phần thứ nhất của phương pháp đề xuất, so sánh chi tiết giữa hai mô hình này nằm ở Bảng 6.4. TAGE chỉ có điểm SPICE. †Mô hình chọn ứng viên chỉ so sánh trực tiếp được với Base.

Mô hình	**BLEU-4**	**METEOR**	**ROUGE-L**	**CIDEr-D**	**SPICE**	**chrF**	**BERTScore**
Base	15,3	24,6	42,3	88,0	18,5	40,2	40,1
7B, chỉ prompting	14,48	21,90	39,79	100,71	18,74	36,22	39,70
S1/101	51,56	36,79	67,35	416,12	44,37	61,26	66,33
S1/202	51,66	37,17	67,71	419,19	44,23	61,92	66,75
Nhánh đối chứng	51,32	36,95	67,36	418,13	44,40	61,52	66,40
GRPO-SPICE, lượt 2	52,94	37,53	68,48	431,22	45,69	62,37	67,12
S2	48,7	35,8	66,0	387,7	41,3	59,9	65,1
CE2-S2	50,1	37,3	68,6	402,2	42,3	61,9	66,8
MIN-DESC	49,9	37,3	68,5	401,0	42,2	61,8	66,7
Giai đoạn ba	49,9	37,3	68,5	402,9	42,5	61,9	66,8
GRPO-SPICE*	52,36	37,92	68,36	430,05	45,79	62,87	67,07
Phương pháp đề xuất	**53,47**	**38,37**	**69,11**	**442,02**	**47,13**	**63,44**	**67,73**
TAGE	-	-	-	-	45,7	-	-
Chọn ứng viên†	46,9	34,2	63,3	370,6	39,3	57,7	62,8
Câu chuẩn	100,0	100,0	100,0	988,7	98,6	100,0	100,0

Bảng 6.7: Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và so sánh ghép cặp (dưới). Khoảng tin cậy được ước lượng bằng 10.000 lần bootstrap theo cách gom cụm ở Mục 5.13, gồm 1.091 cụm. Giá trị p tính bằng kiểm định McNemar. AitW đầy đủ là tiêu chí của AndroidInTheWild, hộp phần tử là tiêu chí của AndroidControl. Giai đoạn ba là giai đoạn thưởng tọa độ (Phụ lục A.4).

Mô hình	**Executability**	**Hộp phần tử**	**AitW đầy đủ**
Base	47,6 [45,9; 49,3]	53,6 [51,9; 55,3]	63,4 [61,8; 65,0]
S1/101	59,1 [57,3; 60,8]	65,5 [63,8; 67,2]	74,4 [72,8; 75,8]
S1/202	59,6 [57,9; 61,3]	66,1 [64,4; 67,7]	75,3 [73,8; 76,7]
MIN-DESC	60,0 [58,3; 61,8]	66,5 [64,9; 68,2]	76,4 [74,9; 77,8]
Giai đoạn ba	60,1 [58,3; 61,8]	67,0 [65,3; 68,7]	77,3 [75,8; 78,8]
GRPO-SPICE	60,7 [58,9; 62,4]	67,0 [65,3; 68,7]	76,3 [74,7; 77,7]
Phương pháp đề xuất	60,7 [58,9; 62,4]	67,1 [65,4; 68,8]	76,3 [74,8; 77,8]
Câu chuẩn	75,7 [74,1; 77,3]	83,8 [82,5; 85,1]	92,1 [91,1; 93,1]

Phép so	**Tiêu chí**	**Δ**	**KTC 95%**	**p**
S1/101 − Base	Executability	+11,52	[+10,02; +13,07]	<0,001
	Hộp phần tử	+11,90	[+10,36; +13,47]	<0,001
	AitW đầy đủ	+10,98	[+9,44; +12,56]	<0,001
Phương pháp đề xuất − S1/101	Executability	+1,57	[+0,86; +2,31]	<0,001
	Hộp phần tử	+1,61	[+0,88; +2,35]	<0,001
	AitW đầy đủ	+1,95	[+1,27; +2,66]	<0,001
S2 − S1/101	Executability	−1,93	[−3,06; −0,75]	<0,001
	Hộp phần tử	−1,86	[−3,04; −0,67]	<0,001
	AitW đầy đủ	−0,96	[−2,18; +0,29]	0,100



Hình 6.2: Chênh lệch so với S1/101 theo ba tiêu chí đánh giá trên 4.463 bước có thao tác chạm. Mỗi điểm là chênh lệch ghép cặp, vạch ngang là khoảng tin cậy 95% bootstrap theo cụm (Mục 5.13). Vùng nền xám gồm phương pháp đề xuất và GRPO-SPICE với hai seed. Hàng S1/202 cho biết mức dao động khi chỉ đổi seed của S1. Các hàng dưới cùng là các hướng đã thử ở Phụ lục A, trong đó giai đoạn ba là MIN-DESC học tiếp với phần thưởng đặt trên tọa độ. Vạch không chứa 0 nghĩa là chênh lệch có ý nghĩa thống kê ở mức 5%. Riêng GRPO-SPICE (seed 202) theo executability có cận dưới đúng bằng 0,00.

executability (Mục A.1.3) nhưng không theo AitW đầy đủ. Theo AitW đầy đủ, phần lớn mức tăng của giai đoạn học theo cặp ưu tiên và giai đoạn thưởng tọa độ so với mô hình mô tả phần tử cũng xuất hiện ở mô hình chỉ học thêm có giám sát với cùng số bước. Giai đoạn thưởng tọa độ cao hơn S1 có ý nghĩa theo hai tiêu chí vị trí, nhưng không theo executability.

> Mức cải thiện theo AitW đầy đủ tập trung ở 256 bước (5,7%) mà S1 dự đoán sai loại thao tác, chẳng hạn sinh câu mô tả thao tác vuốt hoặc cuộn khi bước đúng là chạm. Nhóm này đóng góp +3,11 điểm theo AitW đầy đủ và +1,97 điểm theo executability. Khi so với seed 202, mức đóng góp tương ứng là +3,09 điểm. Ở 4.189 bước mà cả hai mô hình đều dự đoán đúng loại thao tác, tỉ lệ đạt gần như tương đương (79,04% so với 78,92%). AitW đầy đủ cũng không loại những lần chạm rơi vào phần tử sát bên, trong khi executability loại các trường hợp này. Giai đoạn thưởng tọa độ gặp các trường hợp này nhiều hơn, nên trên nhóm bước mà cả hai mô hình đều dự đoán đúng loại thao tác, giai đoạn này thấp hơn S1 0,81 điểm theo executability. Do đó, trong phân rã này, mức cải thiện của hai giai đoạn chủ yếu gắn với việc dự đoán đúng loại thao tác, chưa cho thấy cải thiện tương ứng về khả năng định vị phần tử.

Nhóm độ đo so với câu chuẩn. Bảng 6.6 sử dụng các độ đo được báo cáo trong Widget Captioning [10] và Screen2Words [11], gồm BLEU [20], METEOR [22], ROUGE-L [21], CIDEr [23] và SPICE [24], cùng chrF [25] và BERTScore [26]. BLEU-4 trong bảng này được tính trên toàn tập bằng bộ công cụ COCO Captions, nên khác với BLEU-4 trung bình theo từng câu ở Bảng 6.1. So với S1/101, GRPO-SPICE cao hơn ở cả bảy thước và cả sáu thước có KTC đều loại 0. Lượt GRPO thứ hai cho cùng xu hướng, trong khi nhánh đối chứng nằm gần S1/101 và cả sáu KTC của chênh lệch đều phủ 0. ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu thước có KTC, với toàn bộ khoảng tin cậy nằm trên 0. Qwen2.5-VL-7B dùng prompting thấp hơn rõ rệt so với các nhánh 3B đã tinh chỉnh trên cả bảy thước, cùng chiều với executability. BERTScore sử dụng phiên bản đã co giãn theo mức điểm nền. Câu rỗng được tính 0 điểm và vẫn nằm trong mẫu số, tương tự quy ước của executability.

CIDEr-D vượt quá 100 vì mỗi bước chỉ có một câu chuẩn và trọng số nghịch đảo tần

suất văn bản (IDF) được ước lượng từ chính tập câu chuẩn. Vì vậy, giá trị này chỉ nên được so sánh giữa các hàng trong cùng bảng. Ở các mô hình có kết quả gần nhau, thứ hạng theo nhóm độ đo dựa trên câu chuẩn không hoàn toàn giống với executability, phù hợp với phân tích ở Mục 5.11. Chúng tôi dùng nhóm độ đo này chủ yếu để đối chiếu với các công trình cùng mảng. So sánh giữa các mô hình vẫn dựa trên executability.

6.6 So sánh ghép cặp

Mọi mô hình được đánh giá trên cùng một tập bước, nên các so sánh được thực hiện theo cặp ở mức từng bước bằng kiểm định McNemar (Mục 5.13). Bảng 6.8 tổng hợp các so sánh được sử dụng trong chương.

Bảng 6.8: So sánh ghép cặp executability trên 4.463 bước có thao tác chạm. Δ là điểm của mô hình đứng trước dấu trừ trừ điểm của mô hình đứng sau. b là số bước chỉ mô hình đứng sau đạt, c là số bước chỉ mô hình đứng trước đạt, nên $\Delta = (c - b)/n$. Khoảng tin cậy 95% tính bằng bootstrap theo cụm với 10.000 lần lấy mẫu (Mục 5.13), mọi hàng dùng chung các cụm. Base là mô hình gốc, S1/101 và S1/202 là S1 với seed 101 và 202, CE2-S2 là mô hình chỉ học thêm có giám sát, TAGE là mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ. Câu rỗng được tính là không đạt và vẫn nằm trong mẫu số.

So sánh	Δ	**KTC 95%**	**b**	**c**	**p**
Mốc so sánh (S1 có hai seed)					
S1/101 − Base	+11,52	[+10,02; +13,07]	284	798	<0,001
7B − Base	+3,92	[+2,66; +5,23]	–	–	5×10^{-10}
S1/101 − 7B	+7,60	[+5,95; +9,28]	–	–	$< 10^{-24}$
Câu chuẩn − S1/101	+16,63	[+15,18; +18,09]	102	844	<0,001
Câu chuẩn − Base	+28,14	[+26,46; +29,88]	102	1.358	<0,001
S1/202 − S1/101 (hai seed)	+0,52	[−0,22; +1,26]	132	155	0,194
Phương pháp đề xuất và các so sánh liên quan					
Phương pháp đề xuất − S1/101	+1,57	[+0,86; +2,31]	88	158	<0,001
Phương pháp đề xuất − GRPO-SPICE	+0,02	[−0,21; +0,26]	14	15	1,00
Nhánh đối chứng − S1/101	+0,00	[−0,41; +0,42]	45	45	1,00
GRPO-SPICE − nhánh đối chứng	+1,55	[+0,81; +2,30]	94	163	2×10^{-5}

Bảng 6.8 (tiếp theo)

So sánh	Δ	KTC 95%	b	c	p
GRPO-SPICE − 7B	+9,14	[+7,55; +10,75]	–	–	$< 10^{-24}$
Phương pháp đề xuất − 7B	+9,16	[+7,57; +10,79]	–	–	$< 10^{-24}$
GRPO-SPICE − S1/101	+1,55	[+0,80; +2,33]	90	159	<0,001
GRPO-SPICE − S1/202	+1,03	[+0,25; +1,83]	145	191	0,014
GRPO-SPICE (lượt 2) − S1/101	+0,83	[0,00; +1,67]	129	166	0,036
GRPO-SPICE (lượt 2) − S1/202	+0,31	[−0,53; +1,17]	180	194	0,50
GRPO-SPICE (lượt 2) − lượt 1	−0,72	[−1,27; −0,16]	91	59	0,011
GRPO-SPICE − MIN-DESC	+0,60	[−0,52; +1,73]	304	331	0,30
GRPO-SPICE − giai đoạn ba	+0,58	[−0,50; +1,69]	286	312	0,31
TAGE − GRPO-SPICE	−0,43	[−0,87; +0,02]	67	48	0,093
Hướng đã thử (Phụ lục A)					
S2 − S1/101	−1,93	[−3,06; −0,75]	340	254	<0,001
S2 − S1/202	−2,44	[−3,53; −1,34]	353	244	<0,001
S2 − Base	+9,59	[+8,16; +11,06]	324	752	<0,001
CE2-S2 − S2	+2,24	[+1,36; +3,13]	127	227	<0,001
MIN-DESC − S2	+2,87	[+1,97; +3,75]	130	258	<0,001
MIN-DESC − CE2-S2	+0,63	[+0,16; +1,09]	42	70	0,011
MIN-DESC − S1/101	+0,94	[−0,16; +2,08]	300	342	0,11
CE2-S2 − S1/101	+0,31	[−0,84; +1,46]	312	326	0,61
Chọn ứng viên − Base	+8,54	[+7,00; +10,08]	350	731	<0,001

Với seed 101, tinh chỉnh có giám sát trên tập dữ liệu được xây dựng tự động cải thiện executability thêm 11,5 điểm, tương ứng thu hẹp 41% khoảng cách giữa mô hình gốc và câu chuẩn. Khi loại các bước mà S1 có cùng nội dung từ với câu chuẩn và chỉ xét 3.367 bước còn lại, S1 vẫn cao hơn mô hình gốc 8,4 điểm. Trên nhóm này, mô hình gốc, S1 và câu chuẩn đạt lần lượt 44,7, 53,1 và 75,0, tương ứng S1 thu hẹp 28% khoảng cách giữa hai mốc.

6.7 Biến thiên giữa các lượt huấn luyện

Để mô tả mức biến thiên khi huấn luyện lại, cả mô hình tinh chỉnh có giám sát (S1) và thành phần thứ nhất của phương pháp đề xuất đều được huấn luyện thêm một lượt, chỉ đổi seed và giữ nguyên mọi tham số cấu hình khác (Mục A.1.2). Mục 6.7.2 trình bày lượt thứ hai của thành phần thứ nhất.

6.7.1 Hai lượt huấn luyện S1

Bảng 6.9: Mức khác nhau giữa hai lượt huấn luyện S1 chỉ khác seed, đặt cạnh mức khác nhau giữa S1/101 và mô hình gốc, trên cùng 4.463 bước có thao tác chạm. S1/101 đạt 59,11% và S1/202 đạt 59,62% executability. Cột cuối đếm số bước mà đúng một trong hai mô hình đạt.

Phép so	**Δ executability**	**Số bước cho kết quả khác**
S1/202 − S1/101	+0,52	287 (6,4%)
S1/101 − Base	+11,52	1.082 (24,2%)

Chênh lệch 0,52 điểm giữa hai lượt S1 có khoảng tin cậy 95% chứa 0 (p = 0,194, Bảng 6.8), nên hai lượt được xem là gần nhau về executability. Hai lượt cho kết quả khác nhau ở 6,4% số bước, so với 24,2% giữa S1 và mô hình gốc. Xét độ lớn của điểm, chênh lệch giữa S1 và mô hình gốc lớn gấp 22 lần chênh lệch giữa hai seed, và gấp 3,8 lần nếu xét tỉ lệ bước đổi kết quả.

Phân tích nội dung loại một bước mà cả hai lượt đều trả về câu rỗng, nên còn 4.462 bước. Trong số này, hai lượt tạo cùng một câu ở 2.810 bước và cho cùng kết quả đánh giá ở tất cả các bước đó. Khi tính executability trên toàn bộ 4.463 bước, mức đồng thuận giữa hai lượt là 93,6% (κ = 0,867, hệ số đồng thuận đã điều chỉnh theo mức đồng thuận do ngẫu nhiên). Trên 1.652 bước có câu hướng dẫn khác nhau, mức đồng thuận còn 82,6% (κ = 0,650).

Với seed thứ hai, chênh lệch ở cả sáu cách chia nhóm trong Mục 6.10 vẫn cùng dấu với seed thứ nhất, và độ lệch giữa hai seed không vượt quá 0,9 điểm. Trong 1.091 cụm (Mục 5.13), số cụm mà S1 hơn, bằng và kém mô hình gốc là 395/565/131 ở seed 101 và 406/572/113 ở seed 202.

6.7.2 Hai lượt huấn luyện thành phần thứ nhất

Lượt thứ hai của thành phần thứ nhất dùng seed 202 cho thứ tự câu nhắc và quá trình lấy mẫu, còn điểm xuất phát vẫn là S1/101 và các tham số chính được giữ nguyên (500 bước, tám câu cho mỗi câu nhắc, phần thưởng SPICE). Mô hình sau 500 bước được đánh giá trên tập kiểm tra bằng cùng quy trình với lượt thứ nhất. Bảng 6.10 so sánh hai lượt với hai seed của S1 theo ba tiêu chí.

Bảng 6.10: Hai lượt huấn luyện thành phần thứ nhất so với hai seed của S1 trên 4.463 bước. Phần trên là điểm theo ba tiêu chí, phần dưới là chênh lệch ghép cặp, khoảng tin cậy 95% từ bootstrap theo cách gom cụm ở Mục 5.13. Lượt 1 là mô hình được dùng trong phương pháp đề xuất.

Mô hình	Executability	Hộp phần tử	AitW đầy đủ
S1/101	59,11	65,49	74,37
S1/202	59,62	66,10	75,31
GRPO-SPICE, lượt 1	60,65	67,02	76,25
GRPO-SPICE, lượt 2	59,94	66,55	76,23
Lượt 2 − S1/101	+0,83 [0,00; +1,67]	+1,05 [+0,22; +1,90]	+1,86 [+1,06; +2,67]
Lượt 2 − S1/202	+0,31 [−0,53; +1,17]	+0,45 [−0,44; +1,34]	+0,92 [+0,02; +1,82]
Lượt 2 − lượt 1	−0,72 [−1,27; −0,16]	−0,47 [−1,04; +0,09]	−0,02 [−0,57; +0,54]
Lượt 1 − S1/202	+1,03 [+0,25; +1,83]	+0,92 [+0,11; +1,75]	+0,94 [+0,07; +1,81]

Hai lượt GRPO đều cao hơn S1/101, là điểm xuất phát chung, theo cả ba tiêu chí. Theo executability, mức tăng lần lượt là 1,55 và 0,83 điểm. Hộp phần tử và AitW đầy đủ cũng giữ cùng chiều. Khi đối chiếu với S1/202, các chênh lệch nhỏ hơn. Độ lớn của mức tăng thay đổi giữa các lượt huấn luyện, trong khi hướng cải thiện so với điểm xuất phát vẫn được giữ. ACE được xây dựng trên lượt GRPO thứ nhất, nên kết quả của ACE được đọc qua phép so trực tiếp với lượt này ở Mục 6.4.

6.7.3 Độ ổn định khi thay công cụ đánh giá

Bảng 6.11 đặt các nhánh chính cạnh nhau dưới bốn công cụ đánh giá. UGround và UI-Venus là các bộ trỏ thuộc họ Qwen. Phi-Ground được xây dựng trên Phi-3.5-Vision và theo báo cáo kỹ thuật không dùng AndroidControl để huấn luyện (Mục 5.9). Phi-4

là listener dạng lựa chọn (Mục 5.10). Các công cụ không dùng cùng thang điểm, vì vậy chúng tôi tập trung vào thứ tự giữa các nhánh và chênh lệch ghép cặp thay vì so điểm tuyệt đối giữa các cột.

Bảng 6.11: Kết quả của các nhánh chính trên 4.463 bước có thao tác chạm khi thay công cụ đánh giá. Dấu – cho biết cấu hình chưa có kết quả trên công cụ tương ứng. Phi-4 báo tỉ lệ listener chọn đúng phần tử. Ba cột còn lại báo executability.

Nhánh	UGround	UI-Venus	Phi-Ground	Phi-4
Base	47,59	–	40,80	38,23
S1/101	59,11	54,51	46,96	44,63
S1/202	59,62	55,12	–	45,53
GRPO-SPICE	60,65	56,06	47,75	45,33
ACE	60,68	56,20	47,73	45,33
Câu chuẩn	75,73	–	–	54,94

So với S1/101, GRPO-SPICE cao hơn dưới cả bốn công cụ: +1,55 điểm với UGround, +1,55 với UI-Venus, +0,78 [+0,05; +1,51] với Phi-Ground và +0,69 [+0,02; +1,40] với Phi-4. Khoảng tin cậy của cả bốn chênh lệch đều nằm trên 0. Phi-Ground và Phi-4 đều nằm ngoài họ Qwen. Chiều cải thiện vì thế không chỉ xuất hiện khi dùng công cụ đánh giá cùng họ kiến trúc với mô hình sinh. ACE tiếp tục giữ kết quả gần với GRPO-SPICE dưới mọi công cụ. Các sai khác nhỏ giữa những mô hình đã tinh chỉnh được đọc cùng mức biến thiên giữa các lượt huấn luyện, thay vì dùng để thay đổi kết luận chính.

6.8 Khả năng khái quát và độ ổn định khi thay điều kiện đầu vào

Ba phép kiểm trong mục này mở rộng thiết lập đánh giá theo ba hướng khác nhau: tác vụ mới trong cùng nguồn AndroidControl, miền dữ liệu AitZ và lịch sử do chính mô hình sinh. Mục tiêu là kiểm tra liệu chênh lệch giữa GRPO-SPICE và S1 có được giữ ngoài thiết lập chính hay không.

6.8.1 Đánh giá trên các tác vụ chưa xuất hiện trong huấn luyện S1

Để kiểm tra khả năng khái quát sang tác vụ mới trong cùng nguồn dữ liệu, chúng tôi đánh giá các nhánh chính trên ACU, gồm 1.484 bước có thao tác chạm thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1 (Mục 3.3). Tập này bổ sung cho tập kiểm tra chính và tập trung riêng vào trường hợp mã tác vụ chưa xuất hiện trong huấn luyện S1. Quan hệ của ACU với cách chia chính thức của AndroidControl được trình bày ở Chương 3.

Bảng 6.12: Kết quả trên 1.484 bước có thao tác chạm của ACU. Cột AitW chỉ dùng vế khoảng cách vì ACU không có hộp phần tử vàng để tính tiêu chí hộp phần tử hoặc AitW đầy đủ.

Nhánh	Executability	Vế khoảng cách AitW
Base	49,80	57,95
S1/101	52,16	61,79
GRPO-SPICE, lượt 2	56,20	66,37
GRPO-SPICE	56,74	66,91
ACE	57,01	66,98
Câu chuẩn	71,70	83,29

GRPO-SPICE cao hơn S1/101 4,58 điểm executability, với khoảng tin cậy 95% [+3,17; +6,05] và $p = 2{,}1 \times 10^{-10}$. Lượt GRPO thứ hai cho kết quả cùng chiều, cao hơn S1/101 4,04 điểm [+2,66; +5,48]. ACE đạt 57,01%, là điểm cao nhất trong các nhánh đã tinh chỉnh trên ACU, và cao hơn S1/101 4,85 điểm [+3,43; +6,32]. Theo vế khoảng cách AitW, GRPO-SPICE và ACE cao hơn S1/101 lần lượt 5,12 và 5,19 điểm.

Mức tăng trên ACU lớn hơn mức +1,55 điểm trên tập kiểm tra chính, và được lặp lại ở cả hai lượt GRPO. Khi gộp hai tập thành 5.947 bước có thao tác chạm, GRPO-SPICE cao hơn S1/101 2,30 điểm [+1,62; +2,99], còn ACE cao hơn 2,39 điểm [+1,73; +3,05]. Mức cải thiện của GRPO-SPICE vì thế không chỉ xuất hiện ở tập kiểm tra chính mà còn được giữ trên những tác vụ S1 chưa gặp trong huấn luyện.

MDE của thiết kế trên tập kiểm tra chính là 2,11 điểm executability. Mức +1,55 trên tập kiểm tra chính nhỏ hơn MDE này, còn trên ACU, mức +4,58 có cả cận dưới khoảng tin cậy (+3,17) cao hơn 2,11. Khi gộp 5.947 bước, mức +2,30 cũng vượt MDE.

ACU và tập gộp vì vậy bổ sung bằng chứng về độ lớn cải thiện bên cạnh khoảng tin cậy ghép cặp trên tập kiểm tra chính.

Các thước dựa trên câu chuẩn cho cùng chiều và mức chênh còn lớn hơn tập kiểm tra chính. GRPO-SPICE cao hơn S1/101 ở cả bảy thước, và cả sáu thước có KTC đều nằm trên 0: BLEU-4 +2,32 [+0,74; +3,82], ROUGE-L +2,93 [+1,97; +3,92], CIDEr-D +26,73 [+15,84; +37,96], SPICE +2,51 [+1,18; +3,87], chrF +2,87 [+1,83; +3,94] và BERTScore +1,87 [+1,08; +2,71]. ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu thước có KTC. Trên nhóm tác vụ chưa xuất hiện trong huấn luyện S1, mức tăng xuất hiện đồng thời ở khả năng xác định phần tử và chất lượng câu.

So với tập kiểm tra chính, executability của S1 giảm từ 59,11% xuống 52,16%, trong khi GRPO-SPICE giảm từ 60,65% xuống 56,74%.

6.8.2 Đánh giá chuyển miền trên AitZ

Để kiểm tra khả năng chuyển sang một phân phối khác với AndroidControl, chúng tôi đánh giá các nhánh chính trên 2.736 bước có thao tác chạm của AitZ. Câu hướng dẫn từng bước của AitZ được sinh bằng GPT-4V rồi được người đánh giá đối chiếu với thao tác tham chiếu và sửa các trường hợp chưa phù hợp, nên phân phối câu chuẩn khác với AndroidControl. UGround có dữ liệu AITZ 8K trong tập huấn luyện công bố, vì vậy phép thử này được dùng để kiểm tra chuyển miền của mô hình sinh, không được dùng như một phép kiểm độc lập về dữ liệu của công cụ đánh giá. S1 đạt 37,79% executability so với 34,50% của Base, chênh +3,29 điểm với khoảng tin cậy 95% [+1,51; +5,03]. Mức tăng này xác nhận lợi ích của tinh chỉnh có giám sát vẫn được giữ khi đổi miền dữ liệu.

Trên AitZ, GRPO-SPICE đạt 37,28% executability, tương đương mức 37,79% của S1. Chênh lệch giữa hai nhánh là $-0{,}51$ điểm với khoảng tin cậy $[-1{,}39; +0{,}36]$, còn ACE giữ cùng mức 37,28%. Đặt cạnh kết quả ACU, hai phép kiểm cho hai góc nhìn bổ sung. GRPO-SPICE cải thiện rõ trên tác vụ mới trong cùng nguồn AndroidControl, còn trên AitZ với cách viết câu chuẩn khác, GRPO-SPICE và S1 cho executability tương đương. Sự khác biệt giữa hai tập gợi ý rằng phân phối câu chuẩn dùng trong huấn luyện có ảnh hưởng đến mức lợi ích của phần thưởng SPICE.

Bảng 6.13: Executability trên 2.736 bước có thao tác chạm của AitZ. Câu chuẩn được đưa qua cùng quy trình đánh giá để làm mốc diễn giải.

Nhánh	Executability
Base	34,50
S1/101	37,79
GRPO-SPICE	37,28
GRPO-SPICE, lượt 2	36,62
ACE	37,28
Câu chuẩn	66,26

Ở nhóm thước dựa trên câu chuẩn, GRPO-SPICE có điểm cao hơn S1 ở sáu trong bảy thước. Ba chênh lệch có KTC nằm trên 0 gồm BLEU-4 +0,47 [+0,01; +0,95], SPICE +1,10 [+0,53; +1,66] và chrF +0,62 [+0,22; +1,03]. ROUGE-L, CIDEr-D và BERTScore có KTC phủ 0. Vì vậy, khi chuyển sang AitZ, kết quả chính về executability được xem là tương đương S1, trong khi chất lượng câu theo một số thước vẫn giữ mức nhỉnh hơn.

6.8.3 Khi lịch sử thao tác do mô hình tự sinh

Các thực nghiệm chính dùng câu chuẩn của các bước trước làm lịch sử. Chúng tôi kiểm tra thêm trường hợp mỗi tác vụ được chạy tuần tự và câu do mô hình sinh ở bước trước được đưa trở lại làm lịch sử cho bước sau. Thiết lập này cho phép đánh giá trực tiếp việc kết quả có được giữ khi bỏ giả định lịch sử chuẩn hay không.

Bảng 6.14: Executability trên 4.463 bước có thao tác chạm khi lịch sử của các bước trước được thay bằng câu do chính mô hình sinh. Chênh lệch trong hàng cuối là GRPO-SPICE trừ S1.

Nhánh	Lịch sử chuẩn	Lịch sử tự sinh
S1/101	59,11	54,96
GRPO-SPICE	60,65	56,44
GRPO-SPICE − S1	+1,55 [+0,80; +2,33]	+1,48 [+0,54; +2,43]

Khi dùng lịch sử tự sinh, executability của cả hai nhánh cùng giảm khoảng bốn điểm, nhưng khoảng cách giữa GRPO-SPICE và S1 vẫn được giữ. GRPO-SPICE cao hơn S1 1,48 điểm với khoảng tin cậy 95% [+0,54; +2,43] và $p = 7{,}5 \times 10^{-4}$. Trên toàn bộ 4.463 bước có 811 bước phải dùng câu chuẩn thay cho một bước trước đó vì thiếu ảnh. Do đó, chúng tôi kiểm tra riêng 3.492 bước thuộc các tác vụ có đủ ảnh ở mọi bước. Trên tập con này, mức chênh là 1,66 điểm [+0,60; +2,75]. Trên cả hai mẫu, GRPO-SPICE vẫn cao hơn S1 với khoảng tin cậy nằm trên 0, kể cả khi lịch sử không còn luôn dùng câu chuẩn.

Kết quả theo loại thao tác cũng giữ cùng hướng ở các bước có thao tác chạm. GRPO-SPICE đạt 92,67% so với 89,16% của S1, chênh +3,52 điểm [+2,44; +4,69]. Ở 2.495 bước không chạm, xu hướng ngược lại rõ hơn khi dùng lịch sử tự sinh: S1 đạt 81,32% còn GRPO-SPICE đạt 76,83% về đúng loại thao tác. Chênh lệch GRPO-SPICE − S1 là −4,49 điểm [−6,48; −2,61], so với −1,68 điểm [−2,76; −0,62] khi dùng lịch sử chuẩn. Nếu gộp toàn bộ 6.958 bước, chênh lệch về đúng loại thao tác là +0,65 điểm [−0,35; +1,70]. Vì vậy, lợi thế trên các bước chạm không được suy rộng sang mọi loại thao tác, và xu hướng lệch về thao tác chạm rõ hơn khi lịch sử do chính mô hình sinh.

Với các thước dựa trên câu chuẩn, điểm của GRPO-SPICE cao hơn S1 ở cả bảy thước. Trong sáu thước có KTC, chrF tăng +0,83 [+0,07; +1,58], còn các KTC khác phủ 0. Bằng chứng rõ nhất trong thiết lập lịch sử tự sinh nằm ở executability trên bước chạm và khả năng giữ đúng loại thao tác ở nhóm này, còn các thước chữ giữ xu hướng cùng chiều với chênh lệch nhỏ hơn.

6.9 Phân tích độ vững của kết quả S1

Mức tăng 11,5 điểm giữa S1 và mô hình gốc được kiểm tra thêm dưới bảy cách phân nhóm và cách giải thích khác nhau ở Bảng 6.15. Chênh lệch vẫn giữ khi bỏ điều kiện đúng loại thao tác, chia theo vị trí trong chuỗi, độ phức tạp của màn hình và ứng dụng, thay công cụ đánh giá, hoặc loại nhóm câu có cùng nội dung từ với câu chuẩn. Phân tích cũng xem xét riêng mức độ gần với văn phong của câu chú thích để tách ảnh hưởng của bước tinh chỉnh.

Bảng 6.15: Phân tích các cách giải thích cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra.

Cách giải thích được kiểm tra	**Kết quả kiểm tra**
Do điều kiện đúng loại thao tác chi phối	khi bỏ điều kiện này và chỉ đánh giá phần định vị, chênh lệch vẫn còn +11,3 điểm (b=272, c=777). Hơn nữa Base gọi đúng loại thao tác nhiều hơn (96,5% so với 94,4%)
Chỉ cải thiện ở một vị trí trong chuỗi	bước mở đầu tác vụ +15,0 (n=593, [+11,0; +19,1]), các bước sau +11,0 ([+9,4; +12,6]). Hai khoảng tin cậy chồng lấp và đều nằm trên 0
Chỉ cải thiện trên màn hình ít phần tử	chia ba theo số phần tử trên màn cho +12,6, +9,5 và +12,4. Các khoảng giao nhau, không tầng nào đảo chiều
Kết quả bị chi phối bởi một số ít ứng dụng	trên 1.091 cụm, S1 cao hơn ở 395, bằng ở 565 và thấp hơn ở 131
Ảnh hưởng của văn phong chú thích	S1 mở đầu bằng động từ chạm ở 91,0% số câu, so với 86,1% của Base và 95,1% của câu chuẩn. Bước tinh chỉnh đồng thời làm cách diễn đạt của S1 gần hơn với văn phong chú thích. Yếu tố này được tính đến khi diễn giải chênh lệch tổng thể
Do công cụ đo phù hợp với văn phong chú thích	khi đánh giá lại bằng UI-Venus-Ground-7B, một công cụ định vị thứ hai, chênh lệch vẫn giữ 94% (Mục 5.9)
Do lặp lại nội dung câu chuẩn	1.095 trong 4.462 câu không rỗng của S1 lặp đúng các từ nội dung của câu chuẩn. Khi chỉ đánh giá 3.367 bước còn lại, S1 vẫn cao hơn +8,4 điểm (b=264, c=547, p<0,001)

Dòng cuối của bảng tách riêng nhóm bước mà S1 lặp lại các từ nội dung của câu chuẩn. Trên nhóm này, chênh lệch giữa S1 và mô hình gốc là 21,1 điểm, lớn hơn chênh lệch trên các bước còn lại. Vì vậy, việc lặp lại nội dung của câu chuẩn có thể góp phần làm tăng chênh lệch tổng thể. Tuy nhiên, S1 vẫn cao hơn 8,4 điểm trên 3.367 bước còn lại, nên thứ tự giữa hai mô hình không phụ thuộc riêng vào nhóm có nội dung giống câu chuẩn.

Điểm executability thay đổi theo độ dài câu: chia đôi câu của S1 ở độ dài trung vị 33 ký tự thì nhóm câu dài đạt 61,9%, nhóm câu ngắn đạt 56,5%. Nếu câu dài thực sự có lợi cho điểm số, xu hướng này còn nghiêng về phía mô hình gốc, vốn có độ dài trung vị khoảng 70 ký tự. Vì vậy, độ dài câu không giải thích được việc S1 đạt điểm cao hơn. Mối liên hệ giữa độ dài và điểm số cũng khác nhau giữa các mô hình (ở mô hình gốc, câu dài lại kém câu ngắn 1,4 điểm), nên cần được phân tích riêng cho từng mô hình.

6.10 Phân bố lỗi của mô hình tinh chỉnh có giám sát

Mục này xem xét các bước mà S1 chưa đạt executability, nhằm xác định những dạng lỗi còn lại sau tinh chỉnh có giám sát.

6.10.1 Kết quả theo mức độ xuất hiện của ứng dụng trong tập huấn luyện

Trong các bước của tập kiểm tra xác định được ứng dụng, 95,6% thuộc về ứng dụng cũng có trong tập huấn luyện (Mục 3.6). Bảng 6.16 so sánh S1 giữa các nhóm ứng dụng đã thấy, chưa thấy và không xác định. So sánh giữa hai nhóm đầu chỉ áp dụng trên phần dữ liệu xác định được ứng dụng.

Ba ước lượng gần như bằng nhau, lần lượt là 59,1%, 59,0% và 59,1%. Nhóm ứng dụng chưa xuất hiện trong huấn luyện chỉ có 78 bước, nên phân tích này được dùng như bằng chứng bổ sung rằng điểm S1 không thay đổi đáng kể giữa các nhóm ứng dụng trong phần dữ liệu xác định được.

Bảng 6.16: Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa.

Nhóm	S1	n
Ứng dụng đã thấy lúc huấn luyện	59,1%	1.737
Ứng dụng chưa thấy	59,0%	78
Không quy được về ứng dụng	59,1%	2.648

6.10.2 Phân loại lỗi còn lại

Trong 1.825 bước mà S1 không đạt executability, một bước là câu rỗng. Trong 1.824 bước còn lại, 251 bước có loại thao tác bị dự đoán sai. Ở 1.573 bước còn lại, chiếm 86%, loại thao tác đã đúng nhưng quy trình đánh giá vẫn không xác định được phần tử cần chạm từ câu hướng dẫn của S1. Một số câu hướng dẫn gọi sai hoặc mô tả chưa đủ rõ phần tử mục tiêu.

Câu chuẩn	Hướng dẫn của S1
click on the OK option	select minutes 00
Click on the Sort filter	Click on the Air India flight option
Click on the share icon	Open Recorder app

Trong các ví dụ này, lỗi còn lại nằm ở việc gọi tên sai hoặc mô tả chưa đủ rõ phần tử mục tiêu dù loại thao tác đã đúng. Ảnh hưởng của mô hình định vị và tiêu chí đánh giá lên các trường hợp chưa đạt được phân tích riêng ở Mục 6.12.

6.10.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh

Ở 798 bước mà S1 đúng còn mô hình gốc sai, hai dạng lỗi nổi bật trong các trường hợp được xem xét là viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại, hoặc mô tả một bước khác với bước cần làm.

	Câu
Câu chuẩn	Click on the profile icon at the top right of the screen
S1	Click on the profile icon at the top right corner of the screen
Base	To set YouTube video downloads over Wi-Fi only, tap on your profile icon at the top right corner of the screen and select “Settings.” Then navigate to the “Downloads” section and choose “Wi-Fi Only.”
Câu chuẩn	Click on Knoxville
S1	Click on Knoxville
Base	Click on the three dots next to Knoxville to access more options and proceed with reading the local news.

Ở dạng thứ nhất, mô hình gốc viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại. Ở dạng thứ hai, mô hình gốc mô tả một bước khác với bước cần làm. Câu của mô hình gốc vẫn trôi chảy, đúng khuôn và gọi tên nút cụ thể. Điểm thấp xuất hiện vì nội dung không bám sát bước đang xét chứ không phải do sai định dạng. Trong nhóm S1 đúng còn mô hình gốc sai, các ví dụ trên minh họa khác biệt về khả năng bám sát bước hiện tại giữa hai mô hình.

6.10.4 Đối chiếu với câu chuẩn

Phương pháp đề xuất đạt 60,68% executability, cao nhất trong các nhánh chính và cao hơn S1/101 1,57 điểm. Câu chuẩn đạt 75,7% và được dùng như một mốc tham chiếu thực nghiệm của toàn bộ quy trình đánh giá, thay vì một trần lý thuyết của chất lượng câu hướng dẫn (Mục 6.12). Việc đặt hai mức điểm cạnh nhau giúp xác định phần dư địa còn lại, đồng thời cần lưu ý rằng chính điểm của câu chuẩn cũng chịu ảnh hưởng của mô hình định vị và cách tính điểm.

6.11 Các phương án thiết kế đã khảo sát

Bảng 6.17 tóm tắt các phương án thiết kế đã khảo sát trước khi hình thành phương pháp đề xuất. Thiết kế và kết quả chi tiết được trình bày trong Phụ lục A.

Bảng 6.17: Các phương án thiết kế đã khảo sát. Điểm là executability trên 4.463 bước có thao tác chạm của tập kiểm tra, trừ khi ghi khác.

Hướng	Ý tưởng	Kết quả	Điều rút ra
Mô tả phần tử (S2), Mục A.1.3	viết một dòng mô tả phần tử cần chạm trước câu hướng dẫn	57,2%, thấp hơn S1/101 1,93 điểm	câu đầu ra đạt kết quả cao hơn ở nhóm mô tả đúng phần tử và giảm mạnh ở nhóm mô tả sai
Học theo cặp ưu tiên (MIN-DESC), Mục A.2.2	học theo cặp ưu tiên trên các đầu ra chỉ khác ở dòng mô tả	60,0%, trong đó 78% mức tăng so với S2 cũng có ở mô hình chỉ học thêm có giám sát	phần lớn cải thiện xuất hiện ở cấu hình chỉ học thêm
Chọn ứng viên, Mục A.3.2	chọn phần tử cần chạm trong danh sách được xây dựng sẵn	56,1%, chỉ có thể so sánh trực tiếp với mô hình gốc	khi đưa ra lựa chọn, độ chính xác cao, nhưng tần suất từ chối chọn lớn
Giai đoạn thưởng tọa độ, Mục A.4.2	học tăng cường với phần thưởng dựa trên độ chính xác của tọa độ trong dòng mô tả	60,1% (77,3% theo AitW đầy đủ)	độ chính xác tọa độ tăng, còn câu đầu ra thay đổi ít
Đưa thêm thông tin vị trí, Mục A.6	bổ sung thông tin vị trí cho mô hình sinh câu (bốn cách)	dừng ở tập kiểm định nội bộ	thông tin này chưa được phản ánh rõ trong đầu ra của mô hình sinh câu
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE), Mục A.7.2	viết lại câu hướng dẫn ban đầu sau khi xem ảnh phóng to quanh phần tử	60,2%, gần với câu hướng dẫn ban đầu	chất lượng câu hiệu chỉnh phụ thuộc mạnh vào việc vùng ảnh cục bộ có chứa đúng phần tử mục tiêu hay không

Các phương án dựa trên biểu diễn trung gian, như dòng mô tả phần tử hoặc tọa độ, tạo thay đổi rõ hơn ở biểu diễn trung gian so với câu hướng dẫn cuối (Mục A.5). Việc đưa thêm thông tin vị trí trực tiếp vào mô hình sinh cũng chỉ tạo thay đổi nhỏ ở đầu ra trong các cấu hình đã thử. Các quan sát này dẫn đến lựa chọn tối ưu trực tiếp câu hướng dẫn trong phương pháp cuối cùng, còn câu ví dụ chỉ được sử dụng khi thỏa ràng buộc nhất quán về loại thao tác.

6.12 Phân tích điểm của câu chuẩn trong quy trình đánh giá

Câu chuẩn đạt 75,7% executability trên 4.463 bước có thao tác chạm. Ở 1.083 bước chưa đạt, 64,8% có điểm do mô hình định vị trả về nằm ngoài vùng dung sai. Sai số trung vị của nhóm này là 26,2% bề ngang màn hình, so với 0,4% ở các bước đạt. Trong 381 bước còn lại, điểm đã nằm trong vùng dung sai nhưng không thỏa tiêu chí ô Voronoi. Ở 208 bước trong nhóm này, điểm dự đoán vẫn nằm trong hộp nhỏ nhất chứa điểm chạm, cho thấy sự khác nhau giữa cách xác định phần tử bằng hộp bao và bằng các tâm cạnh tranh. Điểm 75,7% vì vậy được sử dụng như một mốc thực nghiệm của toàn bộ quy trình đánh giá, thay vì một giới hạn của chất lượng câu hướng dẫn.

Chúng tôi kiểm tra thêm cách executability phản ứng với thông tin vị trí trong câu (Mục 5.5). Câu nêu tên một vùng trên màn đạt 89,5% khi vùng đó đúng, 3,3% khi vùng đó sai và 54,8% khi không nêu vùng nào. Executability tăng khi thông tin vị trí phù hợp với phần tử cần thao tác và giảm mạnh khi thông tin đó sai. S1 sử dụng từ chỉ vị trí trong 26,8% số câu, gần với 26,4% của câu chuẩn, và chỉ để lại chuỗi tọa độ trong 3 trên 6.958 câu. Hai mẫu câu phổ biến nhất của S1 chiếm 10,4% số bước, so với 6,5% ở câu chuẩn.