Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả thực nghiệm của phương pháp đề xuất trên tập kiểm tra. Sau kết quả tổng thể ở Mục 6.2, Mục 6.3 và Mục 6.4 phân tích riêng hai thành phần của phương pháp. Các mục tiếp theo xem xét độ ổn định giữa các lượt huấn luyện, đối chiếu nhiều nhóm độ đo và phân tích các dạng lỗi còn lại. Những phương án đã khảo sát trước khi hình thành phương pháp cuối cùng được tóm tắt ở Mục 6.10 và trình bày chi tiết trong Phụ lục A.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên cùng 4.463 bước có thao tác chạm của tập kiểm tra bằng cùng một quy trình đánh giá. Phương pháp đề xuất gồm mô hình học tăng cường với phần thưởng SPICE để sinh câu hướng dẫn ban đầu và ACE để quyết định có hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ hay không (Mục 4.4 đến Mục 4.6).

Ba mốc so sánh (Mục 4.7) gồm mô hình gốc (Base), mô hình tinh chỉnh có giám sát với hai seed 101 và 202 (S1), và câu tham chiếu được đưa trực tiếp vào quy trình đánh giá làm mốc tham chiếu để diễn giải thang điểm. Ở một bước, S1 trả về câu rỗng; bước này được tính là không đạt và vẫn nằm trong mẫu số 4.463.

6.2 Kết quả chính

† Mô hình chọn ứng viên khác các mô hình còn lại ở ba yếu tố của thiết lập (Mục A.3.1), nên chỉ có thể so sánh trực tiếp với mô hình gốc (Mục A.3.2). Các hướng đã thử khác

Bảng 6.1: Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra. Exec. là executability, KTC 95% là khoảng tin cậy 95% của executability. Hộp phần tử là tiêu chí của AndroidControl, khoảng cách Euclid là tiêu chí của AndroidInTheWild. BLEU-4 là trung bình theo câu, ROUGE-L theo F1. Số in đậm là số cao nhất của cột, không tính hàng câu tham chiếu.

Mô hình	Exec.	KTC 95%	Hộp phần tử	Khoảng cách Euclid	BLEU-4	ROUGE-L
Mốc so sánh						
Mô hình gốc (Base)	47,6	[45,9; 49,3]	53,6	63,4	9,9	40,4
Tinh chỉnh có giám sát (S1), seed 101	59,1	[57,3; 60,8]	65,5	74,4	38,7	67,3
Tinh chỉnh có giám sát (S1), seed 202	59,6	[57,9; 61,3]	66,1	75,3	39,0	67,6
Phương pháp đề xuất						
Thành phần thứ nhất (phần thưởng SPICE)	60,6	[58,9; 62,4]	67,0	76,2	40,1	68,3
Cả hai thành phần (SPICE + ACE)	**60,7**	[58,9; 62,4]	**67,1**	76,3	**41,2**	**69,1**
Các hướng đã thử (Phụ lục A)						
Mô tả phần tử (S2)	57,2	[55,4; 58,9]	63,6	73,4	36,4	65,9
Học thêm có giám sát (CE2-S2)	59,4	[57,7; 61,1]	66,0	76,1	38,1	68,6
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	[58,3; 61,8]	66,5	76,4	37,9	68,4
Thưởng tọa độ (giai đoạn ba)	60,1	[58,3; 61,8]	67,0	**77,3**	37,8	68,5
Chọn ứng viên†	56,1	[54,2; 58,0]	62,4	71,2	34,5	63,0
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	[58,5; 62,0]	66,4	76,1	40,1	68,4
Câu tham chiếu (mốc tham chiếu)	75,7	[74,1; 77,3]	83,8	92,1	96,1	100,0

(mô-đun định vị, đưa vai trò và vùng của phần tử vào mô hình, làm nét ảnh, mở khoá phần thị giác) không xuất hiện trong bảng vì chỉ được đánh giá trên tập kiểm định nội bộ (Mục A.6).

Kết quả ở Bảng 6.1 cho thấy phương pháp đề xuất đạt 60,7% executability, cao hơn S1/101 1,57 điểm. Khoảng tin cậy 95% của chênh lệch là [+0,86; +2,31], hoàn toàn nằm trên 0. Phương pháp cũng đạt kết quả cao nhất trong bảng theo tiêu chí hộp phần tử và hai độ đo văn bản được báo cáo. Riêng với tiêu chí khoảng cách Euclid, giai đoạn thưởng tọa độ đạt điểm cao hơn.

Phần lớn mức tăng executability so với S1/101 xuất hiện sau giai đoạn học tăng cường với phần thưởng SPICE, khi điểm đạt 60,6% (Mục 6.3). Mức tăng này đến từ một lượt huấn luyện; lượt huấn luyện lại với seed khác đạt 59,9%, thấp hơn 0,72 điểm, nên độ lớn của chênh lệch so với S1 cần được đọc cùng Mục 6.7. Sau khi bổ sung ACE, executability gần như không đổi, còn các độ đo dựa trên câu tham chiếu tiếp tục tăng (Mục 6.4). Để làm rõ nguồn gốc của chênh lệch giữa các mô hình, Bảng 6.2 phân rã executability theo ba điều kiện cấu thành.

Ở hàng câu tham chiếu, đầu vào đánh giá chính là câu tham chiếu nên điều kiện khớp loại thao tác luôn được thỏa mãn. Tỉ lệ khớp thao tác 98,9% của giai đoạn học theo cặp ưu tiên, mô hình học thêm có giám sát và giai đoạn thưởng tọa độ chỉ được tính trên các bước có thao tác chạm; vì vậy, kết quả này cần được xem cùng mức suy giảm trên các bước không chạm (Mục A.2.2.4). Mô hình chọn ứng viên (†) chỉ có thể so sánh trực tiếp với mô hình gốc (Mục A.3.2); tỉ lệ khớp thao tác của mô hình này thấp nhất bảng vì ở những bước không chọn được phần tử trong danh sách ứng viên, mô hình thường sinh câu mô tả một thao tác không chạm.

Khoảng cách giữa các mức tham chiếu. S1 cải thiện 11,5 điểm executability so với mô hình gốc, trong khi vẫn thấp hơn câu tham chiếu 16,6 điểm. Khoảng cách này cho thấy executability ghi nhận rõ mức cải thiện sau tinh chỉnh có giám sát và vẫn còn dư địa đáng kể cho các phương pháp tiếp theo (Mục 5.5, Mục 6.9.4).

Bảng 6.2: Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). Đạt đầy đủ: thoả cả ba điều kiện của executability. Chỉ ô Voronoi: điểm định vị nằm trong cửa sổ dung sai và trong ô Voronoi của phần tử cần chạm, chưa xét loại thao tác. Khớp thao tác: câu gọi đúng loại thao tác. Cửa sổ dung sai: điểm định vị nằm trong cửa sổ $\pm$14% theo từng trục quanh điểm chạm chuẩn.

Mô hình	Đạt đầy đủ	Chỉ ô Voronoi	Khớp thao tác	Cửa sổ dung sai
Câu tham chiếu (mốc tham chiếu)	75,7	75,8	100,0	84,3
Phương pháp đề xuất	60,7	61,5	96,0	70,4
Thành phần thứ nhất	60,6	61,4	96,0	70,3
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	61,0	96,6	70,1
Thưởng tọa độ (giai đoạn ba)	60,1	60,5	98,9	69,9
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	60,4	98,9	69,2
S1 (seed 202)	59,6	60,7	94,6	69,8
Học thêm có giám sát (CE2-S2)	59,4	59,8	98,9	68,9
S1 (seed 101)	59,1	60,2	94,4	69,2
Mô tả phần tử (S2)	57,2	58,1	94,8	67,4
Chọn ứng viên†	56,1	57,4	90,9	66,3
Mô hình gốc (Base)	47,6	48,9	96,5	57,6

6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Mục này đánh giá độc lập thành phần thứ nhất (thiết kế ở Mục 4.5). Mô hình học tăng cường với phần thưởng SPICE học tiếp từ S1 seed 101, nên được so sánh trực tiếp với cấu hình này.

Phân tích tín hiệu phần thưởng trên tập kiểm định nội bộ. Trước khi huấn luyện, S1 được dùng để sinh một câu bằng giải mã tham lam và tám câu bằng lấy mẫu cho mỗi bước. Nếu chọn câu có SPICE cao nhất so với câu tham chiếu, executability cao hơn so với câu từ giải mã tham lam; trong khi đó, việc chọn ngẫu nhiên một trong tám câu không tạo ra xu hướng tương tự. Executability cũng có xu hướng giảm ở những câu có thứ hạng SPICE thấp hơn trong cùng một nhóm. Dù vậy, SPICE không phân biệt được mọi trường hợp: ở khoảng một phần ba số cặp gồm một câu dẫn tới đúng phần tử và một câu không, hai câu nhận cùng điểm. Vì thế, kết quả trên tập kiểm định nội bộ chỉ cho thấy SPICE cung cấp một tín hiệu phân biệt hữu ích cho quá trình phát triển, chứ không phải một tiêu chí hoàn hảo. Các kết quả này chỉ được dùng để lựa chọn thiết kế và không được báo cáo như kết quả chính của luận văn.

Lựa chọn checkpoint. Checkpoint ở bước 250 và 500 được so sánh trên cùng tập kiểm định nội bộ. Mức tăng SPICE của cả hai đều nhỏ, trong khi executability tăng theo số bước; các bước chuyển từ sai sang đúng ở checkpoint 250 so với S1 tiếp tục được dự đoán đúng ở checkpoint 500. Trên cơ sở đó, checkpoint 500 được chọn và cố định trước khi sinh câu trên tập kiểm tra.

6.3.1 Kết quả trên các bước có thao tác chạm

Mô hình học tăng cường với phần thưởng SPICE đạt điểm cao hơn S1 trên cả mười ba độ đo trong Bảng 6.3. Với sáu độ đo dựa trên vị trí, khoảng tin cậy của chênh lệch đều nằm hoàn toàn trên 0. Riêng executability tăng 1,55 điểm, với $p = 1{,}6 \times 10^{-5}$ theo kiểm định McNemar (Mục 6.6). Đây là cấu hình đầu tiên trong các thí nghiệm của luận văn cho thấy mức cải thiện có ý nghĩa thống kê so với S1 theo executability, dù khi huấn luyện lại với seed khác mức cải thiện giảm còn 0,83 điểm (Mục 6.7). Một

Bảng 6.3: Mô hình học tăng cường với phần thưởng SPICE so với S1 seed 101 trên 4.463 bước có thao tác chạm, ghép cặp theo bước. Sáu hàng trên là độ đo theo vị trí (gồm cả tỉ lệ đúng loại thao tác), bảy hàng dưới là độ đo so với câu tham chiếu. Δ là điểm của mô hình học tăng cường với phần thưởng SPICE trừ điểm của S1; KTC 95% từ bootstrap theo cách gom cụm ở Mục 5.13. Sai→Đúng là số bước mà mô hình học tăng cường đạt còn S1 không đạt; Đúng→Sai là chiều ngược lại.

Độ đo	**S1**	**Phần thưởng SPICE**	Δ	**KTC 95%**	**Sai→Đúng / Đúng→Sai**
Executability	59,11	60,65	+1,55	[+0,80; +2,33]	159 / 90
Tiêu chí hộp phần tử	65,49	67,02	+1,52	[+0,77; +2,29]	165 / 97
Tiêu chí khoảng cách Euclid	74,37	76,25	+1,88	[+1,17; +2,63]	172 / 88
Euclid cận trên	81,04	82,90	+1,86	[+1,17; +2,60]	163 / 80
$\pm$14% theo trục	67,24	68,90	+1,66	[+0,90; +2,46]	172 / 98
Đúng loại thao tác	94,35	95,97	+1,61	[+1,17; +2,08]	83 / 11
SPICE	44,37	45,79	+1,42		
BLEU-4	51,56	52,36	+0,80		
METEOR	36,79	37,92	+1,13		
ROUGE-L	67,35	68,36	+1,01		
CIDEr-D	416,12	430,05	+13,93		
chrF	61,26	62,87	+1,61		
BERTScore	66,33	67,07	+0,74		

điểm đáng chú ý là phần thưởng huấn luyện chỉ dựa trên SPICE và không sử dụng mô hình định vị, nhưng các độ đo dựa trên vị trí vẫn tăng đồng thời.

Phân rã nguồn gốc mức cải thiện. Trong 159 bước chuyển từ sai sang đúng, 36 bước là những trường hợp S1 dự đoán sai loại thao tác. Ở chiều ngược lại, trong 90 bước chuyển từ đúng sang sai, chỉ 8 bước xuất phát từ lỗi loại thao tác của mô hình học tăng cường. Như vậy, việc sửa loại thao tác đóng góp ròng 28 bước, tương đương +0,63 điểm. Phần cải thiện còn lại đến từ 4.200 bước mà cả hai mô hình đều xác định đúng loại thao tác: trên nhóm này, executability tăng từ 62,62 lên 63,60, tương đương thêm 41 bước đúng (+0,92 điểm). Nói cách khác, hơn một nửa mức cải thiện quan sát được xuất hiện ở khả năng xác định đúng phần tử cần chạm sau khi loại thao tác đã được dự đoán đúng.

So với S1, mô hình học tăng cường chỉ thay đổi một phần đầu ra: 2.795 trong 4.463 câu được giữ nguyên hoàn toàn, còn độ dài trung bình chỉ tăng từ 7,83 lên 7,96 từ. Vì vậy, mức cải thiện không thể giải thích đơn thuần bằng việc sinh câu dài hơn (Hình 6.1).

Kiểm tra trên các bước không chạm. Vì executability chỉ áp dụng cho bước có thao tác chạm, thành phần này được kiểm tra thêm bằng tỉ lệ khớp loại thao tác trên 2.495 bước không chạm, với biến thể chuẩn hoá đã sửa lỗi các cụm quay lại ở Mục 5.1. So với S1/101, điểm giảm từ 85,97% xuống 84,29%, tương ứng $-1,68$ điểm với khoảng tin cậy 95% $[-2,76; -0,62]$. Mức giảm rõ nhất xuất hiện ở thao tác cuộn, từ 83,97% xuống 77,75% ($-6,23$ điểm; $[-8,30; -4,31]$), và ở thao tác quay lại, từ 72,96% xuống 67,04% ($-5,93$ điểm; $[-9,42; -2,58]$). Vì vậy, mức cải thiện quan sát được trên các bước có thao tác chạm không đồng nghĩa với cải thiện đồng đều trên mọi loại thao tác; các kết luận chính về executability trong mục này được giới hạn ở 4.463 bước có thao tác chạm.

So sánh với các cấu hình khác. Mức cải thiện vẫn được duy trì khi so với S1 được huấn luyện với seed 202 (+1,03 điểm; p = 0,014). Tuy nhiên, lượt huấn luyện lại thành phần này với seed khác chỉ cao hơn S1 seed 202 0,31 điểm và chênh lệch không có ý nghĩa thống kê (Mục 6.7); vì vậy, chưa thể khẳng định mức cải thiện so với S1 ổn định qua các lượt huấn luyện. So với hai hướng thử có executability cao nhất là giai đoạn thưởng tọa độ và giai đoạn học theo cặp ưu tiên, chênh lệch khoảng 0,6 điểm và

chưa có ý nghĩa thống kê (Bảng 6.8). Giai đoạn thưởng tọa độ có ưu thế ở tỉ lệ đúng loại thao tác và một số tiêu chí vị trí lỏng hơn, trong khi mô hình học tăng cường với phần thưởng SPICE đạt executability cao hơn và cao hơn ở sáu trong bảy độ đo dựa trên câu tham chiếu. Ở lượt huấn luyện này, mức cải thiện có cùng chiều trên toàn bộ các độ đo được báo cáo và vẫn dương khi so với cả hai lượt huấn luyện S1.

6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Trên tập kiểm tra, điều kiện đồng thuận của ACE (Mục 4.6) thay thế 402 trong 4.463 câu hướng dẫn ban đầu (9,0%). Bảng 6.4 so sánh ACE, tức phương pháp đề xuất, với câu hướng dẫn ban đầu và với mô hình sinh câu độc lập, trong đó đầu ra của mô hình sinh được sử dụng ở mọi bước.

Khả năng của kho truy hồi. Với mỗi bước có thao tác chạm trong tập kiểm tra, bốn câu tham chiếu gần nhất được truy hồi từ tập huấn luyện theo quy trình ở Mục 4.6. Trong 15,8% số bước, ít nhất một câu ví dụ giống hoàn toàn với câu tham chiếu của bước đang xét. Ở 9,8% số bước, điều này xảy ra đồng thời với việc câu hướng dẫn ban đầu của thành phần thứ nhất không đạt. Nếu luôn có thể nhận ra và chọn đúng câu ví dụ trong các trường hợp này, BLEU-4 tính trên toàn tập có thể tăng khoảng 5 điểm và CIDEr-D khoảng 65 điểm. Tuy nhiên, một chiến lược đơn giản như luôn lấy câu ví dụ đứng đầu lại làm BLEU-4 giảm từ 52,4 xuống 28,3. Kết quả này cho thấy kho truy hồi có chứa thông tin hữu ích, nhưng việc khai thác thông tin đó phụ thuộc vào cơ chế lựa chọn câu ví dụ. Phân tích này được dùng để giải thích vai trò của điều kiện đồng thuận, không thay thế kết quả đánh giá trực tiếp của ACE.

Kết quả. So với câu hướng dẫn ban đầu, ACE làm tăng cả bảy độ đo dựa trên câu tham chiếu, trong đó mức tăng rõ nhất xuất hiện ở CIDEr-D (+11,98) và SPICE (+1,34). Ngược lại, ba độ đo dựa trên vị trí hầu như không thay đổi. Trong 402 câu được thay thế, có 15 bước chuyển từ sai sang đúng và 14 bước chuyển theo chiều ngược lại ($p = 1,0$). Vì vậy, ACE gần như giữ nguyên mức executability mà thành phần thứ nhất đã đạt được, đồng thời làm câu đầu ra gần hơn với câu tham chiếu theo các độ đo văn bản. Theo tiêu chí hộp phần tử và tiêu chí khoảng cách Euclid, phương pháp hoàn

Bảng 6.4: ACE trên 4.463 bước có thao tác chạm, so với câu hướng dẫn ban đầu (của mô hình học tăng cường với phần thưởng SPICE) và với mô hình sinh câu độc lập. Ba độ đo vị trí kèm khoảng tin cậy 95% từ bootstrap theo cách gom cụm ở Mục 5.13. Bảy độ đo dựa trên câu tham chiếu chưa có khoảng tin cậy; cột ACE − câu hướng dẫn ban đầu lệch tối đa 0,02 so với Bảng 6.3 do được đánh giá lại.

Độ đo	**Câu ban đầu**	**Mô hình sinh độc lập**	**ACE**	**ACE − câu ban đầu**
Executability	60,65	59,40	60,68	+0,02 [−0,21; +0,26]
Tiêu chí hộp phần tử	67,02	65,81	67,11	+0,09 [−0,15; +0,33]
Tiêu chí khoảng cách Euclid	76,25	75,02	76,32	+0,07 [−0,15; +0,29]
BLEU-4	52,36	53,47	53,47	+1,11
METEOR	37,91	37,79	38,37	+0,46
ROUGE-L	68,34	68,67	69,08	+0,74
CIDEr-D	430,04	437,54	442,02	+11,98
SPICE	45,79	46,79	47,13	+1,34
chrF	62,86	62,65	63,44	+0,58
BERTScore	67,07	67,52	67,73	+0,66

chỉnh cao hơn S1 lần lượt 1,61 và 1,95 điểm; cả hai chênh lệch đều có $p < 0{,}001$.

Ảnh hưởng khi sử dụng mô hình sinh câu độc lập. Mô hình sinh câu độc lập đạt điểm cao hơn câu hướng dẫn ban đầu trên năm trong bảy độ đo dựa trên câu tham chiếu, nhưng thấp hơn 1,25 điểm executability [−2,06; −0,44] ($p = 0{,}002$). Ở 19,1% số bước, mô hình lặp lại hoàn toàn một câu ví dụ; trong nhóm này, 43,5% số câu giống hoàn toàn với câu tham chiếu, gần gấp đôi tỉ lệ của câu hướng dẫn ban đầu (22,8%). Ngược lại, ở những bước mô hình tạo một câu mới, kết quả thấp hơn câu hướng dẫn ban đầu. Kết quả này cho thấy truy hồi có ích khi mô hình lựa chọn đúng câu ví dụ, nhưng việc thay câu hướng dẫn ban đầu cần đi kèm điều kiện lựa chọn.

Đóng góp của ràng buộc nhất quán loại thao tác. Nếu chỉ dùng điều kiện sao chép, ACE thay 453 câu và vẫn làm tăng cả bảy độ đo dựa trên câu tham chiếu, nhưng executability thấp hơn câu hướng dẫn ban đầu 0,11 điểm (24 bước chuyển từ sai sang đúng và 29 bước chuyển từ đúng sang sai). Ràng buộc loại thao tác loại 51 câu không nhất quán, nhờ đó ACE cao hơn biến thể chỉ dùng điều kiện sao chép 0,13 điểm executability và không thấp hơn ở độ đo nào trong Bảng 6.4.

Phạm vi cải thiện. Lợi ích quan sát được của ACE tập trung ở các độ đo văn bản: cả bảy độ đo dựa trên câu tham chiếu đều tăng, trong khi executability về cơ bản được giữ ổn định. Vì chưa có khoảng tin cậy cho bảy độ đo văn bản, kết quả này chỉ cho thấy xu hướng đầu ra gần câu tham chiếu hơn; chưa đủ để kết luận về độ lớn hay độ ổn định của mức tăng trên các độ đo đó.

6.5 Đánh giá trên nhiều nhóm độ đo

Ngoài executability, luận văn trình bày thêm hai nhóm chỉ số: các độ đo dựa trên vị trí và các độ đo dựa trên câu tham chiếu. Cả hai nhóm được tính lại từ bản ghi ở mức từng bước của các lượt đánh giá trong Bảng 6.1. Hai bảng trong mục này chưa bao gồm hàng của phương pháp đề xuất; kết quả tương ứng được trình bày tại Bảng 6.1 và Bảng 6.4.

Nhóm độ đo theo vị trí. Bảng 6.5 trình bày ba tiêu chí đánh giá chính cùng hai biến thể ở Mục 5.12. Thứ tự các mô hình theo tiêu chí khoảng cách Euclid và hộp phần tử nhìn chung gần với thứ tự theo executability. Phương pháp đề xuất đạt 76,3% theo khoảng cách Euclid và 67,1% theo hộp phần tử, cao hơn S1 seed 101 lần lượt 1,95 và 1,61 điểm; cả hai chênh lệch đều có $p < 0{,}001$. Giai đoạn thưởng tọa độ đạt giá trị cao nhất theo khoảng cách Euclid (77,3%), nhưng phân tích ở Mục A.4.2 cho thấy phần lớn chênh lệch của cấu hình này gắn với việc dự đoán đúng loại thao tác, chưa cho thấy mức tăng tương ứng về khả năng xác định phần tử.

Sai số và kết luận theo ba tiêu chí. Bảng 6.7 trình bày khoảng tin cậy theo ba tiêu chí, được tính trên cùng các mẫu bootstrap nên có thể đối chiếu trực tiếp giữa các cột. Chênh lệch giữa S1 seed 101 và mô hình gốc gần như không thay đổi giữa ba tiêu chí, đều với $p < 0{,}001$, và phương pháp đề xuất cao hơn S1 có ý nghĩa theo cả ba tiêu chí (Mục 6.4). Với các hướng đã thử, kết luận thay đổi tùy tiêu chí. Mô hình mô tả phần tử thấp hơn S1 có ý nghĩa theo executability (Mục A.1.3) nhưng không theo tiêu chí khoảng cách Euclid. Theo tiêu chí khoảng cách Euclid, phần lớn mức tăng của giai đoạn học theo cặp ưu tiên và giai đoạn thưởng tọa độ so với mô hình mô tả phần tử cũng xuất hiện ở mô hình chỉ học thêm có giám sát với cùng số bước. Giai đoạn thưởng tọa độ cao hơn S1 có ý nghĩa theo hai tiêu chí vị trí, nhưng không theo

Bảng 6.5: Nhóm độ đo theo vị trí trên đủ 4.463 bước có thao tác chạm, tính lại từ bản ghi từng bước, không gọi lại mô hình định vị. Khoảng cách Euclid là tiêu chí khoảng cách Euclid trong mã đánh giá gốc của AndroidInTheWild; khoảng cách Euclid cận trên là biến thể của tiêu chí này khi xét khung của mọi phần tử có thể thao tác trên màn hình (Mục 5.12). Hộp phần tử là tiêu chí gốc của AndroidControl. Exec. là executability (Mục 5.12). Thao tác là tỉ lệ gọi đúng loại thao tác. Số in đậm là số cao nhất trong các mô hình ở cột đó. *Phần thưởng SPICE là thành phần thứ nhất của phương pháp đề xuất, học tiếp từ S1 (101) bằng GRPO với phần thưởng SPICE; TAGE là mô-đun hiệu chỉnh câu đã thử đặt sau thành phần đó (Mục 6.3 và A.7.2). Bảng chưa có hàng của phương pháp đề xuất; kết quả của phương pháp này được trình bày ở Bảng 6.4. †Mô hình chọn ứng viên khác ba yếu tố thiết lập so với các mô hình còn lại nên chỉ có thể so sánh trực tiếp với Base.

Mô hình	Euclid	Hộp phần tử	Exec.	±14% trục	Euclid cận trên	Thao tác
Base	63,4	53,6	47,6	55,9	73,4	96,5
S1 (101)	74,4	65,5	59,1	67,2	81,0	94,3
S1 (202)	75,3	66,1	59,6	67,9	81,9	94,6
S2	73,4	63,6	57,2	65,7	80,8	94,8
CE2-S2	76,1	66,0	59,4	68,5	83,9	**98,9**
MIN-DESC	76,4	66,5	60,0	68,7	84,4	**98,9**
Giai đoạn ba	**77,3**	**67,0**	60,1	**69,4**	**85,0**	**98,9**
Phần thưởng SPICE*	76,2	**67,0**	**60,6**	68,9	82,9	96,0
TAGE	76,1	66,4	60,2	68,7	82,7	96,6
Chọn ứng viên†	71,2	62,4	56,1	63,9	77,9	90,9
Câu tham chiếu	92,1	83,8	75,7	84,2	96,2	100,0

Bảng 6.6: Nhóm độ đo so với câu tham chiếu trên đủ 4.463 bước có thao tác chạm. BLEU-4, METEOR 1.5, ROUGE-L, CIDEr-D và SPICE được tính bằng bộ công cụ đánh giá chính thức của COCO Captions, sau khi tách từ bằng PTBTokenizer. chrF được tính bằng sacreBLEU. BERTScore là F1 với roberta-large tầng 17, đã hiệu chỉnh theo đường cơ sở. Mỗi bước chỉ có một câu tham chiếu. Số in đậm là số cao nhất trong các mô hình ở cột đó. Giai đoạn ba là giai đoạn thưởng tọa độ, học tiếp từ MIN-DESC với phần thưởng đặt trên tọa độ trong dòng mô tả. *Thành phần thứ nhất của phương pháp đề xuất; kết quả của phương pháp đề xuất được trình bày ở Bảng 6.4. Với TAGE mới tính SPICE. †Mô hình chọn ứng viên chỉ có thể so sánh trực tiếp với Base.

Mô hình	**BLEU-4**	**METEOR**	**ROUGE-L**	**CIDEr-D**	**SPICE**	**chrF**	**BERTScore**
Base	15,3	24,6	42,3	88,0	18,5	40,2	40,1
S1 (101)	51,6	36,8	67,3	416,1	44,4	61,3	66,3
S1 (202)	51,7	37,2	67,7	419,2	44,2	61,9	66,8
S2	48,7	35,8	66,0	387,7	41,3	59,9	65,1
CE2-S2	50,1	37,3	**68,6**	402,2	42,3	61,9	66,8
MIN-DESC	49,9	37,3	68,5	401,0	42,2	61,8	66,7
Giai đoạn ba	49,9	37,3	68,5	402,9	42,5	61,9	66,8
Phần thưởng SPICE*	**52,4**	**37,9**	68,4	**430,1**	**45,8**	**62,9**	**67,1**
TAGE	–	–	–	–	45,7	–	–
Chọn ứng viên†	46,9	34,2	63,3	370,6	39,3	57,7	62,8
Câu tham chiếu	100,0	100,0	100,0	988,7	98,6	100,0	100,0

Bảng 6.7: Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và so sánh ghép cặp (dưới). Khoảng tin cậy được ước lượng bằng 10.000 lần bootstrap theo cách gom cụm ở Mục 5.13, gồm 1.091 cụm; giá trị p dùng kiểm định McNemar. MIN là MIN-DESC; giai đoạn ba là giai đoạn thưởng tọa độ (Phụ lục A.4).

Mô hình	**Euclid**	**Hộp phần tử**	**Executability**
Base	63,4 [61,8; 65,0]	53,6 [51,9; 55,3]	47,6 [45,9; 49,3]
S1 (101)	74,4 [72,8; 75,8]	65,5 [63,8; 67,2]	59,1 [57,3; 60,8]
S1 (202)	75,3 [73,8; 76,7]	66,1 [64,4; 67,7]	59,6 [57,9; 61,3]
MIN	76,4 [74,9; 77,8]	66,5 [64,9; 68,2]	60,0 [58,3; 61,8]
Giai đoạn ba	77,3 [75,8; 78,8]	67,0 [65,3; 68,7]	60,1 [58,3; 61,8]
Câu tham chiếu	92,1 [91,1; 93,1]	83,8 [82,5; 85,1]	75,7 [74,1; 77,3]

Phép so	**Tiêu chí**	**Δ**	**KTC 95%**	**p**
S1 (101) − Base	Euclid	+10,98	[+9,44; +12,56]	<0,001
	Hộp phần tử	+11,90	[+10,36; +13,47]	<0,001
	Exec.	+11,52	[+10,02; +13,07]	<0,001
S2 − S1 (101)	Euclid	-0,96	[−2,18; +0,29]	0,100
	Hộp phần tử	-1,86	[−3,04; −0,67]	<0,001
	Exec.	-1,93	[−3,06; −0,75]	<0,001

executability.

> Mức cải thiện theo tiêu chí khoảng cách Euclid tập trung ở 256 bước (5,7%) mà S1 dự đoán sai loại thao tác, chẳng hạn sinh câu mô tả thao tác vuốt hoặc cuộn khi bước đúng là chạm. Nhóm này đóng góp +3,11 điểm theo tiêu chí khoảng cách Euclid và +1,97 điểm theo executability; khi so với seed 202, mức đóng góp tương ứng là +3,09 điểm. Ở 4.189 bước mà cả hai mô hình đều dự đoán đúng loại thao tác, tỉ lệ đạt gần như tương đương (79,04% so với 78,92%). Tiêu chí khoảng cách Euclid cũng không loại những lần chạm rơi vào phần tử sát bên, trong khi executability loại các trường hợp này. Giai đoạn thưởng tọa độ mắc lỗi này nhiều hơn, nên trên nhóm bước mà cả hai mô hình đều dự đoán đúng loại thao tác, giai đoạn này thấp hơn S1 0,81 điểm theo executability. Do đó, trong phân rã này, mức cải thiện của hai giai đoạn chủ yếu gắn với việc dự đoán đúng loại thao tác, chưa cho thấy cải thiện tương ứng về khả năng định vị phần tử.

Nhóm độ đo so với câu tham chiếu. Bảng 6.6 sử dụng các độ đo được báo cáo trong Widget Captioning [9] và Screen2Words [10], gồm BLEU [19], METEOR [21], ROUGE-L [20], CIDEr [22] và SPICE [23], cùng chrF [24] và BERTScore [25]. BLEU-4 trong bảng này được tính trên toàn tập bằng bộ công cụ của COCO Captions, nên khác với BLEU-4 trung bình theo từng câu ở Bảng 6.1. Tinh chỉnh có giám sát cải thiện tất cả các độ đo trong nhóm; chẳng hạn SPICE, độ đo mà Zhao và cộng sự [36] khuyến nghị để xếp hạng các mô hình sinh chỉ dẫn khi có câu tham chiếu, tăng từ 18,5 ở mô hình gốc lên 44,4 ở S1 seed 101. Phương pháp đề xuất tiếp tục làm tăng các độ đo này (Bảng 6.4). BERTScore sử dụng phiên bản đã co giãn theo mức điểm nền (*baseline rescaling*), vì ở phiên bản chưa co giãn, mọi mô hình đã tinh chỉnh đều nằm trong khoảng 93,5 đến 94,4. Câu rỗng được tính 0 điểm và vẫn nằm trong mẫu số, tương tự quy ước của executability.

CIDEr-D vượt quá 100 vì mỗi bước chỉ có một câu tham chiếu và trọng số nghịch đảo tần suất văn bản (IDF) được ước lượng từ chính tập câu tham chiếu; vì vậy, giá trị này chỉ nên được so sánh giữa các hàng trong cùng bảng. Ở các mô hình có kết quả gần nhau, thứ hạng theo nhóm độ đo dựa trên câu tham chiếu không hoàn toàn trùng với executability, phù hợp với phân tích ở Mục 5.11. Trong luận văn, nhóm độ đo này

chủ yếu phục vụ đối chiếu với các công trình cùng mảng; so sánh giữa các mô hình vẫn dựa trên executability.

6.6 So sánh ghép cặp

Mọi mô hình được đánh giá trên cùng một tập bước, nên các so sánh được thực hiện theo cặp ở mức từng bước bằng kiểm định McNemar (Mục 5.13); Bảng 6.8 tổng hợp các so sánh được sử dụng trong chương.

Bảng 6.8: So sánh ghép cặp trên 4.463 bước. *b* là số bước mà mô hình sau dấu trừ đạt còn mô hình trước dấu trừ không đạt, *c* là chiều ngược lại, nên Δ = (c-b)/n. Bảng tổng hợp các khoảng tin cậy từ những phân tích đã thực hiện; đơn vị gom cụm không hoàn toàn đồng nhất giữa các hàng. Các phân tích chính dùng cách gom cụm ở Mục 5.13; riêng hàng phần thưởng SPICE − S1/101 trong bảng này dùng gom theo tác vụ, còn khoảng theo cách gom cụm chính là [+0,80; +2,33] như Bảng 6.3. Base là mô hình gốc; S1/101 và S1/202 là mô hình tinh chỉnh có giám sát với seed 101 và 202. Câu rỗng được tính là không đạt và vẫn nằm trong mẫu số 4.463. Phần thưởng SPICE là thành phần thứ nhất của phương pháp đề xuất; học ưu tiên là MIN-DESC; học thêm là mô hình chỉ học thêm có giám sát (CE2-S2); TAGE là mô-đun hiệu chỉnh câu theo vùng cắt.

So sánh	Δ	KTC 95%	b	c	p
Mốc so sánh (S1 có hai seed)					
S1 − Base	+11,5	[+10,0; +13,1]	284	798	<0,001
Câu tham chiếu − S1/101	+16,6	–	102	844	<0,001
Câu tham chiếu − Base	+28,1	–	102	1.358	<0,001
S1/202 − S1/101 (hai seed)	+0,52	[−0,22; +1,26]	132	155	0,194
Phương pháp đề xuất và các so sánh liên quan					
Phương pháp đề xuất − S1/101	+1,57	[+0,86; +2,31]	88	158	<0,001
Phương pháp đề xuất − phần thưởng SPICE	+0,02	[−0,21; +0,26]	14	15	1,00
Phần thưởng SPICE − S1/101	+1,55	[+0,82; +2,28]	90	159	<0,001
Phần thưởng SPICE − S1/202	+1,03	[+0,25; +1,83]	145	191	0,014
Phần thưởng SPICE (lượt 2) − S1/101	+0,83	[0,00; +1,67]	129	166	0,036
Phần thưởng SPICE (lượt 2) − S1/202	+0,31	[−0,53; +1,17]	180	194	0,50
Phần thưởng SPICE (lượt 2) − lượt 1	-0,72	[−1,27; −0,16]	91	59	0,011

So sánh	Δ	KTC 95%	b	c	p
Phần thưởng SPICE − học theo cặp ưu tiên	+0,60	[−0,52; +1,73]	304	331	0,30
Phần thưởng SPICE − thưởng tọa độ	+0,58	[−0,50; +1,69]	286	312	0,31
TAGE − phần thưởng SPICE	-0,43	[−0,87; +0,02]	67	48	0,093
Hướng đã thử (Phụ lục A)					
Mô tả phần tử (S2) − S1/101	-1,93	[−3,06; −0,75]	340	254	0,0005
S2 − S1/202	-2,44	[−3,53; −1,34]	353	244	<0,001
S2 − Base	+9,59	[+8,16; +11,06]	324	752	<0,001
Học thêm − S2	+2,24	[+1,41; +3,11]	127	227	<0,001
Học theo cặp ưu tiên − S2	+2,87	[+2,03; +3,76]	130	258	<0,001
Học theo cặp ưu tiên − học thêm	+0,63	[+0,16; +1,10]	42	70	0,011
Học theo cặp ưu tiên − S1/101	+0,94	[−0,09; +2,05]	300	342	0,11
Học thêm − S1/101	+0,31	[−0,76; +1,45]	312	326	0,61
Chọn ứng viên − Base	+8,54	–	350	731	<0,001

Với seed 101, tinh chỉnh có giám sát trên tập dữ liệu được xây dựng tự động cải thiện executability thêm 11,5 điểm, tương ứng thu hẹp 41% khoảng cách giữa mô hình gốc và câu tham chiếu; phần dư địa còn lại được phân tích ở Mục 6.9.4. Tỉ lệ này chịu ảnh hưởng của việc ở khoảng một phần tư số bước, câu của S1 lặp lại nội dung của câu tham chiếu. Khi chỉ xét 3.367 bước còn lại, mô hình gốc, S1 và câu tham chiếu đạt lần lượt 44,7, 53,1 và 75,0, và tỉ lệ thu hẹp khoảng cách giảm còn 28%.

6.7 Biến thiên giữa các lượt huấn luyện

Để mô tả mức biến thiên khi huấn luyện lại, cả mô hình tinh chỉnh có giám sát (S1) và thành phần thứ nhất của phương pháp đề xuất đều được huấn luyện thêm một lượt, chỉ đổi seed và giữ nguyên mọi tham số cấu hình khác (Mục A.1.2). Mục 6.7.2 trình bày lượt thứ hai của thành phần thứ nhất.

6.7.1 Hai lượt huấn luyện S1

Bảng 6.9: Hai lượt huấn luyện chỉ khác seed, đánh giá trên cùng 4.463 bước.

	Điểm	**Δ ghép cặp**	**Bước bất đồng**
S1 seed 101	59,11%	+0,52 pp	287 = 6,4%
S1 seed 202	59,62%		
So sánh S1 − Base		+11,5 pp	1.082 = 24,2%

Chênh lệch 0,52 điểm giữa hai seed không có ý nghĩa thống kê (khoảng tin cậy 95% chứa 0, p = 0,194, Bảng 6.8). Hai lượt cho kết quả khác nhau ở 6,4% số bước, so với 24,2% giữa S1 và mô hình gốc; xét độ lớn của điểm, chênh lệch giữa S1 và mô hình gốc lớn gấp 22 lần chênh lệch giữa hai seed, và gấp 3,8 lần nếu xét tỉ lệ bước đổi kết quả.

Phân tích nội dung loại một bước mà cả hai lượt đều trả về câu rỗng, nên còn 4.462 bước. Trong số này, hai lượt tạo cùng một câu ở 2.810 bước và cho cùng kết quả đánh giá ở tất cả các bước đó. Khi tính executability trên toàn bộ 4.463 bước, mức đồng thuận giữa hai lượt là 93,6% (κ = 0,867, hệ số đồng thuận đã trừ phần trùng do ngẫu nhiên). Trên 1.652 bước có câu hướng dẫn khác nhau, mức đồng thuận còn 82,6% (κ = 0,650).

Với seed thứ hai, chênh lệch ở cả sáu cách chia nhóm trong Mục 6.9 vẫn cùng dấu với seed thứ nhất, và độ lệch giữa hai seed không vượt quá 0,9 điểm. Trong 1.091 cụm (Mục 5.13), số cụm mà S1 hơn, bằng và kém mô hình gốc là 395/565/131 ở seed 101 và 406/572/113 ở seed 202.

6.7.2 Hai lượt huấn luyện thành phần thứ nhất

Lượt thứ hai của thành phần thứ nhất dùng seed 202 cho thứ tự câu nhắc và quá trình lấy mẫu, còn điểm xuất phát vẫn là S1 seed 101 và mọi tham số khác giữ nguyên (500 bước, tám câu cho mỗi câu nhắc, phần thưởng SPICE). Lượt này được huấn luyện trên GPU L4, bị gián đoạn hai lần và được tiếp tục từ checkpoint gần nhất. Checkpoint 500 được đánh giá một lần trên tập kiểm tra bằng cùng quy trình với lượt thứ nhất.

Bảng 6.10 so sánh hai lượt với hai seed của S1 theo ba tiêu chí.

Bảng 6.10: Hai lượt huấn luyện thành phần thứ nhất so với hai seed của S1 trên 4.463 bước. Phần trên là điểm theo ba tiêu chí; phần dưới là chênh lệch ghép cặp, khoảng tin cậy 95% từ bootstrap theo cách gom cụm ở Mục 5.13. Lượt 1 là mô hình được dùng trong phương pháp đề xuất.

Mô hình	**Executability**	**Hộp phần tử**	**Euclid**
S1 seed 101	59,11	65,49	74,37
S1 seed 202	59,62	66,10	75,31
Thành phần thứ nhất, lượt 1	60,65	67,02	76,25
Thành phần thứ nhất, lượt 2	59,94	66,55	76,23
Lượt 2 − S1/101	+0,83 [0,00; +1,67]	+1,05 [+0,22; +1,90]	+1,86 [+1,06; +2,67]
Lượt 2 − S1/202	+0,31 [−0,53; +1,17]	+0,45 [−0,44; +1,34]	+0,92 [+0,02; +1,82]
Lượt 2 − lượt 1	−0,72 [−1,27; −0,16]	−0,47 [−1,04; +0,09]	−0,02 [−0,57; +0,54]
Lượt 1 − S1/202	+1,03 [+0,25; +1,83]	+0,92 [+0,11; +1,75]	+0,94 [+0,07; +1,81]

So với S1 seed 101, điểm xuất phát của cả hai lượt, lượt thứ hai vẫn cao hơn theo cả ba tiêu chí, nhưng mức tăng executability chỉ còn 0,83 điểm và cận dưới của khoảng tin cậy chạm 0. So với S1 seed 202, lượt thứ hai không khác biệt có ý nghĩa theo executability và tiêu chí hộp phần tử, chỉ cao hơn sát ngưỡng theo tiêu chí khoảng cách Euclid. Hai lượt của thành phần thứ nhất chênh nhau 0,72 điểm executability, có ý nghĩa thống kê, nhưng gần như bằng nhau theo tiêu chí khoảng cách Euclid.

Kết quả này cho thấy hướng của mức cải thiện so với S1 được giữ ở cả hai lượt và cả ba tiêu chí, còn độ lớn dao động trong khoảng từ +0,3 đến +1,9 điểm tuỳ lượt huấn luyện, seed của S1 dùng để so sánh và tiêu chí đánh giá. Ở một số phép so, mức này không lớn hơn chênh lệch 0,52 điểm giữa hai seed của S1 (Mục 6.7.1), và hai lượt của chính thành phần thứ nhất cũng chênh nhau 0,72 điểm. Vì vậy, luận văn báo cáo mức cải thiện +1,55 điểm của lượt thứ nhất như kết quả của một lượt huấn luyện, chưa phải mức cải thiện ổn định của phương pháp. ACE được xây dựng trên lượt thứ nhất, nên chênh lệch giữa ACE và lượt thứ hai phản ánh chủ yếu chênh lệch giữa hai lượt huấn luyện, không phải tác dụng của ACE.

6.8 Phân tích các giả thuyết thay thế

Mức chênh 11,5 điểm giữa S1 và mô hình gốc chưa thể quy hoàn toàn cho bước tinh chỉnh, vì kết quả có thể chịu ảnh hưởng của những yếu tố khác. Bảng 6.11 xem xét bảy cách giải thích thay thế dựa trên bản ghi ở mức từng bước. Dữ liệu hiện tại không ủng hộ sáu cách giải thích liên quan đến điều kiện khớp thao tác, vị trí trong chuỗi, độ phức tạp của màn hình, phân bố theo ứng dụng, công cụ đo và việc lặp lại nội dung câu tham chiếu; riêng ảnh hưởng của việc mô hình học theo văn phong của câu chú thích vẫn chưa được tách hoàn toàn.

Bảng 6.11: Phân tích các giả thuyết thay thế cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra.

Giả thuyết thay thế	**Kết quả kiểm**
Do điều kiện khớp thao tác chi phối	khi bỏ điều kiện này và chỉ đánh giá phần định vị, chênh lệch vẫn còn +11,3 điểm (b=272, c=777). Hơn nữa Base gọi đúng loại thao tác nhiều hơn (96,5% so với 94,4%)
Chỉ cải thiện ở một vị trí trong chuỗi	bước mở đầu tác vụ +15,0 (n=593, [+11,0; +19,1]), các bước sau +11,0 ([+9,4; +12,6]). Hai khoảng tin cậy chồng lấp và đều nằm trên 0
Chỉ cải thiện trên màn hình ít phần tử	chia ba theo số phần tử trên màn cho +12,6, +9,5 và +12,4. Các khoảng giao nhau, không tầng nào đảo chiều
Kết quả bị chi phối bởi một số ít ứng dụng	trên 1.091 cụm, S1 cao hơn ở 395, bằng ở 565 và thấp hơn ở 131
Cải thiện chủ yếu do bắt chước văn phong chú thích	chưa thể loại trừ, vì S1 mở đầu bằng động từ chạm nhiều hơn Base (91,0% so với 86,1%, câu tham chiếu 95,1%), cho thấy văn phong của S1 gần với văn phong người chú thích hơn
Do công cụ đo phù hợp với văn phong chú thích	khi đánh giá lại bằng UI-Venus-Ground-7B, một công cụ định vị thứ hai, chênh lệch vẫn giữ 94% (Mục 5.9)
Do lặp lại nội dung câu tham chiếu	1.095 trong 4.462 câu không rỗng của S1 lặp đúng các từ nội dung của câu tham chiếu. Khi chỉ đánh giá 3.367 bước còn lại, S1 vẫn cao hơn +8,4 điểm (b=264, c=547, p<0,001)

Dòng cuối của bảng tách riêng nhóm bước mà S1 lặp lại các từ nội dung của câu

tham chiếu. Trên nhóm này, chênh lệch giữa S1 và mô hình gốc là 21,1 điểm, lớn hơn chênh lệch trên các bước còn lại. Vì vậy, việc lặp lại nội dung của câu tham chiếu có thể góp phần làm tăng chênh lệch tổng thể. Tuy nhiên, S1 vẫn cao hơn 8,4 điểm trên 3.367 bước còn lại, nên thứ tự giữa hai mô hình không phụ thuộc riêng vào nhóm có nội dung giống câu tham chiếu.

Điểm executability thay đổi theo độ dài câu: chia đôi câu của S1 ở độ dài trung vị 33 ký tự thì nhóm câu dài đạt 61,9%, nhóm câu ngắn đạt 56,5%. Nếu câu dài thực sự có lợi cho điểm số, xu hướng này còn nghiêng về phía mô hình gốc, vốn có độ dài trung vị khoảng 70 ký tự; vì vậy nó không giải thích được việc S1 đạt điểm cao hơn. Mối liên hệ giữa độ dài và điểm số cũng khác nhau giữa các mô hình (ở mô hình gốc, câu dài lại kém câu ngắn 1,4 điểm), nên cần được phân tích riêng cho từng mô hình.

6.9 Phân bố lỗi của mô hình tinh chỉnh có giám sát

Mục này xem xét các bước mà S1 chưa đạt executability, nhằm xác định những dạng lỗi còn lại sau tinh chỉnh có giám sát.

6.9.1 Ảnh hưởng của việc trùng ứng dụng giữa tập huấn luyện và tập kiểm tra

Trong các bước của tập kiểm tra xác định được ứng dụng, 95,6% thuộc về ứng dụng cũng có trong tập huấn luyện (Mục 3.6). Bảng 6.12 so sánh S1 giữa các nhóm ứng dụng đã thấy, chưa thấy và không xác định; so sánh giữa hai nhóm đầu chỉ áp dụng trên phần dữ liệu xác định được ứng dụng.

Bảng 6.12: Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa.

Nhóm	S1	n
Ứng dụng đã thấy lúc huấn luyện	59,1%	1.737
Ứng dụng chưa thấy	59,0%	78
Không quy được về ứng dụng	59,1%	2.648

Ba ước lượng gần nhau, nhưng nhóm ứng dụng chưa xuất hiện trong huấn luyện chỉ có 78 bước và khoảng tin cậy rộng. Kết quả hiện tại chưa cho thấy ảnh hưởng rõ của mức trùng ứng dụng, nhưng cũng chưa đủ để loại trừ một ảnh hưởng nhỏ.

6.9.2 Phân loại lỗi còn lại

Trong 1.825 bước mà S1 không đạt executability, một bước là câu rỗng. Trong 1.824 bước còn lại, 251 bước có loại thao tác bị dự đoán sai. Ở 1.573 bước còn lại, chiếm 86%, loại thao tác đã đúng nhưng quy trình đánh giá vẫn không xác định được phần tử cần chạm từ câu hướng dẫn của S1. Một số trường hợp cho thấy câu hướng dẫn gọi sai hoặc mô tả chưa đủ rõ phần tử mục tiêu.

Câu tham chiếu	**Hướng dẫn của S1**
click on the OK option	select minutes 00
Click on the Sort filter	Click on the Air India flight option
Click on the share icon	Open Recorder app

Các ví dụ này cho thấy lỗi gọi tên hoặc mô tả sai phần tử là một dạng lỗi đáng chú ý sau khi loại thao tác đã đúng. Tuy nhiên, không thể quy toàn bộ 1.573 bước cho riêng dạng lỗi này vì kết quả còn phụ thuộc vào mô hình định vị và tiêu chí đánh giá.

6.9.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh

Ở 798 bước mà S1 đúng còn mô hình gốc sai, hai dạng lỗi nổi bật trong các trường hợp được xem xét là viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại, hoặc mô tả một bước khác với bước cần làm.

	Câu
Câu tham chiếu	Click on the profile icon at the top right of the screen
S1	Click on the profile icon at the top right corner of the screen
Base	To set YouTube video downloads over Wi-Fi only, tap on your profile icon at the top right corner of the screen and select “Settings.” Then navigate to the “Downloads” section and choose “Wi-Fi Only.”
Câu tham chiếu	Click on Knoxville
S1	Click on Knoxville
Base	Click on the three dots next to Knoxville to access more options and proceed with reading the local news.

Ở dạng thứ nhất, mô hình gốc viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại. Ở dạng thứ hai, mô hình gốc mô tả một bước khác với bước cần làm. Câu của mô hình gốc vẫn trôi chảy, đúng khuôn và gọi tên nút cụ thể; điểm thấp xuất hiện vì nội dung không bám sát bước đang xét chứ không phải do sai định dạng. Các ví dụ này cho thấy khả năng bám sát bước hiện tại là một khác biệt đáng chú ý giữa hai mô hình trong nhóm S1 đúng còn mô hình gốc sai.

6.9.4 Khoảng cách còn lại so với câu tham chiếu

Câu tham chiếu cũng không đạt executability ở khoảng một phần tư số bước. Phân tích ở Mục 6.11 cho thấy kết quả này chịu ảnh hưởng của cả mô hình định vị và cách tính điểm, nên 75,7% không phải là trần chất lượng của câu hướng dẫn. S1 thấp hơn câu tham chiếu 16,6 điểm, tương ứng 742 bước (Mục 5.5). Khoảng cách này chỉ được dùng như một mốc tham chiếu thực nghiệm; không thể xem toàn bộ 16,6 điểm là phần có thể thu hẹp bằng cách cải thiện mô hình sinh câu. Nếu lấy khoảng cách này làm mẫu số, mức tăng hai điểm tương ứng khoảng 12% chênh lệch. Theo executability, chưa phương án nào trong luận văn đạt mức tăng hai điểm so với S1; phương pháp đề xuất là cấu hình tiến gần nhất (Bảng 6.1).

6.10 Các phương án thiết kế đã khảo sát

Bảng 6.13 tóm tắt các phương án thiết kế đã khảo sát trước khi hình thành phương pháp đề xuất; thiết kế và kết quả chi tiết được trình bày trong Phụ lục A.

Bảng 6.13: Các phương án thiết kế đã khảo sát. Điểm là executability trên 4.463 bước có thao tác chạm của tập kiểm tra, trừ khi ghi khác.

Hướng	Ý tưởng	Kết quả	Điều rút ra
Mô tả phần tử (S2), Mục A.1.3	viết một dòng mô tả phần tử cần chạm trước câu hướng dẫn	57,2%, thấp hơn S1/101 1,93 điểm	câu đầu ra đạt kết quả cao hơn ở nhóm mô tả đúng phần tử và giảm mạnh ở nhóm mô tả sai
Học theo cặp ưu tiên (MIN-DESC), Mục A.2.2	học theo cặp ưu tiên trên các đầu ra chỉ khác ở dòng mô tả	60,0%; 78% mức tăng so với S2 cũng có ở mô hình chỉ học thêm có giám sát	phần lớn cải thiện xuất hiện ở cấu hình chỉ học thêm
Chọn ứng viên, Mục A.3.2	chọn phần tử cần chạm trong danh sách được xây dựng sẵn	56,1%, chỉ có thể so sánh trực tiếp với mô hình gốc	khi đưa ra lựa chọn, độ chính xác cao, nhưng tần suất từ chối chọn lớn
Giai đoạn thưởng tọa độ, Mục A.4.2	học tăng cường với phần thưởng dựa trên độ chính xác của tọa độ trong dòng mô tả	60,1% (77,3% theo tiêu chí khoảng cách Euclid)	độ chính xác tọa độ tăng nhưng thay đổi ở câu đầu ra còn hạn chế
Đưa thêm thông tin vị trí, Mục A.6	bổ sung thông tin vị trí cho mô hình sinh câu (bốn cách)	dừng ở tập kiểm định nội bộ	thông tin này chưa được phản ánh rõ trong đầu ra của mô hình sinh câu
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE), Mục A.7.2	viết lại câu hướng dẫn ban đầu sau khi xem ảnh phóng to quanh phần tử	60,2%, thấp hơn câu hướng dẫn ban đầu 0,43 điểm	bộ chọn có xu hướng chấp nhận câu hiệu chỉnh ngay cả khi vùng ảnh cục bộ chưa đúng

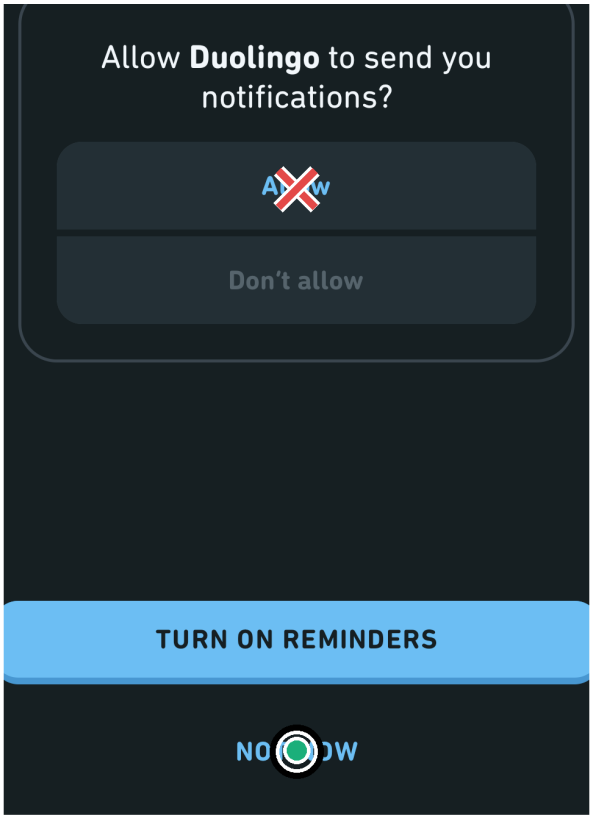
Nhìn chung, các phương án dựa trên biểu diễn trung gian, như dòng mô tả phần tử hoặc tọa độ, chỉ tạo ra thay đổi hạn chế ở câu hướng dẫn cuối (Mục A.5). Nhiều lỗi còn lại xuất hiện khi mô hình hướng tới sai phần tử mục tiêu, nhưng việc đưa thêm

thông tin vị trí trực tiếp vào mô hình sinh cũng chưa làm đầu ra thay đổi tương ứng. Việc tiếp tục huấn luyện trên câu tham chiếu hoặc câu viết lại, khi được thử trong các cấu hình ở Phụ lục A, cũng không bảo đảm cải thiện. Các kết quả này dẫn tới thiết kế cuối cùng: tối ưu trực tiếp câu hướng dẫn và chỉ sử dụng câu ví dụ khi đáp ứng ràng buộc nhất quán về loại thao tác.

6.11 Giới hạn của quy trình đánh giá trên tập kiểm tra

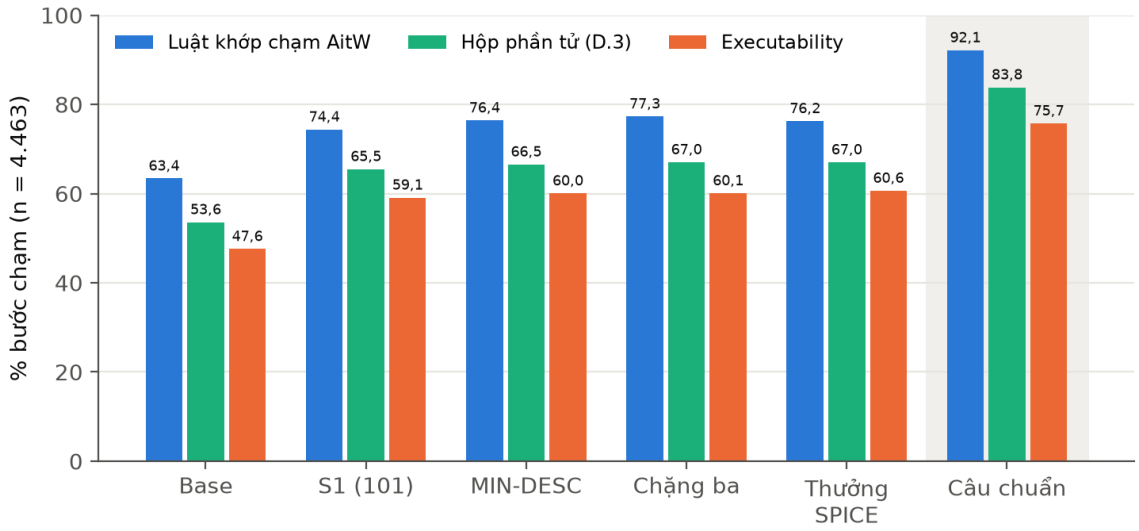
Câu tham chiếu không đạt executability ở 1.083 bước. Trong 64,8% số bước này, điểm do mô hình định vị trả về nằm xa ngoài vùng dung sai; sai số trung vị là 26,2% bề ngang màn hình, so với 0,4% ở các bước đạt. 381 bước còn lại đã nằm trong vùng dung sai nhưng vẫn bị tiêu chí ô Voronoi loại. Đáng chú ý, ở 208 bước trong số đó, điểm dự đoán nằm ngay trong hộp nhỏ nhất chứa điểm chạm; trên các phần tử lớn, một phần tử con có thể bị xem là đối thủ cạnh tranh với chính phần tử cha. Tính trên các bước đã nằm trong vùng dung sai, tiêu chí ô Voronoi loại 10,1% với câu tham chiếu, 13,0% với S1 và 15,2% với mô hình gốc. Ngoài ra, có 935 bước, tương ứng 21% toàn bộ 4.463 bước có thao tác chạm, mà cả ba loại câu đều không đạt. Những con số này cho thấy điểm 75,7% của câu tham chiếu chịu ảnh hưởng của cả mô hình định vị lẫn cách tính điểm trong quy trình đánh giá, nên không thể diễn giải trực tiếp như giới hạn của chất lượng diễn đạt.

Luận văn cũng kiểm tra khả năng mô hình tối ưu cách diễn đạt theo đặc điểm của công cụ đo thay vì theo nhu cầu của người đọc (Mục 5.5). Câu nêu tên một vùng trên màn đạt 89,5% khi vùng đó đúng, 3,3% khi vùng đó sai và 54,8% khi không nêu vùng nào. Kết quả này cho thấy độ đo phản hồi tích cực khi thông tin vị trí phù hợp nhưng không tạo lợi thế tương tự khi thông tin vị trí sai. S1 sử dụng từ chỉ vị trí trong 26,8% số câu, gần bằng 26,4% của câu tham chiếu, và chỉ để lại chuỗi tọa độ trong 3 trên 6.958 câu. Khác biệt rõ hơn nằm ở mức độ lặp khuôn câu: hai mẫu câu phổ biến nhất của S1 chiếm 10,4% số bước, so với 6,5% ở câu tham chiếu.



○ **Câu chuẩn:** "Click on the Not now button to remove this pop up notification"
✕ **S1 (101):** "Click on the Allow button" → trượt
● **Thưởng SPICE:** "Click on the Not Now button at the bottom of the screen" → trúng

Hình 6.1: Một bước được mô hình học tăng cường với phần thưởng SPICE sửa đúng (ảnh chỉ giữ phần dưới màn hình). Cần chạm nút *Not now* ở cuối màn, trong khi một hộp thoại hỏi quyền gửi thông báo đang che màn hình. S1 gọi nút *Allow* trong hộp thoại nên mô hình định vị xác định sai phần tử; mô hình học tăng cường với phần thưởng SPICE gọi đúng nút *Not now* kèm vị trí, và mô hình định vị xác định đúng phần tử.



Hình 6.2: Các mô hình chính theo ba tiêu chí đánh giá trên 4.463 bước có thao tác chạm. Cột nền xám là mốc câu tham chiếu. Thứ hạng nhìn chung được duy trì giữa ba tiêu chí; riêng giai đoạn thưởng tọa độ (giai đoạn ba) đạt điểm cao hơn theo tiêu chí khoảng cách Euclid, còn mô hình học tăng cường với phần thưởng SPICE đạt điểm cao hơn theo executability.