Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả chính của phương pháp đề xuất, sau đó lần lượt xét vai trò của phần thưởng SPICE, so sánh với một mô hình lớn hơn chỉ dùng prompting, độ vững khi thay mô hình đánh giá, khả năng khái quát sang tác vụ mới và sang bộ dữ liệu khác, độ đo văn bản, và thiết lập lịch sử do mô hình tự sinh. Các mục cuối trình bày thành phần ACE, các hướng đã thử và các hạn chế của kết quả.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên 4.463 bước có thao tác chạm của tập kiểm tra (Mục 3.2) bằng quy trình ở Chương 5, với UGround làm mô hình định vị; câu không có nội dung vẫn nằm trong mẫu số và tính là không đạt. Các mốc so sánh gồm Base, Qwen2.5-VL-7B chỉ dùng prompting, S1 với hai seed 101 và 202, và câu chuẩn (Mục 4.5). Các nhánh dùng để xét vai trò của phần thưởng được mô tả ở Mục 6.3.

Mọi phép so được tính theo cặp trên cùng tập bước: chênh lệch Δ, KTC 95% bằng bootstrap theo cụm ứng dụng, và giá trị p của kiểm định McNemar dạng chính xác (Mục 5.6). Mức chênh lệch nhỏ nhất phát hiện được khi tính cả dao động do huấn luyện lại là MDE $\approx$ 2,11 điểm (công thức (5.3)).

6.2 Kết quả chính

Phương pháp đề xuất đạt executability cao nhất trong các cấu hình được so sánh. GRPO-SPICE đạt **60,65%**, cao hơn mô hình xuất phát S1/101 **1,55 điểm** [+0,80;

+2,33] ($p = 1{,}5 \times 10^{-5}$); khi thêm ACE, phương pháp đạt **60,68‰** (Bảng 6.1).

Bảng 6.1: Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra.

Mô hình	Exec.	Hộp	Hộp ∧ 14%	AitW	Δ Exec. so với S1/101
Base	47,59	53,60	49,76	63,39	−11,52 [−13,07; −10,02]
Qwen2.5-VL-7B (prompting)	51,51	57,67	53,71	66,79	−7,60 [−9,28; −5,95]
S1/101	59,11	65,49	61,73	74,37	-
S1/202	59,62	66,10	62,36	75,31	+0,52 [−0,22; +1,26]
GRPO-SPICE	60,65	67,02	63,25	76,25	+1,55 [+0,80; +2,33]
GRPO-SPICE + ACE	**60,68**	**67,11**	**63,28**	**76,32**	**+1,57** [+0,86; +2,31]
Câu chuẩn	75,73	83,82	79,23	92,14	+16,62

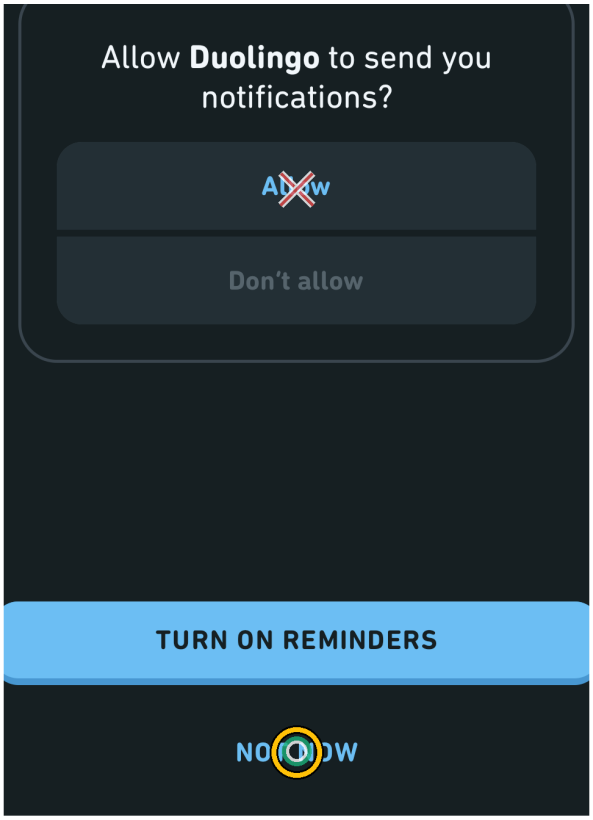
Hộp: tiêu chí hộp phần tử; Hộp ∧ 14%: hộp phần tử kết hợp cửa sổ 14%; AitW: AitW đầy đủ (Mục 5.2.1). Từ đây, GRPO-SPICE + ACE được gọi tắt là ACE.

GRPO-SPICE cũng cao hơn S1/202 1,03 điểm [+0,25; +1,83] ($p = 0{,}014$), và mức tăng so với S1/101 giữ cùng chiều dưới cả ba tiêu chí báo kèm: +1,52 điểm theo tiêu chí hộp phần tử, +1,52 theo hộp kết hợp cửa sổ 14% và +1,88 theo AitW đầy đủ, với KTC đều nằm trên 0. Bước tinh chỉnh có giám sát đưa executability từ 47,59% của Base lên 59,11%; GRPO-SPICE thu hẹp thêm khoảng cách tới câu chuẩn (75,73%) từ 16,62 xuống 15,08 điểm.

Nguồn của mức tăng. GRPO-SPICE đổi câu ở 1.668 bước (37,4%). Trong mức tăng ròng 69 bước (159 bước chỉ GRPO-SPICE đạt so với 90 bước chỉ S1/101 đạt), khoảng 41 bước đến từ câu dẫn tới đúng phần tử, như ở bước trong Hình 6.1: S1/101 gọi nút *Allow* còn GRPO-SPICE gọi đúng nút *Not Now*; khoảng 28 bước còn lại đến từ câu nêu đúng loại thao tác mà S1/101 nêu sai. Số bước không đạt vì sai loại thao tác giảm từ 251 xuống 179.

6.3 Vai trò của phần thưởng SPICE

Mức tăng gắn với tín hiệu SPICE: khi điểm SPICE được ghép ngẫu nhiên giữa các mẫu, executability trở về đúng mức S1/101, và khi thay SPICE bằng CIDEr-D, executability thấp hơn GRPO-SPICE. Bảng 6.2 so bốn cấu hình cùng xuất phát từ S1/101 và chỉ



Vòng vàng: điểm người dùng đã chạm
Câu tham chiếu: "Click on the Not now button to remove this pop up notification"
S1/101: "Click on the Allow button" → không đạt
GRPO-SPICE: "Click on the Not Now button at the bottom of the screen" → đạt

Hình 6.1: Một bước được GRPO-SPICE sửa đúng.

khác nhau ở phần thưởng hoặc số bước GRPO.

Tín hiệu SPICE. Nhánh kiểm soát chạy cùng 500 bước GRPO với GRPO-SPICE nhưng điểm SPICE được ghép ngẫu nhiên giữa các mẫu trong cùng nhóm (Mục 4.3). Nhánh này đạt đúng 59,11%, bằng S1/101, và không khác S1/101 ở độ đo văn bản nào (mọi KTC chứa 0). GRPO-SPICE cao hơn nhánh kiểm soát **1,55 điểm** [+0,81; +2,30] ($p = 2{,}0 \times 10^{-5}$), và cao hơn có ý nghĩa ở cả sáu độ đo văn bản có KTC, chẳng hạn CIDEr-D +11,92 [+5,76; +17,89]. Với cùng quá trình cập nhật, mức tăng chỉ xuất hiện khi phần thưởng giữ đúng quan hệ với câu.

So với phần thưởng CIDEr-D. Thay SPICE bằng CIDEr-D, giữ điểm xuất phát

Bảng 6.2: Executability và độ đo văn bản theo phần thưởng GRPO.

Phần thưởng GRPO	Exec.	Δ so với GRPO-SPICE	CIDEr-D	SPICE	chrF
Không GRPO (S1/101)	59,11	−1,55 [−2,33; −0,80]	416,12	44,37	61,26
SPICE ghép ngẫu nhiên	59,11	−1,55 [−2,30; −0,81]	418,13	44,40	61,52
CIDEr-D, 500 bước	59,96	−0,69 [−1,34; −0,02]	428,27	45,27	61,76
CIDEr-D, 1.000 bước	59,98	−0,67 [−1,33; +0,00]	427,98	44,45	61,92
SPICE (GRPO-SPICE)	**60,65**	-	**430,05**	**45,79**	**62,87**

Mọi nhánh GRPO xuất phát từ S1/101 và chạy 500 bước, trừ hàng ghi 1.000 bước. Nhánh thưởng CIDEr-D dùng 2.000 prompt huấn luyện, gồm cả 1.000 prompt của GRPO-SPICE.

và số bước, cho executability thấp hơn GRPO-SPICE 0,69 điểm [−1,34; −0,02] (p = 0,040). Nhánh này nêu đúng loại thao tác nhiều hơn nhưng dẫn tới sai phần tử nhiều hơn, và tăng lên 1.000 bước không cải thiện thêm. Điểm CIDEr-D của nhánh thưởng CIDEr-D trên tập kiểm tra cũng thấp hơn của GRPO-SPICE (428,27 so với 430,05). Trong các phần thưởng đã thử, SPICE cho executability cao nhất, đồng thời cao nhất ở CIDEr-D, SPICE và chrF.

6.4 So với mô hình lớn hơn chỉ dùng prompting

Mô hình 3B sau GRPO-SPICE cao hơn Qwen2.5-VL-7B chỉ dùng prompting **9,14 điểm** executability [+7,55; +10,75] ($p = 1{,}9 \times 10^{-37}$); ACE cao hơn 9,16 điểm (Bảng 6.1). Khoảng cách ở độ đo văn bản còn lớn hơn: 7B chỉ đạt CIDEr-D 100,71 và SPICE 18,74, gần mức của Base, so với 430,05 và 45,79 của GRPO-SPICE (Bảng 6.6). Mô hình 7B vẫn cao hơn Base 3,92 điểm executability, nên tăng kích thước mô hình nền có giúp, nhưng ít hơn nhiều so với tinh chỉnh trên dữ liệu của bài toán. Phép so chỉ phản ánh cấu hình prompting đã thử, dùng cùng prompt với Base.

6.5 Độ vững khi thay mô hình đánh giá

GRPO-SPICE cao hơn S1/101 dưới cả bốn mô hình đánh giá, trong đó có hai mô hình ngoài họ Qwen (Bảng 6.3). Ngoài UGround, các nhánh chính được đánh giá

bằng UI-Venus-Ground-7B (không học AndroidControl, cùng họ Qwen), Phi-Ground-4B (ngoài họ Qwen) và Phi-4 dạng chọn ô đánh số (ngoài họ Qwen), như mô tả ở Mục 5.5.4.

Bảng 6.3: Kết quả của các nhánh chính dưới bốn mô hình đánh giá.

	UGround	**UI-Venus**	**Phi-Ground**	**Phi-4**
Họ mô hình nền	Qwen2-VL	Qwen2.5-VL	Phi-3.5-Vision	Phi-4
Base	47,59	-	40,80	38,23
S1/101	59,11	54,51	46,96	44,63
S1/202	59,62	55,12	-	**45,53**
GRPO-SPICE	60,65	56,06	**47,75**	45,33
ACE	**60,68**	**56,20**	47,73	45,33
GRPO-SPICE − S1/101	+1,55	+1,55	+0,78	+0,69
	[+0,80; +2,33]	[+0,82; +2,30]	[+0,05; +1,51]	[+0,02; +1,40]
Câu chuẩn	75,73	-	-	54,94

Ô "-" là chưa đánh giá trên đủ 4.463 bước. Với Phi-4, điểm là tỉ lệ chọn đúng phần tử. Với Phi-Ground, Base thiếu dự đoán ở 7 bước, các bước này tính là không đạt; với Phi-4, S1/202 chỉ được đánh giá lại ở 1.652 bước có câu khác S1/101.

Dưới UI-Venus, mức tăng bằng đúng mức dưới UGround (+1,55 điểm, $p = 8{,}7 \times 10^{-6}$). Dưới hai mô hình ngoài họ Qwen, mức tăng tuyệt đối nhỏ hơn (+0,78 và +0,69 điểm), nhưng thang điểm của hai mô hình này cũng hẹp hơn: khoảng cách S1/101 − Base chỉ 6,16 và 6,41 điểm, so với 11,52 điểm dưới UGround. Tính theo khoảng cách đó, mức tăng của GRPO-SPICE bằng khoảng 13% dưới UGround, 13% dưới Phi-Ground và 11% dưới Phi-4. ACE ngang GRPO-SPICE dưới cả bốn mô hình. Riêng dưới Phi-4, S1/202 nhỉnh hơn GRPO-SPICE 0,20 điểm, với KTC chứa 0.

6.6 Khả năng khái quát

6.6.1 Tác vụ chưa xuất hiện trong huấn luyện S1

Trên các tác vụ mà S1 chưa thấy khi huấn luyện, mức tăng của GRPO-SPICE gần gấp ba so với tập kiểm tra chính và vượt MDE. ACU gồm 1.484 bước có thao tác chạm

thuộc các tác vụ không có trong tập huấn luyện S1 (Mục 3.2); Bảng 6.4 báo kết quả trên ACU và trên tập gộp ACU với tập kiểm tra chính.

Bảng 6.4: Executability trên ACU và trên tập gộp với tập kiểm tra chính.

	ACU, 1.484 bước		**Gộp, 5.947 bước**	
Mô hình	**Exec.**	**Δ so với S1/101**	**Exec.**	**Δ so với S1/101**
Base	49,80	-	48,14	-
S1/101	52,16	-	57,37	-
GRPO-SPICE, lượt 2	56,20	+4,04 [+2,66; +5,48]	59,00	+1,63 [+0,93; +2,37]
GRPO-SPICE	56,74	+4,58 [+3,17; +6,05]	59,68	+2,30 [+1,62; +2,99]
ACE	**57,01**	**+4,85** [+3,43; +6,32]	**59,76**	**+2,39** [+1,73; +3,05]
Câu chuẩn	71,70	+19,54	74,73	-

Trên ACU, GRPO-SPICE cao hơn S1/101 **4,58 điểm** [+3,17; +6,05] ($p = 2{,}1 \times 10^{-10}$). Cận dưới KTC của GRPO-SPICE, lượt GRPO thứ hai và ACE đều cao hơn MDE 2,11 điểm. Ở các tác vụ này, S1/101 chỉ cao hơn Base 2,36 điểm (KTC chạm 0), còn GRPO-SPICE cao hơn Base 6,94 điểm [+4,49; +9,34]. Từ tập kiểm tra chính sang ACU, S1/101 giảm 6,95 điểm còn GRPO-SPICE chỉ giảm 3,91 điểm. Gộp hai tập thành 5.947 bước, GRPO-SPICE cao hơn S1/101 **2,30 điểm** [+1,62; +2,99] ($p = 6{,}8 \times 10^{-13}$), cũng vượt MDE.

6.6.2 Chuyển sang bộ dữ liệu AitZ

Trên AitZ, phương pháp đề xuất cạnh tranh với S1: GRPO-SPICE ngang S1/101 về executability và cao hơn ở BLEU-4, SPICE và chrF. AitZ có phân phối câu chuẩn khác AndroidControl, và các mô hình được dùng nguyên, không huấn luyện thêm (Bảng 6.5).

S1/101 cao hơn Base 3,29 điểm ($p = 4{,}5 \times 10^{-4}$) và GRPO-SPICE cao hơn Base 2,78 điểm ($p = 0{,}0028$), nên tinh chỉnh vẫn chuyển được sang miền này. Chênh lệch giữa GRPO-SPICE và S1/101 có KTC chứa 0 ($p = 0{,}33$). Ở độ đo văn bản (Bảng 6.7), GRPO-SPICE cao hơn S1/101 với KTC nằm trên 0 ở SPICE (+1,10 [+0,53; +1,66]), chrF (+0,62 [+0,22; +1,03]) và BLEU-4 (+0,47 [+0,01; +0,95]). ACE chỉ đổi 52 câu

Bảng 6.5: Executability trên 2.736 bước có thao tác chạm của AitZ.

Mô hình	Exec.	Δ so với S1/101
Base	34,50	−3,29 [−5,03; −1,51]
S1/101	**37,79**	-
GRPO-SPICE	37,28	−0,51 [−1,39; +0,36]
ACE	37,28	−0,51 [−1,39; +0,36]
Câu chuẩn	66,26	+28,47

so với GRPO-SPICE, vì kho câu ví dụ lấy từ AndroidControl ít khi có câu phù hợp với AitZ.

6.7 Độ đo văn bản

ACE đạt điểm cao nhất ở cả bảy độ đo văn bản trên tập kiểm tra chính và trên ACU, và GRPO-SPICE cao hơn S1/101 ở cả bảy độ đo (Bảng 6.6 và Bảng 6.7).

Bảng 6.6: Độ đo văn bản trên 4.463 bước có thao tác chạm của tập kiểm tra.

Mô hình	BLEU-4	METEOR	ROUGE-L	CIDEr-D	SPICE	chrF	BERTScore
Base	15,34	24,58	42,31	88,01	18,48	40,18	40,10
7B, chỉ prompting	14,48	21,90	39,79	100,71	18,74	36,22	39,70
S1/101	51,56	36,79	67,35	416,12	44,37	61,26	66,33
S1/202	51,66	37,17	67,71	419,19	44,23	61,92	66,75
GRPO-SPICE	52,36	37,92	68,36	430,05	45,79	62,87	67,07
ACE	**53,47**	**38,37**	**69,11**	**442,02**	**47,13**	**63,45**	**67,73**
GRPO-SPICE − S1/101	+0,80	+1,13	+1,01	+13,93	+1,42	+1,61	+0,74
GRPO-SPICE − S1/202	+0,70[0]	+0,75	+0,66	+10,86	+1,56	+0,96	+0,32[0]
ACE − GRPO-SPICE	+1,11	+0,45	+0,74	+11,97	+1,33	+0,58	+0,66

Câu chuẩn đạt 100 ở mọi độ đo trừ CIDEr-D (988,7) và SPICE (98,6). [0]: KTC 95% (bootstrap theo cụm ứng dụng, 2.000 lần lấy mẫu) chứa 0; METEOR chỉ có giá trị mức toàn tập nên không có KTC.

Trên tập kiểm tra chính, GRPO-SPICE cao hơn S1/101 với KTC nằm trên 0 ở cả sáu độ đo có KTC, rõ nhất ở CIDEr-D +13,93 [+8,05; +19,91] và SPICE +1,42 [+0,71;

+2,16]. So với S1/202, bốn trong sáu độ đo vẫn tăng có ý nghĩa (ROUGE-L, CIDEr-D, SPICE và chrF). ACE cao hơn GRPO-SPICE có ý nghĩa ở cả sáu độ đo có KTC. Trên ACU, GRPO-SPICE cao hơn S1/101 có ý nghĩa ở cả sáu độ đo có KTC, với CIDEr-D +26,73 [+15,84; +37,96] và SPICE +2,51 [+1,18; +3,87], và ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu. Trên AitZ, GRPO-SPICE cao nhất ở năm trong bảy độ đo, ACE cao nhất ở SPICE, còn BERTScore của S1/101 và GRPO-SPICE gần như bằng nhau.

Bảng 6.7: Độ đo văn bản trên ACU và AitZ.

Mô hình	BLEU-4	METEOR	ROUGE-L	CIDEr-D	SPICE	chrF	BERTScore
ACU, 1.484 bước							
Base	15,01	25,14	42,04	93,25	19,28	39,61	40,10
S1/101	47,53	34,47	63,45	385,99	39,74	57,20	62,76
GRPO-SPICE	49,85	36,64	66,38	412,72	42,25	60,06	64,64
ACE	**50,88**	**37,03**	**67,11**	**425,71**	**43,21**	**60,59**	**65,32**
AitZ, 2.736 bước							
Base	18,68	18,56	39,11	86,98	15,66	35,24	38,81
S1/101	21,01	20,83	46,84	120,24	15,27	35,66	**49,69**
GRPO-SPICE	**21,48**	**21,08**	**46,92**	**123,38**	16,37	**36,28**	49,68
ACE	21,45	21,05	46,91	123,29	**16,40**	36,24	49,63

6.8 Lịch sử thao tác do mô hình tự sinh

Khi lịch sử các bước trước do chính mô hình sinh, GRPO-SPICE vẫn cao hơn S1/101 **1,48 điểm** executability [+0,54; +2,43] ($p = 7{,}5 \times 10^{-4}$), gần bằng mức 1,55 điểm với lịch sử chuẩn. Trong thiết lập chính, lịch sử là câu chuẩn của các bước trước (Mục 4.2); ở thí nghiệm này, mỗi tác vụ được sinh lại từ bước đầu và câu mô hình sinh ở bước trước thay câu chuẩn trong lịch sử của bước sau (Bảng 6.8).

Cả hai mô hình giảm khoảng 4 điểm ($-4{,}15$ và $-4{,}21$), nên mức giảm là đặc điểm của thiết lập chứ không riêng mô hình nào. Trên 3.492 bước thuộc các tác vụ có đủ ảnh, trong đó lịch sử hoàn toàn do mô hình sinh, chênh lệch là 1,66 điểm [+0,60; +2,75]. Độ đo văn bản của cả hai mô hình cùng giảm rõ trong thiết lập này, và chênh

Bảng 6.8: Executability khi lịch sử các bước trước do chính mô hình sinh.

Mô hình	Lịch sử chuẩn	Lịch sử tự sinh
S1/101	59,11	54,96
GRPO-SPICE	**60,65**	**56,44**
GRPO-SPICE − S1/101	+1,55 [+0,80; +2,33]	+1,48 [+0,54; +2,43]

lệch giữa hai mô hình chỉ còn có ý nghĩa ở chrF.

6.9 Thành phần thứ hai: ACE

ACE nâng cả bảy độ đo văn bản của GRPO-SPICE mà không làm giảm executability. ACE thay 402 trong 4.463 câu ban đầu, ở những bước câu ứng viên thỏa điều kiện lựa chọn (Mục 4.4).

Bảng 6.9: ACE so với câu ban đầu và với mô hình sinh câu ứng viên dùng độc lập.

Độ đo	Câu ban đầu	Mô hình sinh độc lập	ACE	ACE − câu ban đầu
Executability	60,65	59,40	**60,68**	+0,02 [−0,21; +0,26]
Tiêu chí hộp phần tử	67,02	65,81	**67,11**	+0,09 [−0,15; +0,33]
AitW đầy đủ	76,25	75,02	**76,32**	+0,07 [−0,15; +0,29]
BLEU-4	52,36	**53,47**	**53,47**	+1,11 [+0,78; +1,42]
METEOR	37,92	37,79	**38,37**	+0,45
ROUGE-L	68,36	68,67	**69,11**	+0,74 [+0,54; +0,94]
CIDEr-D	430,05	437,54	**442,02**	+11,97 [+8,24; +15,34]
SPICE	45,79	46,79	**47,13**	+1,33 [+0,92; +1,75]
chrF	62,87	62,65	**63,45**	+0,58 [+0,37; +0,80]
BERTScore	67,07	67,52	**67,73**	+0,66 [+0,46; +0,86]

Độ đo văn bản của mô hình sinh độc lập lấy từ một lượt tính trước đó; ở lượt này, các giá trị của câu ban đầu lệch không quá 0,02 điểm so với cột thứ nhất.

ACE giữ executability của GRPO-SPICE ($p = 1$), và sáu độ đo văn bản có KTC đều tăng với KTC nằm trên 0 (Bảng 6.9). Dùng thẳng mô hình sinh câu ứng viên cho

mọi bước làm năm trong bảy độ đo văn bản tăng nhưng executability giảm 1,25 điểm [−2,06; −0,44] (p = 0,0016). Điều kiện lựa chọn giữ được phần lợi về văn bản mà không mất executability, vì chỉ nhận câu trùng một câu ví dụ và cùng loại thao tác với câu ban đầu; câu được nhận có thể dẫn tới phần tử khác hẳn câu ban đầu, như ở Hình 4.3(a). Trên ACU, ACE cũng ngang GRPO-SPICE về executability (+0,27 điểm, KTC chứa 0) và cao hơn ở cả bảy độ đo văn bản.

6.10 Các phương án thiết kế đã khảo sát

Trước phương pháp cuối cùng, chúng tôi khảo sát các hướng dựa trên mô tả phần tử, học theo cặp ưu tiên, phần thưởng tọa độ, chọn ứng viên và hiệu chỉnh theo vùng ảnh. Các hướng này thay đổi rõ biểu diễn trung gian nhưng mức cải thiện ít truyền sang câu hướng dẫn cuối cùng; chẳng hạn GRPO thưởng tọa độ, xuất phát từ một mô hình sinh mô tả phần tử trước câu, đạt 60,07% executability, thấp hơn GRPO-SPICE 0,58 điểm (KTC chứa 0). Phương pháp vì vậy chuyển sang tối ưu trực tiếp câu bằng GRPO-SPICE, rồi dùng ACE để hiệu chỉnh có chọn lọc. Thiết kế và số liệu của từng hướng được trình bày ở Phụ lục A.

6.11 Hạn chế của kết quả

Độ lớn mức tăng trên tập kiểm tra chính. Mức tăng 1,55 điểm của GRPO-SPICE so với S1/101 có ý nghĩa thống kê nhưng nhỏ hơn MDE 2,11 điểm, tức chưa đủ để loại trừ khả năng một chênh lệch cỡ đó xuất hiện chỉ do huấn luyện lại. Mức tăng vượt MDE trên ACU (cận dưới KTC 3,17 điểm) và trên tập gộp 5.947 bước (2,30 điểm).

Biến thiên giữa các lượt huấn luyện. Hai lượt S1 chênh nhau 0,52 điểm [−0,22; +1,26]. Lượt GRPO-SPICE thứ hai chỉ đổi seed (Mục 4.3) và đạt 59,94%, thấp hơn lượt thứ nhất 0,72 điểm [−1,27; −0,16] nhưng vẫn cao hơn S1/101 0,83 điểm [+0,00; +1,67] (p = 0,036); lượt này chỉ ngang S1/202 (+0,31 điểm [−0,53; +1,17]). Theo AitW đầy đủ, hai lượt GRPO gần như bằng nhau và lượt thứ hai cao hơn S1/101 1,86 điểm [+1,06; +2,67]; ở độ đo văn bản, lượt thứ hai cho mức tăng so với S1/101 tương tự lượt một, và trên ACU cao hơn S1/101 4,04 điểm. Trên AitZ, lượt thứ hai thấp hơn

S1/101 1,17 điểm [−2,12; −0,22].

Bước không chạm. GRPO-SPICE có xu hướng viết câu cho thao tác chạm thường xuyên hơn. Xu hướng này đóng góp một phần mức tăng ở bước chạm (Mục 6.2) nhưng làm giảm tỉ lệ nêu đúng loại thao tác trên 2.495 bước không chạm, rõ nhất ở bước cuộn và quay lại (Bảng 6.10): trong 51 bước cuộn S1/101 nêu đúng còn GRPO-SPICE nêu sai, 47 bước bị đổi thành câu chạm, chẳng hạn *Swipe up* thành *Click on technology*. Ở bước chờ, tỉ lệ đúng tăng 4,55 điểm.

Bảng 6.10: Tỉ lệ nêu đúng loại thao tác trên các bước không chạm.

Nhóm bước	Số bước	S1/101	GRPO-SPICE	Δ [KTC 95%]
Toàn bộ	2.495	85,97	84,29	−1,68 [−2,76; −0,62]
Cuộn	755	83,97	77,75	−6,23 [−8,30; −4,31]
Quay lại	270	72,96	67,04	−5,93 [−9,42; −2,58]
Toàn bộ, lịch sử tự sinh	2.495	81,32	76,83	−4,49 [−6,48; −2,61]

Tiêu chí lỏng hơn. Dưới AitW đầy đủ, GRPO thưởng tọa độ (Mục 6.10) đạt 77,30%, cao hơn GRPO-SPICE 1,05 điểm [−0,09; +2,18] ($p = 0{,}066$), và nhánh thưởng CIDEr-D 500 bước đạt 76,52%; cả hai chênh lệch đều không có ý nghĩa thống kê. Dưới executability, cả hai nhánh này thấp hơn GRPO-SPICE.

Lỗi còn lại trên bước chạm. Trong 1.756 bước GRPO-SPICE không đạt, 1.576 bước (89,7%) đã đúng loại thao tác nhưng chưa dẫn tới đúng phần tử, gần bằng 1.573 bước của S1/101; điểm nghẽn còn lại là gọi tên hoặc mô tả phần tử mục tiêu.