Chương 7

Kết luận

7.1 Đóng góp chính

Chúng tôi nghiên cứu bài toán sinh hướng dẫn cho giao diện di động từ ảnh màn hình, mục tiêu của người dùng và lịch sử thao tác, trong đó đầu ra là một câu hướng dẫn ngắn cho bước kế tiếp. Công trình tập trung vào ba đóng góp chính gồm (i) một phương pháp sinh gồm hai thành phần nối tiếp, (ii) độ đo khả năng thực hiện theo hướng dẫn (executability), dùng để đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác và đúng loại thao tác, và (iii) các phân tích thực nghiệm trên nhiều phương án thiết kế, qua đó làm rõ những yếu tố ảnh hưởng đến chất lượng câu đầu ra.

Về phương pháp đề xuất

Phương pháp đề xuất (Mục 4.4) tối ưu trực tiếp câu đầu ra và gồm hai thành phần. Thành phần thứ nhất học tiếp mô hình tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE để sinh câu hướng dẫn ban đầu. Thành phần thứ hai, ACE, chỉ hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ truy hồi khi đầu ra thỏa ràng buộc sao chép và nhất quán loại thao tác. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng hoặc điều kiện lựa chọn của phương pháp.

Trên 4.463 bước có thao tác chạm của tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Chiều cải thiện được giữ theo executability, tiêu chí hộp phần tử, tiêu chí hộp phần tử kết hợp cửa sổ 14% và AitW đầy đủ. GRPO-SPICE cũng cao hơn S1/101 ở cả bảy thước dựa trên câu chuẩn, trong đó cả sáu thước có KTC đều

có khoảng tăng nằm trên 0. Lượt GRPO thứ hai đạt 59,94% executability và tiếp tục cao hơn S1/101 0,83 điểm. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11% executability, bằng S1/101, và cả sáu KTC của nhóm thước chữ đều phủ 0. GRPO-SPICE cao hơn nhánh này 1,55 điểm executability [+0,81; +2,30] và cao hơn ở cả sáu thước chữ có KTC. Với cùng số bước huấn luyện, mức tăng chỉ xuất hiện khi tín hiệu SPICE giữ đúng quan hệ với mẫu.

Trên các tác vụ mới trong AndroidControl, mức cải thiện còn rõ hơn. Với 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện S1, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48]. Cả sáu thước chữ có KTC cũng tăng với khoảng tin cậy nằm trên 0. Khi gộp ACU với tập kiểm tra chính thành 5.947 bước, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99]. Khi thay lịch sử chuẩn bằng câu do chính mô hình sinh ở các bước trước, GRPO-SPICE vẫn cao hơn S1 1,48 điểm [+0,54; +2,43]. Hướng tăng vì vậy được giữ trên tác vụ mới trong cùng nguồn AndroidControl và khi lịch sử do chính mô hình sinh.

ACE đạt 60,68% executability, giữ mức của GRPO-SPICE và đồng thời nâng cả bảy thước dựa trên câu chuẩn. Với sáu thước có KTC, toàn bộ khoảng tăng đều nằm trên 0, gồm BLEU-4 +1,11, ROUGE-L +0,74, CIDEr-D +11,97, SPICE +1,33, chrF +0,58 và BERTScore +0,66. Trên AitZ, bước tinh chỉnh có giám sát vẫn cao hơn Base 3,29 điểm executability [+1,51; +5,03]. GRPO-SPICE và S1 tương đương về executability với chênh lệch $-0{,}51$ điểm [$-1{,}39$; +0,36], trong khi GRPO-SPICE có điểm cao hơn S1 ở sáu trong bảy thước chữ, với BLEU-4, SPICE và chrF có KTC nằm trên 0. Mức tăng executability của GRPO-SPICE thể hiện rõ trên AndroidControl và các tác vụ mới trong cùng nguồn dữ liệu. Khi đổi miền sang AitZ, lợi ích bổ sung của SPICE chưa xuất hiện rõ ở executability nhưng một số thước chất lượng câu vẫn giữ mức tăng.

Về độ đo

Khi đầu ra là một câu hướng dẫn thay vì một tọa độ, một câu chuẩn duy nhất khó có thể bao quát hết các cách diễn đạt hợp lệ. Executability tiếp cận vấn đề này bằng cách

đưa câu hướng dẫn do mô hình tạo ra vào một mô hình định vị tách biệt với mô hình sinh, rồi kiểm tra xem câu có dẫn tới đúng phần tử cần thao tác và đúng loại thao tác hay không. Đóng góp của phần đo lường không chỉ nằm ở định nghĩa điểm số, mà còn ở việc xây dựng tiêu chí xác định dự đoán đúng và đánh giá độ tin cậy của cách đo qua nhiều kiểm tra bổ sung (Chương 5).

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101: +1,55 điểm với UGround, +1,55 với UI-Venus, +0,78 [+0,05; +1,51] với Phi-Ground và +0,69 [+0,02; +1,40] với listener Phi-4. Cả bốn KTC đều nằm trên 0. Phi-Ground được xây dựng trên Phi-3.5-Vision, thuộc họ kiến trúc khác Qwen và theo báo cáo kỹ thuật không dùng AndroidControl để huấn luyện. Phi-4 là listener dạng lựa chọn. Thứ tự Base < S1/101 < GRPO-SPICE vì vậy không phụ thuộc vào một kiến trúc đánh giá duy nhất.

Kết quả nền tảng về dữ liệu và mô hình tinh chỉnh có giám sát

Tập giám sát gồm 64.567 bước được xây dựng hoàn toàn tự động, không yêu cầu gán nhãn thủ công bổ sung và không sử dụng nhãn do một mô hình ngôn ngữ khác sinh ra trong quá trình huấn luyện. Các bước kiểm tra chất lượng dữ liệu gồm đánh giá quá trình hợp nhất hai nguồn và mô tả mức lặp lại của cách diễn đạt giữa tập huấn luyện với tập kiểm tra (Chương 3).

Trên 4.463 bước có thao tác chạm của tập kiểm tra, S1/101 đạt 59,11% executability, cao hơn Base 11,52 điểm. Qwen2.5-VL-7B dùng prompting đạt 51,51%, nên mô hình 3B sau SFT cao hơn 7,60 điểm và sau GRPO-SPICE cao hơn 9,14 điểm. Trong thiết lập của đề tài, việc tinh chỉnh trên dữ liệu phù hợp với bài toán đem lại mức tăng lớn hơn rõ rệt so với chỉ tăng mô hình nền từ 3B lên 7B.

Về phân tích các hướng đã thử

Đóng góp thứ ba là phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát trước phương pháp đề xuất. Mục 6.11 tóm tắt kết quả, còn Phụ lục A trình bày thiết kế và số liệu chi tiết. Với biểu diễn mô tả phần tử, chất lượng câu hướng dẫn phụ thuộc mạnh vào việc biểu diễn trung gian có xác định đúng phần tử hay không. Nhóm bước mà biểu diễn này xác định sai chỉ chiếm 29,9% số bước được phân tích nhưng

đóng góp khoảng 91% khoảng cách giữa mô hình và câu chuẩn. Trong các giai đoạn học tiếp, mức cải thiện ở biểu diễn trung gian tạo tác động nhỏ hơn lên executability. Đây là một trong những căn cứ để phương pháp cuối cùng chuyển sang tối ưu trực tiếp câu hướng dẫn.

Với phương án chọn ứng viên, executability đạt 71,4% khi danh sách có ứng viên đúng và mô hình đưa ra lựa chọn. Phần giảm điểm chủ yếu xuất hiện ở những bước mô hình không đưa ra lựa chọn dù danh sách đã có ứng viên phù hợp. Điều này tách quyết định có đưa ra lựa chọn khỏi bài toán xếp hạng ứng viên.

7.2 Hạn chế

Các kết quả được diễn giải trong phạm vi của công cụ đánh giá, thiết lập mô hình và bộ dữ liệu đã sử dụng. Những điểm cần lưu ý khi mở rộng kết luận được tóm tắt dưới đây. Các phân tích kỹ thuật chi tiết nằm ở Chương 5, Chương 6 và Phụ lục A.

7.2.1 Phạm vi của công cụ đo

Executability là một độ đo tự động, dùng mô hình định vị để kiểm tra liệu câu hướng dẫn có dẫn tới đúng phần tử và đúng loại thao tác hay không. Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 dưới cả UGround, UI-Venus, Phi-Ground và Phi-4 (Mục 6.7.3). Hai công cụ ngoài họ Qwen cho mức chênh nhỏ hơn UGround và UI-Venus, nhưng khoảng tin cậy của chênh lệch vẫn nằm trên 0. Các đánh giá chéo này được dùng để xác nhận chiều của kết quả chính, còn executability với UGround là thiết lập đánh giá chính. Đánh giá trực tiếp với người dùng trên quy mô lớn hơn là một hướng bổ sung để tiếp tục đối chiếu executability với khả năng làm theo hướng dẫn trong thực tế.

7.2.2 Phạm vi của kết quả về mô hình

S1 và GRPO-SPICE đều được lặp lại qua hai lượt huấn luyện để quan sát mức biến thiên của kết quả. Trên tập kiểm tra chính, hai lượt GRPO-SPICE cùng cao hơn

S1/101, với mức tăng 1,55 và 0,83 điểm executability. Trên ACU, hai lượt tiếp tục cùng chiều với mức tăng 4,58 và 4,04 điểm. Kết luận chính vì vậy được hỗ trợ bởi hai lượt huấn luyện và một thí nghiệm riêng trên nhóm tác vụ mới. Thiết kế ban đầu đặt mức chênh lệch tối thiểu có thể phát hiện là 2,11 điểm. Mức +1,55 trên tập kiểm tra chính nhỏ hơn ngưỡng thiết kế này nhưng khoảng tin cậy ghép cặp vẫn nằm trên 0. Trên ACU, mức +4,58 vượt ngưỡng, và khi gộp hai tập thành 5.947 bước, mức +2,30 cũng vượt ngưỡng. ACE được xây dựng trên lượt GRPO thứ nhất, đạt 60,68% executability và tăng cả bảy thước dựa trên câu chuẩn. Các nhánh ablation còn lại phục vụ so sánh thiết kế và lựa chọn thành phần của phương pháp.

7.2.3 Phạm vi dữ liệu và thực nghiệm

Thực nghiệm chính được thực hiện trên AndroidControl với giao diện tiếng Anh và mô hình nền Qwen2.5-VL-3B. Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05] ở các tác vụ không xuất hiện trong tập huấn luyện S1. Trên AitZ, lợi ích của bước tinh chỉnh có giám sát vẫn được giữ khi chuyển miền, còn GRPO-SPICE và S1 tương đương về executability. Các kết luận chính về executability tập trung vào bước có thao tác chạm. Ở toàn bộ nhóm bước không chạm với lịch sử chuẩn, tỉ lệ gọi đúng loại thao tác giảm từ 85,97% ở S1 xuống 84,29% ở GRPO-SPICE. Khi dùng lịch sử tự sinh, chênh lệch trên 2.495 bước không chạm là $-4{,}49$ điểm $[-6{,}48; -2{,}61]$. Đây là phạm vi cần tiếp tục cải thiện khi mở rộng phương pháp sang các loại thao tác khác. Việc mở rộng sang nhiều miền giao diện hơn, chuỗi tương tác dài hơn và giao diện tiếng Việt cũng là các hướng tiếp theo để kiểm tra phạm vi áp dụng của phương pháp.

7.3 Tính sẵn có của dữ liệu và mã nguồn

Mã nguồn và các tệp kết quả thô dùng trong quá trình thực nghiệm được lưu kèm theo đề tài để người đọc có thể đối chiếu các bảng và phân tích đã trình bày. Dữ liệu nguồn là AndroidControl [1], giấy phép Apache 2.0, lấy qua hai bản phân phối công khai trên Hugging Face đã nêu ở Bảng 3.1. Ảnh màn hình không được phân phối lại.

Mã nguồn bao gồm quy trình xây dựng dữ liệu, cấu hình huấn luyện, chương trình sinh câu và mã đánh giá. Kết quả được lưu ở mức từng bước, gồm câu hướng dẫn do mô hình tạo ra, điểm đánh giá, tọa độ do mô hình định vị trả về, tọa độ tham chiếu và các thành phần của executability. Nhờ đó, các bảng và phân tích theo nhóm có thể được đối chiếu trực tiếp với kết quả ở mức từng bước mà không cần gọi lại mô hình định vị.

7.4 Hướng phát triển

Các kết quả thực nghiệm gợi ra bốn hướng phát triển tiếp theo.

- **Mở rộng đánh giá qua nhiều lượt huấn luyện.** Hai lượt GRPO hiện cùng giữ hướng cải thiện trên tập kiểm tra chính và ACU. Việc lặp thêm các lượt trong cùng thiết lập sẽ giúp ước lượng chính xác hơn mức biến thiên của độ lớn cải thiện.
- **Kết hợp chặt hơn giữa nhận diện phần tử, lựa chọn phần tử và sinh câu.** Trong các thí nghiệm ở Phụ lục A, việc bổ sung thông tin vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo thay đổi nhỏ ở câu đầu ra. Với phương án chọn ứng viên, quyết định có đưa ra lựa chọn hay không ảnh hưởng đáng kể đến kết quả. Một hướng tiếp theo là học chung biểu diễn phần tử với câu hướng dẫn, hoặc tách rõ bước xác định có ứng viên phù hợp khỏi bước xếp hạng và sinh câu.
- **Đối chiếu executability với đánh giá của người dùng.** Một tập câu được nhiều người đánh giá độc lập có thể được sử dụng để xem executability phản ánh đến đâu khả năng người dùng xác định đúng phần tử và thao tác cần thực hiện. Đồng thời, cần mở rộng các biến thể diễn đạt để đánh giá độ ổn định của độ đo trong nhiều cách mô tả cùng một phần tử.
- **Mở rộng phạm vi thực nghiệm.** Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability trên tác vụ mới trong AndroidControl, còn AitZ cung cấp thêm một đánh giá khi đổi miền dữ liệu. Các thí nghiệm tiếp theo có thể mở rộng sang nhiều bộ dữ liệu có câu hướng dẫn do người viết, chuỗi nhiều màn hình, các loại thao tác ngoài thao tác chạm và giao diện tiếng Việt.