Chương 7

Kết luận

7.1 Đóng góp của luận văn

Luận văn nghiên cứu bài toán sinh hướng dẫn cho giao diện di động từ ảnh màn hình, mục tiêu của người dùng và lịch sử thao tác, trong đó đầu ra là một câu hướng dẫn ngắn cho bước kế tiếp. Từ bài toán này, luận văn tập trung vào ba đóng góp chính: (i) một phương pháp sinh gồm hai thành phần nối tiếp; (ii) độ đo khả năng thực hiện theo hướng dẫn (executability), dùng để đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác và đúng loại thao tác; và (iii) các phân tích thực nghiệm trên nhiều phương án thiết kế, qua đó làm rõ những yếu tố ảnh hưởng đến chất lượng câu đầu ra.

Về phương pháp đề xuất

Phương pháp đề xuất (Mục 4.4) tối ưu trực tiếp câu đầu ra và gồm hai thành phần. Thành phần thứ nhất học tiếp mô hình tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE để sinh câu hướng dẫn ban đầu. Thành phần thứ hai, ACE, chỉ hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ truy hồi khi đầu ra thỏa ràng buộc sao chép và nhất quán loại thao tác. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng hoặc điều kiện lựa chọn của phương pháp.

Trên 4.463 bước có thao tác chạm của tập kiểm tra, phương pháp đề xuất đạt 60,7% executability, cao hơn S1/101 1,57 điểm với khoảng tin cậy 95% [+0,86; +2,31]. Phần lớn mức tăng xuất hiện sau giai đoạn học tăng cường với phần thưởng SPICE. Khi bổ sung ACE, executability tăng nhẹ 0,02 điểm và về cơ bản được giữ ổn định, trong khi

cả bảy độ đo dựa trên câu tham chiếu đều tăng. Hai thành phần vì vậy tác động lên hai khía cạnh khác nhau của kết quả: giai đoạn học tăng cường cải thiện chủ yếu các độ đo theo vị trí, còn ACE làm đầu ra gần hơn với câu tham chiếu mà không làm thay đổi đáng kể executability. Khi huấn luyện lại thành phần thứ nhất với seed khác, mô hình đạt 59,9%, vẫn cao hơn S1/101 theo cả ba tiêu chí nhưng mức tăng executability giảm còn 0,83 điểm và không khác S1/202 có ý nghĩa (Mục 6.7.2). Chiều của mức cải thiện được giữ, còn độ lớn chưa ổn định giữa các lượt huấn luyện.

Về độ đo

Khi đầu ra là một câu hướng dẫn thay vì một tọa độ, một câu tham chiếu duy nhất khó có thể bao quát hết các cách diễn đạt hợp lệ. Executability tiếp cận vấn đề này bằng cách đưa câu hướng dẫn do mô hình tạo ra vào một mô hình định vị tách biệt với mô hình sinh, rồi kiểm tra xem câu có dẫn tới đúng phần tử cần thao tác và đúng loại thao tác hay không. Đóng góp của phần đo lường không chỉ nằm ở định nghĩa điểm số, mà còn ở việc xây dựng tiêu chí xác định dự đoán đúng và đánh giá độ tin cậy của cách đo qua nhiều kiểm tra bổ sung (Chương 5).

Các phân tích ở Chương 5 cho thấy những kết luận chính vẫn nhất quán trên các cấu hình đã kiểm tra khi thay đổi tiêu chí đánh giá hoặc mô hình định vị. Với UI-Venus, chênh lệch S1–Base vẫn giữ khoảng 94% độ lớn và phương pháp đề xuất vẫn cao hơn cả hai seed của S1; listener Phi-4 giữ chênh lệch S1–Base, nhưng không phân biệt được phương pháp đề xuất với S1 seed 202. Executability đồng thời ổn định trước một số biến đổi câu giữ nguyên nội dung, trong khi giảm khi thông tin dùng để xác định phần tử bị loại bỏ.

Kết quả nền tảng về dữ liệu và mô hình tinh chỉnh có giám sát

Tập giám sát gồm 64.567 bước được xây dựng hoàn toàn tự động, không yêu cầu gán nhãn thủ công bổ sung và không sử dụng nhãn do một mô hình ngôn ngữ khác sinh ra trong quá trình huấn luyện. Các bước kiểm tra chất lượng dữ liệu gồm đánh giá quá trình hợp nhất hai nguồn và kiểm tra mức trùng lặp giữa tập huấn luyện với tập kiểm tra (Chương 3).

Trên 4.463 bước có thao tác chạm của tập kiểm tra, S1 đạt 59,1% executability, cao hơn 11,5 điểm so với mô hình gốc. Chiều cải thiện này vẫn được duy trì trong các phân tích theo nhóm và khi thay công cụ định vị, cho thấy tinh chỉnh có giám sát tạo ra thay đổi rõ rệt trong khả năng sinh hướng dẫn bám sát bước hiện tại.

Về phân tích các hướng đã thử

Đóng góp thứ ba là phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát trước phương pháp đề xuất. Mục 6.10 tóm tắt kết quả, còn Phụ lục A trình bày thiết kế và số liệu chi tiết. Các thí nghiệm với biểu diễn mô tả phần tử cho thấy chất lượng câu hướng dẫn phụ thuộc mạnh vào việc biểu diễn trung gian có xác định đúng phần tử hay không. Nhóm bước mà biểu diễn này xác định sai chỉ chiếm 29,9% số bước được phân tích nhưng đóng góp khoảng 91% khoảng cách giữa mô hình và câu tham chiếu. Việc cải thiện biểu diễn trung gian ở các giai đoạn học tiếp cũng chưa chuyển thành mức tăng executability tương ứng, nên phương pháp cuối cùng chuyển sang tối ưu trực tiếp câu hướng dẫn.

Phương án chọn ứng viên cho thấy một điểm nghẽn khác. Khi danh sách có ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4%; tuy nhiên mô hình vẫn từ chối chọn ở nhiều bước dù ứng viên đúng đã có trong danh sách. Kết quả này cho thấy việc nhận biết khi nào nên đưa ra lựa chọn là một vấn đề riêng, không thể giải quyết chỉ bằng cách cải thiện bước xếp hạng ứng viên.

7.2 Hạn chế

Các kết quả cần được hiểu trong phạm vi của công cụ đánh giá, thiết lập mô hình và bộ dữ liệu đã sử dụng. Các hạn chế chính được tóm tắt dưới đây; những phân tích kỹ thuật chi tiết nằm ở Chương 5, Chương 6 và Phụ lục A.

7.2.1 Hạn chế của công cụ đo

Executability dùng mô hình định vị như một thước đo thay thế cho khả năng câu hướng dẫn giúp xác định đúng phần tử. Khi thay công cụ đánh giá bằng UI-Venus-Ground-7B hoặc listener Phi-4, chênh lệch giữa S1 và mô hình gốc vẫn được duy trì. Phương pháp đề xuất vẫn cao hơn cả hai seed của S1 dưới UI-Venus, nhưng dưới Phi-4 thì nằm trong phạm vi dao động giữa hai seed của S1 (Mục 5.10); UI-Venus lại cùng họ Qwen với mô hình được đánh giá. Tuy vậy, executability vẫn chỉ phản ánh gián tiếp việc một người dùng thực sự có thể xác định và thực hiện đúng thao tác hay không, và chưa được đối chiếu với đánh giá thủ công trên một tập đủ lớn. Ngoài ra, tiêu chí ô Voronoi còn phụ thuộc vào mức độ đầy đủ của danh sách phần tử giao diện, đặc biệt đối với các nút biểu tượng và các hàng danh sách.

7.2.2 Hạn chế của kết quả về mô hình

Trên các độ đo chính của 4.463 bước có thao tác chạm, phương pháp đề xuất cho mức cải thiện cùng chiều so với S1, nhưng thiết lập so sánh vẫn còn một số hạn chế. Hai lượt huấn luyện thành phần thứ nhất chênh nhau 0,72 điểm executability, và lượt thứ hai không khác S1/202 có ý nghĩa; mức cải thiện +1,55 điểm vì vậy là kết quả của một lượt huấn luyện. ACE chỉ được xây dựng và đánh giá trên lượt thứ nhất. S1 và mô hình sau GRPO-SPICE được sinh theo hai thiết lập kỹ thuật chưa hoàn toàn đồng nhất, nên một phần chênh lệch quan sát được có thể chịu ảnh hưởng của khác biệt này. Các kết quả executability chính chỉ áp dụng cho 4.463 bước có thao tác chạm; trên 2.495 bước không chạm, thành phần GRPO-SPICE làm tỉ lệ khớp loại thao tác giảm 1,68 điểm so với S1/101 và mức giảm tập trung rõ ở thao tác cuộn và quay lại (Mục 6.3). Với ACE, các độ đo dựa trên câu tham chiếu chưa có khoảng tin cậy. Các phương án trong Phụ lục A chủ yếu được dùng để phân tích hành vi của mô hình; do một số nhánh chưa tách riêng được từng yếu tố, kết quả từ các nhánh này không được diễn giải như bằng chứng nhân quả.

7.2.3 Hạn chế của dữ liệu và phạm vi

Thực nghiệm hiện tập trung trên AndroidControl, giao diện tiếng Anh, một màn hình tại mỗi bước và mô hình nền Qwen2.5-VL-3B. Tập huấn luyện và tập kiểm tra được tách theo tác vụ nhưng vẫn có mức trùng lặp đáng kể về ứng dụng và cách diễn đạt, nên khả năng khái quát sang ứng dụng, ngôn ngữ hoặc bộ dữ liệu khác chưa được đánh giá. Trong các bộ dữ liệu di động công khai đã xem xét (MoTIF, GUI-Odyssey, AITZ, PixelHelp), chưa có bộ nào vừa có câu hướng dẫn từng bước do người viết, vừa có hộp phần tử và ảnh màn hình ở quy mô đủ để so sánh các mô hình; câu từng bước của GUI-Odyssey và AITZ do mô hình ngôn ngữ sinh, còn PixelHelp chỉ gồm 187 tác vụ. Ngoài ra, mỗi bước được đánh giá với lịch sử tham chiếu của các bước trước; vì vậy điểm số phản ánh chất lượng sinh hướng dẫn theo từng bước trong ngữ cảnh đúng, chưa phản ánh đầy đủ lỗi tích lũy trong một phiên tương tác dài.

7.3 Tính sẵn có của dữ liệu và mã nguồn

Mã nguồn và các tệp kết quả thô dùng trong quá trình thực nghiệm được lưu kèm theo đề tài để người đọc có thể đối chiếu các bảng và phân tích trong luận văn. Dữ liệu nguồn là AndroidControl [1], giấy phép Apache 2.0, lấy qua hai bản phân phối công khai trên Hugging Face đã nêu ở Bảng 3.1; ảnh màn hình không được phân phối lại.

Mã nguồn bao gồm quy trình xây dựng dữ liệu, cấu hình huấn luyện, chương trình sinh câu và mã đánh giá. Kết quả được lưu ở mức từng bước, gồm câu hướng dẫn do mô hình tạo ra, điểm đánh giá, tọa độ do mô hình định vị trả về, tọa độ tham chiếu và các thành phần của executability. Nhờ đó, các bảng và phân tích theo nhóm có thể được đối chiếu trực tiếp với kết quả ở mức từng bước mà không cần gọi lại mô hình định vị.

7.4 Hướng phát triển

Từ các hạn chế và kết quả trên, luận văn xác định một số hướng phát triển tiếp theo.

- **Hoàn thiện thiết lập đánh giá giữa các thành phần.** Quy trình sinh câu giữa

các mô hình cần được đồng nhất chặt hơn khi so sánh. Với ACE, khoảng tin cậy cho các độ đo dựa trên câu tham chiếu sẽ giúp đánh giá rõ hơn mức thay đổi ở nhóm độ đo này.

- **Kết hợp chặt hơn giữa nhận diện phần tử, lựa chọn phần tử và sinh câu.** Các phân tích ở Phụ lục A cho thấy việc bổ sung thông tin vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo ảnh hưởng hạn chế, còn phương án chọn ứng viên gặp khó ở quyết định từ chối chọn. Một hướng tiếp theo là học chung biểu diễn phần tử với câu hướng dẫn, hoặc tách rõ bước xác định có ứng viên phù hợp khỏi bước xếp hạng và sinh câu.
- **Đối chiếu executability với đánh giá của người dùng.** Một tập câu được nhiều người đánh giá độc lập có thể được sử dụng để xem executability phản ánh đến đâu khả năng người dùng xác định đúng phần tử và thao tác cần thực hiện. Đồng thời, cần mở rộng các biến thể diễn đạt để đánh giá độ ổn định của độ đo trong nhiều cách mô tả cùng một phần tử.
- **Mở rộng phạm vi thực nghiệm.** Cần đánh giá trên tập kiểm tra chính thức của AndroidControl và một bộ dữ liệu thứ hai, cải thiện các bước không chạm, xét chuỗi nhiều màn hình và giao diện tiếng Việt.