Chương 8

Các công trình nghiên cứu

Một phần nội dung của đề tài đã được phát triển thành hai bài báo, mỗi bài tập trung vào một hướng đóng góp khác nhau của luận văn.

> Lê Đoàn Phương Uyên, TS. Nguyễn Hồng Bửu Long. "Sinh hướng dẫn sử dụng phần mềm từ ảnh chụp màn hình và mục tiêu người dùng: xây dựng nhãn quy chiếu tự động khi phần tử giao diện không có tên để gọi."

Bài viết bằng tiếng Việt, nộp ngày 30 tháng 8 năm 2026 và đã được chấp nhận tại Hội thảo Quốc gia lần thứ tư về Ngôn ngữ học Tính toán (VCL 2026). Đóng góp chính của bài là nhãn quy chiếu và quy trình xây dựng dữ liệu ở Chương 3. Bài báo đặt bài toán trong hướng nghiên cứu về sinh biểu thức quy chiếu, tức sinh mô tả đủ để người tiếp nhận xác định đúng một đối tượng, rồi áp dụng vào miền giao diện. Trong dữ liệu khảo sát, 22,0% phần tử cần chạm không có tên hiển thị phù hợp và 7,6% có cùng tên với một phần tử khác trên cùng màn hình.

> Lê Đoàn Phương Uyên. "GUIStep: A Compact Vision-Language Model for GUI Step Instruction Generation".

Bài viết bằng tiếng Anh, nộp ngày 21 tháng 9 năm 2026 và đã được chấp nhận trình bày tại phiên oral của SOICT 2026 (Paper ID 5590), đồng thời được chấp nhận xuất bản trong kỷ yếu Springer CCIS. Bài báo tập trung vào sinh câu hướng dẫn cho từng bước thao tác trên giao diện và trình bày GUIStep, một mô hình thị giác–ngôn ngữ gọn nhẹ được xây dựng từ Qwen2.5-VL-3B-Instruct. Dữ liệu huấn luyện gồm 64.567 bước của AndroidControl. Bài khảo sát ba cấu hình gồm tinh chỉnh trực tiếp trên câu

hướng dẫn, bổ sung một khai báo có cấu trúc về phần tử đích trước câu hướng dẫn, và tinh chỉnh tiếp bằng các cặp ưu tiên thay đổi phần tử trong phần khai báo. Trong thiết lập đánh giá được sử dụng ở bài SOICT, trên 4.463 bước có thao tác chạm, cấu hình tốt nhất đạt 66,5% so với 53,6% của mô hình nền chưa tinh chỉnh. Kết quả 66,5% và 53,6% được báo cáo theo phiên bản phương pháp và thiết lập đánh giá của bài SOICT. So với bài SOICT, luận văn mở rộng phần thực nghiệm và phát triển phương pháp cuối cùng được trình bày ở Chương 4 đến Chương 6. Phân tích thành phần cho thấy tinh chỉnh có giám sát trên câu hướng dẫn tạo ra phần lớn mức cải thiện, còn các cấu hình có biểu diễn trung gian được dùng để khảo sát thêm vai trò của thông tin phần tử và học theo cặp ưu tiên.

Hai công trình tương ứng với hai hướng nghiên cứu của luận văn: bài VCL tập trung vào xây dựng nhãn quy chiếu và dữ liệu, còn bài SOICT tập trung vào sinh hướng dẫn theo bước và đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác.

Tài liệu tham khảo

[1] W. Li, W. Bishop, A. Li, C. Rawles, F. Campbell-Ajala, D. Tyamagundlu, O. Riva, "On the effects of data scale on UI control agents," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024.

[2] C. Rawles, A. Li, D. Rodriguez, O. Riva, T. P. Lillicrap, "AndroidInTheWild: A large-scale dataset for Android device control," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[3] K. Cheng, Q. Sun, Y. Chu, F. Xu, Y. Li, J. Zhang, Z. Wu, "SeeClick: Harnessing GUI grounding for advanced visual GUI agents," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

[4] Z. Wu, Z. Wu, F. Xu, Y. Wang, Q. Sun, C. Jia, K. Cheng, Z. Ding, L. Chen, P. P. Liang, Y. Qiao, "OS-ATLAS: Foundation action model for generalist GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[5] B. Gou, R. Wang, B. Zheng, Y. Xie, C. Chang, Y. Shu, H. Sun, Y. Su, "Navigating the digital world as humans do: Universal visual grounding for GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025 (Oral).

[6] Z. Gu *et al.*, "UI-Venus technical report: Building high-performance UI agents with RFT," arXiv:2508.10833, 2025 (bản tiền ấn phẩm).

[7] M. Zhang *et al.*, "Phi-Ground Tech Report: Advancing Perception in GUI Grounding," arXiv:2507.23779, 2025 (bản tiền ấn phẩm).

[8] Y. Xu, Z. Wang, J. Wang, D. Lu, T. Xie, A. Saha, D. Sahoo, T. Yu, C. Xiong, "Aguvis: Unified pure vision agents for autonomous GUI interaction," in *Proc. International Conference on Machine Learning (ICML)*, 2025.

[9] X. Deng, Y. Gu, B. Zheng, S. Chen, S. Stevens, B. Wang, H. Sun, Y. Su, "Mind2Web: Towards a generalist agent for the web," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] Y. Li, G. Li, L. He, J. Zheng, H. Li, Z. Guan, "Widget captioning: Generating natural language description for mobile user interface elements," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020.

[11] B. Wang, G. Li, X. Zhou, Z. Chen, T. Grossman, Y. Li, "Screen2Words: Automatic mobile UI summarization with multimodal learning," in *Proc. ACM Symposium on User Interface Software and Technology (UIST)*, 2021.

[12] J. Mao, J. Huang, A. Toshev, O. Camburu, A. Yuille, K. Murphy, "Generation and comprehension of unambiguous object descriptions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[13] R. Luo, G. Shakhnarovich, "Comprehension-guided referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[14] L. Yu, H. Tan, M. Bansal, T. L. Berg, "A joint speaker-listener-reinforcer model for referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[15] S. Petryk, D. Chan, A. Kachinthaya, H. Zou, J. Canny, J. Gonzalez, T. Darrell, "ALOHa: A new measure for hallucination in captioning models," in *Proc. NAACL-HLT, Short Papers*, 2024.

[16] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," in *Findings of the Association for Computational Linguistics: ACL*, pp. 2318–2335, 2024.

[17] A. B. Sai, T. Dixit, D. Y. Sheth, S. Mohan, M. M. Khapra, "Perturbation CheckLists for evaluating NLG evaluation metrics," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2021.

[18] S. Jandial, Y. Li, J. Wagle, K. Koishida, "Do GUI grounders truly understand UI elements?," in *Findings of the Association for Computational Linguistics: EACL*, 2026.

[19] K. Fang, J. Zhang, S.-T. Ni, P. Hui, Y. Wang, "GuideMe: A VLM-based system assisting independent smartphone learning for older adults," in *Proc. ACM Conference on Human Factors in Computing Systems (CHI)*, 2026.

[20] K. Papineni, S. Roukos, T. Ward, W.-J. Zhu, "BLEU: A method for automatic evaluation of machine translation," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2002.

[21] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in *Proc. Workshop on Text Summarization Branches Out, ACL*, 2004.

[22] M. Denkowski, A. Lavie, "Meteor Universal: Language specific translation evaluation for any target language," in *Proc. Ninth Workshop on Statistical Machine Translation (WMT)*, pp. 376–380, 2014.

[23] R. Vedantam, C. L. Zitnick, D. Parikh, "CIDEr: Consensus-based image description evaluation," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4566–4575, 2015.

[24] P. Anderson, B. Fernando, M. Johnson, S. Gould, "SPICE: Semantic propositional image caption evaluation," in *Proc. European Conference on Computer Vision (ECCV)*, pp. 382–398, 2016.

[25] M. Popović, "chrF: Character n-gram F-score for automatic MT evaluation," in *Proc. Tenth Workshop on Statistical Machine Translation (WMT)*, pp. 392–395, 2015.

[26] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi, "BERTScore: Evaluating text generation with BERT," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[27] A. C. Cameron, J. B. Gelbach, D. L. Miller, "Bootstrap-based improvements for inference with clustered errors," *Review of Economics and Statistics*, vol. 90, no. 3, pp. 414–427, 2008.

[28] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965.

[29] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, "LoRA: Low-rank adaptation of large language models," in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[30] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[31] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, "LlamaFactory: Unified efficient fine-tuning of 100+ language models," in *Proc. ACL, System Demonstrations*, 2024.

[32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[33] J. Qi, M. Ding, W. Wang, Y. Bai, Q. Lv, W. Hong, B. Xu, L. Hou, J. Li, Y. Dong, J. Tang, "CogCoM: A visual language model with chain-of-manipulations reasoning," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[34] S. Bai *et al.*, "Qwen2.5-VL technical report," arXiv:2502.13923, 2025 (bản thảo tiền ấn phẩm).

[35] K. Chen, Z. Zhang, W. Zeng, R. Zhang, F. Zhu, R. Zhao, "Shikra: Unleashing multimodal LLM's referential dialogue magic," arXiv:2306.15195, 2023 (bản thảo tiền ấn phẩm).

[36] Q. Wu, X. Yang, Y. Zhou, C. Fang, B. Song, X. Sun, R. Ji, "Grounded chain-of-thought for multimodal large language models," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 33577–33587, 2026.

[37] M. Zhao, P. Anderson, V. Jain, S. Wang, A. Ku, J. Baldridge, E. Ie, "On the evaluation of vision-and-language navigation instructions," in *Proc. Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, pp. 1302–1316, 2021.

[38] P. Rajpurkar, R. Jia, P. Liang, "Know what you don't know: Unanswerable questions for SQuAD," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL), Short Papers*, pp. 784–789, 2018.

[39] A. K. Menon, S. Jayasumana, A. S. Rawat, H. Jain, A. Veit, S. Kumar, "Long-tail learning via logit adjustment," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[40] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024.

[41] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, "DeepSeekMath: Pushing the limits of mathematical reasoning in open language models," bản tiền ấn phẩm arXiv:2402.03300, 2024.

[42] A. Abouelenin *et al.*, "Phi-4-Mini technical report: Compact yet powerful multimodal language models via mixture-of-LoRAs," bản tiền ấn phẩm arXiv:2503.01743, 2025.

[43] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, J. Gao, "Set-of-Mark prompting unleashes extraordinary visual grounding in GPT-4V," bản tiền ấn phẩm arXiv:2310.11441, 2023.

[44] S. J. Rennie, E. Marcheret, Y. Mroueh, J. Ross, V. Goel, "Self-critical sequence training for image captioning," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017.

[45] R. Ramos, B. Martins, D. Elliott, Y. Kementchedjhieva, "SmallCap: Lightweight image captioning prompted with retrieval augmentation," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2023.

[46] S. Liu, Z. Zhu, N. Ye, S. Guadarrama, K. Murphy, "Improved image captioning via policy gradient optimization of SPIDEr," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 873–881.