ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

LUẬN VĂN THẠC SĨ

TP. Hồ Chí Minh - Năm 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

Ngành: TRÍ TUỆ NHÂN TẠO
Mã số ngành: 8480107

NGƯỜI HƯỚNG DẪN KHOA HỌC
TS. Nguyễn Hồng Bửu Long

TP. Hồ Chí Minh - Năm 2026

Lời cam đoan

Tôi cam đoan luận văn thạc sĩ ngành Trí tuệ nhân tạo với đề tài **Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng** là công trình do tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Các số liệu và kết quả trình bày trong luận văn là trung thực, được tính từ mã nguồn cùng các tệp kết quả đi kèm, và chưa từng được công bố trong công trình của tác giả khác. Những thí nghiệm đã lên kế hoạch nhưng chưa thực hiện đều được ghi rõ là chưa thực hiện. Các tài liệu tham khảo được trích dẫn đầy đủ.

Tôi xin chịu trách nhiệm về tính trung thực của các kết quả trình bày trong luận văn.

Học viên cao học

Lê Đoàn Phương Uyên

Lời cảm ơn

Tôi thực hiện luận văn này tại Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh, dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Trước hết, tôi xin gửi lời cảm ơn chân thành đến thầy hướng dẫn, người đã định hướng đề tài và góp ý cho tôi trong suốt quá trình thực hiện luận văn.

Tôi xin cảm ơn quý thầy cô Khoa Công nghệ Thông tin đã giảng dạy trong suốt chương trình cao học, và cảm ơn Văn phòng Khoa đã hỗ trợ các thủ tục liên quan đến luận văn.

Cuối cùng, tôi xin cảm ơn gia đình đã tạo điều kiện để tôi theo học và hoàn thành chương trình này.

Tp. Hồ Chí Minh, tháng 10 năm 2026

Lê Đoàn Phương Uyên

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Danh mục các hình vẽ, đồ thị **viii**

Danh mục các bảng số liệu **ix**

Danh mục các từ viết tắt, khái niệm và thuật ngữ **xii**

Trang thông tin luận văn tiếng Việt **xxii**

Trang thông tin luận văn tiếng Anh **xxvi**

1 Giới thiệu **1**

1.1 Đặt vấn đề 1

1.2 Động lực nghiên cứu 2

1.2.1 Động lực khoa học 2

1.2.2 Động lực ứng dụng 3

1.3 Mục đích nghiên cứu 4

1.4 Khoảng trống nghiên cứu và vị trí của đề tài 5

1.5 Nội dung và phạm vi thực hiện đề tài 6

1.5.1 Nội dung nghiên cứu 6

1.5.2 Phạm vi nghiên cứu 6

1.6 Đóng góp của luận văn 7

2 Tổng quan **9**

2.1 Mô hình ngôn ngữ thị giác 9

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA 10

2.3 GRPO và phần thưởng dựa trên độ đo văn bản 11

2.4 Định vị phần tử giao diện 12

2.5 Bộ dữ liệu AndroidControl 12

2.6 Hạn chế của các độ đo dựa trên câu tham chiếu 13

3 Xây dựng bộ dữ liệu **14**

3.1 Nguồn dữ liệu và quy trình hợp nhất dữ liệu đa nguồn 15

3.2 Kiểm chứng độ chính xác của quy trình hợp nhất 15

3.3 Quy mô và phân chia dữ liệu 16

3.4 Xây dựng thông tin đầu vào từ giao diện 17

3.5 Dữ liệu phục vụ phương pháp đề xuất 18

3.6 Đặc điểm dữ liệu ảnh hưởng đến diễn giải kết quả 19

3.7 Dữ liệu cho các phương án biểu diễn phần tử và học theo cặp 20

3.8 Dữ liệu cho mô hình chọn ứng viên 22

4 Phương pháp đề xuất **24**

4.1 Quy trình tổng thể 24

4.2 Đầu vào và cấu trúc prompt 25

4.3 Cấu hình huấn luyện 26

4.4 Tổng quan phương pháp đề xuất 27

4.5 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE 28

4.6 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE) 30

4.7 Mô hình và thiết lập so sánh 32
4.8 Thiết lập so sánh và diễn giải kết quả 32

5 Độ đo khả năng thực hiện theo hướng dẫn 34
5.1 Định nghĩa 34
5.2 Quy tắc xác định dự đoán đúng và giới hạn của quy tắc dung sai quy ước 36
5.3 Mô hình định vị dùng làm công cụ đo 38
5.4 Sai số của công cụ đo 39
5.5 Mốc tham chiếu của thang điểm 39
5.6 Độ nhạy với thông tin quy chiếu 41
5.6.1 Vai trò của tên phần tử so với vị trí 41
5.7 Kiểm chứng bằng biến đổi lỗi có kiểm soát 42
5.8 Độ ổn định trước các biến thể diễn đạt 43
5.9 Đánh giá chéo bằng mô hình định vị thứ hai 44
5.10 Đánh giá chéo bằng mô hình listener thuộc họ kiến trúc khác 45
5.11 So sánh với các độ đo dựa trên câu tham chiếu 46
5.12 Độ nhạy của kết luận theo quy tắc đánh giá 48
5.13 Phương pháp phân tích thống kê 51

6 Thực nghiệm và kết quả 53
6.1 Thiết lập thực nghiệm 53
6.2 Kết quả chính 53
6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE 57
6.3.1 Kết quả trên bước chạm 57
6.3.2 Độ ổn định của kết quả 59
6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE) 60

6.5 Đánh giá trên nhiều nhóm độ đo 62
6.6 So sánh ghép cặp 66
6.7 Biến thiên giữa hai lượt huấn luyện 68
6.8 Phân tích các giả thuyết thay thế 69
6.9 Phân bố lỗi của mô hình tinh chỉnh có giám sát 70
6.9.1 Ảnh hưởng của việc trùng ứng dụng giữa tập huấn luyện và tập kiểm tra 70
6.9.2 Phân loại lỗi còn lại 71
6.9.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh . 71
6.9.4 Ước lượng dư địa cải thiện còn lại 72
6.10 Các phương án thiết kế đã khảo sát 73
6.11 Giới hạn của độ đo trên tập kiểm tra 74
6.12 Tổng hợp các mô hình và phép thử 75

7 Kết luận **80**
7.1 Đóng góp của luận văn 80
7.2 Hạn chế 82
7.2.1 Hạn chế của công cụ đo 83
7.2.2 Hạn chế của kết quả về mô hình 83
7.2.3 Hạn chế của dữ liệu và phạm vi 83
7.3 Hướng phát triển 84
7.4 Tính sẵn có của dữ liệu và mã nguồn 85

8 Các công trình nghiên cứu **86**

Tài liệu tham khảo **88**

A Các phương án thiết kế đã khảo sát **93**

A.1 Sinh mô tả phần tử trước câu hướng dẫn 93
A.1.1 Thiết kế 93
A.1.2 Các cấu hình của thiết kế so sánh ban đầu 95
A.1.3 Kết quả 96
A.2 Học theo cặp ưu tiên trên dòng mô tả 97
A.2.1 Thiết kế 97
A.2.2 Kết quả 98
A.2.3 Phân tích điểm nghẽn của cơ chế mô tả phần tử 100
A.3 Chọn phần tử trong danh sách ứng viên 101
A.3.1 Thiết kế 101
A.3.2 Kết quả 102
A.4 Huấn luyện tăng cường với phần thưởng tọa độ 106
A.4.1 Thiết kế 106
A.4.2 Kết quả 106
A.4.3 Nội suy trọng số giữa hai checkpoint 107
A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn 108
A.5.1 Độ ổn định của ước lượng trên nhóm con 110
A.6 Tích hợp thông tin vị trí vào mô hình sinh câu 111
A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE) 111
A.7.1 Thiết kế 111
A.7.2 Kết quả 114

Danh mục các hình vẽ, đồ thị

4.1 Quy trình sinh câu của phương pháp đề xuất. 25

4.2 Vòng huấn luyện của thành phần thứ nhất, học tăng cường với phần thưởng SPICE. 29

5.1 Một bước mà hai quy tắc đánh giá cho hai kết quả khác nhau. 37

6.1 Một bước được mô hình học tăng cường với phần thưởng SPICE sửa đúng (ảnh chỉ giữ phần dưới màn hình). 78

6.2 Các mô hình chính theo ba quy tắc đánh giá trên 4.463 bước chạm. . . 79

A.1 Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng cắt (TAGE). 114

A.2 Hai bước mà bộ chọn của TAGE nhận câu sửa, cắt phần dưới màn hình. 116

A.3 Tỉ lệ ô cắt chứa đúng phần tử mục tiêu (bộ định vị trỏ trong dung sai 14%) theo nhóm Δlp, trên các câu mà bộ biên tập đã đổi ở tập kiểm tra. 116

Danh mục các bảng số liệu

3.1 Ba khái niệm trong tên đề tài và dạng cụ thể của từng khái niệm khi triển khai. 14

3.2 Hai bản phân phối trên Hugging Face và phần thiếu của mỗi bản. . . . 15

3.3 Quy mô hai tập dữ liệu sau khi xây dựng. 16

3.4 Bốn ô của dòng mô tả phần tử và lý do cần có từng ô. 20

3.5 Chất lượng nhãn mô tả ở quy mô đầy đủ so với mẫu thử (n = 1.074). . 21

4.1 Cấu hình tinh chỉnh có giám sát. 27

5.1 So sánh các quy tắc xác định dự đoán đúng. 36

5.2 Kiểm chứng độ đo bằng các lỗi được cố ý chèn vào có kiểm soát. . . . 42

5.3 Điểm khi viết lại câu tham chiếu theo bốn biến thể rồi đánh giá lại, tính trên phần bị tác động. 43

5.4 Chênh lệch giữa các mô hình trên cùng 2.532 bước, đánh giá bằng hai mô hình định vị khác nhau. 44

5.5 Tỉ lệ chọn đúng của mô hình listener dạng lựa chọn Phi-4 trên 4.463 bước chạm. 45

5.6 Điểm của câu tham chiếu và chênh lệch giữa S1 với mô hình gốc theo năm quy tắc đánh giá (698 bước): đĩa Euclid, hình chữ nhật theo từng trục, ô Voronoi, ô Voronoi lấy hạt là tâm hộp chứa g, và hộp gần nhất. 48

5.7 Điểm theo quy tắc hộp phần tử (Phụ lục D.3 của AndroidControl) trên 4.463 bước. 49

6.1 Kết quả chính trên 4.463 bước chạm của tập kiểm tra. 54

6.2 Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). . . 56
6.3 Mô hình học tăng cường với phần thưởng SPICE so với S1 seed 101 trên 4.463 bước chạm, ghép cặp theo bước. 58
6.4 ACE trên 4.463 bước chạm, so với câu hướng dẫn ban đầu (của mô hình học tăng cường với phần thưởng SPICE) và với mô hình sinh câu độc lập. 61
6.5 Nhóm độ đo theo vị trí trên đủ 4.463 bước chạm, tính lại từ bản ghi từng bước, không gọi lại mô hình định vị. 62
6.6 Nhóm độ đo so với câu tham chiếu trên đủ 4.463 bước chạm. 63
6.7 Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và phép so ghép cặp (dưới). 64
6.8 So sánh ghép cặp trên 4.463 bước. 66
6.9 Hai lượt huấn luyện chỉ khác seed, đánh giá trên cùng 4.463 bước. . . 68
6.10 Phân tích các giả thuyết thay thế cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra. 69
6.11 Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa. 70
6.12 Các phương án thiết kế đã khảo sát. 73
6.13 Trạng thái cuối của các mô hình, cấu hình và phép thử. 75

A.1 Ảnh hưởng của bước trung gian trong các công trình trước. 94
A.2 Các cấu hình của thiết kế so sánh ban đầu. 95
A.3 Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không. 96
A.4 Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh. 97
A.5 Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình. 98

A.6 Khớp loại thao tác trên mẫu 400 bước không chạm (cuộn 96, chờ 86, gõ chữ 82, mở ứng dụng 81, quay lại 55), đánh giá với biến thể nghiêm ngặt của điều kiện khớp loại thao tác. 99

A.7 Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. 100

A.8 Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). 101

A.9 Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. 103

A.10 Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng. 104

A.11 Tỉ lệ thẻ `none` theo bốn mẫu số. 104

A.12 Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. 108

A.13 Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm. 109

A.14 Ngưỡng tối đa của một can thiệp chỉ thay câu, dưới bốn cách định nghĩa nhóm (4.437 bước ghép cặp được). 110

A.15 Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. 112

A.16 Mô-đun hiệu chỉnh câu theo vùng cắt (TAGE) trên 4.463 bước chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của mô hình học tăng cường với phần thưởng SPICE và với S1. 114

Danh mục các từ viết tắt, khái niệm và thuật ngữ

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
GUI	Graphical User Interface	Giao diện đồ họa người dùng
VLM	Vision-Language Model	Mô hình ngôn ngữ thị giác
LLM	Large Language Model	Mô hình ngôn ngữ lớn
SFT	Supervised Fine-Tuning	Tinh chỉnh có giám sát
LoRA	Low-Rank Adaptation	Tinh chỉnh hạng thấp
QLoRA	Quantized LoRA	LoRA trên trọng số đã lượng tử hoá
NF4	4-bit NormalFloat	Định dạng lượng tử hoá 4 bit
AitW	AndroidInTheWild	Bộ dữ liệu Android quy mô lớn (NeurIPS 2023). Trong các bảng, AitW chỉ quy tắc khoảng cách Euclid của bộ dữ liệu này
OCR	Optical Character Recognition	Nhận dạng văn bản trong ảnh
KTC	Confidence Interval	Khoảng tin cậy
dp	density-independent pixel	Đơn vị độ dài độc lập mật độ điểm ảnh trên Android

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
pp	percentage point	Điểm phần trăm (chênh lệch tuyệt đối giữa hai tỉ lệ)
ORPO	Odds Ratio Preference Optimization	Mục tiêu ưu tiên gắn thẳng vào hàm mất mát có giám sát, không cần mô hình tham chiếu
GRPO	Group Relative Policy Optimization	Học tăng cường trên từng nhóm đầu ra sinh từ cùng một prompt, sử dụng phần thưởng tương đối trong nhóm thay cho một mô hình ước lượng giá trị riêng
KL	Kullback-Leibler divergence	Độ lệch giữa hai phân bố xác suất, dùng để giữ mô hình không trôi xa mô hình tham chiếu
SPICE	Semantic Propositional Image Caption Evaluation	Độ đo dựa trên câu tham chiếu, so sánh các đối tượng, thuộc tính và quan hệ được trích xuất từ hai câu
Thuật ngữ riêng của đề tài: phương pháp đề xuất		
Phương pháp đề xuất		Đóng góp chính của đề tài, gồm hai thành phần nối tiếp. Thành phần thứ nhất viết câu hướng dẫn ban đầu, sau đó ACE quyết định giữ câu hướng dẫn ban đầu hay thay bằng một câu ví dụ truy hồi được (Mục 4.4).

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Mô hình học tăng cường với phần thưởng SPICE		Đây là thành phần thứ nhất của phương pháp đề xuất, trong đó mô hình tinh chỉnh có giám sát (S1) được học tiếp bằng học tăng cường theo nhóm, với phần thưởng là điểm SPICE giữa câu sinh và câu tham chiếu (Mục 4.5).
Câu hướng dẫn ban đầu		Câu mà mô hình học tăng cường với phần thưởng SPICE sinh cho bước đang xét bằng giải mã tham lam. Câu này được giữ nguyên, trừ khi quy tắc đồng thuận của ACE cho phép hiệu chỉnh.
ACE (hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác)		*Action-Consistent Exemplar copying*, thành phần thứ hai của phương pháp đề xuất. Một mô hình sinh câu nhận thêm bốn câu tham chiếu của các bước tương tự nhất trong tập huấn luyện. Câu sinh chỉ được dùng để thay câu hướng dẫn ban đầu khi sao chép nguyên văn một câu ví dụ và cùng loại thao tác với câu hướng dẫn ban đầu; điều kiện này được gọi là quy tắc đồng thuận (Mục 4.6).
Thuật ngữ riêng của đề tài: độ đo và thực nghiệm		

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
	executability (khả năng thực hiện theo hướng dẫn)	Độ đo của đề tài, dùng để chấm phương pháp đề xuất và mọi mô hình khác. Một câu hướng dẫn được tính là đúng nếu, khi đưa câu đó cho một mô hình định vị tách biệt với mô hình sinh, mô hình ấy xác định đúng phần tử mà người dùng đã chạm và câu gọi đúng loại thao tác.
	Mô hình định vị phần tử (GUI grounding model)	Mô hình nhận một câu mô tả cùng một ảnh màn hình và trả về tọa độ của phần tử được mô tả. Trong đề tài, mô hình này chỉ được dùng làm công cụ đo và không nằm trong số các mô hình được sử dụng để so sánh.
	Câu tham chiếu	Câu hướng dẫn từng bước do người chú thích AndroidControl viết cho bước tương ứng; được sử dụng làm đầu ra tham chiếu trong huấn luyện và đánh giá văn bản.
	Bước chạm	Bước thao tác mà người dùng chạm vào màn hình, tức bước có tọa độ đích. Toàn bộ điểm số của đề tài tính trên nhóm bước này.

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
	Phần tử cần chạm	Nút, ô nhập hoặc mục danh sách mà người dùng đã chạm ở bước đang xét, tức đối tượng mà câu hướng dẫn phải chỉ ra được.
	Ô Voronoi	Vùng trên màn hình gồm những điểm nằm gần phần tử cần chạm hơn bất kỳ phần tử nào khác. Chúng tôi dùng vùng này để xác định một dự đoán đúng, thay cho một dung sai cố định.
	Tập bước được chấm	Tập này gồm 4.463 bước chạm của tập kiểm tra và được dùng chung để chấm mọi mô hình, nên hai mô hình bất kỳ luôn so được với nhau trên đúng những bước như nhau.
	Các mốc tham chiếu của độ đo	Điểm executability của chính câu tham chiếu được dùng làm mốc để hỗ trợ diễn giải điểm của các mô hình. Mốc tham chiếu dưới được ước lượng bằng các câu mang rất ít hoặc không mang thông tin quy chiếu. Hai mức này là các mốc thực nghiệm, không phải giới hạn toán học tuyệt đối của độ đo.

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Mô hình gốc (Base)		Đây là mô hình Qwen2.5-VL-3B-Instruct khi chưa tinh chỉnh, được dùng làm một mốc so sánh và trong các bảng được gọi là Base (Mục 4.7).
Mô hình tinh chỉnh có giám sát (S1)		Mô hình gốc được tinh chỉnh có giám sát để sinh trực tiếp câu hướng dẫn từ prompt, không qua bước trung gian nào. Mô hình này được huấn luyện hai lần với hai seed, 101 và 202; thành phần thứ nhất của phương pháp đề xuất học tiếp từ seed 101. Trong các bảng, mô hình này được gọi là S1 (Mục 4.7).
Mốc so sánh và mô hình có can thiệp		Khi đánh giá một can thiệp, mốc so sánh là mô hình không có can thiệp đó, thường là mô hình tinh chỉnh có giám sát, còn mô hình có can thiệp là mô hình được thêm đúng can thiệp ấy. Đại lượng cần đo là chênh lệch điểm giữa hai mô hình.
Hạt giống ngẫu nhiên (random seed)		Giá trị dùng để khởi tạo các thành phần ngẫu nhiên của một lượt huấn luyện. Hai lượt dùng seed khác nhau nhưng cùng cấu hình được sử dụng để kiểm tra độ ổn định của kết quả.

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Checkpoint (bản lưu trọng số)		Bản trọng số mô hình được ghi ra đĩa tại một thời điểm của lượt huấn luyện.
Cách chia nhóm, nhóm con		Tập bước được đánh giá có thể chia thành các nhóm con, ví dụ theo độ dài câu hoặc theo số phần tử trên màn hình, để xem kết quả riêng trên từng nhóm.
Phép so sánh kiểm chứng		Phép so sánh có chênh lệch đủ rõ, được dùng để kiểm tra liệu một công cụ đánh giá khác có bảo toàn chiều và độ lớn tương đối của kết quả hay không.
Tập kiểm định nội bộ		Tập 1.567 bước được chỉ định từ dữ liệu huấn luyện theo tác vụ để xếp hạng checkpoint và biến thể, không dùng để báo cáo kết quả chính. S1 đã được huấn luyện trên toàn bộ 64.567 bước trước khi tập này được chỉ định (Mục 3.3).

Thuật ngữ riêng của đề tài: các hướng đã thử (Phụ lục A)

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
	Dòng mô tả phần tử (descriptor)	Đây là một dòng có cấu trúc gồm bốn phần, `[vai trò | tên | tọa độ | dấu hiệu phân biệt]`, mà mô hình phải viết ra trước câu hướng dẫn, gọi tắt là dòng mô tả. Dòng này bị cắt bỏ trước khi đánh giá và chỉ xuất hiện ở các hướng đã thử, không có trong phương pháp đề xuất.
	Mô hình mô tả phần tử (S2)	Đây là hướng đã thử đầu tiên, trong đó mô hình gốc được tinh chỉnh có giám sát để viết dòng mô tả phần tử rồi mới viết câu, theo nguyên tắc mô tả phân biệt trước, phát ngôn sau (Mục A.1.1).
	Cấu hình mô tả giả và cấu hình mô tả không có tọa độ (S2r, S2-nopoint)	Đây là hai cấu hình đối chứng được thiết kế cho mô hình mô tả phần tử nhưng chưa được chạy. Cấu hình thứ nhất thay dòng mô tả thật bằng một dòng mô tả giả có cùng độ dài, cấu hình thứ hai bỏ tọa độ khỏi dòng mô tả (Mục A.1.2).
	Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	Đây là giai đoạn huấn luyện thứ hai, học tiếp từ mô hình mô tả phần tử và trong đó mô hình học từ các cặp chuỗi chỉ khác nhau ở dòng mô tả, còn câu hướng dẫn thì giống hệt nhau (Mục A.2.1).

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
	Mô hình học thêm có giám sát (CE2-S2)	Đây là mô hình dùng để so với giai đoạn học ưu tiên, chỉ học thêm có giám sát với cùng số bước, nhờ đó tách được phần cải thiện do mục tiêu ưu tiên mang lại khỏi phần chỉ do mô hình được huấn luyện thêm (Mục A.2.1).
	Danh sách ứng viên	Danh sách tối đa 40 phần tử của một màn hình, mỗi dòng gồm tên và tọa độ, được xây dựng từ cây trợ năng và văn bản trích xuất trên màn hình, rồi đưa vào prompt của mô hình chọn ứng viên (Mục 3.8).
	Mô hình chọn ứng viên	Đây là hướng đã thử trong đó mô hình chọn phần tử cần chạm từ danh sách ứng viên thay vì tự viết dòng mô tả; thẻ ghi phần tử được chọn bị cắt bỏ trước khi đánh giá (Mục A.3.1).
	Từ chối chọn	Đây là trường hợp mô hình chọn ứng viên phát thẻ `none` thay vì chọn một phần tử; việc từ chối là đúng khi danh sách không chứa phần tử cần chạm, và là sai khi danh sách có chứa phần tử đó.

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
	Huấn luyện tăng cường với phần thưởng tọa độ	Giai đoạn học tiếp từ MIN-DESC bằng GRPO, trong đó phần thưởng chủ yếu được tính từ tọa độ ghi trong dòng mô tả thay vì từ câu hướng dẫn (Mục A.4.1).
	Mô-đun hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE)	Biến thể hậu xử lý được khảo sát ở cùng vị trí với ACE. TAGE gồm mô-đun định vị, mô-đun biên tập nhận vùng ảnh cục bộ và câu hướng dẫn ban đầu, cùng một bộ chọn quyết định có sử dụng câu đã hiệu chỉnh hay không (Mục A.7.1).

Trang thông tin luận văn

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn:	Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng.
Ngành:	Trí tuệ nhân tạo
Mã số ngành:	8480107
Họ và tên HVCH:	Lê Đoàn Phương Uyên
MSHV:	**[CẦN ĐIỀN: MSHV — kiểm lại: 24C15039?]**
Khóa đào tạo:	34
GVHD:	TS. Nguyễn Hồng Bửu Long
Cơ sở đào tạo:	Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM

1. Tóm tắt nội dung luận văn

Trong khi các hệ thống tác tử giao diện thường sử dụng ảnh chụp màn hình để dự đoán thao tác và tọa độ tương tác nhằm tự động thực hiện tác vụ, luận văn giữ nguyên dạng đầu vào nhưng thay đổi mục tiêu đầu ra. Thay vì dự đoán tọa độ, mô hình sinh câu hướng dẫn ngắn gọn giúp người dùng xác định thao tác và phần tử giao diện cần tương tác. Đầu vào gồm thông tin về trường hợp sử dụng như mục tiêu của người dùng và các bước đã hoàn thành, kết hợp với trạng thái giao diện thể hiện qua ảnh chụp màn hình hiện tại và văn bản hiển thị.

Phương pháp đề xuất gồm hai thành phần nối tiếp. Thành phần đầu tiên tiếp tục huấn luyện mô hình Qwen2.5-VL-3B đã được tinh chỉnh có giám sát bằng GRPO, trong đó điểm SPICE giữa câu sinh và câu tham chiếu được sử dụng làm phần thưởng. SPICE đánh giá mức tương đồng dựa trên các đối tượng, thuộc tính và quan hệ được

trích xuất từ nội dung câu. Sau giai đoạn này, mô hình sinh câu hướng dẫn ban đầu cho từng bước. Thành phần thứ hai là ACE, sử dụng bốn câu tham chiếu được truy hồi từ các bước tương tự nhất trong tập huấn luyện làm ví dụ. ACE chỉ thay câu hướng dẫn ban đầu khi đầu ra của mô-đun sinh câu trùng nguyên văn với câu ví dụ và có cùng loại thao tác với câu hướng dẫn ban đầu.

Trên tập kiểm tra, phương pháp đề xuất đạt 60,7% executability, cao hơn mô hình tinh chỉnh có giám sát 1,57 điểm với khoảng tin cậy 95% [+0,86; +2,31]. Giai đoạn GRPO-SPICE đạt 60,6%, cao hơn 1,55 điểm so với mô hình tinh chỉnh có giám sát ([+0,80; +2,33], $p < 0,001$) và cho kết quả cao hơn trên cả mười ba độ đo được báo cáo. Khi bổ sung ACE, executability gần như được giữ nguyên trong khi cả bảy độ đo dựa trên câu tham chiếu đều tăng. Mức cải thiện rõ nhất xuất hiện ở CIDEr-D với +12,0 điểm và SPICE với +1,3 điểm.

Để đánh giá phương pháp, luận văn xây dựng và kiểm chứng độ đo khả năng thực hiện theo hướng dẫn (instruction executability), sau đây gọi ngắn là executability. Cùng phần tử giao diện có thể được mô tả theo nhiều cách hợp lệ, chẳng hạn "thanh tìm kiếm" hoặc "biểu tượng kính lúp". Vì vậy, việc so sánh câu sinh với duy nhất câu tham chiếu chưa phản ánh đầy đủ khả năng câu hướng dẫn giúp xác định đúng phần tử cần tương tác. Executability đánh giá câu sinh thông qua mô hình định vị được tách biệt với mô hình sinh. Bước tương tác được tính là đúng khi mô hình định vị xác định đúng phần tử người dùng đã chạm và câu hướng dẫn sử dụng đúng loại thao tác. Khi áp dụng cách đánh giá này lên các câu tham chiếu, executability đạt 75,7%. Kết quả này được dùng làm mốc tham chiếu khi diễn giải điểm số của các mô hình. Thứ tự giữa các hệ thống vẫn được duy trì khi đánh giá lại bằng mô hình định vị thứ hai không được huấn luyện trên dữ liệu của đề tài và mô hình listener thuộc họ mô hình khác, trong đó câu hướng dẫn được dùng để lựa chọn phần tử từ danh sách đã đánh số.

Luận văn xây dựng quy trình hoàn toàn tự động để chuyển dữ liệu AndroidControl thành tập huấn luyện gồm 64.567 bước. Trên 4.463 bước chạm của tập kiểm tra, mô hình tinh chỉnh có giám sát được sử dụng làm điểm xuất phát cho phương pháp đề xuất đạt 59,1% executability, trong khi mô hình gốc đạt 47,6%. Theo quy tắc khung phần tử của AndroidControl, hai mô hình lần lượt đạt 65,5% và 53,6%. Luận văn cũng xem xét bảy giả thuyết có thể giải thích chênh lệch giữa hai mô hình. Trong số đó, sáu giả

thuyết không phù hợp với các quan sát thu được từ thực nghiệm.

Phương pháp cuối cùng được lựa chọn sau khi khảo sát nhiều hướng thiết kế khác nhau, được trình bày chi tiết trong Phụ lục A. Phần lớn các hướng này can thiệp vào biểu diễn trung gian giữa ảnh và câu hướng dẫn. Chẳng hạn, mô hình có thể sinh trước nội dung mô tả phần tử cần chạm hoặc sử dụng thêm thông tin vị trí khi sinh câu. Kết quả cho thấy việc cải thiện biểu diễn trung gian chưa chắc dẫn đến cải thiện tương ứng ở câu hướng dẫn cuối cùng. Vì vậy, phương pháp đề xuất tập trung trực tiếp vào việc tối ưu câu hướng dẫn được sinh.

2. Những kết quả mới của luận văn

- **Phương pháp hai thành phần cải thiện executability so với mô hình tinh chỉnh có giám sát.** Thành phần thứ nhất sử dụng học tăng cường với phần thưởng SPICE để sinh câu hướng dẫn ban đầu; thành phần thứ hai (ACE) sử dụng câu ví dụ truy hồi với ràng buộc nhất quán loại thao tác. Phương pháp đạt mức executability cao hơn mô hình tinh chỉnh có giám sát với ý nghĩa thống kê, trong khi mô hình định vị dùng để đánh giá không tham gia vào phần thưởng. ACE đồng thời cải thiện cả bảy độ đo dựa trên câu tham chiếu mà không làm giảm executability đáng kể.

- **Độ đo khả năng thực hiện theo hướng dẫn không yêu cầu một câu tham chiếu duy nhất làm đáp án.** Quy tắc xác định dự đoán đúng được lựa chọn dựa trên hành vi đo được của công cụ định vị thay vì chỉ sử dụng một dung sai quy ước. Thứ tự giữa các hệ thống được duy trì khi đánh giá lại bằng năm quy tắc khác nhau.

- **Các mốc tham chiếu của độ đo được đo trực tiếp.** Câu tham chiếu đạt 75,7% executability. Một câu chung chung không xác định phần tử đạt 12,0%, còn câu tham chiếu lấy từ một màn hình khác đạt 6,1%. Các kết quả này cung cấp các mốc thực nghiệm để diễn giải thang điểm và cho thấy điểm số nhạy với nội dung quy chiếu của câu.

- **Quy trình xây dựng dữ liệu hoàn toàn tự động.** Quy trình chuyển Android-Control thành tập huấn luyện cho tác vụ mới bằng cách ghép hai bản phát hành

công khai, một bản chứa câu hướng dẫn và một bản chứa ảnh, đồng thời kiểm tra độ chính xác của quá trình ghép bằng một đối chứng được làm lệch có chủ đích.

- **Phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát (Phụ lục A).** Kết quả cho thấy lợi ích của biểu diễn mô tả phần tử phụ thuộc mạnh vào việc biểu diễn này xác định đúng phần tử mục tiêu. Một số can thiệp cải thiện tín hiệu nhận diện phần tử nhưng chỉ tạo thay đổi nhỏ ở executability, cho thấy cải thiện ở biểu diễn trung gian không tự động chuyển thành cải thiện tương ứng ở câu đầu ra. Mô hình chọn ứng viên có độ chính xác cao khi đưa ra lựa chọn nhưng từ chối chọn với tần suất lớn; các thí nghiệm bổ sung thông tin vị trí cũng cho thấy tín hiệu này có thể được mã hóa trong trạng thái ẩn nhưng ảnh hưởng tới câu sinh còn hạn chế.
- **Thiết lập lại vai trò của câu hướng dẫn trong AndroidControl.** Trong AndroidControl và các công trình sử dụng bộ dữ liệu này, câu hướng dẫn từng bước do người chú thích viết thường được dùng làm đầu vào. Trong luận văn, câu này trở thành mục tiêu sinh và là đầu ra được đánh giá.

CÁN BỘ HƯỚNG DẪN	HỌC VIÊN CAO HỌC
(Ký tên, họ tên)	(Ký tên, họ tên)

XÁC NHẬN CỦA CƠ SỞ ĐÀO TẠO
HIỆU TRƯỞNG

Thesis information

THESIS INFORMATION

Thesis title:	LLM-Based Automatic Generation of Software User Guides from Use Cases and Front-End Structures.
Speciality:	Artificial Intelligence
Code:	8480107
Name:	Le Doan Phuong Uyen
Student ID:	**[CẦN ĐIỀN: MSHV — kiểm lại: 24C15039?]**
Academic year:	34
Supervisor:	Dr. Nguyen Hong Buu Long
At:	VNUHCM - University of Science

1. Summary

Current GUI agents commonly take a screenshot as input and predict an action together with an interaction location so that the system can execute the task automatically. This thesis considers a similar input setting but changes the output objective: instead of predicting an interaction coordinate, the model generates a short instruction that helps a user identify the required action and target interface element. The input consists of the use case, including the user's goal and preceding steps, and the current user interface, represented by the screenshot and the text displayed on it.

The main contribution is a two-stage method. The first stage continues training a supervised Qwen2.5-VL-3B model with GRPO, using the SPICE score between the generated instruction and the reference instruction as the reward. SPICE compares sentences through the objects, attributes, and relations extracted from their content.

This stage produces a draft instruction for each step. The second stage, ACE (Action-Consistent Exemplar Copying), provides four reference instructions retrieved from the most similar training steps as exemplars. The draft is replaced only when the generator output copies one exemplar verbatim and has the same action type as the draft.

The proposed method reaches 60.7% executability, 1.57 percentage points above the supervised baseline (95% CI [+0.86, +2.31]). The first stage alone reaches 60.6%, 1.55 points above the supervised baseline (95% CI [+0.80, +2.33], $p < 0.001$), and improves all thirteen reported measures. Relative to the first stage, ACE keeps executability nearly unchanged while improving all seven reference-based text measures, most notably CIDEr-D (+12.0) and SPICE (+1.3).

To evaluate the method, the thesis develops and validates a measure of instruction executability, referred to as executability. A GUI element can be described correctly in multiple ways, for example "the search bar" and "the magnifying glass", so comparison against a single reference sentence does not fully capture valid outputs. Executability passes the generated instruction to a GUI grounding model that is separate from the generator; a step is counted as correct when the model identifies the element touched by the user and the instruction specifies the correct action type. Applying the measure to the human-written reference instructions yields 75.7%, which is used as a reference point for interpreting model scores. System ordering is also preserved when evaluation is repeated with a second grounding model not trained on this corpus and with a multiple-choice listener from a different model family.

A fully automatic pipeline converts AndroidControl into 64,567 training steps. On 4,463 held-out touch steps, the supervised model, which serves as the starting point of the proposed method, reaches 59.1% executability compared with 47.6% for the base model. Under AndroidControl's element-box rule, the corresponding scores are 65.5% and 53.6%. The thesis further examines seven alternative explanations for this gap; six are inconsistent with the observed experimental patterns.

The final method was selected after examining several alternative designs (Appendix A). Most of these designs intervene on an intermediate representation between the screenshot and the generated instruction, such as an element description produced before the instruction or location information added to the sentence generator. The

analysis shows that improvements in an intermediate representation do not automatically translate into corresponding improvements in the final instruction, motivating the final method to optimize the generated instruction directly.

2. Novelty of thesis

- **A two-stage method that improves executability over supervised fine-tuning.** The first stage uses reinforcement learning with SPICE reward to produce a draft instruction, while the second stage (ACE) uses retrieved exemplars under an action-consistency constraint. The method improves executability over the supervised baseline with statistical significance, although the grounding model used for evaluation is not part of the reward. ACE also improves all seven reference-based text measures without a meaningful decrease in executability.
- **A measure of instruction executability that does not require a single reference sentence as the answer key.** The criterion for a correct grounding prediction is selected from measured grounding behaviour rather than solely from a conventional tolerance. System ordering is preserved under five alternative evaluation rules.
- **Empirically measured reference points for the evaluation scale.** Human-written reference instructions reach 75.7% executability. A generic sentence that does not identify an element scores 12.0%, while a reference instruction taken from a different screen scores 6.1%. These measurements provide empirical reference points for interpreting the scale and show that the score is sensitive to the referential content of an instruction.
- **A fully automatic data construction pipeline.** The pipeline converts AndroidControl into supervision for the new task by joining two public releases, one containing instructions and the other screenshots, and validates the join against a deliberately shifted control.
- **A step-level analysis of alternative designs (Appendix A).** The benefit of the intermediate element description depends strongly on whether that

representation identifies the correct target. Some interventions improve target-identification signals but produce only small changes in executability, indicating that improvements in intermediate representations do not automatically transfer to the generated instruction. The candidate-selection model is accurate when it makes a selection but rejects too frequently; experiments that inject location information likewise show that the signal can be encoded in hidden states while its effect on generated instructions remains limited.

- **A reformulation of the role of instructions in AndroidControl.** In AndroidControl and prior work using it, the human-written per-step instruction is typically an input. In this thesis, it becomes the generation target and the output being evaluated.

SUPERVISOR MASTER STUDENT

CERTIFICATION
UNIVERSITY OF SCIENCE
PRESIDENT

Chương 1

Giới thiệu

1.1 Đặt vấn đề

Khi thực hiện một tác vụ trên ứng dụng di động, người dùng có thể biết mục tiêu cần đạt nhưng chưa biết phải thao tác như thế nào trên giao diện hiện tại. Trong trường hợp này, một hướng dẫn hữu ích không chỉ cần nêu đúng hành động, mà còn phải giúp người dùng xác định được phần tử cần tương tác. Chẳng hạn, thay vì chỉ yêu cầu "chia sẻ", hệ thống có thể hướng dẫn "Chạm vào biểu tượng chia sẻ ở góc trên bên phải màn hình".

Các nghiên cứu gần đây về tác tử giao diện người dùng (GUI agent), như SeeClick [3], OS-Atlas [4] và Aguvis [7], cũng giải quyết bài toán hiểu trạng thái giao diện và xác định hành động tiếp theo. Tuy nhiên, các hệ thống này chủ yếu hướng tới việc tự động thực hiện tác vụ: đầu ra thường là loại thao tác cùng vị trí trên màn hình, chẳng hạn `click(872,141)`. Biểu diễn này phù hợp với một tác tử phần mềm, nhưng không trực tiếp tạo ra hướng dẫn để người dùng đọc và làm theo.

Luận văn này tập trung vào bài toán sinh hướng dẫn cho thao tác kế tiếp bằng ngôn ngữ tự nhiên. Tại mỗi thời điểm, mô hình nhận thông tin về mục tiêu của tác vụ, các thao tác đã được thực hiện trước đó và trạng thái giao diện hiện tại. Trạng thái giao diện được biểu diễn chủ yếu bằng ảnh chụp màn hình cùng phần văn bản đang hiển thị. Từ các thông tin này, mô hình cần sinh một câu hướng dẫn cho biết người dùng nên thực hiện thao tác nào và tương tác với phần tử nào để tiếp tục tác vụ.

Thiết lập này tạo ra một yêu cầu khác với bài toán GUI agent truyền thống. Một dự đoán có thể xác định đúng thao tác hoặc đúng vị trí trên màn hình nhưng vẫn chưa

phải là một hướng dẫn tốt cho người dùng nếu phần tử cần tương tác được mô tả không rõ ràng. Ngược lại, cùng một thao tác có thể được diễn đạt bằng nhiều câu khác nhau nhưng vẫn dẫn người dùng đến đúng phần tử và đúng hành động. Vì vậy, việc đánh giá hệ thống không thể chỉ dựa vào mức độ tương đồng giữa câu sinh và một câu tham chiếu, mà còn cần xem xét liệu hướng dẫn được sinh ra có cung cấp đủ thông tin để người dùng thực hiện đúng thao tác hay không.

Một thách thức khác là câu hướng dẫn phải đủ cụ thể để người dùng xác định đúng phần tử cần thao tác. Việc mô tả đúng loại phần tử chưa chắc đã đủ, đặc biệt khi trên cùng màn hình có nhiều phần tử giống hoặc gần giống nhau. Chẳng hạn, câu "Chạm vào biểu tượng tìm kiếm" vẫn có thể gây nhầm lẫn nếu giao diện xuất hiện hai biểu tượng tìm kiếm ở những vị trí khác nhau. Trong trường hợp đó, hướng dẫn cần bổ sung các đặc điểm giúp phân biệt phần tử mục tiêu, chẳng hạn vị trí, nội dung hiển thị hoặc mối quan hệ với các thành phần xung quanh. Vì vậy, chất lượng của câu hướng dẫn không chỉ nằm ở việc nêu đúng thao tác, mà còn ở khả năng giúp người dùng nhận ra chính xác phần tử cần tương tác.

Từ yêu cầu này, luận văn tập trung vào hai vấn đề chính. Thứ nhất, cần một cách đánh giá phản ánh được liệu câu hướng dẫn có đủ thông tin để xác định đúng phần tử mục tiêu hay không, thay vì chỉ đo mức độ giống nhau về từ ngữ giữa câu sinh và câu tham chiếu. Thứ hai, cần một phương pháp sinh có khả năng tạo ra các hướng dẫn rõ ràng và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình. Hai vấn đề này được xem xét cùng nhau: độ đo được xây dựng để đánh giá khả năng xác định đúng phần tử, và sau đó được sử dụng để đánh giá phương pháp sinh hướng dẫn được đề xuất trong luận văn.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Về mặt khoa học, bài toán của luận văn có liên hệ gần với hướng nghiên cứu sinh biểu thức quy chiếu (*referring expression generation*). Trong bài toán này, một mô tả được xem là hữu ích khi người tiếp nhận có thể dựa vào mô tả đó để nhận ra đúng đối

tượng được nhắc tới. Mao và cộng sự [11] đánh giá chất lượng mô tả thông qua một mô hình *listener*: mô hình nhận câu mô tả và lựa chọn đối tượng mà câu đó đề cập tới; mô tả được xem là thành công nếu đối tượng được chọn trùng với đối tượng mục tiêu. Các nghiên cứu sau đó tiếp tục đưa tín hiệu từ listener vào quá trình huấn luyện nhằm khuyến khích mô hình tạo ra những mô tả có khả năng phân biệt đối tượng tốt hơn [12, 13]. Cách tiếp cận này phù hợp với bài toán sinh hướng dẫn giao diện, bởi một câu hướng dẫn chỉ thực sự hữu ích khi nó giúp người dùng nhận ra đúng phần tử cần thao tác.

Trong miền giao diện người dùng, Widget Captioning [9] cũng xem xét việc mô tả các phần tử trên màn hình, bao gồm những trường hợp có nhiều phần tử giống hoặc gần giống nhau. Tuy nhiên, mục tiêu huấn luyện vẫn chủ yếu dựa trên mức độ phù hợp với câu tham chiếu. Điều này tạo ra một khoảng cách giữa hai yêu cầu: sinh ra một câu giống với dữ liệu huấn luyện và sinh ra một câu đủ rõ để người dùng phân biệt đúng phần tử mục tiêu. Khoảng cách đó là một trong những động lực chính để luận văn xem xét cách đánh giá và tối ưu câu hướng dẫn theo khả năng xác định đúng phần tử, thay vì chỉ dựa vào độ tương đồng về từ ngữ.

Việc dùng một mô hình định vị làm công cụ đánh giá cũng đặt ra một vấn đề khác: kết quả đo phụ thuộc vào chính khả năng của mô hình định vị đó. ALOHa [14] cho thấy có thể đánh giá đầu ra sinh bằng cách đối chiếu với nguồn thông tin có cấu trúc, thay vì chỉ so sánh trực tiếp với một câu tham chiếu. Tuy nhiên, khi thành phần dùng để đối chiếu cũng là một mô hình học máy, độ tin cậy của phép đo cần được kiểm chứng riêng. Jandial và cộng sự [18] cũng chỉ ra rằng khả năng định vị có thể thay đổi theo cách một đối tượng được diễn đạt bằng ngôn ngữ. Vì vậy, trước khi sử dụng một mô hình định vị để so sánh các phương pháp sinh, cần kiểm tra xem độ đo có duy trì hành vi hợp lý trước các biến đổi của câu và khi thay đổi mô hình đánh giá hay không.

1.2.2 Động lực ứng dụng

Về mặt ứng dụng, nhu cầu hướng dẫn người dùng thao tác trực tiếp trên giao diện đã xuất hiện trong các hệ thống thực tế. GuideMe [19], chẳng hạn, hỗ trợ người cao tuổi sử dụng điện thoại thông minh bằng cách nhận câu hỏi cùng nội dung màn hình và trả về hướng dẫn cho các thao tác cần thực hiện. Hệ thống này sử dụng một mô hình

thương mại cỡ lớn qua mạng và được đánh giá thông qua nghiên cứu người dùng với 18 người tham gia. Tuy nhiên, công trình chưa cung cấp một độ đo tự động để có thể so sánh định lượng các phương pháp sinh hướng dẫn trong quá trình phát triển hệ thống.

Một độ đo tự động có khả năng tái lập sẽ giúp việc thử nghiệm và so sánh các phương pháp thuận tiện hơn, đặc biệt khi mỗi thay đổi của mô hình không thể đều được đánh giá bằng một nghiên cứu người dùng riêng. Bên cạnh đó, ảnh chụp màn hình điện thoại có thể chứa các thông tin nhạy cảm như tin nhắn, danh bạ hoặc dữ liệu tài chính. Do đó, việc nghiên cứu các mô hình ngôn ngữ thị giác có quy mô vừa phải và có khả năng triển khai cục bộ có ý nghĩa thực tế, vì có thể hạn chế nhu cầu gửi dữ liệu màn hình tới dịch vụ bên ngoài. Đây là một trong những lý do luận văn tập trung vào mô hình ngôn ngữ thị giác cỡ nhỏ thay vì đặt trọng tâm vào các mô hình lớn nhất hiện có.

1.3 Mục đích nghiên cứu

Mục tiêu tổng quát của luận văn là nâng cao chất lượng câu hướng dẫn cho thao tác kế tiếp trên giao diện di động, đặc biệt ở khả năng giúp người dùng nhận ra đúng phần tử cần tương tác. Để thực hiện mục tiêu này, luận văn tập trung vào ba mục tiêu cụ thể:

1. Xây dựng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ, hướng tới các câu mô tả rõ thao tác cần thực hiện và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình.

2. Xây dựng và kiểm chứng độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability, cho các bước chạm. Thay vì chỉ đo mức độ tương đồng giữa câu sinh và một câu tham chiếu, độ đo này xem xét liệu thông tin trong câu hướng dẫn có giúp xác định đúng phần tử cần thao tác hay không.

3. Xây dựng tự động tập dữ liệu giám sát cho tác vụ sinh hướng dẫn từ Android-Control [1], không yêu cầu gán nhãn thủ công bổ sung và không sử dụng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

Ba mục tiêu trên bổ trợ lẫn nhau: dữ liệu giám sát được dùng để huấn luyện mô hình sinh, executability cung cấp thêm một góc nhìn để đánh giá chất lượng hướng dẫn, còn phương pháp sinh là đối tượng chính được cải tiến và so sánh trong phần thực nghiệm.

1.4 Khoảng trống nghiên cứu và vị trí của đề tài

Các nghiên cứu về tác tử giao diện và định vị phần tử, như SeeClick [3], OS-Atlas [4], Aguvis [7] và UGround [5], đã đạt nhiều tiến bộ trong việc liên kết mô tả ngôn ngữ với thao tác và vị trí trên màn hình. Tuy nhiên, mục tiêu chính của các hệ thống này là giúp một tác tử phần mềm tự thực hiện hành động. Đầu ra vì thế thường là loại thao tác hoặc tọa độ tương tác. Luận văn này xem xét một bài toán khác: từ trạng thái tác vụ và giao diện hiện tại, hệ thống cần sinh một câu hướng dẫn để con người đọc và thực hiện. AndroidControl [1] cũng thường được sử dụng theo chiều câu hướng dẫn làm đầu vào để dự đoán thao tác; trong luận văn này, chiều bài toán được đảo lại, với câu hướng dẫn cho thao tác kế tiếp là đầu ra cần sinh.

Ở phía sinh ngôn ngữ, các nghiên cứu về biểu thức quy chiếu cho thấy một mô tả chỉ thực sự hữu ích khi người tiếp nhận có thể dùng nó để nhận ra đúng đối tượng [11, 12, 13]. Widget Captioning [9] đưa bài toán mô tả phần tử vào miền giao diện, nhưng việc huấn luyện và đánh giá vẫn chủ yếu dựa trên câu tham chiếu. Cách đánh giá này có hạn chế đối với hướng dẫn giao diện: hai câu có thể khác nhau đáng kể về từ ngữ nhưng vẫn chỉ đúng cùng một phần tử, trong khi một câu gần với tham chiếu vẫn có thể chưa đủ cụ thể để phân biệt phần tử mục tiêu trên màn hình. Vì vậy, vẫn còn thiếu một cách đánh giá trực tiếp hơn khả năng quy chiếu của câu hướng dẫn tới phần tử cần thao tác.

Một khoảng trống khác nằm ở cách cải thiện mô hình sinh. Học tăng cường đã được sử dụng để tối ưu trực tiếp các độ đo văn bản trong các bài toán sinh, chẳng hạn CIDEr và SPIDEr trong sinh chú thích ảnh [46, 48]; GRPO [43] cũng cung cấp cơ chế học từ so sánh tương đối giữa nhiều đầu ra của cùng một đầu vào. Tuy nhiên, việc lựa chọn kỹ thuật tối ưu không tự giải quyết câu hỏi quan trọng hơn đối với bài toán này: một câu hướng dẫn như thế nào mới cung cấp đủ thông tin để người dùng xác định

đúng phần tử cần thao tác. Do đó, bài toán sinh và bài toán đánh giá cần được xem xét đồng thời thay vì tách rời.

Từ đó, luận văn đặt mình ở giao điểm của ba hướng nghiên cứu: hiểu và định vị phần tử giao diện, sinh mô tả bằng ngôn ngữ tự nhiên, và đánh giá khả năng một mô tả dẫn tới đúng đối tượng. Đề tài xây dựng executability để đánh giá khả năng xác định đúng phần tử ở các bước chạm (Chương 5), đồng thời phát triển phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ (Chương 4). Độ đo được kiểm chứng bằng các phép biến đổi câu có kiểm soát và bằng các mô hình đánh giá khác [16, 15], nhằm hạn chế việc kết luận chỉ dựa trên hành vi của một mô hình định vị duy nhất. Các phương án thiết kế thay thế và kết quả thực nghiệm tương ứng được trình bày ở Phụ lục A và Chương 6.

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

Để thực hiện các mục tiêu đã nêu, luận văn triển khai bốn nhóm nội dung chính. Trước hết, dữ liệu từ AndroidControl được chuyển đổi thành tập giám sát phù hợp với bài toán sinh hướng dẫn. Trên cơ sở đó, luận văn khảo sát các độ đo hiện có, xây dựng executability cho các bước chạm và kiểm chứng độ đo bằng nhiều phép đánh giá chéo. Tiếp theo, một phương pháp sinh hướng dẫn được thiết kế và huấn luyện trên mô hình ngôn ngữ thị giác cỡ nhỏ; một số phương án thiết kế khác cũng được thử nghiệm để làm rõ ảnh hưởng của từng lựa chọn. Cuối cùng, các mô hình được đánh giá trên cùng tập kiểm tra và phân tích theo từng nhóm trường hợp nhằm xác định những điểm đã cải thiện cũng như các dạng lỗi còn tồn tại.

1.5.2 Phạm vi nghiên cứu

Về bài toán, luận văn chỉ xét việc sinh hướng dẫn cho thao tác kế tiếp tại trạng thái giao diện hiện tại. Mỗi mẫu đầu vào bao gồm thông tin về tác vụ, các thao tác đã thực hiện trước đó và màn hình ở thời điểm cần đưa ra hướng dẫn. Việc lập kế hoạch cho

toàn bộ tác vụ hoặc sinh đồng thời một chuỗi nhiều thao tác không thuộc phạm vi của đề tài.

Về đánh giá, executability được xây dựng cho các bước chạm và chỉ phản ánh một khía cạnh của chất lượng hướng dẫn: câu sinh có cung cấp đủ thông tin để xác định đúng phần tử cần thao tác hay không. Độ đo này không trực tiếp phản ánh các yếu tố khác như độ trôi chảy, độ dài, mức dễ hiểu đối với từng nhóm người dùng hay chất lượng trải nghiệm tổng thể.

Về dữ liệu, các thực nghiệm sử dụng AndroidControl với giao diện và câu hướng dẫn bằng tiếng Anh. Luận văn không xây dựng bộ dữ liệu tiếng Việt; các câu tiếng Việt xuất hiện trong phần trình bày chỉ được dùng để minh họa cho bài toán.

Về mô hình, hệ thống sinh được phát triển từ Qwen2.5-VL-3B-Instruct [34] và được tinh chỉnh bằng QLoRA [30] hoặc LoRA trong điều kiện một GPU. Luận văn không đặt mục tiêu huấn luyện mô hình nền từ đầu và cũng không thực hiện so sánh có hệ thống giữa nhiều mô hình nền khác nhau.

1.6 Đóng góp của luận văn

Luận văn có ba đóng góp chính, tương ứng với phương pháp sinh, độ đo đánh giá và phân tích thực nghiệm về quá trình tạo hướng dẫn.

Thứ nhất, luận văn đề xuất một phương pháp sinh hướng dẫn gồm hai thành phần nối tiếp trên nền Qwen2.5-VL-3B. Mô hình ban đầu được tinh chỉnh có giám sát trên 64.567 bước được xây dựng tự động từ AndroidControl. Sau đó, GRPO với phần thưởng SPICE được sử dụng để tiếp tục tối ưu câu sinh. Trên 4.463 bước chạm của tập kiểm tra, mô hình sau giai đoạn này đạt 60,65% executability, so với 59,11% của mô hình tinh chỉnh có giám sát, tương ứng mức tăng 1,55 điểm phần trăm với khoảng tin cậy 95% [+0,80; +2,33]. Thành phần thứ hai, ACE, sử dụng ví dụ truy hồi để hiệu chỉnh câu khi ví dụ và câu hướng dẫn ban đầu nhất quán về loại thao tác. Phương pháp hoàn chỉnh đạt 60,68% executability; đồng thời, trong cấu hình thực nghiệm của luận văn, ACE cải thiện cả bảy độ đo dựa trên câu tham chiếu so với câu đầu vào mà không làm giảm executability. Thiết kế chi tiết và kết quả được trình bày ở Chương 4 và Chương 6.

Thứ hai, luận văn xây dựng và kiểm chứng độ đo khả năng thực hiện theo hướng dẫn (executability) cho các bước chạm. Thay vì đánh giá câu sinh chỉ qua mức độ tương đồng với một câu tham chiếu, executability sử dụng một mô hình định vị tách biệt để kiểm tra liệu câu hướng dẫn có dẫn tới đúng phần tử cần thao tác hay không. Độ đo được kiểm tra qua phân tích sai số định vị, các phép biến đổi câu có kiểm soát, các biến thể diễn đạt và các phép đánh giá chéo bằng mô hình khác. Khi thay UGround bằng UI-Venus-Ground-7B, chiều của các chênh lệch được kiểm tra vẫn được duy trì; listener Phi-4, thuộc họ kiến trúc khác với Qwen, cũng duy trì cùng thứ hạng giữa các hệ thống trong phép đánh giá tương ứng. Kết quả này không xem mô hình định vị là một chuẩn tuyệt đối, nhưng cung cấp thêm bằng chứng về tính ổn định của độ đo trong các kiểm tra đã thực hiện. Chương 5 trình bày đầy đủ định nghĩa và quy trình kiểm chứng.

Thứ ba, luận văn phân tích có hệ thống nhiều phương án trung gian trước khi lựa chọn phương pháp cuối cùng, gồm sinh mô tả phần tử, học theo cặp ưu tiên, thưởng tọa độ, chọn phần tử từ danh sách ứng viên, bổ sung tín hiệu vị trí và hiệu chỉnh câu bằng vùng ảnh cục bộ. Kết quả cho thấy việc cải thiện một biểu diễn trung gian không nhất thiết dẫn tới cải thiện tương ứng ở câu hướng dẫn cuối. Đồng thời, điểm số thấp hơn rõ rệt ở các nhóm bước mà biểu diễn trung gian không xác định đúng phần tử mục tiêu, dù cách chia nhóm này không đủ để khẳng định quan hệ nhân quả. Những quan sát này giúp làm rõ giới hạn của các hướng thiết kế đã thử và là cơ sở thực nghiệm cho việc ưu tiên tối ưu trực tiếp chất lượng câu sinh trong phương pháp cuối cùng. Kết quả tổng hợp được trình bày ở Mục 6.10, còn thiết kế chi tiết của các phương án nằm trong Phụ lục A.

Chương 2

Tổng quan

Chương này trình bày các khái niệm và công trình nền tảng trực tiếp liên quan đến bài toán của luận văn. Trước hết, chương giới thiệu mô hình ngôn ngữ thị giác và các kỹ thuật tinh chỉnh hiệu quả tham số được sử dụng để xây dựng mô hình sinh. Tiếp theo là GRPO và SPICE, hai thành phần tạo nền tảng cho giai đoạn tối ưu bằng học tăng cường. Phần sau trình bày bài toán định vị phần tử giao diện và bộ dữ liệu AndroidControl, là cơ sở cho cách xây dựng dữ liệu và đánh giá trong luận văn. Cuối cùng, chương phân tích hạn chế của việc đánh giá câu hướng dẫn chỉ bằng một câu tham chiếu; các kiểm chứng định lượng tương ứng được trình bày ở Chương 5.

2.1 Mô hình ngôn ngữ thị giác

Bài toán của luận văn yêu cầu mô hình xử lý đồng thời hai nguồn thông tin. Ảnh chụp màn hình cung cấp trạng thái trực quan của giao diện, trong khi phần văn bản mô tả mục tiêu của tác vụ, các thao tác đã thực hiện trước đó và nội dung chữ xuất hiện trên màn hình. Vì vậy, mô hình sinh không chỉ cần hiểu ngôn ngữ mà còn phải liên kết nội dung văn bản với các thành phần trực quan trên giao diện.

Mô hình ngôn ngữ thị giác (*vision-language model*, VLM) được thiết kế cho kiểu đầu vào này. Thông thường, ảnh được chuyển thành các đặc trưng hoặc token thị giác, sau đó được tích hợp với chuỗi token văn bản để mô hình có thể suy luận và sinh đầu ra dựa trên cả hai nguồn thông tin. Phần sinh ngôn ngữ thường dựa trên kiến trúc Transformer [32], trong đó cơ chế tự chú ý cho phép mô hình học quan hệ giữa các phần tử trong chuỗi đầu vào.

Luận văn sử dụng Qwen2.5-VL-3B-Instruct [34] làm mô hình nền. Lựa chọn này xuất phát từ ba lý do. Thứ nhất, mô hình có trọng số mở nên có thể tinh chỉnh trực tiếp cho bài toán nghiên cứu. Thứ hai, quy mô khoảng ba tỉ tham số phù hợp hơn với mục tiêu thử nghiệm và triển khai cục bộ so với các mô hình lớn hơn nhiều. Thứ ba, họ Qwen-VL hỗ trợ xử lý ảnh với độ phân giải động, phù hợp với ảnh chụp màn hình điện thoại vốn có tỉ lệ và kích thước thay đổi. Cấu hình sử dụng cụ thể của Qwen2.5-VL-3B-Instruct được trình bày ở Chương 4.

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA

Tinh chỉnh toàn bộ một mô hình ngôn ngữ thị giác đòi hỏi lượng bộ nhớ lớn vì quá trình huấn luyện không chỉ lưu trọng số mô hình mà còn cần gradient và trạng thái của bộ tối ưu. LoRA [29] giảm chi phí này bằng cách giữ cố định trọng số gốc và chỉ học một cập nhật có hạng thấp. Với ma trận trọng số $W \in \mathbb{R}^{d\times k}$, trọng số sau khi áp dụng LoRA được viết dưới dạng

$$W' = W + \frac{\alpha}{r}BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k), \tag{2.1}$$

trong đó r là hạng của cập nhật và α là hệ số tỉ lệ. Thay vì cập nhật toàn bộ dk tham số của ma trận W, LoRA chỉ cần học $r(d+k)$ tham số trong hai ma trận A và B.

QLoRA [30] tiếp tục giảm nhu cầu bộ nhớ bằng cách kết hợp LoRA với lượng tử hóa trọng số nền xuống 4 bit. Trong đó, định dạng NormalFloat (NF4) được thiết kế cho phân bố trọng số của mạng nơ-ron. Trong quá trình huấn luyện, trọng số nền vẫn được giữ cố định ở dạng lượng tử hóa, còn gradient chỉ cập nhật các tham số LoRA ở độ chính xác cao hơn. Cách làm này cho phép tinh chỉnh các mô hình có kích thước lớn hơn trong điều kiện tài nguyên hạn chế. Trong luận văn, QLoRA được sử dụng ở các giai đoạn tinh chỉnh mô hình sinh; cấu hình cụ thể được trình bày ở Chương 4.

2.3 GRPO và phần thưởng dựa trên độ đo văn bản

Trong tinh chỉnh có giám sát, mô hình học bằng cách tăng xác suất của câu tham chiếu tương ứng với mỗi đầu vào. Cách huấn luyện này phù hợp để hình thành khả năng sinh ban đầu, nhưng không trực tiếp biểu diễn mức độ tốt hơn hay kém hơn giữa nhiều câu mà mô hình có thể sinh cho cùng một trường hợp. Học tăng cường cho phép bổ sung tín hiệu này bằng cách gán phần thưởng cho từng đầu ra và cập nhật mô hình theo chất lượng tương đối của các đầu ra được sinh.

Tối ưu chính sách tương đối theo nhóm (*Group Relative Policy Optimization*, GRPO) được giới thiệu trong DeepSeekMath [43]. Với mỗi đầu vào x, mô hình sinh một nhóm gồm G đầu ra $y_1, \dots, y_G$ và nhận các phần thưởng tương ứng $r_1, \dots, r_G$. Lợi thế của đầu ra thứ i được xác định bằng cách chuẩn hóa phần thưởng trong cùng nhóm:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G})}, \tag{2.2}$$

sau đó chính sách được cập nhật dựa trên lợi thế tương đối này, đồng thời có số hạng kiểm soát mức sai lệch so với mô hình tham chiếu. Điểm đáng chú ý của GRPO là không cần huấn luyện thêm một mô hình ước lượng giá trị riêng. Mặt khác, nếu các đầu ra trong cùng nhóm nhận phần thưởng giống nhau thì nhóm đó không cung cấp tín hiệu phân biệt hữu ích cho bước cập nhật.

Trong luận văn, phần thưởng cho GRPO được xây dựng từ SPICE [24]. SPICE là một độ đo dựa trên câu tham chiếu, trong đó nội dung câu được biểu diễn thông qua các đối tượng, thuộc tính và quan hệ, sau đó so sánh các thành phần tương ứng bằng điểm F1. Zhao và cộng sự [37] đã sử dụng SPICE khi đánh giá mô hình sinh chỉ dẫn. Đặc điểm này khiến SPICE phù hợp để cung cấp một tín hiệu phần thưởng ở mức nội dung cho câu hướng dẫn. Cách xây dựng phần thưởng và quy trình huấn luyện GRPO trong luận văn được trình bày cụ thể ở Mục 4.5.

2.4 Định vị phần tử giao diện

Định vị phần tử giao diện (*GUI grounding*) là bài toán xác định vị trí của một phần tử trên màn hình từ ảnh giao diện và một mô tả bằng ngôn ngữ. Đầu ra thường được biểu diễn dưới dạng một điểm hoặc một khung bao quanh phần tử mục tiêu. Một số mô hình tiêu biểu cho hướng nghiên cứu này gồm SeeClick [3], OS-Atlas [4] và UGround [5].

Bài toán định vị tạo ra một cách kiểm tra trực tiếp mối liên hệ giữa câu mô tả và phần tử mà câu đó hướng tới. Nếu câu hướng dẫn cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử khác trên màn hình, một mô hình định vị có thể được dùng để suy ra phần tử mà câu đang mô tả. Đây là cơ sở cho độ đo executability được xây dựng trong luận văn. Chương 5 trình bày mô hình định vị được lựa chọn, cách xác định một dự đoán đúng và các phép kiểm chứng cần thiết trước khi sử dụng mô hình này như một thành phần của độ đo.

2.5 Bộ dữ liệu AndroidControl

AndroidControl [1] là bộ dữ liệu do Google DeepMind công bố tại NeurIPS 2024 theo giấy phép CC0. Bộ dữ liệu gồm 15.283 chuỗi thao tác do người thật thực hiện trên thiết bị Pixel trong khoảng một năm. Ở mỗi bước, dữ liệu lưu trạng thái màn hình, loại thao tác, tọa độ chạm khi có và trường `step_instructions`, tức câu hướng dẫn do người thực hiện viết cho thao tác tương ứng.

Điểm quan trọng đối với luận văn nằm ở cách sử dụng trường hướng dẫn này. Trong công trình AndroidControl và trong các nghiên cứu về tác tử giao diện sử dụng bộ dữ liệu này, như Aguvis [7] và SeeClick [3], câu hướng dẫn thường được đưa vào làm đầu vào để mô hình dự đoán thao tác cần thực hiện. Luận văn sử dụng dữ liệu theo chiều ngược lại: trạng thái tác vụ và giao diện được dùng làm đầu vào, còn câu hướng dẫn cho thao tác kế tiếp là đầu ra cần sinh. Nhờ đó, AndroidControl có thể được chuyển thành tập dữ liệu giám sát cho bài toán sinh hướng dẫn mà không cần thu thập lại toàn bộ dữ liệu từ đầu. Quy trình hợp nhất, làm sạch và phân chia dữ liệu được trình bày ở Chương 3.

2.6 Hạn chế của các độ đo dựa trên câu tham chiếu

Một thao tác trên giao diện có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn dẫn người dùng tới cùng một phần tử. Vì vậy, một câu tham chiếu chỉ phản ánh một trong nhiều cách mô tả có thể chấp nhận được. Các độ đo phụ thuộc nhiều vào mức trùng khớp từ vựng có thể đánh giá thấp một câu diễn đạt khác với tham chiếu dù nội dung hướng dẫn vẫn đúng. Chẳng hạn, cùng một phần tử có thể được mô tả là "search bar" trong một câu và "magnifying glass" trong một câu khác.

Các độ đo tương đồng ngữ nghĩa giảm bớt sự phụ thuộc vào từ ngữ cụ thể, nhưng vẫn không trực tiếp trả lời câu hỏi quan trọng đối với bài toán này: câu hướng dẫn có giúp xác định đúng phần tử cần thao tác hay không. Hai câu có thể gần nhau về nghĩa nhưng lại chỉ tới hai phần tử khác nhau trên cùng màn hình, chẳng hạn "inbox" và "outbox". Ngược lại, hai cách diễn đạt khác nhau đáng kể vẫn có thể cùng quy chiếu tới một phần tử. Do đó, mức độ gần nhau trong không gian ngữ nghĩa không đồng nghĩa với khả năng dẫn tới cùng một đối tượng trên giao diện.

Từ hạn chế này, việc đánh giá câu hướng dẫn cần xem xét trực tiếp mối quan hệ giữa câu sinh và phần tử mà câu đó mô tả, thay vì chỉ đo mức độ giống với một câu tham chiếu. Đây là động cơ trực tiếp cho executability ở Chương 5. Chương đó kiểm chứng định lượng hành vi của các độ đo trong những trường hợp nêu trên và trình bày cách sử dụng mô hình định vị để đánh giá khả năng xác định đúng phần tử mục tiêu.

Chương 3

Xây dựng bộ dữ liệu

Không có một bản phân phối AndroidControl nào được sử dụng trong đề tài chứa đầy đủ mọi thành phần cần thiết cho bài toán sinh hướng dẫn ở từng bước. Vì vậy, chương này trình bày cách hợp nhất các nguồn dữ liệu, xây dựng đầu vào từ giao diện và tổ chức dữ liệu cho huấn luyện, lựa chọn mô hình và đánh giá. Toàn bộ quy trình được tự động hóa, không cần gán nhãn thủ công bổ sung và không dùng nhãn do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

Bảng 3.1 ánh xạ ba khái niệm trong tên đề tài sang các thành phần dữ liệu cụ thể được sử dụng trong luận văn.

Bảng 3.1: Ba khái niệm trong tên đề tài và dạng cụ thể của từng khái niệm khi triển khai.

Khái niệm	**Dạng cụ thể trong đề tài**
Trường hợp sử dụng	Mục tiêu của cả tác vụ, ví dụ như đặt vé xem phim cho tối nay, cùng chuỗi các bước đã thực hiện trước bước đang xét
Giao diện người dùng	Ảnh chụp màn hình đang mở, văn bản hiển thị trên màn, và trong giai đoạn xây dựng dữ liệu còn có cây trợ năng của chính màn hình ấy
Hướng dẫn sử dụng	Câu hướng dẫn cho bước kế tiếp; các câu của cùng một tác vụ nối lại theo thứ tự bước thành hướng dẫn đầy đủ cho tác vụ đó

Dữ liệu được tổ chức ở mức từng bước thay vì yêu cầu mô hình sinh toàn bộ hướng dẫn trong một lần. Cách tổ chức này phù hợp với cấu trúc nhãn của AndroidControl, trong đó mỗi bước có một câu tham chiếu riêng, đồng thời tương thích với executability ở Chương 5, vốn đánh giá khả năng từng câu dẫn tới đúng phần tử cần thao tác. Hướng dẫn đầy đủ cho một tác vụ có thể được hình thành bằng cách ghép các câu theo thứ tự bước.

Các mục đầu của chương mô tả dữ liệu dùng trong phương pháp đề xuất và những đặc điểm cần lưu ý khi diễn giải kết quả. Hai mục cuối trình bày riêng các cấu trúc dữ liệu chỉ phục vụ những phương án thiết kế được phân tích trong Phụ lục A.

3.1 Nguồn dữ liệu và quy trình hợp nhất dữ liệu đa nguồn

Để xây dựng một mẫu đầy đủ cho mỗi bước, cần ba thành phần: câu hướng dẫn do người chú thích viết, ảnh chụp màn hình và cây trợ năng. Tuy nhiên, không có bản phân phối công khai nào của AndroidControl cung cấp đồng thời cả ba thành phần này. Vì vậy, luận văn hợp nhất hai bản phân phối như trình bày ở Bảng 3.2.

Bảng 3.2: Hai bản phân phối trên Hugging Face và phần thiếu của mỗi bản.

Bản phát hành	**Có**	**Thiếu**
`HarrytheOrange/parsed_AndroidControl`	câu hướng dẫn đủ 15.283 chuỗi	không có ảnh
`ckg/AndroidControlParsedWithImages-20k`	ảnh màn hình	mất câu hướng dẫn

Hai bản được ghép theo cặp mã tác vụ và số thứ tự bước, `(episode_id, step_id)`. Cây trợ năng của 99.131 màn được lấy từ bản phát hành gốc.

Một đặc điểm của nguồn dữ liệu là 99,0% chuỗi mô tả mục tiêu chung của tác vụ kết thúc giữa một cụm từ. Ảnh hưởng của đặc điểm này tới phạm vi diễn giải kết quả được trình bày cùng các tính chất khác của dữ liệu ở Mục 3.6.

3.2 Kiểm chứng độ chính xác của quy trình hợp nhất

Rủi ro chính của quy trình hợp nhất dữ liệu là ghép lệch bước giữa ảnh và câu hướng dẫn. Lỗi này khó phát hiện chỉ bằng số lượng bản ghi hoặc quá trình hội tụ của mô hình, nên cần một phép kiểm tra trực tiếp dựa trên nội dung.

Phép kiểm tra sử dụng văn bản OCR tại vị trí chạm. Với dữ liệu ghép đúng, chuỗi văn bản tại vị trí này được kỳ vọng xuất hiện trong câu hướng dẫn thường xuyên hơn so với một đối chứng được cố ý dịch lệch một bước. Trên mẫu 400 bước, tỉ lệ khớp của dữ liệu ghép đúng là 48%, so với 20% ở đối chứng lệch bước.

	Ghép đúng	**Ghép lệch một bước (đối chứng)**
	48%	20%
Tỉ số	2,4×	

Tỉ lệ khớp của dữ liệu ghép đúng cao gấp 2,4 lần đối chứng bị dịch lệch một bước. Kết quả này cho thấy khóa ghép giữ được mối liên hệ giữa ảnh và câu hướng dẫn tốt hơn rõ rệt so với trường hợp ghép sai bước. Phép kiểm tra tương tự được áp dụng cho các lần xây dựng dữ liệu sau đó.

3.3 Quy mô và phân chia dữ liệu

Bảng 3.3: Quy mô hai tập dữ liệu sau khi xây dựng.

	Tập huấn luyện	**Tập kiểm tra**
Số bước	64.567	6.958
Bước chạm (tập bước được đánh giá)	41.191 (63,8%)	4.463 (64,1%)
Số tác vụ	12.895	1.432
Độ phủ OCR	100%	100%
Độ phủ nhãn mô tả trên bước chạm	-	99,7%

Tập đánh giá đầy đủ gồm 6.958 bước. Trong số đó, 4.463 bước chạm được sử dụng để tính executability chính ở Chương 5 và Chương 6; các bước còn lại được phân tích riêng khi cần.

Dữ liệu được phân chia theo tác vụ, tức toàn bộ các bước thuộc cùng một tác vụ nằm trong cùng một tập. Cách chia này tránh việc các màn hình rất giống nhau của cùng một chuỗi thao tác xuất hiện đồng thời ở huấn luyện và đánh giá. Kiểm tra toàn bộ mã tác vụ không phát hiện tác vụ trùng giữa hai tập.

Tập kiểm định nội bộ. Sau khi S1 đã được huấn luyện trên toàn bộ 64.567 bước, 1.567 bước được tách theo tác vụ để làm tập kiểm định nội bộ; 63.000 bước còn lại được dùng cho các giai đoạn huấn luyện tiếp theo. Tập kiểm định nội bộ chỉ phục vụ việc xếp hạng checkpoint và lựa chọn biến thể, gồm checkpoint của mô hình học tăng cường với phần thưởng SPICE và quy tắc lựa chọn của ACE (Mục 4.5 và Mục 4.6). Cần lưu ý rằng phép tách này diễn ra sau khi S1 đã học trên toàn bộ 64.567 bước. Vì thế, 1.567 mẫu kiểm định không phải là dữ liệu hoàn toàn chưa từng xuất hiện trong quá trình huấn luyện của S1 hoặc các mô hình khởi tạo từ S1, và điểm tuyệt đối trên tập này không được sử dụng như kết quả chính của luận văn.

Quan hệ với cách chia chính thức của AndroidControl. Tập huấn luyện và tập kiểm tra trong đề tài kế thừa phép chia theo tác vụ của bản phân phối có ảnh từ `ckg`, không trùng với cách chia chính thức của AndroidControl. Trong 1.432 tác vụ của tập kiểm tra, 1.287 tác vụ thuộc phần huấn luyện chính thức, 131 thuộc phần kiểm tra và 14 thuộc phần kiểm định. Hai tập của đề tài vẫn rời nhau theo tác vụ, nên có thể dùng để so sánh các mô hình được huấn luyện và đánh giá theo cùng giao thức của đề tài. Tuy nhiên, các kết quả trên tập này không được diễn giải như kết quả trên phần kiểm tra chính thức của AndroidControl. Trong các chương sau, tập này được gọi là *tập kiểm tra giữ riêng theo tác vụ*.

3.4 Xây dựng thông tin đầu vào từ giao diện

Ảnh màn hình là đầu vào thị giác của mô hình, còn văn bản OCR cung cấp thông tin chữ hiển thị trên giao diện. Kết quả OCR được đưa vào prompt và đồng thời được sử dụng khi xây dựng các nhãn phụ trợ ở Mục 3.7. Cây trợ năng chỉ được dùng trong quá trình xây dựng dữ liệu và nhãn; nó không được đưa vào đầu vào của quy trình suy luận cuối cùng ở Chương 4.

Trung bình mỗi màn hình có 24,2 chuỗi văn bản nhận dạng được ở tập kiểm tra và 23,6 ở tập huấn luyện. Giá trị trung vị ở hai tập bằng nhau, cho thấy lượng văn bản trích xuất được có phân bố tương tự giữa hai tập.

Trên bộ dữ liệu này, chúng tôi quan sát được hai dạng lỗi phổ biến của OCR: biểu tượng bị nhận dạng nhầm thành ký tự, và mất khoảng trắng (ví dụ `Turnon` thay cho

"Turn on"). Dạng lỗi thứ hai khiến phần tử bị xếp vào nhóm "không có tên" thay vì được gán một tên sai; vì vậy lỗi chủ yếu làm mất thông tin tên thay vì tạo nhãn tên sai.

3.5 Dữ liệu phục vụ phương pháp đề xuất

Phương pháp đề xuất ở Chương 4 sử dụng ba nguồn dữ liệu có vai trò khác nhau. Mục này chỉ mô tả nguồn gốc và ranh giới của các nguồn đó; cách huấn luyện và quy tắc suy luận được trình bày ở Chương 4.

Tập huấn luyện có giám sát cho S1. S1 được huấn luyện trên toàn bộ 64.567 bước của tập huấn luyện có giám sát. Với mỗi bước, đầu ra đích là câu hướng dẫn do người chú thích AndroidControl viết. S1 là điểm xuất phát của cả hai thành phần trong phương pháp đề xuất.

Dữ liệu cho giai đoạn học tăng cường với phần thưởng SPICE. Sau khi 1.567 bước được chỉ định làm tập kiểm định nội bộ, 63.000 bước còn lại tạo thành phần huấn luyện cho các giai đoạn sau. Giai đoạn học tăng cường lấy prompt và câu tham chiếu tương ứng từ phần dữ liệu này; câu tham chiếu được dùng để tính phần thưởng SPICE. Tập kiểm định nội bộ chỉ phục vụ xếp hạng checkpoint theo giao thức ở Mục 3.3. Việc chỉ định 1.567 bước diễn ra sau khi S1 đã được huấn luyện trên toàn bộ 64.567 bước, nên không làm các mẫu này trở thành dữ liệu chưa từng được S1 nhìn thấy.

Kho truy hồi cho ACE. Kho truy hồi của ACE được xây dựng từ dữ liệu phía huấn luyện sau khi loại các tác vụ thuộc tập kiểm định nội bộ, gồm 62.880 bước thuộc 12.542 tác vụ. Kho này không chứa tác vụ nào của tập kiểm tra giữ riêng theo tác vụ. Câu tham chiếu của các bước trong kho đóng vai trò câu ví dụ có thể được truy hồi; Mục 4.6 trình bày cách truy hồi và quy tắc quyết định có sử dụng câu ví dụ hay không. Vì vậy, ACE không truy cập câu tham chiếu của chính bước kiểm tra đang được đánh giá.

3.6 Đặc điểm dữ liệu ảnh hưởng đến diễn giải kết quả

Bên cạnh cách chia theo tác vụ, bốn đặc điểm của dữ liệu cần được tính đến khi diễn giải các kết quả ở Chương 6.

Mục tiêu tác vụ bị cắt ở nguồn. Có 99,0% chuỗi mô tả mục tiêu chung của tác vụ kết thúc giữa một cụm từ. Đặc điểm này làm giảm lượng thông tin về mục tiêu mà mọi mô hình trong đề tài có thể sử dụng, nhưng chưa có phép đo riêng để quy đổi phần thông tin bị mất thành mức thay đổi điểm số.

Trùng lặp cách diễn đạt. Trên mẫu so sánh đã sử dụng trong quá trình phân tích dữ liệu, 17,3% câu tham chiếu của tập kiểm tra xuất hiện nguyên văn trong tập huấn luyện và 66,5% chia sẻ ít nhất một cụm bốn từ liên tiếp. Đây là mức lặp đáng kể về cách diễn đạt, không phải trùng tác vụ giữa hai tập. Đặc điểm này có liên quan trực tiếp đến ACE vì thành phần này truy hồi câu ví dụ từ dữ liệu huấn luyện, nhưng các thống kê trên không cho phép quy toàn bộ mức thay đổi của ACE cho hiện tượng lặp câu.

Trùng lặp ứng dụng. Trong các bước của tập kiểm tra xác định được ứng dụng, 95,6% thuộc về ứng dụng đã xuất hiện trong tập huấn luyện; nếu tính theo ứng dụng riêng biệt, tỉ lệ là 91,8%. Vì vậy, thiết lập đánh giá chủ yếu phản ánh khả năng xử lý tác vụ mới trong những ứng dụng phần lớn đã có mặt ở dữ liệu huấn luyện, thay vì chỉ phản ánh khả năng khái quát sang ứng dụng hoàn toàn mới.

Ứng dụng không xác định và ứng dụng chưa thấy. Tên ứng dụng chỉ xác định được cho 45,0% tổng số 6.958 bước trong tập kiểm tra. Các bước còn lại mang nhãn "không biết"; nhãn này chỉ biểu thị việc thiếu thông tin định danh và khác với nhóm "chưa thấy", tức các ứng dụng xác định được nhưng không xuất hiện trong tập huấn luyện. Vì vậy, các phân tích theo ứng dụng đã thấy/chưa thấy ở Chương 6 chỉ được diễn giải trên phần dữ liệu có thể xác định ứng dụng; tỉ lệ 45,0% không phải là độ phủ của riêng tập 4.463 bước chạm.

3.7 Dữ liệu cho các phương án biểu diễn phần tử và học theo cặp

Các cấu trúc dữ liệu trong mục này chỉ phục vụ những phương án được phân tích trong Phụ lục A; chúng không tham gia vào cấu hình cuối của phương pháp đề xuất.

Nhãn mô tả phần tử. Dòng mô tả phần tử được tạo tự động từ tọa độ chạm, cây trợ năng và OCR. Chương trình chọn hộp trợ năng nhỏ nhất chứa điểm chạm, lấy vai trò từ cây trợ năng và lấy tên từ cây hoặc OCR sau khi qua các bộ lọc. Tọa độ được chuẩn hóa về thang [0, 1000], còn trường cuối chứa một dấu hiệu phân biệt được sinh theo quy tắc định sẵn.

Bảng 3.4: Bốn ô của dòng mô tả phần tử và lý do cần có từng ô.

Ô	Ví dụ	Lý do cần
Vai trò	`tappable text`	phân biệt nút, ô nhập, mục danh sách
Tên	`Search here`	chữ hiển thị; nguồn là OCR hoặc cây trợ năng
Tọa độ	`<point> 440,91 </point>`	lấy trực tiếp từ điểm chạm, không cần gán nhãn bổ sung
Dấu hiệu phân biệt	`just above the text "Coffee"`	mệnh đề tách phần tử này khỏi các phần tử giống nó, nhằm vào dạng lỗi "câu mơ hồ"

Làm sạch tên và dấu hiệu phân biệt. Bộ lọc nhãn trợ năng loại 14,7% nhãn tại các phần tử cần chạm, gồm định danh lấy từ mã nguồn, chuỗi số dài, hậu tố dành cho trình đọc màn hình và các chuỗi chỉ báo phần tử không có nhãn như `No label specified`. Bộ lọc hình học chỉ lấy tên từ OCR khi hộp phần tử chiếm dưới 25% diện tích màn hình; trong 25 trường hợp hộp chiếm gần hết màn hình được kiểm tra thủ công, không có trường hợp nào khớp với câu tham chiếu. Khi tạo dấu hiệu phân biệt, quy trình ưu tiên kết hợp một chuỗi OCR gần phần tử với thông tin vị trí tương đối để làm tham chiếu. Trên mẫu thử, 75,9% dấu hiệu được tạo ra đủ để phân biệt phần tử cần chạm với các phần tử tương tự; 24,1% còn lại không đạt yêu cầu này.

Chất lượng nhãn ở quy mô đầy đủ. Bảng 3.5 so sánh 41.191 nhãn ở bước chạm

với mẫu thử gồm 1.074 nhãn. Với ba chỉ số có số liệu đối chiếu, chênh lệch giữa hai cột không vượt quá 1,4 điểm.

Bảng 3.5: Chất lượng nhãn mô tả ở quy mô đầy đủ so với mẫu thử (n = 1.074). Ở ba chỉ số có số đối chiếu, hai cột lệch nhau không quá 1,4 điểm.

Chỉ số	Quy mô đầy đủ	Mẫu thử
Tên rõ ràng	73,6%	73,8%
Chỉ có ký hiệu, không có chữ	4,4%	-
Không có tên	22,0%	23,4%
Vai trò rõ ràng	75,8%	-
Trùng tên trên cùng màn	7,6%	7,0%
Có phần tử cùng vai trò để so	91,6%	-

Trong 32.061 tên lấy được, 8.581 tên đến từ cây trợ năng và 23.480 tên đến từ OCR. Các thống kê này mô tả nguồn tên của nhãn phụ trợ, không thay đổi đầu vào của quy trình suy luận cuối cùng ở Mục 3.4.

Các biến thể chuỗi đích. Từ cùng đầu vào, ba biến thể phụ trợ được xây dựng cho phương án mô tả phần tử. S2 sinh dòng mô tả thật trước câu hướng dẫn; S2r thay dòng mô tả bằng một dòng lấy từ màn khác có độ dài gần tương đương; S2-nopoint bỏ tọa độ và giữ ba trường còn lại. Câu hướng dẫn dùng để đánh giá được giữ giống hệt nhau từng byte giữa các biến thể khi thiết kế yêu cầu; ở các bước không chạm, chuỗi đích cũng được giữ giống nhau. Các bước không chạm chiếm 36,2% tập huấn luyện. Dữ liệu S2r và S2-nopoint đã được xây dựng nhưng không được tiếp tục huấn luyện; trạng thái cuối được ghi ở Bảng 6.13.

Tập cặp ưu tiên. Phương án học theo cặp ở Mục A.2.1 sử dụng 22.854 cặp gồm một chuỗi được ưu tiên và một chuỗi đối chứng. Hai vế giữ nguyên câu hướng dẫn và chỉ khác dòng mô tả. Ở vế đối chứng, dòng mô tả trỏ tới một phần tử có thật, cùng vai trò, cách phần tử cần chạm từ 80 đến 350 điểm ảnh và khác ở cả tên lẫn tọa độ. Sau khi xây dựng, các cặp được kiểm tra để câu hướng dẫn của hai vế trùng nhau từng byte và dòng mô tả đối chứng không trỏ vào phần tử cần chạm.

Tập cặp này chỉ chứa bước chạm. Ngoài ra, ở 17,4% số cặp, chuỗi `(no name)` chỉ xuất hiện ở một trong hai vế, nên mô hình có thể dựa vào dấu hiệu này thay vì nội

dung màn hình để phân biệt hai vế. Hạn chế được phát hiện sau khi mô hình đã học xong, nên các kết quả ở Phụ lục A sử dụng dữ liệu chưa chỉnh sửa.

3.8 Dữ liệu cho mô hình chọn ứng viên

Mục này mô tả cấu trúc dữ liệu của một phương án khác trong Phụ lục A, không phải thành phần của phương pháp đề xuất. Mô hình chọn ứng viên (Mục A.3.1) thay danh sách OCR không có vị trí bằng tối đa 40 ứng viên, mỗi ứng viên gồm tên phần tử và tọa độ trên lưới [0, 1000]. Danh sách sử dụng cùng quy tắc đặt tên với nhãn mô tả phần tử và được sắp theo thứ tự đọc tự nhiên trên màn hình.

Tên xuất hiện trong dòng mô tả của một bước được xem là tên mục tiêu của bước đó. Một ứng viên được xem là đúng khi có cùng tên mục tiêu và cách điểm chạm không quá 140 đơn vị lưới (tương đương 14% kích thước màn hình) trên mỗi trục; nếu có nhiều ứng viên cùng thoả điều kiện, ứng viên gần điểm chạm nhất được chọn. Trên tập kiểm tra, tên đúng có mặt trong danh sách ở 96,7% số bước có tên đúng, và ở 91,2% số bước ấy danh sách có một dòng vừa trùng tên đúng vừa nằm trong dung sai trên. Trên mẫu 300 bước, vị trí xếp hạng của ứng viên đúng, sau khi chuẩn hóa về [0,1], có giá trị trung bình 0,481; ứng viên đúng đứng đầu ở 5,0% số mẫu. Các thống kê này cho thấy bản thân vị trí trong danh sách không phải là một dấu hiệu hiển nhiên của đáp án. Mẫu dài nhất vẫn dưới giới hạn độ dài ngữ cảnh 3.072 token, nên không mẫu nào bị cắt.

Từ cùng một prompt, hai cấu hình dữ liệu được xây dựng với chuỗi đích khác nhau. Ở cấu hình chọn ứng viên, mô hình phải sinh thêm thẻ lựa chọn phần tử trước câu hướng dẫn; cấu hình đối chứng sử dụng cùng đầu vào nhưng chỉ yêu cầu sinh câu hướng dẫn.

Mô hình chọn ứng viên	`<sel>`tên `<point>`*x*, *y*`</point></sel>` + `\n` + câu hoặc `<sel>none</sel>` + `\n` + câu
Cấu hình đối chứng	câu

Nội dung thẻ chọn là phần sao chép nguyên văn thông tin của ứng viên đúng từ

danh sách. Thẻ `none` được dùng cho bước không chạm, bước chạm không có tên đúng, hoặc bước chạm có tên đúng nhưng danh sách không chứa dòng khớp. Câu ở cả hai tập đều là câu tham chiếu nguyên bản; prompt và ảnh của hai cấu hình cũng được giữ giống nhau theo các điều kiện cấu trúc đã kiểm tra.

Do mọi bước không chạm đều sử dụng thẻ `none`, 54,78% mẫu huấn luyện mang nhãn này; nếu chỉ xét 41.191 bước chạm, tỉ lệ còn 29,12%. Hai thống kê được sử dụng để phân tích hành vi từ chối chọn ở Mục A.3.2.

Như vậy, Mục 3.7 và Mục 3.8 chỉ ghi lại dữ liệu của các phương án thay thế đã khảo sát; các cấu trúc này không tham gia vào cấu hình phương pháp đề xuất được báo cáo như kết quả chính.

Chương 4

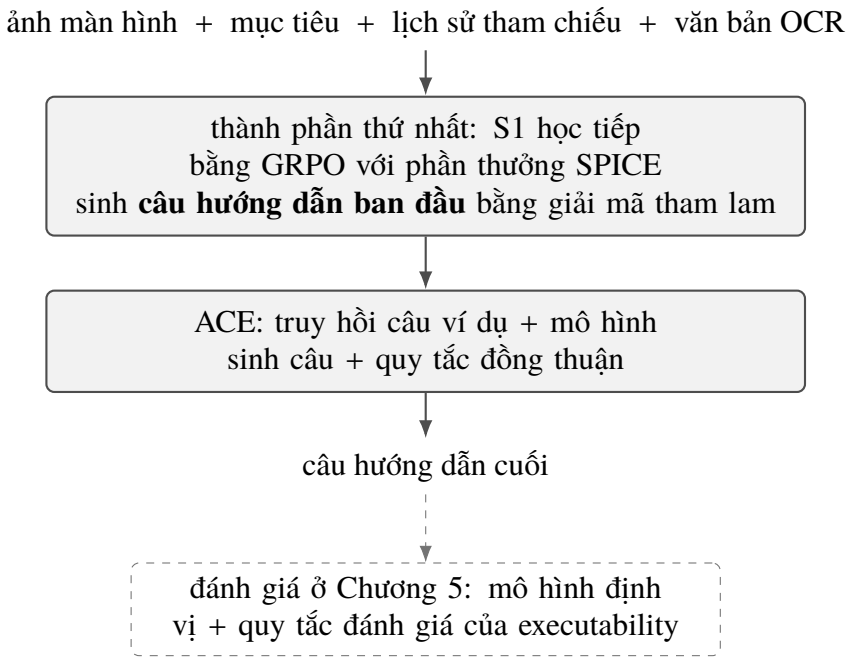
Phương pháp đề xuất

Chương này trình bày phương pháp đề xuất của luận văn. Phương pháp gồm hai thành phần được áp dụng nối tiếp (Mục 4.4). Thành phần thứ nhất tiếp tục tối ưu mô hình bằng học tăng cường với phần thưởng SPICE để tạo câu hướng dẫn ban đầu (Mục 4.5). Thành phần thứ hai, ACE, sử dụng các câu ví dụ được truy hồi để hiệu chỉnh câu hướng dẫn ban đầu dưới ràng buộc nhất quán về loại thao tác (Mục 4.6). Trước khi đi vào từng thành phần, chương mô tả quy trình tổng thể, cấu trúc đầu vào và cấu hình huấn luyện. Phần cuối trình bày các mốc so sánh và nguyên tắc diễn giải kết quả. Những hướng đã được khảo sát trước khi hình thành phương pháp cuối cùng được trình bày ở Phụ lục A; độ đo đánh giá được trình bày riêng ở Chương 5.

4.1 Quy trình tổng thể

Bài toán là: cho một màn hình điện thoại và mục tiêu của người dùng, viết một câu tiếng Anh nói người dùng cần làm gì ở bước tiếp theo, chẳng hạn "Click on the search icon". Hệ thống gồm bốn khâu (Hình 4.1).

1. **Đầu vào:** ảnh màn hình, mục tiêu, các bước đã làm và chữ đọc được trên màn.
2. **Mô hình sinh câu:** viết câu hướng dẫn. Đây là phần duy nhất được huấn luyện, và phương pháp đề xuất nằm ở khâu này.
3. **Mô hình định vị phần tử:** một mô hình có sẵn, đọc câu vừa sinh và chỉ ra điểm trên màn hình mà câu ấy nói tới.



Hình 4.1: Quy trình sinh câu của phương pháp đề xuất. Hai khối tô xám tạo và hiệu chỉnh câu hướng dẫn; nhánh nét đứt là quy trình đánh giá riêng ở Chương 5, không phải thành phần của luồng suy luận.

4. **Luật tính điểm:** câu được tính là đúng khi điểm ấy rơi vào đúng phần tử cần chạm và câu nói đúng loại thao tác.

Mô hình định vị và luật tính điểm chỉ phục vụ việc đánh giá; khi triển khai, hệ thống nhận đầu vào và trả về câu hướng dẫn do mô hình sinh câu viết ra.

Hình 4.1 tách rõ luồng sinh câu khỏi luồng đánh giá. Ở giai đoạn suy luận, phương pháp sử dụng ảnh màn hình, mục tiêu, lịch sử tham chiếu, văn bản OCR, mô hình sinh và kho câu tham chiếu của tập huấn luyện dùng cho truy hồi ACE. Cây trợ năng và mô hình định vị chỉ được dùng trong quá trình xây dựng dữ liệu hoặc đánh giá, không tham gia vào việc tạo câu hướng dẫn cuối.

4.2 Đầu vào và cấu trúc prompt

Prompt chuẩn gồm bốn phần và được sử dụng cho S1 cũng như thành phần học tăng cường với phần thưởng SPICE. Ở giai đoạn suy luận, cấu trúc prompt được giữ cố

định giữa các mô hình để phép so sánh chỉ phản ánh khác biệt do phương pháp tạo ra. Riêng mô hình sinh câu của ACE nhận thêm một khối câu ví dụ ngay trước yêu cầu sinh câu (Mục 4.6). Ví dụ dưới đây minh họa cấu trúc prompt chuẩn.

```
<image>
Mục tiêu: Open Google maps app, Search for the nearest
  park to 98103 …
Đã làm: Click on the title of this note Grocery to
edit
  the title
Văn bản trên màn: Search here · Coffee ·
  Restaurants · Groceries · …
Viết câu hướng dẫn cho bước tiếp theo.
```

Các nhãn trường được viết bằng tiếng Việt, còn câu trả lời được yêu cầu viết bằng tiếng Anh, vì đây là ngôn ngữ của bộ ngữ liệu nguồn và của toàn bộ các câu được đánh giá.

Đầu vào có thêm văn bản trích xuất từ màn hình bằng nhận dạng chữ quang học (OCR), nhằm bổ sung thông tin về tên các phần tử giao diện. Thành phần OCR được sử dụng như một lựa chọn thiết kế; việc cung cấp danh sách phần tử có cấu trúc ở đầu vào đã xuất hiện trong nhiều công trình trước (Chương 1).

Trường "Đã làm" chứa câu tham chiếu của các bước trước, không sử dụng đầu ra do mô hình sinh ở các bước trước. Vì vậy, mỗi bước được đánh giá với lịch sử tham chiếu (ground-truth history) và không tích lũy lỗi sinh từ các bước trước. Điều kiện này được giữ cố định giữa các mô hình.

4.3 Cấu hình huấn luyện

Mọi mô hình trong đề tài đều được tinh chỉnh từ Qwen2.5-VL-3B-Instruct [34], một mô hình ngôn ngữ thị giác 3 tỉ tham số, bằng QLoRA [29, 30] trên thư viện LLaMA-Factory [31]. QLoRA giữ nguyên trọng số gốc ở dạng nén 4 bit và chỉ học thêm các ma trận nhỏ gắn vào từng tầng (gọi là bộ chuyển đổi LoRA). Nhờ vậy, số tham số cần học chỉ khoảng 15 triệu và việc huấn luyện vừa trên một GPU. Bảng 4.1 ghi cấu hình tinh chỉnh có giám sát từ mô hình gốc.

Bảng 4.1: Cấu hình tinh chỉnh có giám sát. Các mô hình tinh chỉnh từ mô hình gốc dùng chung cấu hình này và chỉ khác nhau ở tập dữ liệu và seed. Hai thành phần của phương pháp đề xuất học tiếp với số bước và tốc độ học riêng (Mục 4.5 và Mục 4.6).

Tham số	**Giá trị**
Mô hình gốc	Qwen2.5-VL-3B-Instruct
Lượng tử hoá	NF4, 4 bit
Hạng LoRA r / α / dropout	8 / 16 / 0,05
Mô-đun gắn bộ chuyển đổi	q, k, v, o, gate, up, down
Tháp thị giác, tầng chiếu đa phương thức	đóng băng
Độ dài ngữ cảnh	2560
Cỡ lô mỗi thiết bị / tích luỹ gradient	4 / 4 (hiệu dụng 16)
Tốc độ học / lịch / tỉ lệ khởi động	1×10^{-4} / cosine / 0,05
Số lượt duyệt	2 (=8.072 bước)
Độ chính xác	bf16, có gradient checkpointing
Hạt giống	101 và 202
Phần cứng	một GPU A100
Tham số huấn luyện được	14.966.784 (0,48% phần ngôn ngữ)

Độ dài ngữ cảnh. Độ dài ngữ cảnh được đặt ở 2560 token, cao hơn mức 2.017 token của mẫu dài nhất trong các cấu hình đã huấn luyện. Giới hạn này đủ để chứa cả phần đầu vào và câu đích trong các thiết lập của đề tài.

4.4 Tổng quan phương pháp đề xuất

Phương pháp đề xuất sử dụng S1 làm điểm khởi đầu và gồm hai thành phần nối tiếp. Ở thành phần thứ nhất, S1 được học tiếp bằng GRPO với phần thưởng SPICE. Khi suy luận, mô hình sau giai đoạn này sinh một câu hướng dẫn ban đầu bằng giải mã tham lam.

Thành phần thứ hai, ACE, khai thác các câu tham chiếu trong tập huấn luyện như nguồn ví dụ. Với mỗi bước, bốn câu gần nhất được truy hồi và đưa vào mô hình sinh cùng đầu vào hiện tại để tạo một câu ứng viên. Một quy tắc đồng thuận sau đó quyết định có thay câu hướng dẫn ban đầu bằng câu ứng viên hay không. Việc thay thế chỉ

xảy ra khi câu ứng viên trùng nguyên văn với một câu ví dụ và đồng thời nhất quán với câu hướng dẫn ban đầu về loại thao tác; trong các trường hợp còn lại, câu hướng dẫn ban đầu được giữ nguyên. Kết quả sau bước lựa chọn này là câu hướng dẫn cuối cùng.

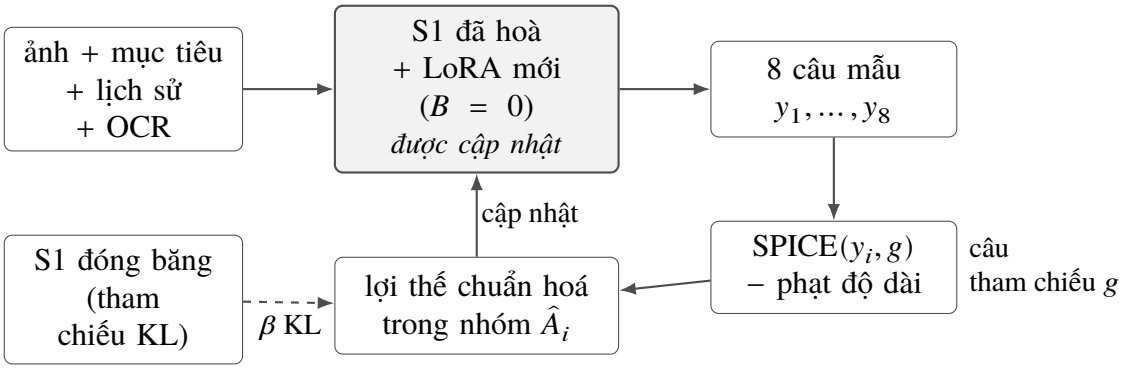
Hai thành phần tác động trực tiếp lên câu đầu ra nhưng sử dụng hai nguồn tín hiệu khác nhau. Thành phần thứ nhất tối ưu mô hình sinh bằng phần thưởng văn bản trên các đầu ra được lấy mẫu. ACE bổ sung thông tin từ các câu tham chiếu truy hồi và chỉ cho phép thay câu hướng dẫn ban đầu khi thỏa các ràng buộc lựa chọn. Chi tiết huấn luyện của hai thành phần lần lượt được trình bày ở Mục 4.5 và Mục 4.6.

Mô hình định vị dùng trong executability không tham gia vào phần thưởng của thành phần thứ nhất hoặc quy tắc đồng thuận của ACE. Ở giai đoạn suy luận, phương pháp cũng không truy cập câu tham chiếu của chính bước đang xét. Trong các phần sau, thuật ngữ *mô hình học tăng cường với phần thưởng SPICE* dùng để chỉ riêng thành phần thứ nhất, còn *phương pháp đề xuất* dùng để chỉ toàn bộ quy trình sau khi áp dụng ACE.

4.5 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Cơ sở lựa chọn. Những hướng được khảo sát trước phương pháp cuối cùng chủ yếu tác động vào một biểu diễn trung gian trước khi sinh câu hướng dẫn (Phụ lục A). Thành phần thứ nhất chuyển sang tối ưu trực tiếp câu đầu ra bằng một phần thưởng văn bản, theo tinh thần của các công trình sinh chú thích ảnh sử dụng CIDEr hoặc SPIDEr làm phần thưởng [46, 48]. SPICE được chọn sau khi phân tích trên tập kiểm định nội bộ cho thấy độ đo này có khả năng phân biệt một phần các đầu ra khác nhau mà S1 sinh cho cùng một bước; kết quả phân tích được trình bày ở Mục 6.3.

Thiết kế. Thành phần thứ nhất khởi tạo từ mô hình tinh chỉnh có giám sát với seed 101, thay vì từ các giai đoạn học tiếp trên mô hình mô tả phần tử. Nhờ đó, khi so sánh với mô hình khởi tạo, khác biệt chính giữa hai cấu hình nằm ở bước học tăng cường. Bộ chuyển đổi LoRA của mô hình xuất phát được hợp nhất vào trọng số gốc,



Hình 4.2: Vòng huấn luyện của thành phần thứ nhất, học tăng cường với phần thưởng SPICE. Chỉ khối tô xám được cập nhật.

tức phần cập nhật hạng thấp được cộng trực tiếp vào ma trận trọng số để tạo thành một mô hình duy nhất. Sau đó, một bộ chuyển đổi LoRA mới với cùng hạng và cùng các mô-đun được gắn vào mô hình; ma trận B (một trong hai ma trận hạng thấp của LoRA) được khởi tạo bằng không. Vì vậy, trước bước cập nhật đầu tiên, mô hình mới tương đương với mô hình tinh chỉnh có giám sát. Một bản sao của mô hình tinh chỉnh có giám sát được đóng băng và dùng làm mô hình tham chiếu cho số hạng KL; độ lệch Kullback–Leibler này hạn chế mức thay đổi của chính sách đang học so với mô hình tham chiếu. Phần thưởng của một câu s so với câu tham chiếu là

$$r(s) = \text{SPICE}(s, g) - 0{,}02 \cdot \max(0,\ |s| - |g| - 3), \tag{4.1}$$

trong đó $|\cdot|$ là số từ, và câu rỗng nhận 0 điểm. Số hạng thứ hai chỉ phạt những câu dài hơn câu tham chiếu quá ba từ, để mô hình không tăng SPICE bằng cách liệt kê thêm chi tiết.

Mỗi bước cập nhật sử dụng hai prompt; với mỗi prompt, mô hình sinh $G = 8$ câu ở nhiệt độ 1,0, mỗi câu dài tối đa 96 token. Quá trình huấn luyện kéo dài 500 bước, tương ứng một lượt duyệt qua 1.000 prompt lấy từ phần tập huấn luyện sau khi loại tập kiểm định nội bộ. Các prompt gồm mọi loại thao tác, trong đó khoảng hai phần ba là bước chạm. Tốc độ học là 10^{-5} và hệ số KL là $\beta = 0{,}04$; vòng huấn luyện được tóm tắt ở Hình 4.2. GRPO sử dụng chênh lệch phần thưởng tương đối giữa các đầu ra trong cùng nhóm; vì vậy, các nhóm mà phần thưởng không phân tách các ứng viên không cung cấp tín hiệu xếp hạng tương đối hữu ích.

Lựa chọn checkpoint. Hai checkpoint ở bước 250 và 500 được dùng để sinh câu bằng giải mã tham lam trên tập kiểm định nội bộ và được xếp hạng theo executability. Checkpoint 500 được lựa chọn từ bước phát triển này, sau đó được cố định để sinh câu trên tập kiểm tra. Các quan sát dùng trong quá trình lựa chọn checkpoint được trình bày cùng phân tích tín hiệu phần thưởng ở Mục 6.3.

Lưu ý về thiết lập so sánh. Thành phần học tăng cường và S1 hiện sử dụng hai quy trình sinh câu có một số khác biệt kỹ thuật, đồng thời chưa có cấu hình đối chứng chỉ học thêm có giám sát với cùng số bước. Hai yếu tố này được giữ cố định trong các kết quả đã báo cáo và được liệt kê như nội dung cần kiểm chứng bổ sung ở Chương 7.

4.6 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Cơ sở lựa chọn. ACE (*Action-Consistent Exemplar copying*) sử dụng các câu tham chiếu trong tập huấn luyện làm nguồn ví dụ cho bước hiện tại. Do các câu được truy hồi đến từ những bước khác, việc dùng chúng trực tiếp có thể dẫn tới sai phần tử hoặc sai loại thao tác. Vì vậy, ACE tách quá trình thành hai giai đoạn: trước hết, mô hình sinh tạo một câu ứng viên từ đầu vào hiện tại và các ví dụ truy hồi; sau đó, quy tắc đồng thuận quyết định có thay câu hướng dẫn ban đầu của thành phần thứ nhất bằng câu ứng viên hay không. Mức độ hữu ích và những giới hạn của kho truy hồi trên tập kiểm tra được phân tích ở Mục 6.4.

Mô hình sinh câu với ví dụ truy hồi. Kho truy hồi là phần tập huấn luyện đã bỏ mọi tác vụ của tập kiểm định nội bộ, gồm 62.880 bước thuộc 12.542 tác vụ, không chứa tác vụ nào của tập kiểm tra. Phép truy hồi chỉ dùng văn bản, không dùng ảnh, và so khớp bằng TF-IDF, tức cách đánh trọng số từ theo tần suất trong câu và độ hiếm trong kho. Việc truy hồi dùng hai cách tìm, rồi gộp kết quả và bỏ các câu trùng nhau. Cách thứ nhất, theo SmallCap [47], truy hồi trực tiếp những bước có mục tiêu và câu gần nhất trong lịch sử thao tác tương tự bước đang xét. Cách thứ hai tìm trước những tác vụ có mục tiêu giống nhất, rồi trong mỗi tác vụ ấy chọn bước tương ứng dựa trên câu gần nhất trong lịch sử. Bốn câu ví dụ được chèn vào prompt ngay trước dòng yêu cầu viết câu.

Mô hình sinh câu được tạo bằng cách tiếp tục tinh chỉnh có giám sát bộ chuyển đổi của thành phần thứ nhất thêm 250 bước với tốc độ học 2×10^{-5}, trên 3.991 bước thuộc phần tập huấn luyện có sẵn ảnh. Để hạn chế việc mô hình phụ thuộc quá mức vào câu ví dụ, khối ví dụ trong quá trình huấn luyện được biến đổi ngẫu nhiên. Số câu ví dụ được lấy ngẫu nhiên từ 2 đến 6 và thứ tự các câu bị xáo trộn; 15% prompt không có khối ví dụ và 10% prompt có khối ví dụ lấy ngẫu nhiên; tác vụ đang học cũng bị loại khỏi kho truy hồi. Để tách phần do truy hồi khỏi phần do học thêm, chúng tôi huấn luyện thêm một mô hình để so sánh trên cùng các bước, cùng chuỗi đích và cùng siêu tham số, chỉ khác ở chỗ prompt không có khối ví dụ.

Quy tắc đồng thuận. Ở mỗi bước có hai câu: câu hướng dẫn ban đầu của thành phần thứ nhất và câu do mô hình sinh với các ví dụ truy hồi tạo ra. Câu thứ hai chỉ được chọn khi thỏa đồng thời hai điều kiện.

1. **Khớp nguyên văn với câu ví dụ.** Sau khi tách từ, câu của mô hình sinh trùng hoàn toàn với một trong bốn câu ví dụ của khối. Điều kiện này chỉ giữ lại những bước mà mô hình sinh lựa chọn đúng câu ví dụ, và bỏ những bước mô hình sinh tự tạo câu mới.

2. **Đồng thuận loại thao tác.** Động từ ở đầu câu của mô hình sinh và động từ ở đầu câu hướng dẫn ban đầu thuộc cùng một lớp thao tác (chạm, nhấn giữ, gõ, cuộn, mở ứng dụng, quay lại). Câu ví dụ đến từ một bước khác, nên có thể nói đúng phần tử nhưng sai thao tác, ví dụ sinh thao tác gõ ở một bước yêu cầu chạm. Câu hướng dẫn ban đầu được sinh từ chính màn hình hiện tại và được sử dụng làm tín hiệu kiểm tra loại thao tác.

Lựa chọn quy tắc. Quy tắc trên được lựa chọn trên tập kiểm định nội bộ từ bốn biến thể: chỉ dùng điều kiện chép; chép kèm đồng thuận loại thao tác; chép kèm điều kiện phần lõi của câu (phần còn lại sau khi bỏ động từ và hư từ) trùng với câu hướng dẫn ban đầu ít nhất một nửa; và chép kèm cả hai điều kiện. Tiêu chí lựa chọn được xác định trước khi tính executability trên tập này. Theo tiêu chí đó, chỉ những biến thể không kém hơn câu hướng dẫn ban đầu trên đa số độ đo dựa trên câu tham chiếu mới được xem xét; trong số này, biến thể có executability cao nhất được lựa chọn. Quy tắc đã chọn sau đó chỉ được áp dụng một lần trên tập kiểm tra.

4.7 Mô hình và thiết lập so sánh

Kết quả của phương pháp đề xuất được so sánh với ba mốc chính. Mốc thứ nhất là mô hình gốc Qwen2.5-VL-3B-Instruct khi chưa tinh chỉnh, được ký hiệu là Base trong các bảng. Mốc thứ hai là mô hình tinh chỉnh có giám sát, ký hiệu S1. Mô hình này được tinh chỉnh từ mô hình gốc với cấu hình ở Bảng 4.1 để sinh trực tiếp câu hướng dẫn từ prompt, không qua bước trung gian, và được huấn luyện hai lần với seed 101 và 202. Vì hai lượt huấn luyện chỉ khác seed, chênh lệch giữa chúng được dùng để đánh giá độ ổn định khi lặp lại cùng một cấu hình. Thành phần thứ nhất của phương pháp đề xuất học tiếp từ lượt seed 101, nên lượt này đồng thời là mốc so sánh trực tiếp. Mốc thứ ba là câu tham chiếu được đưa trực tiếp vào quy trình đánh giá. Điểm của câu tham chiếu được sử dụng như một mốc tham chiếu để hỗ trợ diễn giải kết quả của các mô hình.

Trước khi hình thành phương pháp đề xuất, đề tài đã khảo sát nhiều phương án khác, gồm viết trước câu một dòng mô tả phần tử cần chạm, học theo cặp ưu tiên trên dòng mô tả, chọn phần tử trong một danh sách ứng viên, thưởng cho tọa độ ghi trong dòng mô tả và hiệu chỉnh câu dựa trên vùng ảnh cục bộ. Kết quả của các hướng này là căn cứ để chọn phương pháp và được tóm tắt ở Mục 6.10; thiết kế và số liệu chi tiết nằm ở Phụ lục A.

4.8 Thiết lập so sánh và diễn giải kết quả

Các phép so sánh giữa hai mô hình đều được thực hiện theo cặp trên cùng 4.463 bước chạm của tập kiểm tra. Trong phần lớn trường hợp, một mô hình có can thiệp được so với mốc tương ứng của nó. Mỗi phép so sánh được báo cáo bằng ba đại lượng: mức chênh Δ, khoảng tin cậy 95% ước lượng bằng bootstrap gom cụm theo ứng dụng, và giá trị p của kiểm định McNemar. Việc gom cụm được thực hiện ở mức ứng dụng thay vì từng bước vì các bước trong cùng một ứng dụng có thể tương quan với nhau. Kiểm định McNemar chỉ sử dụng những bước mà hai mô hình cho kết quả khác nhau (Mục 5.13). Một mô hình được xem là cải thiện hoặc suy giảm có ý nghĩa so với mốc khi khoảng tin cậy của chênh lệch nằm hoàn toàn về một phía của 0; nếu khoảng tin

cậy chứa 0, kết quả được xem là chưa đủ cơ sở để kết luận, kể cả khi Δ dương.

Độ ổn định khi huấn luyện lại S1 với seed khác được phân tích riêng ở Mục 6.7; sai số chuẩn của các hiệu ghép cặp và chi tiết bootstrap được trình bày ở Mục 5.13.

Ngoài kết quả trên toàn tập, chúng tôi còn phân tích kết quả theo ba cách chia nhóm chính: độ dài câu, độ khó của màn hình và nguồn của tên phần tử.

Chương 5

Độ đo khả năng thực hiện theo hướng dẫn

Chương này xây dựng và kiểm chứng độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability. Khác với các độ đo chỉ dựa trên mức độ tương đồng với một câu tham chiếu, executability xem xét liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử cần thao tác và loại thao tác tương ứng hay không. Chương trước hết trình bày định nghĩa và quy tắc xác định một dự đoán đúng, sau đó đánh giá độ tin cậy của công cụ định vị, thiết lập các mốc tham chiếu cho thang điểm và kiểm tra độ nhạy, độ ổn định của độ đo. Phần cuối trình bày phương pháp phân tích thống kê được sử dụng trong các chương thực nghiệm.

5.1 Định nghĩa

Với mỗi bước chạm, độ đo sử dụng năm đại lượng. s là câu hướng dẫn cần đánh giá; nếu một phương án đã thử sinh thêm dòng mô tả phần tử trước câu (Phụ lục A), phần này được loại bỏ trước khi tính điểm. I là ảnh màn hình và g là tọa độ chạm của người dùng. E là tập phần tử trên màn hình, được lấy từ cây trợ năng; các phần tử có tâm cách nhau dưới 24 dp được gộp thành một (dp là đơn vị độ dài của Android, không phụ thuộc mật độ điểm ảnh; trên thiết bị được sử dụng, 24 dp tương ứng 63 điểm ảnh). G là mô hình định vị phần tử: mô hình nhận ảnh cùng câu hướng dẫn và trả về tọa độ $p = G(I, s)$ của phần tử được câu quy chiếu tới. G tách biệt với mô hình sinh đang được đánh giá và không nhận g làm đầu vào.

Một bước được tính là đúng khi thoả cả ba điều kiện:

- **(i) Khớp loại thao tác.** Loại thao tác của s, sau khi chuẩn hoá, phải trùng với của câu tham chiếu. Có năm loại: chạm, gõ, cuộn, nhấn giữ và quay lại; mười hai động từ (*tap, click, press, select, choose, touch, open, launch, go, navigate, visit, view*) được xếp vào loại chạm.

  Cách chuẩn hoá này có một lỗi đã biết: động từ được dò từ trái sang phải, nên *go back, navigate back* và *press the back button* bị xếp vào chạm thay vì quay lại. Các điểm chính vẫn giữ cách chuẩn hoá cũ để nhất quán với toàn bộ kết quả đã báo cáo; ảnh hưởng định lượng của lỗi được trình bày ở Mục 5.12, còn bản đã sửa chỉ dùng ở phép kiểm tra các bước không chạm (Mục A.2.2.4).

- **(ii) Không đảo nghĩa.** s và câu tham chiếu không được gọi tên hai trạng thái ngược nhau của cùng một điều khiển, chẳng hạn nút "bật thông báo" và "tắt thông báo". Điều kiện (iii) không bắt được lỗi này vì hai trạng thái nằm cùng một chỗ. Danh sách lập thủ công gồm chín cặp từ trái nghĩa (*on/off, enable/disable, show/hide, mute/unmute, expand/collapse, check/uncheck, select/deselect, start/stop, enabled/disabled*).

- **(iii) Định vị đúng.** p nằm trong vùng dung sai quy ước quanh g, $|p_x - g_x| \le \tau W$ và $|p_y - g_y| \le \tau H$, với W, H là bề ngang và chiều cao màn hình và $\tau = 0{,}14$ theo [2]; đồng thời không phần tử nào khác có tâm gần p hơn chính g:

$$\|p - g\| < \|p - c(e)\| \quad \forall e \in E, \tag{5.1}$$

với $c(e)$ là tâm của phần tử e. Vùng gồm mọi điểm thoả điều kiện này gọi là ô Voronoi của phần tử cần chạm (Hình 5.1). Như vậy, điểm mô hình định vị chỉ ra phải rơi vào phần tử cần chạm chứ không rơi sang phần tử bên cạnh.

Điểm executability là tỉ lệ bước chạm thoả cả ba điều kiện.

Điều kiện (iii) có hai chi tiết cần làm rõ. Vùng dung sai là hình chữ nhật, không phải hình tròn: trên màn 1080×2400, vùng rộng ± 151 điểm ảnh theo chiều ngang và ± 336 điểm ảnh theo chiều dọc. Ô Voronoi được dựng quanh điểm chạm g thay vì tâm

hộp của phần tử chứa g; sử dụng tâm hộp làm hạt làm tăng đáng kể số trường hợp bị loại. Mọi hộp chứa g đều được coi là thuộc phần tử cần chạm.

Vai trò của mô hình định vị và phạm vi của độ đo. Tọa độ chạm của người dùng được dùng làm mốc đối chiếu. Mô hình G không được tinh chỉnh trong đề tài và chỉ có nhiệm vụ suy ra một tọa độ từ ảnh cùng câu hướng dẫn; tọa độ này sau đó được so sánh với g theo các điều kiện ở trên. Vì vậy, executability chỉ phản ánh một khía cạnh của chất lượng hướng dẫn: câu có đủ thông tin để xác định đúng phần tử và đúng thao tác hay không. Độ đo không trực tiếp phản ánh độ trôi chảy, độ ngắn gọn, mức dễ hiểu đối với từng nhóm người dùng, mức hữu ích tổng thể hay trải nghiệm sử dụng.

5.2 Quy tắc xác định dự đoán đúng và giới hạn của quy tắc dung sai quy ước

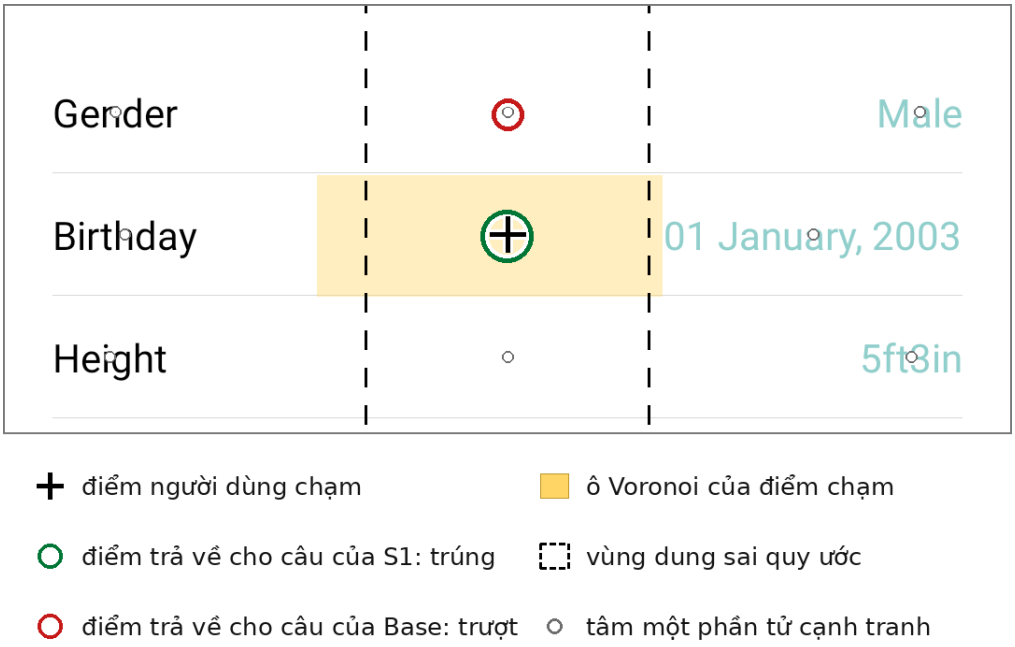
Điều kiện ô Voronoi chặt hơn quy tắc dung sai quy ước nhưng phức tạp hơn, nên chúng tôi kiểm tra hành vi của hai quy tắc trên 250 bước chạm (Bảng 5.1). Hai tình huống được dùng để phân biệt vai trò của quy tắc: dự đoán chỉ lệch nhẹ so với điểm chạm và dự đoán bị chuyển sang phần tử lân cận sai.

Bảng 5.1: So sánh các quy tắc xác định dự đoán đúng trong hai tình huống tổng hợp: dự đoán lệch nhẹ và dự đoán bị chuyển sang phần tử lân cận sai.

Quy tắc	**Chấp nhận khi lệch 3%**	**Chấp nhận khi sai nút lân cận**	**Biên độ**
Cửa sổ dung sai $\pm$ 14% theo từng trục	–	84,3%	$\approx$ 16 điểm
Ô Voronoi	99,7%	**2,8%**	$\approx$ 97 điểm

Quy tắc dung sai quy ước vẫn chấp nhận phần lớn dự đoán bị chuyển sang nút lân cận, vì 63,2% số bước có ít nhất một phần tử khác nằm trong vùng dung sai của phần tử cần chạm. Ngược lại, quy tắc ô Voronoi chỉ chấp nhận 2,8% các dự đoán sai nút lân cận nhưng vẫn giữ tỉ lệ chấp nhận 99,7% khi điểm chỉ lệch 3%. Vì vậy quy tắc ô Voronoi được chọn làm quy tắc chính.

Kết quả này cần đọc kèm hai lưu ý. Thứ nhất, mức 2,8% chỉ mô tả tình huống dự



Hình 5.1: Một bước mà hai quy tắc đánh giá cho hai kết quả khác nhau. Người dùng chạm dòng *Birthday*. Câu của S1 dẫn mô hình định vị tới đúng dòng đó. Câu của mô hình gốc tả dòng *Gender* ngay phía trên, nên điểm trả về lệch 128 điểm ảnh, vẫn trong vùng dung sai quy ước. Quy tắc dung sai vẫn đánh giá dự đoán là đúng; quy tắc ô Voronoi phân biệt được việc câu đang quy chiếu sang một dòng khác.

đoán bị chuyển sang một phần tử khác, không áp dụng cho điểm dịch nhẹ nhưng vẫn nằm trong ô của phần tử cần chạm (Mục 5.7). Thứ hai, phép gộp phần tử quyết định thế nào là hai phần tử khác nhau: phép gộp xoá ít nhất một tâm ở 96,3% số bước, phần lớn là tâm trùng của cùng một phần tử, nhưng ở 8,2% số bước lại xoá nhầm một phần tử khác có thật. Vì vậy điểm theo quy tắc dung sai luôn được trình bày kèm, nhưng không dùng làm điểm chính.

Kết luận này vẫn đúng với điểm do mô hình định vị thật trả về. Trên 300 bước của Mục 5.4, khi nhận câu tham chiếu, quy tắc ô Voronoi cho điểm mọi bước có sai số định vị dưới 3% bề ngang màn ($n = 188$) và không cho điểm bước nào có sai số trên 14% ($n = 63$).

5.3 Mô hình định vị dùng làm công cụ đo

UGround-V1-2B [5] được chọn làm công cụ định vị chính vì mô hình có trọng số công khai, được phát triển cho bài toán GUI grounding và có thể trả về trực tiếp tọa độ phần tử từ ảnh cùng mô tả văn bản. Tuy nhiên, để đầu ra của mô hình có thể dùng làm cơ sở đánh giá, sai số định vị phải đủ nhỏ so với khoảng cách giữa các phần tử trên màn hình. Điều kiện này được kiểm tra riêng ở Mục 5.4.

Hai đặc điểm của UGround cần được lưu ý khi diễn giải kết quả. Thứ nhất, mô hình được xây dựng trên Qwen2-VL, thuộc cùng họ kiến trúc với Qwen2.5-VL-3B được sử dụng làm mô hình sinh. Thứ hai, UGround được huấn luyện trên 47 nghìn phần tử do người gán nhãn lấy từ phần huấn luyện chính thức của AndroidControl; phần dữ liệu này chứa các tác vụ liên quan tới khoảng 90% tập kiểm tra của đề tài (Mục 3.3). Vì vậy, công cụ đo có thể đã gặp một phần màn hình liên quan và có khả năng đã tiếp xúc với quy ước chú thích của bộ dữ liệu. Các phép đánh giá chéo ở Mục 5.9 và Mục 5.10 được sử dụng để kiểm tra mức độ ổn định của một số kết luận khi thay đổi công cụ đánh giá, chứ không nhằm khẳng định rằng các nguồn thiên lệch này không tồn tại.

Phân tích này chưa cho thấy ảnh hưởng rõ của việc trùng dữ liệu huấn luyện lên điểm số. Tách 4.463 bước chạm theo phần chia chính thức (3.994 bước thuộc phần huấn luyện, 469 bước thuộc phần kiểm tra và kiểm định), câu tham chiếu đạt 75,9% và 74,0%, S1 đạt 59,1% và 59,3%, mô hình gốc đạt 47,7% và 46,7%. Khoảng tin cậy của hai phần chồng nhau ở cả ba loại câu, và không nhóm câu nào cho điểm cao hơn rõ rệt ở phần dữ liệu mà công cụ có thể đã gặp trong huấn luyện. Với 469 bước, phép đo loại được độ lệch từ năm điểm trở lên, chưa loại được độ lệch một đến hai điểm.

Phép tách trên không đánh giá được thiên lệch do văn phong, vì hai phần dữ liệu sử dụng cùng phong cách chú thích. Mục 5.9 kiểm tra khả năng này bằng một công cụ đo thứ hai không được huấn luyện trên AndroidControl nhưng vẫn thuộc họ Qwen (Mục 7.2); Mục 5.10 tiếp tục đánh giá bằng một mô hình thuộc họ kiến trúc khác. Prompt cung cấp cho G được giữ nguyên theo trang giới thiệu mô hình của nhóm tác giả.

5.4 Sai số của công cụ đo

Độ tin cậy của executability phụ thuộc trực tiếp vào độ chính xác của mô hình định vị G, vì vậy G được đánh giá trước khi được sử dụng để đánh giá các mô hình sinh câu. Sai số định vị được xem xét trong tương quan với khoảng cách giữa các phần tử giao diện. Biên dung sai được định nghĩa là nửa khoảng cách từ phần tử cần chạm tới phần tử khác gần nhất sau khi gộp. Trên 1.496 bước chạm, biên dung sai có trung vị 67 điểm ảnh (6,2% bề ngang) và phân vị thứ mười là 39 điểm ảnh (3,6%), nên sai số cỡ 3% bề ngang (khoảng 32 điểm ảnh) vẫn nhỏ hơn cả phân vị thứ mười. Mức sai số này đạt được vì tọa độ chạm trong AndroidControl phần lớn là tâm phần tử (79,4% số điểm chạm cách một tâm không quá 1,5 điểm ảnh). Tỉ lệ loại nhầm là 0% ở mức sai số 3%, 7,5% ở mức 5%, 24,1% ở mức 8% và tăng mạnh lên 55% ở mức sai số 13%.

Kết quả đo. Trên 300 bước của tập kiểm tra, khi đầu vào là câu tham chiếu, UGround-V1-2B có sai số trung vị bằng 0,7% bề ngang màn hình; 62,7% số bước có sai số dưới 3%. Tuy vậy, phân bố sai số có đuôi dài, với các phân vị 25, 75 và 90 lần lượt là 0,2%, 8,8% và 36,3%. Như vậy, ở phần lớn trường hợp mô hình định vị khá sát phần tử mục tiêu, nhưng vẫn có một nhóm nhỏ trường hợp sai lệch lớn. Những lỗi này chủ yếu làm giảm điểm executability thay vì tạo ra điểm dương giả.

5.5 Mốc tham chiếu của thang điểm

Để có cơ sở diễn giải điểm executability, cùng một quy trình đánh giá được áp dụng cho một số loại câu có vai trò tham chiếu khác nhau. **Mốc tham chiếu** được xác định bằng câu hướng dẫn do người chú thích viết cho chính bước đang xét. Trên toàn bộ 4.463 bước chạm, các câu này đạt 75,7% executability, với khoảng tin cậy 95% [74,1; 77,3] (Mục 5.13); nếu dùng quy tắc dung sai, điểm tương ứng là 84,3% [82,9; 85,6].

Điểm 75,7% không phải là giới hạn tối đa của độ đo. Có 148 bước mà câu tham chiếu không đạt nhưng câu của mô hình gốc hoặc S1 lại đạt; nếu xét cả ba loại câu, 3.527 bước, tương ứng 79,1%, đạt theo ít nhất một loại câu. Vì thế, 75,7% chỉ nên được hiểu là điểm của câu do người chú thích viết khi đi qua cùng quy trình đánh giá, chứ không phải một trần lý thuyết hay mức tối đa mà mô hình có thể đạt. Mốc này

được dùng để đặt kết quả của các mô hình vào bối cảnh; chẳng hạn S1 đạt 59,1%, thấp hơn câu tham chiếu 16,6 điểm (Mục 6.9.4). Cách đối chiếu kết quả hệ thống với một mốc từ con người cũng được sử dụng trong nghiên cứu sinh chỉ dẫn điều hướng của Zhao và cộng sự [37].

Ở chiều ngược lại, **mốc tham chiếu dưới** được khảo sát bằng các câu mang rất ít hoặc không mang thông tin quy chiếu. Trên một mẫu ngẫu nhiên 800 bước, câu tham chiếu đạt 74,9%, S1 đạt 58,8% và Base đạt 48,6%. Cùng mẫu này, câu chung chung "*Tap the button.*" chỉ đạt 12,0% [9,7; 14,4], còn câu tham chiếu lấy từ một màn hình khác đạt 6,1% [4,5; 7,9].

Trường hợp	**Câu đưa cho mô hình định vị**	**Điểm**	**KTC 95%**
Câu tham chiếu	câu của chính bước đang xét	74,9	–
S1	mô hình đã tinh chỉnh	58,8	–
Base	mô hình chưa tinh chỉnh	48,6	–
Câu chung chung	"*Tap the button.*"	12,0	[9,7; 14,4]
Câu của màn hình khác	câu tham chiếu của một bước khác	6,1	[4,5; 7,9]

Hai mức 12,0% và 6,1% là các mốc thực nghiệm chứ không phải sàn toán học. Chúng cũng cho thấy tỉ lệ 40,0% số bước mà câu tham chiếu, S1 và Base cùng đạt không thể được dùng để suy ra một mức điểm nền: khi nội dung quy chiếu bị loại bỏ hoặc thay bằng nội dung của màn hình khác, điểm giảm rõ rệt. Nếu dùng 12,0% như một mốc thực hành để chuẩn hoá dải 74,9–12,0 trên mẫu 800 bước, Base nằm ở 58,3% và S1 ở 74,4% dải này; phép chuẩn hoá này chỉ phục vụ diễn giải và không thay đổi điểm executability gốc.

Mốc tham chiếu cũng không thay thế đánh giá chất lượng câu bởi người dùng. Một mô hình được tối ưu trực tiếp theo công cụ đo có thể học cách diễn đạt phù hợp với mô hình định vị nhưng chưa chắc thuận tiện cho người đọc. Vì vậy, ngay cả khi điểm tiến gần mốc câu tham chiếu, vẫn cần đánh giá thêm các khía cạnh ngôn ngữ và khả năng sử dụng mà executability không đo trực tiếp.

5.6 Độ nhạy với thông tin quy chiếu

Các mốc dưới ở Mục 5.5 cho thấy câu chung chung hoặc câu đúng văn phong nhưng lấy từ màn hình khác nhận điểm thấp. Mục này kiểm tra trực tiếp hơn việc điểm số thay đổi ra sao khi chỉ loại bỏ một phần thông tin quy chiếu khỏi câu tham chiếu.

5.6.1 Vai trò của tên phần tử so với vị trí

Hai phép biến đổi dưới đây được áp dụng cho các câu có thành phần tương ứng: phép thứ nhất bỏ tên phần tử nhưng giữ mệnh đề vị trí, còn phép thứ hai bỏ mệnh đề vị trí nhưng giữ tên phần tử. Hai nhóm bước có kích thước gần bằng nhau nên có thể đối chiếu trực tiếp.

Phép cắt	**n**	**Trước → sau biến đổi**	**Mức giảm**
Bỏ tên phần tử, giữ vị trí	193	89,6 → 61,1	**-28,5 pp**
Bỏ mệnh đề vị trí, giữ tên	198	89,4 → 85,9	**-3,5 pp**

Với phép bỏ tên, $b = 58$ bước chuyển từ đạt sang không đạt và $c = 3$ bước theo chiều ngược lại; kiểm định McNemar (Mục 5.13) cho $\chi^2 = 47{,}8$, $p < 0{,}001$. Mức giảm do bỏ tên phần tử lớn gấp khoảng tám lần mức giảm do bỏ mệnh đề vị trí. Cùng với hai mốc thực nghiệm ở Mục 5.5, kết quả cho thấy độ đo nhạy với thông tin quy chiếu bị thao tác trong các phép thử này, đặc biệt là tên phần tử.

Diễn giải kết quả trên tập con chịu tác động. Phép bỏ tên phần tử chỉ áp dụng cho 24,1% số bước có mệnh đề vị trí. Vì vậy, khi tính trên toàn mẫu 800 bước, mức giảm bị thu nhỏ do phần lớn các bước không thay đổi. Kết quả chính cần đọc trên tập con chịu tác động, nơi điểm giảm 28,5 điểm; nguyên tắc này cũng được áp dụng cho các phép biến đổi chỉ tác động lên một phần dữ liệu.

5.7 Kiểm chứng bằng biến đổi lỗi có kiểm soát

Một cách kiểm độ đo là cố ý làm hỏng câu theo những cách đã biết rồi xem độ đo có bắt được không [15]. Chúng tôi chèn mười loại lỗi vào 398 bước chạm (Bảng 5.2). Ba dòng đầu kiểm độ đo có loại nhầm câu đúng không, bảy dòng sau kiểm độ đo có bắt được câu sai không.

Bảng 5.2: Kiểm chứng độ đo bằng các lỗi được cố ý chèn vào có kiểm soát.

Loại lỗi chèn vào	Đo được	n
Loại nhầm câu diễn đạt khác	0,0%	398
Loại nhầm ở điều kiện thao tác	0,0%	398
Loại nhầm ở quy tắc đảo nghĩa	0,0%	398
Bắt được phần tử kề gần	33,1%	121
Bắt được phần tử kề xa	99,6%	233
Chấp nhận dự đoán ở phần tử cách xa	100,0%	397
Bắt được phủ định ngoài bảng	20,0%	15
Bắt được sai loại thao tác	100,0%	369
Bắt được sai nội dung	91,1%	494
Bắt được sai hướng	100,0%	755

Diễn giải kết quả của phép biến đổi lỗi. Một số biến đổi cho kết quả gần như xác định bởi chính cách tạo lỗi, chẳng hạn thay loại thao tác hoặc hướng. Hai trường hợp có giá trị phân tích hơn là chuyển sang phần tử lân cận và phủ định câu, vì chúng kiểm tra trực tiếp khả năng phân biệt giữa các phần tử gần nhau và khả năng xử lý thay đổi ngữ nghĩa.

Phần tử kề gần. Tỉ lệ thấp ở dòng này là hệ quả của thiết kế. Độ đo gộp các phần tử có tâm cách nhau dưới 24 dp (Mục 5.1), nên không phân biệt được các điểm đích dưới khoảng 63 điểm ảnh, gần bằng biên dung sai trung vị 67 điểm ảnh (Mục 5.4). Độ đo bắt được việc gọi tên sai phần tử, nhưng không bắt được một điểm chỉ hơi lệch bên trong chính phần tử cần chạm.

Phủ định ngoài tập từ vựng quy định. Dòng này do một cơ chế dự phòng cho các từ phủ định ngoài bảng từ vựng đã liệt kê, và chỉ có 15 ca, quá ít để rút ra kết luận.

5.8 Độ ổn định trước các biến thể diễn đạt

Một độ đo phù hợp cần tương đối ổn định trước các biến thể diễn đạt giữ nguyên nội dung. Jandial và cộng sự [18] chỉ ra rằng mô hình định vị có thể nhạy với cách diễn đạt của câu. Vì vậy, chúng tôi xây dựng các biến thể của câu tham chiếu và đánh giá lại executability trên mẫu 800 bước.

Bốn biến thể được xây dựng bằng quy tắc xác định, không sử dụng mô hình ngôn ngữ, gồm: thay động từ thao tác (ví dụ *click* thành *tap*), đảo thứ tự hai mệnh đề, kết hợp hai biến đổi trên, và loại bỏ mệnh đề vị trí. Ba biến thể đầu giữ nguyên nội dung chính; biến thể cuối chủ động loại bỏ thông tin để làm đối chứng.

Bảng 5.3: Điểm khi viết lại câu tham chiếu theo bốn biến thể rồi đánh giá lại, tính trên phần bị tác động. Ở cột McNemar, *b* là số bước chuyển từ đạt sang không đạt sau khi viết lại, *c* là chiều ngược lại.

Biến thể	Số câu viết lại	Trên phần bị tác động	McNemar
Đổi động từ thao tác	725 (90,6%)	76,8 → 77,0	b=13, c=14, p=1,000
Đảo trật tự mệnh đề	211 (26,4%)	89,6 → 90,0	b=0, c=1, p=1,000
Đổi động từ và đảo trật tự	203 (25,4%)	90,1 → 91,1	b=0, c=2, p=0,480
Bỏ mệnh đề vị trí	198 (24,8%)	89,4 → 85,9	b=8, c=1, **p=0,046**

Gộp ba biến thể giữ nguyên nghĩa, 30 trong 1.139 câu viết lại (2,6%) làm thay đổi kết quả đánh giá. Hiệu ròng là +0,35 điểm, với khoảng tin cậy 95% [−0,59; +1,29]. Ngược lại, loại bỏ thông tin vị trí làm điểm giảm có ý nghĩa thống kê. Kết quả này cho thấy độ đo tương đối ổn định trước các thay đổi bề mặt được khảo sát nhưng vẫn nhạy với việc mất thông tin định vị.

Phạm vi của kết luận. Công cụ đo ổn định trước việc thay động từ và đảo trật tự câu trong các phép thử trên, nhưng chưa thể suy rộng kết luận này cho mọi cách diễn đạt lại. Các phép viết lại chỉ thay động từ trong cùng lớp thao tác (điều kiện khớp thao tác vẫn đạt ở 100% số câu của ba biến thể), không thay đổi phần mô tả phần tử như phép biến đổi của Jandial và cộng sự. Trường hợp thay chính tên gọi của phần tử chưa được kiểm tra và được ghi nhận như một hạn chế (Mục 7.2).

5.9 Đánh giá chéo bằng mô hình định vị thứ hai

Do UGround được huấn luyện trên dữ liệu có liên hệ với AndroidControl, luận văn thực hiện thêm một phép đánh giá chéo bằng công cụ thứ hai để kiểm tra mức độ ổn định của các kết luận. UI-Venus-Ground-7B [6] được lựa chọn vì có giấy phép mở, đạt kết quả tốt trên các bộ chuẩn định vị giao diện di động và không sử dụng AndroidControl trong quá trình huấn luyện. Phép so sánh được thực hiện trên 2.532 bước mà các mô hình sinh ra câu khác nhau; những bước có đầu ra giống nhau không ảnh hưởng đến chênh lệch giữa các mô hình.

Do hai công cụ sử dụng thang điểm khác nhau, phép đánh giá tập trung vào chênh lệch tương đối giữa các mô hình thay vì so sánh trực tiếp điểm tuyệt đối. Chênh lệch giữa S1 và mô hình gốc được chọn làm phép kiểm chứng vì có độ lớn đủ lớn và mang dấu dương rõ ràng. Nếu công cụ thứ hai làm thu hẹp thang điểm đáng kể, chênh lệch này sẽ giảm tương ứng và các khác biệt nhỏ hơn sẽ trở nên khó diễn giải hơn.

Bảng 5.4: Chênh lệch giữa các mô hình trên cùng 2.532 bước, đánh giá bằng hai mô hình định vị khác nhau. Chênh lệch giữa mô hình mô tả phần tử (S2, một hướng đã thử ở Phụ lục A) và S1 được quy về mẫu số 4.463 để so sánh với các bảng khác. Trong ngoặc vuông là khoảng tin cậy 95%.

Phép so	**UGround**	**UI-Venus**
S1 − mô hình gốc (Base), phép so sánh kiểm chứng	+10,35 [+8,39; +12,40]	+9,68 [+7,60; +11,78]
Mô tả phần tử (S2) − S1	-1,93 [−3,08; −0,78]	-1,21 [−2,30; −0,12]
Câu tham chiếu trên mẫu	70,0%	69,3%

Kết quả của phép so sánh kiểm chứng. Chênh lệch giữa S1 và mô hình gốc là +10,35 điểm khi đánh giá bằng UGround và +9,68 điểm khi đánh giá bằng UI-Venus. Việc chênh lệch gần như được bảo toàn sau khi thay công cụ đo cho thấy thứ hạng và độ lớn tương đối giữa hai mô hình khá ổn định trước lựa chọn mô hình định vị.

Kết quả trên một chênh lệch nhỏ. Chênh lệch giữa mô hình mô tả phần tử (S2) và S1 vẫn âm khi đánh giá bằng cả hai công cụ, và cận trên của khoảng tin cậy đều nhỏ hơn 0. Khi sử dụng UI-Venus, độ lớn của chênh lệch giảm so với UGround, phù hợp với việc thang điểm của UI-Venus thấp hơn trên cả ba mô hình. Nhìn chung, phép

đánh giá chéo vẫn bảo toàn chiều của chênh lệch quan sát được.

5.10 Đánh giá chéo bằng mô hình listener thuộc họ kiến trúc khác

Các phép đánh giá ở những mục trước đều dựa trên bài toán định vị mở: mô hình nhận ảnh và câu hướng dẫn rồi trả về một tọa độ. Để kiểm tra xem thứ hạng giữa các hệ thống có còn được duy trì khi thay đổi cách đánh giá hay không, luận văn thực hiện thêm một phép đánh giá với Phi-4-multimodal-instruct [44], một mô hình ngôn ngữ thị giác không thuộc họ Qwen. Ở đây, Phi-4 đóng vai trò listener theo dạng lựa chọn. Mô hình nhận câu hướng dẫn cùng ảnh màn hình trong đó các phần tử tương tác đã được đánh số, sau đó chọn phần tử mà câu hướng dẫn đề cập tới. Các phần tử này được lấy từ cây trợ năng, khoanh vùng và đánh số theo phương pháp Set-of-Mark [45]; mỗi màn hình có trung vị 15 phần tử. Listener chỉ nhận ảnh đã đánh dấu và câu hướng dẫn, không được cung cấp mục tiêu của tác vụ hay lịch sử thao tác. Một dự đoán được tính là đúng khi phần tử được chọn chứa tọa độ chạm tham chiếu. Cách đánh giá này gần với *comprehension accuracy* trong các nghiên cứu về sinh biểu thức quy chiếu [11, 12], nhưng được áp dụng cho bài toán lựa chọn phần tử giao diện như trong Mind2Web [8]. Trong thiết lập của luận văn, Phi-4 không được huấn luyện hoặc tinh chỉnh trên AndroidControl.

Bảng 5.5: Tỉ lệ chọn đúng của mô hình listener dạng lựa chọn Phi-4 trên 4.463 bước chạm. Đoán ngẫu nhiên đạt 10,1%, và 95,7% số bước có ít nhất một ô chứa điểm chạm thật. Do giới hạn tài nguyên tính toán, mô hình gốc (Base) chỉ được đánh giá trên 3.566 bước. Giai đoạn thưởng tọa độ là một hướng đã thử (Phụ lục A).

Câu đưa cho mô hình listener	**Chọn đúng**	**KTC 95%**
Câu tham chiếu	54,9	[53,1; 56,8]
Giai đoạn thưởng tọa độ (giai đoạn ba)	45,8	[44,1; 47,5]
S1 (seed 101)	44,6	[42,9; 46,4]
Mô hình gốc (Base, 3.566 bước)	38,6	[36,7; 40,4]
Câu chung chung "*Tap the button.*"	15,9	[14,7; 17,0]

Bảng 5.5 cho thấy thứ hạng giữa các mô hình không thay đổi so với executability, quy tắc hộp phần tử và quy tắc khoảng cách Euclid (Mục 5.12). Nếu chuẩn hóa điểm theo khoảng từ mô hình gốc đến câu tham chiếu, mô hình sau giai đoạn thưởng tọa độ đạt khoảng 45–48% khoảng cải thiện này ở cả bốn cách đánh giá. So với S1 seed 101, mô hình đó cao hơn 1,14 điểm theo listener, với khoảng tin cậy 95% [+0,23; +2,10] và p = 0,020. Mức chênh lệch tương ứng là +0,96 điểm theo executability và +1,55 điểm theo quy tắc hộp phần tử.

Trong phép kiểm tra lặp lại trên 200 bước, mô hình listener cho kết quả hoàn toàn nhất quán giữa các lần chạy. Mức đồng thuận theo từng bước giữa listener và UGround ở mức vừa phải (κ từ 0,25 đến 0,44 tùy mô hình). Điều này cho thấy hai công cụ có thể đưa ra đánh giá khác nhau ở từng bước cụ thể nhưng vẫn duy trì cùng thứ hạng giữa các hệ thống.

Khoảng phân tách giữa câu tham chiếu và câu chung chung của listener là 39 điểm, hẹp hơn mức 63 điểm của executability. Một nguyên nhân có thể là listener chỉ nhận câu hướng dẫn và ảnh đã đánh số, không có thêm mục tiêu tác vụ hay lịch sử thao tác để hỗ trợ xác định phần tử. Vì vậy, kết quả của listener chỉ được sử dụng để kiểm tra thứ hạng và chiều của các chênh lệch, không được dùng làm chỉ số chính. Phương pháp đề xuất, S1 seed 202 và mô hình sau giai đoạn học ưu tiên chưa được đánh giá bằng listener này.

5.11 So sánh với các độ đo dựa trên câu tham chiếu

Để làm rõ hạn chế của việc đánh giá chỉ dựa trên một câu tham chiếu, luận văn khảo sát hai cách phổ biến: so khớp chuỗi và đo độ tương đồng ngữ nghĩa. Với cách thứ nhất, 97,5% các câu diễn đạt khác của cùng một nội dung bị xem là không khớp. Trường hợp "search bar" và "magnifying glass" là một ví dụ: hai cụm từ không có từ chung nhưng vẫn có thể cùng chỉ tới một phần tử trên màn hình.

Phép thử thứ hai được thực hiện trên 51 trường hợp viết tay gồm các cặp cùng phần tử và khác phần tử. Độ tương đồng ngữ nghĩa đạt AUC 0,336 trên tập thử nghiệm này. Cặp `inbox` và `outbox`, dù chỉ hai phần tử khác nhau, có điểm 0,76; trong khi `search` và `magnifying glass`, hai cách gọi có thể quy chiếu cùng một phần tử,

chỉ đạt 0,55. Kết quả này cho thấy trên 51 trường hợp được khảo sát, mức gần nhau về ngữ nghĩa không biến thiên cùng chiều với quan hệ quy chiếu và không quan sát được một ngưỡng điểm có khả năng phân tách đáng tin cậy hai nhóm. Kết luận này chỉ áp dụng cho phép thử nêu trên, không được dùng để suy rộng rằng mọi mô hình nhúng ngữ nghĩa đều có cùng hành vi.

Hai phép thử trên minh họa hai hạn chế cơ bản của việc so với một câu tham chiếu. Trên đầu ra thực tế của các mô hình, hiện tượng tương tự vẫn xuất hiện: trong những câu được executability chấp nhận, 52,8% số câu của mô hình chưa tinh chỉnh có F1 trên các từ nội dung so với câu tham chiếu dưới 0,5, so với 13,9% ở mô hình đã tinh chỉnh. Tinh chỉnh làm cách diễn đạt gần hơn với văn phong của người chú thích, nên độ đo dựa trên câu tham chiếu có thể tạo mức phạt khác nhau do khác biệt về cách diễn đạt, thay vì chỉ phản ánh khả năng xác định phần tử.

Bảng 6.1 ở Chương 6 có thêm BLEU-4 [20], tính cho từng câu rồi lấy trung bình, và ROUGE-L [21], F1 của chuỗi con chung dài nhất. Với ba loại câu có chất lượng khác biệt rõ rệt (câu của mô hình gốc, của S1 và câu tham chiếu), hai độ đo này và executability cho cùng thứ hạng. Vì vậy, các độ đo dựa trên câu tham chiếu vẫn có thể phản ánh những khác biệt lớn giữa các mô hình.

Tuy nhiên, các độ đo dựa trên câu tham chiếu có hai hạn chế trong thiết lập này. Thứ nhất, chúng không cho biết dư địa còn lại. Câu tham chiếu đạt 100 điểm theo ROUGE-L và 96,1 điểm theo BLEU-4 (phần thiếu hoàn toàn do 176 câu tham chiếu ngắn hơn bốn token), trong khi executability của câu tham chiếu là 75,7 và cho phép xác định những bước còn chưa đạt. Thứ hai, các độ đo này không xếp hạng nhất quán những mô hình có kết quả gần nhau. Trong nhóm mô hình đã tinh chỉnh có executability từ 57,2 đến 60,0, ba độ đo cho ba thứ hạng khác nhau (Bảng 6.1). Executability xếp giai đoạn học ưu tiên cao nhất; BLEU-4 xếp mô hình này dưới cả hai seed của S1; còn ROUGE-L xếp mô hình học thêm có giám sát cao nhất (hai hướng đã thử ở Phụ lục A). Đây đều là những khác biệt dưới hai điểm, vùng mà Zhao và cộng sự [37] chỉ ra rằng độ đo dựa trên câu tham chiếu có độ tin cậy hạn chế.

5.12 Độ nhạy của kết luận theo quy tắc đánh giá

Giá trị tuyệt đối của điểm số phụ thuộc vào quy tắc dùng để xác định một dự đoán đúng. Khi đánh giá lại câu tham chiếu, S1 và mô hình gốc trên 698 bước theo năm quy tắc khác nhau, điểm tuyệt đối thay đổi tới 26 điểm (Bảng 5.6), nhưng thứ hạng giữa các mô hình vẫn được duy trì. Chênh lệch S1–Base dao động từ 9,5 đến 13,0 điểm và luôn lớn hơn đáng kể sai số chuẩn ghép cặp (Mục 5.13).

Bảng 5.6: Điểm của câu tham chiếu và chênh lệch giữa S1 với mô hình gốc theo năm quy tắc đánh giá (698 bước): đĩa Euclid, hình chữ nhật theo từng trục, ô Voronoi, ô Voronoi lấy hạt là tâm hộp chứa *g*, và hộp gần nhất.

	Đĩa	**Chữ nhật**	**Voronoi**	**Voronoi (hạt tâm hộp)**	**Hộp gần nhất**
Câu tham chiếu	80,2	82,2	74,2	56,6	82,2
S1 − mô hình gốc (Base)	+12,6	+13,0	+11,7	+9,5	+13,0

Ảnh hưởng đến kết luận thống kê. Việc thay đổi quy tắc đánh giá có thể dẫn tới kết luận thống kê khác nhau. Bảng dưới đây so sánh mô hình sau giai đoạn thưởng tọa độ (một hướng đã thử, Phụ lục A) với S1 seed 101 trên 4.463 bước theo ba quy tắc đều yêu cầu đúng loại thao tác; giá trị p được hiệu chỉnh Holm cho ba kiểm định.

Quy tắc	**Δ**	**p**	**Sau hiệu chỉnh Holm**
Cửa sổ ± 14% từng trục	+2,13	0,0003	giữ ý nghĩa
Khoảng cách Euclid (AndroidInTheWild)	+1,99	0,0010	giữ ý nghĩa
Ô Voronoi (executability)	+0,96	0,0860	mất ý nghĩa

Sự khác biệt giữa các kết luận bắt nguồn từ mức độ chặt của từng quy tắc. Executability yêu cầu câu dẫn tới đúng phần tử khi có các phần tử lân cận cạnh tranh, trong khi quy tắc dung sai chấp nhận mọi điểm đủ gần tọa độ tham chiếu. Vì vậy, các câu chứa ít thông tin quy chiếu có xu hướng nhận điểm cao hơn theo quy tắc dung sai; chẳng hạn câu chung chung "*Tap the button.*" đạt 12,00 với executability nhưng 20,50 theo quy tắc dung sai. Do đó, luận văn trình bày song song kết quả theo nhiều quy tắc;

hai quy tắc có tiền lệ trong các công trình trước được báo cáo như các chỉ số bổ sung bên cạnh executability.

Ảnh hưởng của lỗi chuẩn hoá loại thao tác. Như đã nêu ở Mục 5.1, cách chuẩn hoá cũ xếp *go back*, *navigate back* và *press the back button* vào lớp chạm. Khi sửa riêng lỗi này, điểm của S1 giảm từ 59,12 xuống 58,81 và của Base từ 47,60 xuống 47,40; chênh lệch S1–Base đổi từ 11,52 thành 11,41 điểm. Các bảng chính vẫn dùng cách chuẩn hoá cũ để giữ nhất quán với kết quả đã báo cáo.

Quy tắc hộp phần tử của AndroidControl. Phụ lục D.3 của bài gốc AndroidControl [1] coi một dự đoán là đúng khi tọa độ nằm trong hộp bao của phần tử cần chạm, vì chạm vào đâu trong phần tử thì phần tử cũng kích hoạt; chúng tôi gọi đây là quy tắc hộp phần tử. Hộp bao có sẵn trong nhãn của tập kiểm tra, nên quy tắc này tính được từ các điểm mô hình định vị đã trả về (Bảng 5.7).

Bảng 5.7: Điểm theo quy tắc hộp phần tử (Phụ lục D.3 của AndroidControl) trên 4.463 bước. Giai đoạn học ưu tiên và mô hình chọn ứng viên là hai hướng đã thử (Phụ lục A). Cột cuối yêu cầu thêm điều kiện điểm dự đoán nằm trong cửa sổ dung sai 14%. Hai hàng cuối là các mốc tham chiếu dưới, được tính trên mẫu 800 bước.

	Ô Voronoi	**Hộp phần tử**	**Hộp phần tử ∧ cửa sổ 14%**
Câu tham chiếu	75,7	83,8	79,2
Giai đoạn học ưu tiên (MIN-DESC)	60,0	66,5	62,7
S1 (seed 101)	59,1	65,5	61,7
Mô hình chọn ứng viên (Mục A.3.2)	56,1	62,4	58,6
Mô hình gốc (Base)	47,6	53,6	49,8
Câu chung chung (mốc dưới, mẫu 800)	12,0	14,1	12,1
Câu của màn hình khác (mốc dưới, mẫu 800)	6,1	8,6	6,6

Thứ hạng giữa các mô hình không thay đổi, và chênh lệch giữa S1 với mô hình gốc là 11,9 điểm, gần tương đương mức chênh theo quy tắc ô Voronoi. Trên mẫu 800 bước, điểm của câu tham chiếu tăng từ 74,9 lên 83,0 khi sử dụng quy tắc hộp phần tử, trong khi các câu dùng làm mốc dưới tăng ít hơn. Khác biệt này liên quan đến việc

dung sai phụ thuộc vào kích thước phần tử; xét theo chiều dọc, chiều cao trung vị của hộp chỉ bằng 5,2% màn hình, chặt hơn đáng kể so với cửa sổ 14%.

Điểm 83,8 của câu tham chiếu cần được diễn giải cùng hai lưu ý. Hộp được suy ra từ cây trợ năng bằng cách chọn nút nhỏ nhất chứa điểm chạm, nên ở khoảng 48% số bước hộp nhỏ hơn phần tử thực tế; đồng thời, 78% mức tăng so với ô Voronoi đến từ các bước có hộp rộng hơn nửa màn hình. Vì vậy, kết quả theo hai quy tắc được báo cáo song song khi trình bày các kết quả chính. Quy tắc hộp phần tử cũng cho thấy ô Voronoi có thể quá chặt đối với các hàng danh sách. Trong 417 bước mà câu tham chiếu không đạt quy tắc ô Voronoi nhưng đạt quy tắc hộp, khoảng một nửa bị loại vì điểm dự đoán nằm gần một mảnh chữ do OCR tách ra trên cùng hàng và mảnh chữ này bị xem là một phần tử cạnh tranh trong E (Mục 7.2).

Quy tắc khoảng cách Euclid của AndroidInTheWild. Quy tắc thứ hai được lấy từ mã đánh giá gốc của AndroidInTheWild [2], một bộ dữ liệu điều khiển thiết bị Android được sử dụng trong nhiều nghiên cứu về tác tử giao diện. Hai lần chạm được xem là trùng nhau khi khoảng cách Euclid giữa hai điểm, trên hệ tọa độ chuẩn hoá về [0; 1], không vượt quá 0,14, hoặc khi cả hai điểm cùng nằm trong một khung phần tử được nới thêm 1,4 lần theo cả chiều cao và chiều rộng; luận văn bổ sung điều kiện đúng loại thao tác. Mã gốc xét mọi khung chú thích trên màn hình, trong khi dữ liệu của luận văn chỉ có khung của phần tử cần chạm, nên biến thể xấp xỉ này chỉ có thể cho điểm không cao hơn quy tắc gốc. Trên mẫu 800 bước, khoảng điểm giữa câu tham chiếu (90,8) và mốc dưới tương ứng là 64,9 điểm, rộng hơn mức 62,9 của executability. Tuy vậy, quy tắc này ít nhạy hơn với việc thiếu tên phần tử: câu bỏ tên nhưng giữ vị trí chỉ thấp hơn câu tham chiếu 4,5 điểm, so với 6,9 điểm khi đánh giá bằng executability (Mục 5.6.1). Vì vậy, quy tắc khoảng cách Euclid được báo cáo song song với executability thay vì thay thế độ đo chính; điểm của từng mô hình được trình bày ở Bảng 6.5.

Cận trên của quy tắc khoảng cách Euclid. Ở biến thể còn lại, phép xét khung được mở rộng tới mọi phần tử có thể chạm trên màn hình, lấy từ cây trợ năng và chỉ giữ các khung chiếm không quá nửa màn hình; do đó quy tắc gốc nằm giữa hai biến thể. Với biến thể cận trên, câu tham chiếu đạt 96,2% nhưng câu chung chung cũng tăng lên 41,6 (mẫu 800 bước), nên khoảng phân tách chỉ còn 54,3 điểm, hẹp hơn cả

executability. Vì vậy, kết quả theo quy tắc khoảng cách Euclid được trình bày dưới dạng khoảng giữa hai biến thể, trong đó cận dưới được sử dụng làm giá trị chính.

5.13 Phương pháp phân tích thống kê

Điểm. Điểm là tổng số bước đúng chia tổng số bước.

Khoảng tin cậy. Khoảng tin cậy được ước lượng bằng bootstrap phi tham số với 10.000 lần lấy mẫu, trong đó đơn vị lấy mẫu là cụm ứng dụng. Ở mỗi lần lặp, các cụm được lấy mẫu lại có hoàn lại, sau đó điểm số được tính lại; khoảng tin cậy được xác định từ các phân vị của phân bố thu được. Cameron và cộng sự [27] cho thấy cách tính này có thể có độ phủ thấp hơn mức danh nghĩa khi số cụm ít, nên số cụm được báo cáo cùng các khoảng tin cậy.

Quy tắc gom cụm. Bước không quy được về ứng dụng thì mỗi tác vụ là một cụm riêng, để không gộp các tác vụ không liên quan chỉ vì cùng thiếu nhãn ứng dụng. Tổng cộng có 1.091 cụm, cụm lớn nhất gồm 58 bước; vì cỡ cụm rất khác nhau, số cụm hiệu dụng theo công thức Kish [28] (số cụm có đều cho cùng độ chính xác) chỉ là 454,3. Cách gom cụm này không làm thay đổi kết luận: khoảng tin cậy của mức chênh lệch giữa S1 và mô hình gốc là [+10,0; +13,1], giống hệt khi gom mọi bước theo tác vụ (1.345 cụm), và là [+10,2; +13,8] khi dồn mọi bước không nhãn vào một cụm (260 cụm). Nếu chỉ giữ 40,7% số bước quy được ứng dụng, số cụm hiệu dụng còn 107 và công suất thống kê giảm mạnh.

So sánh ghép cặp. Mọi mô hình được đánh giá trên cùng 4.463 bước nên các chênh lệch được phân tích theo cặp. Mỗi cặp mô hình được báo cáo bằng khoảng tin cậy ghép cặp và giá trị p của kiểm định McNemar (Mục 4.8), chỉ dựa trên các bước hai mô hình cho kết quả khác nhau, với b là số bước mô hình thứ nhất đạt còn mô hình thứ hai không đạt và c là chiều ngược lại. Hệ số nở do gom cụm, tức mức phóng to độ bất định do các bước cùng cụm tương quan, là 1,10 trong phép tính hiện tại. Như một minh hoạ cho lợi ích của ghép cặp, sai số chuẩn của hiệu S1–Base là 0,79 điểm, so với 1,05 điểm nếu tính như hai tỉ lệ độc lập. Mức dao động khi chỉ huấn luyện lại với seed khác không thuộc sai số của độ đo và được phân tích riêng ở Mục 6.7.

Đánh giá ở bước không chạm. Executability chỉ áp dụng cho các bước chạm,

trong khi 35,9% số bước của tập kiểm tra thuộc các loại thao tác khác (cuộn, chờ, gõ, mở ứng dụng và quay lại). Một mô hình có thể cải thiện điểm trên bước chạm do thiên về cách diễn đạt thao tác chạm nhưng đồng thời suy giảm ở các bước còn lại mà độ đo chính không phản ánh. Vì vậy, các mô hình được huấn luyện thêm còn được kiểm tra trên nhóm bước này bằng tỉ lệ khớp loại thao tác, sử dụng cùng hàm chuẩn hoá thao tác của độ đo chính. Kết quả của các hướng đã thử được trình bày ở Mục A.2.2.4.

Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả thực nghiệm của phương pháp đề xuất trên tập kiểm tra. Mục 6.2 trước hết đưa ra kết quả tổng thể, sau đó Mục 6.3 và Mục 6.4 phân tích riêng đóng góp của từng thành phần. Các mục tiếp theo xem xét độ ổn định của kết quả, so sánh nhiều nhóm độ đo và phân tích những hành vi đáng chú ý của mô hình. Những phương án thiết kế đã được khảo sát trước khi hình thành phương pháp cuối cùng được tóm tắt ở Mục 6.10 và trình bày chi tiết trong Phụ lục A.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên cùng 4.463 bước chạm của tập kiểm tra bằng cùng một quy trình đánh giá. Phương pháp đề xuất gồm mô hình học tăng cường với phần thưởng SPICE để sinh câu hướng dẫn ban đầu và ACE để quyết định có hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ hay không (Mục 4.4 đến Mục 4.6).

Ba mốc so sánh (Mục 4.7) gồm mô hình gốc (Base), mô hình tinh chỉnh có giám sát với hai seed 101 và 202 (S1), và câu tham chiếu được đưa trực tiếp vào quy trình đánh giá làm mốc tham chiếu để diễn giải thang điểm. Ở một bước, S1 trả về câu rỗng; bước này được tính là không đạt và vẫn nằm trong mẫu số 4.463.

6.2 Kết quả chính

† Mô hình chọn ứng viên khác các mô hình còn lại ở ba yếu tố của thiết lập (Mục A.3.1), nên chỉ có thể so sánh trực tiếp với mô hình gốc (Mục A.3.2). Các hướng đã thử khác

Bảng 6.1: Kết quả chính trên 4.463 bước chạm của tập kiểm tra. Exec. là executability, KTC 95% là khoảng tin cậy 95% của executability. Hộp phần tử là quy tắc của AndroidControl, khoảng cách Euclid là quy tắc của AndroidInTheWild. BLEU-4 là trung bình theo câu, ROUGE-L theo F1. Số in đậm là số cao nhất của cột, không tính hàng câu tham chiếu.

Mô hình	Exec.	KTC 95%	Hộp phần tử	Khoảng cách Euclid	BLEU-4	ROUGE-L
Mốc so sánh						
Mô hình gốc (Base)	47,6	[45,9; 49,3]	53,6	63,4	9,9	40,4
Tinh chỉnh có giám sát (S1), seed 101	59,1	[57,3; 60,8]	65,5	74,4	38,7	67,3
Tinh chỉnh có giám sát (S1), seed 202	59,6	[57,9; 61,3]	66,1	75,3	39,0	67,6
Phương pháp đề xuất						
Thành phần thứ nhất (phần thưởng SPICE)	60,6	[58,9; 62,4]	67,0	76,2	40,1	68,3
Cả hai thành phần (SPICE + ACE)	**60,7**	[58,9; 62,4]	**67,1**	76,3	**41,2**	**69,1**
Các hướng đã thử (Phụ lục A)						
Mô tả phần tử (S2)	57,2	[55,4; 58,9]	63,6	73,4	36,4	65,9
Học thêm có giám sát (CE2-S2)	59,4	[57,7; 61,1]	66,0	76,1	38,1	68,6
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	[58,3; 61,8]	66,5	76,4	37,9	68,4
Thưởng tọa độ (giai đoạn ba)	60,1	[58,3; 61,8]	67,0	**77,3**	37,8	68,5
Chọn ứng viên†	56,1	[54,2; 58,0]	62,4	71,2	34,5	63,0
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	[58,5; 62,0]	66,4	76,1	40,1	68,4
Câu tham chiếu (mốc tham chiếu)	75,7	[74,1; 77,3]	83,8	92,1	96,1	100,0

(mô-đun định vị, đưa vai trò và vùng của phần tử vào mô hình, làm nét ảnh, mở khoá phần thị giác) không xuất hiện trong bảng vì chỉ được đánh giá trên tập kiểm định nội bộ (Mục A.6).

Kết quả ở Bảng 6.1 cho thấy phương pháp đề xuất đạt 60,7% executability, cao hơn S1/101 1,57 điểm. Khoảng tin cậy 95% của chênh lệch là [+0,86; +2,31], hoàn toàn nằm trên 0. Phương pháp cũng đạt kết quả cao nhất trong bảng theo quy tắc hộp phần tử và hai độ đo văn bản được báo cáo. Riêng với quy tắc khoảng cách Euclid, giai đoạn thưởng tọa độ đạt điểm cao hơn.

Mức cải thiện về executability chủ yếu đến từ thành phần thứ nhất: mô hình học tăng cường với phần thưởng SPICE đạt 60,6% (Mục 6.3). Khi ACE được bổ sung, executability gần như được giữ nguyên, trong khi các độ đo dựa trên câu tham chiếu tiếp tục tăng (Mục 6.4). Để làm rõ nguồn gốc của chênh lệch giữa các mô hình, Bảng 6.2 phân rã executability theo ba điều kiện cấu thành.

Ở hàng câu tham chiếu, đầu vào đánh giá chính là câu tham chiếu nên điều kiện khớp loại thao tác luôn được thỏa mãn. Tỉ lệ khớp thao tác 98,9% của giai đoạn học theo cặp ưu tiên, mô hình học thêm có giám sát và giai đoạn thưởng tọa độ chỉ được tính trên các bước chạm; vì vậy, kết quả này cần được xem cùng mức suy giảm trên các bước không chạm (Mục A.2.2.4). Mô hình chọn ứng viên (†) chỉ có thể so sánh trực tiếp với mô hình gốc (Mục A.3.2); tỉ lệ khớp thao tác của mô hình này thấp nhất bảng vì ở những bước không chọn được phần tử trong danh sách ứng viên, mô hình thường sinh câu mô tả một thao tác không chạm.

Khoảng cách giữa các mức tham chiếu. S1 cải thiện 11,5 điểm executability so với mô hình gốc, trong khi vẫn thấp hơn câu tham chiếu 16,6 điểm. Khoảng cách này cho thấy phép đánh giá ghi nhận rõ lợi ích của tinh chỉnh có giám sát và vẫn còn dư địa đáng kể cho các phương pháp tiếp theo (Mục 5.5, Mục 6.9.4).

Bảng 6.2: Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). Đạt đầy đủ: thoả cả ba điều kiện của executability. Chỉ ô Voronoi: điểm định vị nằm trong cửa sổ dung sai và trong ô Voronoi của phần tử cần chạm, chưa xét loại thao tác. Khớp thao tác: câu gọi đúng loại thao tác. Cửa sổ dung sai: điểm định vị nằm trong cửa sổ $\pm$14% theo từng trục quanh điểm chạm chuẩn.

Mô hình	Đạt đầy đủ	Chỉ ô Voronoi	Khớp thao tác	Cửa sổ dung sai
Câu tham chiếu (mốc tham chiếu)	75,7	75,8	100,0	84,3
Phương pháp đề xuất	60,7	61,5	96,0	70,4
Thành phần thứ nhất	60,6	61,4	96,0	70,3
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	61,0	96,6	70,1
Thưởng tọa độ (giai đoạn ba)	60,1	60,5	98,9	69,9
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	60,4	98,9	69,2
S1 (seed 202)	59,6	60,7	94,6	69,8
Học thêm có giám sát (CE2-S2)	59,4	59,8	98,9	68,9
S1 (seed 101)	59,1	60,2	94,4	69,2
Mô tả phần tử (S2)	57,2	58,1	94,8	67,4
Chọn ứng viên†	56,1	57,4	90,9	66,3
Mô hình gốc (Base)	47,6	48,9	96,5	57,6

6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Mục này đánh giá độc lập thành phần thứ nhất (thiết kế ở Mục 4.5). Mô hình học tăng cường với phần thưởng SPICE học tiếp từ S1 seed 101, nên được so sánh trực tiếp với cấu hình này.

Phân tích tín hiệu phần thưởng trên tập kiểm định nội bộ. Trước khi huấn luyện, S1 được dùng để sinh một câu bằng giải mã tham lam và tám câu bằng lấy mẫu cho mỗi bước. Nếu chọn câu có SPICE cao nhất so với câu tham chiếu, executability cao hơn so với câu từ giải mã tham lam; trong khi đó, việc chọn ngẫu nhiên một trong tám câu không tạo ra xu hướng tương tự. Executability cũng có xu hướng giảm ở những câu có thứ hạng SPICE thấp hơn trong cùng một nhóm. Dù vậy, SPICE không phân biệt được mọi trường hợp: ở khoảng một phần ba số cặp gồm một câu dẫn tới đúng phần tử và một câu không, hai câu nhận cùng điểm. Vì thế, kết quả trên tập kiểm định nội bộ chỉ cho thấy SPICE cung cấp một tín hiệu phân biệt hữu ích cho quá trình phát triển, chứ không phải một tiêu chí hoàn hảo. Các kết quả này chỉ được dùng để lựa chọn thiết kế và không được báo cáo như kết quả chính của luận văn.

Lựa chọn checkpoint. Checkpoint ở bước 250 và 500 được so sánh trên cùng tập kiểm định nội bộ. Mức tăng SPICE của cả hai đều nhỏ, trong khi executability tăng theo số bước; các bước chuyển từ sai sang đúng ở checkpoint 250 so với S1 tiếp tục được dự đoán đúng ở checkpoint 500. Trên cơ sở đó, checkpoint 500 được chọn và cố định trước khi sinh câu trên tập kiểm tra.

6.3.1 Kết quả trên bước chạm

Mô hình học tăng cường với phần thưởng SPICE đạt điểm cao hơn S1 trên cả mười ba độ đo trong Bảng 6.3. Với sáu độ đo dựa trên vị trí, khoảng tin cậy của chênh lệch đều nằm hoàn toàn trên 0. Riêng executability tăng 1,55 điểm, với $p = 1{,}6 \times 10^{-5}$ theo kiểm định McNemar (Mục 6.6). Đây là cấu hình đầu tiên trong các thí nghiệm của luận văn cho thấy mức cải thiện có ý nghĩa thống kê so với S1 theo executability. Một điểm đáng chú ý là phần thưởng huấn luyện chỉ dựa trên SPICE và không sử dụng mô

Bảng 6.3: Mô hình học tăng cường với phần thưởng SPICE so với S1 seed 101 trên 4.463 bước chạm, ghép cặp theo bước. Sáu hàng trên là độ đo theo vị trí (gồm cả tỉ lệ đúng loại thao tác), bảy hàng dưới là độ đo so với câu tham chiếu. Δ là điểm của mô hình học tăng cường với phần thưởng SPICE trừ điểm của S1; KTC 95% từ bootstrap gom cụm theo ứng dụng (Mục 5.13). Sai→Đúng là số bước mà mô hình học tăng cường đạt còn S1 không đạt; Đúng→Sai là chiều ngược lại.

Độ đo	**S1**	**Phần thưởng SPICE**	**Δ**	**KTC 95%**	**Sai→Đúng / Đúng→Sai**
Executability	59,11	60,65	+1,55	[+0,80; +2,33]	159 / 90
Quy tắc hộp phần tử	65,49	67,02	+1,52	[+0,77; +2,29]	165 / 97
Quy tắc khoảng cách Euclid	74,37	76,25	+1,88	[+1,17; +2,63]	172 / 88
Euclid cận trên	81,04	82,90	+1,86	[+1,17; +2,60]	163 / 80
±14% theo trục	67,24	68,90	+1,66	[+0,90; +2,46]	172 / 98
Đúng loại thao tác	94,35	95,97	+1,61	[+1,17; +2,08]	83 / 11
SPICE	44,37	45,79	+1,42		
BLEU-4	51,56	52,36	+0,80		
METEOR	36,79	37,92	+1,13		
ROUGE-L	67,35	68,36	+1,01		
CIDEr-D	416,12	430,05	+13,93		
chrF	61,26	62,87	+1,61		
BERTScore	66,33	67,07	+0,74		

hình định vị, nhưng các độ đo dựa trên vị trí vẫn tăng đồng thời.

Phân rã nguồn gốc mức cải thiện. Trong 159 bước chuyển từ sai sang đúng, 36 bước là những trường hợp S1 dự đoán sai loại thao tác. Ở chiều ngược lại, trong 90 bước chuyển từ đúng sang sai, chỉ 8 bước xuất phát từ lỗi loại thao tác của mô hình học tăng cường. Như vậy, việc sửa loại thao tác đóng góp ròng 28 bước, tương đương +0,63 điểm. Phần cải thiện còn lại đến từ 4.200 bước mà cả hai mô hình đều xác định đúng loại thao tác: trên nhóm này, executability tăng từ 62,62 lên 63,60, tương đương thêm 41 bước đúng (+0,92 điểm). Nói cách khác, hơn một nửa mức cải thiện quan sát được xuất hiện ở khả năng xác định đúng phần tử cần chạm sau khi loại thao tác đã được dự đoán đúng.

So với S1, mô hình học tăng cường chỉ thay đổi một phần đầu ra: 2.795 trong 4.463 câu được giữ nguyên hoàn toàn, còn độ dài trung bình chỉ tăng từ 7,83 lên 7,96 từ. Vì vậy, mức cải thiện không thể giải thích đơn thuần bằng việc sinh câu dài hơn (Hình 6.1).

So sánh với các cấu hình khác. Mức cải thiện vẫn được duy trì khi so với S1 được huấn luyện với seed 202 (+1,03 điểm; p = 0,014), cho thấy chênh lệch dương không chỉ xuất hiện khi so với lượt huấn luyện seed 101. So với hai hướng thử có executability cao nhất là giai đoạn thưởng tọa độ và giai đoạn học theo cặp ưu tiên, chênh lệch khoảng 0,6 điểm và chưa có ý nghĩa thống kê (Bảng 6.8). Giai đoạn thưởng tọa độ có ưu thế ở tỉ lệ đúng loại thao tác và một số quy tắc vị trí lỏng hơn, trong khi mô hình học tăng cường với phần thưởng SPICE đạt executability cao hơn và cao hơn ở sáu trong bảy độ đo dựa trên câu tham chiếu.

6.3.2 Độ ổn định của kết quả

Mức cải thiện có cùng chiều trên toàn bộ các độ đo được báo cáo và vẫn dương khi so với cả hai lượt huấn luyện S1. Các cấu hình đối chứng bổ sung để tách riêng ảnh hưởng của học tăng cường được dành cho phần mở rộng của thí nghiệm.

6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Trên tập kiểm tra, quy tắc đồng thuận của ACE (Mục 4.6) thay thế 402 trong 4.463 câu hướng dẫn ban đầu (9,0%). Bảng 6.4 so sánh ACE, tức phương pháp đề xuất, với câu hướng dẫn ban đầu và với mô hình sinh câu độc lập, trong đó đầu ra của mô hình sinh được sử dụng ở mọi bước.

Khả năng của kho truy hồi. Với mỗi bước chạm trong tập kiểm tra, bốn câu tham chiếu gần nhất được truy hồi từ tập huấn luyện theo quy trình ở Mục 4.6. Trong 15,8% số bước, ít nhất một câu ví dụ trùng nguyên văn với câu tham chiếu của bước đang xét. Ở 9,8% số bước, điều này xảy ra đồng thời với việc câu hướng dẫn ban đầu của thành phần thứ nhất không đạt. Nếu luôn có thể nhận ra và chọn đúng câu ví dụ trong các trường hợp này, BLEU-4 tính trên toàn tập có thể tăng khoảng 5 điểm và CIDEr-D khoảng 65 điểm. Tuy nhiên, một chiến lược đơn giản như luôn lấy câu ví dụ đứng đầu lại làm BLEU-4 giảm từ 52,4 xuống 28,3. Kết quả này cho thấy kho truy hồi có chứa thông tin hữu ích, nhưng việc khai thác thông tin đó phụ thuộc vào cơ chế lựa chọn câu ví dụ. Phân tích này được dùng để giải thích vai trò của quy tắc đồng thuận, không thay thế kết quả đánh giá trực tiếp của ACE.

Kết quả. So với câu hướng dẫn ban đầu, ACE làm tăng cả bảy độ đo dựa trên câu tham chiếu, trong đó mức tăng rõ nhất xuất hiện ở CIDEr-D (+11,98) và SPICE (+1,34). Ngược lại, ba độ đo dựa trên vị trí hầu như không thay đổi. Trong 402 câu được thay thế, có 15 bước chuyển từ sai sang đúng và 14 bước chuyển theo chiều ngược lại ($p = 1,0$). Vì vậy, ACE gần như giữ nguyên mức executability mà thành phần thứ nhất đã đạt được, đồng thời làm câu đầu ra gần hơn với câu tham chiếu theo các độ đo văn bản. Theo quy tắc hộp phần tử và quy tắc khoảng cách Euclid, phương pháp hoàn chỉnh cao hơn S1 lần lượt 1,61 và 1,95 điểm; cả hai chênh lệch đều có $p < 0,001$.

Ảnh hưởng khi sử dụng mô hình sinh câu độc lập. Mô hình sinh câu độc lập đạt điểm cao hơn câu hướng dẫn ban đầu trên năm trong bảy độ đo dựa trên câu tham chiếu, nhưng thấp hơn 1,25 điểm executability $[-2,06; -0,44]$ ($p = 0,002$). Ở 19,1% số bước, mô hình sao chép nguyên văn một câu ví dụ; 43,5% số câu sao chép trùng câu tham chiếu, gần gấp đôi tỉ lệ của câu hướng dẫn ban đầu (22,8%). Ngược lại, ở

Bảng 6.4: ACE trên 4.463 bước chạm, so với câu hướng dẫn ban đầu (của mô hình học tăng cường với phần thưởng SPICE) và với mô hình sinh câu độc lập. Ba độ đo vị trí kèm khoảng tin cậy 95% từ bootstrap gom cụm theo ứng dụng. Bảy độ đo dựa trên câu tham chiếu chưa có khoảng tin cậy; cột ACE − câu hướng dẫn ban đầu lệch tối đa 0,02 so với Bảng 6.3 do được đánh giá lại.

Độ đo	Câu ban đầu	Mô hình sinh độc lập	ACE	ACE − câu ban đầu
Executability	60,65	59,40	60,68	+0,02 [−0,21; +0,26]
Quy tắc hộp phần tử	67,02	65,81	67,11	+0,09 [−0,15; +0,33]
Quy tắc khoảng cách Euclid	76,25	75,02	76,32	+0,07 [−0,15; +0,29]
BLEU-4	52,36	53,47	53,47	+1,11
METEOR	37,91	37,79	38,37	+0,46
ROUGE-L	68,34	68,67	69,08	+0,74
CIDEr-D	430,04	437,54	442,02	+11,98
SPICE	45,79	46,79	47,13	+1,34
chrF	62,86	62,65	63,44	+0,58
BERTScore	67,07	67,52	67,73	+0,66

những bước mô hình tự sinh câu mới, kết quả thấp hơn câu hướng dẫn ban đầu. Kết quả này cho thấy truy hồi có ích khi mô hình lựa chọn đúng câu ví dụ, nhưng việc thay câu hướng dẫn ban đầu cần đi kèm điều kiện lựa chọn.

Đóng góp của ràng buộc nhất quán loại thao tác. Nếu chỉ dùng điều kiện sao chép, quy tắc thay 453 câu và vẫn cải thiện cả bảy độ đo dựa trên câu tham chiếu, nhưng executability thấp hơn câu hướng dẫn ban đầu 0,11 điểm (24 bước chuyển từ sai sang đúng và 29 bước chuyển từ đúng sang sai). Ràng buộc loại thao tác loại 51 câu không nhất quán, nhờ đó ACE cao hơn biến thể chỉ dùng điều kiện sao chép 0,13 điểm executability và không thấp hơn ở độ đo nào trong Bảng 6.4.

Phạm vi cải thiện. Lợi ích của ACE tập trung ở các độ đo văn bản: cả bảy độ đo dựa trên câu tham chiếu đều tăng, trong khi executability được duy trì gần như không đổi. Kết quả này cho thấy ACE đóng vai trò bổ sung cho thành phần học tăng cường, cải thiện mức tương đồng với câu tham chiếu mà không đánh đổi khả năng định vị. Khoảng tin cậy của nhóm độ đo văn bản chưa được ước lượng; đây là nội dung cần bổ sung trong các phân tích tiếp theo.

6.5 Đánh giá trên nhiều nhóm độ đo

Ngoài executability, luận văn trình bày thêm hai nhóm chỉ số: các độ đo dựa trên vị trí và các độ đo dựa trên câu tham chiếu. Cả hai nhóm được tính lại từ bản ghi ở mức từng bước của các lượt đánh giá trong Bảng 6.1. Hai bảng trong mục này chưa bao gồm hàng của phương pháp đề xuất; kết quả tương ứng được trình bày tại Bảng 6.1 và Bảng 6.4.

Bảng 6.5: Nhóm độ đo theo vị trí trên đủ 4.463 bước chạm, tính lại từ bản ghi từng bước, không gọi lại mô hình định vị. Khoảng cách Euclid là quy tắc khoảng cách Euclid trong mã đánh giá gốc của AndroidInTheWild; khoảng cách Euclid cận trên là biến thể của quy tắc này khi xét khung của mọi phần tử có thể thao tác trên màn hình (Mục 5.12). Hộp phần tử là quy tắc khớp gốc của AndroidControl. Exec. là executability (Mục 5.12). Thao tác là tỉ lệ gọi đúng loại thao tác. Số in đậm là số cao nhất trong các mô hình ở cột đó. *Phần thưởng SPICE là thành phần thứ nhất của phương pháp đề xuất, học tiếp từ S1 (101) bằng GRPO với phần thưởng SPICE; TAGE là mô-đun hiệu chỉnh câu đã thử đặt sau thành phần đó (Mục 6.3 và A.7.2). Bảng chưa có hàng của phương pháp đề xuất; kết quả của phương pháp này được trình bày ở Bảng 6.4. †Mô hình chọn ứng viên khác ba yếu tố thiết lập so với các mô hình còn lại nên chỉ có thể so sánh trực tiếp với Base.

Mô hình	Euclid	Hộp phần tử	Exec.	±14% trục	Euclid cận trên	Thao tác
Base	63,4	53,6	47,6	55,9	73,4	96,5
S1 (101)	74,4	65,5	59,1	67,2	81,0	94,3
S1 (202)	75,3	66,1	59,6	67,9	81,9	94,6
S2	73,4	63,6	57,2	65,7	80,8	94,8
CE2-S2	76,1	66,0	59,4	68,5	83,9	**98,9**
MIN-DESC	76,4	66,5	60,0	68,7	84,4	**98,9**
Giai đoạn ba	**77,3**	**67,0**	60,1	**69,4**	**85,0**	**98,9**
Phần thưởng SPICE*	76,2	**67,0**	**60,6**	68,9	82,9	96,0
TAGE	76,1	66,4	60,2	68,7	82,7	96,6
Chọn ứng viên†	71,2	62,4	56,1	63,9	77,9	90,9
Câu tham chiếu	92,1	83,8	75,7	84,2	96,2	100,0

Nhóm độ đo theo vị trí. Thứ tự các mô hình dưới luật khoảng cách Euclid và luật hộp phần tử gần như trùng với thứ tự dưới executability (Bảng 6.5, Hình 6.2). Phương pháp đề xuất đạt 76,3% theo luật khoảng cách Euclid và 67,1% theo luật hộp phần tử,

Bảng 6.6: Nhóm độ đo so với câu tham chiếu trên đủ 4.463 bước chạm. BLEU-4, METEOR 1.5, ROUGE-L, CIDEr-D và SPICE được tính bằng bộ công cụ đánh giá chính thức của COCO Captions, sau khi tách từ bằng PTBTokenizer. chrF được tính bằng sacreBLEU. BERTScore là F1 với roberta-large tầng 17, đã hiệu chỉnh theo đường cơ sở. Mỗi bước chỉ có một câu tham chiếu. Số in đậm là số cao nhất trong các mô hình ở cột đó. Giai đoạn ba là giai đoạn thưởng tọa độ, học tiếp từ MIN-DESC với phần thưởng đặt trên tọa độ trong dòng mô tả. *Thành phần thứ nhất của phương pháp đề xuất; kết quả của phương pháp đề xuất được trình bày ở Bảng 6.4. Với TAGE mới tính SPICE. †Mô hình chọn ứng viên chỉ có thể so sánh trực tiếp với Base.

Mô hình	**BLEU-4**	**METEOR**	**ROUGE-L**	**CIDEr-D**	**SPICE**	**chrF**	**BERTScore**
Base	15,3	24,6	42,3	88,0	18,5	40,2	40,1
S1 (101)	51,6	36,8	67,3	416,1	44,4	61,3	66,3
S1 (202)	51,7	37,2	67,7	419,2	44,2	61,9	66,8
S2	48,7	35,8	66,0	387,7	41,3	59,9	65,1
CE2-S2	50,1	37,3	**68,6**	402,2	42,3	61,9	66,8
MIN-DESC	49,9	37,3	68,5	401,0	42,2	61,8	66,7
Giai đoạn ba	49,9	37,3	68,5	402,9	42,5	61,9	66,8
Phần thưởng SPICE*	**52,4**	**37,9**	68,4	**430,1**	**45,8**	**62,9**	**67,1**
TAGE	–	–	–	–	45,7	–	–
Chọn ứng viên†	46,9	34,2	63,3	370,6	39,3	57,7	62,8
Câu tham chiếu	100,0	100,0	100,0	988,7	98,6	100,0	100,0

so với 74,4% và 65,5% của S1 hạt giống 101; mức hơn có ý nghĩa dưới cả hai luật ($p < 0{,}001$). Giai đoạn thưởng tọa độ cao nhất theo luật khoảng cách Euclid (77,3%), nhưng mức hơn này đến từ việc gọi đúng loại thao tác chứ không từ việc chỉ đúng phần tử (Mục A.4.2). Bảng 6.7 cho khoảng tin cậy của các mốc dưới ba luật: chênh lệch giữa S1 và mô hình gốc giữ gần nguyên ở cả ba luật.

Bảng 6.7: Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và phép so ghép cặp (dưới). Khoảng tin cậy lấy từ bootstrap 10.000 lần gom cụm theo ứng dụng (G = 1.091), giá trị p của kiểm định McNemar. MIN là MIN-DESC; giai đoạn ba là giai đoạn thưởng tọa độ (Phụ lục A.4).

Mô hình	**Euclid**	**Hộp phần tử**	**Executability**
Base	63,4 [61,8; 65,0]	53,6 [51,9; 55,3]	47,6 [45,9; 49,3]
S1 (101)	74,4 [72,8; 75,8]	65,5 [63,8; 67,2]	59,1 [57,3; 60,8]
S1 (202)	75,3 [73,8; 76,7]	66,1 [64,4; 67,7]	59,6 [57,9; 61,3]
MIN	76,4 [74,9; 77,8]	66,5 [64,9; 68,2]	60,0 [58,3; 61,8]
Giai đoạn ba	77,3 [75,8; 78,8]	67,0 [65,3; 68,7]	60,1 [58,3; 61,8]
Câu tham chiếu	92,1 [91,1; 93,1]	83,8 [82,5; 85,1]	75,7 [74,1; 77,3]

Phép so	**Quy tắc**	**Δ**	**KTC 95%**	**p**
S1 (101) − Base	Euclid	+10,98	[+9,44; +12,56]	<0,001
	Hộp phần tử	+11,90	[+10,36; +13,47]	<0,001
	Exec.	+11,52	[+10,02; +13,07]	<0,001
S2 − S1 (101)	Euclid	-0,96	[−2,18; +0,29]	0,100
	Hộp phần tử	-1,86	[−3,04; −0,67]	<0,001
	Exec.	-1,93	[−3,06; −0,75]	<0,001

Nhóm độ đo theo vị trí. Bảng 6.5 trình bày đồng thời ba quy tắc đánh giá chính (quy tắc khoảng cách Euclid, quy tắc hộp phần tử và executability) cùng hai biến thể ở Mục 5.12. Phương pháp đề xuất đạt 76,3% theo quy tắc khoảng cách Euclid, so với 74,4% của S1 seed 101. Trong các phương án đã khảo sát, giai đoạn thưởng tọa độ đạt giá trị cao nhất theo quy tắc khoảng cách Euclid, 77,3%. Thứ hạng các mô hình theo hai quy tắc vị trí nhìn chung nhất quán với thứ hạng theo executability.

Sai số và kết luận theo ba quy tắc. Bảng 6.7 trình bày khoảng tin cậy theo ba

quy tắc, được tính trên cùng các mẫu bootstrap nên có thể đối chiếu trực tiếp giữa các cột. Chênh lệch giữa S1 seed 101 và mô hình gốc gần như không thay đổi giữa ba quy tắc, đều với $p < 0{,}001$, và phương pháp đề xuất cao hơn S1 có ý nghĩa theo cả ba quy tắc (Mục 6.4). Với các hướng đã thử, kết luận thay đổi tùy quy tắc. Mô hình mô tả phần tử thấp hơn S1 có ý nghĩa theo executability (Mục A.1.3) nhưng không theo quy tắc khoảng cách Euclid. Theo quy tắc khoảng cách Euclid, phần lớn mức cải thiện của giai đoạn học theo cặp ưu tiên và giai đoạn thưởng tọa độ so với mô hình mô tả phần tử có được chỉ nhờ học tiếp, vì mô hình chỉ học thêm có giám sát với cùng số bước cũng đạt phần lớn mức cải thiện ấy. Giai đoạn thưởng tọa độ cao hơn S1 có ý nghĩa theo hai quy tắc vị trí, nhưng không theo executability.

> Mức cải thiện theo quy tắc khoảng cách Euclid tập trung ở 256 bước (5,7%) mà S1 dự đoán sai loại thao tác, chẳng hạn sinh câu mô tả thao tác vuốt hoặc cuộn khi bước đúng là chạm. Nhóm này đóng góp +3,11 điểm theo quy tắc khoảng cách Euclid và +1,97 điểm theo executability; khi so với seed 202, mức đóng góp tương ứng là +3,09 điểm. Ở 4.189 bước mà cả hai mô hình đều dự đoán đúng loại thao tác, tỉ lệ đạt gần như tương đương (79,04% so với 78,92%). Quy tắc khoảng cách Euclid cũng không loại những lần chạm rơi vào phần tử sát bên, trong khi executability loại các trường hợp này. Giai đoạn thưởng tọa độ mắc lỗi này nhiều hơn, nên trên nhóm bước mà cả hai mô hình đều dự đoán đúng loại thao tác, giai đoạn này thấp hơn S1 0,81 điểm theo executability. Do đó, trong phép phân rã này, mức cải thiện của hai giai đoạn chủ yếu gắn với việc dự đoán đúng loại thao tác, chưa cho thấy cải thiện tương ứng về khả năng định vị phần tử.

Nhóm độ đo so với câu tham chiếu. Bảng 6.6 sử dụng các độ đo được báo cáo trong Widget Captioning [9] và Screen2Words [10], gồm BLEU [20], METEOR [22], ROUGE-L [21], CIDEr [23] và SPICE [24], cùng chrF [25] và BERTScore [26]. BLEU-4 trong bảng này được tính trên toàn tập bằng bộ công cụ của COCO Captions, nên khác với BLEU-4 trung bình theo từng câu ở Bảng 6.1. Tinh chỉnh có giám sát cải thiện tất cả các độ đo trong nhóm; chẳng hạn SPICE, độ đo mà Zhao và cộng sự [37] khuyến nghị để xếp hạng các mô hình sinh chỉ dẫn khi có câu tham chiếu, tăng

từ 18,5 ở mô hình gốc lên 44,4 ở S1 seed 101. Phương pháp đề xuất tiếp tục cải thiện các độ đo này (Bảng 6.4). BERTScore sử dụng phiên bản đã co giãn theo mức điểm nền (*baseline rescaling*), vì ở phiên bản chưa co giãn, mọi mô hình đã tinh chỉnh đều nằm trong khoảng 93,5 đến 94,4. Câu rỗng được tính 0 điểm và vẫn nằm trong mẫu số, tương tự quy ước của executability.

Khi diễn giải nhóm độ đo này cần lưu ý hai điểm. Thứ nhất, CIDEr-D vượt quá 100 vì mỗi bước chỉ có một câu tham chiếu và trọng số nghịch đảo tần suất văn bản (IDF) được ước lượng từ chính tập câu tham chiếu; do đó, giá trị này chỉ nên được so sánh giữa các hàng trong cùng bảng. Thứ hai, nhóm độ đo này xếp giai đoạn học theo cặp ưu tiên cao hơn giai đoạn thưởng tọa độ, ngược với executability, phù hợp với phân tích ở Mục 5.11 về các mô hình chênh nhau dưới hai điểm. Vì vậy, nhóm độ đo này chủ yếu được dùng để đối chiếu với các công trình cùng mảng; so sánh giữa các mô hình trong đề tài vẫn dựa trên executability.

6.6 So sánh ghép cặp

Mọi mô hình được đánh giá trên cùng một tập bước, nên các phép so sánh được thực hiện theo cặp ở mức từng bước (kiểm định McNemar, Mục 5.13); Bảng 6.8 tổng hợp các phép so sánh được sử dụng trong chương.

Bảng 6.8: So sánh ghép cặp trên 4.463 bước. *b* là số bước mà mô hình sau dấu trừ đạt còn mô hình trước dấu trừ không đạt, *c* là chiều ngược lại, nên Δ = (c-b)/n. Khoảng tin cậy từ bootstrap gom cụm theo tác vụ (Mục 5.13), trừ nhóm có dấu *. Base là mô hình gốc; S1/101 và S1/202 là mô hình tinh chỉnh có giám sát với seed 101 và 202. Hai hàng có câu tham chiếu dùng n = 4.462 vì bỏ một bước mà mô hình được đánh giá sinh câu rỗng. Phần thưởng SPICE là thành phần thứ nhất của phương pháp đề xuất; học ưu tiên là MIN-DESC; học thêm là mô hình chỉ học thêm có giám sát (CE2-S2); TAGE là mô-đun hiệu chỉnh câu theo vùng cắt. *Ở nhóm này, chỉ hàng phần thưởng SPICE − S1/101 gom cụm theo tác vụ, các hàng khác gom cụm theo ứng dụng; gom cụm theo ứng dụng cho hàng ấy khoảng gần như trùng ([+0,80; +2,33]).

So sánh	Δ	KTC 95%	b	c	p
Mốc so sánh (S1 có hai seed)					
S1 − Base	+11,5	[+10,0; +13,1]	284	798	<0,001
Câu tham chiếu − S1	+16,6	–	102	843	<0,001

So sánh	Δ	KTC 95%	b	c	p
Câu tham chiếu − Base	+28,1	–	102	1.357	<0,001
S1/202 − S1/101 (hai seed)	+0,52	[−0,22; +1,26]	132	155	0,194
Phương pháp đề xuất và các so sánh liên quan					
Phương pháp đề xuất − S1/101	+1,57	[+0,86; +2,31]	88	158	<0,001
Phương pháp đề xuất − phần thưởng SPICE	+0,02	[−0,21; +0,26]	14	15	1,00
Phần thưởng SPICE − S1/101	+1,55	[+0,82; +2,28]	90	159	<0,001
Phần thưởng SPICE − S1/202	+1,03	[+0,25; +1,83]	145	191	0,014
Phần thưởng SPICE − học theo cặp ưu tiên	+0,60	[−0,52; +1,73]	304	331	0,30
Phần thưởng SPICE − thưởng tọa độ	+0,58	[−0,50; +1,69]	286	312	0,31
TAGE − phần thưởng SPICE	-0,43	[−0,87; +0,02]	67	48	0,093
Hướng đã thử (Phụ lục A)					
Mô tả phần tử (S2) − S1/101	-1,93	[−3,06; −0,75]	340	254	0,0005
S2 − S1/202	-2,44	[−3,53; −1,34]	353	244	<0,001
S2 − Base	+9,59	[+8,16; +11,06]	324	752	<0,001
Học thêm − S2	+2,24	[+1,41; +3,11]	127	227	<0,001
Học theo cặp ưu tiên − S2	+2,87	[+2,03; +3,76]	130	258	<0,001
Học theo cặp ưu tiên − học thêm	+0,63	[+0,16; +1,10]	42	70	0,011
Học theo cặp ưu tiên − S1/101	+0,94	[−0,09; +2,05]	300	342	0,11
Học thêm − S1/101	+0,31	[−0,76; +1,45]	312	326	0,61
Chọn ứng viên − Base	+8,54	–	350	731	<0,001

Với seed 101, tinh chỉnh có giám sát trên tập dữ liệu được xây dựng tự động cải thiện executability thêm 11,5 điểm, tương ứng thu hẹp 41% khoảng cách giữa mô hình gốc và câu tham chiếu; phần dư địa còn lại được phân tích ở Mục 6.9.4. Tỉ lệ này cao hơn mức cải thiện thực chất, vì ở khoảng một phần tư số bước, S1 chép lại câu tham chiếu. Nếu chỉ xét 3.367 bước mà mô hình tự sinh câu, mô hình gốc, S1 và câu tham chiếu đạt lần lượt 44,7, 53,1 và 75,0, và tỉ lệ thu hẹp khoảng cách giảm còn 28%.

6.7 Biến thiên giữa hai lượt huấn luyện

Để mô tả mức biến thiên khi huấn luyện lại, mô hình tinh chỉnh có giám sát (S1) được huấn luyện thêm một lượt, chỉ đổi seed và giữ nguyên mọi tham số cấu hình khác (Mục A.1.2).

Bảng 6.9: Hai lượt huấn luyện chỉ khác seed, đánh giá trên cùng 4.463 bước.

	Điểm	**Δ ghép cặp**	**Bước bất đồng**
S1 seed 101	59,11%	+0,52 pp	287 = 6,4%
S1 seed 202	59,62%		
Phép so sánh kiểm chứng S1 − Base		+11,5 pp	1.082 = 24,2%

Chênh lệch 0,52 điểm giữa hai seed không có ý nghĩa thống kê (khoảng tin cậy 95% chứa 0, p = 0,194, Bảng 6.8). Hai lượt cho kết quả khác nhau ở 6,4% số bước, so với 24,2% giữa S1 và mô hình gốc; xét độ lớn của điểm, chênh lệch giữa S1 và mô hình gốc lớn gấp 22 lần chênh lệch giữa hai seed, và gấp 3,8 lần nếu xét tỉ lệ bước đổi kết quả.

Trong phép so sánh này, chênh lệch giữa hai lượt bắt nguồn từ sự khác biệt trong câu sinh chứ không phải từ công cụ đo: trên 2.810 bước mà hai lượt tạo ra câu giống hệt nhau, kết quả đánh giá cũng trùng khớp ở mọi bước. Mức đồng thuận từng bước trên toàn tập là 93,6% (κ = 0,867, hệ số đồng thuận đã trừ phần trùng do ngẫu nhiên). Giá trị này chịu ảnh hưởng đáng kể từ các bước mà hai lượt sinh cùng một câu; trên 1.652 bước có câu sinh khác nhau, mức đồng thuận còn 82,6% (κ = 0,650).

Với seed thứ hai, chênh lệch ở cả sáu cách chia nhóm trong Mục 6.9 vẫn cùng dấu với seed thứ nhất, và độ lệch giữa hai seed không vượt quá 0,9 điểm. Trong 1.091 cụm (Mục 5.13), số cụm mà S1 hơn, bằng và kém mô hình gốc là 395/565/131 ở seed 101 và 406/572/113 ở seed 202.

6.8 Phân tích các giả thuyết thay thế

Mức chênh 11,5 điểm giữa S1 và mô hình gốc chưa thể mặc nhiên quy hoàn toàn cho bước tinh chỉnh, vì kết quả có thể chịu ảnh hưởng của những yếu tố khác. Bảng 6.10 lần lượt kiểm tra bảy cách giải thích thay thế dựa trên bản ghi ở mức từng bước. Sáu giả thuyết không được dữ liệu hiện tại ủng hộ; riêng ảnh hưởng của việc mô hình học theo văn phong của câu chú thích vẫn chưa được tách hoàn toàn.

Bảng 6.10: Phân tích các giả thuyết thay thế cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra.

Giả thuyết thay thế	**Kết quả kiểm**
Do điều kiện khớp thao tác chi phối	khi bỏ điều kiện này và chỉ đánh giá phần định vị, chênh lệch vẫn còn +11,3 điểm (b=272, c=777). Hơn nữa Base gọi đúng loại thao tác nhiều hơn (96,5% so với 94,4%)
Chỉ cải thiện ở một vị trí trong chuỗi	bước mở đầu tác vụ +15,0 (n=593, [+11,0; +19,1]), các bước sau +11,0 ([+9,4; +12,6]). Hai khoảng tin cậy chồng lấp và đều nằm trên 0
Chỉ cải thiện trên màn hình ít phần tử	chia ba theo số phần tử trên màn cho +12,6, +9,5 và +12,4. Các khoảng giao nhau, không tầng nào đảo chiều
Kết quả bị chi phối bởi một số ít ứng dụng	trên 1.091 cụm, S1 cao hơn ở 395, bằng ở 565 và thấp hơn ở 131
Cải thiện chủ yếu do bắt chước văn phong chú thích	chưa thể loại trừ, vì S1 mở đầu bằng động từ chạm nhiều hơn Base (91,0% so với 86,1%, câu tham chiếu 95,1%), cho thấy văn phong của S1 gần với văn phong người chú thích hơn
Do công cụ đo phù hợp với văn phong chú thích	khi đánh giá lại bằng UI-Venus-Ground-7B, một mô hình định vị không học AndroidControl, chênh lệch vẫn giữ 94% (Mục 5.9)
Do sao chép câu tham chiếu	1.095 trong 4.462 câu không rỗng của S1 lặp đúng các từ nội dung của câu tham chiếu. Khi chỉ đánh giá 3.367 bước mà mô hình tự sinh câu, S1 vẫn cao hơn +8,4 điểm (b=264, c=547, p<0,001)

Dòng cuối của bảng cho thấy một độ đo dựa trên câu tham chiếu không tách riêng được ảnh hưởng của việc mô hình tái tạo nguyên văn câu tham chiếu. Trên nhóm bước sao chép nguyên văn, S1 cao hơn mô hình gốc 21,1 điểm, cho thấy một phần mức cải

thiện do tinh chỉnh gắn với việc tái tạo cách diễn đạt của người chú thích. Tuy vậy, S1 vẫn cao hơn trên các bước không sao chép nguyên văn, nên thứ tự giữa hai mô hình không phụ thuộc riêng vào nhóm này.

Điểm executability thay đổi theo độ dài câu: chia đôi câu của S1 ở độ dài trung vị 33 ký tự thì nhóm câu dài đạt 61,9%, nhóm câu ngắn đạt 56,5%. Xu hướng này nếu có lợi cho câu dài thì nghiêng về phía mô hình gốc, vốn viết câu dài khoảng 70 ký tự (trung vị), nên không giải thích được việc S1 cao hơn mô hình gốc. Mối liên hệ giữa độ dài và điểm số cũng khác nhau giữa các mô hình (ở mô hình gốc, câu dài lại kém câu ngắn 1,4 điểm), nên cần được phân tích riêng cho từng mô hình.

6.9 Phân bố lỗi của mô hình tinh chỉnh có giám sát

Mục này phân tích lỗi của S1, để thấy tinh chỉnh đã sửa được gì và còn thiếu gì.

6.9.1 Ảnh hưởng của việc trùng ứng dụng giữa tập huấn luyện và tập kiểm tra

Trong các bước của tập kiểm tra xác định được ứng dụng, 95,6% thuộc về ứng dụng cũng có trong tập huấn luyện (Mục 3.6). Bảng 6.11 so sánh S1 giữa các nhóm ứng dụng đã thấy, chưa thấy và không xác định; phép so giữa hai nhóm đầu chỉ áp dụng trên phần dữ liệu xác định được ứng dụng.

Bảng 6.11: Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa.

Nhóm	S1	n
Ứng dụng đã thấy lúc huấn luyện	59,1%	1.737
Ứng dụng chưa thấy	59,0%	78
Không quy được về ứng dụng	59,1%	2.648

Ba ước lượng gần nhau, nhưng nhóm ứng dụng chưa xuất hiện trong huấn luyện chỉ có 78 bước và khoảng tin cậy rộng. Kết quả hiện tại chưa cho thấy ảnh hưởng rõ

của mức trùng ứng dụng, nhưng cũng chưa đủ để loại trừ một ảnh hưởng nhỏ.

6.9.2 Phân loại lỗi còn lại

Trong 1.824 bước mà S1 không đạt executability, chỉ 251 bước xuất phát từ việc dự đoán sai loại thao tác. Ở 1.573 bước còn lại, chiếm 86%, loại thao tác đã đúng nhưng câu do S1 sinh vẫn không giúp mô hình định vị xác định được phần tử cần chạm. Một số ví dụ nguyên văn được trình bày dưới đây.

câu tham chiếu	**câu S1 sinh ra**
click on the OK option	select minutes 00
Click on the Sort filter	Click on the Air India flight option
Click on the share icon	Open Recorder app

Vì vậy, nhóm lỗi còn lại của S1 chủ yếu liên quan đến việc gọi tên và mô tả phần tử.

6.9.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh

Ở 798 bước mà S1 đúng còn mô hình gốc sai, mô hình gốc thường mắc một trong hai lỗi: viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại, hoặc mô tả một bước khác với bước cần làm.

	Câu
chuẩn	Click on the profile icon at the top right of the screen
S1	Click on the profile icon at the top right corner of the screen
Base	To set YouTube video downloads over Wi-Fi only, tap on your profile icon at the top right corner of the screen and select “Settings.” Then navigate to the “Downloads” section and choose “Wi-Fi Only.”
chuẩn	Click on Knoxville
S1	Click on Knoxville
Base	Click on the three dots next to Knoxville to access more options and proceed with reading the local news.

Ở dạng thứ nhất, mô hình gốc viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại. Ở dạng thứ hai, mô hình gốc mô tả một bước khác với bước cần làm. Câu của mô hình gốc vẫn trôi chảy, đúng khuôn và gọi tên nút cụ thể; câu này nhận điểm thấp vì không bám sát bước hiện tại chứ không vì viết sai định dạng. Kết quả cho thấy tinh chỉnh có giám sát chủ yếu cải thiện khả năng bám sát bước hiện tại.

6.9.4 Ước lượng dư địa cải thiện còn lại

Câu tham chiếu cũng không đạt ở khoảng một phần tư số bước, chủ yếu do những giới hạn của công cụ đo được phân tích ở Mục 6.11. Với thiết lập đánh giá hiện tại, S1 còn thấp hơn câu tham chiếu 16,6 điểm, tương ứng 741 bước (Mục 5.5). Trong thiết lập đánh giá hiện tại, khoảng cách này được dùng như một mốc tham chiếu thực nghiệm cho phần chênh lệch còn lại có liên quan đến cách diễn đạt của câu sinh; độ lớn của nó cũng cao hơn nhiều so với sai số chuẩn 0,79 điểm của hiệu ghép cặp. Một mức tăng hai điểm sẽ thu hẹp khoảng 13% chênh lệch này, xấp xỉ quy mô hiệu ứng trung vị được báo cáo trong các công trình liên quan. Theo executability, chưa phương án nào trong luận văn đạt mức tăng đó; phương pháp đề xuất là cấu hình tiến gần nhất (Bảng 6.1).

6.10 Các phương án thiết kế đã khảo sát

Bảng 6.12 tóm tắt các phương án thiết kế đã khảo sát trước khi hình thành phương pháp đề xuất; thiết kế và kết quả chi tiết được trình bày trong Phụ lục A.

Bảng 6.12: Các phương án thiết kế đã khảo sát. Điểm là executability trên 4.463 bước chạm của tập kiểm tra, trừ khi ghi khác.

Hướng	Ý tưởng	Kết quả	Điều rút ra
Mô tả phần tử (S2), Mục A.1.3	viết một dòng mô tả phần tử cần chạm trước câu hướng dẫn	57,2%, thấp hơn S1/101 1,93 điểm	câu đầu ra đạt kết quả cao hơn ở nhóm mô tả đúng phần tử và giảm mạnh ở nhóm mô tả sai
Học theo cặp ưu tiên (MIN-DESC), Mục A.2.2	học theo cặp ưu tiên trên các đầu ra chỉ khác ở dòng mô tả	60,0%; 78% mức tăng so với S2 cũng có ở mô hình chỉ học thêm có giám sát	phần lớn cải thiện xuất hiện ở cấu hình chỉ học thêm
Chọn ứng viên, Mục A.3.2	chọn phần tử cần chạm trong danh sách được xây dựng sẵn	56,1%, chỉ có thể so sánh trực tiếp với mô hình gốc	khi đưa ra lựa chọn, độ chính xác cao, nhưng tần suất từ chối chọn lớn
Giai đoạn thưởng tọa độ, Mục A.4.2	học tăng cường với phần thưởng dựa trên độ chính xác của tọa độ trong dòng mô tả	60,1% (77,3% theo quy tắc khoảng cách Euclid)	độ chính xác tọa độ tăng nhưng thay đổi ở câu đầu ra còn hạn chế
Đưa thêm thông tin vị trí, Mục A.6	bổ sung thông tin vị trí cho mô hình sinh câu (bốn cách)	dừng ở tập kiểm định nội bộ	thông tin này chưa được phản ánh rõ trong đầu ra của mô hình sinh câu
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE), Mục A.7.2	viết lại câu hướng dẫn ban đầu sau khi xem ảnh phóng to quanh phần tử	60,2%, thấp hơn câu hướng dẫn ban đầu 0,43 điểm	bộ chọn có xu hướng chấp nhận câu hiệu chỉnh ngay cả khi vùng ảnh cục bộ chưa đúng

Các phương án trên dẫn tới ba quan sát quan trọng cho thiết kế cuối cùng. Thứ nhất, việc cải thiện các biểu diễn trung gian, như dòng mô tả phần tử hoặc tọa độ, chỉ tạo ra thay đổi hạn chế ở câu hướng dẫn cuối (Mục A.5). Thứ hai, nhiều lỗi còn lại

xuất hiện ở những bước mô hình xác định sai phần tử mục tiêu, nhưng việc đưa thêm thông tin vị trí trực tiếp vào mô hình sinh chưa làm câu đầu ra thay đổi tương ứng. Thứ ba, chỉ tiếp tục huấn luyện trên câu tham chiếu hoặc câu viết lại cũng không bảo đảm mang lại cải thiện. Từ những kết quả này, phương pháp cuối cùng chuyển trọng tâm sang tối ưu trực tiếp câu hướng dẫn và chỉ sử dụng câu ví dụ khi đáp ứng ràng buộc nhất quán về loại thao tác.

6.11 Giới hạn của độ đo trên tập kiểm tra

Câu tham chiếu không đạt executability ở 1.083 bước. Trong 64,8% số bước này, điểm do mô hình định vị trả về nằm xa ngoài vùng dung sai; sai số trung vị là 26,2% bề ngang màn hình, so với 0,4% ở các bước đạt. 381 bước còn lại đã nằm trong vùng dung sai nhưng vẫn bị quy tắc ô Voronoi loại. Đáng chú ý, ở 208 bước trong số đó, điểm dự đoán nằm ngay trong hộp nhỏ nhất chứa điểm chạm; trên các phần tử lớn, một phần tử con có thể bị xem là đối thủ cạnh tranh với chính phần tử cha. Tính trên các bước đã nằm trong vùng dung sai, quy tắc ô Voronoi loại 10,1% với câu tham chiếu, 13,0% với S1 và 15,2% với mô hình gốc. Ngoài ra, có 935 bước, tương ứng 21% toàn bộ tập chạm, mà cả ba loại câu đều không đạt. Những con số này cho thấy điểm 75,7% của câu tham chiếu chịu ảnh hưởng đáng kể từ giới hạn của công cụ đo và không nên được diễn giải như giới hạn của chất lượng diễn đạt.

Luận văn cũng kiểm tra khả năng mô hình tối ưu cách diễn đạt theo đặc điểm của công cụ đo thay vì theo nhu cầu của người đọc (Mục 5.5). Câu nêu tên một vùng trên màn đạt 89,5% khi vùng đó đúng, 3,3% khi vùng đó sai và 54,8% khi không nêu vùng nào. Kết quả này cho thấy độ đo phản hồi tích cực khi thông tin vị trí phù hợp nhưng không tạo lợi thế tương tự khi thông tin vị trí sai. S1 sử dụng từ chỉ vị trí trong 26,8% số câu, gần bằng 26,4% của câu tham chiếu, và chỉ để lại chuỗi tọa độ trong 3 trên 6.958 câu. Khác biệt rõ hơn nằm ở mức độ lặp khuôn câu: hai mẫu câu phổ biến nhất của S1 chiếm 10,4% số bước, so với 6,5% ở câu tham chiếu.

6.12 Tổng hợp các mô hình và phép thử

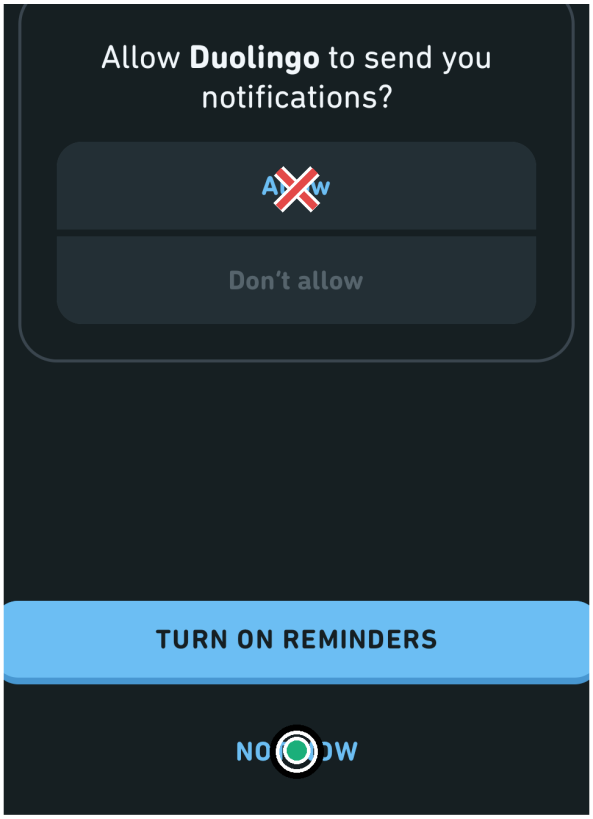
Bảng 6.13 ghi trạng thái cuối của từng mô hình và phép thử, kèm lý do đối với các cấu hình không được thực hiện hoặc dừng trước khi hoàn tất.

Bảng 6.13: Trạng thái cuối của các mô hình, cấu hình và phép thử. Điểm trong cột ghi chú là executability trên tập kiểm tra, trừ khi ghi khác.

Mô hình hoặc phép thử	Trạng thái	Ghi chú
Phương pháp đề xuất (thưởng SPICE + ACE)	Hoàn tất, đã đánh giá	60,7; hơn S1/101 +1,57 có ý nghĩa thống kê; tương đương thành phần thứ nhất về các độ đo vị trí, cao hơn ở cả bảy độ đo dựa trên câu tham chiếu (CIDEr-D +12,0); Mục 6.4
Thành phần thứ nhất (thưởng SPICE)	Hoàn tất, đã đánh giá	60,6; hơn S1/101 +1,55 có ý nghĩa thống kê, tăng ở cả mười ba độ đo; Mục 6.3
Mô hình tinh chỉnh có giám sát (S1), hai seed	Hoàn tất, đã đánh giá	59,1 và 59,6; chênh lệch giữa hai seed +0,52 điểm; Mục 6.7
Mô tả phần tử (S2), seed 101	Hoàn tất, đã đánh giá	57,2; thấp hơn S1/101 có ý nghĩa; Mục A.1.3
Mô tả phần tử (S2), seed 202	Không tiếp tục	giới hạn tài nguyên tính toán
Mô tả giả (S2r); mô tả không có tọa độ (S2-nopoint)	Không tiếp tục	mô tả giả chỉ cần khi S2 cho kết quả dương; tọa độ tự nó có ích (+1,12 điểm)
Đưa danh sách phần tử vào S1 lúc suy luận	Không thực hiện	không được yêu cầu bởi các cấu hình đã đánh giá

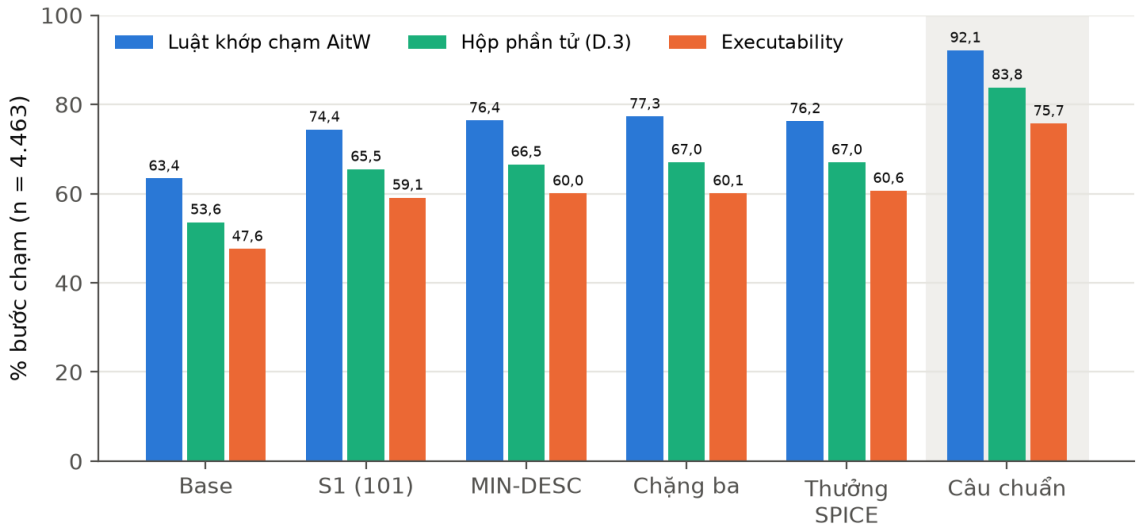
Mô hình hoặc phép thử	Trạng thái	Ghi chú
Học thêm có giám sát (CE2-S2); giai đoạn học theo cặp ưu tiên (MIN-DESC)	Hoàn tất, đã đánh giá	59,4 và 60,0; 78% mức tăng so với S2 cũng có ở mô hình học thêm; Mục A.2.2
Học ưu tiên với vế sai lấy từ lỗi của chính mô hình	Dừng ở khâu tạo dữ liệu	chỉ 3,3% cặp hợp lệ; Mục A.2.2.3
Giai đoạn thưởng tọa độ	Hoàn tất, đã đánh giá	60,1; +0,02 so với giai đoạn học theo cặp ưu tiên; Mục A.4.2
Nội suy trọng số giữa hai giai đoạn trên	Hoàn tất	điểm thay đổi đơn điệu, không đánh giá thêm cấu hình mới trên tập kiểm tra; Mục A.4.3
Cấu hình đối chứng của giai đoạn thưởng tọa độ	Không thực hiện	mức chênh gần bằng không
Bước không chạm sau giai đoạn học theo cặp ưu tiên	Đã đánh giá	giảm 19,75 điểm; Mục A.2.2.4
Chọn ứng viên, seed 101	Hoàn tất, đã đánh giá	56,1; độ chính xác chọn 57,5%, thấp hơn khi tự viết dòng mô tả; Mục A.3.2
Năm lượt còn lại của mô hình chọn ứng viên	Không tiếp tục	độ chính xác chọn không vượt dòng mô tả tự viết
Hiệu chỉnh ngưỡng từ chối chọn	Hoàn tất	tốt nhất thêm 8 bước đúng trên 1.400 bước
Mở khoá phần thị giác để cùng huấn luyện	Dừng trước khi hoàn tất	bản lưu sau 41% số bước kém giai đoạn học theo cặp ưu tiên rõ trên tập kiểm định nội bộ

Mô hình hoặc phép thử	Trạng thái	Ghi chú
Mô-đun định vị và cầu nối	Dừng sau một lượt	cầu nối không làm câu thay đổi; Mục A.6
Vùng cắt làm ảnh thứ hai	Dừng ở khâu đánh giá	không phân biệt phần tử đúng với phần tử lân cận
Đưa thêm vai trò, vùng và loại thao tác vào mô hình	Dừng sau một lượt	hệ số trộn tự giảm về gần không; chỉ 4% số câu đổi
Làm nét ảnh quanh phần tử	Dừng ở khâu đánh giá	không cải thiện so với làm nét ở vị trí đối diện
Hai lượt viết lại có chọn lọc; bộ xếp hạng câu dùng màn kế tiếp	Dừng ở khâu sàng lọc	số câu lỗi đủ điều kiện hiệu chỉnh còn ít; bộ xếp hạng cho kết quả thấp hơn giải mã tham lam
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	Hoàn tất, đã đánh giá	60,2; thấp hơn câu hướng dẫn ban đầu 0,43; Mục A.7.2
Mô hình định vị thứ hai (UI-Venus)	Hoàn tất	chênh lệch S1 với mô hình gốc giữ 94%; Mục 5.9
Mô hình listener dạng lựa chọn (Phi-4)	Hoàn tất một phần	đã đánh giá câu tham chiếu, giai đoạn thưởng tọa độ, S1/101 và 3.566 bước của mô hình gốc; Mục 5.10
Đánh giá thủ công 100 câu bởi hai người	Không thực hiện	còn là một hạn chế; Mục 7.2



○ **Câu chuẩn:** "Click on the Not now button to remove this pop up notification"
✕ **S1 (101):** "Click on the Allow button" → trượt
● **Thưởng SPICE:** "Click on the Not Now button at the bottom of the screen" → trúng

Hình 6.1: Một bước được mô hình học tăng cường với phần thưởng SPICE sửa đúng (ảnh chỉ giữ phần dưới màn hình). Cần chạm nút *Not now* ở cuối màn, trong khi một hộp thoại hỏi quyền gửi thông báo đang che màn hình. S1 gọi nút *Allow* trong hộp thoại nên mô hình định vị xác định sai phần tử; mô hình học tăng cường với phần thưởng SPICE gọi đúng nút *Not now* kèm vị trí, và mô hình định vị xác định đúng phần tử.



Hình 6.2: Các mô hình chính theo ba quy tắc đánh giá trên 4.463 bước chạm. Cột nền xám là mốc câu tham chiếu. Thứ hạng nhìn chung được duy trì giữa ba quy tắc; riêng giai đoạn thưởng tọa độ (giai đoạn ba) đạt điểm cao hơn theo quy tắc khoảng cách Euclid, còn mô hình học tăng cường với phần thưởng SPICE đạt điểm cao hơn theo executability.

Chương 7

Kết luận

7.1 Đóng góp của luận văn

Luận văn nghiên cứu bài toán sinh hướng dẫn cho giao diện di động từ ảnh màn hình, mục tiêu của người dùng và lịch sử thao tác, trong đó đầu ra là một câu hướng dẫn ngắn cho bước kế tiếp. Từ bài toán này, luận văn tập trung vào ba đóng góp chính: (i) một phương pháp sinh gồm hai thành phần nối tiếp; (ii) độ đo khả năng thực hiện theo hướng dẫn (executability), dùng để đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác; và (iii) các phân tích thực nghiệm trên nhiều phương án thiết kế, qua đó làm rõ những yếu tố ảnh hưởng đến chất lượng câu đầu ra.

Về phương pháp đề xuất

Phương pháp đề xuất (Mục 4.4) tối ưu trực tiếp câu đầu ra và gồm hai thành phần. Thành phần thứ nhất học tiếp mô hình tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE để sinh câu hướng dẫn ban đầu. Thành phần thứ hai, ACE, chỉ hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ truy hồi khi đầu ra thỏa ràng buộc sao chép và nhất quán loại thao tác. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng hoặc quy tắc lựa chọn của phương pháp.

Phương pháp đề xuất đạt 60,7% executability, cao hơn mô hình tinh chỉnh có giám sát S1/101 1,57 điểm, với khoảng tin cậy 95% [+0,86; +2,31] và $p < 0{,}001$. Riêng thành phần thứ nhất đạt 60,6%, cao hơn S1 1,55 điểm [+0,80; +2,33] và đạt kết quả tốt hơn trên cả mười ba độ đo được báo cáo. Đây là cấu hình đầu tiên trong các thí nghiệm của luận văn cho thấy mức cải thiện có ý nghĩa thống kê theo executability.

Khi bổ sung ACE, executability gần như được giữ nguyên, trong khi cả bảy độ đo dựa trên câu tham chiếu đều tăng, rõ nhất ở CIDEr-D (+12,0) và SPICE (+1,3). Hai thành phần vì thế có vai trò bổ sung cho nhau: học tăng cường tạo ra phần lớn mức cải thiện theo các độ đo định vị, còn ACE cải thiện mức tương đồng với câu tham chiếu mà không làm giảm các độ đo dựa trên vị trí.

Về độ đo

Khi đầu ra là một câu hướng dẫn thay vì một tọa độ, một câu tham chiếu duy nhất khó có thể bao quát hết các cách diễn đạt hợp lệ. Executability tiếp cận vấn đề này bằng cách đưa câu sinh vào một mô hình định vị tách biệt với mô hình sinh, rồi kiểm tra xem câu có dẫn tới đúng phần tử cần thao tác hay không. Đóng góp của phần đo lường không chỉ nằm ở định nghĩa điểm số, mà còn ở việc xây dựng quy tắc xác định dự đoán đúng và kiểm chứng độ đo qua nhiều phép thử bổ sung (Chương 5).

Các phép kiểm chứng cho kết quả nhất quán trên nhiều cách đánh giá. Thứ hạng giữa câu tham chiếu, S1 và mô hình gốc được duy trì theo năm quy tắc đánh giá khác nhau (Mục 5.12); độ đo cũng ổn định trước việc thay động từ hoặc đảo thứ tự mệnh đề (Mục 5.8). Khi thay UGround bằng UI-Venus, chênh lệch S1–Base vẫn giữ khoảng 94% độ lớn (Mục 5.9). Phi-4, một mô hình listener thuộc họ kiến trúc khác với Qwen, cũng duy trì cùng thứ hạng giữa các cấu hình đã được đánh giá (Mục 5.10).

Kết quả nền tảng về dữ liệu và mô hình tinh chỉnh có giám sát

Tập giám sát gồm 64.567 bước được xây dựng hoàn toàn tự động, không yêu cầu gán nhãn thủ công bổ sung và không sử dụng nhãn do một mô hình ngôn ngữ khác sinh ra trong quá trình huấn luyện. Các bước kiểm tra chất lượng dữ liệu gồm đánh giá quá trình hợp nhất hai nguồn, kiểm tra cấu trúc và kiểm tra mức trùng lặp giữa tập huấn luyện với tập kiểm tra (Chương 3).

Trên 4.463 bước chạm của tập kiểm tra, S1 đạt 59,1% executability, tăng 11,5 điểm so với 47,6% của mô hình gốc. Theo quy tắc hộp phần tử của AndroidControl, hai giá trị tương ứng là 65,5% và 53,6%. Mức cải thiện này được duy trì trong các phân tích theo nhóm và khi thay công cụ định vị, cho thấy tinh chỉnh có giám sát tạo ra thay đổi

rõ rệt trong khả năng sinh hướng dẫn bám sát bước hiện tại.

Về phân tích các hướng đã thử

Đóng góp thứ ba là phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát trước phương pháp đề xuất. Mục 6.10 tóm tắt kết quả, còn Phụ lục A trình bày thiết kế và số liệu chi tiết.

Phương án đầu tiên yêu cầu mô hình sinh một dòng mô tả phần tử cần chạm trước câu hướng dẫn. Cấu hình này đạt kết quả thấp hơn S1, nhưng các giai đoạn học tiếp cho thấy trên những bước mà biểu diễn trung gian xác định đúng phần tử, chất lượng câu đầu ra cao hơn rõ rệt. Tuy nhiên, lợi ích này bị giới hạn bởi độ chính xác của chính biểu diễn trung gian. Giai đoạn học ưu tiên và giai đoạn thưởng tọa độ tiếp tục cải thiện một số độ đo, nhưng phần lớn chênh lệch có thể giải thích bằng việc học thêm hoặc bằng thay đổi ở loại thao tác thay vì cải thiện trực tiếp việc xác định phần tử.

Các phân tích tiếp theo cho thấy lỗi còn lại tập trung chủ yếu ở những bước mà biểu diễn trung gian xác định sai phần tử mục tiêu. Đồng thời, khi bổ sung trực tiếp thông tin vị trí vào mô hình sinh câu đã huấn luyện, tín hiệu này có thể được giải mã từ trạng thái ẩn nhưng chưa được phản ánh tương ứng trong câu đầu ra. Hai quan sát này là cơ sở để phương pháp cuối cùng chuyển từ tối ưu biểu diễn trung gian sang tối ưu trực tiếp câu sinh.

Ở phương án chọn ứng viên, mô hình chọn phần tử từ danh sách được xây dựng sẵn thay vì tự sinh dòng mô tả. Khi mô hình đưa ra lựa chọn, độ chính xác tương đối cao; hạn chế chính nằm ở tần suất từ chối chọn dù danh sách có chứa phần tử mục tiêu. Phân tích này gợi ý rằng quyết định có nên từ chối chọn cần được mô hình hóa riêng trong các nghiên cứu tiếp theo.

7.2 Hạn chế

Các kết quả cần được hiểu trong phạm vi của công cụ đánh giá, thiết lập mô hình và bộ dữ liệu đã sử dụng. Các hạn chế chính được tóm tắt dưới đây; những phân tích kỹ thuật chi tiết nằm ở Chương 5, Chương 6 và Phụ lục A.

7.2.1 Hạn chế của công cụ đo

Executability dùng mô hình định vị như một thước đo thay thế cho khả năng câu hướng dẫn giúp xác định đúng phần tử. Khi thay công cụ đánh giá bằng UI-Venus-Ground-7B hoặc listener Phi-4, thứ hạng giữa các cấu hình đã được kiểm tra vẫn được duy trì, cho thấy các kết luận chính tương đối ổn định trước lựa chọn công cụ đo. Tuy vậy, executability vẫn chỉ phản ánh gián tiếp việc một người dùng thực sự có thể xác định và thực hiện đúng thao tác hay không, và chưa được đối chiếu với đánh giá thủ công trên một tập đủ lớn. Ngoài ra, quy tắc ô Voronoi còn phụ thuộc vào mức độ đầy đủ của danh sách phần tử giao diện, đặc biệt đối với các nút biểu tượng và các hàng danh sách.

7.2.2 Hạn chế của kết quả về mô hình

Phương pháp đề xuất cho mức cải thiện nhất quán so với S1 trên các độ đo đã báo cáo, nhưng một số cấu hình đối chứng bổ sung vẫn hữu ích để tách riêng đóng góp của từng cơ chế. Cụ thể, thành phần học tăng cường chưa có đối chứng chỉ học thêm có giám sát với cùng số bước, còn ACE chưa có khoảng tin cậy cho nhóm độ đo văn bản. Các phương án trong Phụ lục A chủ yếu đóng vai trò phân tích thiết kế; do một số nhánh không có đầy đủ ablation, kết luận từ các nhánh này được sử dụng để giải thích hành vi mô hình thay vì xem như so sánh nhân quả độc lập.

7.2.3 Hạn chế của dữ liệu và phạm vi

Thực nghiệm hiện tập trung trên AndroidControl, giao diện tiếng Anh, một màn hình tại mỗi bước và mô hình nền Qwen2.5-VL-3B. Tập huấn luyện và tập kiểm tra được tách theo tác vụ nhưng vẫn có mức trùng lặp đáng kể về ứng dụng và cách diễn đạt, nên khả năng khái quát sang ứng dụng, ngôn ngữ hoặc bộ dữ liệu khác chưa được kiểm chứng. Ngoài ra, mỗi bước được đánh giá với lịch sử tham chiếu của các bước trước; vì vậy điểm số phản ánh chất lượng sinh hướng dẫn theo từng bước trong ngữ cảnh đúng, chưa phản ánh đầy đủ lỗi tích lũy trong một phiên tương tác dài.

7.3 Hướng phát triển

Từ các kết quả hiện tại, năm hướng phát triển được ưu tiên.

- **Hoàn thiện các thí nghiệm đối chứng của phương pháp đề xuất.** Bổ sung cấu hình chỉ học thêm có giám sát với cùng số bước cho thành phần SPICE, đồng nhất quy trình sinh câu giữa các cấu hình và ước lượng khoảng tin cậy cho các độ đo văn bản của ACE. Các thí nghiệm này giúp tách rõ hơn phần cải thiện đến từ từng thành phần.
- **Kết hợp chặt hơn giữa nhận diện phần tử và sinh câu.** Các phân tích ở Phụ lục A cho thấy việc bổ sung thông tin vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo ảnh hưởng hạn chế. Một hướng phù hợp hơn là học đồng thời biểu diễn phần tử, thông tin vị trí và câu hướng dẫn, hoặc mở một phần mô-đun thị giác trong quá trình tinh chỉnh.
- **Cải thiện cơ chế chọn ứng viên và từ chối chọn.** Khi mô hình đưa ra lựa chọn, độ chính xác tương đối cao; tuy nhiên tỉ lệ từ chối chọn vẫn lớn. Việc tách quyết định "có ứng viên đúng hay không" khỏi bước xếp hạng ứng viên là một hướng trực tiếp để khai thác tốt hơn danh sách phần tử có cấu trúc.
- **Đối chiếu executability với đánh giá của người dùng.** Một tập câu được nhiều người đánh giá độc lập có thể được sử dụng để đo tương quan giữa executability và khả năng người dùng thực sự xác định đúng phần tử. Đồng thời, cần mở rộng kiểm tra độ ổn định trước các cách diễn đạt khác nhau của cùng một phần tử.
- **Mở rộng phạm vi thực nghiệm.** Các bước tiếp theo gồm đánh giá trên tập kiểm tra chính thức của AndroidControl, bổ sung một bộ dữ liệu thứ hai, xét chuỗi thao tác qua nhiều màn hình và mở rộng sang giao diện tiếng Việt. Những thiết lập này cho phép kiểm tra mức độ khái quát của phương pháp ngoài cấu hình hiện tại.

7.4 Tính sẵn có của dữ liệu và mã nguồn

Các số liệu trong đề tài có thể được tái tạo từ mã nguồn và các tệp kết quả thô đi kèm.

Dữ liệu nguồn là AndroidControl [1], giấy phép CC0, lấy qua hai bản phân phối công khai trên Hugging Face đã nêu ở Bảng 3.2; ảnh màn hình không được phân phối lại.

Mã nguồn bao gồm quy trình xây dựng dữ liệu, cấu hình huấn luyện, chương trình sinh câu, mã đánh giá và các phép kiểm tra phục vụ tái lập kết quả.

Kết quả thô được lưu ở mức từng bước, gồm câu sinh, điểm tổng hợp, tọa độ do mô hình định vị trả về, tọa độ tham chiếu và các thành phần của executability. Cách lưu này cho phép tính lại quy tắc đánh giá hoặc các phân tích theo nhóm mà không cần gọi lại mô hình định vị.

Chương 8

Các công trình nghiên cứu

Một phần nội dung của đề tài được viết thành hai bài báo tách rời, khác nhau về đóng góp chính, về ngôn ngữ và về số liệu sử dụng.

> Lê Đoàn Phương Uyên, TS. Nguyễn Hồng Bửu Long. "Sinh hướng dẫn sử dụng phần mềm từ ảnh chụp màn hình và mục tiêu người dùng: xây dựng nhãn quy chiếu tự động khi phần tử giao diện không có tên để gọi."

Bài viết bằng tiếng Việt, nộp ngày 30 tháng 8 năm 2026 và đã được chấp nhận tại Hội thảo Quốc gia lần thứ tư về Ngôn ngữ học Tính toán (VCL 2026). Đóng góp chính của bài là nhãn quy chiếu và quy trình xây dựng dữ liệu ở Chương 3. Bài đặt bài toán trong hướng nghiên cứu về sinh biểu thức quy chiếu, tức sinh mô tả đủ để người tiếp nhận xác định đúng một đối tượng, rồi áp dụng vào miền giao diện. Trong dữ liệu khảo sát, 22,0% phần tử cần chạm không có tên hiển thị phù hợp và 7,6% trùng tên với một phần tử khác trên cùng màn hình.

> Lê Đoàn Phương Uyên, TS. Nguyễn Hồng Bửu Long. "Separating the Action Gate from Geometry in Execution-Based Evaluation for GUI Instruction Generation".

Bài viết bằng tiếng Anh, nộp ngày 21 tháng 9 năm 2026 tới hội nghị SOICT 2026 (mã bài 5577) và đang chờ kết quả bình duyệt. Kỷ yếu của hội nghị dự kiến thuộc tùng thư CCIS. Đóng góp chính của bài thuộc về đo lường, cụ thể bài chỉ ra rằng khi chấm câu hướng dẫn bằng độ đo dựa trên khả năng thực thi, cần tách phần điểm do điều kiện đúng loại thao tác mang lại khỏi phần điểm do định vị phần tử. Lý do là dưới quy tắc

khoảng cách Euclid của AndroidInTheWild, phần điểm mà giai đoạn huấn luyện tăng cường với phần thưởng tọa độ (một hướng đã thử) hơn mô hình tinh chỉnh có giám sát (S1) gần như hoàn toàn đến từ nhóm bước mà S1 gọi sai loại thao tác (Mục 6.5).

Hai bài không chồng lấn về đóng góp, vì bài thứ nhất thuộc về dữ liệu còn bài thứ hai thuộc về đo lường. Phương pháp đề xuất (Chương 4) được thực hiện sau ngày nộp của cả hai bài, nên không thuộc bài nào.

Tài liệu tham khảo

[1] W. Li, W. E. Bishop, A. Li, C. Rawles, F. Campbell-Ajala, D. Tyamagundlu, O. Riva, "On the effects of data scale on UI control agents," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024.

[2] C. Rawles, A. Li, D. Rodriguez, O. Riva, T. P. Lillicrap, "AndroidInTheWild: A large-scale dataset for Android device control," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[3] K. Cheng, Q. Sun, Y. Chu, F. Xu, Y. Li, J. Zhang, Z. Wu, "SeeClick: Harnessing GUI grounding for advanced visual GUI agents," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

[4] Z. Wu, Z. Wu, F. Xu, Y. Wang, Q. Sun, C. Jia, K. Cheng, Z. Ding, L. Chen, P. P. Liang, Y. Qiao, "OS-ATLAS: Foundation action model for generalist GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[5] B. Gou, R. Wang, B. Zheng, Y. Xie, C. Chang, Y. Shu, H. Sun, Y. Su, "Navigating the digital world as humans do: Universal visual grounding for GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025 (Oral).

[6] inclusionAI, "UI-Venus technical report: Building high-performance UI agents with RFT," arXiv:2508.10833, 2025 (bản tiền ấn phẩm).

[7] Y. Xu, Z. Wang, J. Wang, D. Lu, T. Xie, A. Saha, D. Sahoo, T. Yu, C. Xiong, "Aguvis: Unified pure vision agents for autonomous GUI interaction," in *Proc. International Conference on Machine Learning (ICML)*, 2025.

[8] X. Deng, Y. Gu, B. Zheng, S. Chen, S. Stevens, B. Wang, H. Sun, Y. Su, "Mind2Web: Towards a generalist agent for the web," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[9] Y. Li, G. Li, L. He, J. Zheng, H. Li, Z. Guan, "Widget captioning: Generating natural language description for mobile user interface elements," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020.

[10] B. Wang, G. Li, X. Zhou, Z. Chen, T. Grossman, Y. Li, "Screen2Words: Automatic mobile UI summarization with multimodal learning," in *Proc. ACM Symposium on User Interface Software and Technology (UIST)*, 2021.

[11] J. Mao, J. Huang, A. Toshev, O. Camburu, A. Yuille, K. Murphy, "Generation and comprehension of unambiguous object descriptions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[12] R. Luo, G. Shakhnarovich, "Comprehension-guided referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[13] L. Yu, H. Tan, M. Bansal, T. L. Berg, "A joint speaker-listener-reinforcer model for referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[14] S. Petryk, D. Chan, A. Kachinthaya, H. Zou, J. Canny, J. Gonzalez, T. Darrell, "ALOHa: A new measure for hallucination in captioning models," in *Proc. NAACL-HLT, Short Papers*, 2024.

[15] A. B. Sai, T. Dixit, D. Y. Sheth, S. Mohan, M. M. Khapra, "Perturbation CheckLists for evaluating NLG evaluation metrics," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2021.

[16] E. Clark, T. August, S. Serrano, N. Haduong, S. Gururangan, N. A. Smith, "All that's 'human' is not gold: Evaluating human evaluation of generated text," in *Proc. ACL-IJCNLP*, 2021.

[17] J. Chen, C. Chen, Z. Xing, X. Xu, L. Zhu, G. Li, J. Wang, "Unblind your apps: Predicting natural-language labels for mobile GUI components by deep learning," in *Proc. International Conference on Software Engineering (ICSE)*, 2020 (Distinguished Paper).

[18] S. Jandial, Y. Li, J. Wagle, K. Koishida, "Do GUI grounders truly understand UI elements?," in *Findings of the Association for Computational Linguistics: EACL*, 2026.

[19] K. Fang, J. Zhang, S.-T. Ni, P. Hui, Y. Wang, "GuideMe: A VLM-based system assisting independent smartphone learning for older adults," in *Proc. ACM Conference on Human Factors in Computing Systems (CHI)*, 2026.

[20] K. Papineni, S. Roukos, T. Ward, W.-J. Zhu, "BLEU: A method for automatic evaluation of machine translation," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2002.

[21] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in *Proc. Workshop on Text Summarization Branches Out, ACL*, 2004.

[22] M. Denkowski, A. Lavie, "Meteor Universal: Language specific translation evaluation for any target language," in *Proc. Ninth Workshop on Statistical Machine Translation (WMT)*, pp. 376–380, 2014.

[23] R. Vedantam, C. L. Zitnick, D. Parikh, "CIDEr: Consensus-based image description evaluation," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4566–4575, 2015.

[24] P. Anderson, B. Fernando, M. Johnson, S. Gould, "SPICE: Semantic propositional image caption evaluation," in *Proc. European Conference on Computer Vision (ECCV)*, pp. 382–398, 2016.

[25] M. Popović, "chrF: Character n-gram F-score for automatic MT evaluation," in *Proc. Tenth Workshop on Statistical Machine Translation (WMT)*, pp. 392–395, 2015.

[26] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi, "BERTScore: Evaluating text generation with BERT," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[27] A. C. Cameron, J. B. Gelbach, D. L. Miller, "Bootstrap-based improvements for inference with clustered errors," *Review of Economics and Statistics*, vol. 90, no. 3, pp. 414–427, 2008.

[28] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965.

[29] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, "LoRA: Low-rank adaptation of large language models," in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[30] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[31] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, "LlamaFactory: Unified efficient fine-tuning of 100+ language models," in *Proc. ACL, System Demonstrations*, 2024.

[32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[33] J. Qi, M. Ding, W. Wang, Y. Bai, Q. Lv, W. Hu, Z. Yang, Y. Dong, J. Tang, "CogCoM: A visual language model with chain-of-manipulations reasoning," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[34] S. Bai *et al.*, "Qwen2.5-VL technical report," arXiv:2502.13923, 2025 (bản thảo tiền ấn phẩm).

[35] K. Chen, Z. Zhang, W. Zeng, R. Zhang, F. Zhu, R. Zhao, "Shikra: Unleashing multimodal LLM's referential dialogue magic," arXiv:2306.15195, 2023 (bản thảo tiền ấn phẩm).

[36] Q. Wu, X. Yang, Y. Zhou, C. Fang, B. Song, X. Sun, R. Ji, "Grounded chain-of-thought for multimodal large language models," arXiv:2503.12799, 2025 (bản thảo tiền ấn phẩm; *không* phải bài ICCV 2025 cùng hướng, mã số 2507.02859).

[37] M. Zhao, P. Anderson, V. Jain, S. Wang, A. Ku, J. Baldridge, E. Ie, "On the evaluation of vision-and-language navigation instructions," in *Proc. Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, pp. 1302–1316, 2021.

[38] N. Nangia, S. R. Bowman, "Human vs. Muppet: A conservative estimate of human performance on the GLUE benchmark," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2019.

[39] P. Rajpurkar, R. Jia, P. Liang, "Know what you don't know: Unanswerable questions for SQuAD," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL), Short Papers*, pp. 784–789, 2018.

[40] A. K. Menon, S. Jayasumana, A. S. Rawat, H. Jain, A. Veit, S. Kumar, "Long-tail learning via logit adjustment," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[41] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024.

[42] D. Guo *et al.*, "DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning," *Nature*, vol. 645, no. 8081, pp. 633–638, 2025.

[43] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, "DeepSeekMath: Pushing the limits of mathematical reasoning in open language models," bản tiền ấn phẩm arXiv:2402.03300, 2024.

[44] A. Abouelenin *et al.*, "Phi-4-Mini technical report: Compact yet powerful multimodal language models via mixture-of-LoRAs," bản tiền ấn phẩm arXiv:2503.01743, 2025.

[45] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, J. Gao, "Set-of-Mark prompting unleashes extraordinary visual grounding in GPT-4V," bản tiền ấn phẩm arXiv:2310.11441, 2023.

[46] S. J. Rennie, E. Marcheret, Y. Mroueh, J. Ross, V. Goel, "Self-critical sequence training for image captioning," trong *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017.

[47] R. Ramos, B. Martins, D. Elliott, Y. Kementchedjhieva, "SmallCap: Lightweight image captioning prompted with retrieval augmentation," trong *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2023.

[48] S. Liu, Z. Zhu, N. Ye, S. Guadarrama, K. Murphy, "Improved image captioning via policy gradient optimization of SPIDEr," trong *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 873–881.

Phụ lục A

Các phương án thiết kế đã khảo sát

Phụ lục này trình bày, theo thứ tự thực hiện, các hướng đã thử trước khi chọn phương pháp đề xuất, với phần tóm tắt ở Mục 6.10. Trong các bảng, S1 là mô hình tinh chỉnh có giám sát, dùng làm mốc so sánh; S2 là mô hình mô tả phần tử; CE2-S2 là mô hình học thêm có giám sát; MIN-DESC (MIN) là mô hình sau giai đoạn học theo cặp ưu tiên; Base là mô hình gốc; câu tham chiếu là câu hướng dẫn do người chú thích viết cho bước tương ứng.

A.1 Sinh mô tả phần tử trước câu hướng dẫn

A.1.1 Thiết kế

Phương án đầu tiên yêu cầu mô hình sinh mô tả phần tử cần chạm trước khi sinh câu hướng dẫn. Mô hình huấn luyện theo thiết kế này được gọi là mô hình mô tả phần tử. Một số công trình trước cho thấy hiệu quả của bước trung gian phụ thuộc đáng kể vào dạng biểu diễn và cách đưa biểu diễn đó vào quá trình huấn luyện (Bảng A.1).

Hai cấu hình của Shikra [35] dùng cùng mô hình và bài kiểm nhưng cho kết quả trái chiều khi thay đổi dạng biểu diễn trung gian: văn xuôi làm giảm kết quả, trong khi biểu diễn có tọa độ làm tăng kết quả. GCoT [36] cũng cho thấy lợi ích xuất hiện khi bước định vị được đưa vào quy trình huấn luyện thay vì chỉ bổ sung ở prompt. Các kết quả này không cho thấy rằng mọi bước trung gian đều có lợi; chúng chỉ cung cấp

Bảng A.1: Ảnh hưởng của bước trung gian trong các công trình trước. Chênh lệch dương biểu thị cấu hình có bước trung gian đạt kết quả cao hơn.

Công trình	Phép so	Chênh lệch
Aguvis [7]	bỏ bước trung gian trên tác vụ mức thấp của AndroidControl	-11,4
Shikra (văn xuôi) [35]	bước trung gian viết bằng văn tự do	-7,4
Shikra (có tọa độ) [35]	cùng mô hình, bước trung gian có tọa độ	+5,9
GCoT [36]	huấn luyện sinh định vị trước (LLaVA-7B / 13B)	+4,5 / +5,8
CogCoM [33]	bỏ 70K dữ liệu chuỗi trung gian khỏi huấn luyện	+6,6 / +0,2 / +0,9

căn cứ để kiểm tra có kiểm soát một biểu diễn tập trung vào phần tử mục tiêu trong bài toán của đề tài.

Chuỗi đích của phương án gồm hai phần như minh họa dưới đây.

dòng mô tả phần tử	`<desc>` vai trò | tên | `<point>`x, y`</point>` | dấu hiệu phân biệt `</desc>`
phần câu	câu hướng dẫn

Lúc chấm, dòng mô tả bị cắt bỏ và mô hình định vị chỉ nhận câu hướng dẫn, nên mọi thay đổi về điểm số phải xuất phát từ thay đổi trong câu sinh. Thiết kế dựa trên ba căn cứ. Thứ nhất, dạng lỗi đã đo được chủ yếu là câu mơ hồ (Chương 1), nên dòng mô tả có một ô ghi dấu hiệu phân biệt. Thứ hai, hai cấu hình Shikra trong Bảng A.1 cho kết quả âm khi bước trung gian là văn xuôi và dương khi bước trung gian có tọa độ, nên dòng mô tả gồm bốn ô cố định và bắt buộc có tọa độ. Thứ ba, tọa độ chạm của người thật đã có sẵn trong dữ liệu, nên có thể sử dụng trực tiếp mà không cần gán nhãn bổ sung. Thiết kế còn có mục thứ hai, tức phạt mô hình khi xác suất của dòng mô tả xác định đúng phần tử không vượt xác suất của dòng mô tả trỏ sang phần tử lân cận ít nhất một khoảng lề, là phần mà Widget Captioning [9] chưa xử lý. Mục này chưa được thực hiện vì mục thứ nhất, tức bản thân dòng mô tả, chưa cho thấy tác dụng (Mục A.1.3).

A.1.2 Các cấu hình của thiết kế so sánh ban đầu

Thiết kế so sánh ban đầu gồm bảy cấu hình, dùng chung dữ liệu, mô hình gốc, siêu tham số và tập kiểm tra (Bảng A.2).

Bảng A.2: Các cấu hình của thiết kế so sánh ban đầu. Ba cấu hình cuối không cần huấn luyện.

Cấu hình	**Chuỗi phải sinh ra hoặc cách chạy**	**Vai trò**
Tinh chỉnh có giám sát (S1)	chỉ câu hướng dẫn (2 seed)	mốc so sánh
Mô tả phần tử (S2)	dòng mô tả thật + câu (2 seed)	phép so sánh chính của thiết kế ban đầu, kiểm tác dụng của việc mô tả phần tử trước
Mô tả giả (S2r)	dòng mô tả giả khớp độ dài + câu	loại trừ khả năng điểm tăng chỉ do chuỗi phải sinh ra dài thêm
Mô tả không có tọa độ (S2-nopoint)	dòng mô tả bỏ tọa độ + câu	tách phần đóng góp của tọa độ
Danh sách phần tử lúc chạy (B-infer)	trọng số S1, danh sách phần tử đưa vào đầu vào lúc chạy	so huấn luyện với việc chỉ cung cấp thông tin lúc chạy
Mô hình gốc (Base)	mô hình gốc, không tinh chỉnh	đo phần cải thiện do bản thân việc tinh chỉnh
Câu tham chiếu	câu tham chiếu được đưa trực tiếp vào quy trình đánh giá	mốc tham chiếu của độ đo

Đại lượng quan tâm là $\Delta = \mathrm{S2} - \mathrm{S1}$, tính trên trung bình hai seed của mỗi mô hình. Hai lượt huấn luyện mô hình tinh chỉnh có giám sát chỉ khác nhau ở seed, nên chênh lệch giữa chúng cho biết điểm số dao động bao nhiêu khi chỉ huấn luyện lại mà không có can thiệp nào. Bốn cấu hình không được chạy, gồm seed thứ hai của mô hình mô tả phần tử, cấu hình mô tả giả, cấu hình mô tả không có tọa độ và cấu hình chỉ đưa danh sách phần tử vào lúc chạy (lý do ở Bảng 6.13). Do thiếu seed thứ hai của mô hình mô tả phần tử, Δ không thể được ước lượng đầy đủ theo định nghĩa ban đầu; vì vậy các kết quả sau chỉ báo cáo những phép so sánh có dữ liệu tương ứng.

A.1.3 Kết quả

Mô hình mô tả phần tử đạt 57,2%, thấp hơn mô hình tinh chỉnh có giám sát 1,93 điểm ở seed 101 và 2,44 điểm ở seed 202 (Bảng 6.8); khoảng tin cậy của cả hai chênh lệch đều nằm dưới 0. Theo tiêu chí ở Mục 4.8, đây là kết quả âm, dù chưa đủ để kết luận rằng việc mô tả phần tử trước luôn gây hại. Kết quả âm này giữ nguyên khi chấm lại bằng mô hình định vị thứ hai (Mục 5.9). Mô hình vẫn hơn mô hình gốc 9,59 điểm, nên việc thêm dòng mô tả không làm mất tác dụng của việc tinh chỉnh.

Chúng tôi đã kiểm ba cách giải thích thay thế và không cách nào giải thích được chênh lệch. Ba cách đó là độ dài câu, nhóm ứng dụng, và tên ghi trong dòng mô tả bị sai do lỗi nhận dạng chữ.

A.1.3.1 Chia nhóm theo việc có sinh dòng mô tả hay không

Bảng A.3: Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không.

Nhóm	**n**	**S1**	**S2**	**Δ**
Có sinh dòng mô tả	4.138	62,2	60,8	-1,38 [−2,54; −0,19]
Không sinh dòng mô tả	325	19,7	10,8	-8,92 [−12,57; −5,25]

Theo Bảng A.3, nhóm 325 bước mà mô hình mô tả phần tử bỏ qua dòng mô tả chỉ gồm 7,3% số bước nhưng chiếm 34% toàn bộ chênh lệch. Ở nhóm này mô hình phần lớn đoán sai loại thao tác, trong khi câu tham chiếu vẫn đạt 68,3%, cho thấy các bước này vẫn có thể đạt điểm cao với một câu hướng dẫn phù hợp. Mô hình gốc gọi đúng loại thao tác ở 83,4% số bước trong nhóm, mô hình tinh chỉnh có giám sát ở 55,1% và mô hình mô tả phần tử ở 38,8%. Như vậy chính việc tinh chỉnh đã làm lệch xu hướng chọn loại thao tác, và việc thêm dòng mô tả khuếch đại độ lệch ấy. Một giả thuyết là mô hình học một tương quan tắt từ dữ liệu, vì tập huấn luyện chỉ gắn dòng mô tả cho bước chạm, nên mô hình có thể học quy tắc "đã viết dòng mô tả thì là chạm". Giả thuyết này chưa được kiểm vì cấu hình mô tả không có tọa độ không được tiếp tục. Nhóm này được định nghĩa bằng hành vi của chính mô hình mô tả phần tử, nên việc mô hình này kém trên nhóm một phần là hệ quả của cách chia nhóm. Dù vậy, mô hình

tinh chỉnh có giám sát cũng chỉ đạt 19,7% trên cùng nhóm.

A.1.3.2 Ảnh hưởng hai chiều của dòng mô tả

Bảng A.4: Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh. Cột Tham chiếu là điểm của câu tham chiếu trên chính nhóm đó.

Tên	Tọa độ	n	Base	S1	S2	Tham chiếu
đúng	đạt	1.871	69,0	81,4	87,1	86,6
đúng	không đạt	184	23,4	25,5	26,1	31,0
sai	đạt	452	41,4	56,4	57,5	72,8
sai	không đạt	738	24,4	30,8	5,6	66,3
không sinh dòng mô tả		228	25,9	20,6	9,6	70,6

Bảng A.4 chia các bước được chấm theo việc dòng mô tả do chính mô hình mô tả phần tử sinh ra có đúng tên và tọa độ hay không. Khi đúng cả hai, mô hình đạt 87,1%, hơn mô hình tinh chỉnh có giám sát 5,7 điểm và vượt cả câu tham chiếu trên nhóm đó. Khi sai cả hai, mô hình chỉ còn 5,6%, thấp hơn cả mốc tham chiếu dưới dùng câu chung chung không nói phần tử nào (12,0%, Mục 5.5), trong khi câu tham chiếu vẫn đạt 66,3% trên 738 bước ấy. Ở nhóm này mô hình đã chọn một phần tử sai rồi viết câu khẳng định về phần tử đó, còn mô hình tinh chỉnh có giám sát viết câu chung chung nên vẫn có khả năng đạt tiêu chí. Dòng mô tả vì vậy khuếch đại kết quả theo cả hai chiều, và đây là căn cứ của giai đoạn học theo cặp ưu tiên (Mục A.2.1).

A.2 Học theo cặp ưu tiên trên dòng mô tả

A.2.1 Thiết kế

Kết quả của mô hình mô tả phần tử cho thấy chất lượng dòng mô tả có liên hệ chặt với kết quả chung (Mục A.1.3.2). Vì học có giám sát chỉ tối ưu xác suất của chuỗi đích, giai đoạn tiếp theo bổ sung mục tiêu ưu tiên trên các cặp đầu ra gần nhau. Giai đoạn này, gọi tắt là học theo cặp ưu tiên và ký hiệu MIN-DESC trong bảng, học tiếp 800 bước từ trọng số của mô hình mô tả phần tử.

vế được chọn	<desc>mô tả trỏ đúng phần tử</desc> + \n + câu
vế bị loại	<desc>mô tả trỏ sai phần tử</desc> + \n + đúng câu đó

Hai vế chỉ khác nhau ở dòng mô tả, nên số hạng ưu tiên chỉ giảm được khi mô hình chọn đúng phần tử. Dòng mô tả trỏ sai là mô tả của một phần tử có thật, cùng vai trò, nằm gần phần tử cần chạm; quy trình xây dựng 22.854 cặp được trình bày ở Mục 3.7. Hàm mục tiêu thuộc họ tối ưu theo ưu tiên dạng tỉ số odds (ORPO), không cần mô hình tham chiếu đóng băng.

Để tách phần của mục tiêu ưu tiên khỏi phần của việc học thêm, mô hình học thêm có giám sát (CE2-S2) học có giám sát thuần trên vế được chọn của các cặp ấy, cùng điểm xuất phát và số bước. Đại lượng chính là hiệu ghép cặp Δ_thành phần = MIN-DESC − CE2-S2, tính trên cùng các bước của tập kiểm tra (Mục 4.8). Tập cặp chỉ chứa bước chạm, nên thiệt hại ở bước không chạm được đo riêng (Mục A.2.2.4).

A.2.2 Kết quả

A.2.2.1 Độ chính xác của dòng mô tả

Bảng A.5 đối chiếu trực tiếp dòng mô tả do mô hình tự sinh với nhãn chuẩn của tập kiểm tra, không cần gọi mô hình định vị.

Bảng A.5: Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình.

Mô hình	Sinh dòng mô tả	Tên đúng	Tọa độ đúng	Cả hai đúng
Mô tả phần tử (S2)	93,4%	59,2%	66,9%	53,9%
Học thêm có giám sát (CE2-S2)	99,6%	66,2%	71,2%	59,8%
Học theo cặp ưu tiên (MIN-DESC)	99,6%	67,0%	71,8%	60,6%

So với mô hình mô tả phần tử, tỉ lệ đúng cả tên lẫn tọa độ sau giai đoạn học theo cặp ưu tiên tăng 6,77 điểm. Mô hình học thêm có giám sát cũng đạt 5,93 điểm trong mức tăng ấy, nên phần riêng của mục tiêu ưu tiên chỉ là 0,84 điểm, và 87,7% mức tăng đến từ chính việc học thêm.

A.2.2.2 Executability và đại lượng chính

Sau giai đoạn học theo cặp ưu tiên, mô hình đạt 60,0%, còn cấu hình chỉ học thêm có giám sát đạt 59,4% (Bảng 6.1). Chênh lệch trực tiếp giữa hai cấu hình là +0,63 điểm, với khoảng tin cậy 95% [+0,16; +1,10] và p = 0,011. Tuy nhiên, 2,24 trong 2,87 điểm cải thiện so với mô hình mô tả phần tử đã xuất hiện ở cấu hình chỉ học thêm, cho thấy phần lớn mức tăng đến từ việc tiếp tục huấn luyện. So với S1/101, MIN-DESC cao hơn 0,94 điểm nhưng khoảng tin cậy vẫn chứa 0.

A.2.2.3 Biến thể lấy về bị loại theo chính sách

Ngoài nguồn cặp được xây dựng bằng quy tắc (cửa sổ 80–350 điểm ảnh quanh phần tử mục tiêu), chúng tôi thử biến thể on-policy, trong đó vế bị loại lấy từ chính phần tử mô hình dự đoán sai. Trên 14.000 màn huấn luyện chỉ thu được 459 cặp hợp lệ (3,3%). Phân bố lỗi cho thấy mô hình thường rơi vào một trong hai trường hợp: gọi đúng phần tử bằng tên khác, hoặc xác định một vùng cách xa phần tử mục tiêu; lỗi nhầm giữa hai nút lân cận xuất hiện ít hơn giả định ban đầu. Vì vậy biến thể on-policy không cung cấp đủ cặp phù hợp để tiếp tục huấn luyện.

A.2.2.4 Ảnh hưởng trên các bước không chạm

Bảng A.6: Khớp loại thao tác trên mẫu 400 bước không chạm (cuộn 96, chờ 86, gõ chữ 82, mở ứng dụng 81, quay lại 55), đánh giá với biến thể nghiêm ngặt của điều kiện khớp loại thao tác.

Mô hình	Khớp loại thao tác	Δ so với S2
Mô tả phần tử (S2)	83,5%	–
Học thêm có giám sát (CE2-S2)	63,0%	-20,50
Học theo cặp ưu tiên (MIN-DESC)	63,8%	-19,75

Đánh giá ở bước không chạm (Mục 5.13) cho thấy sau giai đoạn học theo cặp ưu tiên, mức khớp loại thao tác giảm mạnh ở nhóm bước này (Bảng A.6). Mức giảm tập trung ở cuộn ($-43{,}8$), quay lại ($-36{,}4$) và gõ chữ ($-29{,}2$), ba loại thao tác mà câu tham

chiếu không nhắc tên phần tử nào; hai loại chờ và mở ứng dụng không giảm, chủ yếu do phép chuẩn hoá loại thao tác xếp động từ "mở" vào lớp chạm. Mô hình học thêm có giám sát giảm ở mức gần tương đương ($-20{,}50$ so với $-19{,}75$), nên mức giảm gắn với việc học thêm trên dữ liệu chỉ gồm bước chạm, không phải với mục tiêu ưu tiên. Executability chỉ đánh giá bước chạm nên không phản ánh mức giảm này.

A.2.3 Phân tích điểm nghẽn của cơ chế mô tả phần tử

Cách chia nhóm dựa trên hành vi của chính mô hình được đo. Hai nhóm khác nhau nhiều về độ khó, nên chỉ phép so sánh ghép cặp bên trong một nhóm là hợp lệ. Bảng A.7 chia 3.473 bước có tên đúng để đối chiếu theo việc dòng mô tả của MIN-DESC trỏ đúng phần tử (tên khớp và tọa độ nằm trong dung sai 14%) hay trỏ sai.

Bảng A.7: Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. Cột Tham chiếu là điểm của câu tham chiếu trên chính nhóm đó.

Nhóm	n	MIN-DESC	S1	Δ ghép cặp	Tham chiếu
Trỏ đúng phần tử	2.106 (60,6%)	87,1	78,3	+8,83	86,3
Trỏ sai phần tử	1.367 (39,4%)	21,8	32,9	-11,12	61,4

Khi dòng mô tả xác định đúng phần tử, MIN-DESC hơn mô hình tinh chỉnh có giám sát 8,83 điểm và vượt cả điểm của câu tham chiếu trên nhóm đó; khi dòng mô tả xác định sai, MIN-DESC thấp hơn 11,12 điểm. Hai chiều gần như triệt tiêu nhau, chỉ còn lại mức +0,94 điểm không có ý nghĩa thống kê (Mục A.2.2). Kết quả này phù hợp với giả thuyết rằng biểu diễn mô tả phần tử có thể hỗ trợ câu sinh khi xác định đúng mục tiêu, nhưng lợi ích chỉ xuất hiện trên 60,6% số bước mà dòng mô tả xác định đúng phần tử.

Ngưỡng tối đa lý thuyết khi bù được phần thiệt ở các bước mô tả sai. Giả sử ở mỗi bước mà dòng mô tả xác định sai, MIN-DESC cho đúng kết quả của mô hình tinh chỉnh có giám sát. Khi đó điểm trên 3.473 bước có tên đúng để đối chiếu sẽ là 65,8% thay vì 61,4% thực đo, tức cao hơn mô hình tinh chỉnh có giám sát 5,4 điểm. Mức này không đạt được ở khâu suy luận bằng một quy tắc chọn câu ở từng bước, tức

quyết định lấy câu của MIN-DESC hay câu của mô hình tinh chỉnh có giám sát. Một quy tắc hoàn hảo, biết trước dòng mô tả xác định đúng hay sai, cho 63,5% trên toàn bộ 4.463 bước, nhưng bảy quy tắc thực tế đã thử chỉ cho 60,0 đến 60,3%, không khác biệt rõ so với mức 60,0% của MIN-DESC. Điểm nghẽn này vì vậy cần được xử lý ở khâu huấn luyện.

Bảng A.8: Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). Cột cuối là phần dư địa tới mức câu tham chiếu mà mỗi nhóm đóng góp, tính bằng điểm trên toàn tập bước được chấm.

Nhóm	n	%	MIN	S1	Tham chiếu	Dư địa
tên đúng, tọa độ đúng	2.082	46,7	87,1	78,2	86,3	-0,36
tên đúng, tọa độ sai	220	4,9	26,4	27,7	32,3	+0,29
tên sai, tọa độ đúng	411	9,2	57,2	53,0	73,0	+1,46
không sinh dòng mô tả	15	0,3	0,0	0,0	60,0	+0,20
tên sai, tọa độ sai	745	16,7	3,6	25,8	64,4	+10,15
không có tên để đối chiếu	990	22,2	55,3	54,4	73,0	+3,94
Tổng	**4.463**		**60,0**	**59,1**	**75,7**	**+15,7**

Theo Bảng A.8, nhóm đúng cả tên lẫn tọa độ chiếm 46,7% số bước và không còn dư địa nếu lấy điểm của câu tham chiếu trên nhóm làm mốc, vì MIN-DESC đã vượt mốc này. Phần lớn dư địa còn lại (63%) nằm ở nhóm sai cả tên lẫn tọa độ. Trên nhóm này MIN-DESC chỉ đạt 3,6% và mô hình tinh chỉnh có giám sát đạt 25,8%, trong khi câu tham chiếu đạt 64,4%, nên đây không phải nhóm bước bất khả thi.

A.3 Chọn phần tử trong danh sách ứng viên

A.3.1 Thiết kế

Phân tích ở Mục A.2.3 cho thấy phần lớn dư địa còn lại của MIN-DESC nằm ở những bước mà dòng mô tả sai cả tên lẫn tọa độ. Vì vậy, thay vì để mô hình tự viết dòng mô tả, chúng tôi cho mô hình chọn phần tử trong danh sách lấy từ chính màn hình; mô hình huấn luyện theo cách này gọi là mô hình chọn ứng viên. Căn cứ là ba con số đo được trước khi huấn luyện. Tên đúng có mặt trong chữ OCR hoặc cây trợ năng ở

99,7% số bước. Ở 80,2% số bước có một ứng viên vừa khớp tên vừa nằm trong dung sai, so với 59,9% của dòng mô tả tự sinh. Ở 67,7% số bước mà MIN-DESC gọi sai tên, tên đúng đã nằm sẵn trong 24 dòng OCR của prompt nhưng không kèm vị trí.

Cách làm. Prompt thay 24 dòng OCR bằng danh sách ứng viên ở Mục 3.8. Chuỗi đích mở đầu bằng một thẻ chọn, là bản chép nguyên văn một dòng trong danh sách hoặc thẻ `none`, rồi mới tới câu; thẻ này được cắt bỏ trước khi chấm. Danh sách phần tử có cấu trúc đã được sử dụng trong các công trình trước (Chương 1); trong phương án này, thành phần được khảo sát là cơ chế chọn tường minh, tức mô hình ghi rõ ứng viên được chọn ngay trong chuỗi đích.

Điều kiện thí nghiệm. Mô hình chọn ứng viên khác mô hình tinh chỉnh có giám sát (S1) và MIN-DESC ở ba biến. Ngữ cảnh dài 3072 thay vì 2560 token để chứa danh sách ứng viên (mẫu dài nhất 2.017 token cộng danh sách dài nhất 1.012 token), số lượt duyệt chỉ còn một (4.036 bước) do giới hạn tài nguyên, và đầu vào có thêm danh sách ứng viên. Vì vậy điểm của mô hình này không thể so sánh trực tiếp với điểm của hai mô hình kia. Đại lượng hợp lệ là hiệu ghép cặp Δ_chọn với một cấu hình đối chứng nhận cùng danh sách ứng viên ở đầu vào nhưng chuỗi đích chỉ có câu, còn các tham số khác giữ như Bảng 4.1. Thiết kế ban đầu gồm sáu lượt huấn luyện (ba cấu hình, mỗi cấu hình hai seed), nhưng năm lượt sau chỉ được chạy nếu lượt đầu cho độ chính xác chọn hơn rõ tỉ lệ 60,6% dòng mô tả xác định đúng phần tử của MIN-DESC. Độ chính xác chọn là tỉ lệ thẻ chọn đúng phần tử cần chạm (tên khớp, tọa độ trong dung sai 14%) trên những bước mà danh sách có chứa phần tử ấy, tức có ứng viên đúng, đo trên 1.400 bước chạm đầu của tập kiểm tra.

A.3.2 Kết quả

Mô hình chọn ứng viên được huấn luyện với seed 101 trên 64.567 mẫu của Mục 3.8.

A.3.2.1 Độ chính xác chọn và executability

Trên 1.400 bước dùng làm tiêu chí, 1.008 bước có ứng viên đúng và thẻ chọn đúng ở 580 bước, cho độ chính xác chọn 57,54%, thấp hơn mức 60,6% của MIN-DESC, nên năm lượt còn lại không được chạy. Từ đây, 1.400 bước này được gọi là *mẫu phát*

triển, còn 3.062 bước còn lại chỉ dùng để đọc kết quả. Độ chính xác chọn không phù hợp làm tiêu chí duy nhất để ra quyết định, vì cũng như cột "có đáp án" của SQuAD 2.0 [39], đại lượng này chỉ đếm những bước có đáp án. Khi ép mô hình luôn chọn, độ chính xác chọn lên 69,05%, nhưng tỉ lệ thẻ đúng trên cả mẫu phát triển giảm từ 63,43% xuống 49,71%.

Trên 4.463 bước chạm, mô hình chọn ứng viên đạt 56,1%, khoảng tin cậy [54,2; 58,0] (bootstrap theo 1.091 cụm), với tỉ lệ khớp loại thao tác 90,9% và tỉ lệ đạt tiêu chí ô Voronoi 57,4%. Điểm trên mẫu phát triển (55,4%) và trên phần còn lại (56,5%) gần nhau. Mô hình hơn mô hình gốc (chưa tinh chỉnh) 8,54 điểm (731 bước chỉ mô hình chọn ứng viên đúng, 350 bước chỉ mô hình gốc đúng, kiểm định McNemar cho $p < 0{,}001$); đây là phép so sánh duy nhất có thể được dùng để rút ra kết luận trực tiếp. Cấu hình đối chứng nhận cùng danh sách ứng viên nằm trong năm lượt không được chạy, nên không tính được Δ_chọn và chưa thể tách riêng ảnh hưởng của cơ chế chọn tường minh khỏi ảnh hưởng của danh sách ứng viên.

A.3.2.2 Hành vi chọn và từ chối chọn

Bảng A.9: Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. Hàng đầu và hàng cuối là hành vi đúng, hai hàng giữa là hai dạng lỗi.

Có ứng viên đúng	Mô hình	n	% tập	Exec.	Khớp thao tác
có	**chọn**	2.326	52,1	**71,4 [69,5; 73,2]**	99,1
có	**từ chối (sai)**	872	19,5	**23,7 [21,0; 26,7]**	71,2
không	chọn (sai)	264	5,9	37,5	99,6
không	**từ chối (đúng)**	1.001	22,4	53,8	86,6

Khi danh sách chứa ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4%, chỉ thấp hơn câu tham chiếu 4,3 điểm. Hạn chế chính nằm ở 872 bước, tương ứng 27,3% số bước có ứng viên đúng, mà mô hình vẫn phát thẻ từ chối chọn; nhóm này chỉ đạt 23,7%. Tỉ lệ từ chối nhầm gần trùng với mức 27,1% trên mẫu phát triển. Kết quả cho thấy chất lượng xếp hạng ứng viên không phải vấn đề duy nhất; quyết định có đưa ra lựa chọn hay không đóng vai trò đáng kể.

Dấu hiệu đi kèm việc từ chối chọn. Câu mang động từ không phải chạm chiếm 28,3% số bước từ chối chọn, so với 0,97% ở bước đưa ra lựa chọn, giống hiện tượng lẫn loại thao tác ở Mục A.1.3.1. Sai số của mô hình định vị ở nhóm từ chối chọn có trung vị 19,9% bề ngang màn, so với 0,78% ở nhóm còn lại, tức mô hình xác định một vùng khác của màn như dạng lỗi lưỡng cực ở Mục A.2.2.3. Tỉ lệ từ chối chọn tăng theo độ dài danh sách (Bảng A.10), nhưng các màn hình có nhiều phần tử cũng thường khó hơn, nên quan sát này chỉ phản ánh tương quan.

Bảng A.10: Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng.

Số dòng trong danh sách	n	Từ chối chọn	Exec.
1 đến 5	178	18,5%	70,8
6 đến 10	363	15,7%	70,5
11 đến 20	826	25,9%	60,3
21 đến 39	1.036	29,3%	55,6
40 (mức tối đa)	795	33,2%	51,8

Tỉ lệ từ chối chọn cũng cao hơn khi ứng viên đúng nằm giữa danh sách (31,4%, so với 27,2% ở phần đầu và 24,3% ở phần cuối), giống hiện tượng Liu và cộng sự [41] mô tả cho ngữ cảnh dài. Đây là quan sát chưa qua kiểm định, và vị trí trong danh sách có tương quan với độ dài danh sách.

A.3.2.3 Phân bố nhãn từ chối chọn trong tập huấn luyện

Bảng A.11: Tỉ lệ thẻ `none` theo bốn mẫu số. Mô hình phát `none` nhiều hơn tỉ lệ đúng trên loại bước bị đánh giá, và ít hơn tỉ lệ gặp trên toàn tập huấn luyện.

Mẫu số	Tỉ lệ `none`
Toàn bộ tập huấn luyện (64.567 mẫu)	54,78%
Chỉ bước chạm của tập huấn luyện (41.191)	29,12%
Bước chạm của tập kiểm tra, tỉ lệ đúng (4.463)	28,34%
Tỉ lệ mô hình phát ra trên tập kiểm tra	41,97%

Tỉ lệ mô hình phát ra nằm giữa tỉ lệ đúng trên bước chạm và tỉ lệ trên toàn tập huấn luyện, và gần tỉ lệ toàn tập hơn. Vì mọi bước không chạm đều mang thẻ `none` (Mục 3.8), thẻ này chiếm hơn một nửa số mẫu huấn luyện. Một cách giải thích phù hợp với quan sát là mô hình học tiên nghiệm của nhãn này trên toàn bộ tập huấn luyện rồi duy trì xu hướng đó khi xử lý bước chạm, là loại bước duy nhất được chấm. Rajpurkar và cộng sự [39] nêu hiện tượng tương tự cho SQuAD 2.0, còn Menon và cộng sự [40] chứng minh rằng dưới dạng lệch phân bố nhãn, sửa tiên nghiệm lúc huấn luyện tương đương với sửa sau huấn luyện. Tỉ lệ đúng trên bước chạm của tập huấn luyện (29,12%) và của tập kiểm tra (28,34%) chỉ chênh 0,8 điểm, nên phân bố nhãn trên riêng nhóm bước chạm gần như không thay đổi giữa hai tập; quan hệ nhân quả giữa tiên nghiệm toàn tập và mức từ chối chọn thì chưa được chứng minh.

Chúng tôi cũng đánh giá ba phương án hiệu chỉnh khác. Sửa toàn bộ lỗi loại thao tác chỉ thêm 1,21 điểm. Rút danh sách còn mười dòng hạ độ phủ ứng viên đúng từ 71,7% xuống nhiều nhất 51,7%. Nới dung sai tọa độ chỉ nâng độ phủ lên 76,0% nhưng đồng thời làm thay đổi nhãn huấn luyện. Hướng còn lại là huấn luyện lại chỉ trên 41.191 bước chạm để đưa tiên nghiệm về 29,12%.

A.3.2.4 Ghép với giai đoạn học theo cặp ưu tiên và hiệu chỉnh mức từ chối chọn

Ghép hai mô hình theo quy tắc "bước nào mô hình chọn ứng viên từ chối chọn thì lấy câu của MIN-DESC" cho 60,7%, chỉ hơn MIN-DESC 0,67 điểm và nhỏ hơn mức chênh giữa hai seed. Ngay cả một quy tắc biết trước ở từng bước mô hình nào đúng cũng chỉ đạt 66,1%.

Trước khi huấn luyện lại, chúng tôi thử hiệu chỉnh mức từ chối chọn sau huấn luyện. Theo Menon và cộng sự, nếu hiệu chỉnh hậu xử lý không khắc phục được các bước từ chối nhầm thì khả năng huấn luyện lại chỉ để sửa tiên nghiệm nhãn cũng bị hạn chế. Thủ tục này chọn ứng viên có log-xác suất cao nhất khi điểm ấy hơn điểm của thẻ `none` quá một ngưỡng τ, với ngưỡng và ba biến thể cách xếp hạng được quét trên mẫu phát triển. So với hành vi hiện tại (888 trên 1.400 bước đúng), biến thể tốt nhất chỉ thêm +8 bước (khoảng tin cậy từ -11 đến +27), tức +0,6 điểm.

Theo tổng log-xác suất, ứng viên đúng đứng đầu ở 67,5% số bước có ứng viên đúng, trong khi điểm của thẻ `none` chỉ phân tách hạn chế giữa bước có và không có

ứng viên đúng (AUC 0,69–0,72). Vì vậy điểm nghẽn quan sát được nằm ở quyết định từ chối chọn. Hiệu chỉnh ngưỡng làm tăng số bước chuyển từ sai sang đúng nhưng đồng thời tạo số bước chuyển theo chiều ngược lại gần tương đương, nên hướng này được dừng ở mức phân tích.

A.4 Huấn luyện tăng cường với phần thưởng tọa độ

A.4.1 Thiết kế

Căn cứ và phần thưởng. Hai giai đoạn trước tối ưu trên các chuỗi mục tiêu có sẵn. Giai đoạn huấn luyện tăng cường với phần thưởng tọa độ tiếp tục từ MIN-DESC bằng GRPO (Mục 2.3). Với mỗi prompt, mô hình sinh nhiều đầu ra và nhận phần thưởng dựa trên ba thành phần: 1,0 nếu tọa độ trong thẻ `<point>` nằm trong cửa sổ $\pm$14% quanh tọa độ tham chiếu; 0,2 nếu dòng mô tả đủ trường và đúng thứ tự; 0,1 nếu tên phần tử khớp nhãn. Mô hình định vị không tham gia vào phần thưởng.

Cấu hình và giới hạn. Giai đoạn này học tiếp từ checkpoint của MIN-DESC với cùng lượng tử hoá bốn bit và phần thị giác đóng băng. Mỗi prompt sinh bốn câu trả lời ở nhiệt độ 1,0; mô hình tham chiếu cho số hạng ràng buộc độ lệch là bản sao đóng băng của checkpoint xuất phát. Tập thưởng gồm 2.000 bước chạm của tập huấn luyện, duyệt một lượt (500 bước cập nhật). Tập này chỉ gồm bước chạm vì chỉ bước chạm có tọa độ chuẩn; ảnh hưởng lên các bước còn lại được đo ở Mục A.2.2.4.

A.4.2 Kết quả

Trên 4.463 bước chạm, MIN-DESC (seed 101) và mô hình sau giai đoạn thưởng tọa độ đạt 60,05% và 60,07% executability, với khoảng tin cậy lần lượt [58,35; 61,79] và [58,32; 61,83]. Mức chênh ghép cặp là +0,02 điểm (98 bước chỉ mô hình giai đoạn hai đúng, 99 bước chỉ mô hình giai đoạn ba đúng, χ^2 = 0,00, p = 1, khoảng tin cậy [−0,59; +0,64]), nên không phân biệt được hai mô hình. Khớp loại thao tác (98,88 so với 98,86) và quy tắc hộp phần tử của AndroidControl (66,55 so với 67,04) cũng gần như không đổi. Trước khi chấm, chúng tôi dự báo mức tăng executability bằng cách

nhân mức tăng độ chính xác của dòng mô tả với hệ số chuyển đổi 0,43 đo ở giai đoạn hai (số điểm executability tăng thêm ứng với mỗi điểm tăng của dòng mô tả), được +1,10 điểm [+0,59; +1,49]. Mức đo được ứng với hệ số chỉ khoảng 0,01, nên hệ số chuyển đổi không cố định mà phụ thuộc dạng can thiệp.

Hai chiều tác động triệt tiêu nhau. Ở 164 bước mà giai đoạn ba sửa dòng mô tả từ sai thành đúng, executability tăng từ 32,9 lên 70,7; ở 75 bước mà giai đoạn ba làm dòng mô tả từ đúng thành sai, executability giảm từ 69,3 xuống 29,3. Một bước được coi là đổi kết quả chấm khi bước ấy chuyển từ không đạt sang đạt hoặc ngược lại. Đếm số bước đổi kết quả chấm (không đạt thành đạt tính +1, đạt thành không đạt tính -1), bốn nhóm (sửa đúng, làm sai, giữ nguyên, không có tên đối chiếu) cho +62, -30, -14 và -17, với tổng ròng chỉ +1. Trong 1.950 bước có dòng mô tả thay đổi, 1.300 bước (66,7%) có câu không đổi một ký tự, và toàn bộ 197 lần đổi kết quả chấm nằm trong 961 bước có câu thay đổi.

Hệ quả. Phần thưởng cải thiện trực tiếp biểu diễn trung gian, với +2,56 điểm ở dòng mô tả ($p = 1{,}3 \times 10^{-8}$), nhưng không có số hạng nào ràng buộc câu. Khi trọng số thay đổi, câu cũng thay đổi ở những bước mà phần thưởng không cung cấp tín hiệu, và mức suy giảm ở các bước này bù trừ phần cải thiện đạt được ở những bước khác. Cấu hình đối chứng chỉ huấn luyện thêm có giám sát trên cùng tập thưởng không được chạy vì mức chênh executability gần bằng không, nên 2,56 điểm chưa tách được khỏi phần do việc học thêm đem lại. Phép đo dòng mô tả lại dùng đúng cửa sổ của phần thưởng, nên đại lượng độc lập còn lại chỉ là executability.

A.4.3 Nội suy trọng số giữa hai checkpoint

Giai đoạn ba nối tiếp giai đoạn hai, nên hai bộ trọng số chỉ khác nhau tương đối ít. Phép thử này xây dựng năm điểm trên đoạn nối hai bộ trọng số (kể cả hai đầu mút), bằng cách ghép các ma trận hạng thấp của hai bộ chuyển đổi LoRA ở từng mô-đun theo tỉ lệ pha trộn, rồi chấm trên tập kiểm định nội bộ. Giả thuyết là một điểm ở giữa có thể giữ phần sửa của giai đoạn ba mà tránh bớt phần làm sai. Đường cong đơn điệu, với cực đại tại đầu mút giai đoạn ba. Điểm giữa tốt nhất thấp hơn đầu mút 0,38 điểm, mọi phép so sánh ghép cặp giữa các mức đều có khoảng tin cậy phủ 0, nên không cấu hình mới nào được đánh giá trên tập kiểm tra. Số bước có câu khác đầu mút giai đoạn

hai tăng đều theo mức pha trộn (53, 95, 127 rồi 155 trên 407 bước), cho thấy phép ghép hoạt động đúng. Dư địa vốn hẹp, vì giai đoạn ba chỉ dịch hai ma trận hạng thấp 1,39% và 6,87% so với giai đoạn hai.

Mức lạc quan của tập kiểm định nội bộ. Cả hai checkpoint đều đã học trên tập này (Mục 3.3). Trên tập ấy, mức chênh giữa hai mô hình lớn gần bốn mươi lần mức chênh trên tập kiểm tra, và điểm tuyệt đối cao hơn khoảng bảy điểm rưỡi, nên tập này chỉ dùng để xếp hạng biến thể trong cùng một họ.

A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn

Các phương án từ Mục A.1.3 tới đây chưa tạo ra mức cải thiện rõ so với S1 theo executability. Mục này phân rã quá trình từ ảnh tới câu thành hai khâu: nhận diện phần tử, đo bằng tọa độ mô hình ghi trong dòng mô tả; và sinh câu hướng dẫn, đo bằng tọa độ mà mô hình định vị suy ra từ câu. Hai đại lượng được đánh giá với cùng cửa sổ dung sai 14%. Trên 4.442 bước có dòng mô tả hợp lệ, MIN-DESC đạt 70,10% ở khâu nhận diện phần tử và 69,36% ở khâu sinh câu.

Bảng A.12: Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. Cột câu tham chiếu là điểm của câu do người chú thích viết, đo trên cùng nhóm bước.

Nhóm	n	MIN-DESC	S1	Câu tham chiếu
Nhận ra đúng phần tử	3.114 (70,1%)	82,37	74,18	84,36
Nhận ra sai phần tử	1.328 (29,9%)	8,43	24,47	55,72

Khoảng cách dồn vào một phần ba số bước. Trên toàn tập bước được chấm, câu tham chiếu hơn MIN-DESC 15,53 điểm. Nhóm mà mô hình nhận ra đúng phần tử (70,1% số bước) chỉ đóng góp 1,40 điểm, tức 9,0% khoảng cách. Nhóm nhận ra sai (29,9% số bước) đóng góp 14,14 điểm, tức 91,0%.

Chênh lệch theo trạng thái nhận diện phần tử. Nhóm mà mô hình nhận diện sai phần tử cũng khó hơn đối với câu tham chiếu. Tuy nhiên, mức giảm của MIN-DESC lớn hơn đáng kể: từ 82,37 xuống 8,43, trong khi câu tham chiếu giảm từ 84,36 xuống

55,72. Quan sát này cho thấy lỗi nhận diện phần tử có liên hệ mạnh với chất lượng câu sinh, dù cách chia nhóm chưa cho phép diễn giải hoàn toàn theo quan hệ nhân quả.

Mức cải thiện ở khâu nhận diện phần tử chuyển hóa hạn chế thành executability. Trong các can thiệp đã chạy, chỉ giai đoạn thưởng tọa độ đặt phần thưởng trực tiếp lên tọa độ trong dòng mô tả, nên đây là chỗ đo trực tiếp được phần cải thiện ấy chuyển thành bao nhiêu điểm executability. Trên 4.437 bước ghép cặp được, giai đoạn này nâng tỉ lệ nhận diện đúng phần tử 1,60 điểm nhưng chỉ nâng executability 0,045 điểm, tương ứng 0,028 điểm executability cho mỗi điểm tăng ở tỉ lệ nhận diện đúng phần tử (tỉ số giữa hai mức tăng).

Bảng A.13: Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm.

Nhóm	n	MIN-DESC	Giai đoạn ba	Chênh
giữ đúng	2.997	83,08	82,95	-0,13
giữ sai	1.143	6,91	6,30	-0,61
sai chuyển thành đúng	184	17,93	58,15	+40,22
đúng chuyển thành sai	113	62,83	8,85	-53,98

Bảng A.13 cho thấy vì sao con số này nhỏ. Giai đoạn ba sửa được 184 bước với mức tăng 40,22 điểm mỗi bước nhưng làm sai 113 bước với mức giảm 53,98 điểm mỗi bước, nên hai chiều gần như triệt tiêu.

Tương quan giữa các mô hình không phản ánh hệ số quy đổi giữa hai đại lượng. Giữa các mô hình đã huấn luyện, tỉ lệ nhận diện đúng phần tử và executability tương quan ở mức 0,739, nhưng tỉ số đo được trong can thiệp thực nghiệm chỉ là 0,028, nhỏ hơn 26 lần. Tương quan này phản ánh việc mô hình mạnh thường mạnh ở cả hai khâu, nhưng không cho biết mức thay đổi của executability khi chỉ can thiệp vào khâu nhận diện phần tử.

Giới hạn. Cách chia nhóm dựa trên hành vi của chính mô hình được đo, nên chỉ phép so sánh giữa hai mô hình bên trong một nhóm là hợp lệ. Mẫu số 4.442 nhỏ hơn 4.463 vì 21 bước có dòng mô tả thiếu hoặc sai định dạng.

A.5.1 Độ ổn định của ước lượng trên nhóm con

Bảng A.12 gợi ra một can thiệp chỉ thay câu. Trên nhóm mà MIN-DESC nhận ra sai phần tử, thay câu của MIN-DESC bằng câu của mô hình tinh chỉnh có giám sát (S1) đưa điểm trên toàn tập bước được chấm lên 65,04 (+4,80 điểm), còn thay bằng câu tham chiếu đưa lên 74,40 (+14,14 điểm). Mục này đánh giá độ ổn định của ước lượng 4,80 điểm và cho thấy ước lượng này không đủ tin cậy để làm căn cứ thiết kế. Nhóm được định nghĩa bằng tọa độ do chính MIN-DESC viết ra, mà tọa độ ấy và câu của mô hình này đến từ cùng một lượt sinh nên có chung nhiều yếu tố ngẫu nhiên. Chọn những bước mà MIN-DESC nhận ra sai phần tử là chọn ra những bước lượt sinh ấy gặp bất lợi, nên trên nhóm này MIN-DESC có kết quả thấp hơn một cách hệ thống so với bất kỳ mô hình nào khác.

Bảng A.14: Ngưỡng tối đa của một can thiệp chỉ thay câu, dưới bốn cách định nghĩa nhóm (4.437 bước ghép cặp được). Cột cuối là mức tăng trên toàn tập bước được chấm khi thay câu của MIN-DESC (cột MIN) trên nhóm đó bằng câu của S1.

Cách định nghĩa nhóm	n	MIN	S1	Câu tham chiếu	Dư địa
MIN-DESC nhận ra sai phần tử	1.327	8,44	24,49	55,69	+4,80
giai đoạn ba nhận ra sai phần tử	1.256	11,94	22,13	54,70	+2,88
giai đoạn ba sai mà MIN-DESC đúng	113	62,83	34,51	60,18	-0,72
30% màn hình có nhiều phần tử có thể chạm nhất	1.331	58,53	56,35	73,55	-0,65

Bảng A.14 đổi cách định nghĩa nhóm ba lần. Khi nhóm được định nghĩa bằng tọa độ của mô hình sau giai đoạn thưởng tọa độ, tức hành vi của một mô hình khác, ngưỡng tối đa còn 2,88. Khi lấy phần giai đoạn ba sai còn MIN-DESC đúng, ngưỡng tối đa đổi dấu. Khi dùng số phần tử có thể chạm trên màn, không dựa vào hành vi của mô hình nào, ngưỡng tối đa là $-0{,}65$. Trong khi đó, cột câu tham chiếu tương đối ổn định ở ba hàng đầu (55,69, 54,70 và 60,18) và chỉ cao hơn ở hàng cuối, vốn là nhóm dễ hơn. Ưu thế giữa hai mô hình cùng họ thay đổi theo cách chia nhóm trong khi khoảng cách tới câu tham chiếu tương đối ổn định, và đây là dấu hiệu của hiệu ứng chọn nhóm.

Hệ quả cho phân tích. Mọi ngưỡng tối đa ước lượng từ một nhóm định nghĩa bằng hành vi của chính mô hình được đo phải được kiểm lại với ít nhất một cách chia

nhóm khác trước khi dùng làm căn cứ. Nguyên tắc này áp dụng cả cho những con số thuận lợi ở Mục A.2.3, và trong đề tài này đã ngăn một lượt huấn luyện được đề xuất trên căn cứ 4,80 điểm.

A.6 Tích hợp thông tin vị trí vào mô hình sinh câu

Mục A.5 cho thấy chất lượng câu giảm mạnh ở nhóm bước có lỗi nhận diện phần tử. Từ quan sát này, chúng tôi khảo sát bốn cách bổ sung thông tin vị trí cho mô hình sinh câu, cùng hai phép sàng lọc ý tưởng không cần GPU (Bảng A.15). Phần lớn phép đo được thực hiện trên tập kiểm định nội bộ và chỉ dùng để so sánh tương đối giữa các biến thể.

Kết luận chung của chuỗi phép thử. Trong các biến thể đã khảo sát, tín hiệu vị trí có thể được mã hóa trong trạng thái ẩn nhưng chưa tạo ra thay đổi tương ứng ở câu đầu ra. Ở phép tiêm vai trò/vùng/thao tác, hệ số trộn tự giảm về gần 0; ở các phép biến đổi ảnh, mô hình phản ứng với thay đổi hình ảnh nhưng chưa phân biệt ổn định phần tử mục tiêu với phần tử lân cận. Vì các mô-đun bổ sung được gắn vào mô hình sinh câu đã huấn luyện, kết quả chỉ cho thấy việc bổ sung hậu kỳ một đường tín hiệu vị trí chưa đủ để thay đổi câu; không cho phép kết luận rằng thông tin vị trí không hữu ích cho bài toán.

A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE)

A.7.1 Thiết kế

Căn cứ. TAGE (*Type-Aware Grounded Editor*) được xây dựng để kiểm tra khả năng hiệu chỉnh câu sau khi tập trung vào một vùng ảnh cục bộ quanh phần tử dự đoán. Mô-đun nhận câu hướng dẫn ban đầu từ mô hình học tăng cường với phần thưởng SPICE, định vị vùng cần xem và sinh lại câu từ ảnh gốc cùng vùng cắt. TAGE nằm ở cùng vị trí hậu xử lý với ACE, nên mốc so sánh trực tiếp là câu hướng dẫn ban đầu của thành phần thứ nhất.

Ba thành phần. TAGE gồm ba thành phần, và Hình A.1 vẽ đường đi của một

Bảng A.15: Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. Dấu * chỉ phép đo trên tập kiểm định nội bộ.

Hướng	Cách làm	Kết quả
Mô-đun định vị và cầu nối*	một bộ chú ý học vị trí phần tử trên các mảnh ảnh, rồi cộng đặc trưng vùng đó vào trạng thái ẩn giữa mô hình	bộ chú ý học được vị trí (trùng hộp 52,0% so với 5,3% của tiên nghiệm), nhưng các cấu hình cầu nối chỉ làm thay đổi 15% số câu và executability chỉ lệch +0,17 điểm [−1,03; +1,33]
Vùng cắt làm ảnh thứ hai*	đo xác suất câu tham chiếu khi cho thêm ảnh cắt quanh phần tử đúng, quanh phần tử lân cận cùng loại, hoặc quanh một vùng ngẫu nhiên	tách được vùng đúng khỏi vùng ngẫu nhiên, nhưng gần như không tách được khỏi phần tử lân cận (+0,004 nat mỗi token)
Tích hợp vai trò, vùng, thao tác*	đọc vai trò, vùng màn và loại thao tác từ trạng thái ẩn, rồi tích hợp lại qua một hệ số trộn học được	các thông tin này có thể được giải mã từ trạng thái ẩn (vai trò 51,5%, thao tác 82,8%), nhưng hệ số trộn giảm về gần không, chỉ 4% số câu thay đổi, và hoán vị thông tin giữa các bước không làm điểm giảm
Làm nét ảnh quanh phần tử cần chạm*	giữ S1 đóng băng, đưa ảnh được làm nét quanh phần tử cần chạm, quanh vùng đối diện, hoặc quanh tâm màn	S1 đổi câu ở 16,9% số bước, nhưng làm nét đúng phần tử cần chạm không tốt hơn làm nét vùng đối diện
Hai lượt viết lại có chọn lọc	sàng lọc trên tập kiểm tra: trong 958 câu của S1 chỉ khác câu tham chiếu ở một cụm từ, đếm số câu làm mô hình định vị trỏ sai	147/958 (15,3%), tức phần lớn lỗi sát nghĩa chỉ là khác cách nói, không phải chỉ sai phần tử
Bộ xếp hạng câu biết màn sau*	học chọn một trong chín câu do S1 sinh, dùng đặc trưng tính nhanh, có bản học theo một mô hình thấy được xem màn kế tiếp	kém hơn câu giải mã tham lam ở cả BLEU-4, CIDEr-D và SPICE, kể cả bản học theo mô hình thấy màn kế tiếp

bước qua cả ba.

1. Bộ định vị nhận ảnh và mục tiêu rồi viết ra một điểm (x, y) trên thang 0 đến 1000. Quanh điểm ấy, một ô vuông có cạnh bằng 40% bề ngang màn hình được cắt ra và phóng lên 448 × 448 điểm ảnh.

2. Bộ biên tập nhận ảnh gốc, ô cắt và câu hướng dẫn ban đầu rồi viết lại câu. Lúc huấn luyện, ô cắt đặt quanh điểm chạm thật, và hàm mất mát gồm entropy chéo của câu tham chiếu cộng một số hạng lề

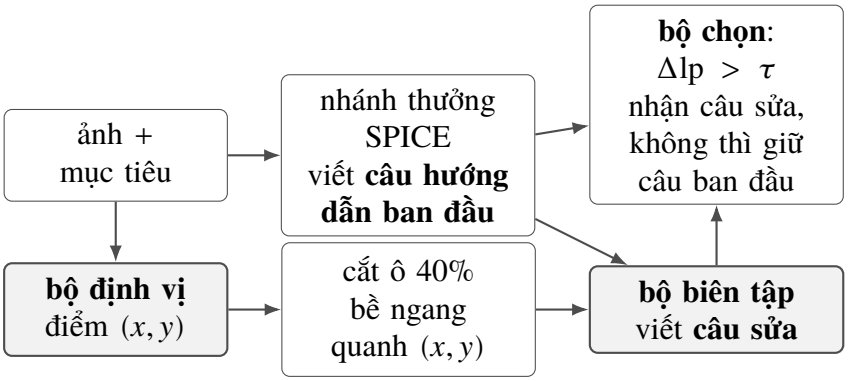
$$\mathscr{L} = \mathrm{CE}(g \mid \text{ô đúng}) + 0{,}5 \cdot \max\bigl(0,\ 0{,}2 - (\mathrm{nll}_{\text{lân cận}} - \mathrm{nll}_{\text{đúng}})\bigr), \qquad \text{(A.1)}$$

trong đó $\mathrm{nll}_{\text{đúng}}$ và $\mathrm{nll}_{\text{lân cận}}$ là log-xác suất âm của câu tham chiếu khi ô cắt đặt quanh phần tử đúng và quanh một phần tử lân cận cùng vai trò. Số hạng này buộc bộ biên tập dựa vào nội dung ô cắt thay vì chép lại câu hướng dẫn ban đầu. Câu hướng dẫn ban đầu lúc huấn luyện lấy từ mô hình học tăng cường với phần thưởng SPICE, và 30% số câu hướng dẫn ban đầu này bị thay tên phần tử bằng tên phần tử lân cận.

1. Bộ chọn nhận câu sửa khi $\Delta\mathrm{lp} = \mathrm{lp}(\text{sửa}) - \mathrm{lp}(\text{ban đầu})$, tức hiệu log-xác suất trung bình theo token do bộ biên tập tính, lớn hơn một hằng số τ; ngược lại giữ câu hướng dẫn ban đầu. Giá trị $\tau = 0{,}738$ được chọn chéo trên tập kiểm định nội bộ, bằng cách chọn trên một nửa số tác vụ rồi áp lên nửa kia.

Bộ định vị và bộ biên tập là hai bộ chuyển đổi LoRA hạng 16 ở phần ngôn ngữ, gắn trên mô hình tinh chỉnh có giám sát (S1) sau khi đã cộng hẳn trọng số bộ chuyển đổi của S1 vào mô hình gốc. Mỗi bộ học một lượt trên 2.554 bước chạm của tập huấn luyện không chứa tác vụ nào của tập kiểm định nội bộ.

Cỡ mẫu khi chọn τ. Trên tập kiểm định nội bộ, bộ chọn chỉ nhận 11 câu sửa trong 249 bước chạm, nên τ được chọn từ một mẫu rất nhỏ. Mục A.7.2 cho thấy đây là hạn chế chính của thiết kế.



Hình A.1: Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng cắt (TAGE). Hai khối tô xám là hai bộ chuyển đổi được huấn luyện. Đầu ra của bộ chọn là câu được sử dụng để đánh giá.

A.7.2 Kết quả

Trên tập kiểm định nội bộ, câu sửa tốt hơn câu hướng dẫn ban đầu rõ rệt khi ô cắt đặt quanh điểm chạm đúng và kém đi rõ khi ô cắt cố ý đặt quanh một phần tử lân cận, cho thấy bộ biên tập thực sự khai thác nội dung vùng cắt. Mô-đun hiệu chỉnh câu hoàn chỉnh cũng cao hơn nhẹ so với câu hướng dẫn ban đầu trên tập ấy, nên được chấm một lần trên tập kiểm tra.

Bảng A.16: Mô-đun hiệu chỉnh câu theo vùng cắt (TAGE) trên 4.463 bước chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của mô hình học tăng cường với phần thưởng SPICE và với S1. Quy tắc hộp phần tử lấy từ AndroidControl, còn quy tắc khoảng cách Euclid lấy từ AndroidInTheWild. Ghép cặp theo bước.

Độ đo	**S1**	**Câu ban đầu**	**TAGE**	**TAGE – câu ban đầu**	**p**
Executability	59,11	60,65	60,23	-0,43 [−0,87; +0,02]	0,093
Quy tắc hộp phần tử	65,49	67,02	66,44	-0,58 [−1,07; −0,09]	0,027
quy tắc khoảng cách Euclid	74,37	76,25	76,07	-0,18 [−0,66; +0,32]	0,55
Đúng loại thao tác	94,35	95,97	96,64	+0,67 [+0,44; +0,92]	<0,001
SPICE	44,37	45,79	45,74	-0,05 [−0,38; +0,27]	–

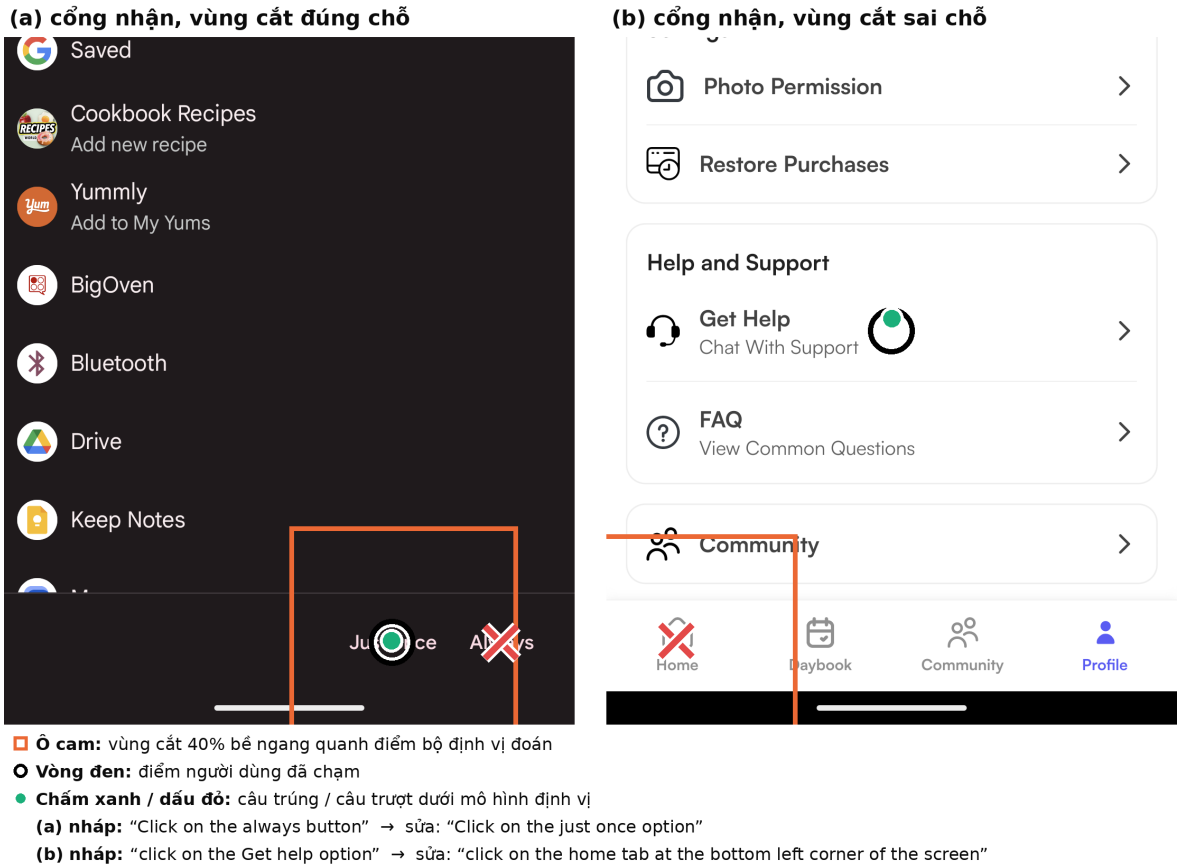
Kết quả trên tập kiểm tra. TAGE đạt executability thấp hơn câu hướng dẫn ban đầu 0,43 điểm (p = 0,093) và thấp hơn 0,58 điểm theo quy tắc hộp phần tử (p = 0,027). TAGE vẫn cao hơn S1 1,12 điểm [+0,31; +1,94], nhưng mức này được kế thừa từ câu

hướng dẫn ban đầu. Do đó, biến thể hiện tại chưa bổ sung lợi ích so với thành phần thứ nhất và không được đưa vào phương pháp đề xuất.

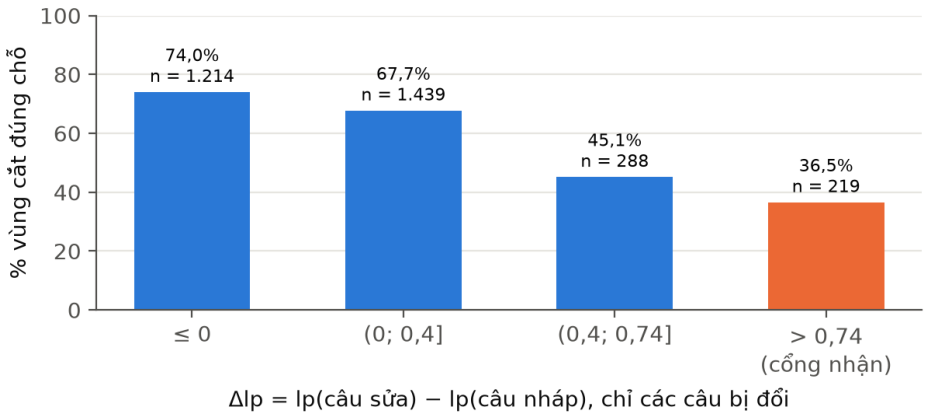
Nguồn của mức giảm. Mô hình định vị xác định đúng phần tử 69,5% số bước, bộ biên tập đổi câu ở 70,8% số bước, và bộ chọn nhận 219 câu sửa (4,9%). Trên 219 bước ấy, câu hướng dẫn ban đầu chỉ đúng 34,7%, cho thấy bộ chọn tập trung vào các bước mà câu hướng dẫn ban đầu có chất lượng thấp; tuy nhiên câu sửa còn đạt tỉ lệ đúng thấp hơn (26,0%). Ở 80 bước có ô cắt chứa đúng phần tử mục tiêu, câu sửa chuyển 46 bước từ sai sang đúng và 7 bước theo chiều ngược lại. Ở 139 bước có ô cắt không chứa đúng phần tử mục tiêu, câu sửa chuyển 2 bước từ sai sang đúng và 60 bước theo chiều ngược lại, vì bộ biên tập mô tả phần tử nằm trong ô cắt và thay một câu hướng dẫn ban đầu vốn đúng bằng câu về phần tử khác (Hình A.2).

Tín hiệu của bộ chọn. Theo Hình A.3, tỉ lệ ô cắt chứa đúng phần tử mục tiêu giảm đều khi Δlp tăng, từ 74,0% ở nhóm thấp nhất xuống 36,5% ở nhóm được nhận. Một cách giải thích phù hợp với quan sát này là khi ô cắt rơi vào phần tử khác, mô-đun biên tập tạo câu có xác suất cao đối với nội dung trong ô, trong khi câu hướng dẫn ban đầu mô tả phần tử ngoài ô nên nhận log-xác suất thấp. Hiệu Δlp vì vậy đo mức lệch giữa câu hướng dẫn ban đầu và ô cắt, và không cho biết câu nào đúng hơn. Trên tập kiểm định nội bộ, nhóm trên cùng chỉ có 11 câu, trong đó 8 câu có ô cắt chứa đúng phần tử mục tiêu, và τ lại được chọn từ chính 11 câu ấy.

Hệ quả cho thiết kế. Bộ chọn dựa trên xác suất của chính bộ biên tập không độc lập với ô cắt, nên không phát hiện được lỗi chính của mô-đun hiệu chỉnh câu là vùng cắt không chứa phần tử mục tiêu. Bộ chọn cần một tín hiệu không phụ thuộc trực tiếp vào vùng cắt, ví dụ so điểm mà mô hình định vị suy ra từ câu hướng dẫn ban đầu với điểm của bộ định vị, và τ cần được chọn trên mẫu lớn hơn nhiều so với 11 câu. Nếu bộ chọn chỉ nhận câu sửa khi ô cắt chứa đúng phần tử mục tiêu, mô-đun hiệu chỉnh câu tăng thêm 39 bước đạt, tương đương khoảng 0,87 điểm. Đây là ngưỡng tối đa ước lượng bằng điểm chạm đúng của bước, không phải kết quả của một cấu hình đã chạy.



Hình A.2: Hai bước mà bộ chọn của TAGE nhận câu sửa, cắt phần dưới màn hình. (a) Ô cắt chứa đúng phần tử mục tiêu: câu hướng dẫn ban đầu gọi nút *Always*, câu sửa gọi đúng *Just once*. (b) Ô cắt rơi vào thanh điều hướng ở góc dưới bên trái: câu hướng dẫn ban đầu *Get help* vốn đúng bị thay bằng câu về thẻ *Home* nằm trong ô cắt.



Hình A.3: Tỉ lệ ô cắt chứa đúng phần tử mục tiêu (bộ định vị trỏ trong dung sai 14%) theo nhóm Δlp, trên các câu mà bộ biên tập đã đổi ở tập kiểm tra. Cột cam là nhóm được nhận. Tỉ lệ ô cắt đúng giảm khi Δlp tăng.