ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

LUẬN VĂN THẠC SĨ

TP. Hồ Chí Minh - Năm 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

Ngành: TRÍ TUỆ NHÂN TẠO
Mã số ngành: 8480107

NGƯỜI HƯỚNG DẪN KHOA HỌC
TS. Nguyễn Hồng Bửu Long

TP. Hồ Chí Minh - Năm 2026

Lời cam đoan

Tôi cam đoan luận văn thạc sĩ ngành Trí tuệ nhân tạo với đề tài **Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng** là công trình do tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Các số liệu và kết quả trình bày trong luận văn là trung thực, được tính từ mã nguồn cùng các tệp kết quả đi kèm và không sao chép từ công trình của tác giả khác. Những thí nghiệm đã lên kế hoạch nhưng chưa thực hiện đều được ghi rõ là chưa thực hiện. Các tài liệu tham khảo được trích dẫn đầy đủ.

Tôi xin chịu trách nhiệm về tính trung thực của các kết quả trình bày trong luận văn.

Học viên cao học

Lê Đoàn Phương Uyên

Lời cảm ơn

Tôi thực hiện luận văn này tại Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh, dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Trước hết, tôi xin gửi lời cảm ơn chân thành đến thầy hướng dẫn, người đã định hướng đề tài và góp ý cho tôi trong suốt quá trình thực hiện luận văn.

Tôi xin cảm ơn quý thầy cô Khoa Công nghệ Thông tin đã giảng dạy trong suốt chương trình cao học và Văn phòng Khoa đã hỗ trợ các thủ tục liên quan đến luận văn.

Cuối cùng, tôi xin cảm ơn gia đình đã tạo điều kiện để tôi theo học và hoàn thành chương trình này.

Tp. Hồ Chí Minh, tháng 10 năm 2026

Lê Đoàn Phương Uyên

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Danh mục các hình vẽ, đồ thị **viii**

Danh mục các bảng số liệu **ix**

Danh mục từ viết tắt và thuật ngữ **xii**

Trang thông tin luận văn tiếng Việt **xvii**

Trang thông tin luận văn tiếng Anh **xxi**

1 Giới thiệu **1**

1.1 Đặt vấn đề 1

1.2 Động lực nghiên cứu 3

1.2.1 Động lực khoa học 3

1.2.2 Động lực ứng dụng 4

1.3 Mục đích nghiên cứu 4

1.4 Khoảng trống nghiên cứu và vị trí của đề tài 5

1.5 Nội dung và phạm vi thực hiện đề tài 5

1.5.1 Nội dung nghiên cứu 5

1.5.2 Phạm vi nghiên cứu 5

1.6 Đóng góp chính 6

2 Tổng quan **9**

2.1 Mô hình ngôn ngữ thị giác 9

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA 10

2.3 GRPO và phần thưởng dựa trên độ đo văn bản 10

2.4 Định vị phần tử giao diện 11

2.5 Bộ dữ liệu AndroidControl 12

2.6 Độ đo dựa trên câu chuẩn trong bài toán sinh hướng dẫn 12

3 Xây dựng bộ dữ liệu **14**

3.1 Nguồn dữ liệu, cách hợp nhất và kiểm tra 14

3.2 Quy mô và phân chia dữ liệu 15

3.3 Dữ liệu cho từng thành phần của phương pháp 16

3.4 Một số đặc điểm cần lưu ý 17

4 Phương pháp đề xuất **18**

4.1 Quy trình tổng thể 18

4.2 Đầu vào và cấu trúc prompt 20

4.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE 20

4.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ nhất quán thao tác (ACE) 22

4.5 Mô hình so sánh và cấu hình của S1 23

5 Độ đo khả năng thực hiện theo hướng dẫn **26**

5.1 Ý tưởng và định nghĩa executability 26

5.2 Xác định điểm đúng phần tử 29

5.2.1 Các tiêu chí báo kèm 31

5.3 Loại thao tác 32

5.4 Độ đo văn bản 33
5.5 Kiểm chứng độ tin cậy của executability 34
5.5.1 Mốc trên và mốc dưới 34
5.5.2 Độ bền khi diễn đạt lại 35
5.5.3 Độ chính xác và tính tất định của mô hình định vị 35
5.5.4 Thay mô hình B 36
5.5.5 Giới hạn của mô hình định vị 38
5.6 Phương pháp phân tích thống kê 38

6 Thực nghiệm và kết quả **40**
6.1 Thiết lập thực nghiệm 40
6.2 Kết quả chính 40
6.3 Vai trò của phần thưởng SPICE 41
6.4 So với mô hình lớn hơn chỉ dùng prompting 43
6.5 Độ vững khi thay mô hình đánh giá 43
6.6 Khả năng khái quát 44
6.6.1 Tác vụ chưa xuất hiện trong huấn luyện S1 44
6.6.2 Chuyển sang bộ dữ liệu AitZ 45
6.7 Độ đo văn bản 46
6.8 Lịch sử thao tác do mô hình tự sinh 47
6.9 Thành phần thứ hai: ACE 48
6.10 Các phương án thiết kế đã khảo sát 49
6.11 Hạn chế của kết quả 49

7 Kết luận **51**
7.1 Đóng góp chính 51
7.2 Hạn chế 54

7.2.1 Phạm vi của công cụ đo 54
7.2.2 Phạm vi của kết quả về mô hình 55
7.2.3 Phạm vi dữ liệu và thực nghiệm 55
7.3 Tính sẵn có của dữ liệu và mã nguồn 56
7.4 Hướng phát triển 56

8 Các công trình nghiên cứu **58**

Tài liệu tham khảo **59**

A Các phương án thiết kế đã khảo sát **64**
A.1 Sinh mô tả phần tử trước câu hướng dẫn 64
A.1.1 Thiết kế 64
A.1.2 Các cấu hình của thiết kế so sánh ban đầu 67
A.1.3 Kết quả 69
A.2 Học theo cặp ưu tiên trên dòng mô tả 71
A.2.1 Thiết kế 71
A.2.2 Kết quả 72
A.2.3 Phân tích cơ chế mô tả phần tử 73
A.3 Chọn phần tử trong danh sách ứng viên 75
A.3.1 Thiết kế 75
A.3.2 Kết quả 77
A.4 Huấn luyện tăng cường với phần thưởng tọa độ 80
A.4.1 Thiết kế 80
A.4.2 Kết quả 81
A.4.3 Nội suy trọng số giữa hai mô hình 81
A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn 82
A.5.1 Độ ổn định của ước lượng trên nhóm con 84

A.6 Tích hợp thông tin vị trí vào mô hình sinh câu 85
A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE) 85
A.7.1 Thiết kế 85
A.7.2 Kết quả 88
A.8 Trạng thái các cấu hình đã khảo sát 89

B Kiểm chứng bổ sung cho executability **94**
B.1 Biến đổi lỗi có kiểm soát 94
B.2 Độ tương đồng nhúng giữa các cách gọi phần tử 95
B.3 So sánh năm cách xác định vị trí 96
B.4 Tiêu chí lỏng và kết luận thống kê 96
B.5 Viết lại câu chuẩn 97

Danh mục các hình vẽ, đồ thị

1.1 Bài toán sinh hướng dẫn cho thao tác kế tiếp và cách đánh giá bằng executability. 2

4.1 Quy trình sinh hướng dẫn của phương pháp đề xuất. 19
4.2 Vòng huấn luyện GRPO-SPICE. 21
4.3 Hai ví dụ minh họa điều kiện lựa chọn của ACE trên tập kiểm tra. . . 24

5.1 Quy trình đánh giá một câu hướng dẫn bằng executability. 28
5.2 Một bước được đánh giá: câu của S1 đạt, câu của Base dẫn tới dòng *Gender* nên không đạt. 29

6.1 Một bước được GRPO-SPICE sửa đúng. 42

A.1 Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE). 88
A.2 Hai bước mà bộ chọn của TAGE nhận câu sửa, cắt phần dưới màn hình. 90
A.3 Tỉ lệ bước bộ định vị trỏ đúng theo nhóm Δlp. 91

Danh mục các bảng số liệu

3.1 Hai bản phân phối trên Hugging Face được ghép để dựng dữ liệu. . . . 14
3.2 Quy mô tập huấn luyện và tập kiểm tra. 15

4.1 Cấu hình tinh chỉnh có giám sát của S1. 25

5.1 Tỉ lệ chấp nhận khi dự đoán lệch nhẹ và khi dự đoán chuyển sang phần tử lân cận. 30
5.2 Các tiêu chí xác định điểm đúng phần tử. 31
5.3 Điểm theo executability và ba tiêu chí báo kèm. 32
5.4 Mốc tham chiếu trên mẫu 800 bước; hai hàng cuối chỉ tính trên các bước có thành phần bị bỏ. 35
5.5 Điểm của ba loại câu dưới bốn mô hình B. 37

6.1 Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra. . . . 41
6.2 Executability và độ đo văn bản theo phần thưởng GRPO. 43
6.3 Kết quả của các nhánh chính dưới bốn mô hình đánh giá. 44
6.4 Executability trên ACU và trên tập gộp với tập kiểm tra chính. 45
6.5 Executability trên 2.736 bước có thao tác chạm của AitZ. 46
6.6 Độ đo văn bản trên 4.463 bước có thao tác chạm của tập kiểm tra. . . 46
6.7 Độ đo văn bản trên ACU và AitZ. 47
6.8 Executability khi lịch sử các bước trước do chính mô hình sinh. 48
6.9 ACE so với câu ban đầu và với mô hình sinh câu ứng viên dùng độc lập. 48
6.10 Tỉ lệ nêu đúng loại thao tác trên các bước không chạm. 50

A.1 Ảnh hưởng của bước trung gian trong các công trình trước. 65
A.2 Bốn trường của dòng mô tả phần tử và vai trò của từng trường. 66
A.3 Chất lượng nhãn mô tả ở quy mô đầy đủ so với mẫu thử. 67
A.4 Các cấu hình của thiết kế so sánh ban đầu. 68
A.5 Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không. 69
A.6 Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh. 70
A.7 Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình. 72
A.8 Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. 73
A.9 Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). 74
A.10 Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. 78
A.11 Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng. 78
A.12 Tỉ lệ thẻ `none` theo bốn mẫu số. 79
A.13 Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. 82
A.14 Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm. 83
A.15 Ước lượng lợi ích của can thiệp chỉ thay câu dưới bốn cách định nghĩa nhóm. 84
A.16 Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. 86

A.17 Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE) trên 4.463 bước chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của mô hình học tăng cường với phần thưởng SPICE và với S1. 88

A.18 Trạng thái cuối của các cấu hình đã khảo sát. 91

B.1 Tỉ lệ phản ứng đúng chiều của cách đánh giá trước các biến đổi đã biết kết quả. 95

B.2 Điểm của câu chuẩn và chênh lệch S1 − Base theo năm cách xác định vị trí (698 bước). 96

B.3 Mô hình sau giai đoạn thưởng tọa độ trừ S1/101 dưới ba tiêu chí, kèm hiệu chỉnh Holm. 96

B.4 Executability khi viết lại câu chuẩn. 97

Danh mục từ viết tắt và thuật ngữ

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
GUI	Graphical User Interface	Giao diện đồ họa người dùng
VLM	Vision-Language Model	Mô hình ngôn ngữ thị giác
LLM	Large Language Model	Mô hình ngôn ngữ lớn
SFT	Supervised Fine-Tuning	Tinh chỉnh có giám sát
LoRA	Low-Rank Adaptation	Tinh chỉnh hạng thấp
QLoRA	Quantized LoRA	LoRA trên trọng số đã lượng tử hoá
NF4	4-bit NormalFloat	Định dạng lượng tử hoá 4 bit
AitW	AndroidInTheWild	Bộ dữ liệu Android quy mô lớn (NeurIPS 2023)
ACU	-	Tập bổ sung gồm các tác vụ AndroidControl không xuất hiện trong tập huấn luyện của S1
OCR	Optical Character Recognition	Nhận dạng văn bản trong ảnh
KTC	Confidence Interval	Khoảng tin cậy

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Exec.	executability	Viết tắt của executability trong các bảng
dp	density-independent pixel	Đơn vị độ dài độc lập mật độ điểm ảnh trên Android
ORPO	Odds Ratio Preference Optimization	Mục tiêu học ưu tiên không cần mô hình tham chiếu riêng
GRPO	Group Relative Policy Optimization	Tối ưu chính sách dựa trên phần thưởng tương đối giữa các đầu ra của cùng một nhóm
KL	Kullback-Leibler divergence	Độ lệch giữa hai phân bố xác suất
SPICE	Semantic Propositional Image Caption Evaluation	Độ đo dựa trên câu chuẩn, so sánh các đối tượng, thuộc tính và quan hệ được trích xuất từ hai câu
BLEU	Bilingual Evaluation Understudy	Độ đo mức lặp lại của cụm từ giữa câu sinh ra và câu chuẩn
METEOR	Metric for Evaluation of Translation with Explicit ORdering	Độ đo ghép từ giữa hai câu, có tính từ đồng nghĩa và biến thể từ
ROUGE-L	Recall-Oriented Understudy for Gisting Evaluation, Longest common subsequence	Độ đo dựa trên chuỗi con chung dài nhất giữa hai câu
CIDEr-D	Consensus-based Image Description Evaluation, bản D	Độ đo trùng lặp cụm từ có trọng số theo độ hiếm của cụm từ, bản D thêm phạt độ dài và giới hạn số lần đếm

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
McNemar	McNemar's test	Kiểm định ghép cặp cho hai tỉ lệ trên cùng các bước
UGround	-	Mô hình định vị chính dùng để tính executability
chrF	character n-gram F-score	Độ đo trùng lặp cụm ký tự giữa hai câu
BERTScore	BERTScore	Độ đo tương đồng ngữ nghĩa giữa hai câu dựa trên biểu diễn của mô hình ngôn ngữ
Thuật ngữ riêng của đề tài		
ACE (*Action-Consistent Exemplar Copying*)		Thành phần hiệu chỉnh của phương pháp đề xuất. ACE truy hồi bốn câu chuẩn từ các bước tương tự trong tập huấn luyện và chỉ thay hướng dẫn ban đầu khi câu ứng viên giống hoàn toàn với một trong các câu được truy hồi và có cùng loại thao tác với hướng dẫn ban đầu (Mục 4.4).
executability (khả năng thực hiện theo hướng dẫn)		Độ đo xem xét liệu một câu hướng dẫn có dẫn tới đúng phần tử cần thao tác hay không. Một câu đạt khi mô hình định vị xác định đúng phần tử mà người dùng đã chạm và câu nêu đúng loại thao tác (Chương 5).

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Mô hình tinh chỉnh có giám sát (S1)		Qwen2.5-VL-3B-Instruct sau khi được tinh chỉnh có giám sát cho bài toán sinh hướng dẫn. S1 là mốc so sánh chính và cũng là mô hình khởi tạo cho giai đoạn học tăng cường của phương pháp đề xuất.
S1/101, S1/202		S1 huấn luyện với seed 101 và seed 202. Base là mô hình gốc Qwen2.5-VL-3B-Instruct chưa tinh chỉnh
GRPO-SPICE		Thành phần thứ nhất của phương pháp đề xuất: S1/101 học tiếp bằng GRPO với phần thưởng SPICE (Mục 4.3)
S2, CE2-S2, MIN-DESC, giai đoạn ba		Các mô hình của hướng mô tả phần tử trước khi sinh câu (Phụ lục A): mô hình mô tả phần tử, mô hình chỉ học thêm có giám sát, mô hình học theo cặp ưu tiên trên dòng mô tả, và giai đoạn thưởng tọa độ
TAGE (*Type-Aware Grounded Editor*)		Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ, một hướng đã thử (Mục A.7)

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Câu chuẩn		Câu hướng dẫn theo từng bước do người thực hiện AndroidControl viết cho bước tương ứng. Câu này được dùng làm mục tiêu trong huấn luyện có giám sát và trong các độ đo dựa trên câu chuẩn.

Trang thông tin luận văn

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn:	Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng.
Ngành:	Trí tuệ nhân tạo
Mã số ngành:	8480107
Họ và tên HVCH:	Lê Đoàn Phương Uyên
MSHV:	24C15039
Khóa đào tạo:	34
GVHD:	TS. Nguyễn Hồng Bửu Long
Cơ sở đào tạo:	Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM

1. Tóm tắt nội dung luận văn

Đề tài nghiên cứu bài toán sinh một câu hướng dẫn cho bước tiếp theo trên giao diện di động. Ở mỗi bước, mô hình nhận mục tiêu của tác vụ, các bước đã hoàn thành, ảnh chụp màn hình hiện tại và phần văn bản hiển thị, rồi sinh câu nêu thao tác cần thực hiện và phần tử cần tương tác. Dữ liệu huấn luyện được xây dựng tự động từ AndroidControl, với 64.567 bước sau khi hợp nhất.

Phương pháp đề xuất gồm hai thành phần. Đầu tiên, mô hình Qwen2.5-VL-3B sau khi tinh chỉnh có giám sát được tiếp tục huấn luyện bằng GRPO với SPICE làm phần thưởng để sinh hướng dẫn ban đầu. Sau đó, ACE truy hồi bốn câu chuẩn từ các bước tương tự trong tập huấn luyện và chỉ thay hướng dẫn ban đầu khi câu ứng viên giống hoàn toàn với một trong các câu được truy hồi và có cùng loại thao tác với hướng dẫn ban đầu.

Để đánh giá chất lượng hướng dẫn, chúng tôi xây dựng độ đo khả năng thực hiện theo hướng dẫn (instruction executability), gọi ngắn là executability. Thay vì chỉ so sánh hướng dẫn do mô hình tạo ra với một câu chuẩn, executability sử dụng một mô hình định vị tách biệt với mô hình sinh để kiểm tra liệu câu hướng dẫn có dẫn tới đúng phần tử cần tương tác và đúng loại thao tác hay không. Câu chuẩn đạt 75,7% executability và được dùng làm mốc để diễn giải kết quả. So với S1/101, GRPO-SPICE giữ hướng tăng dưới bốn tiêu chí đánh giá vị trí và cả bốn công cụ đánh giá UGround, UI-Venus, Phi-Ground và Phi-4.

Trên 4.463 bước có thao tác chạm của tập kiểm tra AndroidControl, GRPO-SPICE đạt 60,65% executability, cao hơn S1 1,55 điểm với khoảng tin cậy 95% [+0,80; +2,33]. Nhánh kiểm soát được huấn luyện cùng 500 bước GRPO nhưng điểm SPICE được ghép ngẫu nhiên giữa các mẫu chỉ đạt 59,11%, bằng S1. So sánh này cho thấy mức tăng của GRPO-SPICE gắn với tín hiệu SPICE, thay vì chỉ đến từ việc tiếp tục huấn luyện.

Trên 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05]. Lượt huấn luyện GRPO thứ hai cho cùng chiều với mức tăng 4,04 điểm. Khi gộp tập này với tập kiểm tra chính, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99].

ACE đạt 60,68% executability trên tập kiểm tra chính và tiếp tục cải thiện cả bảy độ đo dựa trên câu chuẩn. Cả sáu độ đo có khoảng tin cậy đều có khoảng tăng nằm trên 0. Khi lịch sử các bước trước do mô hình tự sinh, GRPO-SPICE vẫn cao hơn S1 1,48 điểm [+0,54; +2,43]. Trên AitZ, S1 cao hơn Base 3,29 điểm, còn GRPO-SPICE và S1 cho kết quả tương đương về executability. Kết quả này cho thấy tinh chỉnh có giám sát vẫn chuyển được sang miền dữ liệu khác, còn lợi ích bổ sung của SPICE phụ thuộc vào phân phối câu chuẩn.

2. Những kết quả mới của luận văn

Chúng tôi tập trung vào ba đóng góp chính gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích các phương án thiết kế. Quy trình xây dựng dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ các phần này.

- **Phương pháp sinh hướng dẫn gồm hai thành phần.** GRPO-SPICE dùng phần

thưởng SPICE để cải thiện câu hướng dẫn, còn ACE hiệu chỉnh có chọn lọc bằng các câu ví dụ được truy hồi. Trên tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1 1,55 điểm [+0,80; +2,33], đồng thời cao hơn S1 ở cả bảy độ đo dựa trên câu chuẩn. Nhánh kiểm soát với điểm SPICE được ghép ngẫu nhiên giữa các mẫu chỉ đạt 59,11%, bằng S1. Trên 1.484 bước thuộc các tác vụ S1 chưa thấy trong huấn luyện, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05]. ACE giữ executability ở 60,68% và tiếp tục cải thiện cả bảy độ đo dựa trên câu chuẩn. Cả sáu độ đo có khoảng tin cậy đều có khoảng tăng nằm trên 0.

- **Độ đo executability và các mốc dùng để diễn giải điểm số.** Executability đánh giá liệu câu hướng dẫn có giúp xác định đúng phần tử cần tương tác và đúng loại thao tác hay không, thay vì chỉ dựa vào mức tương đồng với một câu chuẩn duy nhất. Trên toàn bộ 4.463 bước có thao tác chạm, câu chuẩn đạt 75,7%. Trên mẫu ngẫu nhiên 800 bước dùng để kiểm tra các mốc thấp, câu chuẩn đạt 74,9%, một câu chung chung không xác định phần tử đạt 12,0%, còn câu chuẩn lấy từ một màn hình khác đạt 6,1%. So với S1/101, GRPO-SPICE cao hơn 1,55 điểm dưới UGround, 1,55 điểm dưới UI-Venus, 0,78 điểm dưới Phi-Ground và 0,69 điểm dưới Phi-4. Hướng tăng cũng được giữ dưới bốn tiêu chí đánh giá vị trí trên UGround.

- **Kết quả nền tảng hỗ trợ ba đóng góp chính: dữ liệu được xây dựng tự động từ AndroidControl.** Chúng tôi chuyển AndroidControl sang bài toán sinh hướng dẫn bằng cách ghép hai bản phát hành công khai, một bản chứa câu hướng dẫn và một bản chứa ảnh. Tính nhất quán của cách ghép được kiểm tra bằng cách đối chiếu kết quả khi giữ đúng liên kết giữa hai nguồn và khi dịch liên kết đi một bước. Trong thiết lập mới, câu hướng dẫn từng bước chuyển từ vai trò đầu vào trong AndroidControl thành mục tiêu cần sinh và đánh giá.

- **Phân tích các phương án thiết kế đã khảo sát.** Các thí nghiệm ở Phụ lục A cho thấy chất lượng của biểu diễn trung gian và chất lượng câu hướng dẫn cuối không luôn thay đổi cùng nhau. Phân tích này làm rõ vai trò của mô tả phần tử, thông tin vị trí và cơ chế chọn ứng viên, đồng thời dẫn tới lựa chọn tối ưu trực tiếp câu hướng dẫn trong phương pháp cuối cùng.

CÁN BỘ HƯỚNG DẪN	HỌC VIÊN CAO HỌC
(Ký tên, họ tên)	(Ký tên, họ tên)

XÁC NHẬN CỦA CƠ SỞ ĐÀO TẠO
HIỆU TRƯỞNG

Thesis information

THESIS INFORMATION

Thesis title:	LLM-Based Automatic Generation of Software User Guides from Use Cases and Front-End Structures.
Field of study:	Artificial Intelligence
Code:	8480107
Name:	Le Doan Phuong Uyen
Student ID:	24C15039
Cohort:	34
Supervisor:	Dr. Nguyen Hong Buu Long
Institution:	VNUHCM - University of Science

1. Summary

GUI agents commonly take screenshots as input and predict an action together with an interaction location so that the system can execute a task automatically. This thesis uses a similar input setting but targets user-facing instructions. At each step, the model receives the task goal, preceding steps, the current screenshot and displayed text, then generates one instruction specifying the required action and target interface element. The training data are constructed automatically from AndroidControl without additional manual annotation. The merged training set contains 64,567 steps.

The proposed method has two components. First, Qwen2.5-VL-3B is fine-tuned with supervised learning and then further trained with GRPO using SPICE as the reward to produce the initial instruction. ACE then retrieves four reference instructions from similar training steps and replaces the initial instruction only when a candidate

exactly matches one retrieved exemplar and has the same action type as the initial instruction.

To evaluate instruction quality, we use instruction executability, referred to as executability. Rather than relying only on similarity to a single reference sentence, executability uses a GUI grounding model separate from the generator to test whether an instruction identifies the correct target element and specifies the correct action type. Human-written instructions reach 75.7% executability and serve as a reference point for interpreting model scores. Relative to S1/101, GRPO-SPICE retains a positive gain under four position-based evaluation criteria and across all four evaluators: UGround, UI-Venus, Phi-Ground and Phi-4.

On the 4,463 touch-action steps of the AndroidControl test set, GRPO-SPICE reaches 60.65% executability, 1.55 percentage points above S1 with a 95% confidence interval of [+0.80, +2.33]. A control branch trained for the same 500 GRPO steps but with SPICE scores randomly reassigned across samples reaches 59.11%, the same level as S1. This comparison indicates that the gain is associated with the SPICE signal rather than with additional training alone.

On 1,484 steps from tasks absent from the S1 training set, GRPO-SPICE improves over S1 by 4.58 points [+3.17, +6.05]. The second GRPO run shows the same direction with a 4.04-point gain. Combining these steps with the main test set gives a 2.30-point executability gain [+1.62, +2.99].

ACE reaches 60.68% executability on the main test set and improves all seven reference-based evaluation metrics, with all six available confidence intervals entirely above zero. With self-generated interaction history, GRPO-SPICE remains 1.48 points above S1 [+0.54, +2.43]. On AitZ, S1 remains 3.29 points above Base, while GRPO-SPICE and S1 are comparable in executability. This result shows that supervised fine-tuning still transfers to a different data distribution, while the additional benefit of SPICE depends on the reference-instruction distribution.

2. Novelty of thesis

The three main contributions are the instruction-generation method, executability, and the analysis of alternative design choices. The automatically constructed AndroidControl data are a foundational result supporting these contributions.

- **A two-component instruction-generation method.** GRPO-SPICE uses SPICE reward to improve the instruction, while ACE selectively revises the output using retrieved examples. On the main test set, GRPO-SPICE reaches 60.65% executability, 1.55 points above S1 [+0.80, +2.33], and also outperforms S1 on all seven reference-based evaluation metrics. A control branch with SPICE scores randomly reassigned across samples reaches 59.11%, the same level as S1. On 1,484 steps from tasks absent from S1 training, GRPO-SPICE improves over S1 by 4.58 points [+3.17, +6.05]. ACE retains 60.68% executability and further improves all seven reference-based evaluation metrics. All six metrics with confidence intervals have intervals entirely above zero.

- **Executability and empirical reference points for interpreting the score.** Executability evaluates whether an instruction identifies the correct target element and action type rather than relying only on similarity to a single reference sentence. On all 4,463 touch-action steps, human-written instructions reach 75.7%. In the random sample of 800 steps used to examine low reference points, the human-written instructions reach 74.9%, a generic instruction that does not identify an element scores 12.0%, and an instruction from a different screen scores 6.1%. Relative to S1/101, GRPO-SPICE is 1.55 points higher under UGround, 1.55 under UI-Venus, 0.78 under Phi-Ground and 0.69 under Phi-4. The positive direction is also preserved under four position-based evaluation criteria with UGround.

- **A foundational result supporting the three main contributions: automatically constructed data from AndroidControl.** The thesis reformulates AndroidControl for instruction generation by joining two public releases, one containing instructions and the other screenshots. The consistency of the join is checked by comparing the original linkage with a version in which the linkage is

shifted by one step. In the resulting task, the human-written per-step instruction changes from an input in AndroidControl to the generation target and evaluated output.

- **An analysis of alternative design choices.** The experiments in Appendix A show that improving an intermediate representation does not always improve the final instruction. This analysis clarifies the roles of element descriptions, location information and candidate selection, and supports the design choices made in the final method.

SUPERVISOR MASTER'S STUDENT

CERTIFICATION
UNIVERSITY OF SCIENCE
RECTOR

Chương 1

Giới thiệu

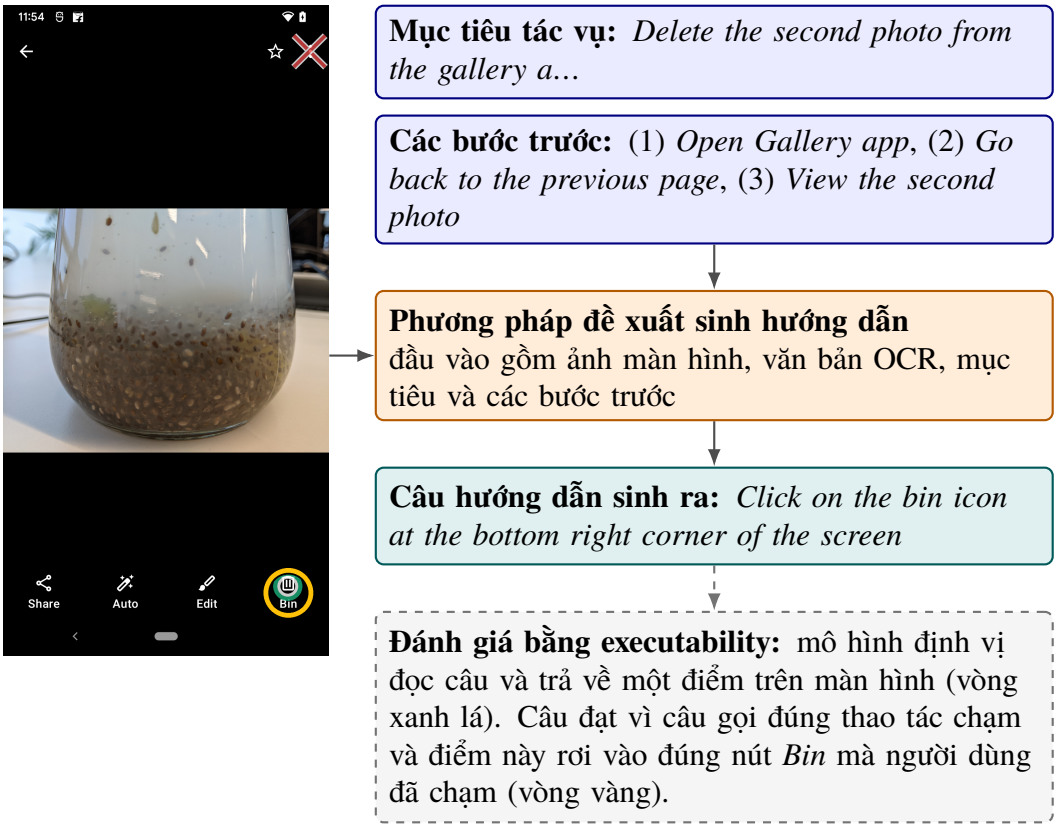
1.1 Đặt vấn đề

Khi sử dụng ứng dụng di động, người dùng có thể biết kết quả cần đạt nhưng chưa biết cần thực hiện thao tác nào tiếp theo trên giao diện hiện tại. Trong trường hợp này, một hướng dẫn hữu ích không chỉ cần nêu đúng thao tác, mà còn phải giúp người dùng xác định được phần tử cần tương tác. Chẳng hạn, thay vì chỉ yêu cầu "chia sẻ", hệ thống có thể hướng dẫn "Chạm vào biểu tượng chia sẻ ở góc trên bên phải màn hình".

Các nghiên cứu gần đây về tác tử giao diện người dùng (GUI agent), như SeeClick [3], OS-Atlas [4] và Aguvis [8], cũng giải quyết bài toán hiểu trạng thái giao diện và xác định hành động tiếp theo. Tuy nhiên, các hệ thống này chủ yếu hướng tới việc tự động thực hiện tác vụ: đầu ra thường gồm loại thao tác và vị trí trên màn hình, chẳng hạn `click(872,141)`. Biểu diễn này phù hợp với một tác tử phần mềm, nhưng không trực tiếp tạo ra hướng dẫn để người dùng đọc và làm theo.

Chúng tôi tập trung vào bài toán sinh hướng dẫn cho thao tác kế tiếp bằng ngôn ngữ tự nhiên. Tại mỗi thời điểm, mô hình nhận thông tin về mục tiêu của tác vụ, các thao tác đã được thực hiện trước đó và trạng thái giao diện hiện tại. Trạng thái giao diện được biểu diễn chủ yếu bằng ảnh chụp màn hình cùng phần văn bản đang hiển thị. Từ các thông tin này, mô hình cần sinh một câu hướng dẫn cho biết người dùng nên thực hiện thao tác nào và tương tác với phần tử nào để tiếp tục tác vụ. Hình 1.1 minh họa bài toán trên một bước của tập kiểm tra.

Khác với đầu ra dạng tọa độ, chất lượng của một câu hướng dẫn còn phụ thuộc vào việc người dùng có nhận ra đúng phần tử cần tương tác hay không. Câu "Chạm vào



Hình 1.1: Bài toán sinh hướng dẫn cho thao tác kế tiếp và cách đánh giá bằng executability, minh họa trên một bước của tập kiểm tra. Vòng vàng là điểm người dùng đã chạm. Vòng xanh lá là điểm mà mô hình định vị trả về khi đọc câu do phương pháp đề xuất sinh ra. Dấu X đỏ là điểm trả về cho câu của mô hình gốc chưa tinh chỉnh (*Click on the three dots at the top right corner of the screen to access more options.*), nên câu đó không đạt. Phần mô tả mục tiêu tác vụ được giữ nguyên như trong dữ liệu nguồn.

biểu tượng tìm kiếm" vẫn có thể mơ hồ nếu màn hình có nhiều biểu tượng tương tự. Khi đó, hướng dẫn cần thêm thông tin như vị trí, nội dung hiển thị hoặc quan hệ với các thành phần xung quanh. Ở chiều ngược lại, cùng một thao tác có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn hoàn toàn hợp lệ.

Hai vấn đề chính cần giải quyết là đánh giá liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và thao tác cần thực hiện hay không, đồng thời phát triển phương pháp để nâng cao chất lượng hướng dẫn. Executability được xây dựng cho yêu cầu đánh giá này.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Về mặt khoa học, bài toán chúng tôi nghiên cứu có liên hệ gần với hướng sinh biểu thức quy chiếu (*referring expression generation*). Trong bài toán này, một mô tả được xem là hữu ích khi người tiếp nhận có thể dựa vào mô tả đó để nhận ra đúng đối tượng được nhắc tới. Mao và cộng sự [12] đánh giá chất lượng mô tả thông qua một mô hình *listener*. Mô hình nhận vào câu mô tả và lựa chọn đối tượng mà câu đó đề cập tới. Mô tả được xem là thành công nếu đối tượng được chọn chính là đối tượng mục tiêu. Các nghiên cứu sau đó tiếp tục đưa tín hiệu từ listener vào quá trình huấn luyện nhằm khuyến khích mô hình tạo ra những mô tả có khả năng phân biệt đối tượng tốt hơn [13, 14]. Cách tiếp cận này phù hợp với bài toán sinh hướng dẫn giao diện, bởi một câu hướng dẫn chỉ thực sự hữu ích khi nó giúp người dùng nhận ra đúng phần tử cần thao tác.

Trong miền giao diện người dùng, Widget Captioning [10] cũng xem xét việc mô tả các phần tử trên màn hình, bao gồm những trường hợp có nhiều phần tử giống hoặc gần giống nhau. Tuy nhiên, mục tiêu huấn luyện vẫn chủ yếu dựa trên mức độ phù hợp với câu chuẩn. Một hướng dẫn do mô hình tạo ra có thể gần với câu chuẩn về cách diễn đạt nhưng vẫn chưa đủ rõ để người dùng phân biệt đúng phần tử mục tiêu. Vì vậy, chúng tôi đánh giá thêm khả năng câu hướng dẫn giúp xác định đúng phần tử, thay vì chỉ dựa vào độ tương đồng về từ ngữ.

Khi dùng một mô hình định vị làm công cụ đánh giá, cần kiểm tra độ ổn định của kết quả trước những khác biệt về cách diễn đạt và công cụ đánh giá. ALOHa [15] cho thấy có thể đánh giá đầu ra sinh bằng cách đối chiếu với nguồn thông tin có cấu trúc, thay vì chỉ so sánh trực tiếp với một câu chuẩn. Jandial và cộng sự [18] cũng chỉ ra rằng khả năng định vị có thể thay đổi theo cách một đối tượng được diễn đạt bằng ngôn ngữ. Để tránh phụ thuộc vào một cấu hình đánh giá duy nhất, chúng tôi kiểm tra executability với các biến thể câu và nhiều mô hình định vị.

1.2.2 Động lực ứng dụng

Về mặt ứng dụng, nhu cầu hướng dẫn người dùng thao tác trực tiếp trên giao diện đã xuất hiện trong các hệ thống thực tế. GuideMe [19] hỗ trợ người cao tuổi sử dụng điện thoại thông minh bằng cách nhận câu hỏi cùng nội dung màn hình và trả về hướng dẫn cho các thao tác cần thực hiện. Hệ thống này sử dụng một mô hình thương mại cỡ lớn qua mạng và được đánh giá thông qua nghiên cứu người dùng với 18 người tham gia. Tuy nhiên, công trình chưa cung cấp một độ đo tự động để có thể so sánh định lượng các phương pháp sinh hướng dẫn trong quá trình phát triển hệ thống.

Một độ đo tự động có thể được dùng nhất quán qua nhiều lần thử nghiệm sẽ giúp việc so sánh các phương pháp thuận tiện hơn, đặc biệt khi việc thực hiện một nghiên cứu người dùng riêng cho từng thay đổi nhỏ của mô hình là khó khả thi. Bên cạnh đó, ảnh chụp màn hình điện thoại có thể chứa các thông tin nhạy cảm như tin nhắn, danh bạ hoặc dữ liệu tài chính. Mô hình có quy mô vừa phải và có khả năng triển khai cục bộ giúp hạn chế nhu cầu gửi dữ liệu màn hình tới dịch vụ bên ngoài. Trong nghiên cứu này, chúng tôi tập trung vào mô hình ngôn ngữ thị giác cỡ nhỏ thay vì đặt trọng tâm vào các mô hình lớn nhất hiện có.

1.3 Mục đích nghiên cứu

Mục tiêu tổng quát của chúng tôi là nâng cao chất lượng câu hướng dẫn cho thao tác kế tiếp trên giao diện di động, đặc biệt là khả năng giúp người dùng nhận ra đúng phần tử cần tương tác. Để thực hiện mục tiêu này, chúng tôi tập trung vào ba mục tiêu cụ thể:

1. Xây dựng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ, hướng tới câu hướng dẫn nêu rõ thao tác cần thực hiện và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình.

2. Xây dựng và đánh giá độ tin cậy của độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability, cho các bước có thao tác chạm. Thay vì chỉ đo mức độ tương đồng giữa hướng dẫn do mô hình tạo ra và

một câu chuẩn, độ đo này xem xét liệu thông tin trong câu hướng dẫn có giúp xác định đúng phần tử và đúng loại thao tác hay không.

3. Tự động xây dựng tập dữ liệu giám sát cho tác vụ sinh hướng dẫn từ AndroidControl [1], không yêu cầu gán nhãn thủ công bổ sung và không sử dụng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

1.4 Khoảng trống nghiên cứu và vị trí của đề tài

Các công trình trên cho thấy hai khoảng trống nghiên cứu liên quan trực tiếp đến đề tài. Phần lớn nghiên cứu về GUI agent tập trung vào dự đoán thao tác hoặc tọa độ cho tác tử phần mềm, thay vì sinh hướng dẫn để con người đọc và thực hiện. Đồng thời, các độ đo dựa trên câu chuẩn không trực tiếp cho biết hướng dẫn do mô hình tạo ra có đủ rõ để xác định đúng phần tử mục tiêu hay không. Chúng tôi giải quyết hai vấn đề này bằng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ (Chương 4) và executability để đánh giá liệu câu hướng dẫn có xác định đúng phần tử và đúng loại thao tác hay không (Chương 5). Kết quả được phân tích ở Chương 6.

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

Để thực hiện các mục tiêu đã nêu, chúng tôi triển khai bốn nhóm nội dung gồm xây dựng tập giám sát từ AndroidControl, xây dựng và đánh giá độ tin cậy của executability, phát triển phương pháp sinh hướng dẫn, và thực nghiệm so sánh cùng phân tích lỗi. Các phương án thiết kế không thuộc phương pháp cuối được trình bày ở Phụ lục A.

1.5.2 Phạm vi nghiên cứu

Về bài toán, mỗi lần suy luận, mô hình sinh một hướng dẫn cho thao tác kế tiếp dựa trên trạng thái giao diện hiện tại, mục tiêu tác vụ và lịch sử các bước trước. Mô hình

vì vậy có sử dụng ngữ cảnh của chuỗi thao tác, nhưng không sinh toàn bộ chuỗi hướng dẫn trong một lần. Khả năng sử dụng lịch sử do chính mô hình sinh ở các bước trước được đánh giá riêng trong phần thực nghiệm.

Về đánh giá, executability được áp dụng cho các bước có thao tác chạm và tập trung vào câu hỏi liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Các khía cạnh như độ trôi chảy, độ dài, mức dễ hiểu đối với từng nhóm người dùng và trải nghiệm tổng thể không phải mục tiêu trực tiếp của độ đo này.

Về dữ liệu, các thực nghiệm chính được thực hiện trên AndroidControl với giao diện và câu hướng dẫn bằng tiếng Anh. Khả năng khái quát được kiểm tra thêm theo hai hướng: các tác vụ AndroidControl không xuất hiện trong tập huấn luyện của S1 và bộ dữ liệu AitZ thuộc một phân phối khác. Các câu tiếng Việt xuất hiện trong phần trình bày chỉ được dùng để minh họa cho bài toán.

Về mô hình, hệ thống sinh được phát triển từ Qwen2.5-VL-3B-Instruct [34] và được tinh chỉnh bằng QLoRA [30] hoặc LoRA trong điều kiện một GPU. Việc sử dụng cùng Qwen2.5-VL-3B-Instruct làm điểm khởi tạo giúp việc so sánh tập trung vào ảnh hưởng của dữ liệu và cách tinh chỉnh, trong khi điều kiện tính toán được giữ tương đương.

1.6 Đóng góp chính

Chúng tôi tập trung vào ba đóng góp chính, gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích thực nghiệm các phương án thiết kế. Bên cạnh đó, quy trình xây dựng dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ toàn bộ quá trình huấn luyện và đánh giá.

Thứ nhất, chúng tôi đề xuất một phương pháp sinh hướng dẫn gồm hai thành phần nối tiếp dựa trên Qwen2.5-VL-3B. Thành phần thứ nhất tiếp tục tối ưu S1 bằng GRPO với phần thưởng SPICE. S1 là Qwen2.5-VL-3B-Instruct sau khi được tinh chỉnh có giám sát. Bước tinh chỉnh có giám sát này được thực hiện với hai seed 101 và 202, tạo thành S1/101 và S1/202. Thành phần thứ hai, ACE, sử dụng các câu ví dụ truy hồi để hiệu chỉnh câu hướng dẫn khi câu ứng viên đáp ứng các điều kiện lựa chọn. Thiết kế

được trình bày ở Chương 4, còn kết quả thực nghiệm nằm ở Chương 6.

Trên tập kiểm tra chính gồm 4.463 bước có thao tác chạm, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Lượt GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm. Một nhánh đối chứng cũng chạy 500 bước GRPO với cùng cấu hình, nhưng điểm SPICE được ghép ngẫu nhiên giữa các mẫu. Nhánh này đạt 59,11%, bằng S1/101. GRPO-SPICE cao hơn nhánh đối chứng 1,55 điểm [+0,81; +2,30], nên mức tăng không xuất hiện khi điểm SPICE không còn gắn với đúng mẫu dù số bước huấn luyện được giữ nguyên.

Với tập bổ sung gồm 1.484 bước có thao tác chạm từ các tác vụ chưa xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05], gần gấp ba mức 1,55 điểm trên tập kiểm tra chính. Lượt GRPO thứ hai tiếp tục cho cùng chiều với mức tăng 4,04 điểm [+2,66; +5,48]. Khi gộp tập này với tập kiểm tra chính, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99].

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 1,55 điểm dưới UGround, 1,55 điểm dưới UI-Venus, 0,78 điểm dưới Phi-Ground và 0,69 điểm dưới Phi-4. So với Qwen2.5-VL-7B chỉ dùng prompting, GRPO-SPICE trên mô hình 3B cao hơn 9,14 điểm executability. Khi áp dụng ACE trên tập kiểm tra chính, executability đạt 60,68%. Cả bảy thước đo dựa trên câu chuẩn đều cao hơn GRPO-SPICE. Với sáu thước có khoảng tin cậy, cận dưới của khoảng tăng đều lớn hơn 0.

Khi lịch sử các bước trước do chính mô hình sinh, GRPO-SPICE vẫn cao hơn S1 1,48 điểm executability [+0,54; +2,43]. Trên AitZ, S1 cao hơn Base 3,29 điểm [+1,51; +5,03], còn GRPO-SPICE và S1 tương đương về executability với chênh lệch -0,51 điểm [-1,39; +0,36]. Mức cải thiện bổ sung của SPICE chưa xuất hiện rõ trong miền này, trong khi bước tinh chỉnh có giám sát vẫn giữ mức tăng so với mô hình gốc. Các kết quả và phân tích tương ứng được trình bày ở Chương 6.

Thứ hai, chúng tôi xây dựng executability cho các bước có thao tác chạm. Độ đo này sử dụng một mô hình định vị tách biệt để kiểm tra liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Chương 5 trình bày định nghĩa, độ tin cậy của cách đo và các kiểm tra độ ổn định trước khi executability được dùng để so sánh các mô hình sinh.

Thứ ba, chúng tôi phân tích nhiều phương án thiết kế đã được khảo sát trước khi lựa chọn phương pháp cuối cùng, gồm mô tả phần tử, học theo cặp ưu tiên, sử dụng thông tin tọa độ, chọn ứng viên và hiệu chỉnh câu theo vùng ảnh. Các phân tích cho thấy chất lượng của biểu diễn trung gian và chất lượng của câu hướng dẫn cuối không luôn thay đổi cùng nhau. Vì vậy, phương pháp cuối cùng chuyển trọng tâm sang tối ưu trực tiếp câu hướng dẫn. Kết quả tổng hợp được trình bày ở Mục 6.10, còn thiết kế chi tiết nằm trong Phụ lục A.

Bên cạnh ba đóng góp chính, chúng tôi xây dựng một tập dữ liệu giám sát cho bài toán sinh hướng dẫn từ AndroidControl bằng quy trình tự động hợp nhất hai bản phân phối công khai, trong đó một bản chứa câu hướng dẫn và một bản chứa ảnh màn hình. Quy trình không yêu cầu gán nhãn thủ công bổ sung và có bước kiểm tra tính nhất quán sau hợp nhất bằng cách so sánh hai trường hợp: ảnh được ghép với câu hướng dẫn đúng bước và ảnh được ghép với câu hướng dẫn của bước kế tiếp. Quy trình xây dựng dữ liệu được trình bày ở Chương 3.

Chương 2

Tổng quan

Chương này trình bày các khái niệm và công trình nền tảng trực tiếp liên quan đến luận văn. Các nội dung chính gồm mô hình ngôn ngữ thị giác, LoRA và QLoRA, GRPO và SPICE, định vị phần tử giao diện, bộ dữ liệu AndroidControl và hạn chế của các độ đo dựa trên một câu chuẩn. Cấu hình cụ thể của mô hình và cách đánh giá được trình bày lần lượt ở Chương 4 và Chương 5.

2.1 Mô hình ngôn ngữ thị giác

Bài toán chúng tôi nghiên cứu yêu cầu mô hình xử lý đồng thời hai nguồn thông tin. Ảnh chụp màn hình cung cấp trạng thái trực quan của giao diện, trong khi phần văn bản mô tả mục tiêu của tác vụ, các thao tác đã thực hiện trước đó và nội dung chữ xuất hiện trên màn hình. Vì vậy, mô hình sinh không chỉ cần hiểu ngôn ngữ mà còn phải liên kết nội dung văn bản với các thành phần trực quan trên giao diện.

Mô hình ngôn ngữ thị giác (*vision-language model*, VLM) xử lý đồng thời ảnh và văn bản. Thông thường, ảnh được chuyển thành các đặc trưng hoặc token thị giác, sau đó được tích hợp với chuỗi token văn bản để mô hình có thể suy luận và sinh đầu ra dựa trên cả hai nguồn thông tin. Phần sinh ngôn ngữ thường dựa trên kiến trúc Transformer [32], trong đó cơ chế tự chú ý giúp mô hình học quan hệ giữa các phần tử trong chuỗi đầu vào.

Chúng tôi sử dụng Qwen2.5-VL-3B-Instruct [34] làm mô hình khởi tạo vì mô hình có trọng số mở, quy mô khoảng ba tỉ tham số phù hợp với điều kiện thử nghiệm và triển khai cục bộ, đồng thời hỗ trợ xử lý ảnh với độ phân giải động. Khả năng này phù

hợp với ảnh chụp màn hình điện thoại, vốn có tỉ lệ và kích thước thay đổi. Cấu hình sử dụng cụ thể của Qwen2.5-VL-3B-Instruct được trình bày ở Chương 4.

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA

Tinh chỉnh toàn bộ một mô hình ngôn ngữ thị giác đòi hỏi lượng bộ nhớ lớn vì quá trình huấn luyện không chỉ lưu trọng số mô hình mà còn cần gradient và trạng thái của bộ tối ưu. LoRA [29] giảm chi phí này bằng cách giữ cố định trọng số gốc và chỉ học một cập nhật có hạng thấp. Với ma trận trọng số $W \in \mathbb{R}^{d\times k}$, trọng số sau khi áp dụng LoRA được viết dưới dạng

$$W' = W + \frac{\alpha}{r}BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k), \tag{2.1}$$

trong đó r là hạng của cập nhật và α là hệ số tỉ lệ. Thay vì cập nhật toàn bộ dk tham số của ma trận W, LoRA chỉ cần học $r(d+k)$ tham số trong hai ma trận A và B.

QLoRA [30] tiếp tục giảm nhu cầu bộ nhớ bằng cách kết hợp LoRA với lượng tử hóa trọng số nền xuống 4 bit. Trong đó, định dạng NormalFloat (NF4) được thiết kế cho phân bố trọng số của mạng nơ-ron. Trong quá trình huấn luyện, trọng số nền vẫn được giữ cố định ở dạng lượng tử hóa, còn gradient chỉ cập nhật các tham số LoRA ở độ chính xác cao hơn. Cách làm này giúp tinh chỉnh các mô hình có kích thước lớn hơn trong điều kiện tài nguyên hạn chế. Trong nghiên cứu này, chúng tôi sử dụng QLoRA cho các lượt tinh chỉnh trực tiếp từ Qwen2.5-VL-3B-Instruct. Các giai đoạn học tiếp của phương pháp có cấu hình riêng ở Chương 4.

2.3 GRPO và phần thưởng dựa trên độ đo văn bản

Trong tinh chỉnh có giám sát, mô hình học bằng cách tăng xác suất của câu chuẩn tương ứng với mỗi đầu vào. Cách huấn luyện này phù hợp để hình thành khả năng sinh ban đầu, nhưng không trực tiếp phân biệt chất lượng giữa nhiều câu mà mô hình có thể sinh cho cùng một trường hợp. Học tăng cường bổ sung tín hiệu này bằng cách

gán phần thưởng cho từng đầu ra và cập nhật mô hình dựa trên chất lượng tương đối giữa các đầu ra.

Tối ưu chính sách tương đối theo nhóm (*Group Relative Policy Optimization*, GRPO) được giới thiệu trong DeepSeekMath [41]. Với mỗi đầu vào x, mô hình sinh một nhóm gồm G đầu ra $y_1, \ldots, y_G$ và nhận các phần thưởng tương ứng $r_1, \ldots, r_G$. Lợi thế của đầu ra thứ i được xác định bằng cách chuẩn hóa phần thưởng trong cùng nhóm:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G})}, \tag{2.2}$$

sau đó chính sách được cập nhật dựa trên lợi thế tương đối này, đồng thời có số hạng kiểm soát mức sai lệch so với mô hình tham chiếu. GRPO không cần huấn luyện thêm một mô hình ước lượng giá trị riêng. Khi các đầu ra trong cùng nhóm nhận phần thưởng giống nhau, lợi thế tương đối giữa chúng cũng không tạo ra khác biệt cho bước cập nhật.

Trong phương pháp đề xuất, chúng tôi xây dựng phần thưởng cho GRPO từ SPICE [24]. Đây là một độ đo dựa trên câu chuẩn, trong đó nội dung câu được biểu diễn thông qua các đối tượng, thuộc tính và quan hệ, sau đó so sánh các thành phần tương ứng bằng điểm F1. Zhao và cộng sự [37] đã sử dụng SPICE khi đánh giá mô hình sinh chỉ dẫn. Trong nghiên cứu này, SPICE được dùng làm tín hiệu phần thưởng ở mức nội dung cho câu hướng dẫn. Cách xây dựng phần thưởng và quy trình huấn luyện GRPO được trình bày cụ thể ở Mục 4.3.

2.4 Định vị phần tử giao diện

Định vị phần tử giao diện (*GUI grounding*) là bài toán xác định vị trí của một phần tử trên màn hình từ ảnh giao diện và một mô tả bằng ngôn ngữ. Đầu ra thường được biểu diễn dưới dạng một điểm hoặc một khung bao quanh phần tử mục tiêu. Một số mô hình tiêu biểu cho hướng nghiên cứu này gồm SeeClick [3], OS-Atlas [4] và UGround [5].

Bài toán định vị giúp kiểm tra trực tiếp mối liên hệ giữa câu mô tả và phần tử mà câu đó hướng tới. Nếu câu hướng dẫn cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử khác trên màn hình, một mô hình định vị có thể được dùng để suy

ra phần tử mà câu đang mô tả. Mối liên hệ này là cơ sở cho executability mà chúng tôi sử dụng. Chương 5 trình bày mô hình định vị được lựa chọn, tiêu chí xác định một dự đoán đúng và các bước kiểm tra độ tin cậy trước khi dùng mô hình này để đánh giá câu hướng dẫn.

2.5 Bộ dữ liệu AndroidControl

AndroidControl [1] là bộ dữ liệu do Google DeepMind công bố tại NeurIPS 2024 và phát hành theo giấy phép Apache 2.0. Bộ dữ liệu gồm 15.283 chuỗi thao tác do người thật thực hiện trên thiết bị Pixel trong khoảng một năm. Ở mỗi bước, dữ liệu lưu trạng thái màn hình, loại thao tác, tọa độ chạm nếu có và trường `step_instructions`, nghĩa là câu hướng dẫn do người thực hiện viết cho thao tác tương ứng.

Trong công trình AndroidControl và các nghiên cứu về tác tử giao diện sử dụng bộ dữ liệu này, như Aguvis [8], câu hướng dẫn thường được đưa vào làm đầu vào để mô hình dự đoán thao tác cần thực hiện. Chúng tôi sử dụng dữ liệu theo chiều ngược lại: đưa trạng thái tác vụ và giao diện vào mô hình để sinh câu hướng dẫn cho thao tác kế tiếp. Nhờ đó, AndroidControl có thể được chuyển thành tập dữ liệu giám sát cho bài toán sinh hướng dẫn mà không cần thu thập lại toàn bộ dữ liệu từ đầu. Quy trình hợp nhất, làm sạch và phân chia dữ liệu được trình bày ở Chương 3.

2.6 Độ đo dựa trên câu chuẩn trong bài toán sinh hướng dẫn

Một thao tác trên giao diện có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn dẫn người dùng tới cùng một phần tử. Vì vậy, một câu chuẩn chỉ phản ánh một trong nhiều cách mô tả có thể chấp nhận được. Các độ đo phụ thuộc nhiều vào mức giống nhau về từ vựng có thể đánh giá thấp một câu diễn đạt khác với câu chuẩn dù nội dung hướng dẫn vẫn đúng. Chẳng hạn, cùng một phần tử có thể được mô tả là “more options button” trong một câu và “three-dot icon” trong một câu khác.

Các độ đo tương đồng ngữ nghĩa có thể giảm bớt sự phụ thuộc vào từ ngữ cụ thể,

nhưng không được thiết kế để kiểm tra trực tiếp liệu câu hướng dẫn có giúp xác định đúng phần tử cần thao tác hay không. Hai câu có thể gần nhau về nghĩa nhưng lại quy chiếu tới hai phần tử khác nhau trên cùng màn hình, chẳng hạn "inbox" và "outbox". Ngược lại, hai cách diễn đạt khác nhau đáng kể vẫn có thể cùng quy chiếu tới một phần tử. Vì vậy, mức độ gần nhau trong không gian ngữ nghĩa không bảo đảm hai câu sẽ dẫn tới cùng một đối tượng trên giao diện.

Vì vậy, bên cạnh các độ đo dựa trên câu chuẩn, chúng tôi đánh giá trực tiếp mối quan hệ giữa hướng dẫn do mô hình tạo ra và phần tử mà hướng dẫn đó mô tả. Chương 5 trình bày executability và các bước kiểm tra độ tin cậy của cách đo.

Chương 3

Xây dựng bộ dữ liệu

Chương này trình bày nguồn dữ liệu, cách hợp nhất và kiểm tra, cách chia tập và dữ liệu dùng cho từng thành phần của phương pháp. Toàn bộ dữ liệu được dựng tự động từ AndroidControl, không gán nhãn thủ công bổ sung và không dùng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

3.1 Nguồn dữ liệu, cách hợp nhất và kiểm tra

Dữ liệu cần ba thành phần: câu hướng dẫn theo từng bước, ảnh màn hình và cây trợ năng. Không bản phân phối công khai nào trên Hugging Face có đủ cả ba, nên chúng tôi ghép hai bản ở Bảng 3.1 theo cặp mã tác vụ và số thứ tự bước, `(episode_id, step_id)`. Cây trợ năng chỉ dùng khi dựng dữ liệu và phân tích, không được đưa vào mô hình.

Bảng 3.1: Hai bản phân phối trên Hugging Face được ghép để dựng dữ liệu.

Bản phân phối	Thành phần sử dụng
`HarrytheOrange/parsed_AndroidControl`	câu hướng dẫn theo từng bước; cây trợ năng của 99.131 màn hình
`ckg/AndroidControlParsedWithImages-20k`	ảnh màn hình; cách chia tập huấn luyện và tập kiểm tra

Ghép sai bước không làm thay đổi số bản ghi, nên chúng tôi kiểm tra trên nội dung. Với mỗi bước có thao tác chạm, chúng tôi lấy văn bản OCR tại vị trí chạm và xem văn bản này có xuất hiện trong câu hướng dẫn hay không. Trên 400 bước được kiểm tra, tỉ

lệ này là 48%. Khi cố ý ghép ảnh với câu hướng dẫn của bước kế tiếp, tỉ lệ giảm còn 20% (trên 311 cặp đủ dữ liệu). Chênh lệch khoảng 2,4 lần cho thấy ảnh và câu hướng dẫn được ghép đúng bước.

3.2 Quy mô và phân chia dữ liệu

Bảng 3.2: Quy mô tập huấn luyện và tập kiểm tra.

	Tập huấn luyện	**Tập kiểm tra**
Số bước	64.567	6.958
Số bước có thao tác chạm	41.191 (63,8%)	4.463 (64,1%)
Số tác vụ	12.895	1.432

Mọi màn hình ở cả hai tập đều có văn bản OCR. Executability ở Chương 5 và Chương 6 chỉ tính trên 4.463 bước có thao tác chạm của tập kiểm tra. Các bước không chạm, như cuộn, quay lại hay nhập chữ, được phân tích riêng ở Mục 6.11.

Dữ liệu được chia theo tác vụ: mọi bước của một tác vụ chỉ nằm trong một tập, nên các màn hình liên tiếp của cùng một chuỗi thao tác không xuất hiện ở cả hai phía. Đối chiếu mã tác vụ cho thấy không có tác vụ chung giữa tập huấn luyện và tập kiểm tra.

Quan hệ với cách chia chính thức. Bản `ckg` tự chia tác vụ thành hai tập, độc lập với cách chia chính thức của AndroidControl [1]. Đối chiếu cho thấy 1.287/1.432 tác vụ (90%) của tập kiểm tra thuộc phần huấn luyện chính thức, còn 1.357 tác vụ của phần kiểm tra chính thức nằm trong tập huấn luyện của chúng tôi. Vì vậy, các chương sau gọi tập này là *tập kiểm tra của đề tài*, và điểm số không so trực tiếp với các công trình báo cáo trên phần kiểm tra chính thức. Ảnh hưởng của điều này tới công cụ đánh giá được kiểm tra ở Mục 5.5.5.

Tập kiểm định nội bộ. Từ tập huấn luyện, chúng tôi tách riêng 346 tác vụ (1.567 bước, trong đó 1.002 bước chạm) để chọn cấu hình cho GRPO-SPICE và ACE. S1 đã được huấn luyện trên phần này, nên điểm trên tập kiểm định nội bộ có xu hướng cao hơn thực tế và chỉ dùng để chọn cấu hình, không dùng làm kết quả báo cáo.

Tập tác vụ chưa xuất hiện trong huấn luyện S1 (ACU). AndroidControl còn những tác vụ có câu hướng dẫn nhưng không thuộc bản `ckg`, nên không thuộc tập nào ở Bảng 3.2. Chúng tôi lấy ảnh của các tác vụ này từ bản phát hành gốc của AndroidControl, chạy OCR theo cùng cách với hai tập trên, và thu được ACU gồm 1.484 bước có thao tác chạm thuộc 818 tác vụ. ACU được dùng để kiểm tra khả năng khái quát trên tác vụ mới. Phần lớn các bước này (1.383/1.484) cũng thuộc phần huấn luyện chính thức, nên ACU chỉ là tập bổ sung, không thay thế tập kiểm tra chính.

3.3 Dữ liệu cho từng thành phần của phương pháp

Mỗi mẫu gồm ảnh màn hình, văn bản OCR do chúng tôi chạy tự động trên ảnh (không sửa thủ công), mục tiêu tác vụ và câu chuẩn của các bước trước làm lịch sử; đích là câu hướng dẫn của bước hiện tại. Các thành phần của phương pháp dùng dữ liệu như sau.

- **S1** được tinh chỉnh có giám sát trên toàn bộ tập huấn luyện ở Bảng 3.2. Có 122 bản ghi không có câu hướng dẫn được giữ nguyên như dữ liệu gốc.
- **GRPO-SPICE** lấy prompt và câu chuẩn (để tính phần thưởng SPICE) từ 3.991 bước của tập huấn luyện có ảnh khả dụng ở giai đoạn này và không trùng tác vụ với tập kiểm định nội bộ.
- **Lượt tinh chỉnh thêm của ACE** dùng cùng 3.991 bước đó, kèm câu ví dụ truy hồi từ kho bên dưới.
- **Kho truy hồi của ACE** gồm 62.880 bước có câu hướng dẫn của tập huấn luyện, đã loại các tác vụ của tập kiểm định nội bộ. Kho không chứa tác vụ nào của tập kiểm tra của đề tài, nên ACE không thể truy hồi câu chuẩn của bước đang được đánh giá.

Cách lấy mẫu, số bước cập nhật và cách truy hồi được trình bày ở Mục 4.3 và Mục 4.4. Các nhãn mô tả phần tử, tập cặp ưu tiên và danh sách ứng viên chỉ phục vụ các phương án đã khảo sát trước phương pháp cuối, và được trình bày cùng từng phương án ở Phụ lục A.

3.4 Một số đặc điểm cần lưu ý

Ba đặc điểm sau ảnh hưởng tới cách đọc kết quả ở Chương 6.

Mục tiêu tác vụ bị cắt ngắn. Trong dữ liệu gốc, phần lớn mô tả mục tiêu bị cắt giữa chừng. Chúng tôi giữ nguyên trường này cho cả tập huấn luyện lẫn tập kiểm tra.

Cách diễn đạt lặp lại. Một số câu và cụm từ xuất hiện ở cả tập huấn luyện và tập kiểm tra dù hai tập không có tác vụ chung. Hiện tượng này phản ánh các khuôn diễn đạt quen thuộc của hướng dẫn giao diện, không phải sự trùng lặp tác vụ.

Phạm vi phân tích theo ứng dụng. Khoảng 55% số bước của tập kiểm tra không xác định được tên ứng dụng, nên các phân tích theo ứng dụng chỉ dùng phần còn lại.

Chương 4

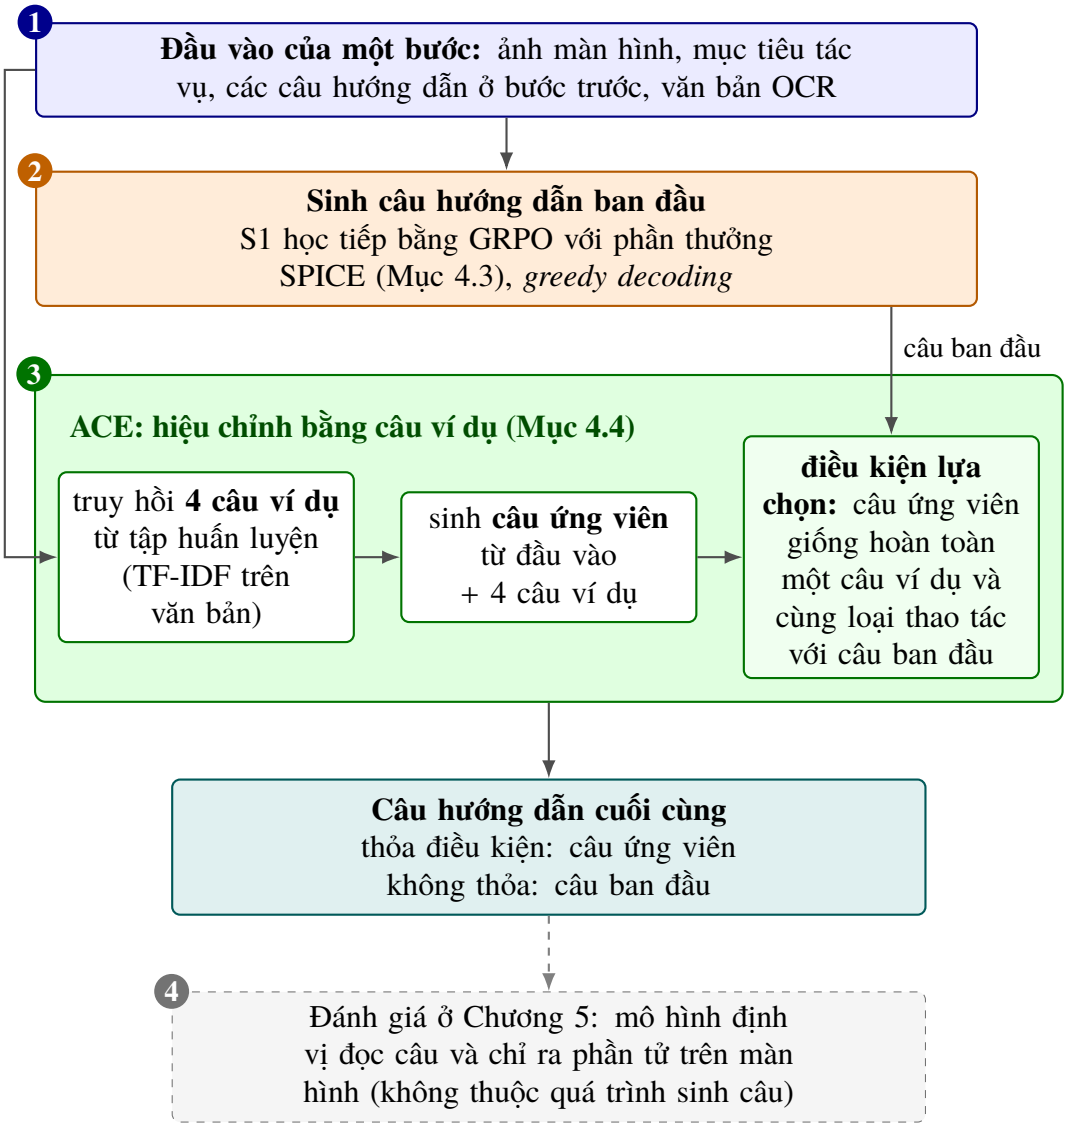
Phương pháp đề xuất

Chương này trình bày phương pháp sinh hướng dẫn gồm hai thành phần, học tăng cường với phần thưởng SPICE và hiệu chỉnh có chọn lọc bằng câu ví dụ truy hồi (ACE), cùng mô hình xuất phát và các mô hình so sánh. Độ đo executability được trình bày ở Chương 5, các phương án đã khảo sát trước phương pháp cuối cùng ở Phụ lục A.

4.1 Quy trình tổng thể

Ở mỗi bước của một tác vụ, hệ thống cần viết một câu hướng dẫn bằng tiếng Anh cho bước tiếp theo. Quy trình gồm bốn bước (Hình 4.1).

1. **Đầu vào:** ảnh chụp màn hình, mục tiêu tác vụ, câu hướng dẫn của các bước trước và văn bản OCR của màn hình (Mục 4.2).
2. **Sinh câu hướng dẫn ban đầu:** S1, tức Qwen2.5-VL-3B-Instruct đã tinh chỉnh có giám sát (Mục 4.5), được học tiếp bằng GRPO với phần thưởng SPICE rồi sinh câu bằng giải mã tham lam (Mục 4.3).
3. **Hiệu chỉnh bằng ACE:** bốn câu ví dụ truy hồi từ tập huấn luyện được dùng để sinh một câu ứng viên, và câu này chỉ thay câu ban đầu khi thỏa điều kiện lựa chọn (Mục 4.4).
4. **Đánh giá:** mô hình định vị đọc câu cuối cùng và chỉ ra phần tử trên màn hình; executability được xác định từ vị trí này và loại thao tác trong câu (Chương 5). Bước này tách riêng khỏi quá trình sinh câu.



Hình 4.1: Quy trình sinh hướng dẫn của phương pháp đề xuất.

Khi suy luận, phương pháp chỉ dùng đầu vào của bước đang xét và kho câu chuẩn của tập huấn luyện. Mô hình định vị không tham gia vào phần thưởng của GRPO hay điều kiện lựa chọn của ACE, và câu chuẩn của chính bước đang xét không được truy cập. Trong các phần sau, *GRPO-SPICE* chỉ riêng thành phần thứ nhất, còn *phương pháp đề xuất* chỉ toàn bộ quy trình sau khi áp dụng ACE.

4.2 Đầu vào và cấu trúc prompt

Base, S1, GRPO-SPICE và Qwen2.5-VL-7B (Mục 4.5) dùng chung một prompt. Ngoài ảnh màn hình và một lời dặn hệ thống yêu cầu viết một câu hướng dẫn ngắn bằng tiếng Anh, prompt có bốn dòng: mục tiêu tác vụ, tối đa ba câu hướng dẫn gần nhất của các bước trước, tối đa 24 đoạn văn bản OCR và yêu cầu sinh câu. Tên các mục viết bằng tiếng Việt, câu trả lời viết bằng tiếng Anh theo ngôn ngữ của dữ liệu. Mô hình sinh câu ứng viên của ACE nhận thêm một khối câu ví dụ ngay trước yêu cầu sinh câu.

```
<image>
Mục tiêu: Open Google maps app, Search for the nearest
  park to 98103 …
Đã làm: Open the Google Maps app
Chữ đọc được trên màn: Search here · Coffee ·
  Restaurants · Groceries · …
Viết câu hướng dẫn cho bước tiếp theo.
```

Trong thiết lập đánh giá chính, dòng "Đã làm" chứa câu chuẩn của các bước trước, nên mọi mô hình được so trên cùng một lịch sử đúng và điểm tuyệt đối phản ánh điều kiện này. Mục 6.8 xét thêm trường hợp lịch sử do chính mô hình sinh.

4.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Cơ sở lựa chọn. Các hướng đã thử trước đó (sinh mô tả phần tử trước câu, học theo cặp ưu tiên, chọn phần tử trong danh sách ứng viên, phần thưởng tọa độ, đưa thông tin vị trí vào mô hình, hiệu chỉnh theo vùng ảnh) chủ yếu tác động vào một biểu diễn trung gian, và thay đổi ở biểu diễn này không luôn truyền sang câu cuối cùng (Mục 6.10, Phụ lục A). Thành phần thứ nhất vì vậy tối ưu trực tiếp câu đầu ra bằng một phần thưởng văn bản, tương tự cách CIDEr hay SPIDEr được dùng làm phần thưởng trong sinh chú thích ảnh [44, 46].

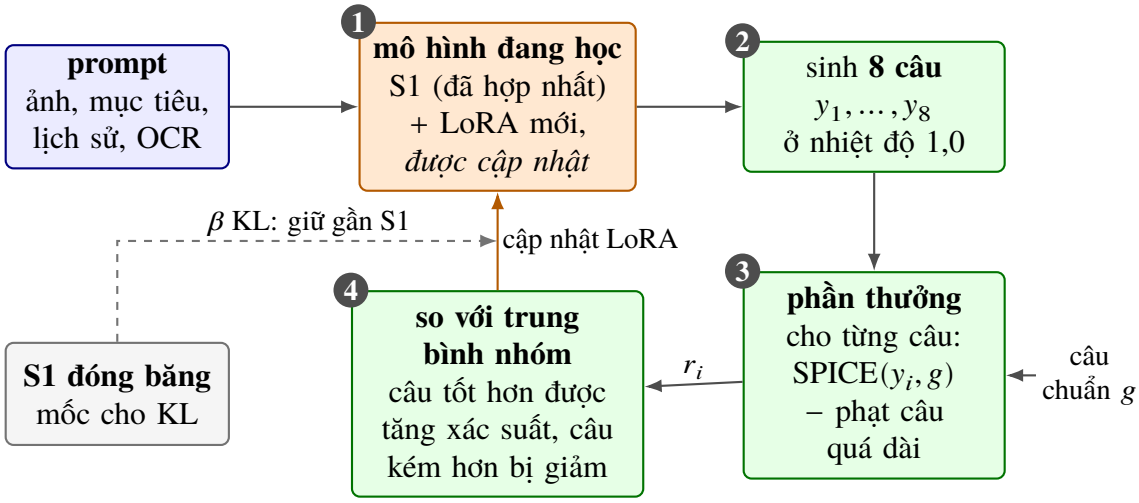
GRPO chỉ học từ chênh lệch phần thưởng giữa các câu sinh cho cùng một prompt (Mục 2.3), nên phần thưởng phải phân biệt được câu tốt với câu kém trong các mẫu của chính S1. Trên tập kiểm định nội bộ, trong các câu S1 sinh cho cùng một bước, câu có SPICE cao nhất có executability cao hơn câu giải mã tham lam, và executability giảm dần theo thứ hạng SPICE. Mục 6.3 so sánh thêm với phần thưởng CIDEr-D.

Thiết kế. GRPO-SPICE khởi tạo từ S1/101: bộ chuyển đổi LoRA của S1 được hợp nhất vào mô hình, rồi một LoRA mới cùng cỡ được gắn để học tiếp, tháp thị giác vẫn đóng băng. Bản S1 đã hợp nhất được giữ cố định làm mô hình tham chiếu cho số hạng KL, giúp mô hình đang học không đi quá xa S1. Phần thưởng của câu sinh s so với câu chuẩn g là

$$r(s) = \mathrm{SPICE}(s, g) - 0{,}02 \cdot \max(0,\ |s| - |g| - 3), \tag{4.1}$$

trong đó $|\cdot|$ là số từ. Số hạng phạt chỉ áp cho câu dài hơn câu chuẩn quá ba từ, nhằm tránh tăng SPICE bằng cách thêm chi tiết thừa. Câu không có nội dung nhận phần thưởng 0.

Mỗi bước cập nhật lấy hai prompt, mỗi prompt sinh $G = 8$ câu ở nhiệt độ 1,0, mỗi câu tối đa 96 token. Huấn luyện gồm 500 bước, tức một lượt duyệt qua 1.000 prompt lấy ngẫu nhiên từ 3.991 bước ở Mục 3.3 (gồm mọi loại thao tác), với tốc độ học 10^{-5} và hệ số KL $\beta = 0{,}04$ (Hình 4.2).



Hình 4.2: Vòng huấn luyện GRPO-SPICE.

Chọn điểm lưu. Điểm lưu sau 250 và 500 bước được so theo executability trên tập kiểm định nội bộ; điểm lưu 500 bước tốt hơn nên được cố định trước khi sinh câu trên tập kiểm tra.

Lượt thứ hai và nhánh kiểm soát. Hai lượt bổ sung dùng cùng điểm khởi tạo S1/101, cùng số bước và siêu tham số với GRPO-SPICE. Lượt GRPO-SPICE thứ hai chỉ đổi seed thành 202; vì điểm xuất phát không đổi, khác biệt giữa hai lượt phản ánh biến thiên của riêng giai đoạn GRPO. Ở nhánh kiểm soát, điểm SPICE được ghép ngẫu nhiên giữa các mẫu trong cùng nhóm trước khi dùng làm phần thưởng. Nhánh này giữ nguyên quá trình cập nhật nhưng cắt liên hệ giữa câu và phần thưởng, nên tách được tác dụng của tín hiệu SPICE khỏi tác dụng của việc huấn luyện thêm (Mục 6.3, Mục 6.11).

4.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ nhất quán thao tác (ACE)

Cơ sở lựa chọn. Câu chuẩn của AndroidControl lặp lại nhiều khuôn diễn đạt giữa các tác vụ (Mục 3.4), nên với nhiều bước, câu chuẩn của một bước tương tự trong tập huấn luyện đã là câu hướng dẫn phù hợp, có khi trùng nguyên văn câu chuẩn của bước đang xét. ACE (*Action-Consistent Exemplar Copying*) tận dụng đặc điểm này bằng cách cho mô hình chép nguyên một câu ví dụ truy hồi thay cho câu tự viết. Chép không chọn lọc lại có rủi ro, vì câu ví dụ có thể mô tả thao tác khác hoặc phần tử không có trên màn hình đang xét; dùng câu ứng viên cho mọi bước làm giảm executability (Mục 6.9). Vì vậy ACE chỉ dùng câu chép khi câu đó giữ đúng loại thao tác của câu ban đầu.

Truy hồi câu ví dụ. Kho truy hồi gồm câu chuẩn của các bước trong tập huấn luyện (Mục 3.3). Truy hồi chỉ dùng văn bản, theo độ tương đồng TF-IDF, không dùng ảnh. Câu ví dụ được lấy theo hai cách: (i) truy hồi trực tiếp các bước có mục tiêu và câu lịch sử gần nhất tương tự, theo ý tưởng của SmallCap [45]; (ii) tìm các tác vụ có mục tiêu gần nhất, rồi trong mỗi tác vụ chọn bước có câu ở bước liền trước giống câu lịch sử gần nhất. Kết quả hai cách được gộp, bỏ câu trùng và giữ bốn câu, ưu tiên câu xuất hiện ở cả hai cách và câu có mọi từ nội dung nằm trong văn bản OCR của màn

hình.

Mô hình sinh câu ứng viên. Mô hình này khởi tạo từ GRPO-SPICE và được tinh chỉnh có giám sát thêm 250 bước với tốc độ học 2×10^{-5} trên cùng 3.991 bước ở Mục 3.3, với prompt có chèn khối câu ví dụ. Để mô hình không chép máy móc, khi học số câu ví dụ thay đổi từ 2 đến 6 với thứ tự ngẫu nhiên, 15% prompt không có khối, 10% dùng câu ví dụ ngẫu nhiên, và tác vụ đang học được loại khỏi kho. Khi suy luận, khối luôn có bốn câu. Một nhánh so sánh được huấn luyện y hệt nhưng không có khối ví dụ, để tách tác dụng của truy hồi khỏi tác dụng của việc học thêm.

Điều kiện lựa chọn. Câu ứng viên chỉ thay câu ban đầu khi thỏa cả hai điều kiện sau.

1. **Trùng một câu ví dụ.** Sau khi tách từ, câu ứng viên giống hoàn toàn một trong bốn câu ví dụ của khối. Câu mô hình tự viết mới không được dùng.

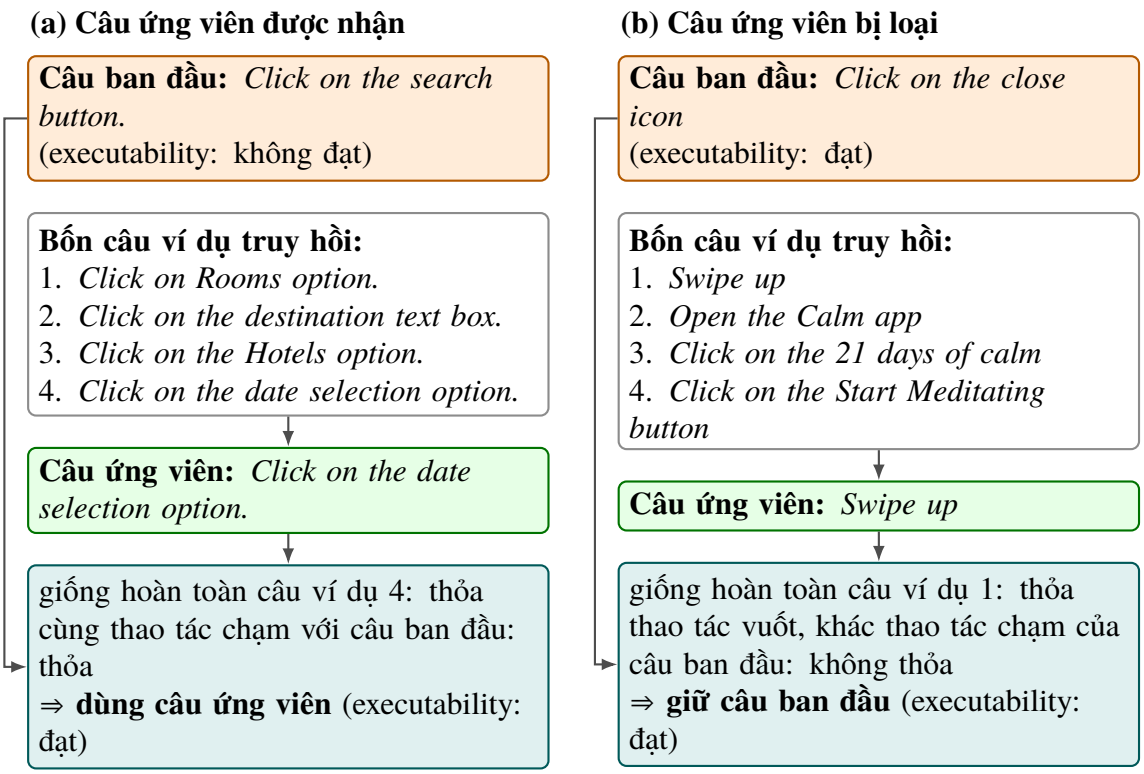
2. **Nhất quán loại thao tác.** Động từ ở đầu câu ứng viên và ở đầu câu ban đầu thuộc cùng một lớp thao tác. Có sáu lớp: chạm, nhấn giữ, nhập chữ, cuộn hoặc vuốt, mở ứng dụng và quay lại.

Hình 4.3 minh họa một trường hợp câu ứng viên được nhận và một trường hợp bị loại vì đổi loại thao tác.

Chọn điều kiện. Điều kiện trên được chọn trong bốn biến thể: chỉ yêu cầu trùng câu ví dụ; thêm yêu cầu cùng lớp thao tác; thêm yêu cầu phần nội dung chính (bỏ động từ, hư từ và từ chỉ vị trí) đạt chỉ số Jaccard ít nhất 0,5 với câu ban đầu; và yêu cầu cả hai. Trên tập kiểm định nội bộ, trong các biến thể cao hơn GRPO-SPICE ở ít nhất bốn trong năm độ đo dựa trên câu chuẩn, biến thể có executability cao nhất được chọn. Biến thể và tiêu chí được xác định trước khi tính executability trên tập kiểm định nội bộ, và biến thể được chọn chỉ áp lên tập kiểm tra một lần.

4.5 Mô hình so sánh và cấu hình của S1

Ngoài lượt GRPO-SPICE thứ hai, nhánh kiểm soát (Mục 4.3) và nhánh so sánh của ACE (Mục 4.4), phương pháp đề xuất được so với bốn mốc. Base là Qwen2.5-VL-



Hình 4.3: Hai ví dụ minh họa điều kiện lựa chọn của ACE trên tập kiểm tra.

3B-Instruct [34] chưa tinh chỉnh. Qwen2.5-VL-7B-Instruct, cũng không tinh chỉnh và dùng đúng prompt của Base, là mốc có cỡ mô hình lớn hơn. S1 là Base được tinh chỉnh có giám sát để sinh trực tiếp câu hướng dẫn, huấn luyện hai lần với seed 101 và 202; S1/101 là điểm khởi tạo của GRPO-SPICE nên là mốc so sánh trực tiếp, còn chênh lệch giữa hai seed cho biết mức dao động khi lặp lại huấn luyện. Cuối cùng, câu chuẩn được đưa qua cùng quy trình đánh giá để làm mốc diễn giải điểm số.

S1 được tinh chỉnh bằng QLoRA [29, 30] trên thư viện LLaMA-Factory [31]: trọng số gốc được lượng tử hóa 4 bit, chỉ các tham số LoRA được cập nhật (Bảng 4.1). Hai giai đoạn học tiếp dùng cấu hình riêng đã nêu ở Mục 4.3 và Mục 4.4.

Mọi phép so executability là so ghép cặp trên cùng các bước có thao tác chạm của tập kiểm tra, báo chênh lệch, khoảng tin cậy 95% và giá trị p (Mục 5.6).

Bảng 4.1: Cấu hình tinh chỉnh có giám sát của S1.

Tham số	**Giá trị**
Mô hình gốc	Qwen2.5-VL-3B-Instruct
Lượng tử hoá	NF4, 4 bit
Hạng LoRA r / α / dropout	8 / 16 / 0,05
Mô-đun gắn bộ chuyển đổi	q, k, v, o, gate, up, down
Tháp thị giác, tầng chiếu đa phương thức	đóng băng
Độ dài ngữ cảnh	2.560
Cỡ lô mỗi thiết bị / tích luỹ gradient	4 / 4 (hiệu dụng 16)
Tốc độ học / lịch / tỉ lệ khởi động	1×10^{-4} / cosine / 0,05
Số lượt duyệt	2 (=8.072 bước)
Độ chính xác, phần cứng	bf16, gradient checkpointing, một GPU A100
Seed	101 và 202
Tham số huấn luyện được	14.966.784 (0,48% phần ngôn ngữ)

Chương 5

Độ đo khả năng thực hiện theo hướng dẫn

Chương này trình bày cách đề tài đánh giá một câu hướng dẫn. Câu được đưa cho một mô hình khác đọc cùng với ảnh màn hình, và mô hình này chọn một điểm trên ảnh để chạm. Nếu điểm được chọn rơi đúng vào phần tử mà người dùng thật đã chạm thì câu được xem là thực hiện được. Mục 5.1 định nghĩa độ đo này, gọi là executability. Mục 5.2 và Mục 5.3 trình bày cách xác định điểm đúng phần tử và loại thao tác đúng. Mục 5.4 giới thiệu bảy độ đo văn bản được báo kèm. Mục 5.5 kiểm chứng độ tin cậy của executability, trong đó có việc thay mô hình đánh giá bằng ba mô hình khác. Mục 5.6 trình bày phương pháp thống kê.

5.1 Ý tưởng và định nghĩa executability

Cách đánh giá thường gặp trong bài toán sinh câu là so câu sinh ra với câu chuẩn bằng các độ đo như BLEU hay ROUGE. Với hướng dẫn sử dụng giao diện, cách so này có hai hạn chế. Thứ nhất, mỗi bước chỉ có một câu chuẩn, trong khi cùng một phần tử có thể được gọi theo nhiều cách đúng: *Click on the Birthday* và *Tap the date of birth row* có thể cùng chỉ một dòng trên màn hình nhưng có rất ít từ chung. Thứ hai, một câu có thể giống câu chuẩn về từ ngữ mà vẫn chỉ sai phần tử. Chẳng hạn, ở một bước có hộp thoại xin quyền gửi thông báo, câu chuẩn là *Click on the Not now button to remove this pop up notification*, còn câu *Click on the Allow button* có gần hết từ ngữ trùng với câu chuẩn nhưng dẫn người dùng tới một nút có tác dụng ngược lại. Zhao và

cộng sự [37] cũng nhận thấy các độ đo dựa trên cụm từ kém tin cậy khi đánh giá chỉ dẫn điều hướng.

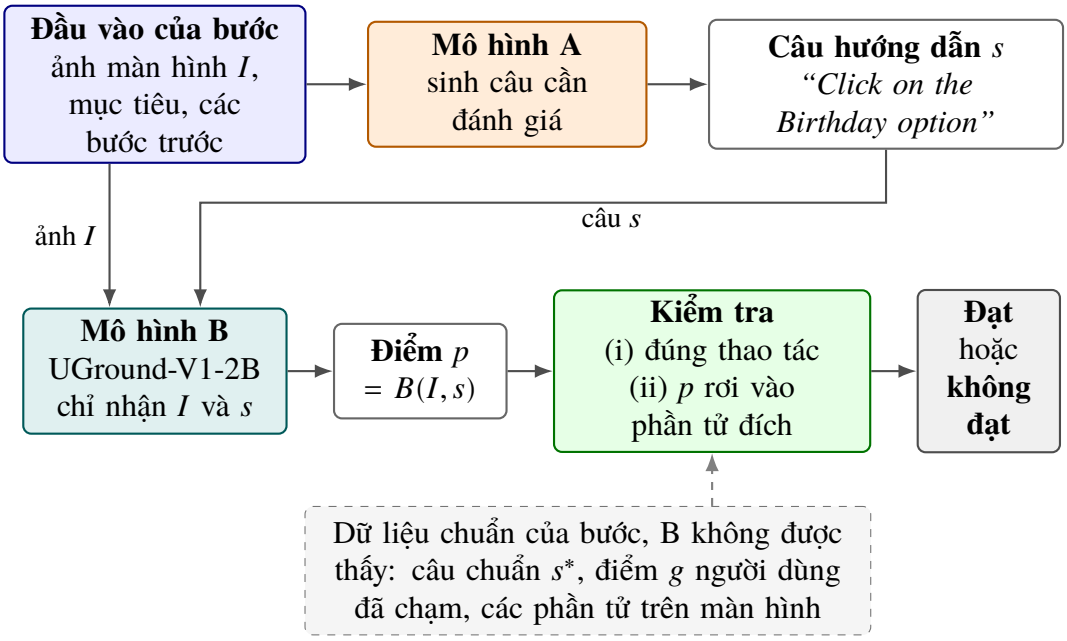
Một câu hướng dẫn tốt là câu giúp người đọc thao tác đúng. Đề tài thay người đọc bằng một mô hình máy rồi kiểm tra thao tác mà mô hình này thực hiện. Cách đánh giá này có tiền lệ trong nghiên cứu sinh biểu thức quy chiếu, nơi câu mô tả một đối tượng trong ảnh được chấm bằng tỉ lệ một mô hình hiểu câu chọn đúng đối tượng đó [12, 13]. Quy trình đánh giá gồm hai mô hình:

- **Mô hình A** là mô hình sinh câu cần đánh giá, chẳng hạn Base, S1 hay phương pháp đề xuất (Chương 4). Ở mỗi bước, A nhận ảnh màn hình cùng thông tin của tác vụ và viết một câu hướng dẫn cho thao tác tiếp theo.
- **Mô hình B** là mô hình định vị phần tử giao diện (*GUI grounding*). B nhận một ảnh màn hình và một câu mô tả, rồi trả về tọa độ của một điểm trên ảnh, là nơi cần chạm theo câu đó. Mô hình B chính của đề tài là UGround-V1-2B [5], một mô hình có trọng số công khai được phát triển riêng cho bài toán này.

B độc lập với A theo ba nghĩa. B không được huấn luyện hay tinh chỉnh trong đề tài. B không tham gia phần thưởng của GRPO hay điều kiện lựa chọn của ACE (Mục 4.1). B chỉ nhận câu và ảnh, không biết mục tiêu tác vụ, các bước trước hay điểm người dùng đã chạm. Vì vậy B chỉ tìm được đúng phần tử khi câu nêu đủ thông tin để nhận ra phần tử đó trên màn hình.

Hình 5.1 tóm tắt quy trình. Ở mỗi bước, A sinh câu s, B đọc s cùng ảnh I và trả về điểm $p = B(I, s)$. Điểm này được so với dữ liệu chuẩn của bước, gồm câu chuẩn s^* do người chú thích viết và điểm g mà người dùng đã chạm. Câu *s thực hiện được* khi thoả cả hai điều kiện:

- **(i) Đúng thao tác.** s nêu cùng loại thao tác với câu chuẩn, trong năm loại chạm, gõ, cuộn, nhấn giữ và quay lại, và không gọi trạng thái ngược với câu chuẩn, chẳng hạn "bật thông báo" thay cho "tắt thông báo" (Mục 5.3).
- **(ii) Đúng phần tử.** p rơi vào phần tử mà người dùng đã chạm. Cụ thể, p nằm trong cửa sổ $\pm 14\%$ quanh g và không gần phần tử nào khác hơn chính g (Mục 5.2).



Hình 5.1: Quy trình đánh giá một câu hướng dẫn bằng executability.

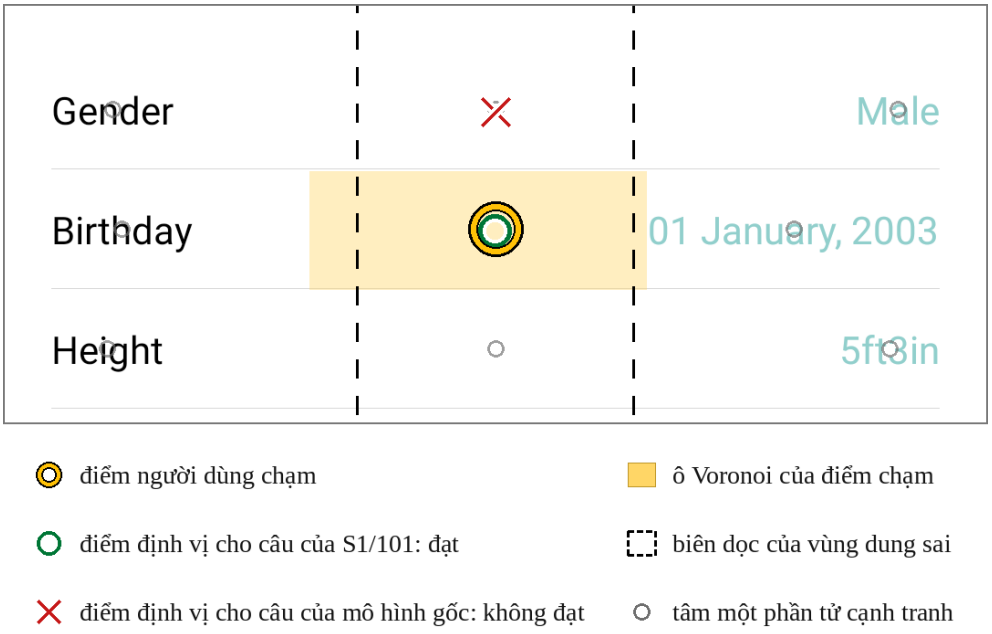
Điểm executability của một mô hình A là tỉ lệ câu thực hiện được trên N bước:

$$\text{Executability} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[\text{ đúng thao tác}(s_i, s_i^*)\ ] \cdot \mathbb{1}[\ B(I_i, s_i) \in V(g_i)\ ], \qquad (5.1)$$

trong đó $\mathbb{1}[\cdot]$ bằng 1 khi điều kiện đúng và bằng 0 khi sai, còn $V(g_i)$ là vùng chấp nhận quanh điểm chạm, định nghĩa ở Mục 5.2.

Hình 5.2 là một bước trên màn hình hồ sơ cá nhân. Người dùng đã chạm dòng *Birthday*, và câu chuẩn là *Click on the Birthday*. S1 viết *Click on the Birthday option*; B chọn một điểm nằm trên dòng *Birthday*, nên câu đạt. Base viết *Click on the "Gender" section to change it to "Male"*. Câu này vẫn nêu đúng thao tác chạm, nhưng B chọn dòng *Gender* ngay phía trên, nên câu không đạt. Điểm của B cho câu của Base vẫn nằm trong cửa sổ 14% quanh điểm chạm; Mục 5.2 giải thích vì sao trường hợp này vẫn được tính là sai.

Độ đo chỉ tính trên các bước có thao tác chạm (gồm chạm và nhấn giữ), tức **4.463** trong 6.958 bước của tập kiểm tra. Chỉ ở các bước này dữ liệu mới có tọa độ của phần tử đích để so với điểm của B; các bước gõ chữ, cuộn và quay lại không có tọa độ đích nên được phân tích riêng bằng tỉ lệ nêu đúng loại thao tác (Mục 6.11). Câu không có



Hình 5.2: Một bước được đánh giá: câu của S1 đạt, câu của Base dẫn tới dòng *Gender* nên không đạt.

nội dung vẫn nằm trong mẫu số và được tính là không đạt. Executability chỉ xét việc câu xác định đúng phần tử và thao tác; các khía cạnh ngôn ngữ được đo riêng bằng độ đo văn bản (Mục 5.4).

5.2 Xác định điểm đúng phần tử

Dữ liệu cho biết điểm g mà người dùng đã chạm nhưng không cho biết chính xác ranh giới của phần tử được chạm. Điều kiện (ii) vì vậy được xác định bằng hai tiêu chí kết hợp.

Cửa sổ dung sai 14%. Theo quy ước của AndroidInTheWild [2], hai lần chạm được coi là tương đương khi cách nhau không quá 14% kích thước màn hình. Đề tài dùng cửa sổ theo từng trục, $|p_x - g_x| \le 0{,}14\,W$ và $|p_y - g_y| \le 0{,}14\,H$, với W và H là bề ngang và chiều cao màn hình. Trên màn hình 1080×2400, cửa sổ này rộng ± 151 điểm ảnh theo chiều ngang và ± 336 điểm ảnh theo chiều dọc, lớn hơn nhiều so với một nút thông thường. Ở 63,2% số bước có ít nhất một phần tử khác nằm trong cửa sổ

quanh điểm chạm, nên một điểm rơi vào phần tử bên cạnh vẫn có thể được chấp nhận, như dòng *Gender* ở Hình 5.2.

Ô Voronoi. Để loại trường hợp này, đề tài thêm một điều kiện: trong các phần tử trên màn hình, phần tử người dùng đã chạm phải là phần tử gần p nhất. Gọi E là tập các phần tử khác trên màn hình, với tâm $c(e)$ lấy từ cây trợ năng. Điểm p phải thoả

$$\|p - g\| \leq \|p - c(e)\| \quad \forall e \in E. \tag{5.2}$$

Tập các điểm thoả (5.2) là ô Voronoi quanh g, được tô vàng ở Hình 5.2. Ô được dựng quanh chính điểm chạm, không quanh tâm hộp của phần tử, vì điểm người dùng chạm thường lệch khỏi tâm phần tử vài chục điểm ảnh. Các tâm cách nhau dưới 24 dp (khoảng 63 điểm ảnh trên thiết bị của bộ dữ liệu; dp là đơn vị độ dài của Android, không phụ thuộc mật độ điểm ảnh) được gộp làm một, và tâm nào cách g dưới 24 dp được coi là thuộc chính phần tử đích. Vùng chấp nhận $V(g)$ trong công thức (5.1) là phần giao của cửa sổ 14% và ô Voronoi, nên ô Voronoi là phiên bản chặt hơn của cửa sổ dung sai chứ không phải một lựa chọn thay thế.

Bảng 5.1 so hai cách xác định trên các dự đoán tổng hợp từ 250 bước, mỗi bước bốn lần theo hướng ngẫu nhiên: điểm dự đoán hoặc lệch 3% bề ngang khỏi điểm chạm, hoặc được đặt vào tâm phần tử khác gần nhất. Cửa sổ 14% chấp nhận 84,3% dự đoán đã chuyển sang phần tử lân cận, còn ô Voronoi chỉ chấp nhận **2,8%** mà vẫn giữ 99,7% dự đoán lệch nhẹ.

Bảng 5.1: Tỉ lệ chấp nhận khi dự đoán lệch nhẹ và khi dự đoán chuyển sang phần tử lân cận.

Tiêu chí	Lệch 3%	Sang phần tử lân cận
Cửa sổ dung sai $\pm$14% theo từng trục	100,0%	84,3%
Cửa sổ 14% và ô Voronoi (executability)	99,7%	**2,8%**

Phép gộp tâm 24 dp có một giới hạn đã biết: khi phần tử lân cận có tâm cách đích từ 30 đến 80 điểm ảnh, nhiều phần tử đã bị gộp với đích nên ô Voronoi chỉ phát hiện 33,1% trường hợp, so với 99,6% khi khoảng cách từ 80 đến 150 điểm ảnh (Phụ lục B.1). Executability vì vậy phân biệt các phần tử tách biệt trên giao diện, không phân biệt các điểm lệch nhẹ trong cùng một vùng tương tác.

5.2.1 Các tiêu chí báo kèm

Chương 6 báo thêm ba tiêu chí có tiền lệ trong các bộ dữ liệu giao diện (Bảng 5.2). Cả ba giữ điều kiện (i), chỉ thay điều kiện (ii), và được tính lại từ chính các điểm B đã trả về.

Bảng 5.2: Các tiêu chí xác định điểm đúng phần tử.

Tiêu chí	**Điểm p được tính là đúng khi**	**Nguồn**
Executability (chính)	p trong cửa sổ $\pm$14% quanh g và phần tử đích là phần tử gần p nhất	Mục 5.2
Hộp phần tử (D.3)	p nằm trong hộp bao của phần tử chứa g	AndroidControl, Phụ lục D.3 [1]
Hộp $\wedge$ 14%	p vừa nằm trong hộp phần tử vừa nằm trong cửa sổ 14%	kết hợp hai tiêu chí trên
AitW đầy đủ	p cách g không quá 0,14 trên tọa độ chuẩn hoá về [0; 1], hoặc p và g cùng nằm trong hộp phần tử nới rộng 1,4 lần	mã đánh giá của AndroidInTheWild [2]

Tiêu chí hộp phần tử dựa trên lập luận rằng chạm vào đâu trong phần tử thì phần tử cũng kích hoạt. Hộp được lấy từ nút nhỏ nhất trong cây trợ năng chứa điểm chạm; khoảng 48% hộp như vậy là nút con không nhận thao tác chạm, nên tiêu chí này chặt hơn khi dùng hộp của phần tử nhận thao tác. Với AitW đầy đủ, mã gốc xét mọi khung chú thích trên màn hình, còn dữ liệu của đề tài chỉ có khung của phần tử cần chạm, nên điểm theo biến thể này không cao hơn tiêu chí gốc. Nếu xét mọi khung phần tử bấm được trong cây trợ năng, gọi là *AitW cận trên*, câu chung chung "*Tap the button.*" đạt tới 41,6% trên mẫu 800 bước, nên biến thể này chỉ dùng để phân tích độ nhạy.

Thứ hạng câu chuẩn > S1 > Base giữ nguyên dưới cả bốn tiêu chí (Bảng 5.3). Ba tiêu chí báo kèm cho điểm cao hơn, nhưng mỗi tiêu chí dễ dãi ở một chỗ. Khoảng 78% mức tăng của câu chuẩn dưới tiêu chí hộp so với executability đến từ các phần tử có hộp rộng hơn nửa bề ngang màn hình. AitW đầy đủ gần như không phạt câu thiếu tên phần tử: trên mẫu 800 bước, câu chuẩn bỏ tên phần tử chỉ thấp hơn câu chuẩn 4,5 điểm theo AitW đầy đủ, so với 6,9 điểm theo executability. Vì vậy executability là tiêu chí chính, còn ba tiêu chí kia được báo kèm. Phụ lục B.3 so thêm năm cách xác định vị trí khác và cho thấy thứ hạng không đổi; Phụ lục B.4 cho thấy một tiêu chí lỏng hơn

Bảng 5.3: Điểm theo executability và ba tiêu chí báo kèm.

	Executability	Hộp	Hộp ∧ 14%	AitW đầy đủ
4.463 bước				
Câu chuẩn	75,7	83,8	79,2	92,1
S1/101	59,1	65,5	61,7	74,4
Base	47,6	53,6	49,8	63,4
Mẫu 800 bước				
Câu chuẩn	74,9	83,0	78,8	90,8
Câu chung chung "*Tap the button.*"	12,0	14,1	12,1	25,9
Câu chuẩn của một màn hình khác	6,1	8,6	6,6	17,4
Dải phân tách (câu chuẩn − câu chung chung)	62,9	68,9	66,6	64,9

có thể biến một chênh lệch không có ý nghĩa thống kê thành có ý nghĩa.

5.3 Loại thao tác

Điều kiện (i) gồm hai phần. Phần thứ nhất là **loại thao tác**: câu sinh và câu chuẩn đều được quy về một trong năm loại chạm, gõ, cuộn, nhấn giữ và quay lại, dựa trên động từ đầu tiên trong câu thuộc một danh sách động từ cho trước.[1] Các cách nói khác nhau của cùng một cú chạm, như *tap*, *click*, *open* hay *select*, được gộp vào một loại, vì trên giao diện chúng đều là chạm vào phần tử được nêu. Trên các bước có thao tác chạm, điều kiện này loại những câu viết nhầm thành cuộn, gõ chữ hay quay lại.

Phần thứ hai là **không đảo nghĩa**: câu sinh và câu chuẩn không được gọi tên hai trạng thái ngược nhau của cùng một điều khiển, chẳng hạn "bật thông báo" và "tắt thông báo". Điều kiện (ii) không bắt được lỗi này vì hai trạng thái nằm ở cùng một

[1]Mười hai động từ được xếp vào loại chạm: *tap, click, press, select, choose, touch, open, launch, go, navigate, visit, view*. Câu không chứa động từ nào trong danh sách được xếp vào loại chạm. Động từ được dò từ trái sang phải, nên các cụm như *go back* hay *press the back button* cũng được xếp vào loại chạm. Nếu sửa quy tắc này, S1 giảm từ 59,12 xuống 58,81, Base từ 47,60 xuống 47,40, và chênh lệch S1 − Base đổi từ 11,52 thành 11,41 điểm. Mọi bảng giữ quy tắc ban đầu để các lượt đánh giá nhất quán với nhau.

chỗ trên màn hình. Danh sách cặp trái nghĩa được lập thủ công.[2]

5.4 Độ đo văn bản

Bên cạnh executability, Chương 6 báo bảy độ đo dựa trên câu chuẩn. Mỗi độ đo đo một kiểu giống nhau giữa câu sinh và câu chuẩn:

- **BLEU-4** [20]: tỉ lệ cụm từ một đến bốn từ của câu sinh xuất hiện trong câu chuẩn, có phạt câu ngắn hơn câu chuẩn.
- **METEOR** [22]: so khớp từng từ giữa hai câu, tính cả từ cùng gốc và từ đồng nghĩa, có phạt khi các từ trùng nằm rời rạc thay vì thành cụm liên tiếp.
- **ROUGE-L** [21]: điểm F1 dựa trên chuỗi con chung dài nhất của hai câu.
- **CIDEr-D** [23]: độ tương đồng cosine giữa hai vectơ cụm từ có trọng số TF-IDF, nên cụm hiếm và mang thông tin được coi trọng hơn cụm phổ biến; bản D có thêm phạt chênh lệch độ dài.
- **SPICE** [24]: phân tích câu thành các đối tượng, thuộc tính và quan hệ rồi tính F1 trên các thành phần này (Mục 2.3).
- **chrF** [25]: điểm F trên các cụm ký tự, nên ghi nhận cả những từ chỉ khác nhau ở dạng viết.
- **BERTScore** [26]: so khớp từng token của hai câu theo độ tương đồng biểu diễn ngữ cảnh của RoBERTa-large, rồi chuẩn hoá thang điểm theo mức nền.

Năm độ đo đầu được tính bằng bộ chấm chính thức của COCO. Cả bảy độ đo tính ở mức toàn tập, tức gộp thống kê của mọi câu rồi mới tính điểm, và câu không có nội dung nhận điểm 0. Công thức CIDEr-D có hệ số 10, nên điểm báo theo thang phần trăm có thể vượt 100.

Các độ đo này thưởng mức giống câu chuẩn về từ ngữ hoặc nội dung, còn executability thưởng việc câu dẫn tới đúng phần tử. Hai cách đánh giá không trùng nhau:

[2]Chín cặp: *on/off, enable/disable, show/hide, mute/unmute, expand/collapse, check/uncheck, select/deselect, start/stop, enabled/disabled*.

trong những câu mà executability chấp nhận, 52,8% câu của Base có F1 trên các từ nội dung so với câu chuẩn dưới 0,5, so với 13,9% ở S1, tức nhiều câu của Base dẫn tới đúng phần tử dù diễn đạt khác hẳn câu chuẩn. Độ tương đồng nhúng câu cũng không thay được executability, vì các cặp câu khác phần tử nhưng chồng từ ngữ có thể gần nhau hơn các cặp cùng phần tử khác cách gọi (Phụ lục B.2). Zhao và cộng sự [37] khuyến nghị SPICE khi cần xếp hạng hệ thống bằng câu chuẩn; SPICE vì vậy được dùng làm phần thưởng ở Mục 4.3, còn executability là độ đo chính cho việc xác định đúng phần tử và thao tác.

5.5 Kiểm chứng độ tin cậy của executability

Executability dựa vào một mô hình máy, nên điểm số chỉ đáng tin khi phản ánh nội dung của câu chứ không phản ánh đặc điểm riêng của mô hình B. Mục này trình bày bốn phép kiểm: mốc trên và mốc dưới của điểm số, độ bền khi diễn đạt lại, độ chính xác và tính tất định của B, việc thay B bằng ba mô hình khác; phần cuối nêu các giới hạn còn lại. Các phép kiểm dùng ba loại câu: câu chuẩn, câu của S1 và câu của Base. Mọi kết quả ở Chương 6 tính trên đủ 4.463 bước; một số phép kiểm ở đây dùng mẫu con và nêu cỡ mẫu tại chỗ, nên điểm của câu chuẩn hơi khác nhau giữa các mẫu.

5.5.1 Mốc trên và mốc dưới

Mốc trên. Khi đưa câu chuẩn của chính bước đang xét qua cùng quy trình, executability trên 4.463 bước là **75,7%** [74,1; 77,3]. Đây là mức mà quy trình đánh giá đạt được với câu do người chú thích viết, không phải trần lý thuyết. Trong 1.083 bước câu chuẩn không đạt, 72% là do điểm của B lệch quá 14% bề ngang, nên phần lớn giới hạn nằm ở mô hình định vị. Theo cách làm của Zhao và cộng sự [37], điểm của các mô hình được đặt cạnh mốc này thay vì quy đổi thành tỉ lệ phần trăm của mốc.

Mốc dưới. Trên mẫu 800 bước, câu chuẩn được thay bằng các câu thiếu thông tin quy chiếu (Bảng 5.4). Câu chung chung "*Tap the button.*" chỉ đạt **12,0%**. Câu chuẩn của một màn hình khác, đúng văn phong nhưng sai nội dung, còn thấp hơn, 6,1%. Độ đo vì vậy phản ứng với nội dung của câu chứ không với văn phong.

Tên phần tử và mệnh đề vị trí. Để biết thành phần nào của câu mang thông tin quy chiếu, chúng tôi bỏ riêng tên phần tử hoặc riêng mệnh đề vị trí khỏi câu chuẩn ở những bước có thành phần đó. Bỏ tên làm executability giảm **28,5 điểm** ($b = 58$, $c = 3$, $p < 0{,}001$), gấp khoảng tám lần mức giảm 3,5 điểm khi bỏ mệnh đề vị trí ($b = 8$, $c = 1$, $p = 0{,}039$). Độ đo vì vậy phản ứng chủ yếu với tên phần tử.

Bảng 5.4: Mốc tham chiếu trên mẫu 800 bước; hai hàng cuối chỉ tính trên các bước có thành phần bị bỏ.

Câu đưa cho mô hình B	Số bước	Executability (%)
Câu chuẩn	800	74,9
S1	800	58,8
Base	800	48,6
Câu chung chung "*Tap the button.*"	800	12,0 [9,7; 14,4]
Câu chuẩn của một màn hình khác	800	6,1 [4,5; 7,9]
Câu chuẩn bỏ tên phần tử, giữ vị trí	193	89,6 → 61,1
Câu chuẩn bỏ mệnh đề vị trí, giữ tên	198	89,4 → 85,9

5.5.2 Độ bền khi diễn đạt lại

Jandial và cộng sự [18] cho thấy mô hình định vị có thể nhạy với cách diễn đạt của câu. Chúng tôi viết lại câu chuẩn trên mẫu 800 bước theo ba cách giữ nguyên nghĩa, bằng quy tắc xác định và không dùng mô hình ngôn ngữ: đổi động từ thao tác (ví dụ *click* thành *tap*), đảo trật tự hai mệnh đề, và kết hợp cả hai. Trong 1.139 câu được viết lại, chỉ 30 câu (2,6%) đổi kết quả đánh giá, với hiệu ròng **+0,35 điểm** [−0,59; +1,29] (chi tiết ở Phụ lục B.5). Các cách viết lại này giữ nguyên phần mô tả phần tử; việc đổi cách gọi tên phần tử, dạng biến đổi mà Jandial và cộng sự khảo sát, nằm ngoài phạm vi phép kiểm.

5.5.3 Độ chính xác và tính tất định của mô hình định vị

Độ chính xác. Để biết sai số bao nhiêu thì đủ nhỏ, chúng tôi đo biên dung sai, là nửa khoảng cách từ g tới tâm phần tử khác gần nhất. Trên 1.496 bước có thao tác chạm,

biên này có trung vị 67 điểm ảnh (6,2% bề ngang) và phân vị 10 là 39 điểm ảnh (3,6%), nên sai số cỡ 3% bề ngang hầu như không làm đổi kết quả. Trên 300 bước dùng câu chuẩn, sai số của UGround có trung vị 0,7% bề ngang và 62,7% số bước có sai số dưới 3%. Sai số có dạng lưỡng cực: phần lớn dự đoán rất gần đích, nhưng 10% số bước lệch quá 36% bề ngang. Trên cùng mẫu, executability chấp nhận mọi bước có sai số dưới 3% ($n = 188$) và không chấp nhận bước nào có sai số trên 14% ($n = 63$).

Tính tất định. Cùng câu và cùng ảnh luôn cho cùng tọa độ. Qua bốn lượt đánh giá độc lập với thứ tự và cách gom lô khác nhau, 1.625 cặp câu và ảnh được đánh giá lặp lại không có bất đồng nào, nên điểm số không phụ thuộc cách chạy.

5.5.4 Thay mô hình B

Nếu điểm số phụ thuộc vào đặc điểm riêng của UGround, việc thay B bằng một mô hình khác sẽ làm đổi thứ hạng giữa các loại câu. Chúng tôi lặp lại đánh giá với ba mô hình B khác, chọn sao cho khác UGround ở họ mô hình, ở dữ liệu huấn luyện hoặc ở cách trả lời (Bảng 5.5):

- **UI-Venus-Ground-7B** [6] không dùng AndroidControl khi huấn luyện nhưng vẫn dựng trên Qwen2.5-VL. Trên 300 bước dùng câu chuẩn, sai số trung vị của mô hình này là 1,56% bề ngang.
- **Phi-Ground-4B** [7] dựng trên Phi-3.5-Vision, ngoài họ Qwen, và theo báo cáo kỹ thuật không dùng AndroidControl khi huấn luyện.
- **Phi-4-multimodal-instruct** [42] là một mô hình ngôn ngữ thị giác đa dụng, ngoài họ Qwen và không được tinh chỉnh trên AndroidControl. Phi-4 không trả về tọa độ mà chọn phần tử: các phần tử bấm được lấy từ cây trợ năng được khoanh vùng và đánh số trên ảnh theo Set-of-Mark [43], với trung vị 15 phần tử mỗi màn hình. Phi-4 chỉ nhận câu và ảnh đã đánh số, rồi trả lời số của phần tử mà câu nhắc tới. Lựa chọn đúng khi phần tử được chọn chứa điểm chạm g; danh sách đánh số chứa phần tử này ở 95,7% số bước. Cách đánh giá này gần với độ chính xác hiểu câu trong các nghiên cứu sinh biểu thức quy chiếu [12, 13] và với bài toán chọn phần tử giao diện của Mind2Web [9].

Bảng 5.5: Điểm của ba loại câu dưới bốn mô hình B.

Mô hình B	Họ mô hình	Học AC	Trả lời	Số bước	Base	S1	Câu chuẩn
UGround-V1-2B	Qwen2-VL	có	tọa độ	4.463	47,6	59,1	75,7
UI-Venus-Ground-7B	Qwen2.5-VL	không	tọa độ	2.532	39,1	48,7	-
Phi-Ground-4B	Phi-3.5-Vision	không	tọa độ	4.463	40,8	47,0	-
Phi-4-multimodal	Phi-4	không	chọn số	4.463	38,2	44,6	54,9

Học AC: có dùng AndroidControl khi huấn luyện. S1 là S1/101. Với UI-Venus, mẫu 2.532 bước là các bước mà S1/101 và S2 (Phụ lục A.1) viết câu khác nhau; trên cùng mẫu, UGround cho Base 42,5 và S1 52,8. Ô "-" là chưa đánh giá trên cùng mẫu. Với Phi-Ground, Base thiếu dự đoán ở 7 bước, các bước này tính là không đạt.

Dưới cả bốn mô hình B, S1 cao hơn Base có ý nghĩa thống kê: **+11,52** điểm dưới UGround, +9,68 [+7,60; +11,78] dưới UI-Venus (so với +10,35 của UGround trên cùng mẫu), +6,16 [+4,71; +7,64] dưới Phi-Ground và +6,41 điểm ($p < 0{,}001$) dưới Phi-4. Ở những mô hình B đã đánh giá câu chuẩn, câu chuẩn luôn cao nhất. Dưới Phi-4, câu chuẩn cao hơn Base 16,72 điểm, còn câu chung chung "*Tap the button.*" chỉ đạt 15,86%, gần mức chọn ngẫu nhiên 10,06%. UI-Venus cũng cho câu chuẩn 69,3% trên mẫu 300 bước nói trên, gần mức 70,0% của UGround trên cùng mẫu.

Thang điểm của các mô hình B khác nhau: dưới hai mô hình ngoài họ Qwen, khoảng cách S1 − Base chỉ bằng khoảng một nửa so với UGround, và câu chuẩn dưới Phi-4 chỉ đạt 54,9%. Vì vậy các mô hình B thay thế được dùng để kiểm tra thứ hạng, không dùng làm số chính. Mức đồng thuận theo từng bước giữa Phi-4 và UGround chỉ ở mức vừa phải (κ từ 0,25 đến 0,44 tùy mô hình sinh), tức hai mô hình sai ở những bước khác nhau nhưng xếp hạng các loại câu như nhau. Cả ba mô hình B thay thế đều cho kết quả trùng hoàn toàn khi đánh giá lặp lại (40 bước với UI-Venus, 40 bước với Phi-Ground, 200 bước với Phi-4). Chênh lệch âm S2 − S1 của một hướng đã thử (Phụ lục A.1) cũng giữ dấu dưới UI-Venus, với cận trên KTC dưới 0. Kết quả so sánh phương pháp đề xuất với S1 dưới cả bốn mô hình B được trình bày ở Mục 6.5.

5.5.5 Giới hạn của mô hình định vị

UGround dựng trên Qwen2-VL, cùng họ với các mô hình sinh của đề tài, và có dùng 47 nghìn nhãn phần tử của AndroidControl khi huấn luyện [5]. Khoảng 90% tác vụ của tập kiểm tra thuộc phần huấn luyện chính thức của AndroidControl (Mục 3.2), nên UGround có thể đã thấy một phần màn hình kiểm tra và quen văn phong chú thích của bộ dữ liệu. Hai kết quả cho thấy rủi ro này không làm đổi kết luận. Khi tách 4.463 bước theo phần chia chính thức, điểm gần như không đổi giữa phần huấn luyện và phần kiểm tra cùng kiểm định chính thức: câu chuẩn đạt 75,9% và 74,0%, S1 đạt 59,1% và 59,3%, Base đạt 47,7% và 46,7%, và KTC của hai phần chồng nhau ở cả ba loại câu. Thứ hạng cũng giữ nguyên khi B là UI-Venus (không học AndroidControl) và khi B là Phi-Ground hoặc Phi-4 (ngoài họ Qwen). Ngoài ra, đề tài không có đánh giá của người thật, và mức 75,7% của câu chuẩn cho thấy ngay với câu do người chú thích viết, B vẫn chọn sai khoảng một phần tư số bước. Điểm tuyệt đối của mọi mô hình vì vậy bị giới hạn bởi B, và các phép so trong đề tài dựa trên chênh lệch giữa các mô hình dưới cùng một B.

5.6 Phương pháp phân tích thống kê

Khoảng tin cậy. Mỗi điểm hoặc chênh lệch đi kèm khoảng tin cậy 95% (KTC), ước lượng bằng bootstrap theo cụm với 10.000 lần lấy mẫu lại. Các bước của cùng một ứng dụng thường cùng dễ hoặc cùng khó, nên lấy mẫu lại từng bước riêng lẻ sẽ làm KTC hẹp hơn thực tế. Vì vậy ở mỗi lần lặp, cả cụm được lấy lại có hoàn lại, điểm số được tính lại, và KTC lấy từ phân vị 2,5% và 97,5% của các giá trị thu được. Cụm là ứng dụng; với các bước không xác định được ứng dụng (Mục 3.4), mỗi tác vụ là một cụm riêng. Tập kiểm tra có 1.091 cụm, cụm lớn nhất gồm 58 bước, và số cụm hiệu dụng theo công thức Kish [28] là 454,3, đủ lớn để bootstrap theo cụm cho kết quả đáng tin cậy [27]. Khi đổi cách gom, theo tác vụ hoặc dồn mọi bước không có nhãn ứng dụng vào một cụm, KTC của chênh lệch S1 − Base thay đổi không quá 0,7 điểm.

So sánh ghép cặp. Mọi mô hình được đánh giá trên cùng 4.463 bước, nên chênh lệch giữa hai mô hình được tính theo cặp: KTC lấy từ bootstrap theo cụm trên hiệu của

từng bước, và mức khó dễ chung của mỗi bước triệt tiêu trong hiệu. Chẳng hạn, sai số chuẩn của chênh lệch S1 − Base là 0,79 điểm khi tính ghép cặp, so với 1,05 điểm nếu coi hai điểm là độc lập. Giá trị p lấy từ kiểm định McNemar dạng chính xác. Kiểm định chỉ xét các bước mà hai mô hình cho kết quả khác nhau, với b là số bước mô hình thứ nhất đạt còn mô hình thứ hai không đạt và c là chiều ngược lại. Nếu hai mô hình ngang nhau, mỗi bước bất đồng nghiêng về bên nào cũng với xác suất 0,5, nên p là xác suất nhị thức để b và c chênh nhau ít nhất bằng mức quan sát được.

Mức chênh lệch nhỏ nhất phát hiện được. KTC ghép cặp chỉ phản ánh dao động của phép đo trên hai mô hình cố định. Mỗi cấu hình trong đề tài được huấn luyện một lượt, nên chênh lệch giữa hai cấu hình còn chịu dao động khi huấn luyện lại với seed khác. Gộp hai nguồn này, mức chênh lệch nhỏ nhất phát hiện được (*minimum detectable effect*, MDE) là mức chênh mà thiết kế một lượt huấn luyện cho mỗi cấu hình phát hiện được với xác suất 80% ở mức ý nghĩa 5%:

$$\mathrm{MDE} = (z_{0,975} + z_{0,80})\sqrt{\mathrm{SE}^2 + 2\sigma^2} \approx 2{,}8 \times \sqrt{0{,}38^2 + 2 \times 0{,}46^2} \approx 2{,}11 \text{ điểm}, \quad (5.3)$$

trong đó $\mathrm{SE} \approx 0{,}38$ điểm là sai số chuẩn ghép cặp theo bootstrap cụm giữa hai lượt S1, còn $\sigma \approx 0{,}46$ điểm là độ lệch chuẩn giữa các lượt huấn luyện, ước từ chênh lệch 0,52 điểm giữa S1/101 và S1/202 theo $\sigma \approx |\Delta|/1{,}128$. Hệ số 2 trước σ^2 đến từ việc cả hai cấu hình được so đều chỉ có một lượt huấn luyện. Vì σ chỉ được ước từ một cặp lượt, MDE là ước lượng thô. Một chênh lệch có KTC không chứa 0 nhưng nhỏ hơn **2,11 điểm** cho thấy phép đo phân biệt được hai mô hình cụ thể, nhưng chưa đủ để loại trừ khả năng một chênh lệch cỡ đó xuất hiện chỉ do huấn luyện lại. Chương 6 diễn giải các chênh lệch như vậy một cách thận trọng và báo kèm biến thiên giữa các lượt huấn luyện (Mục 6.11).

Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả chính của phương pháp đề xuất, sau đó lần lượt xét vai trò của phần thưởng SPICE, so sánh với một mô hình lớn hơn chỉ dùng prompting, độ vững khi thay mô hình đánh giá, khả năng khái quát sang tác vụ mới và sang bộ dữ liệu khác, độ đo văn bản, và thiết lập lịch sử do mô hình tự sinh. Các mục cuối trình bày thành phần ACE, các hướng đã thử và các hạn chế của kết quả.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên 4.463 bước có thao tác chạm của tập kiểm tra (Mục 3.2) bằng quy trình ở Chương 5, với UGround làm mô hình định vị; câu không có nội dung vẫn nằm trong mẫu số và tính là không đạt. Các mốc so sánh gồm Base, Qwen2.5-VL-7B chỉ dùng prompting, S1 với hai seed 101 và 202, và câu chuẩn (Mục 4.5). Các nhánh dùng để xét vai trò của phần thưởng được mô tả ở Mục 6.3.

Mọi phép so được tính theo cặp trên cùng tập bước: chênh lệch Δ, KTC 95% bằng bootstrap theo cụm ứng dụng, và giá trị p của kiểm định McNemar dạng chính xác (Mục 5.6). Mức chênh lệch nhỏ nhất phát hiện được khi tính cả dao động do huấn luyện lại là MDE $\approx$ 2,11 điểm (công thức (5.3)).

6.2 Kết quả chính

Phương pháp đề xuất đạt executability cao nhất trong các cấu hình được so sánh. GRPO-SPICE đạt **60,65%**, cao hơn mô hình xuất phát S1/101 **1,55 điểm** [+0,80;

+2,33] ($p = 1{,}5 \times 10^{-5}$); khi thêm ACE, phương pháp đạt **60,68‰** (Bảng 6.1).

Bảng 6.1: Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra.

Mô hình	Exec.	Hộp	Hộp ∧ 14%	AitW	Δ Exec. so với S1/101
Base	47,59	53,60	49,76	63,39	−11,52 [−13,07; −10,02]
Qwen2.5-VL-7B (prompting)	51,51	57,67	53,71	66,79	−7,60 [−9,28; −5,95]
S1/101	59,11	65,49	61,73	74,37	-
S1/202	59,62	66,10	62,36	75,31	+0,52 [−0,22; +1,26]
GRPO-SPICE	60,65	67,02	63,25	76,25	+1,55 [+0,80; +2,33]
GRPO-SPICE + ACE	**60,68**	**67,11**	**63,28**	**76,32**	**+1,57** [+0,86; +2,31]
Câu chuẩn	75,73	83,82	79,23	92,14	+16,62

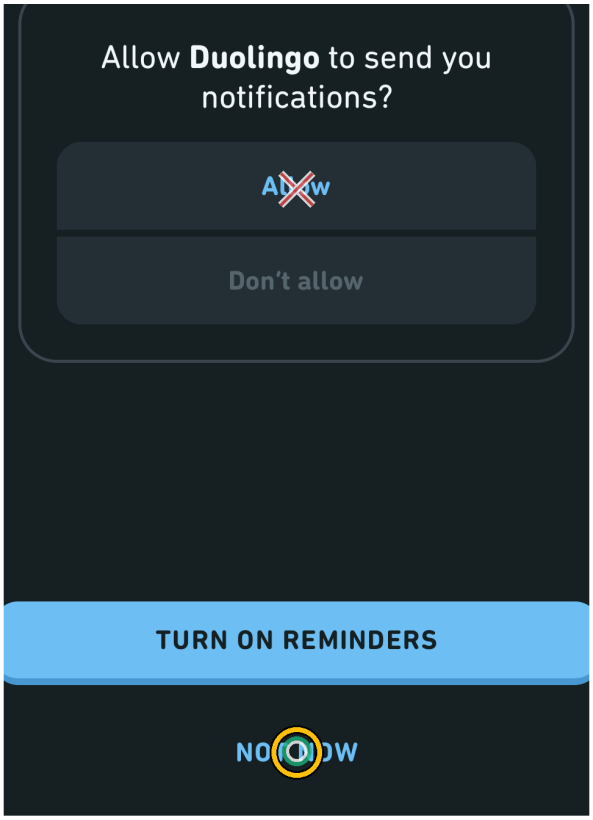
Hộp: tiêu chí hộp phần tử; Hộp ∧ 14%: hộp phần tử kết hợp cửa sổ 14%; AitW: AitW đầy đủ (Mục 5.2.1). Từ đây, GRPO-SPICE + ACE được gọi tắt là ACE.

GRPO-SPICE cũng cao hơn S1/202 1,03 điểm [+0,25; +1,83] ($p = 0{,}014$), và mức tăng so với S1/101 giữ cùng chiều dưới cả ba tiêu chí báo kèm: +1,52 điểm theo tiêu chí hộp phần tử, +1,52 theo hộp kết hợp cửa sổ 14% và +1,88 theo AitW đầy đủ, với KTC đều nằm trên 0. Bước tinh chỉnh có giám sát đưa executability từ 47,59% của Base lên 59,11%; GRPO-SPICE thu hẹp thêm khoảng cách tới câu chuẩn (75,73%) từ 16,62 xuống 15,08 điểm.

Nguồn của mức tăng. GRPO-SPICE đổi câu ở 1.668 bước (37,4%). Trong mức tăng ròng 69 bước (159 bước chỉ GRPO-SPICE đạt so với 90 bước chỉ S1/101 đạt), khoảng 41 bước đến từ câu dẫn tới đúng phần tử, như ở bước trong Hình 6.1: S1/101 gọi nút *Allow* còn GRPO-SPICE gọi đúng nút *Not Now*; khoảng 28 bước còn lại đến từ câu nêu đúng loại thao tác mà S1/101 nêu sai. Số bước không đạt vì sai loại thao tác giảm từ 251 xuống 179.

6.3 Vai trò của phần thưởng SPICE

Mức tăng gắn với tín hiệu SPICE: khi điểm SPICE được ghép ngẫu nhiên giữa các mẫu, executability trở về đúng mức S1/101, và khi thay SPICE bằng CIDEr-D, executability thấp hơn GRPO-SPICE. Bảng 6.2 so bốn cấu hình cùng xuất phát từ S1/101 và chỉ



Vòng vàng: điểm người dùng đã chạm
Câu tham chiếu: "Click on the Not now button to remove this pop up notification"
S1/101: "Click on the Allow button" → không đạt
GRPO-SPICE: "Click on the Not Now button at the bottom of the screen" → đạt

Hình 6.1: Một bước được GRPO-SPICE sửa đúng.

khác nhau ở phần thưởng hoặc số bước GRPO.

Tín hiệu SPICE. Nhánh kiểm soát chạy cùng 500 bước GRPO với GRPO-SPICE nhưng điểm SPICE được ghép ngẫu nhiên giữa các mẫu trong cùng nhóm (Mục 4.3). Nhánh này đạt đúng 59,11%, bằng S1/101, và không khác S1/101 ở độ đo văn bản nào (mọi KTC chứa 0). GRPO-SPICE cao hơn nhánh kiểm soát **1,55 điểm** [+0,81; +2,30] ($p = 2{,}0 \times 10^{-5}$), và cao hơn có ý nghĩa ở cả sáu độ đo văn bản có KTC, chẳng hạn CIDEr-D +11,92 [+5,76; +17,89]. Với cùng quá trình cập nhật, mức tăng chỉ xuất hiện khi phần thưởng giữ đúng quan hệ với câu.

So với phần thưởng CIDEr-D. Thay SPICE bằng CIDEr-D, giữ điểm xuất phát

Bảng 6.2: Executability và độ đo văn bản theo phần thưởng GRPO.

Phần thưởng GRPO	Exec.	Δ so với GRPO-SPICE	CIDEr-D	SPICE	chrF
Không GRPO (S1/101)	59,11	−1,55 [−2,33; −0,80]	416,12	44,37	61,26
SPICE ghép ngẫu nhiên	59,11	−1,55 [−2,30; −0,81]	418,13	44,40	61,52
CIDEr-D, 500 bước	59,96	−0,69 [−1,34; −0,02]	428,27	45,27	61,76
CIDEr-D, 1.000 bước	59,98	−0,67 [−1,33; +0,00]	427,98	44,45	61,92
SPICE (GRPO-SPICE)	**60,65**	-	**430,05**	**45,79**	**62,87**

Mọi nhánh GRPO xuất phát từ S1/101 và chạy 500 bước, trừ hàng ghi 1.000 bước. Nhánh thưởng CIDEr-D dùng 2.000 prompt huấn luyện, gồm cả 1.000 prompt của GRPO-SPICE.

và số bước, cho executability thấp hơn GRPO-SPICE 0,69 điểm [−1,34; −0,02] (p = 0,040). Nhánh này nêu đúng loại thao tác nhiều hơn nhưng dẫn tới sai phần tử nhiều hơn, và tăng lên 1.000 bước không cải thiện thêm. Điểm CIDEr-D của nhánh thưởng CIDEr-D trên tập kiểm tra cũng thấp hơn của GRPO-SPICE (428,27 so với 430,05). Trong các phần thưởng đã thử, SPICE cho executability cao nhất, đồng thời cao nhất ở CIDEr-D, SPICE và chrF.

6.4 So với mô hình lớn hơn chỉ dùng prompting

Mô hình 3B sau GRPO-SPICE cao hơn Qwen2.5-VL-7B chỉ dùng prompting **9,14 điểm** executability [+7,55; +10,75] ($p = 1{,}9 \times 10^{-37}$); ACE cao hơn 9,16 điểm (Bảng 6.1). Khoảng cách ở độ đo văn bản còn lớn hơn: 7B chỉ đạt CIDEr-D 100,71 và SPICE 18,74, gần mức của Base, so với 430,05 và 45,79 của GRPO-SPICE (Bảng 6.6). Mô hình 7B vẫn cao hơn Base 3,92 điểm executability, nên tăng kích thước mô hình nền có giúp, nhưng ít hơn nhiều so với tinh chỉnh trên dữ liệu của bài toán. Phép so chỉ phản ánh cấu hình prompting đã thử, dùng cùng prompt với Base.

6.5 Độ vững khi thay mô hình đánh giá

GRPO-SPICE cao hơn S1/101 dưới cả bốn mô hình đánh giá, trong đó có hai mô hình ngoài họ Qwen (Bảng 6.3). Ngoài UGround, các nhánh chính được đánh giá

bằng UI-Venus-Ground-7B (không học AndroidControl, cùng họ Qwen), Phi-Ground-4B (ngoài họ Qwen) và Phi-4 dạng chọn ô đánh số (ngoài họ Qwen), như mô tả ở Mục 5.5.4.

Bảng 6.3: Kết quả của các nhánh chính dưới bốn mô hình đánh giá.

	UGround	**UI-Venus**	**Phi-Ground**	**Phi-4**
Họ mô hình nền	Qwen2-VL	Qwen2.5-VL	Phi-3.5-Vision	Phi-4
Base	47,59	-	40,80	38,23
S1/101	59,11	54,51	46,96	44,63
S1/202	59,62	55,12	-	**45,53**
GRPO-SPICE	60,65	56,06	**47,75**	45,33
ACE	**60,68**	**56,20**	47,73	45,33
GRPO-SPICE − S1/101	+1,55	+1,55	+0,78	+0,69
	[+0,80; +2,33]	[+0,82; +2,30]	[+0,05; +1,51]	[+0,02; +1,40]
Câu chuẩn	75,73	-	-	54,94

Ô "-" là chưa đánh giá trên đủ 4.463 bước. Với Phi-4, điểm là tỉ lệ chọn đúng phần tử. Với Phi-Ground, Base thiếu dự đoán ở 7 bước, các bước này tính là không đạt; với Phi-4, S1/202 chỉ được đánh giá lại ở 1.652 bước có câu khác S1/101.

Dưới UI-Venus, mức tăng bằng đúng mức dưới UGround (+1,55 điểm, $p = 8{,}7 \times 10^{-6}$). Dưới hai mô hình ngoài họ Qwen, mức tăng tuyệt đối nhỏ hơn (+0,78 và +0,69 điểm), nhưng thang điểm của hai mô hình này cũng hẹp hơn: khoảng cách S1/101 − Base chỉ 6,16 và 6,41 điểm, so với 11,52 điểm dưới UGround. Tính theo khoảng cách đó, mức tăng của GRPO-SPICE bằng khoảng 13% dưới UGround, 13% dưới Phi-Ground và 11% dưới Phi-4. ACE ngang GRPO-SPICE dưới cả bốn mô hình. Riêng dưới Phi-4, S1/202 nhỉnh hơn GRPO-SPICE 0,20 điểm, với KTC chứa 0.

6.6 Khả năng khái quát

6.6.1 Tác vụ chưa xuất hiện trong huấn luyện S1

Trên các tác vụ mà S1 chưa thấy khi huấn luyện, mức tăng của GRPO-SPICE gần gấp ba so với tập kiểm tra chính và vượt MDE. ACU gồm 1.484 bước có thao tác chạm

thuộc các tác vụ không có trong tập huấn luyện S1 (Mục 3.2); Bảng 6.4 báo kết quả trên ACU và trên tập gộp ACU với tập kiểm tra chính.

Bảng 6.4: Executability trên ACU và trên tập gộp với tập kiểm tra chính.

	ACU, 1.484 bước		**Gộp, 5.947 bước**	
Mô hình	**Exec.**	**Δ so với S1/101**	**Exec.**	**Δ so với S1/101**
Base	49,80	-	48,14	-
S1/101	52,16	-	57,37	-
GRPO-SPICE, lượt 2	56,20	+4,04 [+2,66; +5,48]	59,00	+1,63 [+0,93; +2,37]
GRPO-SPICE	56,74	+4,58 [+3,17; +6,05]	59,68	+2,30 [+1,62; +2,99]
ACE	**57,01**	**+4,85** [+3,43; +6,32]	**59,76**	**+2,39** [+1,73; +3,05]
Câu chuẩn	71,70	+19,54	74,73	-

Trên ACU, GRPO-SPICE cao hơn S1/101 **4,58 điểm** [+3,17; +6,05] ($p = 2{,}1 \times 10^{-10}$). Cận dưới KTC của GRPO-SPICE, lượt GRPO thứ hai và ACE đều cao hơn MDE 2,11 điểm. Ở các tác vụ này, S1/101 chỉ cao hơn Base 2,36 điểm (KTC chạm 0), còn GRPO-SPICE cao hơn Base 6,94 điểm [+4,49; +9,34]. Từ tập kiểm tra chính sang ACU, S1/101 giảm 6,95 điểm còn GRPO-SPICE chỉ giảm 3,91 điểm. Gộp hai tập thành 5.947 bước, GRPO-SPICE cao hơn S1/101 **2,30 điểm** [+1,62; +2,99] ($p = 6{,}8 \times 10^{-13}$), cũng vượt MDE.

6.6.2 Chuyển sang bộ dữ liệu AitZ

Trên AitZ, phương pháp đề xuất cạnh tranh với S1: GRPO-SPICE ngang S1/101 về executability và cao hơn ở BLEU-4, SPICE và chrF. AitZ có phân phối câu chuẩn khác AndroidControl, và các mô hình được dùng nguyên, không huấn luyện thêm (Bảng 6.5).

S1/101 cao hơn Base 3,29 điểm ($p = 4{,}5 \times 10^{-4}$) và GRPO-SPICE cao hơn Base 2,78 điểm ($p = 0{,}0028$), nên tinh chỉnh vẫn chuyển được sang miền này. Chênh lệch giữa GRPO-SPICE và S1/101 có KTC chứa 0 ($p = 0{,}33$). Ở độ đo văn bản (Bảng 6.7), GRPO-SPICE cao hơn S1/101 với KTC nằm trên 0 ở SPICE (+1,10 [+0,53; +1,66]), chrF (+0,62 [+0,22; +1,03]) và BLEU-4 (+0,47 [+0,01; +0,95]). ACE chỉ đổi 52 câu

Bảng 6.5: Executability trên 2.736 bước có thao tác chạm của AitZ.

Mô hình	Exec.	Δ so với S1/101
Base	34,50	−3,29 [−5,03; −1,51]
S1/101	**37,79**	-
GRPO-SPICE	37,28	−0,51 [−1,39; +0,36]
ACE	37,28	−0,51 [−1,39; +0,36]
Câu chuẩn	66,26	+28,47

so với GRPO-SPICE, vì kho câu ví dụ lấy từ AndroidControl ít khi có câu phù hợp với AitZ.

6.7 Độ đo văn bản

ACE đạt điểm cao nhất ở cả bảy độ đo văn bản trên tập kiểm tra chính và trên ACU, và GRPO-SPICE cao hơn S1/101 ở cả bảy độ đo (Bảng 6.6 và Bảng 6.7).

Bảng 6.6: Độ đo văn bản trên 4.463 bước có thao tác chạm của tập kiểm tra.

Mô hình	BLEU-4	METEOR	ROUGE-L	CIDEr-D	SPICE	chrF	BERTScore
Base	15,34	24,58	42,31	88,01	18,48	40,18	40,10
7B, chỉ prompting	14,48	21,90	39,79	100,71	18,74	36,22	39,70
S1/101	51,56	36,79	67,35	416,12	44,37	61,26	66,33
S1/202	51,66	37,17	67,71	419,19	44,23	61,92	66,75
GRPO-SPICE	52,36	37,92	68,36	430,05	45,79	62,87	67,07
ACE	**53,47**	**38,37**	**69,11**	**442,02**	**47,13**	**63,45**	**67,73**
GRPO-SPICE − S1/101	+0,80	+1,13	+1,01	+13,93	+1,42	+1,61	+0,74
GRPO-SPICE − S1/202	+0,70[0]	+0,75	+0,66	+10,86	+1,56	+0,96	+0,32[0]
ACE − GRPO-SPICE	+1,11	+0,45	+0,74	+11,97	+1,33	+0,58	+0,66

Câu chuẩn đạt 100 ở mọi độ đo trừ CIDEr-D (988,7) và SPICE (98,6). [0]: KTC 95% (bootstrap theo cụm ứng dụng, 2.000 lần lấy mẫu) chứa 0; METEOR chỉ có giá trị mức toàn tập nên không có KTC.

Trên tập kiểm tra chính, GRPO-SPICE cao hơn S1/101 với KTC nằm trên 0 ở cả sáu độ đo có KTC, rõ nhất ở CIDEr-D +13,93 [+8,05; +19,91] và SPICE +1,42 [+0,71;

+2,16]. So với S1/202, bốn trong sáu độ đo vẫn tăng có ý nghĩa (ROUGE-L, CIDEr-D, SPICE và chrF). ACE cao hơn GRPO-SPICE có ý nghĩa ở cả sáu độ đo có KTC. Trên ACU, GRPO-SPICE cao hơn S1/101 có ý nghĩa ở cả sáu độ đo có KTC, với CIDEr-D +26,73 [+15,84; +37,96] và SPICE +2,51 [+1,18; +3,87], và ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu. Trên AitZ, GRPO-SPICE cao nhất ở năm trong bảy độ đo, ACE cao nhất ở SPICE, còn BERTScore của S1/101 và GRPO-SPICE gần như bằng nhau.

Bảng 6.7: Độ đo văn bản trên ACU và AitZ.

Mô hình	BLEU-4	METEOR	ROUGE-L	CIDEr-D	SPICE	chrF	BERTScore
ACU, 1.484 bước							
Base	15,01	25,14	42,04	93,25	19,28	39,61	40,10
S1/101	47,53	34,47	63,45	385,99	39,74	57,20	62,76
GRPO-SPICE	49,85	36,64	66,38	412,72	42,25	60,06	64,64
ACE	**50,88**	**37,03**	**67,11**	**425,71**	**43,21**	**60,59**	**65,32**
AitZ, 2.736 bước							
Base	18,68	18,56	39,11	86,98	15,66	35,24	38,81
S1/101	21,01	20,83	46,84	120,24	15,27	35,66	**49,69**
GRPO-SPICE	**21,48**	**21,08**	**46,92**	**123,38**	16,37	**36,28**	49,68
ACE	21,45	21,05	46,91	123,29	**16,40**	36,24	49,63

6.8 Lịch sử thao tác do mô hình tự sinh

Khi lịch sử các bước trước do chính mô hình sinh, GRPO-SPICE vẫn cao hơn S1/101 **1,48 điểm** executability [+0,54; +2,43] ($p = 7{,}5 \times 10^{-4}$), gần bằng mức 1,55 điểm với lịch sử chuẩn. Trong thiết lập chính, lịch sử là câu chuẩn của các bước trước (Mục 4.2); ở thí nghiệm này, mỗi tác vụ được sinh lại từ bước đầu và câu mô hình sinh ở bước trước thay câu chuẩn trong lịch sử của bước sau (Bảng 6.8).

Cả hai mô hình giảm khoảng 4 điểm ($-4{,}15$ và $-4{,}21$), nên mức giảm là đặc điểm của thiết lập chứ không riêng mô hình nào. Trên 3.492 bước thuộc các tác vụ có đủ ảnh, trong đó lịch sử hoàn toàn do mô hình sinh, chênh lệch là 1,66 điểm [+0,60; +2,75]. Độ đo văn bản của cả hai mô hình cùng giảm rõ trong thiết lập này, và chênh

Bảng 6.8: Executability khi lịch sử các bước trước do chính mô hình sinh.

Mô hình	Lịch sử chuẩn	Lịch sử tự sinh
S1/101	59,11	54,96
GRPO-SPICE	**60,65**	**56,44**
GRPO-SPICE − S1/101	+1,55 [+0,80; +2,33]	+1,48 [+0,54; +2,43]

lệch giữa hai mô hình chỉ còn có ý nghĩa ở chrF.

6.9 Thành phần thứ hai: ACE

ACE nâng cả bảy độ đo văn bản của GRPO-SPICE mà không làm giảm executability. ACE thay 402 trong 4.463 câu ban đầu, ở những bước câu ứng viên thỏa điều kiện lựa chọn (Mục 4.4).

Bảng 6.9: ACE so với câu ban đầu và với mô hình sinh câu ứng viên dùng độc lập.

Độ đo	Câu ban đầu	Mô hình sinh độc lập	ACE	ACE − câu ban đầu
Executability	60,65	59,40	**60,68**	+0,02 [−0,21; +0,26]
Tiêu chí hộp phần tử	67,02	65,81	**67,11**	+0,09 [−0,15; +0,33]
AitW đầy đủ	76,25	75,02	**76,32**	+0,07 [−0,15; +0,29]
BLEU-4	52,36	**53,47**	**53,47**	+1,11 [+0,78; +1,42]
METEOR	37,92	37,79	**38,37**	+0,45
ROUGE-L	68,36	68,67	**69,11**	+0,74 [+0,54; +0,94]
CIDEr-D	430,05	437,54	**442,02**	+11,97 [+8,24; +15,34]
SPICE	45,79	46,79	**47,13**	+1,33 [+0,92; +1,75]
chrF	62,87	62,65	**63,45**	+0,58 [+0,37; +0,80]
BERTScore	67,07	67,52	**67,73**	+0,66 [+0,46; +0,86]

Độ đo văn bản của mô hình sinh độc lập lấy từ một lượt tính trước đó; ở lượt này, các giá trị của câu ban đầu lệch không quá 0,02 điểm so với cột thứ nhất.

ACE giữ executability của GRPO-SPICE ($p = 1$), và sáu độ đo văn bản có KTC đều tăng với KTC nằm trên 0 (Bảng 6.9). Dùng thẳng mô hình sinh câu ứng viên cho

mọi bước làm năm trong bảy độ đo văn bản tăng nhưng executability giảm 1,25 điểm [−2,06; −0,44] (p = 0,0016). Điều kiện lựa chọn giữ được phần lợi về văn bản mà không mất executability, vì chỉ nhận câu trùng một câu ví dụ và cùng loại thao tác với câu ban đầu; câu được nhận có thể dẫn tới phần tử khác hẳn câu ban đầu, như ở Hình 4.3(a). Trên ACU, ACE cũng ngang GRPO-SPICE về executability (+0,27 điểm, KTC chứa 0) và cao hơn ở cả bảy độ đo văn bản.

6.10 Các phương án thiết kế đã khảo sát

Trước phương pháp cuối cùng, chúng tôi khảo sát các hướng dựa trên mô tả phần tử, học theo cặp ưu tiên, phần thưởng tọa độ, chọn ứng viên và hiệu chỉnh theo vùng ảnh. Các hướng này thay đổi rõ biểu diễn trung gian nhưng mức cải thiện ít truyền sang câu hướng dẫn cuối cùng; chẳng hạn GRPO thưởng tọa độ, xuất phát từ một mô hình sinh mô tả phần tử trước câu, đạt 60,07% executability, thấp hơn GRPO-SPICE 0,58 điểm (KTC chứa 0). Phương pháp vì vậy chuyển sang tối ưu trực tiếp câu bằng GRPO-SPICE, rồi dùng ACE để hiệu chỉnh có chọn lọc. Thiết kế và số liệu của từng hướng được trình bày ở Phụ lục A.

6.11 Hạn chế của kết quả

Độ lớn mức tăng trên tập kiểm tra chính. Mức tăng 1,55 điểm của GRPO-SPICE so với S1/101 có ý nghĩa thống kê nhưng nhỏ hơn MDE 2,11 điểm, tức chưa đủ để loại trừ khả năng một chênh lệch cỡ đó xuất hiện chỉ do huấn luyện lại. Mức tăng vượt MDE trên ACU (cận dưới KTC 3,17 điểm) và trên tập gộp 5.947 bước (2,30 điểm).

Biến thiên giữa các lượt huấn luyện. Hai lượt S1 chênh nhau 0,52 điểm [−0,22; +1,26]. Lượt GRPO-SPICE thứ hai chỉ đổi seed (Mục 4.3) và đạt 59,94%, thấp hơn lượt thứ nhất 0,72 điểm [−1,27; −0,16] nhưng vẫn cao hơn S1/101 0,83 điểm [+0,00; +1,67] (p = 0,036); lượt này chỉ ngang S1/202 (+0,31 điểm [−0,53; +1,17]). Theo AitW đầy đủ, hai lượt GRPO gần như bằng nhau và lượt thứ hai cao hơn S1/101 1,86 điểm [+1,06; +2,67]; ở độ đo văn bản, lượt thứ hai cho mức tăng so với S1/101 tương tự lượt một, và trên ACU cao hơn S1/101 4,04 điểm. Trên AitZ, lượt thứ hai thấp hơn

S1/101 1,17 điểm [−2,12; −0,22].

Bước không chạm. GRPO-SPICE có xu hướng viết câu cho thao tác chạm thường xuyên hơn. Xu hướng này đóng góp một phần mức tăng ở bước chạm (Mục 6.2) nhưng làm giảm tỉ lệ nêu đúng loại thao tác trên 2.495 bước không chạm, rõ nhất ở bước cuộn và quay lại (Bảng 6.10): trong 51 bước cuộn S1/101 nêu đúng còn GRPO-SPICE nêu sai, 47 bước bị đổi thành câu chạm, chẳng hạn *Swipe up* thành *Click on technology*. Ở bước chờ, tỉ lệ đúng tăng 4,55 điểm.

Bảng 6.10: Tỉ lệ nêu đúng loại thao tác trên các bước không chạm.

Nhóm bước	Số bước	S1/101	GRPO-SPICE	Δ [KTC 95%]
Toàn bộ	2.495	85,97	84,29	−1,68 [−2,76; −0,62]
Cuộn	755	83,97	77,75	−6,23 [−8,30; −4,31]
Quay lại	270	72,96	67,04	−5,93 [−9,42; −2,58]
Toàn bộ, lịch sử tự sinh	2.495	81,32	76,83	−4,49 [−6,48; −2,61]

Tiêu chí lỏng hơn. Dưới AitW đầy đủ, GRPO thưởng tọa độ (Mục 6.10) đạt 77,30%, cao hơn GRPO-SPICE 1,05 điểm [−0,09; +2,18] ($p = 0{,}066$), và nhánh thưởng CIDEr-D 500 bước đạt 76,52%; cả hai chênh lệch đều không có ý nghĩa thống kê. Dưới executability, cả hai nhánh này thấp hơn GRPO-SPICE.

Lỗi còn lại trên bước chạm. Trong 1.756 bước GRPO-SPICE không đạt, 1.576 bước (89,7%) đã đúng loại thao tác nhưng chưa dẫn tới đúng phần tử, gần bằng 1.573 bước của S1/101; điểm nghẽn còn lại là gọi tên hoặc mô tả phần tử mục tiêu.

Chương 7

Kết luận

7.1 Đóng góp chính

Chúng tôi nghiên cứu bài toán sinh hướng dẫn cho giao diện di động từ ảnh màn hình, mục tiêu của người dùng và lịch sử thao tác, trong đó đầu ra là một câu hướng dẫn ngắn cho bước kế tiếp. Công trình tập trung vào ba đóng góp chính gồm (i) một phương pháp sinh gồm hai thành phần nối tiếp, (ii) độ đo khả năng thực hiện theo hướng dẫn (executability), dùng để đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác và đúng loại thao tác, và (iii) các phân tích thực nghiệm trên nhiều phương án thiết kế, qua đó làm rõ những yếu tố ảnh hưởng đến chất lượng câu đầu ra.

Về phương pháp đề xuất

Phương pháp đề xuất (Mục 4.1) tối ưu trực tiếp câu đầu ra và gồm hai thành phần. Thành phần thứ nhất học tiếp mô hình tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE để sinh câu hướng dẫn ban đầu. Thành phần thứ hai, ACE, chỉ hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ truy hồi khi đầu ra thỏa ràng buộc sao chép và nhất quán loại thao tác. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng hoặc điều kiện lựa chọn của phương pháp.

Trên 4.463 bước có thao tác chạm của tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Chiều cải thiện được giữ theo executability, tiêu chí hộp phần tử, tiêu chí hộp phần tử kết hợp cửa sổ 14% và AitW đầy đủ. GRPO-SPICE cũng cao hơn S1/101 ở cả bảy độ đo dựa trên câu chuẩn, trong đó cả sáu độ đo có KTC

đều có khoảng tăng nằm trên 0. Lượt GRPO thứ hai đạt 59,94% executability và tiếp tục cao hơn S1/101 0,83 điểm [+0,00; +1,67]. Nhánh kiểm soát chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11% executability, bằng S1/101, và cả sáu KTC của nhóm độ đo dựa trên câu chuẩn đều phủ 0. GRPO-SPICE cao hơn nhánh này 1,55 điểm executability [+0,81; +2,30] và cao hơn ở cả sáu độ đo dựa trên câu chuẩn có KTC. Với cùng số bước huấn luyện, mức tăng chỉ xuất hiện khi tín hiệu SPICE giữ đúng quan hệ với mẫu.

Trên các tác vụ mới trong AndroidControl, mức cải thiện còn rõ hơn. Với 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện S1, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48]. Cả sáu độ đo dựa trên câu chuẩn có KTC cũng tăng với khoảng tin cậy nằm trên 0. Khi gộp ACU với tập kiểm tra chính thành 5.947 bước, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99]. Khi thay lịch sử chuẩn bằng câu do chính mô hình sinh ở các bước trước, GRPO-SPICE vẫn cao hơn S1 1,48 điểm [+0,54; +2,43]. Hướng tăng vì vậy được giữ trên tác vụ mới trong cùng nguồn AndroidControl và khi lịch sử do chính mô hình sinh.

ACE đạt 60,68% executability, giữ mức của GRPO-SPICE và đồng thời nâng cả bảy độ đo dựa trên câu chuẩn. Với sáu độ đo có KTC, toàn bộ khoảng tăng đều nằm trên 0, gồm BLEU-4 +1,11, ROUGE-L +0,74, CIDEr-D +11,97, SPICE +1,33, chrF +0,58 và BERTScore +0,66. Trên AitZ, bước tinh chỉnh có giám sát vẫn cao hơn Base 3,29 điểm executability [+1,51; +5,03]. GRPO-SPICE và S1 tương đương về executability với chênh lệch $-0{,}51$ điểm [$-1{,}39$; +0,36], trong khi GRPO-SPICE có điểm cao hơn S1 ở sáu trong bảy độ đo dựa trên câu chuẩn, với BLEU-4, SPICE và chrF có KTC nằm trên 0. Mức tăng executability của GRPO-SPICE thể hiện rõ trên AndroidControl và các tác vụ mới trong cùng nguồn dữ liệu. Khi đổi miền sang AitZ, lợi ích bổ sung của SPICE chưa xuất hiện rõ ở executability nhưng một số độ đo văn bản vẫn giữ mức tăng.

Về độ đo

Khi đầu ra là một câu hướng dẫn thay vì một tọa độ, một câu chuẩn duy nhất khó có thể bao quát hết các cách diễn đạt hợp lệ. Executability tiếp cận vấn đề này bằng cách

đưa câu hướng dẫn do mô hình tạo ra vào một mô hình định vị tách biệt với mô hình sinh, rồi kiểm tra câu đó có dẫn tới đúng phần tử cần thao tác và đúng loại thao tác. Đóng góp của phần đo lường không chỉ nằm ở định nghĩa điểm số, mà còn ở việc xây dựng tiêu chí xác định dự đoán đúng và đánh giá độ tin cậy của cách đo qua nhiều kiểm tra bổ sung (Chương 5).

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101: +1,55 điểm với UGround, +1,55 với UI-Venus, +0,78 [+0,05; +1,51] với Phi-Ground và +0,69 [+0,02; +1,40] với Phi-4 dạng chọn ô đánh số. Cả bốn KTC đều nằm trên 0. Phi-Ground được xây dựng trên Phi-3.5-Vision, thuộc họ kiến trúc khác Qwen và theo báo cáo kỹ thuật không dùng AndroidControl để huấn luyện. Phi-4 chọn một ô đánh số trên ảnh thay vì trả tọa độ. Thứ tự Base < S1/101 < GRPO-SPICE vì vậy không phụ thuộc vào một kiến trúc đánh giá duy nhất. Thứ tự này được xét so với S1/101; dưới Phi-4, lượt S1 thứ hai (S1/202) ngang GRPO-SPICE (−0,20 điểm [−0,94; +0,55]).

Kết quả nền tảng về dữ liệu và mô hình tinh chỉnh có giám sát

Tập giám sát gồm 64.567 bước được xây dựng hoàn toàn tự động, không yêu cầu gán nhãn thủ công bổ sung và không sử dụng nhãn do một mô hình ngôn ngữ khác sinh ra trong quá trình huấn luyện. Các bước kiểm tra chất lượng dữ liệu gồm đánh giá quá trình hợp nhất hai nguồn và mô tả mức lặp lại của cách diễn đạt giữa tập huấn luyện với tập kiểm tra (Chương 3).

Trên 4.463 bước có thao tác chạm của tập kiểm tra, S1/101 đạt 59,11% executability, cao hơn Base 11,52 điểm. Qwen2.5-VL-7B dùng prompting đạt 51,51%, nên mô hình 3B sau SFT cao hơn 7,60 điểm và sau GRPO-SPICE cao hơn 9,14 điểm. Trong thiết lập của đề tài, việc tinh chỉnh trên dữ liệu phù hợp với bài toán đem lại mức tăng lớn hơn rõ rệt so với chỉ tăng mô hình nền từ 3B lên 7B.

Về phân tích các hướng đã thử

Đóng góp thứ ba là phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát trước phương pháp đề xuất. Mục 6.10 tóm tắt kết quả, còn Phụ lục A trình bày thiết kế và số liệu chi tiết. Với biểu diễn mô tả phần tử, chất lượng câu hướng dẫn phụ

thuộc mạnh vào việc biểu diễn trung gian có xác định đúng phần tử hay không. Nhóm bước mà biểu diễn này xác định sai chỉ chiếm 29,9% số bước được phân tích nhưng đóng góp khoảng 91% khoảng cách giữa mô hình và câu chuẩn. Trong các giai đoạn học tiếp, mức cải thiện ở biểu diễn trung gian tạo tác động nhỏ hơn lên executability. Đây là một trong những căn cứ để phương pháp cuối cùng chuyển sang tối ưu trực tiếp câu hướng dẫn.

Với phương án chọn ứng viên, executability đạt 71,4% khi danh sách có ứng viên đúng và mô hình đưa ra lựa chọn. Phần giảm điểm chủ yếu xuất hiện ở những bước mô hình không đưa ra lựa chọn dù danh sách đã có ứng viên phù hợp. Điều này tách quyết định có đưa ra lựa chọn khỏi bài toán xếp hạng ứng viên.

7.2 Hạn chế

Các kết quả được diễn giải trong phạm vi của công cụ đánh giá, thiết lập mô hình và bộ dữ liệu đã sử dụng. Những điểm cần lưu ý khi mở rộng kết luận được tóm tắt dưới đây. Các phân tích kỹ thuật chi tiết nằm ở Chương 5, Chương 6 và Phụ lục A.

7.2.1 Phạm vi của công cụ đo

Executability là một độ đo tự động, dùng mô hình định vị để kiểm tra câu hướng dẫn có dẫn tới đúng phần tử và đúng loại thao tác. Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 dưới cả UGround, UI-Venus, Phi-Ground và Phi-4 (Mục 6.5). Hai công cụ ngoài họ Qwen cho mức chênh nhỏ hơn UGround và UI-Venus, nhưng khoảng tin cậy của chênh lệch vẫn nằm trên 0. Các đánh giá chéo này được dùng để xác nhận chiều của kết quả chính, còn executability với UGround là thiết lập đánh giá chính. Đánh giá trực tiếp với người dùng trên quy mô lớn hơn là một hướng bổ sung để tiếp tục đối chiếu executability với khả năng làm theo hướng dẫn trong thực tế.

7.2.2 Phạm vi của kết quả về mô hình

S1 và GRPO-SPICE đều được lặp lại qua hai lượt huấn luyện để quan sát mức biến thiên của kết quả. Trên tập kiểm tra chính, hai lượt GRPO-SPICE cùng cao hơn S1/101, với mức tăng 1,55 và 0,83 điểm executability. Trên ACU, hai lượt tiếp tục cùng chiều với mức tăng 4,58 và 4,04 điểm. Kết luận chính vì vậy được hỗ trợ bởi hai lượt huấn luyện và một thí nghiệm riêng trên nhóm tác vụ mới. Thiết kế ban đầu đặt mức chênh lệch tối thiểu có thể phát hiện là 2,11 điểm. Mức +1,55 trên tập kiểm tra chính nhỏ hơn ngưỡng thiết kế này nhưng khoảng tin cậy ghép cặp vẫn nằm trên 0. Trên ACU, mức +4,58 vượt ngưỡng, và khi gộp hai tập thành 5.947 bước, mức +2,30 cũng vượt ngưỡng. ACE được xây dựng trên lượt GRPO thứ nhất, đạt 60,68% executability và tăng cả bảy độ đo dựa trên câu chuẩn. Các nhánh thí nghiệm còn lại phục vụ so sánh thiết kế và lựa chọn thành phần của phương pháp.

7.2.3 Phạm vi dữ liệu và thực nghiệm

Thực nghiệm chính được thực hiện trên AndroidControl với giao diện tiếng Anh và mô hình nền Qwen2.5-VL-3B. Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05] ở các tác vụ không xuất hiện trong tập huấn luyện S1. Trên AitZ, lợi ích của bước tinh chỉnh có giám sát vẫn được giữ khi chuyển miền, còn GRPO-SPICE và S1 tương đương về executability. Các kết luận chính về executability tập trung vào bước có thao tác chạm. Ở toàn bộ nhóm bước không chạm với lịch sử chuẩn, tỉ lệ gọi đúng loại thao tác giảm từ 85,97% ở S1 xuống 84,29% ở GRPO-SPICE. Khi dùng lịch sử tự sinh, chênh lệch trên 2.495 bước không chạm là $-4{,}49$ điểm $[-6{,}48; -2{,}61]$. Đây là phạm vi cần tiếp tục cải thiện khi mở rộng phương pháp sang các loại thao tác khác. Việc mở rộng sang nhiều miền giao diện hơn, chuỗi tương tác dài hơn và giao diện tiếng Việt cũng là các hướng tiếp theo để kiểm tra phạm vi áp dụng của phương pháp.

7.3 Tính sẵn có của dữ liệu và mã nguồn

Mã nguồn và các tệp kết quả thô dùng trong quá trình thực nghiệm được lưu kèm theo đề tài để người đọc có thể đối chiếu các bảng và phân tích đã trình bày. Dữ liệu nguồn là AndroidControl [1], giấy phép CC0, lấy qua hai bản phân phối công khai trên Hugging Face đã nêu ở Bảng 3.1. Ảnh màn hình không được phân phối lại.

Mã nguồn bao gồm quy trình xây dựng dữ liệu, cấu hình huấn luyện, chương trình sinh câu và mã đánh giá. Kết quả được lưu ở mức từng bước, gồm câu hướng dẫn do mô hình tạo ra, điểm đánh giá, tọa độ do mô hình định vị trả về, tọa độ tham chiếu và các thành phần của executability. Nhờ đó, các bảng và phân tích theo nhóm có thể được đối chiếu trực tiếp với kết quả ở mức từng bước mà không cần gọi lại mô hình định vị.

7.4 Hướng phát triển

Các kết quả thực nghiệm gợi ra bốn hướng phát triển tiếp theo.

- **Mở rộng đánh giá qua nhiều lượt huấn luyện.** Hai lượt GRPO hiện cùng giữ hướng cải thiện trên tập kiểm tra chính và ACU. Việc lặp thêm các lượt trong cùng thiết lập sẽ giúp ước lượng chính xác hơn mức biến thiên của độ lớn cải thiện.
- **Kết hợp chặt hơn giữa nhận diện phần tử, lựa chọn phần tử và sinh câu.** Trong các thí nghiệm ở Phụ lục A, việc bổ sung thông tin vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo thay đổi nhỏ ở câu đầu ra. Với phương án chọn ứng viên, quyết định có đưa ra lựa chọn hay không ảnh hưởng đáng kể đến kết quả. Một hướng tiếp theo là học chung biểu diễn phần tử với câu hướng dẫn, hoặc tách rõ bước xác định có ứng viên phù hợp khỏi bước xếp hạng và sinh câu.
- **Đối chiếu executability với đánh giá của người dùng.** Một tập câu được nhiều người đánh giá độc lập có thể được sử dụng để xem executability phản ánh đến đâu khả năng người dùng xác định đúng phần tử và thao tác cần thực hiện. Đồng thời, cần mở rộng các biến thể diễn đạt để đánh giá độ ổn định của độ đo trong nhiều cách mô tả cùng một phần tử.

- **Mở rộng phạm vi thực nghiệm.** Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability trên tác vụ mới trong AndroidControl, còn AitZ cung cấp thêm một đánh giá khi đổi miền dữ liệu. Các thí nghiệm tiếp theo có thể mở rộng sang nhiều bộ dữ liệu có câu hướng dẫn do người viết, chuỗi nhiều màn hình, các loại thao tác ngoài thao tác chạm và giao diện tiếng Việt.

Chương 8

Các công trình nghiên cứu

Nội dung của luận văn đã được phát triển trong bài báo "Sinh hướng dẫn sử dụng phần mềm từ ảnh chụp màn hình và mục tiêu người dùng: xây dựng nhãn quy chiếu tự động khi phần tử giao diện không có tên để gọi", được chấp nhận tại Hội thảo Quốc gia lần thứ tư về Ngôn ngữ học Tính toán (VCL 2026).

Nội dung của luận văn cũng được phát triển trong bài báo "GUIStep: A Compact Vision-Language Model for GUI Step Instruction Generation", được chấp nhận trình bày tại SOICT 2026 và xuất bản trong kỷ yếu Springer CCIS.

Tài liệu tham khảo

[1] W. Li, W. Bishop, A. Li, C. Rawles, F. Campbell-Ajala, D. Tyamagundlu, O. Riva, "On the effects of data scale on UI control agents," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024.

[2] C. Rawles, A. Li, D. Rodriguez, O. Riva, T. P. Lillicrap, "AndroidInTheWild: A large-scale dataset for Android device control," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[3] K. Cheng, Q. Sun, Y. Chu, F. Xu, Y. Li, J. Zhang, Z. Wu, "SeeClick: Harnessing GUI grounding for advanced visual GUI agents," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

[4] Z. Wu, Z. Wu, F. Xu, Y. Wang, Q. Sun, C. Jia, K. Cheng, Z. Ding, L. Chen, P. P. Liang, Y. Qiao, "OS-ATLAS: Foundation action model for generalist GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[5] B. Gou, R. Wang, B. Zheng, Y. Xie, C. Chang, Y. Shu, H. Sun, Y. Su, "Navigating the digital world as humans do: Universal visual grounding for GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025 (Oral).

[6] Z. Gu *et al.*, "UI-Venus technical report: Building high-performance UI agents with RFT," arXiv:2508.10833, 2025 (bản tiền ấn phẩm).

[7] M. Zhang *et al.*, "Phi-Ground Tech Report: Advancing Perception in GUI Grounding," arXiv:2507.23779, 2025 (bản tiền ấn phẩm).

[8] Y. Xu, Z. Wang, J. Wang, D. Lu, T. Xie, A. Saha, D. Sahoo, T. Yu, C. Xiong, "Aguvis: Unified pure vision agents for autonomous GUI interaction," in *Proc. International Conference on Machine Learning (ICML)*, 2025.

[9] X. Deng, Y. Gu, B. Zheng, S. Chen, S. Stevens, B. Wang, H. Sun, Y. Su, "Mind2Web: Towards a generalist agent for the web," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] Y. Li, G. Li, L. He, J. Zheng, H. Li, Z. Guan, "Widget captioning: Generating natural language description for mobile user interface elements," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020.

[11] B. Wang, G. Li, X. Zhou, Z. Chen, T. Grossman, Y. Li, "Screen2Words: Automatic mobile UI summarization with multimodal learning," in *Proc. ACM Symposium on User Interface Software and Technology (UIST)*, 2021.

[12] J. Mao, J. Huang, A. Toshev, O. Camburu, A. Yuille, K. Murphy, "Generation and comprehension of unambiguous object descriptions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[13] R. Luo, G. Shakhnarovich, "Comprehension-guided referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[14] L. Yu, H. Tan, M. Bansal, T. L. Berg, "A joint speaker-listener-reinforcer model for referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[15] S. Petryk, D. Chan, A. Kachinthaya, H. Zou, J. Canny, J. Gonzalez, T. Darrell, "ALOHa: A new measure for hallucination in captioning models," in *Proc. NAACL-HLT, Short Papers*, 2024.

[16] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," in *Findings of the Association for Computational Linguistics: ACL*, pp. 2318–2335, 2024.

[17] A. B. Sai, T. Dixit, D. Y. Sheth, S. Mohan, M. M. Khapra, "Perturbation CheckLists for evaluating NLG evaluation metrics," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2021.

[18] S. Jandial, Y. Li, J. Wagle, K. Koishida, "Do GUI grounders truly understand UI elements?," in *Findings of the Association for Computational Linguistics: EACL*, 2026.

[19] K. Fang, J. Zhang, S.-T. Ni, P. Hui, Y. Wang, "GuideMe: A VLM-based system assisting independent smartphone learning for older adults," in *Proc. ACM Conference on Human Factors in Computing Systems (CHI)*, 2026.

[20] K. Papineni, S. Roukos, T. Ward, W.-J. Zhu, "BLEU: A method for automatic evaluation of machine translation," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2002.

[21] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in *Proc. Workshop on Text Summarization Branches Out, ACL*, 2004.

[22] M. Denkowski, A. Lavie, "Meteor Universal: Language specific translation evaluation for any target language," in *Proc. Ninth Workshop on Statistical Machine Translation (WMT)*, pp. 376–380, 2014.

[23] R. Vedantam, C. L. Zitnick, D. Parikh, "CIDEr: Consensus-based image description evaluation," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4566–4575, 2015.

[24] P. Anderson, B. Fernando, M. Johnson, S. Gould, "SPICE: Semantic propositional image caption evaluation," in *Proc. European Conference on Computer Vision (ECCV)*, pp. 382–398, 2016.

[25] M. Popović, "chrF: Character n-gram F-score for automatic MT evaluation," in *Proc. Tenth Workshop on Statistical Machine Translation (WMT)*, pp. 392–395, 2015.

[26] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi, "BERTScore: Evaluating text generation with BERT," in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[27] A. C. Cameron, J. B. Gelbach, D. L. Miller, "Bootstrap-based improvements for inference with clustered errors," *Review of Economics and Statistics*, vol. 90, no. 3, pp. 414–427, 2008.

[28] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965.

[29] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, "LoRA: Low-rank adaptation of large language models," in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[30] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[31] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, "LlamaFactory: Unified efficient fine-tuning of 100+ language models," in *Proc. ACL, System Demonstrations*, 2024.

[32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[33] J. Qi, M. Ding, W. Wang, Y. Bai, Q. Lv, W. Hong, B. Xu, L. Hou, J. Li, Y. Dong, J. Tang, "CogCoM: A visual language model with chain-of-manipulations reasoning," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[34] S. Bai *et al.*, "Qwen2.5-VL technical report," arXiv:2502.13923, 2025 (bản thảo tiền ấn phẩm).

[35] K. Chen, Z. Zhang, W. Zeng, R. Zhang, F. Zhu, R. Zhao, "Shikra: Unleashing multimodal LLM's referential dialogue magic," arXiv:2306.15195, 2023 (bản thảo tiền ấn phẩm).

[36] Q. Wu, X. Yang, Y. Zhou, C. Fang, B. Song, X. Sun, R. Ji, "Grounded chain-of-thought for multimodal large language models," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 33577–33587, 2026.

[37] M. Zhao, P. Anderson, V. Jain, S. Wang, A. Ku, J. Baldridge, E. Ie, "On the evaluation of vision-and-language navigation instructions," in *Proc. Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, pp. 1302–1316, 2021.

[38] P. Rajpurkar, R. Jia, P. Liang, "Know what you don't know: Unanswerable questions for SQuAD," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL), Short Papers*, pp. 784–789, 2018.

[39] A. K. Menon, S. Jayasumana, A. S. Rawat, H. Jain, A. Veit, S. Kumar, "Long-tail learning via logit adjustment," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[40] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024.

[41] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, "DeepSeekMath: Pushing the limits of mathematical reasoning in open language models," bản tiền ấn phẩm arXiv:2402.03300, 2024.

[42] A. Abouelenin *et al.*, “Phi-4-Mini technical report: Compact yet powerful multimodal language models via mixture-of-LoRAs,” bản tiền ấn phẩm arXiv:2503.01743, 2025.

[43] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, J. Gao, “Set-of-Mark prompting unleashes extraordinary visual grounding in GPT-4V,” bản tiền ấn phẩm arXiv:2310.11441, 2023.

[44] S. J. Rennie, E. Marcheret, Y. Mroueh, J. Ross, V. Goel, “Self-critical sequence training for image captioning,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017.

[45] R. Ramos, B. Martins, D. Elliott, Y. Kementchedjhieva, “SmallCap: Lightweight image captioning prompted with retrieval augmentation,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2023.

[46] S. Liu, Z. Zhu, N. Ye, S. Guadarrama, K. Murphy, “Improved image captioning via policy gradient optimization of SPIDEr,” in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 873–881.

Phụ lục A

Các phương án thiết kế đã khảo sát

Phụ lục này trình bày, theo thứ tự thực hiện, các hướng đã thử trước khi chọn phương pháp đề xuất, với phần tóm tắt ở Mục 6.10. Trong các bảng, S1 là mô hình tinh chỉnh có giám sát và được dùng làm mốc so sánh. S2 là mô hình mô tả phần tử. CE2-S2 là mô hình học thêm có giám sát. MIN-DESC (MIN) là mô hình sau giai đoạn học theo cặp ưu tiên. Base là mô hình gốc. Câu chuẩn là câu hướng dẫn do người chú thích viết cho bước tương ứng.

A.1 Sinh mô tả phần tử trước câu hướng dẫn

A.1.1 Thiết kế

Phương án đầu tiên yêu cầu mô hình sinh mô tả phần tử cần chạm trước khi sinh câu hướng dẫn. Mô hình huấn luyện theo thiết kế này được gọi là mô hình mô tả phần tử. Một số công trình trước cho thấy hiệu quả của bước trung gian phụ thuộc đáng kể vào dạng biểu diễn và cách đưa biểu diễn đó vào quá trình huấn luyện (Bảng A.1).

Hai cấu hình của Shikra [35] dùng cùng mô hình và bài kiểm tra nhưng cho kết quả trái chiều khi thay đổi dạng biểu diễn trung gian: văn xuôi làm giảm kết quả, trong khi biểu diễn có tọa độ làm tăng kết quả. GCoT [36] cũng cho thấy lợi ích xuất hiện khi bước định vị được đưa vào quy trình huấn luyện thay vì chỉ bổ sung ở prompt. Tác dụng của bước trung gian vì thế phụ thuộc vào cách biểu diễn và cách đưa thông tin

Bảng A.1: Ảnh hưởng của bước trung gian trong các công trình trước. Mỗi dòng so cấu hình có bước trung gian với cấu hình không có, theo thước đo và bộ dữ liệu của chính công trình đó. Chênh lệch dương nghĩa là bước trung gian giúp tăng kết quả.

Công trình	Phép so	Chênh lệch
Aguvis [8]	giữ bước suy luận trung gian so với bỏ đi, tác vụ mức thấp của AndroidControl	+11,4
Shikra (văn xuôi) [35]	bước trung gian viết bằng văn tự do	−7,4
Shikra (có tọa độ) [35]	cùng mô hình, bước trung gian có tọa độ	+5,9
GCoT [36]	huấn luyện sinh định vị trước (LLaVA-7B / 13B)	+4,5 / +5,8
CogCoM [33]	thêm 70K mẫu chuỗi thao tác trung gian vào dữ liệu huấn luyện (đọc chữ trong ảnh / hai bài kiểm tra khác)	+6,6 / +0,2 / +0,9

đó vào mô hình. Từ các quan sát này, chúng tôi kiểm tra có kiểm soát một biểu diễn tập trung vào phần tử mục tiêu trong bài toán của đề tài.

Chuỗi đích của phương án gồm hai phần như minh họa dưới đây.

dòng mô tả phần tử	`<desc>` vai trò | tên | `<point>`x, y`</point>` | dấu hiệu phân biệt `</desc>`
phần câu	câu hướng dẫn

A.1.1.1 Xây dựng nhãn mô tả phần tử

Dòng mô tả được tạo tự động từ tọa độ chạm, cây trợ năng và OCR. Chương trình chọn hộp trợ năng nhỏ nhất chứa điểm chạm, lấy vai trò từ cây trợ năng và lấy tên từ cây hoặc OCR sau khi qua các bộ lọc. Tọa độ được chuẩn hóa về thang [0, 1000], còn trường cuối chứa một dấu hiệu phân biệt được sinh theo cách định sẵn. Bảng A.2 tóm tắt bốn trường của nhãn.

Làm sạch tên và dấu hiệu phân biệt. Bộ lọc nhãn trợ năng loại 14,7% nhãn tại các phần tử cần chạm, gồm định danh lấy từ mã nguồn, chuỗi số dài, hậu tố dành cho trình đọc màn hình và các chuỗi chỉ báo phần tử không có nhãn như `No label`

Bảng A.2: Bốn trường của dòng mô tả phần tử và vai trò của từng trường.

Trường	Ví dụ	Vai trò
Vai trò	`tappable text`	phân biệt nút, ô nhập và mục danh sách
Tên	`Search here`	biểu diễn chữ hoặc nhãn của phần tử, lấy từ OCR hoặc cây trợ năng
Tọa độ	`<point> 440,91 </point>`	lấy từ điểm chạm tham chiếu và chuẩn hóa về lưới [0, 1000]
Dấu hiệu phân biệt	`just above the text "Coffee"`	bổ sung quan hệ với phần tử lân cận khi chỉ tên hoặc vai trò chưa đủ phân biệt

`specified`. Tên OCR chỉ được lấy khi hộp phần tử chiếm dưới 25% diện tích màn hình. Trong 25 trường hợp hộp chiếm gần hết màn hình được kiểm tra thủ công, không trường hợp nào khớp với câu chuẩn. Khi tạo dấu hiệu phân biệt, quy trình ưu tiên kết hợp một chuỗi OCR gần phần tử với thông tin vị trí tương đối. Trên mẫu thử, 75,9% dấu hiệu được tạo ra đủ để phân biệt phần tử cần chạm với các phần tử tương tự. 24,1% còn lại không đạt tiêu chí này.

Chất lượng nhãn ở quy mô đầy đủ. Trong 41.191 bước chạm của tập huấn luyện, quy trình xây dựng được 41.099 nhãn mô tả. 92 bước còn lại gồm 50 bước có điểm chạm không nằm trong hộp trợ năng nào và 42 bước không có cây trợ năng. Bảng A.3 so sánh 41.099 nhãn này với mẫu thử gồm 1.074 nhãn. Với ba chỉ số có số liệu đối chiếu ở cả hai cột, chênh lệch không vượt quá 1,4 điểm phần trăm.

Trong 32.061 tên lấy được, 8.581 tên đến từ cây trợ năng và 23.480 tên đến từ OCR. Các thống kê này chỉ mô tả nguồn tên của nhãn phụ trợ. Cây trợ năng không được đưa vào đầu vào của quy trình suy luận cuối cùng ở Chương 4.

A.1.1.2 Lý do thiết kế và cách đánh giá

Khi đánh giá, dòng mô tả bị cắt bỏ và mô hình định vị chỉ nhận câu hướng dẫn, nên mọi thay đổi về điểm số phải xuất phát từ thay đổi trong câu hướng dẫn. Thiết kế dựa trên ba căn cứ. Thứ nhất, một vấn đề quan trọng của bài toán là hướng dẫn có thể chưa

Bảng A.3: Chất lượng 41.099 nhãn mô tả ở quy mô đầy đủ so với mẫu thử gồm 1.074 nhãn.

Chỉ số	Quy mô đầy đủ	Mẫu thử
Tên rõ ràng	73,6%	73,8%
Chỉ có ký hiệu, không có chữ	4,4%	-
Không có tên	22,0%	23,4%
Vai trò rõ ràng	75,8%	-
Trùng tên trên cùng màn	7,6%	7,0%
Có phần tử cùng vai trò để so	91,6%	-

cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử tương tự trên màn hình. Vì vậy, dòng mô tả bổ sung một trường ghi dấu hiệu phân biệt. Thứ hai, hai cấu hình Shikra trong Bảng A.1 cho kết quả âm khi bước trung gian là văn xuôi và dương khi bước trung gian có tọa độ, nên dòng mô tả gồm bốn ô cố định và bắt buộc có tọa độ. Thứ ba, tọa độ chạm của người thật đã có sẵn trong dữ liệu, nên có thể sử dụng trực tiếp mà không cần gán nhãn bổ sung.

Thiết kế ban đầu còn dự kiến một mục thứ hai, tức phạt mô hình khi xác suất của dòng mô tả xác định đúng phần tử không vượt xác suất của dòng mô tả trỏ sang phần tử lân cận ít nhất một khoảng lề, là phần mà Widget Captioning [10] chưa xử lý. Chuỗi thí nghiệm được dừng sau khi đánh giá mục thứ nhất, nên phần này không được triển khai (Mục A.1.3).

A.1.2 Các cấu hình của thiết kế so sánh ban đầu

Thiết kế so sánh ban đầu gồm bảy cấu hình, dùng chung dữ liệu, mô hình gốc, siêu tham số và tập kiểm tra (Bảng A.4).

Cách dựng các biến thể dữ liệu. Ba cấu hình có dòng mô tả dùng cùng đầu vào và cùng câu hướng dẫn. S2 dùng dòng mô tả thật. S2r thay dòng này bằng một dòng lấy từ màn hình khác có độ dài token gần tương đương và thay tọa độ bằng giá trị ngẫu nhiên. S2-nopoint giữ vai trò, tên và dấu hiệu phân biệt nhưng bỏ trường tọa độ. Khi thiết kế yêu cầu so sánh trực tiếp, phần câu hướng dẫn được giữ hoàn toàn giống nhau giữa các biến thể. Ở các bước không chạm, không có dòng mô tả và chuỗi đích của

Bảng A.4: Các cấu hình của thiết kế so sánh ban đầu. Ba cấu hình cuối không cần huấn luyện.

Cấu hình	**Chuỗi phải sinh ra hoặc cách chạy**	**Vai trò**
Tinh chỉnh có giám sát (S1)	chỉ câu hướng dẫn (2 seed)	mốc so sánh
Mô tả phần tử (S2)	dòng mô tả thật + câu (seed 101)	phép so sánh chính của thiết kế ban đầu, kiểm tác dụng của việc mô tả phần tử trước
Mô tả giả (S2r)	dòng mô tả giả có độ dài token gần tương đương + câu	loại trừ khả năng điểm tăng chỉ do chuỗi phải sinh ra dài thêm
Mô tả không có tọa độ (S2-nopoint)	dòng mô tả bỏ tọa độ + câu	tách phần đóng góp của tọa độ
Danh sách phần tử lúc chạy (B-infer)	trọng số S1, danh sách phần tử đưa vào đầu vào lúc chạy	so huấn luyện với việc chỉ cung cấp thông tin lúc chạy
Mô hình gốc (Base)	mô hình gốc, không tinh chỉnh	đo phần cải thiện do bản thân việc tinh chỉnh
Câu chuẩn	câu chuẩn được đưa trực tiếp vào quy trình đánh giá	mốc tham chiếu của độ đo

các cấu hình được giữ giống nhau. Nhóm này chiếm 36,2% tập huấn luyện. Trạng thái cuối của các cấu hình không được tiếp tục huấn luyện được ghi ở Bảng A.18.

Thiết kế ban đầu dự kiến dùng $\Delta = S2 - S1$, tính từ trung bình hai seed của mỗi mô hình. Hai lượt huấn luyện S1 chỉ khác nhau ở seed, nên chênh lệch giữa chúng cho biết mức dao động khi chỉ huấn luyện lại mà không có can thiệp. Tuy nhiên, bốn cấu hình không được chạy, gồm seed 202 của S2, cấu hình mô tả giả, cấu hình mô tả không có tọa độ và cấu hình chỉ đưa danh sách phần tử vào lúc chạy (lý do ở Bảng A.18). Vì S2 chỉ có seed 101, đại lượng theo thiết kế ban đầu không được ước lượng. Các kết quả sau chỉ báo cáo những phép so sánh có dữ liệu tương ứng.

A.1.3 Kết quả

S2/101 đạt 57,2% executability, cao hơn mô hình gốc 9,59 điểm nhưng thấp hơn S1/101 và S1/202 lần lượt 1,93 và 2,44 điểm. Khoảng tin cậy của cả hai chênh lệch so với S1 đều nằm dưới 0, và đánh giá bằng mô hình định vị thứ hai giữ cùng thứ tự (Mục 5.5.4). Ở Mục A.1.3.2, kết quả thay đổi mạnh tùy việc biểu diễn trung gian có xác định đúng phần tử hay không.

Ba cách giải thích thay thế đã được kiểm tra và không cách nào giải thích được chênh lệch. Ba cách đó là độ dài câu, nhóm ứng dụng, và tên ghi trong dòng mô tả bị sai do lỗi nhận dạng chữ.

A.1.3.1 Chia nhóm theo việc có sinh dòng mô tả hay không

Bảng A.5: Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không.

Nhóm	n	S1	S2	Δ
Có sinh dòng mô tả	4.138	62,2	60,8	−1,38 [−2,54; −0,19]
Không sinh dòng mô tả	325	19,7	10,8	−8,92 [−12,57; −5,25]

Theo Bảng A.5, nhóm 325 bước mà mô hình mô tả phần tử bỏ qua dòng mô tả chỉ gồm 7,3% số bước nhưng chiếm 34% toàn bộ chênh lệch. Câu chuẩn vẫn đạt 68,3% trên nhóm này, trong khi mô hình phần lớn đoán sai loại thao tác. Tỉ lệ gọi đúng loại

thao tác lần lượt là 83,4% ở mô hình gốc, 55,1% ở S1 và 38,8% ở S2. Xu hướng lệch loại thao tác đã xuất hiện từ S1 và rõ hơn ở S2. Một giả thuyết là mô hình học tương quan tắt từ dữ liệu vì tập huấn luyện chỉ gắn dòng mô tả cho bước chạm, từ đó có thể hình thành lối tắt "đã viết dòng mô tả thì là chạm". Cấu hình mô tả không có tọa độ không được tiếp tục, nên giả thuyết này không được dùng như một kết luận nhân quả. Nhóm cũng được định nghĩa bằng hành vi của chính S2, vì vậy điểm thấp của S2 một phần gắn với cách chia nhóm. Trên cùng nhóm, S1 cũng chỉ đạt 19,7%.

A.1.3.2 Ảnh hưởng hai chiều của dòng mô tả

Bảng A.6: Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh, trên 3.473 bước có tên phần tử để đối chiếu. Vì vậy nhóm không sinh dòng mô tả chỉ có 228 bước, ít hơn 325 bước khi tính trên toàn bộ 4.463 bước. Cột Câu chuẩn là điểm của câu chuẩn trên chính nhóm đó.

Tên	Tọa độ	n	Base	S1	S2	Câu chuẩn
đúng	đạt	1.871	69,0	81,4	87,1	86,6
đúng	không đạt	184	23,4	25,5	26,1	31,0
sai	đạt	452	41,4	56,4	57,5	72,8
sai	không đạt	738	24,4	30,8	5,6	66,3
không sinh dòng mô tả	-	228	25,9	20,6	9,6	70,6

Bảng A.6 chia các bước được đánh giá theo việc dòng mô tả do chính mô hình mô tả phần tử sinh ra có đúng tên và tọa độ hay không. Khi đúng cả hai, mô hình đạt 87,1%, hơn mô hình tinh chỉnh có giám sát 5,7 điểm và vượt cả câu chuẩn trên nhóm đó. Khi sai cả hai, mô hình chỉ còn 5,6%, thấp hơn cả mốc tham chiếu dưới dùng câu chung chung không nói phần tử nào (12,0%, Mục 5.5.1), trong khi câu chuẩn vẫn đạt 66,3% trên 738 bước ấy. Ở nhóm này mô hình đã chọn một phần tử sai rồi viết câu khẳng định về phần tử đó, còn mô hình tinh chỉnh có giám sát viết câu chung chung nên vẫn có khả năng đạt tiêu chí. Khi dòng mô tả xác định đúng phần tử, S2 đạt 87,1%, cao hơn S1 5,7 điểm trên nhóm tương ứng. Khi biểu diễn trung gian sai, chất lượng câu giảm mạnh. Sự khác biệt giữa hai nhóm là căn cứ để xây dựng giai đoạn học theo cặp ưu tiên ở Mục A.2.1.

A.2 Học theo cặp ưu tiên trên dòng mô tả

A.2.1 Thiết kế

Ở Mục A.1.3.2, chất lượng dòng mô tả thay đổi cùng kết quả của câu hướng dẫn. Vì học có giám sát chỉ tối ưu xác suất của chuỗi đích, giai đoạn tiếp theo bổ sung mục tiêu ưu tiên trên các cặp đầu ra gần nhau. Giai đoạn này, gọi tắt là học theo cặp ưu tiên và ký hiệu MIN-DESC trong bảng, học tiếp 800 bước từ trọng số của mô hình mô tả phần tử.

vế được chọn	`<desc>`mô tả trỏ đúng phần tử`</desc>` + `\n` + câu
vế bị loại	`<desc>`mô tả trỏ sai phần tử`</desc>` + `\n` + đúng câu đó

Hai vế dùng cùng câu hướng dẫn và chỉ khác dòng mô tả. Cách dựng này tập trung tín hiệu ưu tiên vào phần mô tả phần tử, nhưng trong mô hình tự hồi quy, xác suất của phần câu phía sau vẫn được điều kiện hóa bởi tiền tố khác nhau nên ảnh hưởng của câu hậu tố không triệt tiêu hoàn toàn. Hàm mục tiêu thuộc họ tối ưu theo ưu tiên dạng tỉ số odds (ORPO), không cần mô hình tham chiếu đóng băng.

A.2.1.1 Xây dựng tập cặp ưu tiên

Tập huấn luyện của giai đoạn này gồm 22.854 cặp. Ở vế được chọn, dòng mô tả trỏ tới phần tử cần chạm. Ở vế bị loại, dòng mô tả trỏ tới một phần tử có thật trên cùng màn hình, cùng vai trò, cách phần tử mục tiêu từ 80 đến 350 điểm ảnh và khác ở cả tên lẫn tọa độ. Sau khi xây dựng, các cặp được kiểm tra để phần câu hướng dẫn của hai vế hoàn toàn giống nhau và dòng mô tả ở vế bị loại không trỏ vào phần tử cần chạm.

Tập cặp chỉ chứa bước chạm. Ở 17,4% số cặp, chuỗi `(no name)` chỉ xuất hiện ở một trong hai vế, nên mô hình có thể sử dụng dấu hiệu này bên cạnh nội dung màn hình để phân biệt hai vế. Đặc điểm này được phát hiện sau khi lượt huấn luyện hoàn tất, nên Mục A.2.2 giữ nguyên dữ liệu đã dùng và diễn giải nhánh này như một phân tích cơ chế. Phép so với CE2-S2 ở Mục A.2.2.2 được dùng để tách thêm đóng góp của mục tiêu ưu tiên khỏi ảnh hưởng của việc tiếp tục huấn luyện.

A.2.1.2 Tách ảnh hưởng của mục tiêu ưu tiên

Để tách phần của mục tiêu ưu tiên khỏi phần của việc học thêm, mô hình học thêm có giám sát (CE2-S2) học có giám sát thuần trên vế được chọn của các cặp ấy, cùng điểm xuất phát và số bước. Đại lượng chính là hiệu ghép cặp $\Delta_{\text{thành phần}}$ = MIN-DESC − CE2-S2, tính trên cùng các bước của tập kiểm tra (Mục 4.5).

A.2.2 Kết quả

A.2.2.1 Độ chính xác của dòng mô tả

Bảng A.7 đối chiếu trực tiếp dòng mô tả do mô hình tự sinh với nhãn chuẩn của tập kiểm tra, không cần gọi mô hình định vị.

Bảng A.7: Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình.

Mô hình	Sinh dòng mô tả	Tên đúng	Tọa độ đúng	Cả hai đúng
Mô tả phần tử (S2)	93,4%	59,2%	66,9%	53,9%
Học thêm có giám sát (CE2-S2)	99,6%	66,2%	71,2%	59,8%
Học theo cặp ưu tiên (MIN-DESC)	99,6%	67,0%	71,8%	60,6%

Học theo cặp ưu tiên đưa tỉ lệ đúng cả tên lẫn tọa độ lên 60,6%, cao nhất trong ba cấu hình ở Bảng A.7. So với S2, mức tăng là 6,77 điểm. Cấu hình chỉ học thêm có giám sát đạt 59,8%, tương ứng tăng 5,93 điểm. Phần chênh riêng giữa MIN-DESC và CE2-S2 là 0,84 điểm, tức mục tiêu ưu tiên tạo thêm một mức tăng trên nền hiệu quả của việc học tiếp.

A.2.2.2 Executability và đại lượng chính

MIN-DESC đạt 60,0% executability, cao hơn cấu hình chỉ học thêm có giám sát 0,63 điểm với KTC 95% [+0,16; +1,09] và p = 0,011. Mục tiêu ưu tiên vì vậy tạo một mức tăng riêng trong phép so trực tiếp này. So với S2, MIN-DESC tăng 2,87 điểm, trong

đó 2,24 điểm cũng xuất hiện ở CE2-S2. Phần lớn mức tăng tổng thể so với S2 đến từ việc tiếp tục huấn luyện, còn mục tiêu ưu tiên đóng góp thêm 0,63 điểm so với cấu hình học thêm có giám sát. So với S1/101, MIN-DESC cao hơn 0,94 điểm với KTC chứa 0.

A.2.2.3 Biến thể lấy về bị loại theo chính sách

Ngoài nguồn cặp được xây dựng theo cách cố định (cửa sổ 80–350 điểm ảnh quanh phần tử mục tiêu), chúng tôi thử thêm biến thể on-policy, trong đó vế bị loại lấy từ chính phần tử mô hình dự đoán sai. Trên 14.000 màn huấn luyện chỉ thu được 459 cặp hợp lệ (3,3%). Mô hình thường gọi đúng phần tử bằng tên khác hoặc xác định một vùng cách xa phần tử mục tiêu, còn lỗi nhầm giữa hai nút lân cận xuất hiện ít hơn giả định ban đầu. Với mục tiêu tạo đủ cặp lân cận để huấn luyện, nguồn cặp cố định phù hợp hơn trong thiết lập hiện tại.

A.2.3 Phân tích cơ chế mô tả phần tử

Cách chia nhóm dựa trên hành vi của chính mô hình đang được đánh giá. Hai nhóm khác nhau nhiều về độ khó, nên chỉ phép so sánh ghép cặp bên trong một nhóm là hợp lệ. Bảng A.8 chia 3.473 bước có tên đúng để đối chiếu theo việc dòng mô tả của MIN-DESC trỏ đúng phần tử (tên khớp và tọa độ nằm trong dung sai 14%) hay trỏ sai.

Bảng A.8: Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. Dòng mô tả được xem là trỏ đúng khi tên trong đó trùng hoặc chứa tên của phần tử mục tiêu (hay ngược lại) và tọa độ lệch không quá 14% theo mỗi chiều. Cột Câu chuẩn là điểm của câu chuẩn trên chính nhóm đó.

Nhóm	n	MIN-DESC	S1	Δ ghép cặp	Câu chuẩn
Trỏ đúng phần tử	2.106 (60,6%)	87,1	78,3	+8,83	86,3
Trỏ sai phần tử	1.367 (39,4%)	21,8	32,9	−11,12	61,4

Khi dòng mô tả xác định đúng phần tử, MIN-DESC đạt 87,1%, cao hơn S1 8,83

điểm và vượt cả điểm của câu chuẩn trên chính nhóm đó. Khi dòng mô tả xác định sai, MIN-DESC thấp hơn S1 11,12 điểm. Chênh lệch giữa hai nhóm gắn chặt lợi ích của nhánh này với độ chính xác của biểu diễn trung gian. Trên toàn bộ tập, MIN-DESC cao hơn S1/101 0,94 điểm với KTC chứa 0 (Mục A.2.2).

Ngưỡng tối đa lý thuyết khi bù được phần thiệt ở các bước mô tả sai. Giả sử ở mỗi bước mà dòng mô tả xác định sai, MIN-DESC cho đúng kết quả của mô hình tinh chỉnh có giám sát. Khi đó điểm trên 3.473 bước có tên đúng để đối chiếu sẽ là 65,8% thay vì 61,4% thực đo, tức cao hơn mô hình tinh chỉnh có giám sát 5,4 điểm. Mức này không đạt được ở khâu suy luận bằng một cách chọn câu ở từng bước, tức quyết định lấy câu của MIN-DESC hay câu của mô hình tinh chỉnh có giám sát. Một cách chọn hoàn hảo, biết trước dòng mô tả xác định đúng hay sai, cho 63,5% trên toàn bộ 4.463 bước, nhưng bảy cách chọn thực tế đã thử chỉ cho 60,0 đến 60,3%, không khác biệt rõ so với mức 60,0% của MIN-DESC. Các phép chọn câu thực tế chưa đạt mức của cách chọn biết trước, nên nếu tiếp tục hướng này, can thiệp phù hợp hơn nằm ở khâu huấn luyện thay vì hậu xử lý.

Bảng A.9: Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). Tên đúng và tọa độ đúng được xét theo cùng định nghĩa với Bảng A.8. Cột cuối là phần dư địa tới mức câu chuẩn mà mỗi nhóm đóng góp, tính bằng điểm trên toàn bộ các bước được đánh giá.

Nhóm	n	%	MIN	S1	Câu chuẩn	Dư địa
tên đúng, tọa độ đúng	2.106	47,2	87,1	78,3	86,3	−0,40
tên đúng, tọa độ sai	220	4,9	26,4	27,7	32,3	+0,29
tên sai, tọa độ đúng	387	8,7	55,0	50,9	72,4	+1,50
không sinh dòng mô tả	15	0,3	0,0	0,0	60,0	+0,20
tên sai, tọa độ sai	745	16,7	3,6	25,8	64,4	+10,15
không có tên để đối chiếu	990	22,2	55,3	54,4	73,0	+3,94
Tổng	**4.463**	**100,0**	**60,0**	**59,1**	**75,7**	**+15,7**

Nhóm đúng cả tên lẫn tọa độ chiếm 47,2% số bước và MIN-DESC đạt 87,1%, cao hơn mức 86,3% của câu chuẩn trên chính nhóm này. Phần lớn khoảng cách còn lại tập trung ở nhóm sai cả tên lẫn tọa độ: nhóm này đóng góp 10,15 trong tổng 16,08 điểm khoảng cách dương, tương ứng khoảng 63%. Nếu tiếp tục phát triển nhánh biểu diễn

trung gian, cải thiện độ chính xác của biểu diễn phần tử là hướng tác động trực tiếp nhất vào phần dư địa này.

A.3 Chọn phần tử trong danh sách ứng viên

A.3.1 Thiết kế

Ở Mục A.2.3, phần lớn dư địa còn lại của MIN-DESC tập trung ở những bước mà dòng mô tả sai cả tên lẫn tọa độ. Vì vậy, thay vì để mô hình tự viết dòng mô tả, phương án chuyển sang cho mô hình chọn phần tử trong danh sách lấy từ chính màn hình. Mô hình huấn luyện theo cách này được gọi là mô hình chọn ứng viên. Căn cứ là ba con số đo được trước khi huấn luyện. Nếu lấy toàn bộ bước chạm của tập kiểm tra làm mẫu số, 99,7% bước có tên mục tiêu lấy được từ OCR hoặc cây trợ năng và 80,2% bước có một ứng viên vừa khớp tên vừa nằm trong dung sai. Tỉ lệ tương ứng của dòng mô tả tự sinh là 59,9%. Ngoài ra, ở 67,7% số bước mà MIN-DESC gọi sai tên, tên đúng đã nằm sẵn trong 24 dòng OCR của prompt nhưng không kèm vị trí.

Cách làm. Prompt thay 24 dòng OCR bằng một danh sách phần tử có tên và vị trí. Chuỗi đích mở đầu bằng một thẻ chọn, là bản chép nguyên văn một dòng trong danh sách hoặc thẻ `none`, rồi mới tới câu. Thẻ này được cắt bỏ trước khi đánh giá. Danh sách phần tử có cấu trúc đã được sử dụng trong các công trình trước (Chương 1). Trong phương án này, thành phần được khảo sát là cơ chế chọn tường minh, tức mô hình ghi rõ ứng viên được chọn ngay trong chuỗi đích.

A.3.1.1 Xây dựng danh sách ứng viên và chuỗi đích

Mỗi màn hình được chuyển thành danh sách tối đa 40 ứng viên, mỗi ứng viên gồm tên phần tử và tọa độ trên lưới [0, 1000]. Danh sách dùng cùng cách đặt tên với nhãn mô tả phần tử ở Mục A.1.1.1 và được sắp theo thứ tự đọc tự nhiên trên màn hình.

Tên trong nhãn mô tả của một bước được xem là tên mục tiêu của bước đó. Một ứng viên được xem là đúng khi có cùng tên mục tiêu và cách điểm chạm không quá 140 đơn vị lưới trên mỗi trục, tương đương 14% kích thước tương ứng của màn hình.

Nếu có nhiều ứng viên thỏa điều kiện, ứng viên gần điểm chạm nhất được chọn. Trên tập kiểm tra, trong số các bước có tên mục tiêu, 96,7% có tên đó xuất hiện trong danh sách. Trong chính nhóm bước có tên mục tiêu, 91,2% có ít nhất một ứng viên vừa trùng tên vừa nằm trong dung sai vị trí. Trên mẫu 300 bước có ứng viên đúng, vị trí của ứng viên đúng sau khi chuẩn hóa về [0,1] có giá trị trung bình 0,481 và ứng viên đúng đứng đầu danh sách ở 5,0% số mẫu. Vì vậy, vị trí trong danh sách không tạo thành một dấu hiệu thứ tự hiển nhiên của đáp án. Mẫu dài nhất vẫn dưới giới hạn ngữ cảnh 3.072 token nên không mẫu nào bị cắt vì danh sách ứng viên.

Từ cùng một prompt, hai cấu hình dữ liệu được dựng với chuỗi đích khác nhau. Cấu hình chọn ứng viên sinh thêm thẻ lựa chọn phần tử trước câu hướng dẫn. Cấu hình chỉ sinh câu hướng dẫn vẫn nhận cùng danh sách ứng viên ở đầu vào nhưng chuỗi đích chỉ gồm câu hướng dẫn.

Mô hình chọn ứng viên	`<sel>`tên `<point>`x, y`</point></sel>` + `\n` + câu hoặc `<sel>none</sel>` + `\n` + câu
Chỉ sinh câu hướng dẫn	câu

Nội dung thẻ chọn là phần sao chép nguyên văn thông tin của ứng viên đúng từ danh sách. Thẻ `none` được dùng cho bước không chạm, bước chạm không có tên mục tiêu hoặc bước chạm có tên nhưng danh sách không chứa ứng viên khớp. Câu hướng dẫn ở cả hai cấu hình là câu chuẩn nguyên bản. Prompt và ảnh cũng được giữ giống nhau. Do mọi bước không chạm đều sử dụng thẻ `none`, 54,78% toàn bộ mẫu huấn luyện mang nhãn này. Nếu chỉ xét 41.191 bước chạm, tỉ lệ là 29,12%. Hai tỉ lệ được dùng để phân tích hành vi từ chối chọn ở Mục A.3.2.3.

A.3.1.2 Điều kiện thí nghiệm

Mô hình chọn ứng viên khác S1 và MIN-DESC ở ba yếu tố của thiết lập: ngữ cảnh dài 3.072 thay vì 2.560 token để chứa danh sách ứng viên, một lượt duyệt (4.036 bước), và đầu vào có thêm danh sách ứng viên. Vì vậy, phép so trực tiếp dùng để đánh giá cơ chế chọn là $\Delta_{\text{chọn}}$ giữa cấu hình chọn ứng viên và cấu hình chỉ sinh câu hướng dẫn với cùng đầu vào. Thiết kế ban đầu đặt một cổng thực nghiệm: chỉ tiếp tục năm lượt còn

lại nếu lượt đầu vượt mức 60,6% về độ chính xác chọn, là tỉ lệ dòng mô tả xác định đúng phần tử của MIN-DESC. Độ chính xác chọn được tính trên 1.400 bước chạm đầu của tập kiểm tra và chỉ xét các bước có ứng viên đúng.

A.3.2 Kết quả

Mô hình chọn ứng viên được huấn luyện với seed 101 trên 64.567 mẫu của Mục A.3.1.1.

A.3.2.1 Độ chính xác chọn và executability

Trên 1.400 bước của mẫu phát triển, 1.008 bước có ứng viên đúng và mô hình chọn đúng ở 580 bước, tương ứng 57,54%. Mức này chưa vượt cổng 60,6% đã đặt trước, nên phạm vi thí nghiệm được giữ ở lượt đầu. 3.063 bước còn lại chỉ được dùng để đọc kết quả, trong đó 3.062 bước thuộc các tác vụ không xuất hiện trong mẫu phát triển. Độ chính xác chọn riêng lẻ không phản ánh đầy đủ cơ chế: khi ép mô hình luôn chọn, độ chính xác trên các bước có ứng viên đúng tăng lên 69,05%, nhưng tỉ lệ thẻ đúng trên toàn mẫu phát triển giảm từ 63,43% xuống 49,71%.

Trên 4.463 bước chạm, mô hình chọn ứng viên đạt 56,1% executability [54,2; 58,0] và cao hơn mô hình gốc 8,54 điểm, với 731 bước chỉ mô hình chọn ứng viên đạt so với 350 bước theo chiều ngược lại ($p < 0{,}001$). Điểm trên mẫu phát triển (55,4%) và phần còn lại (56,5%) gần nhau. Do cấu hình đối ứng chỉ sinh câu nhưng nhận cùng danh sách ứng viên không được chạy sau cổng thực nghiệm, $\Delta_{\text{chọn}}$ không được ước lượng. Vì vậy, phần này được dùng để phân tích hành vi của cơ chế chọn và so sánh trực tiếp với Base, là mốc có cùng mô hình nền chưa tinh chỉnh.

A.3.2.2 Hành vi chọn và từ chối chọn

Khi danh sách chứa ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4% (Bảng A.10), chỉ cách câu chuẩn 4,3 điểm. Nhóm này chiếm 52,1% toàn bộ tập kiểm tra. Phần lớn cơ hội cải thiện nằm ở 872 bước có ứng viên đúng nhưng mô hình phát thẻ từ chối chọn, với executability 23,7%. Tỉ lệ từ chối nhầm gần bằng mức 27,1%

Bảng A.10: Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. Hàng đầu và hàng cuối là hành vi đúng, hai hàng giữa là hai dạng lỗi. Khoảng tin cậy 95% chỉ được tính cho hai nhóm có ứng viên đúng.

Có ứng viên đúng	Mô hình	n	% tập	Exec.	Khớp thao tác
có	chọn	2.326	52,1	71,4 [69,5; 73,2]	99,1
có	từ chối (sai)	872	19,5	23,7 [21,0; 26,7]	71,2
không	chọn (sai)	264	5,9	37,5	99,6
không	từ chối (đúng)	1.001	22,4	53,8	86,6

trên mẫu phát triển. Khả năng chọn khi mô hình đã quyết định đưa ra lựa chọn vì vậy tốt hơn rõ rệt so với khâu quyết định có chọn hay không.

Dấu hiệu đi kèm việc từ chối chọn. Câu mang động từ không phải chạm chiếm 28,3% số bước từ chối chọn, so với 0,97% ở bước đưa ra lựa chọn, tương tự hiện tượng lẫn loại thao tác ở Mục A.1.3.1. Sai số của mô hình định vị ở nhóm từ chối chọn có trung vị 19,9% bề ngang màn, so với 0,78% ở nhóm còn lại, tức mô hình xác định một vùng khác của màn như dạng lỗi lưỡng cực ở Mục A.2.2.3. Tỉ lệ từ chối chọn tăng theo độ dài danh sách (Bảng A.11), nhưng các màn hình có nhiều phần tử cũng thường khó hơn, nên quan sát này chỉ phản ánh tương quan.

Bảng A.11: Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng.

Số dòng trong danh sách	n	Từ chối chọn	Exec.
1 đến 5	178	18,5%	70,8
6 đến 10	363	15,7%	70,5
11 đến 20	826	25,9%	60,3
21 đến 39	1.036	29,3%	55,6
40 (mức tối đa)	795	33,2%	51,8

Tỉ lệ từ chối chọn cũng cao hơn khi ứng viên đúng nằm giữa danh sách (31,4%, so với 27,2% ở phần đầu và 24,3% ở phần cuối), tương tự hiện tượng Liu và cộng sự [40] mô tả cho ngữ cảnh dài. Đây là quan sát chưa qua kiểm định, và vị trí trong danh sách có tương quan với độ dài danh sách.

A.3.2.3 Phân bố nhãn từ chối chọn trong tập huấn luyện

Bảng A.12: Tỉ lệ thẻ `none` theo bốn mẫu số. Mô hình phát `none` nhiều hơn tỉ lệ đúng trên loại bước bị đánh giá, và ít hơn tỉ lệ gặp trên toàn tập huấn luyện.

Mẫu số	**Tỉ lệ none**
Toàn bộ tập huấn luyện (64.567 mẫu)	54,78%
Chỉ bước chạm của tập huấn luyện (41.191)	29,12%
Bước chạm của tập kiểm tra, tỉ lệ đúng (4.463)	28,34%
Tỉ lệ mô hình phát ra trên tập kiểm tra	41,97%

Theo Bảng A.12, tỉ lệ mô hình phát ra nằm giữa tỉ lệ đúng trên bước chạm và tỉ lệ trên toàn tập huấn luyện, và gần tỉ lệ toàn tập hơn. Vì mọi bước không chạm đều mang thẻ `none` (Mục A.3.1.1), thẻ này chiếm hơn một nửa số mẫu huấn luyện. Một cách giải thích phù hợp với quan sát là mô hình học tiên nghiệm của nhãn này trên toàn bộ tập huấn luyện rồi duy trì xu hướng đó khi xử lý bước chạm, là loại bước duy nhất được đánh giá. Rajpurkar và cộng sự [38] nêu hiện tượng tương tự cho SQuAD 2.0, còn Menon và cộng sự [39] chứng minh rằng dưới dạng lệch phân bố nhãn, sửa tiên nghiệm lúc huấn luyện tương đương với sửa sau huấn luyện. Tỉ lệ đúng trên bước chạm của tập huấn luyện (29,12%) và của tập kiểm tra (28,34%) chỉ chênh 0,8 điểm, nên phân bố nhãn trên riêng nhóm bước chạm gần như không thay đổi giữa hai tập. Phân tích này được dùng để giải thích hành vi quan sát được, không được diễn giải như một kết luận nhân quả.

Ba phương án hiệu chỉnh khác được dùng để xác định nguồn cải thiện khả thi. Sửa toàn bộ lỗi loại thao tác thêm 1,21 điểm. Rút danh sách còn mười dòng làm độ phủ ứng viên đúng giảm từ 71,7% xuống tối đa 51,7%, còn nới dung sai tọa độ nâng độ phủ lên 76,0% nhưng đồng thời thay đổi nhãn huấn luyện. Ba phép thử tiếp tục hướng phân tích về tiên nghiệm của thẻ `none` và quyết định từ chối chọn.

A.3.2.4 Ghép với giai đoạn học theo cặp ưu tiên và hiệu chỉnh mức từ chối chọn

Khi ghép mô hình chọn ứng viên với MIN-DESC theo quy tắc “nếu từ chối chọn thì dùng câu của MIN-DESC”, executability tăng từ 60,0% của MIN-DESC lên 60,7%.

Mức tăng +0,67 điểm gần với chênh lệch giữa hai lượt S1, nên phép ghép này được xem như một kết quả thăm dò hơn là bằng chứng riêng cho cơ chế chọn. Một cách chọn biết trước ở từng bước mô hình nào đúng cho mức 66,1%, cho thấy vẫn còn khoảng cải thiện nếu quyết định kết hợp được học tốt hơn.

Trước khi huấn luyện lại, mức từ chối chọn được hiệu chỉnh thử sau huấn luyện. Theo Menon và cộng sự, nếu hiệu chỉnh hậu xử lý không khắc phục được các bước từ chối nhầm thì khả năng huấn luyện lại chỉ để sửa tiên nghiệm nhãn cũng bị hạn chế. Thủ tục này chọn ứng viên có log-xác suất cao nhất khi điểm ấy hơn điểm của thẻ `none` quá một ngưỡng τ, với ngưỡng và ba biến thể cách xếp hạng được quét trên mẫu phát triển. So với hành vi hiện tại (888 trên 1.400 bước đúng), biến thể tốt nhất chỉ thêm +8 bước (khoảng tin cậy từ -11 đến +27), tức +0,6 điểm.

Theo tổng log-xác suất, ứng viên đúng đứng đầu ở 67,5% số bước có ứng viên đúng. Trong khi đó, điểm của thẻ `none` chỉ phân tách ở mức AUC 0,69–0,72 giữa bước có và không có ứng viên đúng. Hai con số củng cố phân tích ở Bảng A.10: khả năng xếp hạng ứng viên đã có tín hiệu tốt, còn quyết định từ chối chọn là phần cần cải thiện. Quét ngưỡng hậu xử lý làm tăng số bước được sửa nhưng đồng thời tạo số bước đổi theo chiều ngược lại gần tương đương, nên phần này được giữ ở mức phân tích cơ chế.

A.4 Huấn luyện tăng cường với phần thưởng tọa độ

A.4.1 Thiết kế

Căn cứ và phần thưởng. Hai giai đoạn trước tối ưu trên các chuỗi mục tiêu có sẵn. Giai đoạn huấn luyện tăng cường với phần thưởng tọa độ tiếp tục từ MIN-DESC bằng GRPO (Mục 2.3). Với mỗi prompt, mô hình sinh nhiều đầu ra và nhận phần thưởng dựa trên ba thành phần: 1,0 nếu tọa độ trong thẻ `<point>` nằm trong cửa sổ $\pm$14% quanh tọa độ tham chiếu, 0,2 nếu dòng mô tả đủ trường và đúng thứ tự, và 0,1 nếu tên phần tử khớp nhãn. Mô hình định vị không tham gia vào phần thưởng.

Cấu hình. Giai đoạn này học tiếp từ trọng số MIN-DESC với cùng lượng tử hoá bốn bit và phần thị giác đóng băng. Mỗi prompt sinh bốn câu trả lời ở nhiệt độ 1,0,

còn mô hình tham chiếu cho số hạng ràng buộc độ lệch là bản sao đóng băng của mô hình xuất phát. Tập thưởng gồm 2.000 bước chạm của tập huấn luyện, duyệt một lượt (500 bước cập nhật). Tập này chỉ gồm bước chạm vì chỉ bước chạm có tọa độ chuẩn.

A.4.2 Kết quả

Giai đoạn thưởng tọa độ cải thiện trực tiếp đại lượng được tối ưu: độ chính xác của dòng mô tả tăng 2,56 điểm với $p = 1{,}3 \times 10^{-8}$. Trên 4.463 bước chạm, executability của MIN-DESC và mô hình sau giai đoạn này lần lượt là 60,05% và 60,07%, tương ứng chênh +0,02 điểm [−0,59; +0,64]. Tiêu chí hộp phần tử tăng từ 66,55 lên 67,04. Trước khi đánh giá trên tập kiểm tra, mức tăng executability từng được ước lượng từ hệ số chuyển đổi của giai đoạn hai là +1,10 điểm [+0,59; +1,49]. Mức thực đo +0,02 điểm thấp hơn nhiều ước lượng này, nên hệ số chuyển đổi không được xem là cố định giữa các dạng can thiệp.

Phân rã thay đổi theo từng bước. Ở 164 bước mà giai đoạn ba sửa dòng mô tả từ sai thành đúng, executability tăng từ 32,9 lên 70,7. Ở 75 bước mà dòng mô tả chuyển từ đúng thành sai, executability giảm từ 69,3 xuống 29,3. Khi đếm chuyển đổi đạt/không đạt, bốn nhóm sửa đúng, làm sai, giữ nguyên và không có tên đối chiếu đóng góp lần lượt +62, −30, −14 và −17 bước, cho tổng ròng +1. Trong 1.950 bước có dòng mô tả thay đổi, 1.300 bước (66,7%) giữ nguyên câu, và toàn bộ 197 lần đổi kết quả đánh giá nằm trong 961 bước có câu thay đổi.

Diễn giải. Phần thưởng tọa độ đã cải thiện rõ biểu diễn trung gian, nhưng hàm thưởng không có số hạng trực tiếp cho câu hướng dẫn. Vì vậy, thay đổi trọng số có thể sửa tọa độ mà không tạo thay đổi tương ứng ở câu, hoặc làm câu đổi ở những bước không nhận tín hiệu trực tiếp. Quan sát này dẫn các thiết kế sau chuyển trọng tâm từ tối ưu biểu diễn trung gian sang tối ưu trực tiếp câu đầu ra.

A.4.3 Nội suy trọng số giữa hai mô hình

Giai đoạn ba nối tiếp giai đoạn hai, nên hai bộ trọng số chỉ khác nhau tương đối ít. Phép thử này xây dựng năm điểm trên đoạn nối hai bộ trọng số (kể cả hai đầu mút), bằng cách ghép các ma trận hạng thấp của hai bộ chuyển đổi LoRA ở từng mô-đun

theo tỉ lệ pha trộn, rồi đánh giá trên tập kiểm định nội bộ. Giả thuyết là một điểm ở giữa có thể giữ phần sửa của giai đoạn ba mà tránh bớt phần làm sai. Đường cong đơn điệu, với cực đại tại đầu mút giai đoạn ba. Điểm giữa tốt nhất thấp hơn đầu mút 0,38 điểm, mọi phép so sánh ghép cặp giữa các mức đều có khoảng tin cậy phủ 0, nên không cấu hình mới nào được đánh giá trên tập kiểm tra. Số bước có câu khác đầu mút giai đoạn hai tăng đều theo mức pha trộn (53, 95, 127 rồi 155 trên 407 bước), cho thấy phép ghép hoạt động đúng. Dư địa vốn hẹp, vì giai đoạn ba chỉ dịch hai ma trận hạng thấp 1,39% và 6,87% so với giai đoạn hai.

Vai trò của tập kiểm định nội bộ. Cả hai mô hình đều đã tiếp xúc với tập này trong các giai đoạn trước (Mục 3.2), nên tập chỉ được dùng để xếp hạng các biến thể trong cùng một họ. Trên tập kiểm tra độc lập, mọi kết luận định lượng vẫn dựa trên 4.463 bước chạm.

A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn

Các phương án từ Mục A.1.3 đến đây cho thấy biểu diễn phần tử và câu đầu ra có liên hệ chặt, nhưng mức tăng ở biểu diễn trung gian không tự động chuyển thành executability. Mục này tách quá trình thành hai khâu: nhận diện phần tử, đo bằng tọa độ mô hình ghi trong dòng mô tả, và sinh câu hướng dẫn, đo bằng tọa độ mà mô hình định vị suy ra từ câu. Trên 4.442 bước có dòng mô tả hợp lệ, MIN-DESC đạt 70,10% ở khâu nhận diện phần tử và 69,36% ở khâu sinh câu.

Bảng A.13: Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. Cột câu chuẩn là điểm của câu do người chú thích viết, đo trên cùng nhóm bước.

Nhóm	n	MIN-DESC	S1	Câu chuẩn
Nhận ra đúng phần tử	3.114 (70,1%)	82,37	74,18	84,36
Nhận ra sai phần tử	1.328 (29,9%)	8,43	24,47	55,72

Vai trò của nhóm nhận diện sai phần tử. Trên toàn bộ các bước được đánh giá, câu chuẩn hơn MIN-DESC 15,53 điểm. Nhóm mà mô hình nhận ra đúng phần

tử chiếm 70,1% số bước và chỉ đóng góp 1,40 điểm, tương ứng 9,0% khoảng cách. Nhóm nhận ra sai chiếm 29,9% nhưng đóng góp 14,14 điểm, tương ứng 91,0%. Nếu tiếp tục phát triển biểu diễn trung gian, phần dư địa lớn nhất nằm ở khâu nhận diện phần tử của nhóm này.

Chênh lệch theo trạng thái nhận diện phần tử. Nhóm mà mô hình nhận diện sai phần tử cũng khó hơn đối với câu chuẩn. Tuy nhiên, mức giảm của MIN-DESC lớn hơn đáng kể: từ 82,37 xuống 8,43, trong khi câu chuẩn giảm từ 84,36 xuống 55,72. Lỗi nhận diện phần tử vì vậy đi cùng mức giảm mạnh hơn ở câu hướng dẫn của MIN-DESC, dù cách chia nhóm chưa cho phép diễn giải hoàn toàn theo quan hệ nhân quả.

Quan hệ giữa cải thiện nhận diện và executability. Giai đoạn thưởng tọa độ là can thiệp đặt phần thưởng trực tiếp lên tọa độ trong dòng mô tả. Trên 4.437 bước ghép cặp, tỉ lệ nhận diện đúng phần tử tăng 1,60 điểm trong khi executability tăng 0,045 điểm, tương ứng 0,028 điểm executability cho mỗi điểm tăng ở tỉ lệ nhận diện. Hai đại lượng có liên hệ, nhưng mức chuyển đổi đo được ở can thiệp này không thể dùng như một hệ số cố định cho các thiết kế khác.

Bảng A.14: Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm.

Nhóm	n	MIN-DESC	Giai đoạn ba	Chênh
giữ đúng	2.997	83,08	82,95	−0,13
giữ sai	1.143	6,91	6,30	−0,61
sai chuyển thành đúng	184	17,93	58,15	+40,22
đúng chuyển thành sai	113	62,83	8,85	−53,98

Bảng A.14 phân rã mức thay đổi này. Giai đoạn ba sửa được 184 bước, với executability tăng 40,22 điểm trong nhóm, đồng thời 113 bước chuyển theo chiều ngược lại với mức giảm 53,98 điểm. Hai chiều thay đổi giải thích vì sao mức tăng tổng thể nhỏ dù số bước được sửa có cải thiện rõ.

Tương quan giữa các mô hình không phản ánh hệ số quy đổi giữa hai đại lượng. Giữa các mô hình đã huấn luyện, tỉ lệ nhận diện đúng phần tử và executability tương quan ở mức 0,739, nhưng tỉ số đo được trong can thiệp thực nghiệm chỉ là 0,028, nhỏ hơn 26 lần. Tương quan này phản ánh việc mô hình mạnh thường mạnh ở cả hai

khâu, nhưng không cho biết mức thay đổi của executability khi chỉ can thiệp vào khâu nhận diện phần tử.

Phạm vi diễn giải. Cách chia nhóm dựa trên hành vi của chính mô hình đang được đánh giá, nên chỉ phép so sánh giữa hai mô hình bên trong một nhóm là hợp lệ. Mẫu số 4.442 nhỏ hơn 4.463 vì 21 bước có dòng mô tả thiếu hoặc sai định dạng.

A.5.1 Độ ổn định của ước lượng trên nhóm con

Bảng A.13 gợi ý rằng việc thay câu ở nhóm nhận diện sai có thể đem lại mức tăng đáng kể. Nếu thay câu của MIN-DESC bằng câu của S1 trên nhóm do chính MIN-DESC xác định là nhận diện sai, điểm toàn tập tăng 4,80. Tuy nhiên, ước lượng này phụ thuộc mạnh vào cách định nghĩa nhóm vì tọa độ và câu của MIN-DESC đến từ cùng một lượt sinh. Mục này kiểm tra lại con số 4,80 dưới các cách chia độc lập hơn trước khi dùng làm căn cứ thiết kế.

Bảng A.15: Ước lượng lợi ích của can thiệp chỉ thay câu dưới bốn cách định nghĩa nhóm trên 4.437 bước ghép cặp. Cột cuối là mức thay đổi trên toàn bộ các bước khi thay câu của MIN-DESC trong nhóm đó bằng câu của S1.

Cách định nghĩa nhóm	n	MIN	S1	Câu chuẩn	Mức tăng khi thay câu
MIN-DESC nhận ra sai phần tử	1.327	8,44	24,49	55,69	+4,80
giai đoạn ba nhận ra sai phần tử	1.256	11,94	22,13	54,70	+2,88
giai đoạn ba sai mà MIN-DESC đúng	113	62,83	34,51	60,18	−0,72
30% màn hình có nhiều phần tử có thể chạm nhất	1.331	58,53	56,35	73,55	−0,65

Bảng A.15 đổi cách định nghĩa nhóm ba lần. Khi nhóm được định nghĩa bằng tọa độ của mô hình sau giai đoạn thưởng tọa độ, tức hành vi của một mô hình khác, ngưỡng tối đa còn 2,88. Khi lấy phần giai đoạn ba sai còn MIN-DESC đúng, ngưỡng tối đa đổi dấu. Khi dùng số phần tử có thể chạm trên màn, không dựa vào hành vi của mô hình nào, ngưỡng tối đa là −0,65. Trong khi đó, cột câu chuẩn tương đối ổn định ở ba hàng đầu (55,69, 54,70 và 60,18) và chỉ cao hơn ở hàng cuối, vốn là nhóm dễ hơn. Ưu thế giữa hai mô hình cùng họ thay đổi theo cách chia nhóm trong khi khoảng cách tới câu chuẩn tương đối ổn định, và đây là dấu hiệu của hiệu ứng chọn nhóm.

Nguyên tắc sử dụng phân tích nhóm. Một ước lượng lấy nhóm được định nghĩa bằng chính hành vi của mô hình cần được kiểm tra lại với ít nhất một cách chia độc lập trước khi dùng làm căn cứ thiết kế. Quy tắc này cũng được áp dụng cho các con số thuận lợi ở Mục A.2.3, giúp tránh lựa chọn phương án chỉ dựa trên hiệu ứng của cách chia nhóm.

A.6 Tích hợp thông tin vị trí vào mô hình sinh câu

Ở Mục A.5, độ chính xác nhận diện phần tử thay đổi cùng chất lượng câu hướng dẫn, nhưng cải thiện biểu diễn trung gian chưa chuyển trực tiếp thành executability. Từ đó, chúng tôi khảo sát bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc ý tưởng không cần GPU (Bảng A.16). Phần lớn phép đo được thực hiện trên tập kiểm định nội bộ để so sánh tương đối giữa các biến thể trước khi quyết định có mở rộng thí nghiệm.

Điều rút ra từ chuỗi phép thử. Thông tin vị trí có thể được giải mã từ trạng thái ẩn và mô hình có phản ứng với thay đổi hình ảnh, nhưng việc bổ sung đường tín hiệu vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo thay đổi nhỏ ở đầu ra. Ở phép tích hợp vai trò, vùng và thao tác, hệ số trộn tự giảm về gần 0. Ở các phép biến đổi ảnh, mô hình phản ứng với vùng được nhấn mạnh nhưng chưa phân biệt ổn định phần tử mục tiêu với phần tử lân cận. Hai hướng phù hợp hơn là tích hợp tín hiệu vị trí sớm hơn trong quá trình học hoặc tối ưu trực tiếp câu đầu ra, thay vì chỉ bổ sung một mô-đun hậu kỳ.

A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE)

A.7.1 Thiết kế

Căn cứ. TAGE (*Type-Aware Grounded Editor*) được xây dựng để kiểm tra khả năng hiệu chỉnh câu sau khi tập trung vào một vùng ảnh cục bộ quanh phần tử dự đoán. Mô-đun nhận câu hướng dẫn ban đầu từ mô hình học tăng cường với phần thưởng SPICE, định vị vùng cần xem và sinh lại câu từ ảnh gốc cùng ô cắt. TAGE nằm ở

Bảng A.16: Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. Dấu * chỉ phép đo trên tập kiểm định nội bộ.

Hướng	Cách làm	Kết quả
Mô-đun định vị và cầu nối*	một bộ chú ý học vị trí phần tử trên các mảnh ảnh, rồi cộng đặc trưng vùng đó vào trạng thái ẩn ở tầng giữa của mô hình	bộ chú ý học được vị trí (trùng hộp 52,0% so với 5,3% của tiên nghiệm), nhưng các cấu hình cầu nối chỉ làm thay đổi 15% số câu và executability chỉ lệch +0,17 điểm [−1,03; +1,33]
Vùng cắt làm ảnh thứ hai*	đo xác suất câu chuẩn khi cho thêm ảnh cắt quanh phần tử đúng, quanh phần tử lân cận cùng loại, hoặc quanh một vùng ngẫu nhiên	tách được vùng đúng khỏi vùng ngẫu nhiên, nhưng gần như không tách được khỏi phần tử lân cận (+0,004 nat mỗi token)
Tích hợp vai trò, vùng, thao tác*	đọc vai trò, vùng màn và loại thao tác từ trạng thái ẩn, rồi tích hợp lại qua một hệ số trộn học được	các thông tin này có thể được giải mã từ trạng thái ẩn (vai trò 51,5%, thao tác 82,8%), nhưng hệ số trộn giảm về gần không, chỉ 4% số câu thay đổi, và hoán vị thông tin giữa các bước không làm điểm giảm
Làm nét ảnh quanh phần tử cần chạm*	giữ S1 đóng băng, đưa ảnh được làm nét quanh phần tử cần chạm, quanh vùng đối diện, hoặc quanh tâm màn	S1 đổi câu ở 16,9% số bước, nhưng làm nét đúng phần tử cần chạm không tốt hơn làm nét vùng đối diện
Hai lượt viết lại có chọn lọc	sàng lọc trên tập kiểm tra: trong 958 câu của S1 chỉ khác câu chuẩn ở một cụm từ, đếm số câu làm mô hình định vị trỏ sai	147/958 (15,3%), tức phần lớn trường hợp gần nghĩa chỉ khác cách diễn đạt, không phải lỗi quy chiếu sang phần tử khác
Bộ xếp hạng câu biết màn sau*	học chọn một trong chín câu do S1 sinh, dùng đặc trưng tính nhanh, có một biến thể học theo mô hình thầy được xem màn kế tiếp	chưa vượt câu giải mã tham lam ở BLEU-4, CIDEr-D và SPICE, kể cả biến thể học theo mô hình thầy được xem màn kế tiếp

cùng vị trí hậu xử lý với ACE, nên mốc so sánh trực tiếp là câu hướng dẫn ban đầu của thành phần thứ nhất.

Ba thành phần. TAGE gồm ba thành phần, và Hình A.1 vẽ đường đi của một bước qua cả ba.

1. Bộ định vị nhận ảnh và mục tiêu rồi viết ra một điểm (x, y) trên thang 0 đến 1000. Quanh điểm ấy, một ô vuông có cạnh bằng 40% bề ngang màn hình được cắt ra và phóng lên 448 × 448 điểm ảnh.

2. Bộ biên tập nhận ảnh gốc, ô cắt và câu hướng dẫn ban đầu rồi viết lại câu. Lúc huấn luyện, ô cắt đặt quanh điểm chạm thật, và hàm mất mát gồm entropy chéo của câu chuẩn cộng một số hạng lề

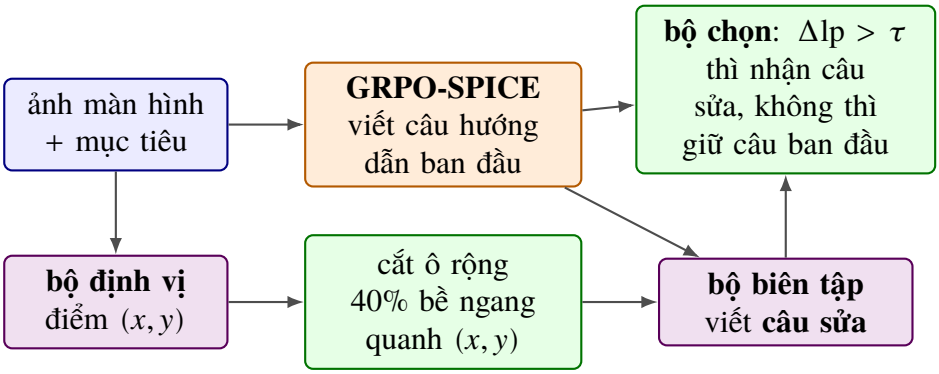
$$\mathscr{L} = \mathrm{CE}(g \mid \text{ô đúng}) + 0{,}5 \cdot \max\bigl(0,\ 0{,}2 - (\mathrm{nll}_{\text{lân cận}} - \mathrm{nll}_{\text{đúng}})\bigr), \qquad \text{(A.1)}$$

trong đó $\mathrm{nll}_{\text{đúng}}$ và $\mathrm{nll}_{\text{lân cận}}$ là log-xác suất âm của câu chuẩn khi ô cắt đặt quanh phần tử đúng và quanh một phần tử lân cận cùng vai trò. Số hạng này buộc bộ biên tập dựa vào nội dung ô cắt thay vì chép lại câu hướng dẫn ban đầu. Câu hướng dẫn ban đầu lúc huấn luyện lấy từ mô hình học tăng cường với phần thưởng SPICE, và 30% số câu hướng dẫn ban đầu này bị thay tên phần tử bằng tên phần tử lân cận.

3. Bộ chọn nhận câu sửa khi $\Delta\mathrm{lp} = \mathrm{lp}(\text{sửa}) - \mathrm{lp}(\text{ban đầu})$, tức hiệu log-xác suất trung bình theo token do bộ biên tập tính, lớn hơn một hằng số τ. Ngược lại, bộ chọn giữ câu hướng dẫn ban đầu. Giá trị $\tau = 0{,}738$ được chọn chéo trên tập kiểm định nội bộ, bằng cách chọn trên một nửa số tác vụ rồi áp lên nửa kia.

Bộ định vị và bộ biên tập là hai bộ chuyển đổi LoRA hạng 16 ở phần ngôn ngữ, gắn trên mô hình tinh chỉnh có giám sát (S1) sau khi đã cộng hẳn trọng số bộ chuyển đổi của S1 vào mô hình gốc. Mỗi bộ học một lượt trên 2.554 bước chạm của tập huấn luyện không chứa tác vụ nào của tập kiểm định nội bộ.

Cỡ mẫu khi chọn τ. Trên tập kiểm định nội bộ, bộ chọn nhận 11 câu sửa trong 249 bước chạm. Vì vậy, ngưỡng τ được xem là một lựa chọn thăm dò và được kiểm tra lại qua hành vi trên tập kiểm tra ở Mục A.7.2.



Hình A.1: Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE). Hai khối tím là hai bộ chuyển đổi được huấn luyện, khối cam là GRPO-SPICE, các khối xanh lá là bước xử lý không học. Δlp là hiệu log-xác suất trung bình theo token giữa câu sửa và câu hướng dẫn ban đầu, $\tau = 0{,}738$. Đầu ra của bộ chọn là câu được dùng để đánh giá.

A.7.2 Kết quả

Trên tập kiểm định nội bộ, câu sửa tốt hơn câu hướng dẫn ban đầu rõ rệt khi ô cắt đặt quanh điểm chạm đúng và kém đi rõ khi ô cắt cố ý đặt quanh một phần tử lân cận. Bộ biên tập vì vậy có phản ứng với nội dung ô cắt. Mô-đun hiệu chỉnh câu hoàn chỉnh cũng cao hơn nhẹ so với câu hướng dẫn ban đầu trên tập ấy, nên được đánh giá một lần trên tập kiểm tra.

Bảng A.17: Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE) trên 4.463 bước có thao tác chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của GRPO-SPICE và với S1/101. Tiêu chí hộp phần tử lấy từ AndroidControl, AitW đầy đủ lấy từ AndroidInTheWild. Các chênh lệch được tính ghép cặp theo bước.

Độ đo	S1	Câu ban đầu	TAGE	TAGE – câu ban đầu	p
Executability	59,11	60,65	60,23	−0,43 [−0,87; +0,02]	0,093
Tiêu chí hộp phần tử	65,49	67,02	66,44	−0,58 [−1,07; −0,09]	0,027
AitW đầy đủ	74,37	76,25	76,07	−0,18 [−0,66; +0,32]	0,55
Đúng loại thao tác	94,35	95,97	96,64	+0,67 [+0,44; +0,92]	<0,001
SPICE	44,37	45,79	45,74	−0,05 [−0,38; +0,27]	-

Kết quả trên tập kiểm tra. TAGE đạt 60,23% executability, cao hơn S1/101 1,12 điểm [+0,31; +1,94] và gần với mức 60,65% của câu hướng dẫn ban đầu từ GRPO-

SPICE. So trực tiếp với câu ban đầu, chênh lệch executability là −0,43 điểm [−0,87; +0,02], còn tiêu chí hộp phần tử giảm 0,58 điểm. Cấu hình TAGE hiện tại vì vậy không được chọn thay ACE. Khi vùng đầu vào chứa đúng phần tử mục tiêu, câu sửa vẫn tạo mức cải thiện rõ ở các phép phân rã theo bước.

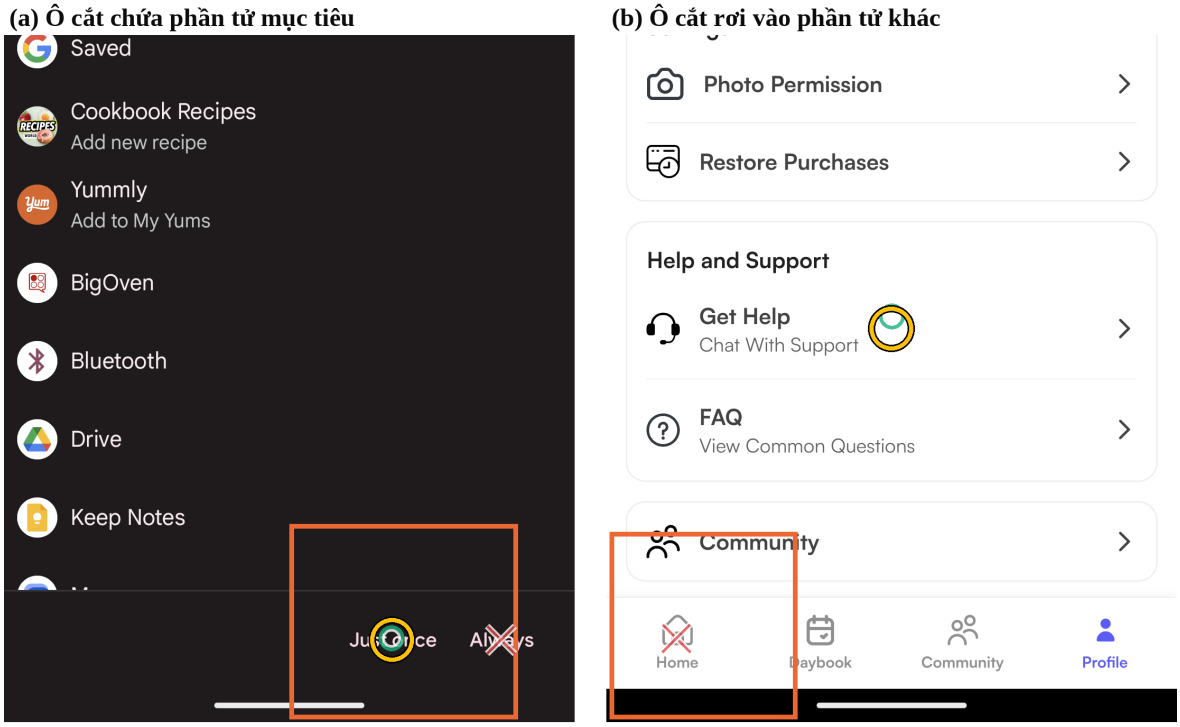
Ảnh hưởng của độ chính xác ô cắt. Mô hình định vị xác định đúng phần tử ở 69,5% số bước, bộ biên tập đổi câu ở 70,8%, và bộ chọn nhận 219 câu sửa. Trong 80 bước mà ô cắt đặt đúng chỗ, câu sửa chuyển 46 bước từ sai sang đúng và chỉ 7 bước theo chiều ngược lại, tương ứng ròng +39 bước. Ngược lại, trong 139 bước ô cắt đặt sai, câu sửa chỉ cứu 2 bước nhưng làm 60 bước chuyển từ đạt sang không đạt. Lợi ích của bộ biên tập vì vậy tập trung ở các trường hợp vùng đầu vào đúng, còn sai số định vị vùng làm đảo chiều tác động của TAGE.

Tín hiệu của bộ chọn. Theo Hình A.3, tỉ lệ ô cắt đặt đúng chỗ giảm đều khi Δlp tăng, từ 74,0% ở nhóm thấp nhất xuống 36,5% ở nhóm được nhận. Một cách giải thích phù hợp với quan sát này là khi ô cắt rơi vào phần tử khác, mô-đun biên tập tạo câu có xác suất cao đối với nội dung trong ô, trong khi câu hướng dẫn ban đầu mô tả phần tử ngoài ô nên nhận log-xác suất thấp. Hiệu Δlp vì vậy đo mức lệch giữa câu hướng dẫn ban đầu và ô cắt, và không cho biết câu nào đúng hơn. Trên tập kiểm định nội bộ, nhóm trên cùng chỉ có 11 câu, trong đó 8 câu có ô cắt đặt đúng chỗ, và τ lại được chọn từ chính 11 câu ấy.

Hướng cải thiện. Bộ chọn hiện dùng xác suất do chính bộ biên tập tính, nên tín hiệu lựa chọn phụ thuộc trực tiếp vào nội dung ô cắt. Một hướng phù hợp hơn là dùng tín hiệu độc lập để xác nhận ô cắt trước khi nhận câu sửa. Nếu chỉ nhận các câu sửa trong 80 bước có ô cắt đúng, số bước đạt tăng ròng 39, tương ứng khoảng +0,87 điểm trên toàn tập. Đây là ước lượng dựa trên điểm chạm thật để xác định ô cắt đúng, không phải kết quả của một cấu hình đã chạy. Giá trị +0,87 điểm chỉ được dùng để định lượng phần dư địa của bộ biên tập nếu khâu xác nhận vùng được cải thiện.

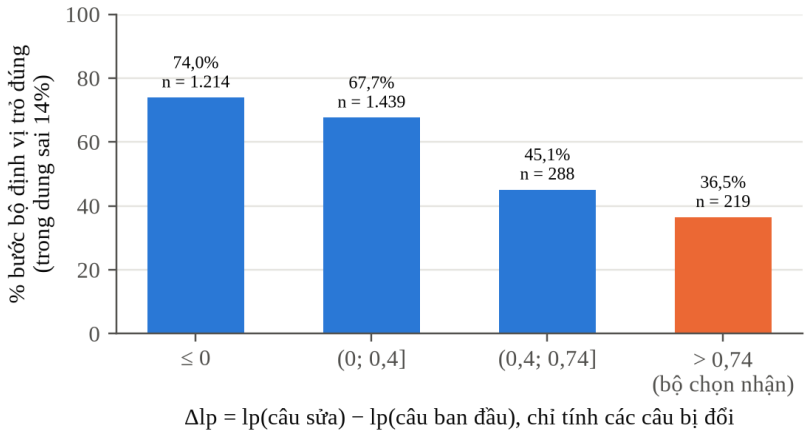
A.8 Trạng thái các cấu hình đã khảo sát

Bảng A.18 tổng hợp trạng thái cuối của các cấu hình đã khảo sát, đồng thời ghi lý do đối với những cấu hình không được tiếp tục hoặc dừng trước khi hoàn tất.



Khung cam: ô cắt rộng 40% bề ngang quanh điểm mà bộ định vị dự đoán
Vòng vàng: điểm người dùng đã chạm
Vòng xanh lá: điểm định vị cho câu đạt, (a) câu sửa, (b) câu ban đầu
Dấu X đỏ: điểm định vị cho câu không đạt, (a) câu ban đầu, (b) câu sửa
(a) câu ban đầu: "Click on the always button"
câu sửa: "Click on the just once option"
(b) câu ban đầu: "click on the Get help option"
câu sửa: "click on the home tab at the bottom left corner of the screen"

Hình A.2: Hai bước mà bộ chọn của TAGE nhận câu sửa (ảnh chỉ giữ phần dưới màn hình). (a) Ô cắt chứa đúng phần tử mục tiêu: câu hướng dẫn ban đầu gọi nút *Always*, câu sửa gọi đúng *Just once*. (b) Ô cắt rơi vào thanh điều hướng ở góc dưới bên trái: câu hướng dẫn ban đầu *Get help* vốn đúng bị thay bằng câu về thẻ *Home* nằm trong ô cắt. Khung cam là ô cắt rộng 40% bề ngang quanh điểm mà bộ định vị dự đoán, vòng vàng là điểm người dùng chạm. Vòng xanh lá và dấu X đỏ là điểm mô hình định vị trả về cho câu đạt và câu không đạt, ở (a) là câu sửa và câu ban đầu, ở (b) thì ngược lại.



Hình A.3: Tỉ lệ bước mà bộ định vị của TAGE trỏ trong dung sai 14% quanh điểm chạm thật, tức ô cắt được đặt đúng chỗ, theo nhóm Δlp, trên các câu mà bộ biên tập đã đổi ở tập kiểm tra. Δlp là hiệu log-xác suất trung bình theo token giữa câu sửa và câu hướng dẫn ban đầu, n là số câu trong mỗi nhóm. Cột cam là nhóm bộ chọn nhận ($\Delta\text{lp} > \tau$). Tỉ lệ này giảm khi Δlp tăng.

Bảng A.18: Trạng thái cuối của các cấu hình đã khảo sát. Điểm trong cột ghi chú là executability trên tập kiểm tra, trừ khi ghi khác.

Mô hình hoặc cấu hình	**Trạng thái**	**Ghi chú**
Phương pháp đề xuất (GRPO-SPICE + ACE)	Hoàn tất, đã đánh giá	60,7, hơn S1/101 +1,57 có ý nghĩa thống kê. Cả bảy độ đo dựa trên câu chuẩn đều tăng so với GRPO-SPICE và cả sáu độ đo có KTC đều loại 0, Mục 6.9
GRPO-SPICE (thành phần thứ nhất)	Hoàn tất, đã đánh giá hai lượt	60,7 và 59,9. Lượt 1 hơn S1/101 +1,55, cao hơn ở cả 13 độ đo và cả 12 độ đo có KTC đều loại 0. Lượt 2 hơn S1/101 +0,83, Mục 6.3, Mục 6.11
Mô hình tinh chỉnh có giám sát (S1), hai seed	Hoàn tất, đã đánh giá	59,1 và 59,6, chênh lệch giữa hai seed +0,52 điểm, Mục 6.11
Mô tả phần tử (S2), seed 101	Hoàn tất, đã đánh giá	57,2, cao hơn Base 9,59 điểm. Trên nhóm mô tả đúng tên và tọa độ đạt 87,1, Mục A.1.3

Mô hình hoặc cấu hình	Trạng thái	Ghi chú
Mô tả phần tử (S2), seed 202	Không tiếp tục	giới hạn tài nguyên tính toán
Mô tả giả (S2r) và mô tả không có tọa độ (S2-nopoint)	Không tiếp tục	phân tích theo nhóm của S2 cho mức +1,12 điểm gắn với tọa độ, nhưng S2-nopoint không được chạy
Đưa danh sách phần tử vào S1 lúc suy luận	Không thực hiện	không được yêu cầu bởi các cấu hình đã đánh giá
Học thêm có giám sát (CE2-S2) và giai đoạn học theo cặp ưu tiên (MIN-DESC)	Hoàn tất, đã đánh giá	59,4 và 60,0. MIN-DESC hơn CE2-S2 +0,63 [+0,16; +1,09], p=0,011, Mục A.2.2
Học ưu tiên với vế sai lấy từ lỗi của chính mô hình	Dừng ở khâu tạo dữ liệu	chỉ 3,3% cặp hợp lệ, Mục A.2.2.3
Giai đoạn thưởng tọa độ	Hoàn tất, đã đánh giá	60,1. Độ chính xác dòng mô tả tăng +2,56 điểm, còn executability giữ gần mức MIN-DESC, Mục A.4.2
Nội suy trọng số giữa hai giai đoạn trên	Hoàn tất	điểm thay đổi đơn điệu, không đánh giá thêm cấu hình mới trên tập kiểm tra, Mục A.4.3
Huấn luyện thêm có giám sát trên cùng 2.000 bước của giai đoạn thưởng tọa độ	Không thực hiện	mức chênh gần bằng không
Chọn ứng viên, seed 101	Hoàn tất, đã đánh giá	56,1, cao hơn Base +8,54. Khi có ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4, Mục A.3.2
Năm lượt còn lại của mô hình chọn ứng viên	Không tiếp tục	độ chính xác chọn không vượt dòng mô tả tự viết
Hiệu chỉnh ngưỡng từ chối chọn	Hoàn tất	tốt nhất thêm 8 bước đúng trên 1.400 bước
Mở khoá phần thị giác để cùng huấn luyện	Dừng trước khi hoàn tất	bản lưu trung gian thấp hơn rõ rệt giai đoạn học theo cặp ưu tiên trên tập kiểm định nội bộ

Mô hình hoặc cấu hình	Trạng thái	Ghi chú
Mô-đun định vị và cầu nối	Dừng sau một lượt	cầu nối không làm câu thay đổi, Mục A.6
Vùng cắt làm ảnh thứ hai	Dừng ở khâu đánh giá	không phân biệt phần tử đúng với phần tử lân cận
Đưa thêm vai trò, vùng và loại thao tác vào mô hình	Dừng sau một lượt	hệ số trộn tự giảm về gần không, chỉ 4% số câu đổi
Làm nét ảnh quanh phần tử	Dừng ở khâu đánh giá	không cải thiện so với làm nét ở vị trí đối diện
Hai lượt viết lại có chọn lọc và bộ xếp hạng câu dùng màn kế tiếp	Dừng ở khâu sàng lọc	số câu lỗi đủ điều kiện hiệu chỉnh còn ít, bộ xếp hạng cho kết quả thấp hơn giải mã tham lam
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	Hoàn tất, đã đánh giá	60,2, cao hơn S1 +1,12. Khi ô cắt đúng, câu sửa cứu ròng 39 bước, Mục A.7.2
Mô hình định vị thứ hai (UI-Venus)	Hoàn tất	chênh lệch S1 với mô hình gốc giữ 94%, phương pháp đề xuất hơn cả hai seed của S1, Mục 5.5.4 và Mục 6.5
Phi-Ground, mô hình định vị ngoài họ Qwen	Hoàn tất	GRPO-SPICE hơn S1/101 +0,78 [+0,05; +1,51], ACE hơn +0,76 [+0,02; +1,49]. Theo báo cáo kỹ thuật, Phi-Ground không dùng AndroidControl để huấn luyện, Mục 6.5
Mô hình người nghe dạng lựa chọn (Phi-4)	Hoàn tất	đã đánh giá mô hình gốc, hai lượt S1, GRPO-SPICE, ACE và câu chuẩn. GRPO-SPICE hơn S1/101 +0,69 [+0,02; +1,40], còn ACE ngang GRPO-SPICE, Mục 6.5
Đánh giá thủ công 100 câu bởi hai người	Hướng mở rộng	được đề xuất như một bước đối chiếu bổ sung, Mục 7.2

Phụ lục B

Kiểm chứng bổ sung cho executability

Phụ lục này trình bày các phép kiểm phụ được nhắc ngắn ở Chương 5.

B.1 Biến đổi lỗi có kiểm soát

Theo cách làm của Sai và cộng sự [17], chúng tôi tạo các trường hợp đúng hoặc sai đã biết trước rồi đếm tỉ lệ cách đánh giá phản ứng đúng chiều (Bảng B.1). Phép kiểm này không gọi mô hình định vị. Điểm dự đoán được đặt tổng hợp, hoặc lệch nhẹ quanh điểm chạm, hoặc gần tâm một phần tử khác, nên bảng chỉ kiểm tra phần tính điểm, tức hai điều kiện ở Mục 5.1. Ảnh hưởng của cách diễn đạt lên chính mô hình định vị được đo riêng ở Mục 5.5.2. Ba dòng đầu và các dòng về vị trí, loại thao tác dùng mẫu 398 bước có thao tác chạm. Ba dòng cuối dùng mọi bước phù hợp của tập kiểm tra; hai dòng cuối lấy từ các bước nhập chữ và bước cuộn, kiểm tra cách so nội dung nhập và hướng cuộn dùng khi phân tích các bước không chạm.

Tỉ lệ thấp ở dòng 30 đến 80 điểm ảnh phản ánh phép gộp tâm 24 dp (khoảng 63 điểm ảnh) ở Mục 5.2: nhiều phần tử trong khoảng này bị gộp với đích nên không được tính là cạnh tranh. Điều kiện đảo nghĩa chỉ bắt các cặp có trong danh sách lập thủ công, nên 12 trường hợp thuộc cặp ngoài danh sách đều không bị phát hiện. Khi điểm dự đoán lệch đều quanh điểm chạm với câu đúng, tỉ lệ loại nhầm là 0% ở mức lệch 3% bề ngang, 7,5% ở 5%, 24,1% ở 8% và 55,0% ở 13%.

Bảng B.1: Tỉ lệ phản ứng đúng chiều của cách đánh giá trước các biến đổi đã biết kết quả.

Trường hợp kiểm tra	**Tỉ lệ**	**n**
Loại nhầm một câu vẫn đúng (càng thấp càng tốt)		
Câu diễn đạt khác, điểm lệch 3% bề ngang	0,0%	398
Điều kiện loại thao tác trên câu diễn đạt khác	0,0%	398
Điều kiện đảo nghĩa trên câu diễn đạt khác	0,0%	398
Phát hiện một câu đã bị làm sai (càng cao càng tốt)		
Điểm gần phần tử cách đích từ 30 đến 80 điểm ảnh	33,1%	121
Điểm gần phần tử cách đích từ 80 đến 150 điểm ảnh	99,6%	233
Điểm gần phần tử cách đích hơn 25% bề ngang	100,0%	397
Sai loại thao tác	100,0%	369
Cặp trạng thái đối lập ngoài danh sách	0,0%	12
Sai nội dung nhập	91,1%	494
Sai hướng cuộn	100,0%	755

B.2 Độ tương đồng nhúng giữa các cách gọi phần tử

Phép thử dùng 51 cặp câu viết tay: 25 cặp cùng phần tử nhưng khác cách gọi, 15 cặp khác phần tử nhưng có từ ngữ chồng lấn, và 11 cặp khó liên quan tới trạng thái đối lập, con số, hướng hoặc quan hệ giữa phần tử cha và phần tử con. Hai vế của mỗi cặp được biểu diễn bằng bge-m3 [16] rồi so bằng độ tương đồng cosine. Điểm trung bình của các cặp cùng phần tử là 0,62, thấp hơn mức 0,67 của các cặp khác phần tử có từ ngữ chồng lấn. Cặp *inbox* và *outbox*, hai phần tử khác nhau, đạt 0,76, trong khi *search* và *magnifying glass*, hai cách gọi có thể chỉ cùng một phần tử, chỉ đạt 0,55. Trên tập này, độ gần trong không gian nhúng không đi cùng chiều với quan hệ quy chiếu, nên không có ngưỡng cosine nào tách được cặp cùng phần tử khỏi cặp khác phần tử. Kết luận chỉ áp dụng cho tập câu và mô hình nhúng nêu trên.

B.3 So sánh năm cách xác định vị trí

Giá trị tuyệt đối của điểm số phụ thuộc cách xác định một điểm là đúng phần tử. Trên mẫu 698 bước, chúng tôi đánh giá lại câu chuẩn, S1 và Base theo năm cách: đĩa Euclid bán kính 14% bề ngang, cửa sổ chữ nhật 14% theo từng trục, ô Voronoi đang dùng, ô Voronoi dựng quanh tâm hộp chứa g thay vì quanh g, và hộp gần nhất. Điểm của câu chuẩn thay đổi từ 56,6 đến 82,2, nhưng thứ hạng giữ nguyên và chênh lệch S1 − Base luôn nằm trong khoảng từ 9,5 đến 13,0 điểm (Bảng B.2).

Bảng B.2: Điểm của câu chuẩn và chênh lệch S1 − Base theo năm cách xác định vị trí (698 bước).

	Đĩa	**Chữ nhật**	**Voronoi**	**Voronoi (tâm hộp)**	**Hộp gần nhất**
Câu chuẩn	80,2	82,2	74,2	56,6	82,2
S1 − Base	+12,6	+13,0	+11,7	+9,5	+13,0

B.4 Tiêu chí lỏng và kết luận thống kê

Tiêu chí dung sai chấp nhận mọi điểm đủ gần, nên trên mẫu 800 bước cả câu chung chung "*Tap the button.*" cũng tăng từ 12,0 lên 20,5 điểm khi chỉ dùng cửa sổ 14%. Một phần mức tăng khi nới tiêu chí vì vậy là phần mà câu không mang thông tin quy chiếu cũng nhận được. Bảng B.3 minh họa hệ quả trên một phép so: mô hình sau giai đoạn thưởng tọa độ (một hướng đã thử, Mục A.4) cao hơn S1/101 có ý nghĩa thống kê dưới hai tiêu chí lỏng nhưng không có ý nghĩa dưới executability.

Bảng B.3: Mô hình sau giai đoạn thưởng tọa độ trừ S1/101 dưới ba tiêu chí, kèm hiệu chỉnh Holm.

Tiêu chí	**Δ**	**p**	**Sau hiệu chỉnh Holm**
Cửa sổ ±14% theo từng trục	+2,13	0,0003	có ý nghĩa thống kê
Điều kiện khoảng cách của AitW	+1,99	0,0007	có ý nghĩa thống kê
Executability	+0,96	0,090	không có ý nghĩa thống kê

B.5 Viết lại câu chuẩn

Bảng B.4 chi tiết phép viết lại câu chuẩn ở Mục 5.5.2, tính trên các câu được viết lại của mẫu 800 bước.

Bảng B.4: Executability khi viết lại câu chuẩn.

Biến thể	**Số câu viết lại**	**Trước → sau**	*b* / *c*	**p**
Đổi động từ thao tác	725 (90,6%)	76,8 → 77,0	13 / 14	1,000
Đảo trật tự mệnh đề	211 (26,4%)	89,6 → 90,0	0 / 1	1,000
Đổi động từ và đảo trật tự	203 (25,4%)	90,1 → 91,1	0 / 2	0,500