ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

LUẬN VĂN THẠC SĨ

TP. Hồ Chí Minh - Năm 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lê Đoàn Phương Uyên

PHÁT SINH TỰ ĐỘNG HƯỚNG DẪN SỬ DỤNG PHẦN MỀM DỰA TRÊN LLM TỪ CÁC TRƯỜNG HỢP SỬ DỤNG VÀ GIAO DIỆN NGƯỜI DÙNG

Ngành: TRÍ TUỆ NHÂN TẠO
Mã số ngành: 8480107

NGƯỜI HƯỚNG DẪN KHOA HỌC
TS. Nguyễn Hồng Bửu Long

TP. Hồ Chí Minh - Năm 2026

Lời cam đoan

Tôi cam đoan luận văn thạc sĩ ngành Trí tuệ nhân tạo với đề tài **Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng** là công trình do tôi thực hiện dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Các số liệu và kết quả trình bày trong luận văn là trung thực, được tính từ mã nguồn cùng các tệp kết quả đi kèm và không sao chép từ công trình của tác giả khác. Những thí nghiệm đã lên kế hoạch nhưng chưa thực hiện đều được ghi rõ là chưa thực hiện. Các tài liệu tham khảo được trích dẫn đầy đủ.

Tôi xin chịu trách nhiệm về tính trung thực của các kết quả trình bày trong luận văn.

Học viên cao học

Lê Đoàn Phương Uyên

Lời cảm ơn

Tôi thực hiện luận văn này tại Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh, dưới sự hướng dẫn của TS. Nguyễn Hồng Bửu Long.

Trước hết, tôi xin gửi lời cảm ơn chân thành đến thầy hướng dẫn, người đã định hướng đề tài và góp ý cho tôi trong suốt quá trình thực hiện luận văn.

Tôi xin cảm ơn quý thầy cô Khoa Công nghệ Thông tin đã giảng dạy trong suốt chương trình cao học và Văn phòng Khoa đã hỗ trợ các thủ tục liên quan đến luận văn.

Cuối cùng, tôi xin cảm ơn gia đình đã tạo điều kiện để tôi theo học và hoàn thành chương trình này.

Tp. Hồ Chí Minh, tháng 10 năm 2026

Lê Đoàn Phương Uyên

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Danh mục các hình vẽ, đồ thị **viii**

Danh mục các bảng số liệu **ix**

Danh mục từ viết tắt và thuật ngữ **xii**

Trang thông tin luận văn tiếng Việt **xvii**

Trang thông tin luận văn tiếng Anh **xxi**

1 Giới thiệu **1**

1.1 Đặt vấn đề 1

1.2 Động lực nghiên cứu 3

1.2.1 Động lực khoa học 3

1.2.2 Động lực ứng dụng 4

1.3 Mục đích nghiên cứu 4

1.4 Khoảng trống nghiên cứu và vị trí của đề tài 5

1.5 Nội dung và phạm vi thực hiện đề tài 5

1.5.1 Nội dung nghiên cứu 5

1.5.2 Phạm vi nghiên cứu 5

1.6 Đóng góp chính 6

2 Tổng quan **9**

2.1 Mô hình ngôn ngữ thị giác 9

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA 10

2.3 GRPO và phần thưởng dựa trên độ đo văn bản 10

2.4 Định vị phần tử giao diện 11

2.5 Bộ dữ liệu AndroidControl 12

2.6 Độ đo dựa trên câu chuẩn trong bài toán sinh hướng dẫn 12

3 Xây dựng bộ dữ liệu **14**

3.1 Nguồn dữ liệu và cách hợp nhất 14

3.2 Kiểm tra tính nhất quán của dữ liệu sau hợp nhất 15

3.3 Quy mô và phân chia dữ liệu 15

3.4 Xây dựng thông tin đầu vào từ giao diện 17

3.5 Dữ liệu phục vụ phương pháp đề xuất 17

3.6 Một số đặc điểm của dữ liệu 18

4 Phương pháp đề xuất **20**

4.1 Quy trình tổng thể 20

4.2 Đầu vào và cấu trúc prompt 22

4.3 Cấu hình huấn luyện 22

4.4 Tổng quan phương pháp đề xuất 23

4.5 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE 24

4.6 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE) 26

4.7 Mô hình và thiết lập so sánh 29

4.8 Thiết lập so sánh và diễn giải kết quả 29

5 Độ đo khả năng thực hiện theo hướng dẫn **30**

5.1 Định nghĩa 30

5.2 Tiêu chí xác định dự đoán đúng và giới hạn của tiêu chí dung sai quy ước 32

5.3 Mô hình định vị dùng làm công cụ đo 34

5.4 Kiểm tra độ chính xác của công cụ đo 34

5.5 Mốc tham chiếu của thang điểm 35

5.6 Độ nhạy với thông tin quy chiếu 36

5.7 Kiểm tra bằng biến đổi lỗi có kiểm soát 37

5.8 Độ ổn định trước các biến thể diễn đạt 38

5.9 Đánh giá chéo bằng mô hình định vị thứ hai 39

5.10 Đánh giá chéo bằng mô hình listener thuộc họ kiến trúc khác 41

5.11 So sánh với các độ đo dựa trên câu chuẩn 43

5.12 Độ nhạy của kết luận theo tiêu chí đánh giá 44

5.12.1 Độ ổn định của thứ hạng và kết luận thống kê 44

5.12.2 Đối chiếu với các tiêu chí dùng trong bộ dữ liệu GUI 45

5.13 Phương pháp phân tích thống kê 47

6 Thực nghiệm và kết quả **49**

6.1 Thiết lập thực nghiệm 49

6.2 Kết quả chính 49

6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE 53

6.3.1 Kết quả trên các bước có thao tác chạm 53

6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE) 57

6.5 Đánh giá trên nhiều nhóm độ đo 59

6.6 So sánh ghép cặp 65

6.7 Biến thiên giữa các lượt huấn luyện 67
6.7.1 Hai lượt huấn luyện S1 67
6.7.2 Hai lượt huấn luyện thành phần thứ nhất 68
6.7.3 Độ ổn định khi thay công cụ đánh giá 68
6.8 Khả năng khái quát và độ ổn định khi thay điều kiện đầu vào 69
6.8.1 Đánh giá trên các tác vụ chưa xuất hiện trong huấn luyện S1 . 70
6.8.2 Đánh giá chuyển miền trên AitZ 71
6.8.3 Khi lịch sử thao tác do mô hình tự sinh 72
6.9 Phân tích độ vững của kết quả S1 73
6.10 Phân bố lỗi của mô hình tinh chỉnh có giám sát 75
6.10.1 Kết quả theo mức độ xuất hiện của ứng dụng trong tập huấn luyện 75
6.10.2 Phân loại lỗi còn lại 76
6.10.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh . 76
6.10.4 Đối chiếu với câu chuẩn 77
6.11 Các phương án thiết kế đã khảo sát 77
6.12 Phân tích điểm của câu chuẩn trong quy trình đánh giá 79

7 Kết luận **80**

7.1 Đóng góp chính 80
7.2 Hạn chế 83
7.2.1 Phạm vi của công cụ đo 83
7.2.2 Phạm vi của kết quả về mô hình 83
7.2.3 Phạm vi dữ liệu và thực nghiệm 84
7.3 Tính sẵn có của dữ liệu và mã nguồn 84
7.4 Hướng phát triển 85

8 Các công trình nghiên cứu **86**

Tài liệu tham khảo **88**

A Các phương án thiết kế đã khảo sát **93**

A.1 Sinh mô tả phần tử trước câu hướng dẫn 93

A.1.1 Thiết kế 93

A.1.2 Các cấu hình của thiết kế so sánh ban đầu 96

A.1.3 Kết quả 98

A.2 Học theo cặp ưu tiên trên dòng mô tả 100

A.2.1 Thiết kế 100

A.2.2 Kết quả 101

A.2.3 Phân tích cơ chế mô tả phần tử 102

A.3 Chọn phần tử trong danh sách ứng viên 104

A.3.1 Thiết kế 104

A.3.2 Kết quả 106

A.4 Huấn luyện tăng cường với phần thưởng tọa độ 109

A.4.1 Thiết kế 109

A.4.2 Kết quả 110

A.4.3 Nội suy trọng số giữa hai mô hình 110

A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn 111

A.5.1 Độ ổn định của ước lượng trên nhóm con 113

A.6 Tích hợp thông tin vị trí vào mô hình sinh câu 114

A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE) 114

A.7.1 Thiết kế 114

A.7.2 Kết quả 117

A.8 Trạng thái các cấu hình đã khảo sát 118

Danh mục các hình vẽ, đồ thị

1.1 Bài toán sinh hướng dẫn cho thao tác kế tiếp và cách đánh giá bằng executability. 2

4.1 Quy trình sinh hướng dẫn của phương pháp đề xuất. 21

4.2 Vòng huấn luyện của thành phần thứ nhất, học tăng cường với phần thưởng SPICE. 25

4.3 Hai bước minh họa điều kiện đồng thuận của ACE. 28

5.1 Một bước mà hai tiêu chí đánh giá cho hai kết quả khác nhau. 33

6.1 Một bước được GRPO-SPICE sửa đúng. 56

6.2 Chênh lệch so với S1/101 theo ba tiêu chí đánh giá. 63

A.1 Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE). 117

A.2 Hai bước mà bộ chọn của TAGE nhận câu sửa, cắt phần dưới màn hình. 119

A.3 Tỉ lệ bước bộ định vị trỏ đúng theo nhóm Δlp. 120

Danh mục các bảng số liệu

3.1 Hai bản phân phối trên Hugging Face dùng để ghép câu hướng dẫn với ảnh màn hình. 14

3.2 Quy mô tập huấn luyện và tập kiểm tra. 15

4.1 Cấu hình tinh chỉnh có giám sát. 23

5.1 So sánh các tiêu chí xác định dự đoán đúng. 32

5.2 Kiểm tra độ đo bằng các biến đổi có kết quả mong đợi đã biết trước. . 38

5.3 Điểm khi viết lại câu chuẩn theo bốn biến thể rồi đánh giá lại, tính trên phần bị tác động. 39

5.4 Chênh lệch giữa các mô hình trên cùng 2.532 bước, đánh giá bằng hai mô hình định vị khác nhau. 40

5.5 Phương pháp đề xuất và hai lượt S1 khi đánh giá bằng UI-Venus trên 4.463 bước. 41

5.6 Tỉ lệ chọn đúng phần tử của listener Phi-4 trên 4.463 bước có thao tác chạm. 42

5.7 Điểm của câu chuẩn và chênh lệch giữa S1 với mô hình gốc theo năm tiêu chí đánh giá (698 bước): đĩa Euclid, hình chữ nhật theo từng trục, ô Voronoi, ô Voronoi lấy hạt là tâm hộp chứa g, và hộp gần nhất. g là điểm chạm của người dùng. 44

5.8 Kết luận thống kê theo ba tiêu chí cho cùng một phép so. 45

5.9 Điểm theo tiêu chí hộp phần tử (Phụ lục D.3 của AndroidControl) trên 4.463 bước có thao tác chạm. 46

6.1 Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra. . . . 50

6.2 Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). . . 52
6.3 GRPO-SPICE so với S1/101, ghép cặp theo bước. 54
6.4 ACE trên 4.463 bước có thao tác chạm, so với câu hướng dẫn ban đầu và mô hình sinh câu độc lập. 58
6.5 Nhóm độ đo theo vị trí trên 4.463 bước có thao tác chạm. 60
6.6 Nhóm độ đo so với câu chuẩn trên 4.463 bước có thao tác chạm. . . . 61
6.7 Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và so sánh ghép cặp (dưới). 62
6.8 So sánh ghép cặp trên 4.463 bước. 65
6.9 Mức khác nhau giữa hai lượt huấn luyện S1 chỉ khác seed. 67
6.10 Hai lượt huấn luyện thành phần thứ nhất so với hai seed của S1 trên 4.463 bước. 68
6.11 Kết quả của các nhánh chính khi thay công cụ đánh giá. 69
6.12 Kết quả trên các tác vụ chưa xuất hiện trong huấn luyện S1. 70
6.13 Kết quả chuyển miền trên AitZ. 72
6.14 Executability khi lịch sử do mô hình tự sinh. 72
6.15 Phân tích các cách giải thích cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra. 74
6.16 Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa. 76
6.17 Các phương án thiết kế đã khảo sát. 78

A.1 Ảnh hưởng của bước trung gian trong các công trình trước. 94
A.2 Bốn trường của dòng mô tả phần tử và vai trò của từng trường. 95
A.3 Chất lượng nhãn mô tả ở quy mô đầy đủ so với mẫu thử. 96
A.4 Các cấu hình của thiết kế so sánh ban đầu. 97
A.5 Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không. 98

A.6 Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh. 99
A.7 Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình. 101
A.8 Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. 102
A.9 Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). 103
A.10 Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. 107
A.11 Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng. 107
A.12 Tỉ lệ thẻ `none` theo bốn mẫu số. 108
A.13 Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. 111
A.14 Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm. 112
A.15 Ước lượng lợi ích của can thiệp chỉ thay câu dưới bốn cách định nghĩa nhóm. 113
A.16 Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. 115
A.17 Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE) trên 4.463 bước chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của mô hình học tăng cường với phần thưởng SPICE và với S1. 117
A.18 Trạng thái cuối của các cấu hình đã khảo sát. 120

Danh mục từ viết tắt và thuật ngữ

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
GUI	Graphical User Interface	Giao diện đồ họa người dùng
VLM	Vision-Language Model	Mô hình ngôn ngữ thị giác
LLM	Large Language Model	Mô hình ngôn ngữ lớn
SFT	Supervised Fine-Tuning	Tinh chỉnh có giám sát
LoRA	Low-Rank Adaptation	Tinh chỉnh hạng thấp
QLoRA	Quantized LoRA	LoRA trên trọng số đã lượng tử hoá
NF4	4-bit NormalFloat	Định dạng lượng tử hoá 4 bit
AitW	AndroidInTheWild	Bộ dữ liệu Android quy mô lớn (NeurIPS 2023)
ACU	-	Tập bổ sung gồm các tác vụ AndroidControl không xuất hiện trong tập huấn luyện của S1
OCR	Optical Character Recognition	Nhận dạng văn bản trong ảnh
KTC	Confidence Interval	Khoảng tin cậy

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Exec.	executability	Viết tắt của executability trong các bảng
dp	density-independent pixel	Đơn vị độ dài độc lập mật độ điểm ảnh trên Android
ORPO	Odds Ratio Preference Optimization	Mục tiêu học ưu tiên không cần mô hình tham chiếu riêng
GRPO	Group Relative Policy Optimization	Tối ưu chính sách dựa trên phần thưởng tương đối giữa các đầu ra của cùng một nhóm
KL	Kullback-Leibler divergence	Độ lệch giữa hai phân bố xác suất
SPICE	Semantic Propositional Image Caption Evaluation	Độ đo dựa trên câu chuẩn, so sánh các đối tượng, thuộc tính và quan hệ được trích xuất từ hai câu
BLEU	Bilingual Evaluation Understudy	Độ đo mức lặp lại của cụm từ giữa câu sinh ra và câu chuẩn
METEOR	Metric for Evaluation of Translation with Explicit ORdering	Độ đo ghép từ giữa hai câu, có tính từ đồng nghĩa và biến thể từ
ROUGE-L	Recall-Oriented Understudy for Gisting Evaluation, Longest common subsequence	Độ đo dựa trên chuỗi con chung dài nhất giữa hai câu
CIDEr-D	Consensus-based Image Description Evaluation, bản D	Độ đo trùng lặp cụm từ có trọng số theo độ hiếm của cụm từ, bản D thêm phạt độ dài và giới hạn số lần đếm

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
McNemar	McNemar's test	Kiểm định ghép cặp cho hai tỉ lệ trên cùng các bước
UGround	-	Mô hình định vị chính dùng để tính executability
chrF	character n-gram F-score	Độ đo trùng lặp cụm ký tự giữa hai câu
BERTScore	BERTScore	Độ đo tương đồng ngữ nghĩa giữa hai câu dựa trên biểu diễn của mô hình ngôn ngữ
Thuật ngữ riêng của đề tài		
ACE (*Action-Consistent Exemplar Copying*)		Thành phần hiệu chỉnh của phương pháp đề xuất. ACE truy hồi bốn câu chuẩn từ các bước tương tự trong tập huấn luyện và chỉ thay hướng dẫn ban đầu khi câu ứng viên giống hoàn toàn với một trong các câu được truy hồi và có cùng loại thao tác với hướng dẫn ban đầu (Mục 4.6).
executability (khả năng thực hiện theo hướng dẫn)		Độ đo xem xét liệu một câu hướng dẫn có dẫn tới đúng phần tử cần thao tác hay không. Một câu đạt khi mô hình định vị xác định đúng phần tử mà người dùng đã chạm và câu nêu đúng loại thao tác (Chương 5).

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Mô hình tinh chỉnh có giám sát (S1)		Qwen2.5-VL-3B-Instruct sau khi được tinh chỉnh có giám sát cho bài toán sinh hướng dẫn. S1 là mốc so sánh chính và cũng là mô hình khởi tạo cho giai đoạn học tăng cường của phương pháp đề xuất.
S1/101, S1/202		S1 huấn luyện với seed 101 và seed 202. Base là mô hình gốc Qwen2.5-VL-3B-Instruct chưa tinh chỉnh
GRPO-SPICE		Thành phần thứ nhất của phương pháp đề xuất: S1/101 học tiếp bằng GRPO với phần thưởng SPICE (Mục 4.5)
S2, CE2-S2, MIN-DESC, giai đoạn ba		Các mô hình của hướng mô tả phần tử trước khi sinh câu (Phụ lục A): mô hình mô tả phần tử, mô hình chỉ học thêm có giám sát, mô hình học theo cặp ưu tiên trên dòng mô tả, và giai đoạn thưởng tọa độ
TAGE (*Type-Aware Grounded Editor*)		Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ, một hướng đã thử (Mục A.7)

Viết tắt	Từ đầy đủ	Tiếng Việt / giải thích
Câu chuẩn		Câu hướng dẫn theo từng bước do người thực hiện AndroidControl viết cho bước tương ứng. Câu này được dùng làm mục tiêu trong huấn luyện có giám sát và trong các độ đo dựa trên câu chuẩn.

Trang thông tin luận văn

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn:	Phát sinh tự động hướng dẫn sử dụng phần mềm dựa trên LLM từ các trường hợp sử dụng và giao diện người dùng.
Ngành:	Trí tuệ nhân tạo
Mã số ngành:	8480107
Họ và tên HVCH:	Lê Đoàn Phương Uyên
MSHV:	24C15039
Khóa đào tạo:	34
GVHD:	TS. Nguyễn Hồng Bửu Long
Cơ sở đào tạo:	Trường ĐH Khoa học Tự nhiên, ĐHQG-HCM

1. Tóm tắt nội dung luận văn

Các tác tử giao diện thường nhận đầu vào là ảnh chụp màn hình rồi dự đoán thao tác và vị trí tương tác để tự động thực hiện tác vụ do người dùng yêu cầu. Chúng tôi sử dụng thông tin đầu vào tương tự nhưng hướng tới việc sinh hướng dẫn cho người dùng. Ở mỗi bước, mô hình nhận mục tiêu của tác vụ, các bước đã hoàn thành, ảnh chụp màn hình hiện tại và phần văn bản hiển thị, sau đó tạo một câu hướng dẫn nêu thao tác cần thực hiện và phần tử giao diện cần tương tác. Dữ liệu huấn luyện được xây dựng tự động từ AndroidControl và không yêu cầu gán nhãn thủ công bổ sung. Tập huấn luyện sau khi hợp nhất gồm 64.567 bước.

Phương pháp đề xuất gồm hai thành phần. Đầu tiên, mô hình Qwen2.5-VL-3B sau khi tinh chỉnh có giám sát được tiếp tục huấn luyện bằng GRPO với SPICE làm phần thưởng để sinh hướng dẫn ban đầu. Sau đó, ACE truy hồi bốn câu chuẩn từ các bước

tương tự trong tập huấn luyện và chỉ thay hướng dẫn ban đầu khi câu ứng viên giống hoàn toàn với một trong các câu được truy hồi và có cùng loại thao tác với hướng dẫn ban đầu.

Để đánh giá chất lượng hướng dẫn, chúng tôi xây dựng độ đo khả năng thực hiện theo hướng dẫn (instruction executability), gọi ngắn là executability. Thay vì chỉ so sánh hướng dẫn do mô hình tạo ra với một câu chuẩn, executability sử dụng một mô hình định vị tách biệt với mô hình sinh để kiểm tra liệu câu hướng dẫn có dẫn tới đúng phần tử cần tương tác và đúng loại thao tác hay không. Câu chuẩn đạt 75,7% executability và được dùng làm mốc để diễn giải kết quả. So với S1/101, GRPO-SPICE giữ hướng tăng dưới bốn luật khớp chạm và cả bốn công cụ đánh giá UGround, UI-Venus, Phi-Ground và Phi-4.

Trên 4.463 bước có thao tác chạm của tập kiểm tra AndroidControl, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm (khoảng tin cậy 95% [+0,80; +2,33]) và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Lượt huấn luyện GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11%, bằng S1/101, còn GRPO-SPICE cao hơn nhánh này 1,55 điểm [+0,81; +2,30]. Mức tăng vì vậy không xuất hiện khi điểm SPICE không còn gắn với đúng mẫu, dù số bước huấn luyện được giữ nguyên.

Trên 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48]. Cả sáu thước chữ có khoảng tin cậy trên tập này đều có khoảng tăng nằm trên 0. Khi gộp tập này với tập kiểm tra chính, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99].

ACE đạt 60,68% executability trên tập kiểm tra chính và nâng cả bảy thước dựa trên câu chuẩn. Với sáu thước có khoảng tin cậy, toàn bộ khoảng tăng đều nằm trên 0. Khi lịch sử các bước trước do mô hình tự sinh, GRPO-SPICE vẫn cao hơn S1 1,48 điểm [+0,54; +2,43]. Trên AitZ, S1 cao hơn Base 3,29 điểm [+1,51; +5,03], còn GRPO-SPICE và S1 cho kết quả tương đương về executability với chênh lệch -0,51 điểm [-1,39; +0,36]. Mức cải thiện bổ sung của SPICE chưa xuất hiện rõ trong miền này, trong khi bước tinh chỉnh có giám sát vẫn giữ mức tăng so với mô hình gốc.

2. Những kết quả mới của luận văn

Chúng tôi tập trung vào ba đóng góp chính gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích các phương án thiết kế. Quy trình xây dựng dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ các phần này.

- **Phương pháp sinh hướng dẫn gồm hai thành phần.** Thành phần thứ nhất sử dụng học tăng cường với phần thưởng SPICE để cải thiện hướng dẫn ban đầu. Thành phần thứ hai, ACE, dùng các câu ví dụ truy hồi để hiệu chỉnh đầu ra khi câu ứng viên đáp ứng điều kiện lựa chọn. Trên tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11%, bằng S1/101. Trên 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05] và lượt huấn luyện thứ hai cho mức tăng 4,04 điểm [+2,66; +5,48]. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng. ACE đạt 60,68% executability và cải thiện cả bảy thước dựa trên câu chuẩn. Cả sáu thước có khoảng tin cậy đều cho khoảng tăng nằm trên 0.
- **Độ đo executability và các mốc dùng để diễn giải điểm số.** Executability đánh giá liệu câu hướng dẫn có giúp xác định đúng phần tử cần tương tác và đúng loại thao tác hay không, thay vì chỉ dựa vào mức tương đồng với một câu chuẩn duy nhất. Trên toàn bộ 4.463 bước có thao tác chạm, câu chuẩn đạt 75,7%. Trên mẫu ngẫu nhiên 800 bước dùng để kiểm tra các mốc thấp, câu chuẩn đạt 74,9%, một câu chung chung không xác định phần tử đạt 12,0%, còn câu chuẩn lấy từ một màn hình khác đạt 6,1%. So với S1/101, GRPO-SPICE cao hơn 1,55 điểm dưới UGround, 1,55 điểm dưới UI-Venus, 0,78 điểm dưới Phi-Ground và 0,69 điểm dưới Phi-4. Hướng tăng cũng được giữ dưới bốn luật khớp chạm trên UGround.
- **Kết quả nền tảng hỗ trợ ba đóng góp chính: dữ liệu được xây dựng tự động từ AndroidControl.** Chúng tôi chuyển AndroidControl sang bài toán sinh hướng dẫn bằng cách ghép hai bản phát hành công khai, một bản chứa câu hướng dẫn và một bản chứa ảnh. Tính nhất quán của cách ghép được kiểm tra

bằng cách đối chiếu kết quả khi giữ đúng liên kết giữa hai nguồn và khi dịch liên kết đi một bước. Trong thiết lập mới, câu hướng dẫn từng bước chuyển từ vai trò đầu vào trong AndroidControl thành mục tiêu cần sinh và đánh giá.

- **Phân tích các phương án thiết kế đã khảo sát.** Các thí nghiệm ở Phụ lục A cho thấy chất lượng của biểu diễn trung gian và chất lượng câu hướng dẫn cuối không luôn thay đổi cùng nhau. Phân tích này làm rõ vai trò của mô tả phần tử, thông tin vị trí và cơ chế chọn ứng viên, đồng thời dẫn tới lựa chọn tối ưu trực tiếp câu hướng dẫn trong phương pháp cuối cùng.

CÁN BỘ HƯỚNG DẪN	HỌC VIÊN CAO HỌC
(Ký tên, họ tên)	(Ký tên, họ tên)

XÁC NHẬN CỦA CƠ SỞ ĐÀO TẠO
HIỆU TRƯỞNG

Thesis information

THESIS INFORMATION

Thesis title:	LLM-Based Automatic Generation of Software User Guides from Use Cases and Front-End Structures.
Field of study:	Artificial Intelligence
Code:	8480107
Name:	Le Doan Phuong Uyen
Student ID:	24C15039
Cohort:	34
Supervisor:	Dr. Nguyen Hong Buu Long
Institution:	VNUHCM - University of Science

1. Summary

GUI agents commonly take screenshots as input and predict an action together with an interaction location so that the system can execute a task automatically. This thesis uses a similar input setting but targets user-facing instructions. At each step, the model receives the task goal, preceding steps, the current screenshot and displayed text, then generates one instruction specifying the required action and target interface element. The training data are constructed automatically from AndroidControl without additional manual annotation. The merged training set contains 64,567 steps.

The proposed method has two components. First, Qwen2.5-VL-3B is fine-tuned with supervised learning and then further trained with GRPO using SPICE as the reward to produce the initial instruction. ACE then retrieves four reference instructions from similar training steps and replaces the initial instruction only when a candidate

exactly matches one retrieved exemplar and has the same action type as the initial instruction.

To evaluate instruction quality, we use instruction executability, referred to as executability. Rather than relying only on similarity to a single reference sentence, executability uses a GUI grounding model separate from the generator to test whether an instruction identifies the correct target element and specifies the correct action type. Human-written instructions reach 75.7% executability and serve as a reference point for interpreting model scores. Relative to S1/101, GRPO-SPICE retains a positive gain under four touch-matching rules and across all four evaluators: UGround, UI-Venus, Phi-Ground and Phi-4.

On the 4,463 touch-action steps of the AndroidControl test set, GRPO-SPICE reaches 60.65% executability, 1.55 percentage points above S1/101 with a 95% confidence interval of [+0.80, +2.33] and 1.03 points above S1/202 [+0.25, +1.83]. A second GRPO run reaches 59.94%, 0.83 points above S1/101. A shuffled-reward branch trained for the same 500 GRPO steps reaches 59.11%, exactly the S1/101 level, whereas GRPO-SPICE is 1.55 points higher [+0.81, +2.30]. The gain therefore does not appear from additional training alone when the SPICE signal is shuffled across samples.

On 1,484 steps from tasks absent from the S1 training set, GRPO-SPICE improves over S1 by 4.58 points [+3.17, +6.05], while the second GRPO run improves by 4.04 points [+2.66, +5.48]. All six text measures with confidence intervals also have positive intervals on this set. Combining these steps with the main test set gives a 2.30-point executability gain [+1.62, +2.99].

ACE reaches 60.68% executability on the main test set and improves all seven reference-based text measures, with all six available confidence intervals entirely above zero. With self-generated interaction history, GRPO-SPICE remains 1.48 points above S1 [+0.54, +2.43]. On AitZ, S1 is 3.29 points above Base [+1.51, +5.03], while GRPO-SPICE and S1 are comparable in executability at -0.51 points [-1.39, +0.36]. The additional gain from SPICE is not clear in this domain, while supervised fine-tuning still transfers beyond AndroidControl.

2. Novelty of thesis

The three main contributions are the instruction-generation method, executability, and the analysis of alternative design choices. The automatically constructed AndroidControl data are a foundational result supporting these contributions.

- **A two-component instruction-generation method.** The first component uses reinforcement learning with SPICE reward to improve the initial instruction, while ACE uses retrieved exemplars to revise the output when the candidate meets the selection criteria. On the main test set, GRPO-SPICE reaches 60.65% executability, 1.55 points above S1/101 [+0.80, +2.33] and 1.03 points above S1/202 [+0.25, +1.83]. A shuffled-reward branch trained for the same 500 GRPO steps returns to 59.11%, exactly the S1/101 level. On 1,484 steps from tasks absent from the S1 training set, GRPO-SPICE improves over S1 by 4.58 points [+3.17, +6.05] and the second GRPO run by 4.04 points [+2.66, +5.48]. The grounding model used for evaluation is not part of the reward. ACE reaches 60.68% executability and improves all seven reported reference-based text measures. All six measures with confidence intervals have intervals entirely above zero.

- **Executability and empirical reference points for interpreting the score.** Executability evaluates whether an instruction identifies the correct target element and action type rather than relying only on similarity to a single reference sentence. On all 4,463 touch-action steps, human-written instructions reach 75.7%. In the random sample of 800 steps used to examine low reference points, the human-written instructions reach 74.9%, a generic instruction that does not identify an element scores 12.0%, and an instruction from a different screen scores 6.1%. Relative to S1/101, GRPO-SPICE is 1.55 points higher under UGround, 1.55 under UI-Venus, 0.78 under Phi-Ground and 0.69 under Phi-4. The positive direction is also preserved under four touch-matching rules with UGround.

- **A foundational result supporting the three main contributions: automatically constructed data from AndroidControl.** The thesis reformulates AndroidControl for instruction generation by joining two public releases, one con-

taining instructions and the other screenshots. The consistency of the join is checked by comparing the original linkage with a version in which the linkage is shifted by one step. In the resulting task, the human-written per-step instruction changes from an input in AndroidControl to the generation target and evaluated output.

- **An analysis of alternative design choices.** The experiments in Appendix A show that improving an intermediate representation does not always improve the final instruction. This analysis clarifies the roles of element descriptions, location information and candidate selection, and supports the design choices made in the final method.

SUPERVISOR MASTER'S STUDENT

CERTIFICATION
UNIVERSITY OF SCIENCE
RECTOR

Chương 1

Giới thiệu

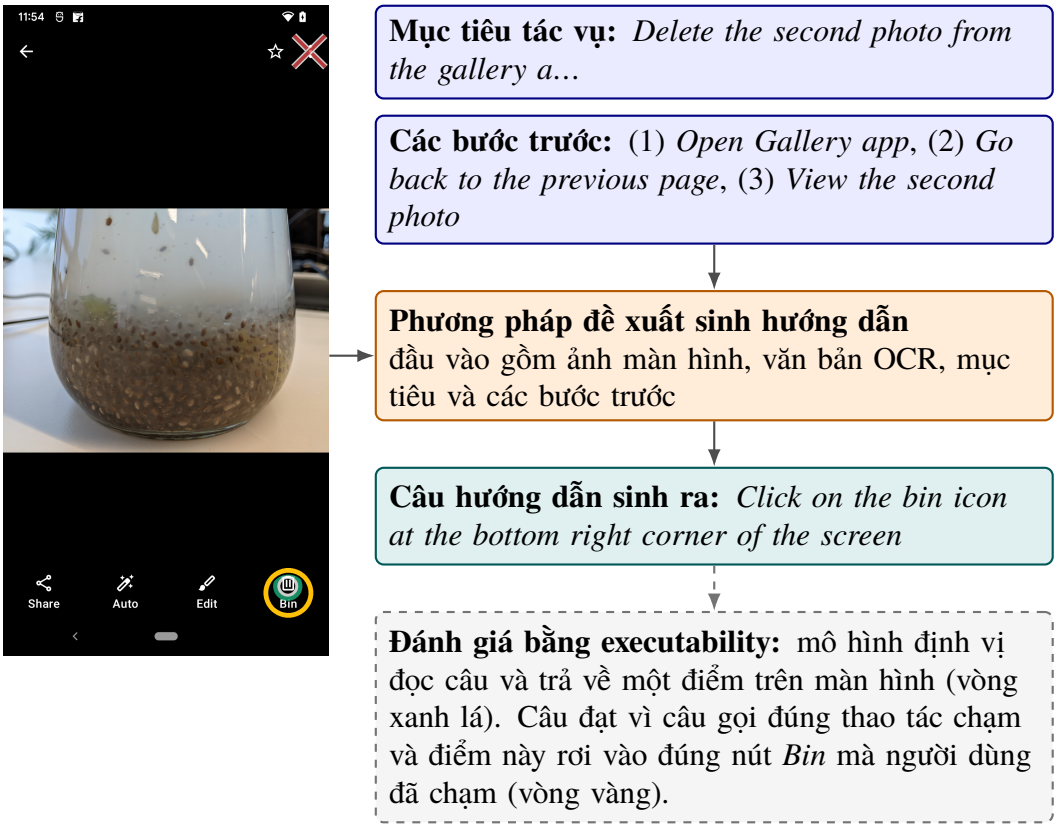
1.1 Đặt vấn đề

Khi thực hiện một tác vụ trên ứng dụng di động, người dùng có thể biết mục tiêu cần đạt nhưng chưa biết phải thao tác như thế nào trên giao diện hiện tại. Trong trường hợp này, một hướng dẫn hữu ích không chỉ cần nêu đúng thao tác, mà còn phải giúp người dùng xác định được phần tử cần tương tác. Chẳng hạn, thay vì chỉ yêu cầu "chia sẻ", hệ thống có thể hướng dẫn "Chạm vào biểu tượng chia sẻ ở góc trên bên phải màn hình".

Các nghiên cứu gần đây về tác tử giao diện người dùng (GUI agent), như SeeClick [3], OS-Atlas [4] và Aguvis [8], cũng giải quyết bài toán hiểu trạng thái giao diện và xác định hành động tiếp theo. Tuy nhiên, các hệ thống này chủ yếu hướng tới việc tự động thực hiện tác vụ: đầu ra thường gồm loại thao tác và vị trí trên màn hình, chẳng hạn `click(872,141)`. Biểu diễn này phù hợp với một tác tử phần mềm, nhưng không trực tiếp tạo ra hướng dẫn để người dùng đọc và làm theo.

Chúng tôi tập trung vào bài toán sinh hướng dẫn cho thao tác kế tiếp bằng ngôn ngữ tự nhiên. Tại mỗi thời điểm, mô hình nhận thông tin về mục tiêu của tác vụ, các thao tác đã được thực hiện trước đó và trạng thái giao diện hiện tại. Trạng thái giao diện được biểu diễn chủ yếu bằng ảnh chụp màn hình cùng phần văn bản đang hiển thị. Từ các thông tin này, mô hình cần sinh một câu hướng dẫn cho biết người dùng nên thực hiện thao tác nào và tương tác với phần tử nào để tiếp tục tác vụ. Hình 1.1 minh họa bài toán trên một bước của tập kiểm tra.

Khác với đầu ra dạng tọa độ, chất lượng của một câu hướng dẫn còn phụ thuộc vào



Hình 1.1: Bài toán sinh hướng dẫn cho thao tác kế tiếp và cách đánh giá bằng executability, minh họa trên một bước của tập kiểm tra. Vòng vàng là điểm người dùng đã chạm. Vòng xanh lá là điểm mà mô hình định vị trả về khi đọc câu do phương pháp đề xuất sinh ra. Dấu X đỏ là điểm trả về cho câu của mô hình gốc chưa tinh chỉnh (*Click on the three dots at the top right corner of the screen to access more options.*), nên câu đó không đạt. Mục tiêu tác vụ được giữ nguyên theo dữ liệu nguồn.

việc người dùng có nhận ra đúng phần tử cần tương tác hay không. Câu "Chạm vào biểu tượng tìm kiếm" vẫn có thể mơ hồ nếu màn hình có nhiều biểu tượng tương tự. Khi đó, hướng dẫn cần thêm thông tin như vị trí, nội dung hiển thị hoặc quan hệ với các thành phần xung quanh. Ở chiều ngược lại, cùng một thao tác có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn hoàn toàn hợp lệ.

Hai vấn đề chính cần giải quyết là đánh giá liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và thao tác cần thực hiện hay không, đồng thời phát triển phương pháp để nâng cao chất lượng hướng dẫn. Executability được xây dựng cho yêu cầu đánh giá này.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Về mặt khoa học, bài toán chúng tôi nghiên cứu có liên hệ gần với hướng sinh biểu thức quy chiếu (*referring expression generation*). Trong bài toán này, một mô tả được xem là hữu ích khi người tiếp nhận có thể dựa vào mô tả đó để nhận ra đúng đối tượng được nhắc tới. Mao và cộng sự [12] đánh giá chất lượng mô tả thông qua một mô hình *listener*. Mô hình nhận câu mô tả và lựa chọn đối tượng mà câu đó đề cập tới. Mô tả được xem là thành công nếu đối tượng được chọn chính là đối tượng mục tiêu. Các nghiên cứu sau đó tiếp tục đưa tín hiệu từ listener vào quá trình huấn luyện nhằm khuyến khích mô hình tạo ra những mô tả có khả năng phân biệt đối tượng tốt hơn [13, 14]. Cách tiếp cận này phù hợp với bài toán sinh hướng dẫn giao diện, bởi một câu hướng dẫn chỉ thực sự hữu ích khi nó giúp người dùng nhận ra đúng phần tử cần thao tác.

Trong miền giao diện người dùng, Widget Captioning [10] cũng xem xét việc mô tả các phần tử trên màn hình, bao gồm những trường hợp có nhiều phần tử giống hoặc gần giống nhau. Tuy nhiên, mục tiêu huấn luyện vẫn chủ yếu dựa trên mức độ phù hợp với câu chuẩn. Một hướng dẫn do mô hình tạo ra có thể gần với câu chuẩn về cách diễn đạt nhưng vẫn chưa đủ rõ để người dùng phân biệt đúng phần tử mục tiêu. Vì vậy, chúng tôi đánh giá thêm khả năng câu hướng dẫn giúp xác định đúng phần tử, thay vì chỉ dựa vào độ tương đồng về từ ngữ.

Khi dùng một mô hình định vị làm công cụ đánh giá, cần kiểm tra độ ổn định của kết quả trước những khác biệt về cách diễn đạt và công cụ đánh giá. ALOHa [15] cho thấy có thể đánh giá đầu ra sinh bằng cách đối chiếu với nguồn thông tin có cấu trúc, thay vì chỉ so sánh trực tiếp với một câu chuẩn. Jandial và cộng sự [18] cũng chỉ ra rằng khả năng định vị có thể thay đổi theo cách một đối tượng được diễn đạt bằng ngôn ngữ. Để tránh phụ thuộc vào một cấu hình đánh giá duy nhất, chúng tôi kiểm tra executability với các biến thể câu và nhiều mô hình định vị.

1.2.2 Động lực ứng dụng

Về mặt ứng dụng, nhu cầu hướng dẫn người dùng thao tác trực tiếp trên giao diện đã xuất hiện trong các hệ thống thực tế. GuideMe [19], chẳng hạn, hỗ trợ người cao tuổi sử dụng điện thoại thông minh bằng cách nhận câu hỏi cùng nội dung màn hình và trả về hướng dẫn cho các thao tác cần thực hiện. Hệ thống này sử dụng một mô hình thương mại cỡ lớn qua mạng và được đánh giá thông qua nghiên cứu người dùng với 18 người tham gia. Tuy nhiên, công trình chưa cung cấp một độ đo tự động để có thể so sánh định lượng các phương pháp sinh hướng dẫn trong quá trình phát triển hệ thống.

Một độ đo tự động có thể được dùng nhất quán qua nhiều lần thử nghiệm sẽ giúp việc so sánh các phương pháp thuận tiện hơn, đặc biệt khi việc thực hiện một nghiên cứu người dùng riêng cho từng thay đổi nhỏ của mô hình là khó khả thi. Bên cạnh đó, ảnh chụp màn hình điện thoại có thể chứa các thông tin nhạy cảm như tin nhắn, danh bạ hoặc dữ liệu tài chính. Mô hình có quy mô vừa phải và có khả năng triển khai cục bộ giúp hạn chế nhu cầu gửi dữ liệu màn hình tới dịch vụ bên ngoài. Trong nghiên cứu này, chúng tôi tập trung vào mô hình ngôn ngữ thị giác cỡ nhỏ thay vì đặt trọng tâm vào các mô hình lớn nhất hiện có.

1.3 Mục đích nghiên cứu

Mục tiêu tổng quát của chúng tôi là nâng cao chất lượng câu hướng dẫn cho thao tác kế tiếp trên giao diện di động, đặc biệt là khả năng giúp người dùng nhận ra đúng phần tử cần tương tác. Để thực hiện mục tiêu này, chúng tôi tập trung vào ba mục tiêu cụ thể:

1. Xây dựng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ, hướng tới câu hướng dẫn nêu rõ thao tác cần thực hiện và đủ cụ thể để phân biệt phần tử mục tiêu với những phần tử tương tự trên màn hình.

2. Xây dựng và đánh giá độ tin cậy của độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability, cho các bước có thao tác

chạm. Thay vì chỉ đo mức độ tương đồng giữa hướng dẫn do mô hình tạo ra và một câu chuẩn, độ đo này xem xét liệu thông tin trong câu hướng dẫn có giúp xác định đúng phần tử và đúng loại thao tác hay không.

3. Tự động xây dựng tập dữ liệu giám sát cho tác vụ sinh hướng dẫn từ AndroidControl [1], không yêu cầu gán nhãn thủ công bổ sung và không sử dụng câu do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

1.4 Khoảng trống nghiên cứu và vị trí của đề tài

Các công trình trên cho thấy hai khoảng trống nghiên cứu liên quan trực tiếp đến đề tài. Phần lớn nghiên cứu về GUI agent tập trung vào dự đoán thao tác hoặc tọa độ cho tác tử phần mềm, thay vì sinh hướng dẫn để con người đọc và thực hiện. Đồng thời, các độ đo dựa trên câu chuẩn không trực tiếp cho biết hướng dẫn do mô hình tạo ra có đủ rõ để xác định đúng phần tử mục tiêu hay không. Chúng tôi giải quyết hai vấn đề này bằng phương pháp sinh hướng dẫn trên mô hình ngôn ngữ thị giác cỡ nhỏ (Chương 4) và executability để đánh giá liệu câu hướng dẫn có xác định đúng phần tử và đúng loại thao tác hay không (Chương 5). Kết quả được phân tích ở Chương 6.

1.5 Nội dung và phạm vi thực hiện đề tài

1.5.1 Nội dung nghiên cứu

Để thực hiện các mục tiêu đã nêu, chúng tôi triển khai bốn nhóm nội dung gồm xây dựng tập giám sát từ AndroidControl, xây dựng và đánh giá độ tin cậy của executability, phát triển phương pháp sinh hướng dẫn, và thực nghiệm so sánh cùng phân tích lỗi. Các phương án thiết kế không thuộc phương pháp cuối được trình bày ở Phụ lục A.

1.5.2 Phạm vi nghiên cứu

Về bài toán, chúng tôi chỉ xét việc sinh hướng dẫn cho thao tác kế tiếp tại trạng thái giao diện hiện tại. Việc lập kế hoạch cho toàn bộ tác vụ hoặc sinh đồng thời một chuỗi

nhiều thao tác không thuộc phạm vi của đề tài.

Về đánh giá, executability được áp dụng cho các bước có thao tác chạm và tập trung vào câu hỏi liệu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Các khía cạnh như độ trôi chảy, độ dài, mức dễ hiểu đối với từng nhóm người dùng và trải nghiệm tổng thể không phải mục tiêu trực tiếp của độ đo này.

Về dữ liệu, các thực nghiệm chính được thực hiện trên AndroidControl với giao diện và câu hướng dẫn bằng tiếng Anh. Khả năng khái quát được kiểm tra thêm theo hai hướng: các tác vụ AndroidControl không xuất hiện trong tập huấn luyện của S1 và bộ dữ liệu AitZ thuộc một phân phối khác. Các câu tiếng Việt xuất hiện trong phần trình bày chỉ được dùng để minh họa cho bài toán.

Về mô hình, hệ thống sinh được phát triển từ Qwen2.5-VL-3B-Instruct [34] và được tinh chỉnh bằng QLoRA [30] hoặc LoRA trong điều kiện một GPU. Việc giữ cố định mô hình nền giúp các thực nghiệm tập trung vào ảnh hưởng của dữ liệu và các chiến lược tinh chỉnh trong cùng một thiết lập tính toán.

1.6 Đóng góp chính

Chúng tôi tập trung vào ba đóng góp chính, gồm phương pháp sinh hướng dẫn, độ đo executability và phân tích thực nghiệm các phương án thiết kế. Bên cạnh đó, quy trình xây dựng dữ liệu tự động từ AndroidControl là kết quả nền tảng phục vụ toàn bộ quá trình huấn luyện và đánh giá.

Thứ nhất, chúng tôi đề xuất một phương pháp sinh hướng dẫn gồm hai thành phần nối tiếp trên nền Qwen2.5-VL-3B. Thành phần thứ nhất tiếp tục tối ưu mô hình đã được tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE. Thành phần thứ hai, ACE, sử dụng các câu ví dụ truy hồi để hiệu chỉnh câu hướng dẫn khi câu ứng viên đáp ứng các điều kiện lựa chọn. Thiết kế được trình bày ở Chương 4, còn kết quả thực nghiệm nằm ở Chương 6.

Trên 4.463 bước có thao tác chạm của tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202

1,03 điểm [+0,25; +1,83]. Lượt GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11%, bằng S1/101. GRPO-SPICE cao hơn nhánh này 1,55 điểm [+0,81; +2,30], nên mức tăng không xuất hiện khi điểm SPICE không còn gắn với đúng mẫu dù số bước huấn luyện được giữ nguyên.

Trên 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm [+3,17; +6,05], gần gấp ba mức 1,55 điểm trên tập kiểm tra chính. Lượt GRPO thứ hai tiếp tục cho cùng chiều với mức tăng 4,04 điểm [+2,66; +5,48]. Khi gộp tập này với tập kiểm tra chính, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99].

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 1,55 điểm dưới UGround, 1,55 điểm dưới UI-Venus, 0,78 điểm dưới Phi-Ground và 0,69 điểm dưới Phi-4. So với Qwen2.5-VL-7B chỉ dùng prompting, GRPO-SPICE trên mô hình 3B cao hơn 9,14 điểm executability. ACE đạt 60,68% executability trên tập kiểm tra chính, đồng thời tăng cả bảy thước dựa trên câu chuẩn. Với sáu thước có khoảng tin cậy, toàn bộ khoảng tăng đều nằm trên 0.

Khi lịch sử các bước trước do chính mô hình sinh, GRPO-SPICE vẫn cao hơn S1 1,48 điểm executability [+0,54; +2,43]. Trên AitZ, S1 cao hơn Base 3,29 điểm [+1,51; +5,03], còn GRPO-SPICE và S1 tương đương về executability với chênh lệch -0,51 điểm [-1,39; +0,36]. Mức cải thiện bổ sung của SPICE chưa xuất hiện rõ trong miền này, trong khi bước tinh chỉnh có giám sát vẫn giữ mức tăng so với mô hình gốc. Các kết quả và phép kiểm tương ứng được trình bày ở Chương 6.

Thứ hai, chúng tôi xây dựng executability cho các bước có thao tác chạm. Độ đo này sử dụng một mô hình định vị tách biệt để kiểm tra liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử và đúng loại thao tác hay không. Chương 5 trình bày định nghĩa, độ tin cậy của cách đo và các kiểm tra độ ổn định trước khi executability được dùng để so sánh các mô hình sinh.

Thứ ba, chúng tôi phân tích nhiều phương án thiết kế đã được khảo sát trước khi lựa chọn phương pháp cuối cùng, gồm mô tả phần tử, học theo cặp ưu tiên, sử dụng thông tin tọa độ, chọn ứng viên và hiệu chỉnh câu theo vùng ảnh. Các phân tích cho thấy chất lượng của biểu diễn trung gian và chất lượng của câu hướng dẫn cuối không

luôn thay đổi cùng nhau. Vì vậy, phương pháp cuối cùng chuyển trọng tâm sang tối ưu trực tiếp câu hướng dẫn. Kết quả tổng hợp được trình bày ở Mục 6.11, còn thiết kế chi tiết nằm trong Phụ lục A.

Bên cạnh ba đóng góp chính, chúng tôi xây dựng một tập dữ liệu giám sát cho bài toán sinh hướng dẫn từ AndroidControl bằng quy trình tự động hợp nhất hai bản phân phối công khai, trong đó một bản chứa câu hướng dẫn và một bản chứa ảnh màn hình. Quy trình không yêu cầu gán nhãn thủ công bổ sung và có bước kiểm tra tính nhất quán sau hợp nhất bằng cách đối chiếu kết quả khi giữ đúng liên kết giữa hai nguồn và khi dịch liên kết đi một bước. Quy trình xây dựng dữ liệu được trình bày ở Chương 3.

Chương 2

Tổng quan

Chương này trình bày các khái niệm và công trình nền tảng trực tiếp liên quan đến luận văn. Các nội dung chính gồm mô hình ngôn ngữ thị giác, LoRA và QLoRA, GRPO và SPICE, định vị phần tử giao diện, bộ dữ liệu AndroidControl và hạn chế của các độ đo dựa trên một câu chuẩn. Cấu hình cụ thể của mô hình và cách đánh giá được trình bày lần lượt ở Chương 4 và Chương 5.

2.1 Mô hình ngôn ngữ thị giác

Bài toán chúng tôi nghiên cứu yêu cầu mô hình xử lý đồng thời hai nguồn thông tin. Ảnh chụp màn hình cung cấp trạng thái trực quan của giao diện, trong khi phần văn bản mô tả mục tiêu của tác vụ, các thao tác đã thực hiện trước đó và nội dung chữ xuất hiện trên màn hình. Vì vậy, mô hình sinh không chỉ cần hiểu ngôn ngữ mà còn phải liên kết nội dung văn bản với các thành phần trực quan trên giao diện.

Mô hình ngôn ngữ thị giác (*vision-language model*, VLM) được thiết kế cho kiểu đầu vào này. Thông thường, ảnh được chuyển thành các đặc trưng hoặc token thị giác, sau đó được tích hợp với chuỗi token văn bản để mô hình có thể suy luận và sinh đầu ra dựa trên cả hai nguồn thông tin. Phần sinh ngôn ngữ thường dựa trên kiến trúc Transformer [32], trong đó cơ chế tự chú ý giúp mô hình học quan hệ giữa các phần tử trong chuỗi đầu vào.

Chúng tôi sử dụng Qwen2.5-VL-3B-Instruct [34] làm mô hình nền vì mô hình có trọng số mở, quy mô khoảng ba tỉ tham số phù hợp với điều kiện thử nghiệm và triển khai cục bộ, đồng thời hỗ trợ xử lý ảnh với độ phân giải động. Khả năng này phù hợp

với ảnh chụp màn hình điện thoại, vốn có tỉ lệ và kích thước thay đổi. Cấu hình sử dụng cụ thể của Qwen2.5-VL-3B-Instruct được trình bày ở Chương 4.

2.2 Tinh chỉnh hiệu quả tham số bằng LoRA và QLoRA

Tinh chỉnh toàn bộ một mô hình ngôn ngữ thị giác đòi hỏi lượng bộ nhớ lớn vì quá trình huấn luyện không chỉ lưu trọng số mô hình mà còn cần gradient và trạng thái của bộ tối ưu. LoRA [29] giảm chi phí này bằng cách giữ cố định trọng số gốc và chỉ học một cập nhật có hạng thấp. Với ma trận trọng số $W \in \mathbb{R}^{d\times k}$, trọng số sau khi áp dụng LoRA được viết dưới dạng

$$W' = W + \frac{\alpha}{r}BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k), \tag{2.1}$$

trong đó r là hạng của cập nhật và α là hệ số tỉ lệ. Thay vì cập nhật toàn bộ dk tham số của ma trận W, LoRA chỉ cần học $r(d+k)$ tham số trong hai ma trận A và B.

QLoRA [30] tiếp tục giảm nhu cầu bộ nhớ bằng cách kết hợp LoRA với lượng tử hóa trọng số nền xuống 4 bit. Trong đó, định dạng NormalFloat (NF4) được thiết kế cho phân bố trọng số của mạng nơ-ron. Trong quá trình huấn luyện, trọng số nền vẫn được giữ cố định ở dạng lượng tử hóa, còn gradient chỉ cập nhật các tham số LoRA ở độ chính xác cao hơn. Cách làm này giúp tinh chỉnh các mô hình có kích thước lớn hơn trong điều kiện tài nguyên hạn chế. Trong nghiên cứu này, chúng tôi sử dụng QLoRA cho các lượt tinh chỉnh trực tiếp từ Qwen2.5-VL-3B-Instruct. Các giai đoạn học tiếp của phương pháp có cấu hình riêng ở Chương 4.

2.3 GRPO và phần thưởng dựa trên độ đo văn bản

Trong tinh chỉnh có giám sát, mô hình học bằng cách tăng xác suất của câu chuẩn tương ứng với mỗi đầu vào. Cách huấn luyện này phù hợp để hình thành khả năng sinh ban đầu, nhưng không trực tiếp phân biệt chất lượng giữa nhiều câu mà mô hình có thể sinh cho cùng một trường hợp. Học tăng cường bổ sung tín hiệu này bằng cách

gán phần thưởng cho từng đầu ra và cập nhật mô hình dựa trên chất lượng tương đối giữa các đầu ra.

Tối ưu chính sách tương đối theo nhóm (*Group Relative Policy Optimization*, GRPO) được giới thiệu trong DeepSeekMath [41]. Với mỗi đầu vào x, mô hình sinh một nhóm gồm G đầu ra $y_1, \ldots, y_G$ và nhận các phần thưởng tương ứng $r_1, \ldots, r_G$. Lợi thế của đầu ra thứ i được xác định bằng cách chuẩn hóa phần thưởng trong cùng nhóm:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G})}, \tag{2.2}$$

sau đó chính sách được cập nhật dựa trên lợi thế tương đối này, đồng thời có số hạng kiểm soát mức sai lệch so với mô hình tham chiếu. GRPO không cần huấn luyện thêm một mô hình ước lượng giá trị riêng. Khi các đầu ra trong cùng nhóm nhận phần thưởng giống nhau, lợi thế tương đối giữa chúng cũng không tạo ra khác biệt cho bước cập nhật.

Trong phương pháp đề xuất, chúng tôi xây dựng phần thưởng cho GRPO từ SPICE [24]. Đây là một độ đo dựa trên câu chuẩn, trong đó nội dung câu được biểu diễn thông qua các đối tượng, thuộc tính và quan hệ, sau đó so sánh các thành phần tương ứng bằng điểm F1. Zhao và cộng sự [37] đã sử dụng SPICE khi đánh giá mô hình sinh chỉ dẫn. Trong nghiên cứu này, SPICE được dùng làm tín hiệu phần thưởng ở mức nội dung cho câu hướng dẫn. Cách xây dựng phần thưởng và quy trình huấn luyện GRPO được trình bày cụ thể ở Mục 4.5.

2.4 Định vị phần tử giao diện

Định vị phần tử giao diện (*GUI grounding*) là bài toán xác định vị trí của một phần tử trên màn hình từ ảnh giao diện và một mô tả bằng ngôn ngữ. Đầu ra thường được biểu diễn dưới dạng một điểm hoặc một khung bao quanh phần tử mục tiêu. Một số mô hình tiêu biểu cho hướng nghiên cứu này gồm SeeClick [3], OS-Atlas [4] và UGround [5].

Bài toán định vị giúp kiểm tra trực tiếp mối liên hệ giữa câu mô tả và phần tử mà câu đó hướng tới. Nếu câu hướng dẫn cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử khác trên màn hình, một mô hình định vị có thể được dùng để suy

ra phần tử mà câu đang mô tả. Mối liên hệ này là cơ sở cho executability mà chúng tôi sử dụng. Chương 5 trình bày mô hình định vị được lựa chọn, tiêu chí xác định một dự đoán đúng và các bước kiểm tra độ tin cậy trước khi dùng mô hình này để đánh giá câu hướng dẫn.

2.5 Bộ dữ liệu AndroidControl

AndroidControl [1] là bộ dữ liệu do Google DeepMind công bố tại NeurIPS 2024 và phát hành theo giấy phép Apache 2.0. Bộ dữ liệu gồm 15.283 chuỗi thao tác do người thật thực hiện trên thiết bị Pixel trong khoảng một năm. Ở mỗi bước, dữ liệu lưu trạng thái màn hình, loại thao tác, tọa độ chạm khi có và trường `step_instructions`, tức câu hướng dẫn do người thực hiện viết cho thao tác tương ứng.

Trong công trình AndroidControl và các nghiên cứu về tác tử giao diện sử dụng bộ dữ liệu này, như Aguvis [8], câu hướng dẫn thường được đưa vào làm đầu vào để mô hình dự đoán thao tác cần thực hiện. Chúng tôi sử dụng dữ liệu theo chiều ngược lại: trạng thái tác vụ và giao diện được dùng làm đầu vào, còn câu hướng dẫn cho thao tác kế tiếp là đầu ra cần sinh. Nhờ đó, AndroidControl có thể được chuyển thành tập dữ liệu giám sát cho bài toán sinh hướng dẫn mà không cần thu thập lại toàn bộ dữ liệu từ đầu. Quy trình hợp nhất, làm sạch và phân chia dữ liệu được trình bày ở Chương 3.

2.6 Độ đo dựa trên câu chuẩn trong bài toán sinh hướng dẫn

Một thao tác trên giao diện có thể được diễn đạt bằng nhiều câu khác nhau mà vẫn dẫn người dùng tới cùng một phần tử. Vì vậy, một câu chuẩn chỉ phản ánh một trong nhiều cách mô tả có thể chấp nhận được. Các độ đo phụ thuộc nhiều vào mức giống nhau về từ vựng có thể đánh giá thấp một câu diễn đạt khác với câu chuẩn dù nội dung hướng dẫn vẫn đúng. Chẳng hạn, cùng một phần tử có thể được mô tả là “more options button” trong một câu và “three-dot icon” trong một câu khác.

Các độ đo tương đồng ngữ nghĩa có thể giảm bớt sự phụ thuộc vào từ ngữ cụ thể,

nhưng không được thiết kế để kiểm tra trực tiếp liệu câu hướng dẫn có giúp xác định đúng phần tử cần thao tác hay không. Hai câu có thể gần nhau về nghĩa nhưng lại quy chiếu tới hai phần tử khác nhau trên cùng màn hình, chẳng hạn "inbox" và "outbox". Ngược lại, hai cách diễn đạt khác nhau đáng kể vẫn có thể cùng quy chiếu tới một phần tử. Vì vậy, mức độ gần nhau trong không gian ngữ nghĩa không bảo đảm hai câu sẽ dẫn tới cùng một đối tượng trên giao diện.

Vì vậy, bên cạnh các độ đo dựa trên câu chuẩn, chúng tôi đánh giá trực tiếp mối quan hệ giữa hướng dẫn do mô hình tạo ra và phần tử mà hướng dẫn đó mô tả. Chương 5 trình bày executability và các phép kiểm độ tin cậy của cách đo.

Chương 3

Xây dựng bộ dữ liệu

Chương này trình bày cách hợp nhất các nguồn dữ liệu, cách chia tập huấn luyện và tập kiểm tra, thông tin giao diện được sử dụng, cùng dữ liệu dành cho từng giai đoạn của phương pháp. Toàn bộ quá trình xây dựng dữ liệu được tự động hóa, không yêu cầu gán nhãn thủ công bổ sung và không dùng nhãn do một mô hình ngôn ngữ khác sinh ra làm mục tiêu huấn luyện.

3.1 Nguồn dữ liệu và cách hợp nhất

Để xây dựng dữ liệu, chúng tôi sử dụng câu hướng dẫn theo từng bước, ảnh chụp màn hình và cây trợ năng. Cây trợ năng chỉ cần thiết ở một số bước tiền xử lý. Hai bản phân phối trên Hugging Face cung cấp các thành phần bổ sung cho nhau, nên chúng tôi kết hợp chúng để ghép câu hướng dẫn với ảnh màn hình như trình bày ở Bảng 3.1. Cây trợ năng được lấy riêng từ bản phát hành gốc của AndroidControl.

Bảng 3.1: Hai bản phân phối trên Hugging Face dùng để ghép câu hướng dẫn với ảnh màn hình.

Bản phát hành	**Có**	**Thiếu**
`HarrytheOrange/parsed_AndroidControl`	câu hướng dẫn theo từng bước	không có ảnh
`ckg/AndroidControlParsedWithImages-20k`	ảnh màn hình	không có câu hướng dẫn theo bước

Hai bản được ghép theo cặp mã tác vụ và số thứ tự bước, `(episode_id,`

step_id). Cây trợ năng của 99.131 màn hình được lấy riêng từ bản phát hành gốc.

3.2 Kiểm tra tính nhất quán của dữ liệu sau hợp nhất

Khi hợp nhất hai nguồn, điểm cần kiểm tra quan trọng là ảnh và câu hướng dẫn có cùng số thứ tự bước hay không. Sai lệch ở bước này có thể không làm thay đổi số lượng bản ghi, nên chúng tôi bổ sung một phép kiểm dựa trên mức độ phù hợp giữa nội dung ảnh và câu hướng dẫn.

Với mỗi bước có thao tác chạm, chúng tôi lấy phần văn bản OCR tại vị trí chạm và kiểm tra xem văn bản này có xuất hiện trong câu hướng dẫn hay không. Nếu ảnh và câu hướng dẫn thuộc cùng một bước, tín hiệu này được kỳ vọng xuất hiện thường xuyên hơn so với khi dịch số thứ tự câu hướng dẫn đi một bước.

Trong 400 bước được kiểm tra, 193 bước có văn bản tại vị trí chạm xuất hiện trong câu hướng dẫn, tương ứng 48%. Khi dịch số thứ tự câu hướng dẫn đi một bước, 311 trường hợp còn đủ dữ liệu để tạo cặp so sánh. Trong số này, 61 trường hợp vẫn có văn bản tại vị trí chạm xuất hiện trong câu hướng dẫn, tương ứng 20%. Như vậy, tỉ lệ quan sát được khi giữ đúng liên kết giữa hai nguồn cao khoảng 2,4 lần so với khi dịch liên kết đi một bước.

Phép kiểm này được dùng để xác nhận tính nhất quán của liên kết theo (episode_id, step_id) sau khi hợp nhất hai nguồn dữ liệu.

3.3 Quy mô và phân chia dữ liệu

Bảng 3.2: Quy mô tập huấn luyện và tập kiểm tra.

	Tập huấn luyện	**Tập kiểm tra**
Số bước	64.567	6.958
Số bước có thao tác chạm	41.191 (63,8%)	4.463 (64,1%)
Số tác vụ	12.895	1.432
Độ phủ OCR	100%	100%

Các kết quả executability ở Chương 5 và Chương 6 được tính trên nhóm bước có thao tác chạm trong Bảng 3.2. Các loại bước còn lại được phân tích riêng khi cần.

Dữ liệu được chia theo tác vụ, nghĩa là tất cả các bước của cùng một tác vụ chỉ nằm trong một tập. Cách chia này tránh để các màn hình liên tiếp của cùng một chuỗi thao tác xuất hiện ở cả tập huấn luyện và tập kiểm tra. Đối chiếu mã tác vụ cho thấy không có tác vụ nào xuất hiện ở cả hai tập.

Tập kiểm định nội bộ. S1 ban đầu được huấn luyện trên toàn bộ tập huấn luyện ở Bảng 3.2. Sau khi giai đoạn này hoàn tất, 1.567 bước được tách theo tác vụ để tạo tập kiểm định nội bộ. Nếu một tác vụ được chọn thì toàn bộ các bước của tác vụ đó đều được đưa vào tập này. 63.000 bước còn lại được dùng cho các giai đoạn sau. Tập kiểm định nội bộ phục vụ việc lựa chọn số bước huấn luyện của GRPO-SPICE và điều kiện của ACE (Mục 4.5 và Mục 4.6). Vì phần dữ liệu này đã xuất hiện trong quá trình huấn luyện S1, các điểm trên tập kiểm định nội bộ chỉ được dùng để lựa chọn cấu hình cho các giai đoạn sau, không được dùng làm kết quả đánh giá cuối cùng.

Quan hệ với cách chia chính thức của AndroidControl. Tập huấn luyện và tập kiểm tra của đề tài theo cách chia của bản phân phối có ảnh từ `ckg` và được tách biệt hoàn toàn theo mã tác vụ. Trong các tác vụ của tập kiểm tra, 1.287 tác vụ thuộc phần huấn luyện chính thức của AndroidControl, 131 thuộc phần kiểm tra và 14 thuộc phần kiểm định. Do đó, các so sánh trong luận văn được thực hiện nhất quán trên tập kiểm tra cố định của đề tài và được diễn giải theo cách chia này. Trong các chương sau, tập này được gọi là *tập kiểm tra của đề tài*.

Tập tác vụ bổ sung chưa xuất hiện trong huấn luyện S1 (ACU). Để kiểm tra khả năng khái quát sang tác vụ mới trong cùng nguồn AndroidControl, chúng tôi xây dựng thêm ACU gồm 1.484 bước có thao tác chạm từ các tác vụ không xuất hiện trong tập huấn luyện của S1. Tập này được dựng từ TFRecord gốc và được đánh giá tách biệt với tập kiểm tra chính. Trong 1.484 bước, 1.383 bước thuộc phần huấn luyện theo cách chia chính thức của AndroidControl. Vì vậy, ACU được dùng cụ thể để kiểm tra trường hợp mã tác vụ chưa xuất hiện trong huấn luyện S1. Kết quả trên ACU được trình bày ở Chương 6.

3.4 Xây dựng thông tin đầu vào từ giao diện

Ảnh màn hình và văn bản OCR là hai nguồn thông tin được đưa vào mô hình. Ảnh cung cấp thông tin thị giác, còn OCR bổ sung phần chữ hiển thị trên giao diện. Cây trợ năng chỉ được dùng khi xây dựng dữ liệu và thực hiện một số phân tích, không được đưa vào mô hình khi suy luận ở Chương 4. Văn bản OCR được giữ nguyên từ dữ liệu nguồn, không được sửa thủ công theo từng màn hình.

3.5 Dữ liệu phục vụ phương pháp đề xuất

Dữ liệu được sử dụng cho bốn phần của phương pháp đề xuất gồm huấn luyện S1, học tăng cường, học thêm mô hình sinh câu ứng viên của ACE và xây dựng kho truy hồi ACE. Mục này làm rõ dữ liệu dùng cho từng phần. Chi tiết huấn luyện, truy hồi và lựa chọn đầu ra được trình bày ở Chương 4.

Tập huấn luyện có giám sát cho S1. S1 được huấn luyện trên toàn bộ tập huấn luyện ở Bảng 3.2 để sinh câu hướng dẫn theo bước của AndroidControl. Tập này gồm 64.445 bản ghi có câu hướng dẫn không rỗng và 122 bản ghi rỗng từ dữ liệu nguồn, tương ứng 0,19% tổng số bước. S1 được dùng làm mô hình khởi tạo cho các giai đoạn tiếp theo của phương pháp đề xuất.

Dữ liệu cho giai đoạn học tăng cường với phần thưởng SPICE. Phần dữ liệu còn lại sau khi tách tập kiểm định nội bộ ở Mục 3.3 được dùng cho các giai đoạn huấn luyện tiếp theo. Giai đoạn học tăng cường sử dụng prompt và câu chuẩn từ phần dữ liệu này. Câu chuẩn được dùng để tính phần thưởng SPICE. Cách lấy mẫu và số bước cập nhật được trình bày ở Mục 4.5.

Dữ liệu để học thêm mô hình sinh câu ứng viên của ACE. Ngoài kho truy hồi, ACE có một lượt tinh chỉnh có giám sát để mô hình học cách sử dụng khối ví dụ. Lượt này sử dụng toàn bộ 3.991 bước có ảnh khả dụng cho giai đoạn huấn luyện. Thiết lập huấn luyện được trình bày ở Mục 4.6.

Kho truy hồi cho ACE. Kho truy hồi ACE được xây dựng từ cùng phần dữ liệu còn lại sau khi tách tập kiểm định nội bộ. Vì mỗi bản ghi trong kho cần một câu hướng

dẫn để làm ví dụ, 120 bản ghi có `target_instruction` rỗng được loại. Hai bản ghi rỗng còn lại trong tổng số 122 bản ghi nêu trên nằm trong tập kiểm định nội bộ. Kho cuối cùng gồm 62.880 bước thuộc 12.542 tác vụ. Kho không chứa tác vụ nào của tập kiểm tra của đề tài, nên ACE không truy cập câu chuẩn của bước đang được đánh giá. Cách truy hồi được trình bày ở Mục 4.6.

3.6 Một số đặc điểm của dữ liệu

Bên cạnh cách chia theo tác vụ, ba đặc điểm dưới đây giúp làm rõ phân bố dữ liệu khi đọc các kết quả ở Chương 6.

Cách biểu diễn mục tiêu tác vụ trong dữ liệu nguồn. Trong dữ liệu nguồn, 99,0% mô tả mục tiêu tác vụ bị cắt giữa một cụm từ. Các thực nghiệm sử dụng nguyên trường mục tiêu được cung cấp và giữ cách xử lý này nhất quán giữa tập huấn luyện và tập kiểm tra.

Mức lặp lại của cách diễn đạt. Chúng tôi so sánh toàn bộ câu chuẩn của tập kiểm tra với 64.445 câu hướng dẫn không rỗng ở tập huấn luyện. Sau khi loại khoảng trắng ở đầu và cuối chuỗi, 45,5% câu kiểm tra có cùng chuỗi ký tự với ít nhất một câu trong tập huấn luyện. Khi xét các cụm bốn token liên tiếp, 77,7% câu kiểm tra có ít nhất một cụm đã xuất hiện trong tập huấn luyện. Hai tập không có mã tác vụ chung, nên các số liệu này mô tả mức độ lặp lại về cách diễn đạt thay vì sự lặp lại tác vụ. Một phần mức lặp ở các cụm bốn token có thể đến từ những khuôn câu thường gặp trong hướng dẫn giao diện. Các thống kê này được dùng để mô tả phân bố ngôn ngữ của dữ liệu, không dùng để suy ra lợi ích của một phương pháp cụ thể.

Phạm vi phân tích theo ứng dụng. Tên ứng dụng xác định được cho 45,0% số bước của tập kiểm tra. Trong nhóm này, 95,6% số bước thuộc về ứng dụng đã xuất hiện trong tập huấn luyện. Nếu tính theo số ứng dụng riêng biệt, tỉ lệ là 91,8%. Vì vậy, phân tích theo ứng dụng chủ yếu phản ánh các tác vụ mới trên những ứng dụng mô hình đã gặp trong tập huấn luyện. Các bước không xác định được tên ứng dụng mang nhãn "không biết" và không được xếp vào nhóm đã thấy hoặc chưa thấy. Các phân tích tương ứng ở Chương 6 chỉ sử dụng phần dữ liệu xác định được ứng dụng.

Các nhãn mô tả phần tử, tập cặp ưu tiên và danh sách ứng viên chỉ phục vụ các

phương án đã khảo sát trước phương pháp cuối. Cách xây dựng và kiểm tra các dữ liệu này được trình bày cùng từng phương án ở Phụ lục A.

Chương 4

Phương pháp đề xuất

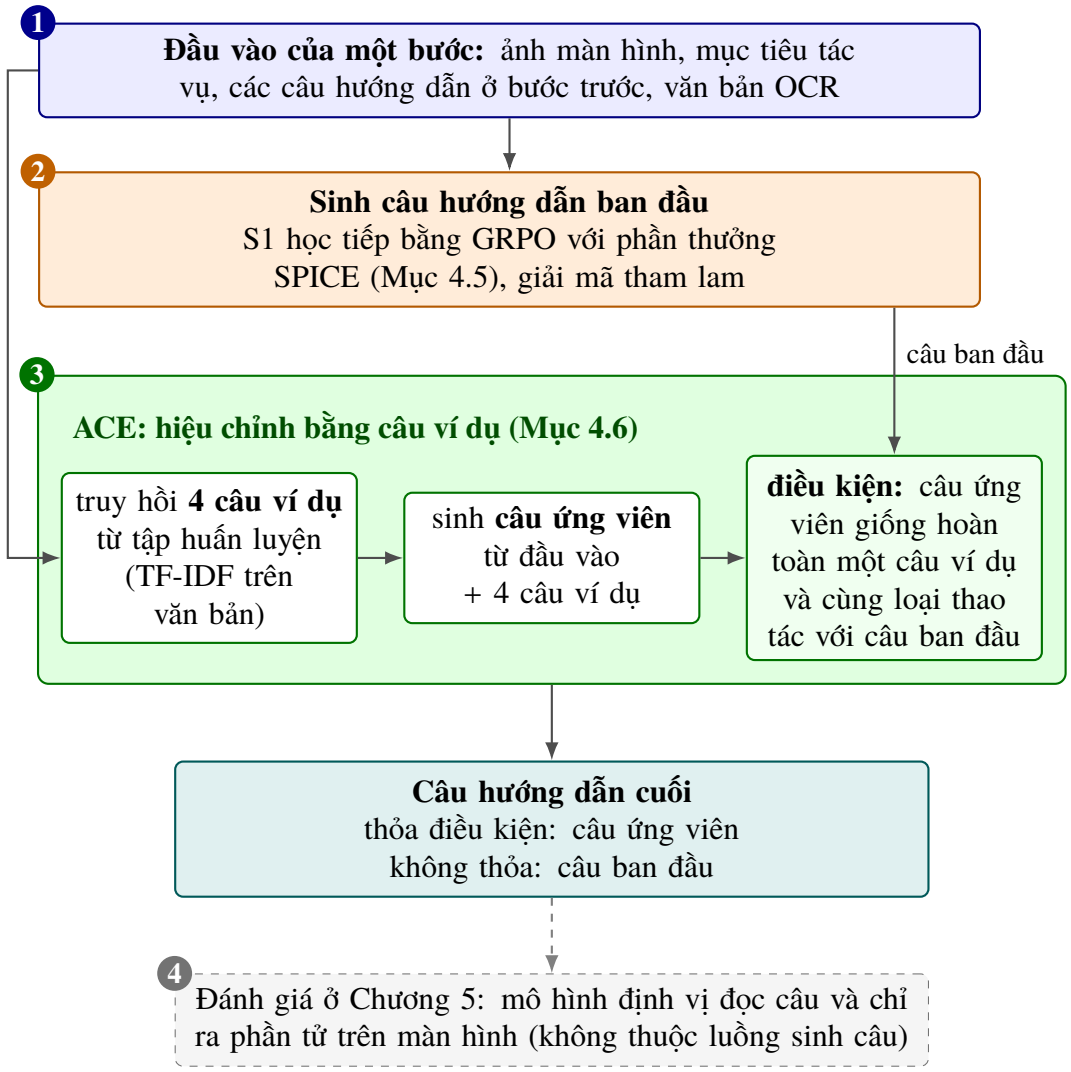
Chương này trình bày phương pháp sinh hướng dẫn của chúng tôi. Sau phần mô tả luồng xử lý, đầu vào và cấu hình huấn luyện, chương đi vào hai thành phần chính là học tăng cường với phần thưởng SPICE và ACE, rồi nêu các mốc so sánh và thiết lập đánh giá. Các phương án đã khảo sát trước phương pháp cuối cùng được trình bày ở Phụ lục A. Độ đo executability được trình bày riêng ở Chương 5.

4.1 Quy trình tổng thể

Với ảnh chụp màn hình và mục tiêu tác vụ, hệ thống cần tạo một câu hướng dẫn bằng tiếng Anh cho bước tiếp theo. Hình 4.1 tóm tắt luồng sinh hướng dẫn và nhánh đánh giá.

1. **Đầu vào:** ảnh chụp màn hình, mục tiêu tác vụ, lịch sử tham chiếu của các bước trước và văn bản OCR.
2. **Sinh hướng dẫn ban đầu:** S1 sau khi học tiếp bằng GRPO với phần thưởng SPICE tạo câu hướng dẫn ban đầu.
3. **Hiệu chỉnh bằng ACE:** các câu ví dụ được truy hồi từ tập huấn luyện được dùng để tạo một câu ứng viên. Điều kiện đồng thuận quyết định có thay câu hướng dẫn ban đầu hay không.
4. **Đánh giá:** mô hình định vị nhận ảnh màn hình cùng câu hướng dẫn và dự đoán vị trí của phần tử được nhắc tới. Executability được xác định từ vị trí này và loại thao tác trong câu.

Ba bước đầu thuộc luồng tạo câu hướng dẫn cuối cùng. Khâu đánh giá được thực hiện riêng và không tham gia vào quá trình suy luận.



Hình 4.1: Quy trình sinh hướng dẫn của phương pháp đề xuất. Số trên mỗi khối ứng với bốn bước liệt kê ở trên. Khối xanh dương là đầu vào. Khối cam sinh câu hướng dẫn ban đầu. Khối xanh lá là ACE: truy hồi câu ví dụ từ mục tiêu và các bước trước, sinh câu ứng viên rồi kiểm tra điều kiện đồng thuận, và câu ứng viên chỉ thay câu ban đầu khi thỏa cả hai điều kiện. Khối xanh ngọc là câu hướng dẫn cuối. Khối nét đứt là khâu đánh giá ở Chương 5, không thuộc luồng suy luận.

Ở giai đoạn suy luận, phương pháp sử dụng ảnh màn hình, mục tiêu, lịch sử tham chiếu, văn bản OCR, mô hình sinh và kho câu chuẩn của tập huấn luyện dùng cho ACE. Cây trợ năng và mô hình định vị chỉ phục vụ xây dựng dữ liệu hoặc đánh giá, không tham gia vào việc tạo câu hướng dẫn cuối.

4.2 Đầu vào và cấu trúc prompt

Prompt chuẩn gồm bốn phần và được sử dụng cho S1 cũng như thành phần học tăng cường với phần thưởng SPICE. Ở giai đoạn suy luận, cấu trúc prompt cơ bản được giữ giống nhau giữa các mô hình để hạn chế khác biệt do cách biểu diễn đầu vào. Riêng mô hình sinh câu của ACE nhận thêm một khối câu ví dụ ngay trước yêu cầu sinh câu (Mục 4.6). Ví dụ dưới đây chỉ minh họa cấu trúc của prompt.

```
<image>
Mục tiêu: Open Google maps app, Search for the nearest
  park to 98103 …
Đã làm: Open the Google Maps app
Văn bản trên màn: Search here · Coffee ·
  Restaurants · Groceries · …
Viết câu hướng dẫn cho bước tiếp theo.
```

Các nhãn trường được viết bằng tiếng Việt, còn câu trả lời được yêu cầu viết bằng tiếng Anh, vì đây là ngôn ngữ của bộ ngữ liệu nguồn và của toàn bộ các câu được đánh giá.

Đầu vào còn bao gồm văn bản được trích xuất từ ảnh màn hình bằng nhận dạng chữ quang học (OCR), nhằm bổ sung thông tin về các nhãn và nội dung văn bản đang hiển thị trên giao diện.

Trường "Đã làm" chứa câu chuẩn của các bước trước, không sử dụng đầu ra do mô hình sinh ở các bước trước. Vì vậy, mỗi bước được đánh giá với lịch sử tham chiếu (ground-truth history) và không tích lũy lỗi sinh từ các bước trước. Điều kiện này được giữ cố định giữa các mô hình.

4.3 Cấu hình huấn luyện

Các lượt tinh chỉnh trực tiếp từ Qwen2.5-VL-3B-Instruct [34], gồm S1 và các cấu hình cùng nhóm, sử dụng QLoRA [29, 30] trên thư viện LLaMA-Factory [31]. Trong thiết lập này, trọng số gốc được lượng tử hóa 4 bit và chỉ các tham số LoRA được cập nhật. Tổng số tham số huấn luyện khoảng 15 triệu. Các lượt này được huấn luyện trên một

GPU A100 với cấu hình ở Bảng 4.1. Thiết lập QLoRA 4 bit chỉ áp dụng cho các lượt tinh chỉnh trực tiếp từ mô hình gốc. Các giai đoạn học tiếp của phương pháp đề xuất có cấu hình riêng ở Mục 4.5 và Mục 4.6.

Bảng 4.1: Cấu hình tinh chỉnh có giám sát. Các mô hình tinh chỉnh từ mô hình gốc dùng chung cấu hình này và chỉ khác nhau ở tập dữ liệu và seed. Hai thành phần của phương pháp đề xuất học tiếp với số bước và tốc độ học riêng (Mục 4.5 và Mục 4.6).

Tham số	**Giá trị**
Mô hình gốc	Qwen2.5-VL-3B-Instruct
Lượng tử hoá	NF4, 4 bit
Hạng LoRA r / α / dropout	8 / 16 / 0,05
Mô-đun gắn bộ chuyển đổi	q, k, v, o, gate, up, down
Tháp thị giác, tầng chiếu đa phương thức	đóng băng
Độ dài ngữ cảnh	2.560
Cỡ lô mỗi thiết bị / tích luỹ gradient	4 / 4 (hiệu dụng 16)
Tốc độ học / lịch / tỉ lệ khởi động	1×10^{-4} / cosine / 0,05
Số lượt duyệt	2 (=8.072 bước)
Độ chính xác	bf16, có gradient checkpointing
Seed	101 và 202
Phần cứng	một GPU A100
Tham số huấn luyện được	14.966.784 (0,48% phần ngôn ngữ)

Độ dài ngữ cảnh. Độ dài ngữ cảnh được đặt ở 2.560 token, cao hơn mức 2.017 token của mẫu dài nhất trong các cấu hình đã huấn luyện. Giới hạn này đủ để chứa cả phần đầu vào và câu đích trong các thiết lập của đề tài.

4.4 Tổng quan phương pháp đề xuất

Phương pháp đề xuất bắt đầu từ S1 và sử dụng hai thành phần đã tóm tắt ở Hình 4.1. Mô hình định vị dùng trong executability không tham gia vào phần thưởng của giai đoạn GRPO-SPICE hoặc điều kiện đồng thuận của ACE. Ở giai đoạn suy luận, phương pháp cũng không truy cập câu chuẩn của chính bước đang xét. Trong các phần sau, thuật ngữ *mô hình học tăng cường với phần thưởng SPICE* (viết gọn là GRPO-SPICE

trong các bảng) dùng để chỉ riêng thành phần thứ nhất, còn *phương pháp đề xuất* dùng để chỉ toàn bộ quy trình sau khi áp dụng ACE.

4.5 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Cơ sở lựa chọn. Những hướng được khảo sát trước phương pháp cuối cùng chủ yếu tác động vào một biểu diễn trung gian trước khi sinh câu hướng dẫn (Phụ lục A). Thành phần thứ nhất chuyển sang tối ưu trực tiếp câu đầu ra bằng một phần thưởng văn bản, tương tự cách CIDEr hoặc SPIDEr được sử dụng làm phần thưởng trong một số công trình sinh chú thích ảnh [44, 46]. SPICE được chọn sau khi phân tích trên tập kiểm định nội bộ cho thấy độ đo này tạo được tín hiệu phân biệt giữa một số đầu ra mà S1 sinh cho cùng một bước. Kết quả phân tích được trình bày ở Mục 6.3.

Thiết kế. Thành phần thứ nhất khởi tạo trực tiếp từ S1 với seed 101. Như vậy, S1 cũng là điểm bắt đầu của giai đoạn học tăng cường. Bộ chuyển đổi LoRA của S1 được hợp nhất vào trọng số gốc, sau đó một bộ chuyển đổi LoRA mới với cùng hạng và cùng các mô-đun được gắn vào mô hình. Ma trận B của bộ chuyển đổi mới được khởi tạo bằng không, nên trước bước cập nhật đầu tiên mô hình vẫn tương đương với S1 sau khi hợp nhất.

Một bản sao của S1 sau khi hợp nhất được đóng băng và dùng làm mô hình tham chiếu cho số hạng KL. Số hạng này hạn chế mức thay đổi của chính sách đang học so với mô hình tham chiếu. Phần thưởng của một câu s so với câu chuẩn là

$$r(s) = \mathrm{SPICE}(s, g) - 0{,}02 \cdot \max(0,\ |s| - |g| - 3), \tag{4.1}$$

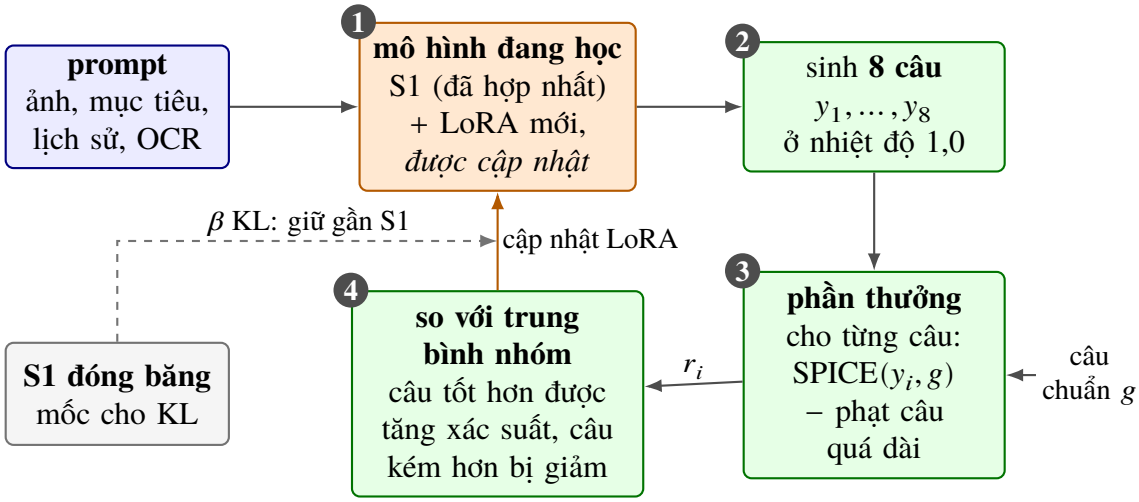
trong đó $|\cdot|$ là số từ, và câu rỗng nhận 0 điểm. Số hạng thứ hai chỉ phạt những câu dài hơn câu chuẩn quá ba từ, nhằm hạn chế việc tăng SPICE bằng cách thêm các chi tiết không cần thiết.

Mỗi bước cập nhật sử dụng hai prompt. Với mỗi prompt, mô hình sinh $G = 8$ câu ở nhiệt độ 1,0, mỗi câu dài tối đa 96 token. Quá trình huấn luyện gồm 500 bước cập nhật, tương ứng tổng cộng 1.000 prompt được lấy từ phần tập huấn luyện sau khi loại

tập kiểm định nội bộ. Các prompt gồm mọi loại thao tác, trong đó khoảng hai phần ba là bước có thao tác chạm. Tốc độ học là 10^{-5} và hệ số KL là $\beta = 0{,}04$. Vòng huấn luyện được tóm tắt ở Hình 4.2. GRPO sử dụng chênh lệch phần thưởng tương đối giữa các đầu ra trong cùng nhóm. Khi các ứng viên nhận cùng phần thưởng, lợi thế tương đối giữa chúng không tạo ra khác biệt cho bước cập nhật.

Lượt huấn luyện GRPO thứ hai. Chúng tôi chạy thêm một lượt 500 bước với cùng cấu hình GRPO-SPICE và seed 202. Lượt này vẫn khởi tạo từ S1/101, nên khác biệt giữa hai lượt phản ánh biến thiên của riêng giai đoạn GRPO. Kết quả được đối chiếu với hai lượt S1 ở Mục 6.7.2.

Thí nghiệm đối chứng với điểm SPICE ghép ngẫu nhiên. Chúng tôi xây dựng thêm một nhánh có cùng điểm khởi tạo, số bước và các siêu tham số với GRPO-SPICE, nhưng điểm SPICE được ghép ngẫu nhiên giữa các mẫu trước khi dùng làm phần thưởng. Cách thiết lập này giữ nguyên quá trình cập nhật GRPO nhưng loại bỏ mối liên hệ giữa câu sinh ra và điểm SPICE, qua đó tách ảnh hưởng của tín hiệu SPICE khỏi ảnh hưởng của việc tiếp tục huấn luyện. Kết quả được trình bày ở Mục 6.7.2.



Hình 4.2: Vòng huấn luyện của thành phần thứ nhất, học tăng cường với phần thưởng SPICE. Với mỗi prompt, mô hình sinh 8 câu (bước 2). Mỗi câu nhận phần thưởng r_i là điểm SPICE so với câu chuẩn g, trừ phần phạt khi câu quá dài (bước 3). Phần thưởng của từng câu được so với trung bình của nhóm để cập nhật LoRA mới (bước 4). Trong khối cam, chỉ LoRA mới được cập nhật. Các khối xanh lá là các bước xử lý. Hàm mất mát gồm số hạng theo lợi thế của từng câu và số hạng KL với hệ số β, trong đó S1 đóng băng (khối xám) là mốc để giữ mô hình không lệch quá xa S1.

Lựa chọn số bước huấn luyện. Mô hình sau 250 và 500 bước được dùng để sinh câu bằng giải mã tham lam trên tập kiểm định nội bộ và được so sánh theo executability. Mô hình sau 500 bước cho kết quả tốt hơn trên tập này, nên được chọn và cố định trước khi sinh câu trên tập kiểm tra. Kết quả trên tập kiểm định nội bộ và phân tích tín hiệu phần thưởng được trình bày ở Mục 6.3.

Đối chiếu giữa các lượt huấn luyện. S1 và mô hình sau GRPO có khác biệt nhỏ ở bước hợp nhất LoRA và cách xử lý theo lô. Vì vậy, kết quả của GRPO-SPICE được đọc cùng lượt huấn luyện GRPO thứ hai và nhánh đối chứng. Hai phép đối chiếu này giúp tách mức cải thiện do tín hiệu SPICE khỏi biến thiên của quá trình huấn luyện và khác biệt triển khai.

4.6 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Cơ sở lựa chọn. ACE (*Action-Consistent Exemplar Copying*) sử dụng các câu chuẩn trong tập huấn luyện làm nguồn ví dụ cho bước hiện tại. Để bảo đảm câu ví dụ phù hợp với thao tác đang xét, ACE thực hiện hai bước. Trước hết, mô hình tạo một câu ứng viên từ đầu vào hiện tại và các ví dụ truy hồi. Sau đó, điều kiện đồng thuận quyết định có thay câu hướng dẫn ban đầu của thành phần thứ nhất bằng câu ứng viên hay không.

Mô hình sinh câu với ví dụ truy hồi. ACE sử dụng kho truy hồi được xác định ở Mục 3.5. Kho chỉ được xây dựng từ dữ liệu huấn luyện và không chứa tác vụ nào của tập kiểm tra của đề tài. Truy hồi chỉ sử dụng văn bản và độ tương đồng TF-IDF, không sử dụng ảnh.

ACE dùng hai cách tìm câu ví dụ. Cách thứ nhất lấy ý tưởng truy hồi trực tiếp câu ví dụ từ SmallCap [45]. Trong thiết lập của chúng tôi, truy vấn được xây dựng từ mục tiêu tác vụ và câu gần nhất trong lịch sử thao tác, rồi dùng để truy hồi trực tiếp các bước tương tự. Cách thứ hai trước hết tìm các tác vụ có mục tiêu gần nhất, sau đó chọn bước trong từng tác vụ dựa trên câu gần nhất trong lịch sử. Kết quả từ hai cách được gộp, loại bỏ câu lặp và giữ bốn câu ví dụ để chèn vào prompt ngay trước yêu cầu sinh

câu.

Để tạo mô hình sinh câu ứng viên cho ACE, bộ chuyển đổi của thành phần thứ nhất được tiếp tục tinh chỉnh có giám sát thêm 250 bước với tốc độ học 2×10^{-5}. Lượt tinh chỉnh này sử dụng 3.991 bước có ảnh được mô tả ở Mục 3.5, tương ứng với phần dữ liệu ảnh khả dụng cho giai đoạn huấn luyện này. Trong quá trình này, số câu ví dụ được lấy ngẫu nhiên từ 2 đến 6 và các câu được sắp theo thứ tự ngẫu nhiên để hạn chế việc mô hình phụ thuộc quá mức vào khối ví dụ. Ngoài ra, 15% prompt không có khối ví dụ, 10% prompt sử dụng các câu ví dụ lấy ngẫu nhiên, và tác vụ đang học được loại khỏi kho truy hồi.

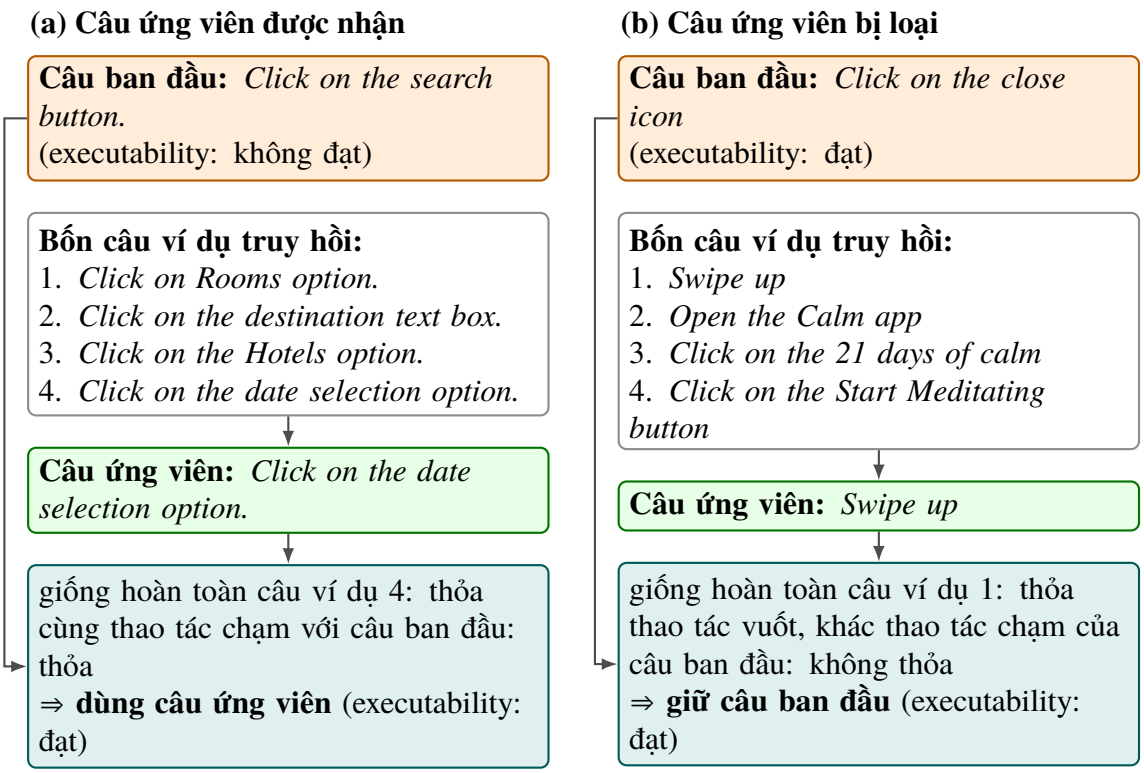
Để tách ảnh hưởng của truy hồi khỏi ảnh hưởng của việc tiếp tục học có giám sát, chúng tôi huấn luyện thêm một mô hình trên cùng các bước, cùng câu đích và cùng siêu tham số, nhưng không chèn khối ví dụ vào prompt.

Tiêu chí đồng thuận. Ở mỗi bước có hai câu: câu hướng dẫn ban đầu của thành phần thứ nhất và câu ứng viên do mô hình ACE tạo ra từ các ví dụ truy hồi. Câu ứng viên chỉ được chọn khi thỏa đồng thời hai điều kiện.

1. **Giống hoàn toàn với câu ví dụ.** Sau khi tách từ, câu của mô hình sinh phải giống hoàn toàn với một trong bốn câu ví dụ của khối. Điều kiện này chỉ giữ lại những bước mà mô hình chọn lại một câu ví dụ và bỏ các bước mà mô hình tạo câu mới.

2. **Đồng thuận loại thao tác.** Động từ ở đầu câu của mô hình sinh và động từ ở đầu câu hướng dẫn ban đầu thuộc cùng một lớp thao tác (chạm, nhấn giữ, gõ, cuộn, mở ứng dụng, quay lại). Ngay cả khi câu ứng viên gọi đúng phần tử, loại thao tác vẫn có thể không phù hợp, chẳng hạn câu yêu cầu gõ ở một bước cần chạm. Câu hướng dẫn ban đầu được sinh từ chính màn hình hiện tại và được sử dụng làm tín hiệu kiểm tra loại thao tác. Phân lớp sáu nhóm này chỉ phục vụ điều kiện đồng thuận của ACE và khác với cách chuẩn hoá năm loại dùng cho executability ở Mục 5.1.

Hình 4.3 minh họa hai bước của tập kiểm tra: một bước câu ứng viên được nhận và một bước câu ứng viên bị loại vì đổi loại thao tác.



Hình 4.3: Hai bước minh họa điều kiện đồng thuận của ACE trên tập kiểm tra. Khối cam là câu hướng dẫn ban đầu do GRPO-SPICE sinh ra, khối trắng là bốn câu ví dụ truy hồi từ tập huấn luyện, khối xanh lá là câu ứng viên do mô hình sinh của ACE tạo ra, khối xanh ngọc là kết quả của hai điều kiện. Câu ví dụ được truy hồi theo mục tiêu và các bước trước, không theo câu ban đầu, còn câu ban đầu chỉ được dùng ở bước kiểm tra loại thao tác (mũi tên bên trái). Ở (a), ACE sửa một câu sai thành câu đúng. Ở (b), điều kiện loại thao tác ngăn ACE thay một câu đúng bằng câu chép từ ví dụ nhưng sai loại thao tác.

Lựa chọn tiêu chí. Bốn biến thể được khảo sát trên tập kiểm định nội bộ gồm chỉ dùng điều kiện sao chép, sao chép kèm đồng thuận loại thao tác, sao chép kèm điều kiện phần lõi của câu (phần còn lại sau khi bỏ động từ và hư từ) giống câu hướng dẫn ban đầu ít nhất một nửa, và sao chép kèm cả hai điều kiện.

Tiêu chí lựa chọn được xác định trước khi tính executability trên tập này. Trước hết, chỉ các biến thể không kém hơn câu hướng dẫn ban đầu trên đa số độ đo dựa trên câu chuẩn được giữ lại. Trong số đó, biến thể có executability cao nhất được lựa chọn. Điều kiện đã chọn được cố định trước khi áp dụng trên tập kiểm tra.

4.7 Mô hình và thiết lập so sánh

Ba mốc chính được sử dụng để so sánh với phương pháp đề xuất gồm Base, S1 và câu chuẩn. Base là Qwen2.5-VL-3B-Instruct khi chưa tinh chỉnh. S1 là mô hình được tinh chỉnh có giám sát từ Base với cấu hình ở Bảng 4.1 để sinh trực tiếp câu hướng dẫn từ prompt. S1 được huấn luyện hai lần với seed 101 và 202. Chênh lệch giữa hai lượt được dùng để tham khảo mức dao động khi lặp lại cùng một cấu hình. Thành phần thứ nhất của phương pháp đề xuất học tiếp từ lượt seed 101, nên lượt này cũng là mốc so sánh trực tiếp. Cuối cùng, câu chuẩn được đưa qua cùng quy trình đánh giá để tạo một mốc giúp diễn giải điểm số của các mô hình.

Các phương án được khảo sát trước khi hình thành phương pháp cuối cùng được tóm tắt ở Mục 6.11. Thiết kế và số liệu chi tiết được trình bày ở Phụ lục A.

4.8 Thiết lập so sánh và diễn giải kết quả

Với executability, các so sánh chính giữa hai mô hình được thực hiện theo cặp trên cùng các bước được đánh giá. Tập chính gồm 4.463 bước có thao tác chạm. Mỗi so sánh báo cáo mức chênh Δ, khoảng tin cậy 95% từ bootstrap và giá trị p của kiểm định McNemar. Cách tạo khoảng tin cậy cho từng phân tích được trình bày ở Mục 5.13 và tại các bảng kết quả tương ứng. Khi khoảng tin cậy của chênh lệch nằm hoàn toàn về một phía của 0, kết quả được diễn giải theo chiều cải thiện hoặc suy giảm so với mốc. Khi khoảng tin cậy chứa 0, chúng tôi không dựa vào dấu của Δ để kết luận khác biệt giữa hai mô hình.

Mức dao động giữa hai seed của S1 được phân tích ở Mục 6.7. Các phân tích theo độ dài câu, độ khó của màn hình và nguồn của tên phần tử được trình bày ở Mục 6.10.

Chương 5

Độ đo khả năng thực hiện theo hướng dẫn

Chương này xây dựng và đánh giá độ đo khả năng thực hiện theo hướng dẫn (*instruction executability*), gọi ngắn là executability. Khác với các độ đo chỉ dựa trên mức độ tương đồng với một câu chuẩn, executability xem xét liệu câu hướng dẫn có cung cấp đủ thông tin để xác định đúng phần tử cần thao tác và loại thao tác tương ứng hay không. Chương trước hết trình bày định nghĩa và tiêu chí xác định một dự đoán đúng, sau đó đánh giá độ tin cậy của công cụ định vị, thiết lập các mốc tham chiếu cho thang điểm và kiểm tra độ nhạy, độ ổn định của độ đo. Phần cuối trình bày phương pháp phân tích thống kê được sử dụng trong các chương thực nghiệm.

5.1 Định nghĩa

Với mỗi bước có thao tác chạm, độ đo sử dụng năm đại lượng. s là câu hướng dẫn cần đánh giá. Nếu một phương án đã thử sinh thêm dòng mô tả phần tử trước câu (Phụ lục A), phần này được loại bỏ trước khi tính điểm. I là ảnh màn hình và g là tọa độ chạm của người dùng. E là tập các phần tử cạnh tranh trên màn hình, được lấy từ cây trợ năng sau bước gộp. Các tâm nằm trong ngưỡng 24 dp quanh g được xem là cùng nhóm với phần tử đích, còn các tâm cạnh tranh cách nhau dưới 24 dp được gộp lại. Dp là đơn vị độ dài của Android, không phụ thuộc mật độ điểm ảnh. Trên thiết bị được sử dụng, 24 dp tương ứng 63 điểm ảnh. G là mô hình định vị phần tử. Mô hình nhận ảnh cùng câu hướng dẫn và trả về tọa độ $p = G(I, s)$ của phần tử được câu quy chiếu

tới. G tách biệt với mô hình sinh đang được đánh giá và không nhận g làm đầu vào.

Một bước được tính là đúng khi thoả cả ba điều kiện:

- **(i) Khớp loại thao tác.** Loại thao tác của s, sau khi chuẩn hoá, phải cùng loại với thao tác của câu chuẩn. Có năm loại gồm chạm, gõ, cuộn, nhấn giữ và quay lại. Mười hai động từ (*tap, click, press, select, choose, touch, open, launch, go, navigate, visit, view*) được xếp vào loại chạm.

  Trong cách chuẩn hoá ban đầu, động từ được dò từ trái sang phải. Vì vậy, một số cụm có từ *back* như *go back, navigate back* và *press the back button* được xếp vào nhóm chạm. Các bảng chính giữ quy tắc này để nhất quán giữa các lượt đánh giá. Mục 5.12 kiểm tra riêng ảnh hưởng của việc điều chỉnh quy tắc.

- **(ii) Không đảo nghĩa.** s và câu chuẩn không được gọi tên hai trạng thái ngược nhau của cùng một điều khiển, chẳng hạn nút "bật thông báo" và "tắt thông báo". Điều kiện (iii) không bắt được lỗi này vì hai trạng thái nằm cùng một chỗ. Danh sách lập thủ công gồm chín cặp từ trái nghĩa (*on/off, enable/disable, show/hide, mute/unmute, expand/collapse, check/uncheck, select/deselect, start/stop, enabled/disabled*).

- **(iii) Định vị đúng.** p nằm trong vùng dung sai quy ước quanh g, $|p_x - g_x| \le \tau W$ và $|p_y - g_y| \le \tau H$, với W, H là bề ngang và chiều cao màn hình và $\tau = 0{,}14$ theo [2]. Đồng thời, không phần tử nào khác có tâm gần p hơn chính g:

$$\|p - g\| \le \|p - c(e)\| \quad \forall e \in E, \tag{5.1}$$

với $c(e)$ là tâm của phần tử e. Vùng gồm mọi điểm thoả điều kiện này được gọi là ô Voronoi quy ước quanh điểm chạm g (Hình 5.1). Như vậy, điểm do mô hình định vị trả về phải nằm trong vùng mà g không xa hơn bất kỳ tâm cạnh tranh nào.

Điểm executability là tỉ lệ các bước có thao tác chạm thoả cả ba điều kiện.

Điều kiện (iii) có hai chi tiết cần làm rõ. Vùng dung sai là hình chữ nhật, không phải hình tròn. Trên màn 1080×2400, vùng rộng ± 151 điểm ảnh theo chiều ngang và ± 336 điểm ảnh theo chiều dọc. Ô Voronoi được dựng quanh điểm chạm g thay vì

tâm hộp của phần tử chứa g. Cách đánh giá chính dùng tâm các phần tử để xác định vùng cạnh tranh, còn các tiêu chí dựa trên hộp bao được phân tích riêng ở Mục 5.12.

Vai trò của mô hình định vị và phạm vi của độ đo. Tọa độ chạm của người dùng được dùng làm mốc đối chiếu. Mô hình G không được tinh chỉnh trong đề tài và chỉ có nhiệm vụ suy ra một tọa độ từ ảnh cùng câu hướng dẫn. Tọa độ này sau đó được so sánh với g theo các điều kiện ở trên. Executability tập trung vào một khía cạnh cụ thể của chất lượng hướng dẫn, đó là câu có cung cấp đủ thông tin để xác định đúng phần tử và đúng thao tác hay không. Các khía cạnh ngôn ngữ và trải nghiệm sử dụng được xem xét bằng các phân tích bổ sung thay vì được gộp vào cùng một điểm số.

5.2 Tiêu chí xác định dự đoán đúng và giới hạn của tiêu chí dung sai quy ước

Điều kiện ô Voronoi chặt hơn tiêu chí dung sai quy ước nhưng cũng phức tạp hơn. Vì vậy, chúng tôi so sánh hành vi của hai tiêu chí trên 250 bước có thao tác chạm (Bảng 5.1). Hai tình huống được dùng để phân biệt vai trò của tiêu chí: dự đoán chỉ lệch nhẹ so với điểm chạm và dự đoán bị chuyển sang phần tử lân cận sai.

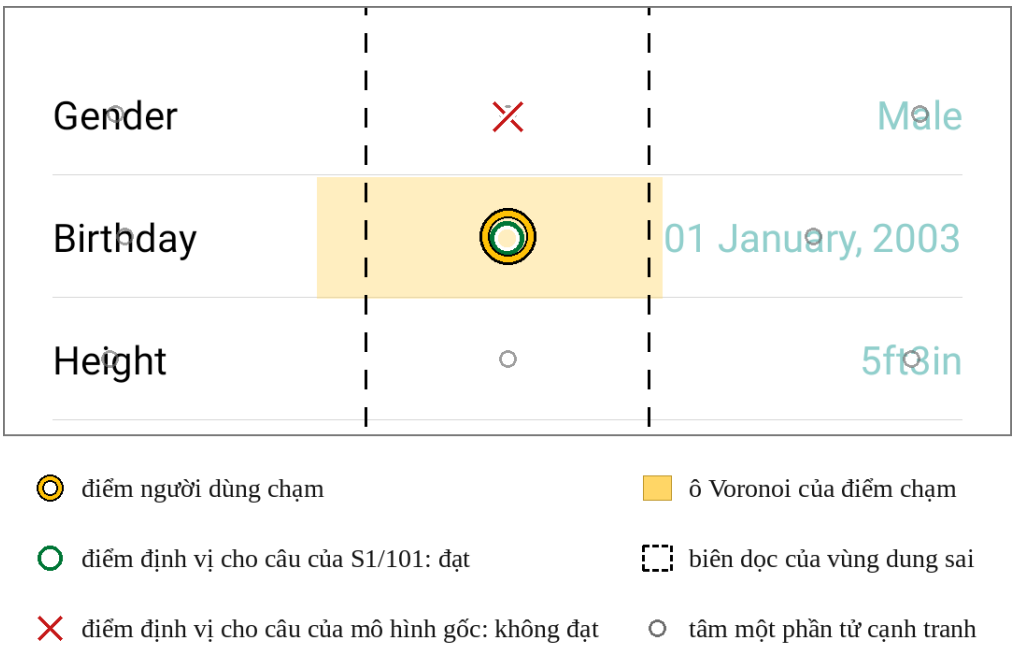
Bảng 5.1: So sánh các tiêu chí xác định dự đoán đúng trong hai tình huống tổng hợp: dự đoán lệch nhẹ và dự đoán bị chuyển sang phần tử lân cận sai. Mỗi tỉ lệ tính trên 1.000 lượt: 250 bước có thao tác chạm, mỗi bước dịch điểm dự đoán bốn lần theo hướng ngẫu nhiên. Cột "Khoảng phân tách" là chênh lệch giữa tỉ lệ chấp nhận hai tình huống.

Tiêu chí	Chấp nhận khi lệch 3%	Chấp nhận khi sai nút lân cận	Khoảng phân tách
Cửa sổ dung sai ± 14% theo từng trục	100,0%	84,3%	≈ 16 điểm
Ô Voronoi	99,7%	**2,8%**	≈ 97 điểm

Tiêu chí dung sai quy ước vẫn chấp nhận phần lớn dự đoán bị chuyển sang nút lân cận, vì 63,2% số bước có ít nhất một phần tử khác nằm trong vùng dung sai của phần tử cần chạm. Ngược lại, tiêu chí ô Voronoi chỉ chấp nhận 2,8% các dự đoán sai nút lân cận nhưng vẫn giữ tỉ lệ chấp nhận 99,7% khi điểm chỉ lệch 3%. Vì vậy tiêu chí ô

Voronoi được chọn làm tiêu chí chính.

Mức 2,8% áp dụng cho tình huống tổng hợp này, còn các điểm lệch nhẹ trong cùng vùng tương tác được xem xét riêng ở Mục 5.7. Cách gộp các tâm gần nhau chủ yếu loại các tâm cùng thuộc một phần tử. Trong 8,2% số bước, phép gộp cũng có thể hợp nhất các tâm thuộc những phần tử khác nhau. Chúng tôi báo cáo thêm tiêu chí dung sai và các tiêu chí dựa trên hộp phần tử để đối chiếu với kết quả chính.



Hình 5.1: Một bước mà hai tiêu chí đánh giá cho hai kết quả khác nhau. Người dùng chạm dòng *Birthday*. Câu của S1 dẫn mô hình định vị tới đúng dòng đó. Câu của mô hình gốc tả dòng *Gender* ngay phía trên, nên điểm trả về lệch 128 điểm ảnh, vẫn trong vùng dung sai quy ước. Tiêu chí dung sai vẫn xem dự đoán là đúng, còn tiêu chí ô Voronoi nhận ra câu đang quy chiếu sang một dòng khác. Hai đường nét đứt là biên trái và phải của vùng dung sai, biên trên và dưới nằm ngoài phần ảnh được cắt.

Kết quả trên điểm do mô hình định vị trả về cũng phù hợp với lựa chọn này. Trên 300 bước của Mục 5.4, khi nhận câu chuẩn, tiêu chí ô Voronoi cho điểm mọi bước có sai số định vị dưới 3% bề ngang màn ($n = 188$) và không cho điểm bước nào có sai số trên 14% ($n = 63$).

5.3 Mô hình định vị dùng làm công cụ đo

UGround-V1-2B [5] được chọn làm công cụ định vị chính vì mô hình có trọng số công khai, được phát triển cho bài toán GUI grounding và có thể trả về trực tiếp tọa độ phần tử từ ảnh cùng mô tả văn bản. Trước khi sử dụng cho executability, sai số định vị của mô hình được kiểm tra trong tương quan với khoảng cách giữa các phần tử trên màn hình ở Mục 5.4.

UGround được xây dựng trên Qwen2-VL và dữ liệu huấn luyện có sử dụng 47 nghìn phần tử được gán nhãn từ AndroidControl [5]. Do tập kiểm tra của đề tài được lấy từ một bản phân phối khác của AndroidControl, chúng tôi bổ sung các phép kiểm theo phần chia chính thức và đánh giá chéo bằng những công cụ khác ở Mục 5.9 và Mục 5.10. Các phép kiểm này được dùng để xem liệu thứ hạng và chiều của các chênh lệch chính có được giữ khi thay đổi công cụ đánh giá hay không.

Khi tách 4.463 bước có thao tác chạm theo phần chia chính thức của AndroidControl, điểm số giữa hai nhóm gần như giữ nguyên. Câu chuẩn đạt 75,9% trên phần huấn luyện chính thức và 74,0% trên phần kiểm tra cùng kiểm định, S1 đạt 59,1% và 59,3%, còn mô hình gốc đạt 47,7% và 46,7%. Khoảng tin cậy của hai phần chồng nhau ở cả ba loại câu, nên không xuất hiện mức tăng riêng trên phần huấn luyện chính thức. Phân tích này được dùng cùng các đánh giá chéo ở Mục 5.9 và Mục 5.10 để kiểm tra độ ổn định của kết luận. Prompt cung cấp cho G được giữ nguyên theo trang giới thiệu mô hình của nhóm tác giả.

5.4 Kiểm tra độ chính xác của công cụ đo

Vì độ tin cậy của executability phụ thuộc trực tiếp vào độ chính xác của mô hình định vị G, mô hình này được kiểm tra trước khi dùng làm công cụ đánh giá các mô hình sinh câu. Sai số định vị được xem xét trong tương quan với khoảng cách giữa các phần tử giao diện. Biên dung sai được định nghĩa là nửa khoảng cách từ điểm chạm g tới tâm phần tử cạnh tranh gần nhất sau khi gộp. Trên 1.496 bước có thao tác chạm, biên dung sai có trung vị 67 điểm ảnh (6,2% bề ngang) và phân vị thứ mười là 39 điểm ảnh (3,6%), nên sai số cỡ 3% bề ngang (khoảng 32 điểm ảnh) vẫn nhỏ hơn cả phân vị thứ

mười. Tọa độ chạm trong AndroidControl cũng phần lớn nằm rất gần tâm phần tử: 79,4% số điểm chạm cách một tâm không quá 1,5 điểm ảnh. Tỉ lệ loại nhầm là 0% ở mức sai số 3%, 7,5% ở mức 5%, 24,1% ở mức 8% và tăng mạnh lên 55% ở mức sai số 13%.

Kết quả đo. Trên 300 bước của tập kiểm tra, khi đầu vào là câu chuẩn, UGround-V1-2B có sai số trung vị bằng 0,7% bề ngang màn hình và 62,7% số bước có sai số dưới 3%. Các phân vị 25, 75 và 90 lần lượt là 0,2%, 8,8% và 36,3%. Phần lớn dự đoán vì vậy tập trung gần phần tử mục tiêu. Do công cụ định vị vẫn có một số trường hợp sai lệch lớn, điểm của câu chuẩn được sử dụng như mốc thực nghiệm của toàn bộ quy trình đánh giá, thay vì được xem là mức tối đa của chất lượng câu.

5.5 Mốc tham chiếu của thang điểm

Để có cơ sở diễn giải điểm executability, cùng một quy trình đánh giá được áp dụng cho một số loại câu có vai trò tham chiếu khác nhau. **Mốc tham chiếu** được xác định bằng câu hướng dẫn do người chú thích viết cho chính bước đang xét. Trên toàn bộ 4.463 bước có thao tác chạm, các câu này đạt 75,7% executability, với khoảng tin cậy 95% [74,1; 77,3] (Mục 5.13). Nếu dùng tiêu chí dung sai, điểm tương ứng là 84,3% [82,9; 85,6].

Điểm 75,7% được dùng như mốc thực nghiệm của câu do người chú thích viết khi đi qua cùng quy trình đánh giá. Có 148 bước mà câu chuẩn không đạt nhưng câu của mô hình gốc hoặc S1 lại đạt. Nếu xét cả ba loại câu, 3.527 bước, tương ứng 79,1%, đạt theo ít nhất một loại câu. Vì vậy, mốc 75,7% được dùng để đặt kết quả của các mô hình vào bối cảnh, không phải như một trần lý thuyết. Cách đối chiếu kết quả hệ thống với một mốc từ con người cũng được sử dụng trong nghiên cứu sinh chỉ dẫn điều hướng của Zhao và cộng sự [37].

Ở chiều ngược lại, **mốc tham chiếu dưới** được khảo sát bằng các câu mang rất ít hoặc không mang thông tin quy chiếu. Trên một mẫu ngẫu nhiên 800 bước, câu chuẩn đạt 74,9%, S1 đạt 58,8% và Base đạt 48,6%. Cùng mẫu này, câu chung chung "*Tap the button.*" chỉ đạt 12,0% [9,7; 14,4], còn câu chuẩn lấy từ một màn hình khác đạt 6,1% [4,5; 7,9].

Trường hợp	Câu đưa cho mô hình định vị	Điểm	KTC 95%
Câu chuẩn	câu của chính bước đang xét	74,9	-
S1	mô hình đã tinh chỉnh	58,8	-
Base	mô hình chưa tinh chỉnh	48,6	-
Câu chung chung	"*Tap the button.*"	12,0	[9,7; 14,4]
Câu của màn hình khác	câu chuẩn của một bước khác	6,1	[4,5; 7,9]

Hai mức 12,0% và 6,1% là các mốc thực nghiệm, được dùng để minh họa điểm số khi thông tin quy chiếu bị giảm đáng kể. Tỉ lệ 40,0% số bước mà câu chuẩn, S1 và Base cùng đạt không được dùng như một mức điểm nền vì khi nội dung quy chiếu bị loại bỏ hoặc thay bằng nội dung của màn hình khác, điểm giảm rõ rệt. Nếu dùng 12,0% như một mốc thực hành để chuẩn hoá dải 74,9–12,0 trên mẫu 800 bước, Base nằm ở 58,3% và S1 ở 74,4% dải này. Cách chuẩn hoá này chỉ phục vụ diễn giải và không thay đổi điểm executability gốc.

Executability tập trung vào khả năng xác định đúng phần tử và thao tác. Vì vậy, ở Chương 6, điểm này được trình bày cùng các độ đo dựa trên câu chuẩn để cung cấp thêm góc nhìn về chất lượng câu đầu ra.

5.6 Độ nhạy với thông tin quy chiếu

Các mốc dưới ở Mục 5.5 cho thấy câu chung chung hoặc câu đúng văn phong nhưng lấy từ màn hình khác nhận điểm thấp. Phần này xem xét trực tiếp hơn mức thay đổi của điểm số khi chỉ loại bỏ một phần thông tin quy chiếu khỏi câu chuẩn.

Vai trò của tên phần tử so với vị trí.

Hai biến đổi dưới đây được áp dụng cho các câu có thành phần tương ứng: biến đổi thứ nhất bỏ tên phần tử nhưng giữ mệnh đề vị trí, còn biến đổi thứ hai bỏ mệnh đề vị trí nhưng giữ tên phần tử. Hai nhóm bước có kích thước gần bằng nhau nên có thể đối chiếu trực tiếp.

Biến đổi	n	Trước → sau biến đổi	Chênh lệch
Bỏ tên phần tử, giữ vị trí	193	89,6 → 61,1	**−28,5**
Bỏ mệnh đề vị trí, giữ tên	198	89,4 → 85,9	**−3,5**

Khi bỏ tên phần tử, $b = 58$ bước chuyển từ đạt sang không đạt và $c = 3$ bước theo chiều ngược lại. Kiểm định McNemar (Mục 5.13) cho $\chi^2 = 47{,}8$, $p < 0{,}001$. Mức giảm do bỏ tên phần tử lớn gấp khoảng tám lần mức giảm do bỏ mệnh đề vị trí. Cùng với hai mốc thực nghiệm ở Mục 5.5, kết quả cho thấy độ đo phản ứng rõ với việc thay đổi thông tin quy chiếu, đặc biệt là tên phần tử.

Diễn giải kết quả trên tập con chịu tác động. Biến đổi bỏ tên phần tử áp dụng được cho 193 trong 800 bước (24,1%). Vì vậy, mức thay đổi được báo cáo trên chính nhóm câu thực sự chịu biến đổi, nơi điểm giảm 28,5 điểm. Cách báo cáo này cũng được áp dụng cho các phép biến đổi chỉ tác động lên một phần dữ liệu.

5.7 Kiểm tra bằng biến đổi lỗi có kiểm soát

Độ đo còn được kiểm tra bằng cách chủ động tạo các trường hợp đúng hoặc sai đã biết trước và xem kết quả đánh giá có thay đổi theo hướng mong đợi hay không [17]. Bảng 5.2 gồm mười kiểm tra. Các kiểm tra về diễn đạt, loại thao tác và vị trí được thực hiện trên một mẫu 398 bước có thao tác chạm. Các kiểm tra về nội dung nhập, hướng cuộn và phủ định được áp dụng trên toàn bộ những bước phù hợp trong tập kiểm tra. Vì vậy, số trường hợp n khác nhau giữa các dòng và có thể lớn hơn 398. Ba dòng đầu báo tỉ lệ loại nhầm trường hợp đúng, còn bảy dòng sau báo tỉ lệ phát hiện trường hợp sai.

Diễn giải kết quả. Một số biến đổi cho kết quả gần như xác định bởi chính cách tạo lỗi, chẳng hạn thay loại thao tác hoặc hướng. Hai trường hợp cần xem kỹ hơn là chuyển sang phần tử lân cận và phủ định câu, vì chúng kiểm tra trực tiếp khả năng phân biệt giữa các phần tử gần nhau và khả năng xử lý thay đổi ngữ nghĩa.

Phần tử kề gần. Tỉ lệ ở dòng này phản ánh trực tiếp quy tắc gộp các phần tử có tâm cách nhau dưới 24 dp (Mục 5.1). Ngưỡng này tương ứng khoảng 63 điểm ảnh,

Bảng 5.2: Kiểm tra độ đo bằng các biến đổi có kết quả mong đợi đã biết trước. Ba dòng đầu là tỉ lệ độ đo loại nhầm một câu vẫn đúng, nên càng thấp càng tốt. Các dòng còn lại là tỉ lệ độ đo phát hiện được một câu đã bị làm sai, nên càng cao càng tốt. Cặp trạng thái đối lập là cặp chưa có trong bảng ánh xạ.

Trường hợp kiểm tra	**Tỉ lệ**	**n**
Loại nhầm câu diễn đạt khác	0,0%	398
Loại nhầm ở điều kiện thao tác	0,0%	398
Loại nhầm ở phép đảo nghĩa	0,0%	398
Phát hiện sai phần tử kề gần	33,1%	121
Phát hiện sai phần tử kề xa	99,6%	233
Phát hiện sai phần tử ở rất xa	100,0%	397
Phát hiện cặp trạng thái đối lập chưa có trong bảng ánh xạ	0,0%	12
Phát hiện sai loại thao tác	100,0%	369
Phát hiện sai nội dung	91,1%	494
Phát hiện sai hướng	100,0%	755

gần với biên dung sai trung vị 67 điểm ảnh (Mục 5.4). Vì vậy, độ đo tập trung vào việc phân biệt các phần tử đủ tách biệt trên giao diện và không xem các sai lệch rất nhỏ bên trong cùng vùng tương tác là một lỗi định vị khác phần tử.

Các cặp trạng thái đối lập ngoài bảng. Điều kiện đảo nghĩa được xây dựng theo danh sách các cặp trạng thái định nghĩa trước. Vì vậy, 12 trường hợp thuộc các cặp chưa có trong danh sách không được nhận diện bởi điều kiện này. Ba trường hợp `enable` → `disable` không thuộc nhóm trên vì cặp `enable`/`disable` đã có trong bảng. Mười hai trường hợp này xác định rõ phạm vi của thành phần kiểm tra đảo nghĩa trong executability.

5.8 Độ ổn định trước các biến thể diễn đạt

Một độ đo phù hợp cần tương đối ổn định trước các biến thể diễn đạt giữ nguyên nội dung. Jandial và cộng sự [18] chỉ ra rằng mô hình định vị có thể nhạy với cách diễn đạt của câu. Vì vậy, chúng tôi xây dựng các biến thể của câu chuẩn và đánh giá lại executability trên mẫu 800 bước.

Bốn biến thể được xây dựng bằng tiêu chí xác định, không sử dụng mô hình ngôn ngữ. Ba biến thể đầu giữ nguyên nội dung chính gồm thay động từ thao tác (ví dụ *click* thành *tap*), đảo thứ tự hai mệnh đề và kết hợp hai biến đổi này. Biến thể cuối bỏ mệnh đề vị trí. Kết quả của biến thể này đã được phân tích ở Mục 5.6 và được đưa vào đây làm mốc đối chiếu với các thay đổi giữ nguyên nội dung.

Bảng 5.3: Điểm khi viết lại câu chuẩn theo bốn biến thể rồi đánh giá lại, tính trên phần bị tác động. Ở cột McNemar, *b* là số bước chuyển từ đạt sang không đạt sau khi viết lại, *c* là chiều ngược lại. Giá trị p in đậm là giá trị nhỏ hơn 0,05, chưa hiệu chỉnh cho bốn kiểm định.

Biến thể	Số câu viết lại	Trên phần bị tác động	McNemar
Đổi động từ thao tác	725 (90,6%)	76,8 → 77,0	b=13, c=14, p=1,000
Đảo trật tự mệnh đề	211 (26,4%)	89,6 → 90,0	b=0, c=1, p=1,000
Đổi động từ và đảo trật tự	203 (25,4%)	90,1 → 91,1	b=0, c=2, p=0,480
Bỏ mệnh đề vị trí	198 (24,8%)	89,4 → 85,9	b=8, c=1, **p=0,046**

Gộp ba biến thể giữ nguyên nghĩa (Bảng 5.3), 30 trong 1.139 câu viết lại (2,6%) làm thay đổi kết quả đánh giá. Hiệu ròng là +0,35 điểm, với khoảng tin cậy 95% [−0,59; +1,29]. So với mốc bỏ mệnh đề vị trí ở Mục 5.6, độ đo tương đối ổn định trước những thay đổi bề mặt được khảo sát nhưng vẫn phản ứng khi thông tin định vị bị loại bỏ.

Phạm vi của phép kiểm. Công cụ đo giữ kết quả ổn định trước việc thay động từ và đảo trật tự câu trong các biến đổi trên. Các cách viết lại này thay đổi bề mặt câu nhưng giữ nguyên phần mô tả phần tử và lớp thao tác. Vì vậy, phép kiểm tập trung vào độ ổn định trước các biến đổi này. Các dạng thay đổi trực tiếp tên gọi của phần tử nằm ngoài phạm vi của thí nghiệm tại mục này.

5.9 Đánh giá chéo bằng mô hình định vị thứ hai

Để kiểm tra độ ổn định của kết luận khi thay công cụ định vị, chúng tôi đánh giá lại một số chênh lệch bằng UI-Venus-Ground-7B [6]. Mô hình này có trọng số công khai và đạt kết quả tốt trên các bộ chuẩn định vị giao diện di động. So sánh được thực hiện trên 2.532 bước mà các mô hình sinh ra câu khác nhau. Những bước có đầu ra giống

nhau không ảnh hưởng đến chênh lệch giữa các mô hình.

Do hai công cụ sử dụng thang điểm khác nhau, phần này tập trung vào chênh lệch tương đối giữa các mô hình thay vì so sánh trực tiếp điểm tuyệt đối. Chênh lệch giữa S1 và mô hình gốc được dùng làm so sánh chính vì mức chênh tương đối lớn và mang dấu dương rõ ràng. Nếu công cụ thứ hai làm thu hẹp thang điểm đáng kể, chênh lệch này sẽ giảm tương ứng và các khác biệt nhỏ hơn sẽ trở nên khó diễn giải hơn.

Bảng 5.4: Chênh lệch giữa các mô hình trên cùng 2.532 bước, đánh giá bằng hai mô hình định vị khác nhau. Chênh lệch giữa mô hình mô tả phần tử (S2, một hướng đã thử ở Phụ lục A) và S1 được quy về mẫu số 4.463 để so sánh với các bảng khác. Hàng cuối là executability của câu chuẩn trên mẫu 300 bước dùng để kiểm tra mức trần của mỗi mô hình định vị, không phải trên toàn bộ 4.463 bước. Trong ngoặc vuông là khoảng tin cậy 95%.

So sánh	**UGround**	**UI-Venus**
S1 − mô hình gốc (Base), so sánh chính	+10,35 [+8,39; +12,40]	+9,68 [+7,60; +11,78]
Mô tả phần tử (S2) − S1	−1,93 [−3,06; −0,75]	−1,21 [−2,30; −0,12]
Câu chuẩn, mẫu 300 bước (điểm tuyệt đối)	70,0 [64,5; 75,3]	69,3 [63,8; 74,8]

So sánh S1 với Base. Chênh lệch giữa S1 và mô hình gốc là +10,35 điểm khi đánh giá bằng UGround và +9,68 điểm khi đánh giá bằng UI-Venus (Bảng 5.4). Việc chênh lệch gần như được bảo toàn sau khi thay công cụ đo cho thấy thứ hạng và độ lớn tương đối giữa hai mô hình khá ổn định trước lựa chọn mô hình định vị.

Kết quả trên một chênh lệch nhỏ. Chênh lệch giữa mô hình mô tả phần tử (S2) và S1 vẫn âm khi đánh giá bằng cả hai công cụ, và cận trên của khoảng tin cậy đều nhỏ hơn 0. Khi sử dụng UI-Venus, độ lớn của chênh lệch giảm so với UGround, phù hợp với việc thang điểm của UI-Venus thấp hơn trên cả ba mô hình. Kết quả đánh giá chéo vẫn giữ chiều của chênh lệch quan sát được.

Phương pháp đề xuất dưới UI-Venus. Phương pháp đề xuất, thành phần thứ nhất và hai lượt S1 được đánh giá thêm bằng UI-Venus trên đủ 4.463 bước. Mỗi cặp bước và câu chỉ được đánh giá một lần, nên các bước có câu giống nhau giữa hai mô hình cho cùng kết quả. GRPO-SPICE cao hơn S1/101 1,55 điểm và cao hơn S1/202 0,94 điểm. Sau ACE, các mức chênh tương ứng là 1,68 và 1,08 điểm. Khoảng tin cậy của cả bốn phép so đều nằm trên 0. Vì UI-Venus cũng được xây dựng trên họ Qwen, Mục 5.10 tiếp tục kiểm tra bằng một mô hình listener thuộc họ kiến trúc khác.

Bảng 5.5: Phương pháp đề xuất và hai lượt S1 khi đánh giá bằng UI-Venus trên 4.463 bước có thao tác chạm. Exec. là executability. Cột phải là chênh lệch ghép cặp, kèm khoảng tin cậy 95% bootstrap theo cụm (Mục 5.13).

Mô hình	Exec.	So sánh	Δ [KTC 95%]
S1/101	54,51	Phương pháp đề xuất − S1/101	+1,68 [+0,97; +2,42]
S1/202	55,12	Phương pháp đề xuất − S1/202	+1,08 [+0,28; +1,88]
GRPO-SPICE	56,06	Phương pháp đề xuất − GRPO-SPICE	+0,13 [−0,11; +0,39]
Phương pháp đề xuất	56,20	GRPO-SPICE − S1/101	+1,55 [+0,82; +2,30]
		GRPO-SPICE − S1/202	+0,94 [+0,14; +1,75]
		S1/202 − S1/101	+0,60 [−0,13; +1,34]

Bộ trỏ ngoài họ Qwen. Chúng tôi đánh giá thêm bằng Phi-Ground-4B [7], mô hình được xây dựng trên Phi-3.5-Vision. Theo báo cáo kỹ thuật, mô hình không dùng AndroidControl để huấn luyện. Dữ liệu được công bố gồm các tập con của OS-Atlas, SeeClick, E2ISynth, GUIAct, dữ liệu web và dữ liệu giao diện Windows/Office do người gán nhãn. Phi-Ground vì vậy cung cấp một phép kiểm bằng kiến trúc khác với UGround và UI-Venus. Ở nhánh Base, tệp dự đoán thiếu 7 trong 4.463 bước và các bước này được tính là không đạt. Kết quả định lượng được tổng hợp ở Chương 6.

5.10 Đánh giá chéo bằng mô hình listener thuộc họ kiến trúc khác

Các đánh giá ở những mục trước đều dựa trên bài toán định vị mở, trong đó mô hình nhận ảnh và câu hướng dẫn rồi trả về một tọa độ. Để kiểm tra độ ổn định của thứ hạng khi thay đổi cách đánh giá, chúng tôi sử dụng thêm Phi-4-multimodal-instruct [42], một mô hình ngôn ngữ thị giác không thuộc họ Qwen, làm listener theo dạng lựa chọn. Các phần tử tương tác được lấy từ cây trợ năng, khoanh vùng và đánh số theo phương pháp Set-of-Mark [43]. Mỗi màn hình có trung vị 15 phần tử. Phi-4 nhận câu hướng dẫn cùng ảnh đã đánh số và chọn phần tử mà câu hướng dẫn đề cập tới.

Listener không được cung cấp mục tiêu tác vụ hoặc lịch sử thao tác. Một dự đoán được tính là đúng khi phần tử được chọn chứa tọa độ chạm tham chiếu. Cách

đánh giá này gần với *comprehension accuracy* trong các nghiên cứu về sinh biểu thức quy chiếu [12, 13], nhưng được áp dụng cho bài toán lựa chọn phần tử giao diện như trong Mind2Web [9]. Chúng tôi không huấn luyện hoặc tinh chỉnh Phi-4 trên AndroidControl.

Bảng 5.6: Tỉ lệ Phi-4 chọn đúng phần tử trong số các phần tử được đánh số trên ảnh, trên 4.463 bước có thao tác chạm. Với S1/202, chỉ 1.652 bước có câu khác S1/101 được đánh giá lại, các bước còn lại dùng kết quả của S1/101. Dấu – cho biết KTC chưa được báo cáo cho nhánh tương ứng.

Câu đưa cho mô hình listener	**Chọn đúng**	**KTC 95%**
Câu chuẩn	54,94	–
S1/202	45,53	–
Phương pháp đề xuất	45,33	[43,57; 47,12]
GRPO-SPICE	45,33	[43,59; 47,11]
S1/101	44,63	[42,88; 46,37]
Mô hình gốc (Base)	38,23	[36,53; 39,93]

Trên đủ 4.463 bước (Bảng 5.6), mô hình gốc đạt 38,23% còn S1/101 đạt 44,63%, chênh +6,41 điểm. GRPO-SPICE đạt 45,33%, cao hơn S1/101 0,69 điểm [+0,02; +1,40]. ACE cũng đạt 45,33% và cho kết quả tương đương GRPO-SPICE. S1/202 đạt 45,53%, gần với hai cấu hình này. Listener ngoài họ Qwen vì vậy vẫn giữ chiều Base < S1/101 < GRPO-SPICE, trong khi chênh lệch giữa các mô hình đã tinh chỉnh nhỏ hơn đáng kể so với khoảng cách S1–Base.

Khi lặp lại đánh giá trên 200 bước, mô hình listener cho kết quả hoàn toàn nhất quán giữa các lần chạy. Mức đồng thuận theo từng bước giữa listener và UGround ở mức vừa phải (κ từ 0,25 đến 0,44 tùy mô hình). Hai công cụ vì thế có thể khác nhau ở từng bước cụ thể nhưng vẫn duy trì cùng thứ hạng giữa các hệ thống.

Phi-4 chỉ nhận câu hướng dẫn và ảnh đã đánh số, không có thêm mục tiêu tác vụ hay lịch sử thao tác như thiết lập executability. Vì vậy, listener này được dùng như một phép kiểm độc lập cho thứ hạng và chiều của các chênh lệch chính, còn executability vẫn là chỉ số chính.

5.11 So sánh với các độ đo dựa trên câu chuẩn

Để đối chiếu executability với các cách đánh giá dựa trên câu chuẩn ở Mục 2.6, chúng tôi khảo sát trực tiếp hai cách so sánh gồm so sánh chuỗi và độ tương đồng ngữ nghĩa. Với so sánh chuỗi, 97,5% các cách diễn đạt khác của cùng một nội dung trong tập khảo sát được xem là khác câu chuẩn.

Với độ tương đồng ngữ nghĩa, chúng tôi sử dụng 51 trường hợp viết tay: 25 cặp cùng phần tử nhưng khác cách gọi, 15 cặp khác phần tử có từ ngữ chồng lấn và 11 cặp khó liên quan đến trạng thái đối lập, số, hướng hoặc quan hệ cha–con. Phép thử dùng `bge-m3` [16] để tạo biểu diễn nhúng và độ tương đồng cosine để so sánh hai vế. Trong các cặp cùng phần tử, điểm cosine trung bình là 0,62. Ở 15 cặp khác phần tử có từ ngữ chồng lấn, trung bình là 0,67. Cặp `inbox` và `outbox`, dù là hai phần tử khác nhau, có điểm 0,76. Trong khi `search` và `magnifying glass`, hai cách gọi có thể quy chiếu cùng một phần tử, chỉ đạt 0,55. Các giá trị này cho thấy độ gần trong không gian nhúng không thay đổi theo cùng chiều với quan hệ quy chiếu trong tập khảo sát, nên không quan sát thấy một ngưỡng cosine có thể phân tách đáng tin cậy các cặp cùng phần tử và khác phần tử. Kết luận này chỉ áp dụng cho tập kiểm tra và mô hình nhúng nêu trên, không được dùng để suy rộng cho mọi mô hình nhúng ngữ nghĩa.

Hai phân tích trên cho thấy cách so sánh với một câu chuẩn và executability tập trung vào những khía cạnh khác nhau của câu đầu ra. Trên đầu ra thực tế của các mô hình, trong những câu được executability chấp nhận, 52,8% số câu của mô hình chưa tinh chỉnh có F1 trên các từ nội dung so với câu chuẩn dưới 0,5, so với 13,9% ở mô hình đã tinh chỉnh. Mức gần với câu chuẩn vì vậy chịu ảnh hưởng đáng kể bởi cách diễn đạt, còn executability tập trung vào phần tử và thao tác mà câu hướng tới.

Bảng 6.1 ở Chương 6 có thêm BLEU-4 [20], tính cho từng câu rồi lấy trung bình, và ROUGE-L [21], F1 của chuỗi con chung dài nhất. Với ba loại câu có chất lượng khác biệt rõ rệt (câu của mô hình gốc, của S1 và câu chuẩn), hai độ đo này và executability cho cùng thứ hạng. Vì vậy, các độ đo dựa trên câu chuẩn vẫn có thể phản ánh những khác biệt lớn giữa các mô hình.

Trong thiết lập này, các độ đo dựa trên câu chuẩn và executability bổ sung cho

nhau. Câu chuẩn đạt 100 điểm theo ROUGE-L và 96,1 điểm theo BLEU-4, trong khi executability của câu chuẩn là 75,7 và còn phân biệt được các bước đạt hoặc chưa đạt theo phần tử và thao tác. Với các mô hình đã tinh chỉnh có kết quả executability gần nhau, thứ hạng giữa các độ đo cũng có thể khác. Bảng 6.1 cho thấy executability, BLEU-4 và ROUGE-L không luôn xếp các cấu hình theo cùng thứ tự. Vì vậy, chúng tôi báo cáo song song các độ đo dựa trên câu chuẩn và executability, trong đó executability được dùng làm tiêu chí chính cho khả năng xác định phần tử và thao tác. Zhao và cộng sự [37] cũng thảo luận sự khác biệt giữa các độ đo khi đánh giá chỉ dẫn điều hướng có grounding và khuyến nghị SPICE khi có câu chuẩn.

5.12 Độ nhạy của kết luận theo tiêu chí đánh giá

5.12.1 Độ ổn định của thứ hạng và kết luận thống kê

Giá trị tuyệt đối của điểm số phụ thuộc vào tiêu chí dùng để xác định một dự đoán đúng. Khi đánh giá lại câu chuẩn, S1 và mô hình gốc trên 698 bước theo năm tiêu chí khác nhau, điểm tuyệt đối thay đổi tới 26 điểm (Bảng 5.7), nhưng thứ hạng giữa các mô hình vẫn được duy trì. Chênh lệch S1–Base dao động từ 9,5 đến 13,0 điểm và luôn lớn hơn đáng kể sai số chuẩn ghép cặp (Mục 5.13).

Bảng 5.7: Điểm của câu chuẩn và chênh lệch giữa S1 với mô hình gốc theo năm tiêu chí đánh giá (698 bước): đĩa Euclid, hình chữ nhật theo từng trục, ô Voronoi, ô Voronoi lấy hạt là tâm hộp chứa g, và hộp gần nhất. g là điểm chạm của người dùng.

	Đĩa	**Chữ nhật**	**Voronoi**	**Voronoi (hạt tâm hộp)**	**Hộp gần nhất**
Câu chuẩn	80,2	82,2	74,2	56,6	82,2
S1 − mô hình gốc (Base)	+12,6	+13,0	+11,7	+9,5	+13,0

Ảnh hưởng đến kết luận thống kê. Việc thay đổi tiêu chí đánh giá có thể dẫn tới kết luận thống kê khác nhau. Bảng 5.8 so sánh mô hình sau giai đoạn thưởng tọa độ (một hướng đã thử, Phụ lục A) với S1/101 theo ba tiêu chí, và kết luận thay đổi tùy tiêu chí.

Bảng 5.8: Kết luận thống kê theo ba tiêu chí cho cùng một phép so: mô hình sau giai đoạn thưởng tọa độ trừ S1/101, trên 4.463 bước có thao tác chạm. Cả ba tiêu chí đều yêu cầu đúng loại thao tác. Cột p là giá trị p trước hiệu chỉnh, cột cuối là kết luận sau khi hiệu chỉnh Holm cho ba kiểm định. Hàng vế khoảng cách AitW chỉ dùng điều kiện khoảng cách của tiêu chí AndroidInTheWild, không gồm điều kiện hộp phần tử, nên khác số AitW đầy đủ ở Bảng 6.7.

Tiêu chí	Δ	**p**	**Sau hiệu chỉnh Holm**
Cửa sổ $\pm$ 14% từng trục	+2,13	0,0003	còn ý nghĩa thống kê
Vế khoảng cách AitW	+1,99	0,0010	còn ý nghĩa thống kê
Ô Voronoi (executability)	+0,96	0,0860	không có ý nghĩa thống kê

Sự khác biệt giữa các kết luận phản ánh mức độ chặt khác nhau của từng tiêu chí. Executability yêu cầu câu dẫn tới đúng phần tử khi có các phần tử lân cận cạnh tranh, trong khi tiêu chí dung sai chấp nhận mọi điểm đủ gần tọa độ tham chiếu. Vì vậy, các câu chứa ít thông tin quy chiếu có xu hướng nhận điểm cao hơn theo tiêu chí dung sai. Chẳng hạn, câu chung chung "*Tap the button.*" đạt 12,00 với executability nhưng 20,50 theo tiêu chí dung sai. Vì vậy, chúng tôi trình bày song song các tiêu chí có tiền lệ trong công trình trước như các chỉ số bổ sung bên cạnh executability.

Ảnh hưởng của việc điều chỉnh quy tắc chuẩn hoá loại thao tác. Khi điều chỉnh riêng quy tắc nêu ở Mục 5.1, điểm của S1 giảm từ 59,12 xuống 58,81 và của Base từ 47,60 xuống 47,40. Chênh lệch S1–Base đổi từ 11,52 thành 11,41 điểm. Mức thay đổi nhỏ và không làm thay đổi kết luận của phép so sánh. Các bảng chính vẫn dùng quy tắc ban đầu để giữ nhất quán giữa toàn bộ lượt đánh giá.

5.12.2 Đối chiếu với các tiêu chí dùng trong bộ dữ liệu GUI

Tiêu chí hộp phần tử của AndroidControl. Phụ lục D.3 của bài gốc AndroidControl [1] coi một dự đoán là đúng khi tọa độ nằm trong hộp bao của phần tử cần chạm, vì chạm vào đâu trong phần tử thì phần tử cũng kích hoạt. Chúng tôi gọi cách đánh giá này là tiêu chí hộp phần tử. Hộp bao có sẵn trong nhãn của tập kiểm tra, nên tiêu chí này tính được từ các điểm mô hình định vị đã trả về (Bảng 5.9).

Thứ hạng giữa các mô hình không thay đổi, và chênh lệch giữa S1 với mô hình gốc là 11,9 điểm, gần tương đương mức chênh theo tiêu chí ô Voronoi. Trên mẫu 800

Bảng 5.9: Điểm theo tiêu chí hộp phần tử (Phụ lục D.3 của AndroidControl) trên 4.463 bước có thao tác chạm. Giai đoạn học ưu tiên và mô hình chọn ứng viên là hai hướng đã thử (Phụ lục A). Cột cuối yêu cầu thêm điều kiện điểm dự đoán nằm trong cửa sổ dung sai 14%. Hai hàng cuối là các mốc tham chiếu dưới, được tính trên mẫu 800 bước.

	Ô Voronoi	**Hộp phần tử**	**Hộp phần tử ∧ cửa sổ 14%**
Câu chuẩn	75,7	83,8	79,2
Giai đoạn học ưu tiên (MIN-DESC)	60,0	66,5	62,7
S1/101	59,1	65,5	61,7
Mô hình chọn ứng viên (Mục A.3.2)	56,1	62,4	58,6
Mô hình gốc (Base)	47,6	53,6	49,8
Câu chung chung (mốc dưới, mẫu 800)	12,0	14,1	12,1
Câu của màn hình khác (mốc dưới, mẫu 800)	6,1	8,6	6,6

bước, điểm của câu chuẩn tăng từ 74,9 lên 83,0 khi sử dụng tiêu chí hộp phần tử, trong khi các câu dùng làm mốc dưới tăng ít hơn. Khác biệt này liên quan đến việc dung sai phụ thuộc vào kích thước phần tử. Xét theo chiều dọc, chiều cao trung vị của hộp chỉ bằng 5,2% màn hình, chặt hơn đáng kể so với cửa sổ 14%.

Điểm 83,8 của câu chuẩn phản ánh cách tiêu chí hộp phần tử sử dụng hình học của hộp bao thay vì khoảng cách tới các tâm cạnh tranh. Phân tích cấu trúc hộp cho thấy khoảng 48% số bước sử dụng nút nhỏ nhất chứa điểm chạm, trong khi 78% mức tăng so với ô Voronoi tập trung ở các bước có hộp rộng hơn nửa màn hình. Trên các hàng danh sách, tiêu chí hộp cũng ít bị ảnh hưởng hơn bởi các mảnh chữ OCR nằm gần nhau. Vì vậy, kết quả theo hai tiêu chí được báo cáo song song để đối chiếu các mô hình dưới hai cách xác định phần tử khác nhau.

Tiêu chí AndroidInTheWild. Tiêu chí này được lấy từ mã đánh giá gốc của AndroidInTheWild [2], một bộ dữ liệu điều khiển thiết bị Android được sử dụng trong nhiều nghiên cứu về tác tử giao diện. Hai lần chạm được xem là tương ứng khi khoảng cách Euclid giữa hai điểm, trên hệ tọa độ chuẩn hoá về [0; 1], không vượt quá 0,14, hoặc khi cả hai điểm cùng nằm trong một khung phần tử được nới thêm 1,4 lần theo

cả chiều cao và chiều rộng. Chúng tôi bổ sung điều kiện đúng loại thao tác. Trong các bảng kết quả, biến thể gồm cả hai điều kiện này được gọi là *AitW đầy đủ*, còn phép đo chỉ dùng điều kiện khoảng cách được gọi là *về khoảng cách AitW*. Mã gốc xét mọi khung chú thích trên màn hình, trong khi dữ liệu chúng tôi sử dụng chỉ có khung của phần tử cần chạm, nên biến thể xấp xỉ này chỉ có thể cho điểm không cao hơn tiêu chí gốc. Trên mẫu 800 bước, khoảng điểm giữa câu chuẩn (90,8) và mốc dưới tương ứng là 64,9 điểm, rộng hơn mức 62,9 của executability. Tiêu chí này ít nhạy hơn với việc thiếu tên phần tử: câu bỏ tên nhưng giữ vị trí chỉ thấp hơn câu chuẩn 4,5 điểm, so với 6,9 điểm khi đánh giá bằng executability (Mục 5.6). Vì vậy, AitW đầy đủ được báo cáo song song với executability thay vì thay thế độ đo chính. Điểm của từng mô hình được trình bày ở Bảng 6.5.

Cận trên của AitW. Ở biến thể còn lại, việc xét khung được mở rộng tới mọi phần tử có thể chạm trên màn hình, lấy từ cây trợ năng và chỉ giữ các khung chiếm không quá nửa màn hình. Do đó tiêu chí gốc nằm giữa hai biến thể. Với biến thể cận trên, câu chuẩn đạt 96,2% nhưng câu chung chung cũng tăng lên 41,6% (mẫu 800 bước), nên khoảng phân tách chỉ còn 54,3 điểm, hẹp hơn cả executability. Vì vậy, kết quả AitW được trình bày cùng biến thể cận trên khi cần phân tích độ nhạy, còn AitW đầy đủ với hộp phần tử đích được dùng làm giá trị chính trong các bảng so sánh.

5.13 Phương pháp phân tích thống kê

Điểm. Điểm là tổng số bước đúng chia tổng số bước.

Khoảng tin cậy. Khoảng tin cậy của các phân tích chính được ước lượng bằng bootstrap phi tham số với 10.000 lần lấy mẫu theo cách gom cụm trình bày dưới đây. Ở mỗi lần lặp, các cụm được lấy mẫu lại có hoàn lại, sau đó điểm số được tính lại. Khoảng tin cậy được xác định từ các phân vị của phân bố thu được. Khi một phân tích sử dụng đơn vị gom cụm khác, cách tính được ghi rõ tại bảng tương ứng. Vì độ chính xác của bootstrap theo cụm phụ thuộc vào số lượng cụm [27], chúng tôi báo cáo cả số cụm cùng các khoảng tin cậy.

Tiêu chí gom cụm. Các bước xác định được ứng dụng được gom theo ứng dụng. Với những bước không xác định được ứng dụng, mỗi tác vụ được xem là một cụm riêng

để tránh gộp các tác vụ không liên quan chỉ vì cùng thiếu nhãn ứng dụng. Tổng cộng có 1.091 cụm, cụm lớn nhất gồm 58 bước. Số cụm hiệu dụng theo công thức Kish [28] là 454,3. Kết luận giữ ổn định khi thay cách gom cụm: khoảng tin cậy của mức chênh lệch giữa S1 và mô hình gốc là [+10,0; +13,1] với cách chính, cũng là [+10,0; +13,1] khi gom mọi bước theo tác vụ, và [+10,2; +13,8] khi dồn mọi bước không nhãn vào một cụm.

So sánh ghép cặp. Trong các so sánh executability chính, các mô hình được đánh giá trên cùng 4.463 bước có thao tác chạm nên các chênh lệch được phân tích theo cặp. Mỗi cặp mô hình được báo cáo bằng khoảng tin cậy ghép cặp và giá trị p của kiểm định McNemar (Mục 4.8), chỉ dựa trên các bước hai mô hình cho kết quả khác nhau, với b là số bước mô hình thứ nhất đạt còn mô hình thứ hai không đạt và c là chiều ngược lại. Hệ số nở do gom cụm, tức mức phóng to độ bất định do các bước cùng cụm tương quan, là 1,10 trong phép tính hiện tại. Như một minh hoạ cho lợi ích của ghép cặp, sai số chuẩn của hiệu S1–Base là 0,79 điểm, so với 1,05 điểm nếu tính như hai tỉ lệ độc lập. Mức dao động giữa các lượt huấn luyện không thuộc sai số của độ đo và được phân tích riêng ở Mục 6.7.

Chương 6

Thực nghiệm và kết quả

Chương này trình bày kết quả thực nghiệm của phương pháp đề xuất. Sau kết quả tổng thể ở Mục 6.2, Mục 6.3 và Mục 6.4 phân tích riêng hai thành phần của phương pháp. Các mục tiếp theo đối chiếu nhiều nhóm độ đo, xem xét biến thiên giữa các lượt huấn luyện, rồi kiểm tra khả năng khái quát trên tác vụ mới, miền dữ liệu khác và lịch sử do mô hình tự sinh. Phần cuối phân tích các dạng lỗi còn lại và tóm tắt những phương án đã khảo sát trước khi hình thành phương pháp cuối cùng.

6.1 Thiết lập thực nghiệm

Mọi mô hình được đánh giá trên cùng 4.463 bước có thao tác chạm của tập kiểm tra bằng cùng một quy trình đánh giá. Phương pháp đề xuất gồm mô hình học tăng cường với phần thưởng SPICE để sinh câu hướng dẫn ban đầu và ACE để quyết định có hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ hay không (Mục 4.4 đến Mục 4.6).

Ba mốc so sánh (Mục 4.7) gồm mô hình gốc (Base), mô hình tinh chỉnh có giám sát qua hai lượt với seed 101 và 202 (S1), và câu chuẩn được đưa trực tiếp vào quy trình đánh giá làm mốc tham chiếu để diễn giải thang điểm. Mọi bước trong tập kiểm tra đều được giữ trong mẫu số đánh giá.

6.2 Kết quả chính

Các hướng đã thử khác (mô-đun định vị, đưa vai trò và vùng của phần tử vào mô hình, làm nét ảnh, mở khoá phần thị giác) không xuất hiện trong bảng vì chỉ được đánh giá

Bảng 6.1: Kết quả chính trên 4.463 bước có thao tác chạm của tập kiểm tra. Exec. là executability, KTC 95% là khoảng tin cậy 95% của executability. Hộp phần tử là tiêu chí của AndroidControl, AitW đầy đủ là tiêu chí của AndroidInTheWild. BLEU-4 và ROUGE-L ở đây là trung bình theo câu: BLEU không làm mượt nên câu ngắn hơn bốn từ nhận 0 điểm và hàng câu chuẩn chỉ đạt 96,1, ROUGE-L tính theo F1. Hai cột này khác BLEU-4 và ROUGE-L của bộ công cụ COCO ở Bảng 6.3, 6.4 và 6.6. Số in đậm là số cao nhất của cột, không tính hàng câu chuẩn, và không hàm ý chênh lệch có ý nghĩa thống kê (xem Bảng 6.8). †Mô hình chọn ứng viên khác các mô hình còn lại ở ba yếu tố của thiết lập (Mục A.3.1), nên chỉ so sánh trực tiếp được với mô hình gốc (Mục A.3.2).

Mô hình	Exec.	KTC 95%	Hộp phần tử	AitW đầy đủ	BLEU-4 theo câu	ROUGE-L theo câu
Mốc so sánh						
Mô hình gốc (Base)	47,59	[45,9; 49,3]	53,60	63,39	9,9	40,4
Qwen2.5-VL-7B, chỉ prompting	51,51	[49,82; 53,15]	57,67	66,79	–	–
Tinh chỉnh có giám sát (S1/101)	59,11	[57,3; 60,8]	65,49	74,37	38,7	67,3
Tinh chỉnh có giám sát (S1/202)	59,62	[57,9; 61,3]	66,10	75,31	39,0	67,6
Nhánh đối chứng, điểm SPICE ghép ngẫu nhiên	59,11	–	65,58	74,59	–	–
Phương pháp đề xuất						
GRPO-SPICE, lượt 2	59,94	[58,13; 61,71]	66,55	76,23	–	–
GRPO-SPICE (thành phần thứ nhất)	**60,65**	[58,9; 62,4]	67,02	76,25	40,1	68,3
Phương pháp đề xuất (GRPO-SPICE + ACE)	**60,68**	[58,9; 62,4]	**67,11**	76,32	**41,2**	**69,1**
Các hướng đã thử (Phụ lục A)						
Mô tả phần tử (S2)	57,2	[55,4; 58,9]	63,6	73,4	36,4	65,9
Học thêm có giám sát (CE2-S2)	59,4	[57,7; 61,1]	66,0	76,1	38,1	68,6
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	[58,3; 61,8]	66,5	76,4	37,9	68,4
Thưởng tọa độ (giai đoạn ba)	60,1	[58,3; 61,8]	67,0	**77,3**	37,8	68,5
Chọn ứng viên†	56,1	[54,2; 58,0]	62,4	71,2	34,5	63,0
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	[58,5; 62,0]	66,4	76,1	40,1	68,4
Câu chuẩn (mốc tham chiếu)	75,7	[74,1; 77,3]	83,8	92,1	96,1	100,0

trên tập kiểm định nội bộ (Mục A.6).

Qwen2.5-VL-7B chỉ dùng prompting đạt 51,51% executability, cao hơn Base 3,92 điểm nhưng thấp hơn S1/101 7,60 điểm và thấp hơn GRPO-SPICE 9,14 điểm. Trong thiết lập này, mô hình 3B sau khi được tinh chỉnh cho kết quả cao hơn rõ rệt so với mô hình 7B chỉ dùng prompting. Phép so với 7B sử dụng cùng câu nhắc của Base và không tối ưu câu nhắc riêng cho mô hình 7B. Chúng tôi cũng không có phép kiểm độc lập để loại trừ khả năng mô hình nền 7B đã gặp AndroidControl trong giai đoạn tiền huấn luyện, nên phép so này chỉ được diễn giải trong thiết lập prompting đã thử.

GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm với khoảng tin cậy 95% [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Hướng tăng được giữ khi thay luật xác định điểm chạm: so với cả hai lượt S1, chênh lệch của GRPO-SPICE đều dương theo executability, tiêu chí hộp phần tử, tiêu chí hộp phần tử kết hợp cửa sổ 14% và AitW đầy đủ, với các khoảng tin cậy nằm trên 0. Lượt GRPO thứ hai đạt 59,94%, cao hơn S1/101 0,83 điểm và cao hơn 1,86 điểm theo AitW đầy đủ. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11% executability, đúng bằng S1/101, còn GRPO-SPICE cao hơn nhánh này 1,55 điểm [+0,81; +2,30]. Với cùng số bước huấn luyện, mức tăng chỉ xuất hiện khi tín hiệu SPICE giữ đúng quan hệ với mẫu.

Trên ACU, gồm các tác vụ không xuất hiện trong tập huấn luyện của S1, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48] (Mục 6.8.1). Sau ACE, executability trên tập kiểm tra chính đạt 60,68%, đồng thời cả bảy thước dựa trên câu chuẩn đều tăng (Mục 6.4). Bảng 6.2 tiếp tục phân rã executability theo ba điều kiện cấu thành.

Ở hàng câu chuẩn, đầu vào đánh giá chính là câu chuẩn nên điều kiện đúng loại thao tác luôn được thỏa mãn. Tỉ lệ đúng loại thao tác 98,9% của giai đoạn học theo cặp ưu tiên, mô hình học thêm có giám sát và giai đoạn thưởng tọa độ được tính trên các bước có thao tác chạm. Mô hình chọn ứng viên (†) chỉ được so sánh trực tiếp với mô hình gốc do khác thiết lập huấn luyện (Mục A.3.2).

Vị trí của S1 trên thang điểm. S1 cải thiện 11,5 điểm executability so với mô hình gốc. Đây là mức tăng lớn và ổn định, trong khi câu chuẩn đạt 75,7% và được dùng làm mốc tham chiếu của quy trình đánh giá. Các giai đoạn tiếp theo tiếp tục cải

Bảng 6.2: Phân rã executability theo từng điều kiện hợp thành (tỉ lệ bước, %). Đạt đầy đủ: thoả cả ba điều kiện của executability. Chỉ ô Voronoi: điểm định vị nằm trong cửa sổ dung sai và trong ô Voronoi của phần tử cần chạm, chưa xét loại thao tác. Khớp thao tác: câu gọi đúng loại thao tác. Cửa sổ dung sai: điểm định vị nằm trong cửa sổ $\pm 14\%$ theo từng trục quanh điểm chạm chuẩn.

Mô hình	Đạt đầy đủ	Chỉ ô Voronoi	Khớp thao tác	Cửa sổ dung sai
Câu chuẩn (mốc tham chiếu)	75,7	75,8	100,0	84,3
Phương pháp đề xuất	60,7	61,5	96,0	70,4
GRPO-SPICE	60,7	61,4	96,0	70,3
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	60,2	61,0	96,6	70,1
Thưởng tọa độ (giai đoạn ba)	60,1	60,5	98,9	69,9
Học theo cặp ưu tiên trên dòng mô tả (MIN-DESC)	60,0	60,4	98,9	69,2
S1/202	59,6	60,7	94,6	69,8
Học thêm có giám sát (CE2-S2)	59,4	59,8	98,9	68,9
S1/101	59,1	60,2	94,4	69,2
Mô tả phần tử (S2)	57,2	58,1	94,8	67,4
Chọn ứng viên†	56,1	57,4	90,9	66,3
Mô hình gốc (Base)	47,6	48,9	96,5	57,6

thiện từ điểm xuất phát S1 (Mục 6.3 và Mục 6.4).

6.3 Thành phần thứ nhất: học tăng cường với phần thưởng SPICE

Mục này đánh giá độc lập thành phần thứ nhất (thiết kế ở Mục 4.5). Mô hình học tăng cường với phần thưởng SPICE học tiếp từ S1/101, nên được so sánh trực tiếp với cấu hình này.

Phân tích tín hiệu phần thưởng trên tập kiểm định nội bộ. Trước khi huấn luyện, S1 được dùng để sinh một câu bằng giải mã tham lam và tám câu bằng lấy mẫu cho mỗi bước. Nếu chọn câu có SPICE cao nhất so với câu chuẩn, executability cao hơn so với câu từ giải mã tham lam. Trong khi đó, việc chọn ngẫu nhiên một trong tám câu không tạo ra xu hướng tương tự. Executability cũng có xu hướng giảm ở những câu có thứ hạng SPICE thấp hơn trong cùng một nhóm. SPICE vì vậy cung cấp tín hiệu phân biệt hữu ích cho quá trình huấn luyện. Phân tích này được dùng để lựa chọn thiết kế trước khi đánh giá trên tập kiểm tra.

Lựa chọn số bước huấn luyện. Mô hình ở bước 250 và bước 500 được so sánh trên cùng tập kiểm định nội bộ. Executability tăng khi tiếp tục huấn luyện đến bước 500, và phần lớn các trường hợp đã được sửa đúng ở bước 250 vẫn được giữ. Vì vậy, mô hình sau 500 bước được chọn và cố định trước khi sinh câu trên tập kiểm tra.

6.3.1 Kết quả trên các bước có thao tác chạm

GRPO-SPICE đạt điểm cao hơn S1/101 trên cả mười ba độ đo trong Bảng 6.3. Với sáu độ đo dựa trên vị trí và cả sáu thước chữ có KTC, khoảng tin cậy của chênh lệch đều nằm hoàn toàn trên 0. Executability tăng 1,55 điểm, với $p = 1{,}6 \times 10^{-5}$ theo kiểm định McNemar (Mục 6.6). Phần thưởng huấn luyện chỉ sử dụng SPICE và không dùng mô hình định vị, nhưng mức tăng vẫn xuất hiện đồng thời ở các tiêu chí dựa trên vị trí và toàn bộ nhóm thước chữ có KTC. Lượt GRPO thứ hai tiếp tục giữ hướng cải thiện so với S1/101, như phân tích ở Mục 6.7.2.

Bảng 6.3: GRPO-SPICE so với S1/101, ghép cặp theo bước. Sáu hàng đầu là độ đo theo vị trí trên 4.463 bước có thao tác chạm, gồm cả tỉ lệ đúng loại thao tác. Bảy hàng cuối là độ đo so với câu chuẩn. Δ là điểm của GRPO-SPICE trừ điểm của S1/101. KTC 95% tính bằng bootstrap theo cụm (Mục 5.13). Với nhóm độ đo dựa trên câu chuẩn, BLEU-4, ROUGE-L, CIDEr-D, SPICE, chrF và BERTScore có KTC từ 2.000 lần lấy mẫu theo cùng các cụm. METEOR chỉ có điểm mức kho. Cột cuối không áp dụng cho nhóm này.

Độ đo	**S1/101**	**GRPO-SPICE**	**Δ**	**KTC 95%**	**Sai→Đúng / Đúng→Sai**
Executability	59,11	60,65	+1,55	[+0,80; +2,33]	159 / 90
Tiêu chí hộp phần tử	65,49	67,02	+1,52	[+0,77; +2,29]	165 / 97
AitW đầy đủ	74,37	76,25	+1,88	[+1,17; +2,63]	172 / 88
AitW cận trên	81,04	82,90	+1,86	[+1,17; +2,60]	163 / 80
$\pm$14% theo trục	67,24	68,90	+1,66	[+0,90; +2,46]	172 / 98
Đúng loại thao tác	94,35	95,97	+1,61	[+1,17; +2,08]	83 / 11
SPICE	44,37	45,79	+1,42	[+0,71; +2,16]	-
BLEU-4	51,56	52,36	+0,80	[+0,22; +1,60]	-
METEOR	36,79	37,92	+1,13	-	-
ROUGE-L	67,35	68,36	+1,01	[+0,55; +1,48]	-
CIDEr-D	416,12	430,05	+13,93	[+8,05; +19,91]	-
chrF	61,26	62,87	+1,61	[+1,10; +2,11]	-
BERTScore	66,33	67,07	+0,74	[+0,32; +1,15]	-

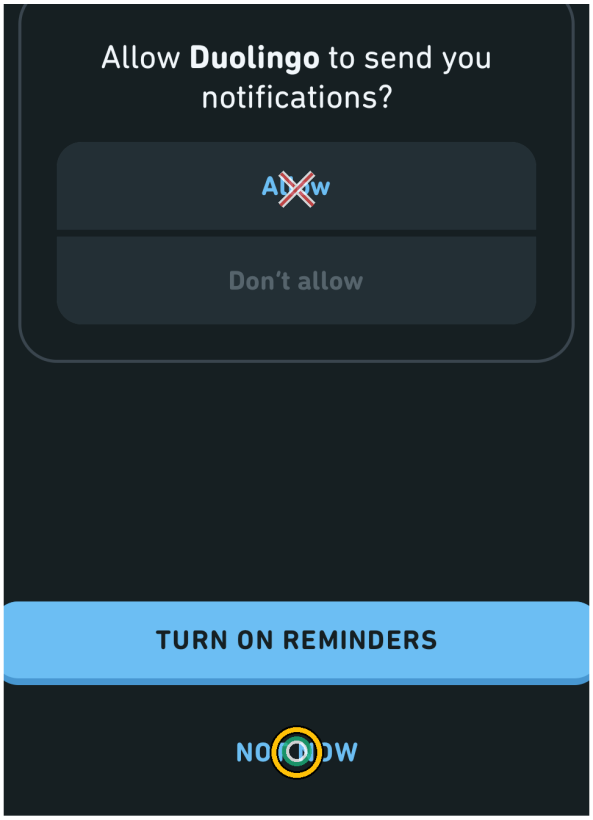
Phân rã nguồn gốc mức cải thiện. Trong 159 bước chuyển từ sai sang đúng, 36 bước là những trường hợp S1 dự đoán sai loại thao tác. Ở chiều ngược lại, trong 90 bước chuyển từ đúng sang sai, chỉ 8 bước xuất phát từ lỗi loại thao tác của mô hình học tăng cường. Việc sửa loại thao tác đóng góp ròng 28 bước, tương đương +0,63 điểm. Phần cải thiện còn lại đến từ 4.200 bước mà cả hai mô hình đều xác định đúng loại thao tác: trên nhóm này, executability tăng từ 62,62 lên 63,60, tương đương thêm 41 bước đúng (+0,92 điểm). Hơn một nửa mức cải thiện nằm ở khả năng xác định đúng phần tử cần chạm khi loại thao tác đã đúng. Hình 6.1 minh họa một bước thuộc nhóm này.

Thí nghiệm đối chứng với điểm SPICE ghép ngẫu nhiên. Nhánh này được huấn luyện thêm cùng 500 bước GRPO nhưng sử dụng điểm SPICE được ghép ngẫu nhiên giữa các mẫu. Executability đạt 59,11%, bằng S1/101, và cả sáu thước chữ có KTC cũng không khác S1/101. Ngược lại, GRPO-SPICE cao hơn nhánh này 1,55 điểm executability [+0,81; +2,30], đồng thời cao hơn ở cả sáu thước chữ có KTC. Sự khác biệt giữa hai nhánh tách rõ mức cải thiện do tín hiệu SPICE khỏi ảnh hưởng của việc tiếp tục cập nhật mô hình.

Ablation phần thưởng CIDEr-D. Khi thay SPICE bằng CIDEr-D trong một lượt GRPO 500 bước, executability thấp hơn GRPO-SPICE 0,69 điểm, với khoảng tin cậy 95% [−1,34; −0,02]. Kéo dài quá trình huấn luyện với CIDEr-D đến 1.000 bước không tạo thêm cải thiện đáng kể. Phân rã theo từng bước cho thấy CIDEr-D có lợi hơn ở loại thao tác nhưng thấp hơn ở khả năng chọn đúng phần tử. Mỗi cấu hình trong phép so này được chạy một lượt. Hai lượt còn khác về số câu nhắc dùng khi huấn luyện (1.000 so với 2.000) và môi trường tính toán (T4 fp16 so với A100 bf16). Vì vậy, kết quả được dùng để hỗ trợ lựa chọn SPICE trong thiết lập đã thử, không để kết luận ưu thế tổng quát của một thước phần thưởng.

So với S1, mô hình học tăng cường chỉ thay đổi một phần đầu ra: 2.795 trong 4.463 câu được giữ nguyên hoàn toàn, còn độ dài trung bình chỉ tăng từ 7,83 lên 7,96 từ. Vì vậy, mức cải thiện không thể giải thích đơn thuần bằng việc sinh câu dài hơn.

So sánh với các cấu hình khác. GRPO-SPICE cao hơn cả S1/101 và S1/202 trên executability, với mức tăng lần lượt 1,55 và 1,03 điểm. Lượt GRPO thứ hai cũng cao hơn điểm xuất phát S1/101 0,83 điểm. Cả hai lượt GRPO đều giữ hướng cải thiện so



Vòng vàng: điểm người dùng đã chạm
Câu tham chiếu: "Click on the Not now button to remove this pop up notification"
S1/101: "Click on the Allow button" → không đạt
GRPO-SPICE: "Click on the Not Now button at the bottom of the screen" → đạt

Hình 6.1: Một bước được GRPO-SPICE sửa đúng (ảnh chỉ giữ phần dưới màn hình). Cần chạm nút *Not now* ở cuối màn, trong khi một hộp thoại hỏi quyền gửi thông báo đang che màn hình. S1 gọi nút *Allow* trong hộp thoại nên mô hình định vị xác định sai phần tử. GRPO-SPICE gọi đúng nút *Not now* kèm vị trí, và mô hình định vị xác định đúng phần tử. Vòng vàng là điểm người dùng chạm. Dấu X đỏ và vòng xanh lá là điểm mà mô hình định vị trả về khi đọc câu của S1/101 và của GRPO-SPICE.

với điểm xuất phát, còn lượt được dùng trong phương pháp đề xuất cao hơn cả hai lượt S1. Trên nhóm thước chữ, GRPO-SPICE cao hơn S1/101 ở cả bảy thước, và cả sáu thước có KTC đều loại 0. Tín hiệu SPICE vì vậy đi cùng mức tăng ở cả executability và chất lượng câu so với câu chuẩn.

Phạm vi trên các bước không chạm. Các kết quả chính ở mục này được tính

trên các bước có thao tác chạm. Khi xét khả năng gọi đúng loại thao tác ở các bước không chạm, GRPO-SPICE chưa giữ được cùng chiều cải thiện: trên toàn bộ nhóm này, tỉ lệ giảm từ 85,97% ở S1 xuống 84,29%. Với thao tác cuộn, S1 đạt 83,97% còn GRPO-SPICE đạt 77,75%, chênh $-6{,}23$ điểm $[-8{,}30; -4{,}31]$. Với thao tác quay lại, mức chênh là $-5{,}93$ điểm. Trong 51 bước cuộn chuyển từ đúng ở S1 sang sai sau GRPO-SPICE, 47 câu chuyển sang dạng thao tác chạm. Phân tích này xác định một giới hạn của phần thưởng SPICE trong thiết lập hiện tại: mô hình có xu hướng lệch về câu thao tác chạm. Đây cũng là một động lực để ACE giữ thêm ràng buộc nhất quán loại thao tác ở thành phần thứ hai.

6.4 Thành phần thứ hai: hiệu chỉnh bằng câu ví dụ với ràng buộc nhất quán thao tác (ACE)

Trên tập kiểm tra, điều kiện đồng thuận của ACE (Mục 4.6) thay thế 402 trong 4.463 câu hướng dẫn ban đầu (9,0%). Bảng 6.4 so sánh ACE, tức phương pháp đề xuất, với câu hướng dẫn ban đầu và với mô hình sinh câu độc lập, trong đó đầu ra của mô hình sinh được sử dụng ở mọi bước.

Khả năng của kho truy hồi. Với mỗi bước có thao tác chạm trong tập kiểm tra, bốn câu chuẩn gần nhất được truy hồi từ tập huấn luyện theo quy trình ở Mục 4.6. Trong 15,8% số bước, ít nhất một câu ví dụ giống hoàn toàn với câu chuẩn của bước đang xét. Ở 9,8% số bước, điều này xảy ra đồng thời với việc câu hướng dẫn ban đầu của thành phần thứ nhất không đạt. Nếu luôn có thể nhận ra và chọn đúng câu ví dụ trong các trường hợp này, BLEU-4 tính trên toàn tập có thể tăng khoảng 5 điểm và CIDEr-D khoảng 65 điểm. Tuy nhiên, một chiến lược đơn giản như luôn lấy câu ví dụ đứng đầu lại làm BLEU-4 giảm từ 52,4 xuống 28,3. Kho truy hồi có chứa thông tin hữu ích, nhưng hiệu quả phụ thuộc vào cơ chế lựa chọn câu ví dụ. Phân tích này được dùng để giải thích vai trò của điều kiện đồng thuận, không thay thế kết quả đánh giá trực tiếp của ACE.

Kết quả. ACE nâng cả bảy thước dựa trên câu chuẩn và giữ executability ở cùng mức với GRPO-SPICE. Cả sáu thước có KTC đều tăng với khoảng tin cậy nằm hoàn toàn trên 0: BLEU-4 +1,11, ROUGE-L +0,74, CIDEr-D +11,97, SPICE +1,33, chrF

Bảng 6.4: ACE trên 4.463 bước có thao tác chạm, so với câu hướng dẫn ban đầu của GRPO-SPICE và với mô hình sinh câu độc lập. Ba độ đo theo vị trí có KTC 95% bootstrap theo cụm (Mục 5.13). Trong nhóm dựa trên câu chuẩn, BLEU-4, ROUGE-L, CIDEr-D, SPICE, chrF và BERTScore có KTC bootstrap với 2.000 lần lấy mẫu. METEOR chỉ có điểm mức kho.

Độ đo	Câu ban đầu	Mô hình sinh độc lập	ACE	ACE − câu ban đầu
Executability	60,65	59,40	60,68	+0,02 [−0,21; +0,26]
Tiêu chí hộp phần tử	67,02	65,81	67,11	+0,09 [−0,15; +0,33]
AitW đầy đủ	76,25	75,02	76,32	+0,07 [−0,15; +0,29]
BLEU-4	52,36	53,47	53,47	+1,11 [+0,78; +1,42]
METEOR	37,92	37,79	38,37	+0,45
ROUGE-L	68,36	68,67	69,11	+0,74 [+0,54; +0,94]
CIDEr-D	430,05	437,54	442,02	+11,97 [+8,24; +15,34]
SPICE	45,79	46,79	47,13	+1,33 [+0,92; +1,75]
chrF	62,87	62,65	63,44	+0,58 [+0,37; +0,80]
BERTScore	67,07	67,52	67,73	+0,66 [+0,46; +0,86]

+0,58 và BERTScore +0,66. METEOR cũng tăng 0,45 điểm nhưng chưa có KTC. Executability đạt 60,68%, chênh +0,02 điểm so với GRPO-SPICE [−0,21; +0,26]. Trong 402 câu được thay thế, có 15 bước chuyển từ sai sang đúng và 14 bước theo chiều ngược lại. ACE vì vậy đưa cách diễn đạt gần câu chuẩn hơn mà không làm giảm executability của GRPO-SPICE. Theo tiêu chí hộp phần tử và AitW đầy đủ, phương pháp hoàn chỉnh cao hơn S1/101 lần lượt 1,61 và 1,95 điểm, cả hai với $p < 0,001$.

Ảnh hưởng khi sử dụng mô hình sinh câu độc lập. Mô hình sinh câu độc lập đạt điểm cao hơn câu hướng dẫn ban đầu trên năm trong bảy độ đo dựa trên câu chuẩn, nhưng thấp hơn 1,25 điểm executability [−2,06; −0,44] ($p = 0,002$). Ở 19,1% số bước, mô hình lặp lại hoàn toàn một câu ví dụ. Trong nhóm này, 43,5% số câu giống hoàn toàn với câu chuẩn, gần gấp đôi tỉ lệ của câu hướng dẫn ban đầu (22,8%). Ngược lại, ở những bước mô hình tạo một câu mới, kết quả thấp hơn câu hướng dẫn ban đầu. Truy hồi có ích khi mô hình lựa chọn đúng câu ví dụ, còn việc thay câu hướng dẫn ban đầu cần đi kèm điều kiện lựa chọn.

Đóng góp của ràng buộc nhất quán loại thao tác. Nếu chỉ dùng điều kiện sao chép, ACE thay 453 câu và vẫn làm tăng cả bảy độ đo dựa trên câu chuẩn, nhưng

executability thấp hơn câu hướng dẫn ban đầu 0,11 điểm (24 bước chuyển từ sai sang đúng và 29 bước chuyển từ đúng sang sai). Ràng buộc loại thao tác loại 51 câu không nhất quán, nhờ đó ACE cao hơn biến thể chỉ dùng điều kiện sao chép 0,13 điểm executability và không thấp hơn ở độ đo nào trong Bảng 6.4.

Phạm vi cải thiện. Lợi ích của ACE thể hiện rõ nhất ở chất lượng câu đầu ra: cả bảy thước dựa trên câu chuẩn đều tăng, và cả sáu thước có KTC đều cho khoảng tăng nằm trên 0. Đồng thời, executability được giữ ở mức của GRPO-SPICE. METEOR chưa có KTC nên được dùng như kết quả bổ sung.

6.5 Đánh giá trên nhiều nhóm độ đo

Ngoài executability, chúng tôi trình bày thêm hai nhóm chỉ số: các độ đo dựa trên vị trí và các độ đo dựa trên câu chuẩn. Cả hai nhóm được tính lại từ bản ghi ở mức từng bước của các lượt đánh giá trong Bảng 6.1. Các bảng dưới đây đặt phương pháp đề xuất cạnh các mốc và những cấu hình đã khảo sát để cho thấy kết quả dưới từng nhóm tiêu chí.

Nhóm độ đo theo vị trí. Bảng 6.5 trình bày ba tiêu chí đánh giá chính cùng hai biến thể ở Mục 5.12. Thứ tự các mô hình theo AitW đầy đủ và hộp phần tử gần với thứ tự theo executability. Phương pháp đề xuất đạt 76,3% theo AitW đầy đủ và 67,1% theo hộp phần tử, cao hơn S1/101 lần lượt 1,95 và 1,61 điểm. Cả hai chênh lệch đều có $p < 0{,}001$. Giai đoạn thưởng tọa độ đạt giá trị cao nhất theo AitW đầy đủ (77,3%), nhưng phân tích ở Mục A.4.2 cho thấy phần lớn chênh lệch của cấu hình này gắn với việc dự đoán đúng loại thao tác, chưa cho thấy mức tăng tương ứng về khả năng xác định phần tử.

Sai số và kết luận theo ba tiêu chí. Bảng 6.7 trình bày khoảng tin cậy theo ba tiêu chí, được tính trên cùng các mẫu bootstrap nên có thể đối chiếu trực tiếp giữa các cột. Hình 6.2 biểu diễn các chênh lệch so với S1/101 cùng khoảng tin cậy, nên có thể thấy ngay phép so nào có khoảng tin cậy nằm hoàn toàn trên 0. Chênh lệch giữa S1/101 và mô hình gốc gần như không thay đổi giữa ba tiêu chí, đều với $p < 0{,}001$, và phương pháp đề xuất cao hơn S1 có ý nghĩa theo cả ba tiêu chí (Mục 6.4). Với các hướng đã thử, kết luận thay đổi tùy tiêu chí. Mô hình mô tả phần tử thấp hơn S1 có ý nghĩa theo

Bảng 6.5: Nhóm độ đo theo vị trí trên 4.463 bước có thao tác chạm, tính lại từ bản ghi từng bước mà không gọi lại mô hình định vị. AitW đầy đủ là biến thể sử dụng cả điều kiện khoảng cách và hộp phần tử của AndroidInTheWild, còn AitW cận trên mở rộng việc xét khung tới mọi phần tử có thể thao tác trên màn hình (Mục 5.12). Hộp phần tử là tiêu chí gốc của AndroidControl. Cột $\pm$14% trục dùng cửa sổ dung sai theo từng trục và có xét loại thao tác. Thao tác là tỉ lệ gọi đúng loại thao tác. Số in đậm là số cao nhất của cột, không tính câu chuẩn. *GRPO-SPICE là thành phần thứ nhất của phương pháp đề xuất. Số in đậm không hàm ý chênh lệch có ý nghĩa thống kê, các phép so có kiểm định nằm ở Bảng 6.7 và 6.8. TAGE là mô-đun hiệu chỉnh câu đặt sau GRPO-SPICE (Mục A.7.2). †Mô hình chọn ứng viên chỉ so sánh trực tiếp được với Base.

Mô hình	Exec.	Hộp phần tử	AitW đầy đủ	$\pm$14% trục	AitW cận trên	Thao tác
Base	47,6	53,6	63,4	55,9	73,4	96,5
S1/101	59,1	65,5	74,4	67,2	81,0	94,4
S1/202	59,6	66,1	75,3	67,9	81,9	94,6
S2	57,2	63,6	73,4	65,7	80,8	94,8
CE2-S2	59,4	66,0	76,1	68,5	83,9	**98,9**
MIN-DESC	60,0	66,5	76,4	68,7	84,4	**98,9**
Giai đoạn ba	60,1	67,0	**77,3**	**69,4**	**85,0**	**98,9**
GRPO-SPICE*	**60,7**	67,0	76,2	68,9	82,9	96,0
Phương pháp đề xuất	**60,7**	**67,1**	76,3	68,9	83,0	96,0
TAGE	60,2	66,4	76,1	68,7	82,7	96,6
Chọn ứng viên†	56,1	62,4	71,2	63,9	77,9	90,9
Câu chuẩn	75,7	83,8	92,1	84,2	96,2	100,0

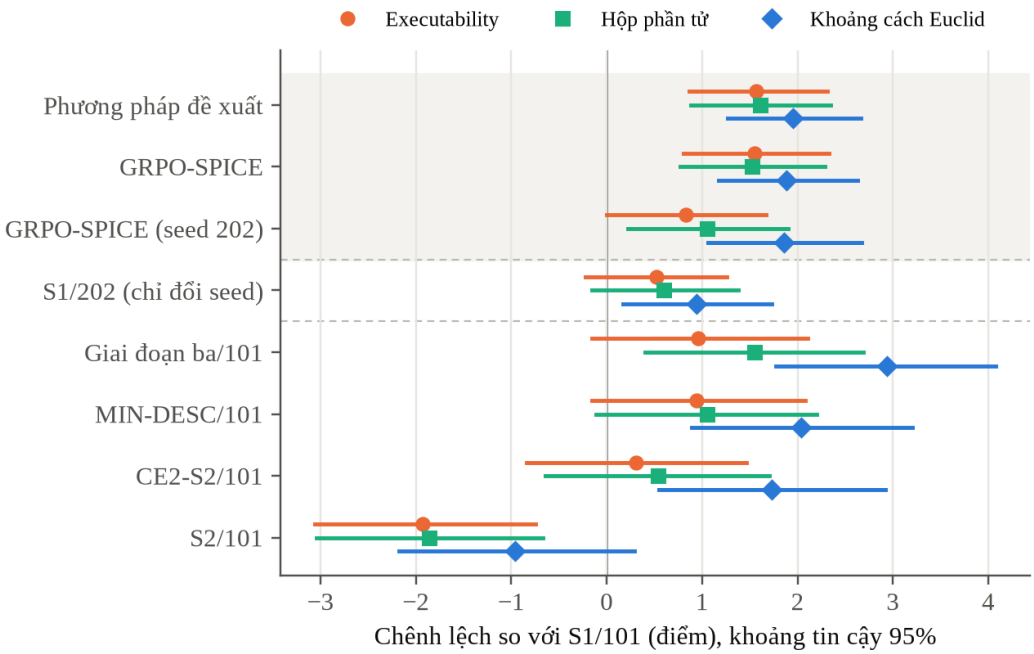
Bảng 6.6: Nhóm độ đo so với câu chuẩn trên 4.463 bước có thao tác chạm. BLEU-4, METEOR 1.5, ROUGE-L, CIDEr-D và SPICE được tính bằng bộ công cụ đánh giá chính thức của COCO Captions sau khi tách từ bằng PTBTokenizer. chrF được tính bằng sacreBLEU. BERTScore là F1 với roberta-large tầng 17, đã hiệu chỉnh theo đường cơ sở. Mỗi bước chỉ có một câu chuẩn. Số in đậm là số cao nhất của cột. Giai đoạn ba học tiếp từ MIN-DESC với phần thưởng đặt trên tọa độ trong dòng mô tả. *GRPO-SPICE là thành phần thứ nhất của phương pháp đề xuất, so sánh chi tiết giữa hai mô hình này nằm ở Bảng 6.4. TAGE chỉ có điểm SPICE. †Mô hình chọn ứng viên chỉ so sánh trực tiếp được với Base.

Mô hình	**BLEU-4**	**METEOR**	**ROUGE-L**	**CIDEr-D**	**SPICE**	**chrF**	**BERTScore**
Base	15,3	24,6	42,3	88,0	18,5	40,2	40,1
7B, chỉ prompting	14,48	21,90	39,79	100,71	18,74	36,22	39,70
S1/101	51,56	36,79	67,35	416,12	44,37	61,26	66,33
S1/202	51,66	37,17	67,71	419,19	44,23	61,92	66,75
Nhánh đối chứng	51,32	36,95	67,36	418,13	44,40	61,52	66,40
GRPO-SPICE, lượt 2	52,94	37,53	68,48	431,22	45,69	62,37	67,12
S2	48,7	35,8	66,0	387,7	41,3	59,9	65,1
CE2-S2	50,1	37,3	68,6	402,2	42,3	61,9	66,8
MIN-DESC	49,9	37,3	68,5	401,0	42,2	61,8	66,7
Giai đoạn ba	49,9	37,3	68,5	402,9	42,5	61,9	66,8
GRPO-SPICE*	52,36	37,92	68,36	430,05	45,79	62,87	67,07
Phương pháp đề xuất	**53,47**	**38,37**	**69,11**	**442,02**	**47,13**	**63,44**	**67,73**
TAGE	-	-	-	-	45,7	-	-
Chọn ứng viên†	46,9	34,2	63,3	370,6	39,3	57,7	62,8
Câu chuẩn	100,0	100,0	100,0	988,7	98,6	100,0	100,0

Bảng 6.7: Khoảng tin cậy 95% của ba số chính trên 4.463 bước (trên) và so sánh ghép cặp (dưới). Khoảng tin cậy được ước lượng bằng 10.000 lần bootstrap theo cách gom cụm ở Mục 5.13, gồm 1.091 cụm. Giá trị p tính bằng kiểm định McNemar. AitW đầy đủ là tiêu chí của AndroidInTheWild, hộp phần tử là tiêu chí của AndroidControl. Giai đoạn ba là giai đoạn thưởng tọa độ (Phụ lục A.4).

Mô hình	**Executability**	**Hộp phần tử**	**AitW đầy đủ**
Base	47,6 [45,9; 49,3]	53,6 [51,9; 55,3]	63,4 [61,8; 65,0]
S1/101	59,1 [57,3; 60,8]	65,5 [63,8; 67,2]	74,4 [72,8; 75,8]
S1/202	59,6 [57,9; 61,3]	66,1 [64,4; 67,7]	75,3 [73,8; 76,7]
MIN-DESC	60,0 [58,3; 61,8]	66,5 [64,9; 68,2]	76,4 [74,9; 77,8]
Giai đoạn ba	60,1 [58,3; 61,8]	67,0 [65,3; 68,7]	77,3 [75,8; 78,8]
GRPO-SPICE	60,7 [58,9; 62,4]	67,0 [65,3; 68,7]	76,3 [74,7; 77,7]
Phương pháp đề xuất	60,7 [58,9; 62,4]	67,1 [65,4; 68,8]	76,3 [74,8; 77,8]
Câu chuẩn	75,7 [74,1; 77,3]	83,8 [82,5; 85,1]	92,1 [91,1; 93,1]

Phép so	**Tiêu chí**	**Δ**	**KTC 95%**	**p**
S1/101 − Base	Executability	+11,52	[+10,02; +13,07]	<0,001
	Hộp phần tử	+11,90	[+10,36; +13,47]	<0,001
	AitW đầy đủ	+10,98	[+9,44; +12,56]	<0,001
Phương pháp đề xuất − S1/101	Executability	+1,57	[+0,86; +2,31]	<0,001
	Hộp phần tử	+1,61	[+0,88; +2,35]	<0,001
	AitW đầy đủ	+1,95	[+1,27; +2,66]	<0,001
S2 − S1/101	Executability	−1,93	[−3,06; −0,75]	<0,001
	Hộp phần tử	−1,86	[−3,04; −0,67]	<0,001
	AitW đầy đủ	−0,96	[−2,18; +0,29]	0,100



Hình 6.2: Chênh lệch so với S1/101 theo ba tiêu chí đánh giá trên 4.463 bước có thao tác chạm. Mỗi điểm là chênh lệch ghép cặp, vạch ngang là khoảng tin cậy 95% bootstrap theo cụm (Mục 5.13). Vùng nền xám gồm phương pháp đề xuất và GRPO-SPICE với hai seed. Hàng S1/202 cho biết mức dao động khi chỉ đổi seed của S1. Các hàng dưới cùng là các hướng đã thử ở Phụ lục A, trong đó giai đoạn ba là MIN-DESC học tiếp với phần thưởng đặt trên tọa độ. Vạch không chứa 0 nghĩa là chênh lệch có ý nghĩa thống kê ở mức 5%. Riêng GRPO-SPICE (seed 202) theo executability có cận dưới đúng bằng 0,00.

executability (Mục A.1.3) nhưng không theo AitW đầy đủ. Theo AitW đầy đủ, phần lớn mức tăng của giai đoạn học theo cặp ưu tiên và giai đoạn thưởng tọa độ so với mô hình mô tả phần tử cũng xuất hiện ở mô hình chỉ học thêm có giám sát với cùng số bước. Giai đoạn thưởng tọa độ cao hơn S1 có ý nghĩa theo hai tiêu chí vị trí, nhưng không theo executability.

> Mức cải thiện theo AitW đầy đủ tập trung ở 256 bước (5,7%) mà S1 dự đoán sai loại thao tác, chẳng hạn sinh câu mô tả thao tác vuốt hoặc cuộn khi bước đúng là chạm. Nhóm này đóng góp +3,11 điểm theo AitW đầy đủ và +1,97 điểm theo executability. Khi so với seed 202, mức đóng góp tương ứng là +3,09 điểm. Ở 4.189 bước mà cả hai mô hình đều dự đoán đúng loại thao tác, tỉ lệ đạt gần như tương đương (79,04% so với 78,92%). AitW đầy đủ cũng không loại những lần chạm rơi vào phần tử sát bên, trong khi executability loại các trường hợp này. Giai đoạn thưởng tọa độ gặp các trường hợp này nhiều hơn, nên trên nhóm bước mà cả hai mô hình đều dự đoán đúng loại thao tác, giai đoạn này thấp hơn S1 0,81 điểm theo executability. Do đó, trong phân rã này, mức cải thiện của hai giai đoạn chủ yếu gắn với việc dự đoán đúng loại thao tác, chưa cho thấy cải thiện tương ứng về khả năng định vị phần tử.

Nhóm độ đo so với câu chuẩn. Bảng 6.6 sử dụng các độ đo được báo cáo trong Widget Captioning [10] và Screen2Words [11], gồm BLEU [20], METEOR [22], ROUGE-L [21], CIDEr [23] và SPICE [24], cùng chrF [25] và BERTScore [26]. BLEU-4 trong bảng này được tính trên toàn tập bằng bộ công cụ COCO Captions, nên khác với BLEU-4 trung bình theo từng câu ở Bảng 6.1. So với S1/101, GRPO-SPICE cao hơn ở cả bảy thước và cả sáu thước có KTC đều loại 0. Lượt GRPO thứ hai cho cùng xu hướng, trong khi nhánh đối chứng nằm gần S1/101 và cả sáu KTC của chênh lệch đều phủ 0. ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu thước có KTC, với toàn bộ khoảng tin cậy nằm trên 0. Qwen2.5-VL-7B dùng prompting thấp hơn rõ rệt so với các nhánh 3B đã tinh chỉnh trên cả bảy thước, cùng chiều với executability. BERTScore sử dụng phiên bản đã co giãn theo mức điểm nền. Câu rỗng được tính 0 điểm và vẫn nằm trong mẫu số, tương tự quy ước của executability.

CIDEr-D vượt quá 100 vì mỗi bước chỉ có một câu chuẩn và trọng số nghịch đảo tần

suất văn bản (IDF) được ước lượng từ chính tập câu chuẩn. Vì vậy, giá trị này chỉ nên được so sánh giữa các hàng trong cùng bảng. Ở các mô hình có kết quả gần nhau, thứ hạng theo nhóm độ đo dựa trên câu chuẩn không hoàn toàn giống với executability, phù hợp với phân tích ở Mục 5.11. Chúng tôi dùng nhóm độ đo này chủ yếu để đối chiếu với các công trình cùng mảng. So sánh giữa các mô hình vẫn dựa trên executability.

6.6 So sánh ghép cặp

Mọi mô hình được đánh giá trên cùng một tập bước, nên các so sánh được thực hiện theo cặp ở mức từng bước bằng kiểm định McNemar (Mục 5.13). Bảng 6.8 tổng hợp các so sánh được sử dụng trong chương.

Bảng 6.8: So sánh ghép cặp executability trên 4.463 bước có thao tác chạm. Δ là điểm của mô hình đứng trước dấu trừ trừ điểm của mô hình đứng sau. b là số bước chỉ mô hình đứng sau đạt, c là số bước chỉ mô hình đứng trước đạt, nên $\Delta = (c - b)/n$. Khoảng tin cậy 95% tính bằng bootstrap theo cụm với 10.000 lần lấy mẫu (Mục 5.13), mọi hàng dùng chung các cụm. Base là mô hình gốc, S1/101 và S1/202 là S1 với seed 101 và 202, CE2-S2 là mô hình chỉ học thêm có giám sát, TAGE là mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ. Câu rỗng được tính là không đạt và vẫn nằm trong mẫu số.

So sánh	Δ	**KTC 95%**	**b**	**c**	**p**
Mốc so sánh (S1 có hai seed)					
S1/101 − Base	+11,52	[+10,02; +13,07]	284	798	<0,001
7B − Base	+3,92	[+2,66; +5,23]	–	–	5×10^{-10}
S1/101 − 7B	+7,60	[+5,95; +9,28]	–	–	$< 10^{-24}$
Câu chuẩn − S1/101	+16,63	[+15,18; +18,09]	102	844	<0,001
Câu chuẩn − Base	+28,14	[+26,46; +29,88]	102	1.358	<0,001
S1/202 − S1/101 (hai seed)	+0,52	[−0,22; +1,26]	132	155	0,194
Phương pháp đề xuất và các so sánh liên quan					
Phương pháp đề xuất − S1/101	+1,57	[+0,86; +2,31]	88	158	<0,001
Phương pháp đề xuất − GRPO-SPICE	+0,02	[−0,21; +0,26]	14	15	1,00
Nhánh đối chứng − S1/101	+0,00	[−0,41; +0,42]	45	45	1,00
GRPO-SPICE − nhánh đối chứng	+1,55	[+0,81; +2,30]	94	163	2×10^{-5}

Bảng 6.8 (tiếp theo)

So sánh	Δ	KTC 95%	b	c	p
GRPO-SPICE − 7B	+9,14	[+7,55; +10,75]	–	–	$< 10^{-24}$
Phương pháp đề xuất − 7B	+9,16	[+7,57; +10,79]	–	–	$< 10^{-24}$
GRPO-SPICE − S1/101	+1,55	[+0,80; +2,33]	90	159	<0,001
GRPO-SPICE − S1/202	+1,03	[+0,25; +1,83]	145	191	0,014
GRPO-SPICE (lượt 2) − S1/101	+0,83	[0,00; +1,67]	129	166	0,036
GRPO-SPICE (lượt 2) − S1/202	+0,31	[−0,53; +1,17]	180	194	0,50
GRPO-SPICE (lượt 2) − lượt 1	−0,72	[−1,27; −0,16]	91	59	0,011
GRPO-SPICE − MIN-DESC	+0,60	[−0,52; +1,73]	304	331	0,30
GRPO-SPICE − giai đoạn ba	+0,58	[−0,50; +1,69]	286	312	0,31
TAGE − GRPO-SPICE	−0,43	[−0,87; +0,02]	67	48	0,093
Hướng đã thử (Phụ lục A)					
S2 − S1/101	−1,93	[−3,06; −0,75]	340	254	<0,001
S2 − S1/202	−2,44	[−3,53; −1,34]	353	244	<0,001
S2 − Base	+9,59	[+8,16; +11,06]	324	752	<0,001
CE2-S2 − S2	+2,24	[+1,36; +3,13]	127	227	<0,001
MIN-DESC − S2	+2,87	[+1,97; +3,75]	130	258	<0,001
MIN-DESC − CE2-S2	+0,63	[+0,16; +1,09]	42	70	0,011
MIN-DESC − S1/101	+0,94	[−0,16; +2,08]	300	342	0,11
CE2-S2 − S1/101	+0,31	[−0,84; +1,46]	312	326	0,61
Chọn ứng viên − Base	+8,54	[+7,00; +10,08]	350	731	<0,001

Với seed 101, tinh chỉnh có giám sát trên tập dữ liệu được xây dựng tự động cải thiện executability thêm 11,5 điểm, tương ứng thu hẹp 41% khoảng cách giữa mô hình gốc và câu chuẩn. Khi loại các bước mà S1 có cùng nội dung từ với câu chuẩn và chỉ xét 3.367 bước còn lại, S1 vẫn cao hơn mô hình gốc 8,4 điểm. Trên nhóm này, mô hình gốc, S1 và câu chuẩn đạt lần lượt 44,7, 53,1 và 75,0, tương ứng S1 thu hẹp 28% khoảng cách giữa hai mốc.

6.7 Biến thiên giữa các lượt huấn luyện

Để mô tả mức biến thiên khi huấn luyện lại, cả mô hình tinh chỉnh có giám sát (S1) và thành phần thứ nhất của phương pháp đề xuất đều được huấn luyện thêm một lượt, chỉ đổi seed và giữ nguyên mọi tham số cấu hình khác (Mục A.1.2). Mục 6.7.2 trình bày lượt thứ hai của thành phần thứ nhất.

6.7.1 Hai lượt huấn luyện S1

Bảng 6.9: Mức khác nhau giữa hai lượt huấn luyện S1 chỉ khác seed, đặt cạnh mức khác nhau giữa S1/101 và mô hình gốc, trên cùng 4.463 bước có thao tác chạm. S1/101 đạt 59,11% và S1/202 đạt 59,62% executability. Cột cuối đếm số bước mà đúng một trong hai mô hình đạt.

Phép so	**Δ executability**	**Số bước cho kết quả khác**
S1/202 − S1/101	+0,52	287 (6,4%)
S1/101 − Base	+11,52	1.082 (24,2%)

Chênh lệch 0,52 điểm giữa hai lượt S1 có khoảng tin cậy 95% chứa 0 (p = 0,194, Bảng 6.8), nên hai lượt được xem là gần nhau về executability. Hai lượt cho kết quả khác nhau ở 6,4% số bước, so với 24,2% giữa S1 và mô hình gốc. Xét độ lớn của điểm, chênh lệch giữa S1 và mô hình gốc lớn gấp 22 lần chênh lệch giữa hai seed, và gấp 3,8 lần nếu xét tỉ lệ bước đổi kết quả.

Phân tích nội dung loại một bước mà cả hai lượt đều trả về câu rỗng, nên còn 4.462 bước. Trong số này, hai lượt tạo cùng một câu ở 2.810 bước và cho cùng kết quả đánh giá ở tất cả các bước đó. Khi tính executability trên toàn bộ 4.463 bước, mức đồng thuận giữa hai lượt là 93,6% (κ = 0,867, hệ số đồng thuận đã điều chỉnh theo mức đồng thuận do ngẫu nhiên). Trên 1.652 bước có câu hướng dẫn khác nhau, mức đồng thuận còn 82,6% (κ = 0,650).

Với seed thứ hai, chênh lệch ở cả sáu cách chia nhóm trong Mục 6.10 vẫn cùng dấu với seed thứ nhất, và độ lệch giữa hai seed không vượt quá 0,9 điểm. Trong 1.091 cụm (Mục 5.13), số cụm mà S1 hơn, bằng và kém mô hình gốc là 395/565/131 ở seed 101 và 406/572/113 ở seed 202.

6.7.2 Hai lượt huấn luyện thành phần thứ nhất

Lượt thứ hai của thành phần thứ nhất dùng seed 202 cho thứ tự câu nhắc và quá trình lấy mẫu, còn điểm xuất phát vẫn là S1/101 và các tham số chính được giữ nguyên (500 bước, tám câu cho mỗi câu nhắc, phần thưởng SPICE). Mô hình sau 500 bước được đánh giá trên tập kiểm tra bằng cùng quy trình với lượt thứ nhất. Bảng 6.10 so sánh hai lượt với hai seed của S1 theo ba tiêu chí.

Bảng 6.10: Hai lượt huấn luyện thành phần thứ nhất so với hai seed của S1 trên 4.463 bước. Phần trên là điểm theo ba tiêu chí, phần dưới là chênh lệch ghép cặp, khoảng tin cậy 95% từ bootstrap theo cách gom cụm ở Mục 5.13. Lượt 1 là mô hình được dùng trong phương pháp đề xuất.

Mô hình	Executability	Hộp phần tử	AitW đầy đủ
S1/101	59,11	65,49	74,37
S1/202	59,62	66,10	75,31
GRPO-SPICE, lượt 1	60,65	67,02	76,25
GRPO-SPICE, lượt 2	59,94	66,55	76,23
Lượt 2 − S1/101	+0,83 [0,00; +1,67]	+1,05 [+0,22; +1,90]	+1,86 [+1,06; +2,67]
Lượt 2 − S1/202	+0,31 [−0,53; +1,17]	+0,45 [−0,44; +1,34]	+0,92 [+0,02; +1,82]
Lượt 2 − lượt 1	−0,72 [−1,27; −0,16]	−0,47 [−1,04; +0,09]	−0,02 [−0,57; +0,54]
Lượt 1 − S1/202	+1,03 [+0,25; +1,83]	+0,92 [+0,11; +1,75]	+0,94 [+0,07; +1,81]

Hai lượt GRPO đều cao hơn S1/101, là điểm xuất phát chung, theo cả ba tiêu chí. Theo executability, mức tăng lần lượt là 1,55 và 0,83 điểm. Hộp phần tử và AitW đầy đủ cũng giữ cùng chiều. Khi đối chiếu với S1/202, các chênh lệch nhỏ hơn. Độ lớn của mức tăng thay đổi giữa các lượt huấn luyện, trong khi hướng cải thiện so với điểm xuất phát vẫn được giữ. ACE được xây dựng trên lượt GRPO thứ nhất, nên kết quả của ACE được đọc qua phép so trực tiếp với lượt này ở Mục 6.4.

6.7.3 Độ ổn định khi thay công cụ đánh giá

Bảng 6.11 đặt các nhánh chính cạnh nhau dưới bốn công cụ đánh giá. UGround và UI-Venus là các bộ trỏ thuộc họ Qwen. Phi-Ground được xây dựng trên Phi-3.5-Vision và theo báo cáo kỹ thuật không dùng AndroidControl để huấn luyện (Mục 5.9). Phi-4

là listener dạng lựa chọn (Mục 5.10). Các công cụ không dùng cùng thang điểm, vì vậy chúng tôi tập trung vào thứ tự giữa các nhánh và chênh lệch ghép cặp thay vì so điểm tuyệt đối giữa các cột.

Bảng 6.11: Kết quả của các nhánh chính trên 4.463 bước có thao tác chạm khi thay công cụ đánh giá. Dấu – cho biết cấu hình chưa có kết quả trên công cụ tương ứng. Phi-4 báo tỉ lệ listener chọn đúng phần tử. Ba cột còn lại báo executability.

Nhánh	UGround	UI-Venus	Phi-Ground	Phi-4
Base	47,59	–	40,80	38,23
S1/101	59,11	54,51	46,96	44,63
S1/202	59,62	55,12	–	45,53
GRPO-SPICE	60,65	56,06	47,75	45,33
ACE	60,68	56,20	47,73	45,33
Câu chuẩn	75,73	–	–	54,94

So với S1/101, GRPO-SPICE cao hơn dưới cả bốn công cụ: +1,55 điểm với UGround, +1,55 với UI-Venus, +0,78 [+0,05; +1,51] với Phi-Ground và +0,69 [+0,02; +1,40] với Phi-4. Khoảng tin cậy của cả bốn chênh lệch đều nằm trên 0. Phi-Ground và Phi-4 đều nằm ngoài họ Qwen. Chiều cải thiện vì thế không chỉ xuất hiện khi dùng công cụ đánh giá cùng họ kiến trúc với mô hình sinh. ACE tiếp tục giữ kết quả gần với GRPO-SPICE dưới mọi công cụ. Các sai khác nhỏ giữa những mô hình đã tinh chỉnh được đọc cùng mức biến thiên giữa các lượt huấn luyện, thay vì dùng để thay đổi kết luận chính.

6.8 Khả năng khái quát và độ ổn định khi thay điều kiện đầu vào

Ba phép kiểm trong mục này mở rộng thiết lập đánh giá theo ba hướng khác nhau: tác vụ mới trong cùng nguồn AndroidControl, miền dữ liệu AitZ và lịch sử do chính mô hình sinh. Mục tiêu là kiểm tra liệu chênh lệch giữa GRPO-SPICE và S1 có được giữ ngoài thiết lập chính hay không.

6.8.1 Đánh giá trên các tác vụ chưa xuất hiện trong huấn luyện S1

Để kiểm tra khả năng khái quát sang tác vụ mới trong cùng nguồn dữ liệu, chúng tôi đánh giá các nhánh chính trên ACU, gồm 1.484 bước có thao tác chạm thuộc các tác vụ không xuất hiện trong tập huấn luyện của S1 (Mục 3.3). Tập này bổ sung cho tập kiểm tra chính và tập trung riêng vào trường hợp mã tác vụ chưa xuất hiện trong huấn luyện S1. Quan hệ của ACU với cách chia chính thức của AndroidControl được trình bày ở Chương 3.

Bảng 6.12: Kết quả trên 1.484 bước có thao tác chạm của ACU. Cột AitW chỉ dùng vế khoảng cách vì ACU không có hộp phần tử vàng để tính tiêu chí hộp phần tử hoặc AitW đầy đủ.

Nhánh	Executability	Vế khoảng cách AitW
Base	49,80	57,95
S1/101	52,16	61,79
GRPO-SPICE, lượt 2	56,20	66,37
GRPO-SPICE	56,74	66,91
ACE	57,01	66,98
Câu chuẩn	71,70	83,29

GRPO-SPICE cao hơn S1/101 4,58 điểm executability, với khoảng tin cậy 95% [+3,17; +6,05] và $p = 2{,}1 \times 10^{-10}$. Lượt GRPO thứ hai cho kết quả cùng chiều, cao hơn S1/101 4,04 điểm [+2,66; +5,48]. ACE đạt 57,01%, là điểm cao nhất trong các nhánh đã tinh chỉnh trên ACU, và cao hơn S1/101 4,85 điểm [+3,43; +6,32]. Theo vế khoảng cách AitW, GRPO-SPICE và ACE cao hơn S1/101 lần lượt 5,12 và 5,19 điểm.

Mức tăng trên ACU lớn hơn mức +1,55 điểm trên tập kiểm tra chính, và được lặp lại ở cả hai lượt GRPO. Khi gộp hai tập thành 5.947 bước có thao tác chạm, GRPO-SPICE cao hơn S1/101 2,30 điểm [+1,62; +2,99], còn ACE cao hơn 2,39 điểm [+1,73; +3,05]. Mức cải thiện của GRPO-SPICE vì thế không chỉ xuất hiện ở tập kiểm tra chính mà còn được giữ trên những tác vụ S1 chưa gặp trong huấn luyện.

MDE của thiết kế trên tập kiểm tra chính là 2,11 điểm executability. Mức +1,55 trên tập kiểm tra chính nhỏ hơn MDE này, còn trên ACU, mức +4,58 có cả cận dưới khoảng tin cậy (+3,17) cao hơn 2,11. Khi gộp 5.947 bước, mức +2,30 cũng vượt MDE.

ACU và tập gộp vì vậy bổ sung bằng chứng về độ lớn cải thiện bên cạnh khoảng tin cậy ghép cặp trên tập kiểm tra chính.

Các thước dựa trên câu chuẩn cho cùng chiều và mức chênh còn lớn hơn tập kiểm tra chính. GRPO-SPICE cao hơn S1/101 ở cả bảy thước, và cả sáu thước có KTC đều nằm trên 0: BLEU-4 +2,32 [+0,74; +3,82], ROUGE-L +2,93 [+1,97; +3,92], CIDEr-D +26,73 [+15,84; +37,96], SPICE +2,51 [+1,18; +3,87], chrF +2,87 [+1,83; +3,94] và BERTScore +1,87 [+1,08; +2,71]. ACE tiếp tục cao hơn GRPO-SPICE ở cả sáu thước có KTC. Trên nhóm tác vụ chưa xuất hiện trong huấn luyện S1, mức tăng xuất hiện đồng thời ở khả năng xác định phần tử và chất lượng câu.

So với tập kiểm tra chính, executability của S1 giảm từ 59,11% xuống 52,16%, trong khi GRPO-SPICE giảm từ 60,65% xuống 56,74%.

6.8.2 Đánh giá chuyển miền trên AitZ

Để kiểm tra khả năng chuyển sang một phân phối khác với AndroidControl, chúng tôi đánh giá các nhánh chính trên 2.736 bước có thao tác chạm của AitZ. Câu hướng dẫn từng bước của AitZ được sinh bằng GPT-4V rồi được người đánh giá đối chiếu với thao tác tham chiếu và sửa các trường hợp chưa phù hợp, nên phân phối câu chuẩn khác với AndroidControl. UGround có dữ liệu AITZ 8K trong tập huấn luyện công bố, vì vậy phép thử này được dùng để kiểm tra chuyển miền của mô hình sinh, không được dùng như một phép kiểm độc lập về dữ liệu của công cụ đánh giá. S1 đạt 37,79% executability so với 34,50% của Base, chênh +3,29 điểm với khoảng tin cậy 95% [+1,51; +5,03]. Mức tăng này xác nhận lợi ích của tinh chỉnh có giám sát vẫn được giữ khi đổi miền dữ liệu.

Trên AitZ, GRPO-SPICE đạt 37,28% executability, tương đương mức 37,79% của S1. Chênh lệch giữa hai nhánh là $-0{,}51$ điểm với khoảng tin cậy $[-1{,}39; +0{,}36]$, còn ACE giữ cùng mức 37,28%. Đặt cạnh kết quả ACU, hai phép kiểm cho hai góc nhìn bổ sung. GRPO-SPICE cải thiện rõ trên tác vụ mới trong cùng nguồn AndroidControl, còn trên AitZ với cách viết câu chuẩn khác, GRPO-SPICE và S1 cho executability tương đương. Sự khác biệt giữa hai tập gợi ý rằng phân phối câu chuẩn dùng trong huấn luyện có ảnh hưởng đến mức lợi ích của phần thưởng SPICE.

Bảng 6.13: Executability trên 2.736 bước có thao tác chạm của AitZ. Câu chuẩn được đưa qua cùng quy trình đánh giá để làm mốc diễn giải.

Nhánh	Executability
Base	34,50
S1/101	37,79
GRPO-SPICE	37,28
GRPO-SPICE, lượt 2	36,62
ACE	37,28
Câu chuẩn	66,26

Ở nhóm thước dựa trên câu chuẩn, GRPO-SPICE có điểm cao hơn S1 ở sáu trong bảy thước. Ba chênh lệch có KTC nằm trên 0 gồm BLEU-4 +0,47 [+0,01; +0,95], SPICE +1,10 [+0,53; +1,66] và chrF +0,62 [+0,22; +1,03]. ROUGE-L, CIDEr-D và BERTScore có KTC phủ 0. Vì vậy, khi chuyển sang AitZ, kết quả chính về executability được xem là tương đương S1, trong khi chất lượng câu theo một số thước vẫn giữ mức nhỉnh hơn.

6.8.3 Khi lịch sử thao tác do mô hình tự sinh

Các thực nghiệm chính dùng câu chuẩn của các bước trước làm lịch sử. Chúng tôi kiểm tra thêm trường hợp mỗi tác vụ được chạy tuần tự và câu do mô hình sinh ở bước trước được đưa trở lại làm lịch sử cho bước sau. Thiết lập này cho phép đánh giá trực tiếp việc kết quả có được giữ khi bỏ giả định lịch sử chuẩn hay không.

Bảng 6.14: Executability trên 4.463 bước có thao tác chạm khi lịch sử của các bước trước được thay bằng câu do chính mô hình sinh. Chênh lệch trong hàng cuối là GRPO-SPICE trừ S1.

Nhánh	Lịch sử chuẩn	Lịch sử tự sinh
S1/101	59,11	54,96
GRPO-SPICE	60,65	56,44
GRPO-SPICE − S1	+1,55 [+0,80; +2,33]	+1,48 [+0,54; +2,43]

Khi dùng lịch sử tự sinh, executability của cả hai nhánh cùng giảm khoảng bốn điểm, nhưng khoảng cách giữa GRPO-SPICE và S1 vẫn được giữ. GRPO-SPICE cao hơn S1 1,48 điểm với khoảng tin cậy 95% [+0,54; +2,43] và $p = 7{,}5 \times 10^{-4}$. Trên toàn bộ 4.463 bước có 811 bước phải dùng câu chuẩn thay cho một bước trước đó vì thiếu ảnh. Do đó, chúng tôi kiểm tra riêng 3.492 bước thuộc các tác vụ có đủ ảnh ở mọi bước. Trên tập con này, mức chênh là 1,66 điểm [+0,60; +2,75]. Trên cả hai mẫu, GRPO-SPICE vẫn cao hơn S1 với khoảng tin cậy nằm trên 0, kể cả khi lịch sử không còn luôn dùng câu chuẩn.

Kết quả theo loại thao tác cũng giữ cùng hướng ở các bước có thao tác chạm. GRPO-SPICE đạt 92,67% so với 89,16% của S1, chênh +3,52 điểm [+2,44; +4,69]. Ở 2.495 bước không chạm, xu hướng ngược lại rõ hơn khi dùng lịch sử tự sinh: S1 đạt 81,32% còn GRPO-SPICE đạt 76,83% về đúng loại thao tác. Chênh lệch GRPO-SPICE − S1 là −4,49 điểm [−6,48; −2,61], so với −1,68 điểm [−2,76; −0,62] khi dùng lịch sử chuẩn. Nếu gộp toàn bộ 6.958 bước, chênh lệch về đúng loại thao tác là +0,65 điểm [−0,35; +1,70]. Vì vậy, lợi thế trên các bước chạm không được suy rộng sang mọi loại thao tác, và xu hướng lệch về thao tác chạm rõ hơn khi lịch sử do chính mô hình sinh.

Với các thước dựa trên câu chuẩn, điểm của GRPO-SPICE cao hơn S1 ở cả bảy thước. Trong sáu thước có KTC, chrF tăng +0,83 [+0,07; +1,58], còn các KTC khác phủ 0. Bằng chứng rõ nhất trong thiết lập lịch sử tự sinh nằm ở executability trên bước chạm và khả năng giữ đúng loại thao tác ở nhóm này, còn các thước chữ giữ xu hướng cùng chiều với chênh lệch nhỏ hơn.

6.9 Phân tích độ vững của kết quả S1

Mức tăng 11,5 điểm giữa S1 và mô hình gốc được kiểm tra thêm dưới bảy cách phân nhóm và cách giải thích khác nhau ở Bảng 6.15. Chênh lệch vẫn giữ khi bỏ điều kiện đúng loại thao tác, chia theo vị trí trong chuỗi, độ phức tạp của màn hình và ứng dụng, thay công cụ đánh giá, hoặc loại nhóm câu có cùng nội dung từ với câu chuẩn. Phân tích cũng xem xét riêng mức độ gần với văn phong của câu chú thích để tách ảnh hưởng của bước tinh chỉnh.

Bảng 6.15: Phân tích các cách giải thích cho chênh lệch giữa S1 và Base, kèm kết quả kiểm tra.

Cách giải thích được kiểm tra	**Kết quả kiểm tra**
Do điều kiện đúng loại thao tác chi phối	khi bỏ điều kiện này và chỉ đánh giá phần định vị, chênh lệch vẫn còn +11,3 điểm (b=272, c=777). Hơn nữa Base gọi đúng loại thao tác nhiều hơn (96,5% so với 94,4%)
Chỉ cải thiện ở một vị trí trong chuỗi	bước mở đầu tác vụ +15,0 (n=593, [+11,0; +19,1]), các bước sau +11,0 ([+9,4; +12,6]). Hai khoảng tin cậy chồng lấp và đều nằm trên 0
Chỉ cải thiện trên màn hình ít phần tử	chia ba theo số phần tử trên màn cho +12,6, +9,5 và +12,4. Các khoảng giao nhau, không tầng nào đảo chiều
Kết quả bị chi phối bởi một số ít ứng dụng	trên 1.091 cụm, S1 cao hơn ở 395, bằng ở 565 và thấp hơn ở 131
Ảnh hưởng của văn phong chú thích	S1 mở đầu bằng động từ chạm ở 91,0% số câu, so với 86,1% của Base và 95,1% của câu chuẩn. Bước tinh chỉnh đồng thời làm cách diễn đạt của S1 gần hơn với văn phong chú thích. Yếu tố này được tính đến khi diễn giải chênh lệch tổng thể
Do công cụ đo phù hợp với văn phong chú thích	khi đánh giá lại bằng UI-Venus-Ground-7B, một công cụ định vị thứ hai, chênh lệch vẫn giữ 94% (Mục 5.9)
Do lặp lại nội dung câu chuẩn	1.095 trong 4.462 câu không rỗng của S1 lặp đúng các từ nội dung của câu chuẩn. Khi chỉ đánh giá 3.367 bước còn lại, S1 vẫn cao hơn +8,4 điểm (b=264, c=547, p<0,001)

Dòng cuối của bảng tách riêng nhóm bước mà S1 lặp lại các từ nội dung của câu chuẩn. Trên nhóm này, chênh lệch giữa S1 và mô hình gốc là 21,1 điểm, lớn hơn chênh lệch trên các bước còn lại. Vì vậy, việc lặp lại nội dung của câu chuẩn có thể góp phần làm tăng chênh lệch tổng thể. Tuy nhiên, S1 vẫn cao hơn 8,4 điểm trên 3.367 bước còn lại, nên thứ tự giữa hai mô hình không phụ thuộc riêng vào nhóm có nội dung giống câu chuẩn.

Điểm executability thay đổi theo độ dài câu: chia đôi câu của S1 ở độ dài trung vị 33 ký tự thì nhóm câu dài đạt 61,9%, nhóm câu ngắn đạt 56,5%. Nếu câu dài thực sự có lợi cho điểm số, xu hướng này còn nghiêng về phía mô hình gốc, vốn có độ dài trung vị khoảng 70 ký tự. Vì vậy, độ dài câu không giải thích được việc S1 đạt điểm cao hơn. Mối liên hệ giữa độ dài và điểm số cũng khác nhau giữa các mô hình (ở mô hình gốc, câu dài lại kém câu ngắn 1,4 điểm), nên cần được phân tích riêng cho từng mô hình.

6.10 Phân bố lỗi của mô hình tinh chỉnh có giám sát

Mục này xem xét các bước mà S1 chưa đạt executability, nhằm xác định những dạng lỗi còn lại sau tinh chỉnh có giám sát.

6.10.1 Kết quả theo mức độ xuất hiện của ứng dụng trong tập huấn luyện

Trong các bước của tập kiểm tra xác định được ứng dụng, 95,6% thuộc về ứng dụng cũng có trong tập huấn luyện (Mục 3.6). Bảng 6.16 so sánh S1 giữa các nhóm ứng dụng đã thấy, chưa thấy và không xác định. So sánh giữa hai nhóm đầu chỉ áp dụng trên phần dữ liệu xác định được ứng dụng.

Ba ước lượng gần như bằng nhau, lần lượt là 59,1%, 59,0% và 59,1%. Nhóm ứng dụng chưa xuất hiện trong huấn luyện chỉ có 78 bước, nên phân tích này được dùng như bằng chứng bổ sung rằng điểm S1 không thay đổi đáng kể giữa các nhóm ứng dụng trong phần dữ liệu xác định được.

Bảng 6.16: Điểm của S1 chia theo việc ứng dụng của bước đã xuất hiện trong tập huấn luyện hay chưa.

Nhóm	S1	n
Ứng dụng đã thấy lúc huấn luyện	59,1%	1.737
Ứng dụng chưa thấy	59,0%	78
Không quy được về ứng dụng	59,1%	2.648

6.10.2 Phân loại lỗi còn lại

Trong 1.825 bước mà S1 không đạt executability, một bước là câu rỗng. Trong 1.824 bước còn lại, 251 bước có loại thao tác bị dự đoán sai. Ở 1.573 bước còn lại, chiếm 86%, loại thao tác đã đúng nhưng quy trình đánh giá vẫn không xác định được phần tử cần chạm từ câu hướng dẫn của S1. Một số câu hướng dẫn gọi sai hoặc mô tả chưa đủ rõ phần tử mục tiêu.

Câu chuẩn	Hướng dẫn của S1
click on the OK option	select minutes 00
Click on the Sort filter	Click on the Air India flight option
Click on the share icon	Open Recorder app

Trong các ví dụ này, lỗi còn lại nằm ở việc gọi tên sai hoặc mô tả chưa đủ rõ phần tử mục tiêu dù loại thao tác đã đúng. Ảnh hưởng của mô hình định vị và tiêu chí đánh giá lên các trường hợp chưa đạt được phân tích riêng ở Mục 6.12.

6.10.3 Khác biệt hành vi giữa mô hình gốc và mô hình đã tinh chỉnh

Ở 798 bước mà S1 đúng còn mô hình gốc sai, hai dạng lỗi nổi bật trong các trường hợp được xem xét là viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại, hoặc mô tả một bước khác với bước cần làm.

	Câu
Câu chuẩn	Click on the profile icon at the top right of the screen
S1	Click on the profile icon at the top right corner of the screen
Base	To set YouTube video downloads over Wi-Fi only, tap on your profile icon at the top right corner of the screen and select “Settings.” Then navigate to the “Downloads” section and choose “Wi-Fi Only.”
Câu chuẩn	Click on Knoxville
S1	Click on Knoxville
Base	Click on the three dots next to Knoxville to access more options and proceed with reading the local news.

Ở dạng thứ nhất, mô hình gốc viết cả một kế hoạch nhiều bước thay vì chỉ bước hiện tại. Ở dạng thứ hai, mô hình gốc mô tả một bước khác với bước cần làm. Câu của mô hình gốc vẫn trôi chảy, đúng khuôn và gọi tên nút cụ thể. Điểm thấp xuất hiện vì nội dung không bám sát bước đang xét chứ không phải do sai định dạng. Trong nhóm S1 đúng còn mô hình gốc sai, các ví dụ trên minh họa khác biệt về khả năng bám sát bước hiện tại giữa hai mô hình.

6.10.4 Đối chiếu với câu chuẩn

Phương pháp đề xuất đạt 60,68% executability, cao nhất trong các nhánh chính và cao hơn S1/101 1,57 điểm. Câu chuẩn đạt 75,7% và được dùng như một mốc tham chiếu thực nghiệm của toàn bộ quy trình đánh giá, thay vì một trần lý thuyết của chất lượng câu hướng dẫn (Mục 6.12). Việc đặt hai mức điểm cạnh nhau giúp xác định phần dư địa còn lại, đồng thời cần lưu ý rằng chính điểm của câu chuẩn cũng chịu ảnh hưởng của mô hình định vị và cách tính điểm.

6.11 Các phương án thiết kế đã khảo sát

Bảng 6.17 tóm tắt các phương án thiết kế đã khảo sát trước khi hình thành phương pháp đề xuất. Thiết kế và kết quả chi tiết được trình bày trong Phụ lục A.

Bảng 6.17: Các phương án thiết kế đã khảo sát. Điểm là executability trên 4.463 bước có thao tác chạm của tập kiểm tra, trừ khi ghi khác.

Hướng	Ý tưởng	Kết quả	Điều rút ra
Mô tả phần tử (S2), Mục A.1.3	viết một dòng mô tả phần tử cần chạm trước câu hướng dẫn	57,2%, thấp hơn S1/101 1,93 điểm	câu đầu ra đạt kết quả cao hơn ở nhóm mô tả đúng phần tử và giảm mạnh ở nhóm mô tả sai
Học theo cặp ưu tiên (MIN-DESC), Mục A.2.2	học theo cặp ưu tiên trên các đầu ra chỉ khác ở dòng mô tả	60,0%, trong đó 78% mức tăng so với S2 cũng có ở mô hình chỉ học thêm có giám sát	phần lớn cải thiện xuất hiện ở cấu hình chỉ học thêm
Chọn ứng viên, Mục A.3.2	chọn phần tử cần chạm trong danh sách được xây dựng sẵn	56,1%, chỉ có thể so sánh trực tiếp với mô hình gốc	khi đưa ra lựa chọn, độ chính xác cao, nhưng tần suất từ chối chọn lớn
Giai đoạn thưởng tọa độ, Mục A.4.2	học tăng cường với phần thưởng dựa trên độ chính xác của tọa độ trong dòng mô tả	60,1% (77,3% theo AitW đầy đủ)	độ chính xác tọa độ tăng, còn câu đầu ra thay đổi ít
Đưa thêm thông tin vị trí, Mục A.6	bổ sung thông tin vị trí cho mô hình sinh câu (bốn cách)	dừng ở tập kiểm định nội bộ	thông tin này chưa được phản ánh rõ trong đầu ra của mô hình sinh câu
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE), Mục A.7.2	viết lại câu hướng dẫn ban đầu sau khi xem ảnh phóng to quanh phần tử	60,2%, gần với câu hướng dẫn ban đầu	chất lượng câu hiệu chỉnh phụ thuộc mạnh vào việc vùng ảnh cục bộ có chứa đúng phần tử mục tiêu hay không

Các phương án dựa trên biểu diễn trung gian, như dòng mô tả phần tử hoặc tọa độ, tạo thay đổi rõ hơn ở biểu diễn trung gian so với câu hướng dẫn cuối (Mục A.5). Việc đưa thêm thông tin vị trí trực tiếp vào mô hình sinh cũng chỉ tạo thay đổi nhỏ ở đầu ra trong các cấu hình đã thử. Các quan sát này dẫn đến lựa chọn tối ưu trực tiếp câu hướng dẫn trong phương pháp cuối cùng, còn câu ví dụ chỉ được sử dụng khi thỏa ràng buộc nhất quán về loại thao tác.

6.12 Phân tích điểm của câu chuẩn trong quy trình đánh giá

Câu chuẩn đạt 75,7% executability trên 4.463 bước có thao tác chạm. Ở 1.083 bước chưa đạt, 64,8% có điểm do mô hình định vị trả về nằm ngoài vùng dung sai. Sai số trung vị của nhóm này là 26,2% bề ngang màn hình, so với 0,4% ở các bước đạt. Trong 381 bước còn lại, điểm đã nằm trong vùng dung sai nhưng không thỏa tiêu chí ô Voronoi. Ở 208 bước trong nhóm này, điểm dự đoán vẫn nằm trong hộp nhỏ nhất chứa điểm chạm, cho thấy sự khác nhau giữa cách xác định phần tử bằng hộp bao và bằng các tâm cạnh tranh. Điểm 75,7% vì vậy được sử dụng như một mốc thực nghiệm của toàn bộ quy trình đánh giá, thay vì một giới hạn của chất lượng câu hướng dẫn.

Chúng tôi kiểm tra thêm cách executability phản ứng với thông tin vị trí trong câu (Mục 5.5). Câu nêu tên một vùng trên màn đạt 89,5% khi vùng đó đúng, 3,3% khi vùng đó sai và 54,8% khi không nêu vùng nào. Executability tăng khi thông tin vị trí phù hợp với phần tử cần thao tác và giảm mạnh khi thông tin đó sai. S1 sử dụng từ chỉ vị trí trong 26,8% số câu, gần với 26,4% của câu chuẩn, và chỉ để lại chuỗi tọa độ trong 3 trên 6.958 câu. Hai mẫu câu phổ biến nhất của S1 chiếm 10,4% số bước, so với 6,5% ở câu chuẩn.

Chương 7

Kết luận

7.1 Đóng góp chính

Chúng tôi nghiên cứu bài toán sinh hướng dẫn cho giao diện di động từ ảnh màn hình, mục tiêu của người dùng và lịch sử thao tác, trong đó đầu ra là một câu hướng dẫn ngắn cho bước kế tiếp. Công trình tập trung vào ba đóng góp chính gồm (i) một phương pháp sinh gồm hai thành phần nối tiếp, (ii) độ đo khả năng thực hiện theo hướng dẫn (executability), dùng để đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác và đúng loại thao tác, và (iii) các phân tích thực nghiệm trên nhiều phương án thiết kế, qua đó làm rõ những yếu tố ảnh hưởng đến chất lượng câu đầu ra.

Về phương pháp đề xuất

Phương pháp đề xuất (Mục 4.4) tối ưu trực tiếp câu đầu ra và gồm hai thành phần. Thành phần thứ nhất học tiếp mô hình tinh chỉnh có giám sát bằng GRPO với phần thưởng SPICE để sinh câu hướng dẫn ban đầu. Thành phần thứ hai, ACE, chỉ hiệu chỉnh câu hướng dẫn ban đầu bằng câu ví dụ truy hồi khi đầu ra thỏa ràng buộc sao chép và nhất quán loại thao tác. Mô hình định vị dùng để đánh giá không tham gia vào phần thưởng hoặc điều kiện lựa chọn của phương pháp.

Trên 4.463 bước có thao tác chạm của tập kiểm tra chính, GRPO-SPICE đạt 60,65% executability, cao hơn S1/101 1,55 điểm [+0,80; +2,33] và cao hơn S1/202 1,03 điểm [+0,25; +1,83]. Chiều cải thiện được giữ theo executability, tiêu chí hộp phần tử, tiêu chí hộp phần tử kết hợp cửa sổ 14% và AitW đầy đủ. GRPO-SPICE cũng cao hơn S1/101 ở cả bảy thước dựa trên câu chuẩn, trong đó cả sáu thước có KTC đều

có khoảng tăng nằm trên 0. Lượt GRPO thứ hai đạt 59,94% executability và tiếp tục cao hơn S1/101 0,83 điểm. Nhánh đối chứng chạy cùng 500 bước GRPO với điểm SPICE được ghép ngẫu nhiên giữa các mẫu đạt 59,11% executability, bằng S1/101, và cả sáu KTC của nhóm thước chữ đều phủ 0. GRPO-SPICE cao hơn nhánh này 1,55 điểm executability [+0,81; +2,30] và cao hơn ở cả sáu thước chữ có KTC. Với cùng số bước huấn luyện, mức tăng chỉ xuất hiện khi tín hiệu SPICE giữ đúng quan hệ với mẫu.

Trên các tác vụ mới trong AndroidControl, mức cải thiện còn rõ hơn. Với 1.484 bước thuộc các tác vụ không xuất hiện trong tập huấn luyện S1, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05], còn lượt GRPO thứ hai cao hơn 4,04 điểm [+2,66; +5,48]. Cả sáu thước chữ có KTC cũng tăng với khoảng tin cậy nằm trên 0. Khi gộp ACU với tập kiểm tra chính thành 5.947 bước, GRPO-SPICE cao hơn S1 2,30 điểm executability [+1,62; +2,99]. Khi thay lịch sử chuẩn bằng câu do chính mô hình sinh ở các bước trước, GRPO-SPICE vẫn cao hơn S1 1,48 điểm [+0,54; +2,43]. Hướng tăng vì vậy được giữ trên tác vụ mới trong cùng nguồn AndroidControl và khi lịch sử do chính mô hình sinh.

ACE đạt 60,68% executability, giữ mức của GRPO-SPICE và đồng thời nâng cả bảy thước dựa trên câu chuẩn. Với sáu thước có KTC, toàn bộ khoảng tăng đều nằm trên 0, gồm BLEU-4 +1,11, ROUGE-L +0,74, CIDEr-D +11,97, SPICE +1,33, chrF +0,58 và BERTScore +0,66. Trên AitZ, bước tinh chỉnh có giám sát vẫn cao hơn Base 3,29 điểm executability [+1,51; +5,03]. GRPO-SPICE và S1 tương đương về executability với chênh lệch $-0{,}51$ điểm [$-1{,}39$; +0,36], trong khi GRPO-SPICE có điểm cao hơn S1 ở sáu trong bảy thước chữ, với BLEU-4, SPICE và chrF có KTC nằm trên 0. Mức tăng executability của GRPO-SPICE thể hiện rõ trên AndroidControl và các tác vụ mới trong cùng nguồn dữ liệu. Khi đổi miền sang AitZ, lợi ích bổ sung của SPICE chưa xuất hiện rõ ở executability nhưng một số thước chất lượng câu vẫn giữ mức tăng.

Về độ đo

Khi đầu ra là một câu hướng dẫn thay vì một tọa độ, một câu chuẩn duy nhất khó có thể bao quát hết các cách diễn đạt hợp lệ. Executability tiếp cận vấn đề này bằng cách

đưa câu hướng dẫn do mô hình tạo ra vào một mô hình định vị tách biệt với mô hình sinh, rồi kiểm tra xem câu có dẫn tới đúng phần tử cần thao tác và đúng loại thao tác hay không. Đóng góp của phần đo lường không chỉ nằm ở định nghĩa điểm số, mà còn ở việc xây dựng tiêu chí xác định dự đoán đúng và đánh giá độ tin cậy của cách đo qua nhiều kiểm tra bổ sung (Chương 5).

Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101: +1,55 điểm với UGround, +1,55 với UI-Venus, +0,78 [+0,05; +1,51] với Phi-Ground và +0,69 [+0,02; +1,40] với listener Phi-4. Cả bốn KTC đều nằm trên 0. Phi-Ground được xây dựng trên Phi-3.5-Vision, thuộc họ kiến trúc khác Qwen và theo báo cáo kỹ thuật không dùng AndroidControl để huấn luyện. Phi-4 là listener dạng lựa chọn. Thứ tự Base < S1/101 < GRPO-SPICE vì vậy không phụ thuộc vào một kiến trúc đánh giá duy nhất.

Kết quả nền tảng về dữ liệu và mô hình tinh chỉnh có giám sát

Tập giám sát gồm 64.567 bước được xây dựng hoàn toàn tự động, không yêu cầu gán nhãn thủ công bổ sung và không sử dụng nhãn do một mô hình ngôn ngữ khác sinh ra trong quá trình huấn luyện. Các bước kiểm tra chất lượng dữ liệu gồm đánh giá quá trình hợp nhất hai nguồn và mô tả mức lặp lại của cách diễn đạt giữa tập huấn luyện với tập kiểm tra (Chương 3).

Trên 4.463 bước có thao tác chạm của tập kiểm tra, S1/101 đạt 59,11% executability, cao hơn Base 11,52 điểm. Qwen2.5-VL-7B dùng prompting đạt 51,51%, nên mô hình 3B sau SFT cao hơn 7,60 điểm và sau GRPO-SPICE cao hơn 9,14 điểm. Trong thiết lập của đề tài, việc tinh chỉnh trên dữ liệu phù hợp với bài toán đem lại mức tăng lớn hơn rõ rệt so với chỉ tăng mô hình nền từ 3B lên 7B.

Về phân tích các hướng đã thử

Đóng góp thứ ba là phân tích ở mức từng bước đối với các phương án thiết kế đã khảo sát trước phương pháp đề xuất. Mục 6.11 tóm tắt kết quả, còn Phụ lục A trình bày thiết kế và số liệu chi tiết. Với biểu diễn mô tả phần tử, chất lượng câu hướng dẫn phụ thuộc mạnh vào việc biểu diễn trung gian có xác định đúng phần tử hay không. Nhóm bước mà biểu diễn này xác định sai chỉ chiếm 29,9% số bước được phân tích nhưng

đóng góp khoảng 91% khoảng cách giữa mô hình và câu chuẩn. Trong các giai đoạn học tiếp, mức cải thiện ở biểu diễn trung gian tạo tác động nhỏ hơn lên executability. Đây là một trong những căn cứ để phương pháp cuối cùng chuyển sang tối ưu trực tiếp câu hướng dẫn.

Với phương án chọn ứng viên, executability đạt 71,4% khi danh sách có ứng viên đúng và mô hình đưa ra lựa chọn. Phần giảm điểm chủ yếu xuất hiện ở những bước mô hình không đưa ra lựa chọn dù danh sách đã có ứng viên phù hợp. Điều này tách quyết định có đưa ra lựa chọn khỏi bài toán xếp hạng ứng viên.

7.2 Hạn chế

Các kết quả được diễn giải trong phạm vi của công cụ đánh giá, thiết lập mô hình và bộ dữ liệu đã sử dụng. Những điểm cần lưu ý khi mở rộng kết luận được tóm tắt dưới đây. Các phân tích kỹ thuật chi tiết nằm ở Chương 5, Chương 6 và Phụ lục A.

7.2.1 Phạm vi của công cụ đo

Executability là một độ đo tự động, dùng mô hình định vị để kiểm tra liệu câu hướng dẫn có dẫn tới đúng phần tử và đúng loại thao tác hay không. Khi thay công cụ đánh giá, GRPO-SPICE vẫn cao hơn S1/101 dưới cả UGround, UI-Venus, Phi-Ground và Phi-4 (Mục 6.7.3). Hai công cụ ngoài họ Qwen cho mức chênh nhỏ hơn UGround và UI-Venus, nhưng khoảng tin cậy của chênh lệch vẫn nằm trên 0. Các phép kiểm chéo này được dùng để xác nhận chiều của kết quả chính, còn executability với UGround là thiết lập đánh giá chính. Đánh giá trực tiếp với người dùng trên quy mô lớn hơn là một hướng bổ sung để tiếp tục đối chiếu executability với khả năng làm theo hướng dẫn trong thực tế.

7.2.2 Phạm vi của kết quả về mô hình

S1 và GRPO-SPICE đều được lặp lại qua hai lượt huấn luyện để quan sát mức biến thiên của kết quả. Trên tập kiểm tra chính, hai lượt GRPO-SPICE cùng cao hơn

S1/101, với mức tăng 1,55 và 0,83 điểm executability. Trên ACU, hai lượt tiếp tục cùng chiều với mức tăng 4,58 và 4,04 điểm. Kết luận chính vì vậy được hỗ trợ bởi hai lượt huấn luyện và một phép kiểm riêng trên nhóm tác vụ mới. Thiết kế ban đầu đặt mức chênh lệch tối thiểu có thể phát hiện là 2,11 điểm. Mức +1,55 trên tập kiểm tra chính nhỏ hơn ngưỡng thiết kế này nhưng khoảng tin cậy ghép cặp vẫn nằm trên 0. Trên ACU, mức +4,58 vượt ngưỡng, và khi gộp hai tập thành 5.947 bước, mức +2,30 cũng vượt ngưỡng. ACE được xây dựng trên lượt GRPO thứ nhất, đạt 60,68% executability và tăng cả bảy thước dựa trên câu chuẩn. Các nhánh ablation còn lại phục vụ so sánh thiết kế và lựa chọn thành phần của phương pháp.

7.2.3 Phạm vi dữ liệu và thực nghiệm

Thực nghiệm chính được thực hiện trên AndroidControl với giao diện tiếng Anh và mô hình nền Qwen2.5-VL-3B. Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability [+3,17; +6,05] ở các tác vụ không xuất hiện trong tập huấn luyện S1. Trên AitZ, lợi ích của bước tinh chỉnh có giám sát vẫn được giữ khi chuyển miền, còn GRPO-SPICE và S1 tương đương về executability. Các kết luận chính về executability tập trung vào bước có thao tác chạm. Ở toàn bộ nhóm bước không chạm với lịch sử chuẩn, tỉ lệ gọi đúng loại thao tác giảm từ 85,97% ở S1 xuống 84,29% ở GRPO-SPICE. Khi dùng lịch sử tự sinh, chênh lệch trên 2.495 bước không chạm là $-4{,}49$ điểm $[-6{,}48; -2{,}61]$. Đây là phạm vi cần tiếp tục cải thiện khi mở rộng phương pháp sang các loại thao tác khác. Việc mở rộng sang nhiều miền giao diện hơn, chuỗi tương tác dài hơn và giao diện tiếng Việt cũng là các hướng tiếp theo để kiểm tra phạm vi áp dụng của phương pháp.

7.3 Tính sẵn có của dữ liệu và mã nguồn

Mã nguồn và các tệp kết quả thô dùng trong quá trình thực nghiệm được lưu kèm theo đề tài để người đọc có thể đối chiếu các bảng và phân tích đã trình bày. Dữ liệu nguồn là AndroidControl [1], giấy phép Apache 2.0, lấy qua hai bản phân phối công khai trên Hugging Face đã nêu ở Bảng 3.1. Ảnh màn hình không được phân phối lại.

Mã nguồn bao gồm quy trình xây dựng dữ liệu, cấu hình huấn luyện, chương trình sinh câu và mã đánh giá. Kết quả được lưu ở mức từng bước, gồm câu hướng dẫn do mô hình tạo ra, điểm đánh giá, tọa độ do mô hình định vị trả về, tọa độ tham chiếu và các thành phần của executability. Nhờ đó, các bảng và phân tích theo nhóm có thể được đối chiếu trực tiếp với kết quả ở mức từng bước mà không cần gọi lại mô hình định vị.

7.4 Hướng phát triển

Các kết quả thực nghiệm gợi ra bốn hướng phát triển tiếp theo.

- **Mở rộng đánh giá qua nhiều lượt huấn luyện.** Hai lượt GRPO hiện cùng giữ hướng cải thiện trên tập kiểm tra chính và ACU. Việc lặp thêm các lượt trong cùng thiết lập sẽ giúp ước lượng chính xác hơn mức biến thiên của độ lớn cải thiện.
- **Kết hợp chặt hơn giữa nhận diện phần tử, lựa chọn phần tử và sinh câu.** Trong các thí nghiệm ở Phụ lục A, việc bổ sung thông tin vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo thay đổi nhỏ ở câu đầu ra. Với phương án chọn ứng viên, quyết định có đưa ra lựa chọn hay không ảnh hưởng đáng kể đến kết quả. Một hướng tiếp theo là học chung biểu diễn phần tử với câu hướng dẫn, hoặc tách rõ bước xác định có ứng viên phù hợp khỏi bước xếp hạng và sinh câu.
- **Đối chiếu executability với đánh giá của người dùng.** Một tập câu được nhiều người đánh giá độc lập có thể được sử dụng để xem executability phản ánh đến đâu khả năng người dùng xác định đúng phần tử và thao tác cần thực hiện. Đồng thời, cần mở rộng các biến thể diễn đạt để đánh giá độ ổn định của độ đo trong nhiều cách mô tả cùng một phần tử.
- **Mở rộng phạm vi thực nghiệm.** Trên ACU, GRPO-SPICE cao hơn S1 4,58 điểm executability trên tác vụ mới trong AndroidControl, còn AitZ cung cấp thêm phép kiểm khi đổi miền dữ liệu. Các thí nghiệm tiếp theo có thể mở rộng sang nhiều bộ dữ liệu có câu hướng dẫn do người viết, chuỗi nhiều màn hình, các loại thao tác ngoài thao tác chạm và giao diện tiếng Việt.

Chương 8

Các công trình nghiên cứu

Một phần nội dung của đề tài đã được phát triển thành hai bài báo, mỗi bài tập trung vào một hướng đóng góp khác nhau của luận văn.

> Lê Đoàn Phương Uyên, TS. Nguyễn Hồng Bửu Long. "Sinh hướng dẫn sử dụng phần mềm từ ảnh chụp màn hình và mục tiêu người dùng: xây dựng nhãn quy chiếu tự động khi phần tử giao diện không có tên để gọi."

Bài viết bằng tiếng Việt, nộp ngày 30 tháng 8 năm 2026 và đã được chấp nhận tại Hội thảo Quốc gia lần thứ tư về Ngôn ngữ học Tính toán (VCL 2026). Đóng góp chính của bài là nhãn quy chiếu và quy trình xây dựng dữ liệu ở Chương 3. Bài báo đặt bài toán trong hướng nghiên cứu về sinh biểu thức quy chiếu, tức sinh mô tả đủ để người tiếp nhận xác định đúng một đối tượng, rồi áp dụng vào miền giao diện. Trong dữ liệu khảo sát, 22,0% phần tử cần chạm không có tên hiển thị phù hợp và 7,6% có cùng tên với một phần tử khác trên cùng màn hình.

> Lê Đoàn Phương Uyên. "GUIStep: A Compact Vision-Language Model for GUI Step Instruction Generation".

Bài viết bằng tiếng Anh, nộp ngày 21 tháng 9 năm 2026 và đã được chấp nhận trình bày tại phiên oral của SOICT 2026 (Paper ID 5590), đồng thời được chấp nhận xuất bản trong kỷ yếu Springer CCIS. Bài báo tập trung vào sinh câu hướng dẫn cho từng bước thao tác trên giao diện và trình bày GUIStep, một mô hình thị giác–ngôn ngữ gọn nhẹ được xây dựng từ Qwen2.5-VL-3B-Instruct. Dữ liệu huấn luyện gồm 64.567 bước của AndroidControl. Bài khảo sát ba cấu hình gồm tinh chỉnh trực tiếp trên câu

hướng dẫn, bổ sung một khai báo có cấu trúc về phần tử đích trước câu hướng dẫn, và tinh chỉnh tiếp bằng các cặp ưu tiên thay đổi phần tử trong phần khai báo. Trong thiết lập đánh giá được sử dụng ở bài SOICT, trên 4.463 bước có thao tác chạm, cấu hình tốt nhất đạt 66,5% so với 53,6% của mô hình nền chưa tinh chỉnh. Kết quả 66,5% và 53,6% được báo cáo theo phiên bản phương pháp và thiết lập đánh giá của bài SOICT. So với bài SOICT, luận văn mở rộng phần thực nghiệm và phát triển phương pháp cuối cùng được trình bày ở Chương 4 đến Chương 6. Phân tích thành phần cho thấy tinh chỉnh có giám sát trên câu hướng dẫn tạo ra phần lớn mức cải thiện, còn các cấu hình có biểu diễn trung gian được dùng để khảo sát thêm vai trò của thông tin phần tử và học theo cặp ưu tiên.

Hai công trình tương ứng với hai hướng nghiên cứu của luận văn: bài VCL tập trung vào xây dựng nhãn quy chiếu và dữ liệu, còn bài SOICT tập trung vào sinh hướng dẫn theo bước và đánh giá khả năng câu hướng dẫn giúp xác định đúng phần tử cần thao tác.

Tài liệu tham khảo

[1] W. Li, W. Bishop, A. Li, C. Rawles, F. Campbell-Ajala, D. Tyamagundlu, O. Riva, "On the effects of data scale on UI control agents," in *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2024.

[2] C. Rawles, A. Li, D. Rodriguez, O. Riva, T. P. Lillicrap, "AndroidInTheWild: A large-scale dataset for Android device control," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[3] K. Cheng, Q. Sun, Y. Chu, F. Xu, Y. Li, J. Zhang, Z. Wu, "SeeClick: Harnessing GUI grounding for advanced visual GUI agents," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024.

[4] Z. Wu, Z. Wu, F. Xu, Y. Wang, Q. Sun, C. Jia, K. Cheng, Z. Ding, L. Chen, P. P. Liang, Y. Qiao, "OS-ATLAS: Foundation action model for generalist GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[5] B. Gou, R. Wang, B. Zheng, Y. Xie, C. Chang, Y. Shu, H. Sun, Y. Su, "Navigating the digital world as humans do: Universal visual grounding for GUI agents," in *Proc. International Conference on Learning Representations (ICLR)*, 2025 (Oral).

[6] Z. Gu *et al.*, "UI-Venus technical report: Building high-performance UI agents with RFT," arXiv:2508.10833, 2025 (bản tiền ấn phẩm).

[7] M. Zhang *et al.*, "Phi-Ground Tech Report: Advancing Perception in GUI Grounding," arXiv:2507.23779, 2025 (bản tiền ấn phẩm).

[8] Y. Xu, Z. Wang, J. Wang, D. Lu, T. Xie, A. Saha, D. Sahoo, T. Yu, C. Xiong, "Aguvis: Unified pure vision agents for autonomous GUI interaction," in *Proc. International Conference on Machine Learning (ICML)*, 2025.

[9] X. Deng, Y. Gu, B. Zheng, S. Chen, S. Stevens, B. Wang, H. Sun, Y. Su, "Mind2Web: Towards a generalist agent for the web," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] Y. Li, G. Li, L. He, J. Zheng, H. Li, Z. Guan, "Widget captioning: Generating natural language description for mobile user interface elements," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020.

[11] B. Wang, G. Li, X. Zhou, Z. Chen, T. Grossman, Y. Li, "Screen2Words: Automatic mobile UI summarization with multimodal learning," in *Proc. ACM Symposium on User Interface Software and Technology (UIST)*, 2021.

[12] J. Mao, J. Huang, A. Toshev, O. Camburu, A. Yuille, K. Murphy, "Generation and comprehension of unambiguous object descriptions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[13] R. Luo, G. Shakhnarovich, "Comprehension-guided referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[14] L. Yu, H. Tan, M. Bansal, T. L. Berg, "A joint speaker-listener-reinforcer model for referring expressions," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.

[15] S. Petryk, D. Chan, A. Kachinthaya, H. Zou, J. Canny, J. Gonzalez, T. Darrell, "ALOHa: A new measure for hallucination in captioning models," in *Proc. NAACL-HLT, Short Papers*, 2024.

[16] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," in *Findings of the Association for Computational Linguistics: ACL*, pp. 2318–2335, 2024.

[17] A. B. Sai, T. Dixit, D. Y. Sheth, S. Mohan, M. M. Khapra, "Perturbation CheckLists for evaluating NLG evaluation metrics," in *Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2021.

[18] S. Jandial, Y. Li, J. Wagle, K. Koishida, "Do GUI grounders truly understand UI elements?," in *Findings of the Association for Computational Linguistics: EACL*, 2026.

[19] K. Fang, J. Zhang, S.-T. Ni, P. Hui, Y. Wang, "GuideMe: A VLM-based system assisting independent smartphone learning for older adults," in *Proc. ACM Conference on Human Factors in Computing Systems (CHI)*, 2026.

[20] K. Papineni, S. Roukos, T. Ward, W.-J. Zhu, “BLEU: A method for automatic evaluation of machine translation,” in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL)*, 2002.

[21] C.-Y. Lin, “ROUGE: A package for automatic evaluation of summaries,” in *Proc. Workshop on Text Summarization Branches Out, ACL*, 2004.

[22] M. Denkowski, A. Lavie, “Meteor Universal: Language specific translation evaluation for any target language,” in *Proc. Ninth Workshop on Statistical Machine Translation (WMT)*, pp. 376–380, 2014.

[23] R. Vedantam, C. L. Zitnick, D. Parikh, “CIDEr: Consensus-based image description evaluation,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4566–4575, 2015.

[24] P. Anderson, B. Fernando, M. Johnson, S. Gould, “SPICE: Semantic propositional image caption evaluation,” in *Proc. European Conference on Computer Vision (ECCV)*, pp. 382–398, 2016.

[25] M. Popović, “chrF: Character n-gram F-score for automatic MT evaluation,” in *Proc. Tenth Workshop on Statistical Machine Translation (WMT)*, pp. 392–395, 2015.

[26] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi, “BERTScore: Evaluating text generation with BERT,” in *Proc. International Conference on Learning Representations (ICLR)*, 2020.

[27] A. C. Cameron, J. B. Gelbach, D. L. Miller, “Bootstrap-based improvements for inference with clustered errors,” *Review of Economics and Statistics*, vol. 90, no. 3, pp. 414–427, 2008.

[28] L. Kish, *Survey Sampling*. New York, NY, USA: Wiley, 1965.

[29] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, “LoRA: Low-rank adaptation of large language models,” in *Proc. International Conference on Learning Representations (ICLR)*, 2022.

[30] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, “QLoRA: Efficient finetuning of quantized LLMs,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[31] Y. Zheng, R. Zhang, J. Zhang, Y. Ye, Z. Luo, "LlamaFactory: Unified efficient fine-tuning of 100+ language models," in *Proc. ACL, System Demonstrations*, 2024.

[32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[33] J. Qi, M. Ding, W. Wang, Y. Bai, Q. Lv, W. Hong, B. Xu, L. Hou, J. Li, Y. Dong, J. Tang, "CogCoM: A visual language model with chain-of-manipulations reasoning," in *Proc. International Conference on Learning Representations (ICLR)*, 2025.

[34] S. Bai *et al.*, "Qwen2.5-VL technical report," arXiv:2502.13923, 2025 (bản thảo tiền ấn phẩm).

[35] K. Chen, Z. Zhang, W. Zeng, R. Zhang, F. Zhu, R. Zhao, "Shikra: Unleashing multimodal LLM's referential dialogue magic," arXiv:2306.15195, 2023 (bản thảo tiền ấn phẩm).

[36] Q. Wu, X. Yang, Y. Zhou, C. Fang, B. Song, X. Sun, R. Ji, "Grounded chain-of-thought for multimodal large language models," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 33577–33587, 2026.

[37] M. Zhao, P. Anderson, V. Jain, S. Wang, A. Ku, J. Baldridge, E. Ie, "On the evaluation of vision-and-language navigation instructions," in *Proc. Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, pp. 1302–1316, 2021.

[38] P. Rajpurkar, R. Jia, P. Liang, "Know what you don't know: Unanswerable questions for SQuAD," in *Proc. Annual Meeting of the Association for Computational Linguistics (ACL), Short Papers*, pp. 784–789, 2018.

[39] A. K. Menon, S. Jayasumana, A. S. Rawat, H. Jain, A. Veit, S. Kumar, "Long-tail learning via logit adjustment," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[40] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, P. Liang, "Lost in the middle: How language models use long contexts," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 157–173, 2024.

[41] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu, D. Guo, "DeepSeekMath: Pushing the limits of mathematical reasoning in open language models," bản tiền ấn phẩm arXiv:2402.03300, 2024.

[42] A. Abouelenin *et al.*, "Phi-4-Mini technical report: Compact yet powerful multimodal language models via mixture-of-LoRAs," bản tiền ấn phẩm arXiv:2503.01743, 2025.

[43] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, J. Gao, "Set-of-Mark prompting unleashes extraordinary visual grounding in GPT-4V," bản tiền ấn phẩm arXiv:2310.11441, 2023.

[44] S. J. Rennie, E. Marcheret, Y. Mroueh, J. Ross, V. Goel, "Self-critical sequence training for image captioning," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017.

[45] R. Ramos, B. Martins, D. Elliott, Y. Kementchedjhieva, "SmallCap: Lightweight image captioning prompted with retrieval augmentation," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2023.

[46] S. Liu, Z. Zhu, N. Ye, S. Guadarrama, K. Murphy, "Improved image captioning via policy gradient optimization of SPIDEr," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 873–881.

Phụ lục A

Các phương án thiết kế đã khảo sát

Phụ lục này trình bày, theo thứ tự thực hiện, các hướng đã thử trước khi chọn phương pháp đề xuất, với phần tóm tắt ở Mục 6.11. Trong các bảng, S1 là mô hình tinh chỉnh có giám sát và được dùng làm mốc so sánh. S2 là mô hình mô tả phần tử. CE2-S2 là mô hình học thêm có giám sát. MIN-DESC (MIN) là mô hình sau giai đoạn học theo cặp ưu tiên. Base là mô hình gốc. Câu chuẩn là câu hướng dẫn do người chú thích viết cho bước tương ứng.

A.1 Sinh mô tả phần tử trước câu hướng dẫn

A.1.1 Thiết kế

Phương án đầu tiên yêu cầu mô hình sinh mô tả phần tử cần chạm trước khi sinh câu hướng dẫn. Mô hình huấn luyện theo thiết kế này được gọi là mô hình mô tả phần tử. Một số công trình trước cho thấy hiệu quả của bước trung gian phụ thuộc đáng kể vào dạng biểu diễn và cách đưa biểu diễn đó vào quá trình huấn luyện (Bảng A.1).

Hai cấu hình của Shikra [35] dùng cùng mô hình và bài kiểm tra nhưng cho kết quả trái chiều khi thay đổi dạng biểu diễn trung gian: văn xuôi làm giảm kết quả, trong khi biểu diễn có tọa độ làm tăng kết quả. GCoT [36] cũng cho thấy lợi ích xuất hiện khi bước định vị được đưa vào quy trình huấn luyện thay vì chỉ bổ sung ở prompt. Tác dụng của bước trung gian vì thế phụ thuộc vào cách biểu diễn và cách đưa thông tin

Bảng A.1: Ảnh hưởng của bước trung gian trong các công trình trước. Mỗi dòng so cấu hình có bước trung gian với cấu hình không có, theo thước đo và bộ dữ liệu của chính công trình đó. Chênh lệch dương nghĩa là bước trung gian giúp tăng kết quả.

Công trình	Phép so	Chênh lệch
Aguvis [8]	giữ bước suy luận trung gian so với bỏ đi, tác vụ mức thấp của AndroidControl	+11,4
Shikra (văn xuôi) [35]	bước trung gian viết bằng văn tự do	−7,4
Shikra (có tọa độ) [35]	cùng mô hình, bước trung gian có tọa độ	+5,9
GCoT [36]	huấn luyện sinh định vị trước (LLaVA-7B / 13B)	+4,5 / +5,8
CogCoM [33]	thêm 70K mẫu chuỗi thao tác trung gian vào dữ liệu huấn luyện (đọc chữ trong ảnh / hai bài kiểm tra khác)	+6,6 / +0,2 / +0,9

đó vào mô hình. Từ các quan sát này, chúng tôi kiểm tra có kiểm soát một biểu diễn tập trung vào phần tử mục tiêu trong bài toán của đề tài.

Chuỗi đích của phương án gồm hai phần như minh họa dưới đây.

dòng mô tả phần tử	`<desc>` vai trò | tên | `<point>`x, y`</point>` | dấu hiệu phân biệt `</desc>`
phần câu	câu hướng dẫn

A.1.1.1 Xây dựng nhãn mô tả phần tử

Dòng mô tả được tạo tự động từ tọa độ chạm, cây trợ năng và OCR. Chương trình chọn hộp trợ năng nhỏ nhất chứa điểm chạm, lấy vai trò từ cây trợ năng và lấy tên từ cây hoặc OCR sau khi qua các bộ lọc. Tọa độ được chuẩn hóa về thang [0, 1000], còn trường cuối chứa một dấu hiệu phân biệt được sinh theo cách định sẵn. Bảng A.2 tóm tắt bốn trường của nhãn.

Làm sạch tên và dấu hiệu phân biệt. Bộ lọc nhãn trợ năng loại 14,7% nhãn tại các phần tử cần chạm, gồm định danh lấy từ mã nguồn, chuỗi số dài, hậu tố dành cho trình đọc màn hình và các chuỗi chỉ báo phần tử không có nhãn như `No label`

Bảng A.2: Bốn trường của dòng mô tả phần tử và vai trò của từng trường.

Trường	Ví dụ	Vai trò
Vai trò	`tappable text`	phân biệt nút, ô nhập và mục danh sách
Tên	`Search here`	biểu diễn chữ hoặc nhãn của phần tử, lấy từ OCR hoặc cây trợ năng
Tọa độ	`<point> 440,91 </point>`	lấy từ điểm chạm tham chiếu và chuẩn hóa về lưới [0, 1000]
Dấu hiệu phân biệt	`just above the text "Coffee"`	bổ sung quan hệ với phần tử lân cận khi chỉ tên hoặc vai trò chưa đủ phân biệt

`specified`. Tên OCR chỉ được lấy khi hộp phần tử chiếm dưới 25% diện tích màn hình. Trong 25 trường hợp hộp chiếm gần hết màn hình được kiểm tra thủ công, không trường hợp nào khớp với câu chuẩn. Khi tạo dấu hiệu phân biệt, quy trình ưu tiên kết hợp một chuỗi OCR gần phần tử với thông tin vị trí tương đối. Trên mẫu thử, 75,9% dấu hiệu được tạo ra đủ để phân biệt phần tử cần chạm với các phần tử tương tự. 24,1% còn lại không đạt tiêu chí này.

Chất lượng nhãn ở quy mô đầy đủ. Trong 41.191 bước chạm của tập huấn luyện, quy trình xây dựng được 41.099 nhãn mô tả. 92 bước còn lại gồm 50 bước có điểm chạm không nằm trong hộp trợ năng nào và 42 bước không có cây trợ năng. Bảng A.3 so sánh 41.099 nhãn này với mẫu thử gồm 1.074 nhãn. Với ba chỉ số có số liệu đối chiếu ở cả hai cột, chênh lệch không vượt quá 1,4 điểm phần trăm.

Trong 32.061 tên lấy được, 8.581 tên đến từ cây trợ năng và 23.480 tên đến từ OCR. Các thống kê này chỉ mô tả nguồn tên của nhãn phụ trợ. Cây trợ năng không được đưa vào đầu vào của quy trình suy luận cuối cùng ở Chương 4.

A.1.1.2 Lý do thiết kế và cách đánh giá

Khi đánh giá, dòng mô tả bị cắt bỏ và mô hình định vị chỉ nhận câu hướng dẫn, nên mọi thay đổi về điểm số phải xuất phát từ thay đổi trong câu hướng dẫn. Thiết kế dựa trên ba căn cứ. Thứ nhất, một vấn đề quan trọng của bài toán là hướng dẫn có thể chưa

Bảng A.3: Chất lượng 41.099 nhãn mô tả ở quy mô đầy đủ so với mẫu thử gồm 1.074 nhãn.

Chỉ số	Quy mô đầy đủ	Mẫu thử
Tên rõ ràng	73,6%	73,8%
Chỉ có ký hiệu, không có chữ	4,4%	-
Không có tên	22,0%	23,4%
Vai trò rõ ràng	75,8%	-
Trùng tên trên cùng màn	7,6%	7,0%
Có phần tử cùng vai trò để so	91,6%	-

cung cấp đủ thông tin để phân biệt phần tử mục tiêu với các phần tử tương tự trên màn hình. Vì vậy, dòng mô tả bổ sung một trường ghi dấu hiệu phân biệt. Thứ hai, hai cấu hình Shikra trong Bảng A.1 cho kết quả âm khi bước trung gian là văn xuôi và dương khi bước trung gian có tọa độ, nên dòng mô tả gồm bốn ô cố định và bắt buộc có tọa độ. Thứ ba, tọa độ chạm của người thật đã có sẵn trong dữ liệu, nên có thể sử dụng trực tiếp mà không cần gán nhãn bổ sung.

Thiết kế ban đầu còn dự kiến một mục thứ hai, tức phạt mô hình khi xác suất của dòng mô tả xác định đúng phần tử không vượt xác suất của dòng mô tả trỏ sang phần tử lân cận ít nhất một khoảng lề, là phần mà Widget Captioning [10] chưa xử lý. Chuỗi thí nghiệm được dừng sau khi đánh giá mục thứ nhất, nên phần này không được triển khai (Mục A.1.3).

A.1.2 Các cấu hình của thiết kế so sánh ban đầu

Thiết kế so sánh ban đầu gồm bảy cấu hình, dùng chung dữ liệu, mô hình gốc, siêu tham số và tập kiểm tra (Bảng A.4).

Cách dựng các biến thể dữ liệu. Ba cấu hình có dòng mô tả dùng cùng đầu vào và cùng câu hướng dẫn. S2 dùng dòng mô tả thật. S2r thay dòng này bằng một dòng lấy từ màn hình khác có độ dài token gần tương đương và thay tọa độ bằng giá trị ngẫu nhiên. S2-nopoint giữ vai trò, tên và dấu hiệu phân biệt nhưng bỏ trường tọa độ. Khi thiết kế yêu cầu so sánh trực tiếp, phần câu hướng dẫn được giữ hoàn toàn giống nhau giữa các biến thể. Ở các bước không chạm, không có dòng mô tả và chuỗi đích của

Bảng A.4: Các cấu hình của thiết kế so sánh ban đầu. Ba cấu hình cuối không cần huấn luyện.

Cấu hình	**Chuỗi phải sinh ra hoặc cách chạy**	**Vai trò**
Tinh chỉnh có giám sát (S1)	chỉ câu hướng dẫn (2 seed)	mốc so sánh
Mô tả phần tử (S2)	dòng mô tả thật + câu (seed 101)	phép so sánh chính của thiết kế ban đầu, kiểm tác dụng của việc mô tả phần tử trước
Mô tả giả (S2r)	dòng mô tả giả có độ dài token gần tương đương + câu	loại trừ khả năng điểm tăng chỉ do chuỗi phải sinh ra dài thêm
Mô tả không có tọa độ (S2-nopoint)	dòng mô tả bỏ tọa độ + câu	tách phần đóng góp của tọa độ
Danh sách phần tử lúc chạy (B-infer)	trọng số S1, danh sách phần tử đưa vào đầu vào lúc chạy	so huấn luyện với việc chỉ cung cấp thông tin lúc chạy
Mô hình gốc (Base)	mô hình gốc, không tinh chỉnh	đo phần cải thiện do bản thân việc tinh chỉnh
Câu chuẩn	câu chuẩn được đưa trực tiếp vào quy trình đánh giá	mốc tham chiếu của độ đo

các cấu hình được giữ giống nhau. Nhóm này chiếm 36,2% tập huấn luyện. Trạng thái cuối của các cấu hình không được tiếp tục huấn luyện được ghi ở Bảng A.18.

Thiết kế ban đầu dự kiến dùng $\Delta = S2 - S1$, tính từ trung bình hai seed của mỗi mô hình. Hai lượt huấn luyện S1 chỉ khác nhau ở seed, nên chênh lệch giữa chúng cho biết mức dao động khi chỉ huấn luyện lại mà không có can thiệp. Tuy nhiên, bốn cấu hình không được chạy, gồm seed 202 của S2, cấu hình mô tả giả, cấu hình mô tả không có tọa độ và cấu hình chỉ đưa danh sách phần tử vào lúc chạy (lý do ở Bảng A.18). Vì S2 chỉ có seed 101, đại lượng theo thiết kế ban đầu không được ước lượng. Các kết quả sau chỉ báo cáo những phép so sánh có dữ liệu tương ứng.

A.1.3 Kết quả

S2/101 đạt 57,2% executability, cao hơn mô hình gốc 9,59 điểm nhưng thấp hơn S1/101 và S1/202 lần lượt 1,93 và 2,44 điểm (Bảng 6.8). Khoảng tin cậy của cả hai chênh lệch so với S1 đều nằm dưới 0, và đánh giá bằng mô hình định vị thứ hai giữ cùng thứ tự (Mục 5.9). Ở Mục A.1.3.2, kết quả thay đổi mạnh tùy việc biểu diễn trung gian có xác định đúng phần tử hay không.

Ba cách giải thích thay thế đã được kiểm tra và không cách nào giải thích được chênh lệch. Ba cách đó là độ dài câu, nhóm ứng dụng, và tên ghi trong dòng mô tả bị sai do lỗi nhận dạng chữ.

A.1.3.1 Chia nhóm theo việc có sinh dòng mô tả hay không

Bảng A.5: Điểm chia theo việc mô hình mô tả phần tử (S2) có sinh dòng mô tả hay không.

Nhóm	n	S1	S2	Δ
Có sinh dòng mô tả	4.138	62,2	60,8	−1,38 [−2,54; −0,19]
Không sinh dòng mô tả	325	19,7	10,8	−8,92 [−12,57; −5,25]

Theo Bảng A.5, nhóm 325 bước mà mô hình mô tả phần tử bỏ qua dòng mô tả chỉ gồm 7,3% số bước nhưng chiếm 34% toàn bộ chênh lệch. Câu chuẩn vẫn đạt 68,3% trên nhóm này, trong khi mô hình phần lớn đoán sai loại thao tác. Tỉ lệ gọi đúng loại

thao tác lần lượt là 83,4% ở mô hình gốc, 55,1% ở S1 và 38,8% ở S2. Xu hướng lệch loại thao tác đã xuất hiện từ S1 và rõ hơn ở S2. Một giả thuyết là mô hình học tương quan tắt từ dữ liệu vì tập huấn luyện chỉ gắn dòng mô tả cho bước chạm, từ đó có thể hình thành lối tắt "đã viết dòng mô tả thì là chạm". Cấu hình mô tả không có tọa độ không được tiếp tục, nên giả thuyết này không được dùng như một kết luận nhân quả. Nhóm cũng được định nghĩa bằng hành vi của chính S2, vì vậy điểm thấp của S2 một phần gắn với cách chia nhóm. Trên cùng nhóm, S1 cũng chỉ đạt 19,7%.

A.1.3.2 Ảnh hưởng hai chiều của dòng mô tả

Bảng A.6: Điểm theo trạng thái dòng mô tả do mô hình mô tả phần tử (S2) tự sinh, trên 3.473 bước có tên phần tử để đối chiếu. Vì vậy nhóm không sinh dòng mô tả chỉ có 228 bước, ít hơn 325 bước khi tính trên toàn bộ 4.463 bước. Cột Câu chuẩn là điểm của câu chuẩn trên chính nhóm đó.

Tên	Tọa độ	n	Base	S1	S2	Câu chuẩn
đúng	đạt	1.871	69,0	81,4	87,1	86,6
đúng	không đạt	184	23,4	25,5	26,1	31,0
sai	đạt	452	41,4	56,4	57,5	72,8
sai	không đạt	738	24,4	30,8	5,6	66,3
không sinh dòng mô tả	-	228	25,9	20,6	9,6	70,6

Bảng A.6 chia các bước được đánh giá theo việc dòng mô tả do chính mô hình mô tả phần tử sinh ra có đúng tên và tọa độ hay không. Khi đúng cả hai, mô hình đạt 87,1%, hơn mô hình tinh chỉnh có giám sát 5,7 điểm và vượt cả câu chuẩn trên nhóm đó. Khi sai cả hai, mô hình chỉ còn 5,6%, thấp hơn cả mốc tham chiếu dưới dùng câu chung chung không nói phần tử nào (12,0%, Mục 5.5), trong khi câu chuẩn vẫn đạt 66,3% trên 738 bước ấy. Ở nhóm này mô hình đã chọn một phần tử sai rồi viết câu khẳng định về phần tử đó, còn mô hình tinh chỉnh có giám sát viết câu chung chung nên vẫn có khả năng đạt tiêu chí. Khi dòng mô tả xác định đúng phần tử, S2 đạt 87,1%, cao hơn S1 5,7 điểm trên nhóm tương ứng. Khi biểu diễn trung gian sai, chất lượng câu giảm mạnh. Sự khác biệt giữa hai nhóm là căn cứ để xây dựng giai đoạn học theo cặp ưu tiên ở Mục A.2.1.

A.2 Học theo cặp ưu tiên trên dòng mô tả

A.2.1 Thiết kế

Ở Mục A.1.3.2, chất lượng dòng mô tả thay đổi cùng kết quả của câu hướng dẫn. Vì học có giám sát chỉ tối ưu xác suất của chuỗi đích, giai đoạn tiếp theo bổ sung mục tiêu ưu tiên trên các cặp đầu ra gần nhau. Giai đoạn này, gọi tắt là học theo cặp ưu tiên và ký hiệu MIN-DESC trong bảng, học tiếp 800 bước từ trọng số của mô hình mô tả phần tử.

vế được chọn	`<desc>`mô tả trỏ đúng phần tử`</desc>` + `\n` + câu
vế bị loại	`<desc>`mô tả trỏ sai phần tử`</desc>` + `\n` + đúng câu đó

Hai vế dùng cùng câu hướng dẫn và chỉ khác dòng mô tả. Cách dựng này tập trung tín hiệu ưu tiên vào phần mô tả phần tử, nhưng trong mô hình tự hồi quy, xác suất của phần câu phía sau vẫn được điều kiện hóa bởi tiền tố khác nhau nên ảnh hưởng của câu hậu tố không triệt tiêu hoàn toàn. Hàm mục tiêu thuộc họ tối ưu theo ưu tiên dạng tỉ số odds (ORPO), không cần mô hình tham chiếu đóng băng.

A.2.1.1 Xây dựng tập cặp ưu tiên

Tập huấn luyện của giai đoạn này gồm 22.854 cặp. Ở vế được chọn, dòng mô tả trỏ tới phần tử cần chạm. Ở vế bị loại, dòng mô tả trỏ tới một phần tử có thật trên cùng màn hình, cùng vai trò, cách phần tử mục tiêu từ 80 đến 350 điểm ảnh và khác ở cả tên lẫn tọa độ. Sau khi xây dựng, các cặp được kiểm tra để phần câu hướng dẫn của hai vế hoàn toàn giống nhau và dòng mô tả ở vế bị loại không trỏ vào phần tử cần chạm.

Tập cặp chỉ chứa bước chạm. Ở 17,4% số cặp, chuỗi `(no name)` chỉ xuất hiện ở một trong hai vế, nên mô hình có thể sử dụng dấu hiệu này bên cạnh nội dung màn hình để phân biệt hai vế. Đặc điểm này được phát hiện sau khi lượt huấn luyện hoàn tất, nên Mục A.2.2 giữ nguyên dữ liệu đã dùng và diễn giải nhánh này như một phân tích cơ chế. Phép so với CE2-S2 ở Mục A.2.2.2 được dùng để tách thêm đóng góp của mục tiêu ưu tiên khỏi ảnh hưởng của việc tiếp tục huấn luyện.

A.2.1.2 Tách ảnh hưởng của mục tiêu ưu tiên

Để tách phần của mục tiêu ưu tiên khỏi phần của việc học thêm, mô hình học thêm có giám sát (CE2-S2) học có giám sát thuần trên vế được chọn của các cặp ấy, cùng điểm xuất phát và số bước. Đại lượng chính là hiệu ghép cặp $\Delta_{\text{thành phần}}$ = MIN-DESC − CE2-S2, tính trên cùng các bước của tập kiểm tra (Mục 4.8).

A.2.2 Kết quả

A.2.2.1 Độ chính xác của dòng mô tả

Bảng A.7 đối chiếu trực tiếp dòng mô tả do mô hình tự sinh với nhãn chuẩn của tập kiểm tra, không cần gọi mô hình định vị.

Bảng A.7: Độ chính xác của dòng mô tả trên 3.473 bước có tên đúng để đối chiếu, chỉ tính các bước có mặt trong kết quả của cả ba mô hình.

Mô hình	Sinh dòng mô tả	Tên đúng	Tọa độ đúng	Cả hai đúng
Mô tả phần tử (S2)	93,4%	59,2%	66,9%	53,9%
Học thêm có giám sát (CE2-S2)	99,6%	66,2%	71,2%	59,8%
Học theo cặp ưu tiên (MIN-DESC)	99,6%	67,0%	71,8%	60,6%

Học theo cặp ưu tiên đưa tỉ lệ đúng cả tên lẫn tọa độ lên 60,6%, cao nhất trong ba cấu hình ở Bảng A.7. So với S2, mức tăng là 6,77 điểm. Cấu hình chỉ học thêm có giám sát đạt 59,8%, tương ứng tăng 5,93 điểm. Phần chênh riêng giữa MIN-DESC và CE2-S2 là 0,84 điểm, tức mục tiêu ưu tiên tạo thêm một mức tăng trên nền hiệu quả của việc học tiếp.

A.2.2.2 Executability và đại lượng chính

MIN-DESC đạt 60,0% executability, cao hơn cấu hình chỉ học thêm có giám sát 0,63 điểm với KTC 95% [+0,16; +1,09] và p = 0,011. Mục tiêu ưu tiên vì vậy tạo một mức tăng riêng trong phép so trực tiếp này. So với S2, MIN-DESC tăng 2,87 điểm, trong

đó 2,24 điểm cũng xuất hiện ở CE2-S2. Phần lớn mức tăng tổng thể so với S2 đến từ việc tiếp tục huấn luyện, còn mục tiêu ưu tiên đóng góp thêm 0,63 điểm so với cấu hình học thêm có giám sát. So với S1/101, MIN-DESC cao hơn 0,94 điểm với KTC chứa 0.

A.2.2.3 Biến thể lấy về bị loại theo chính sách

Ngoài nguồn cặp được xây dựng theo cách cố định (cửa sổ 80–350 điểm ảnh quanh phần tử mục tiêu), chúng tôi thử thêm biến thể on-policy, trong đó vế bị loại lấy từ chính phần tử mô hình dự đoán sai. Trên 14.000 màn huấn luyện chỉ thu được 459 cặp hợp lệ (3,3%). Mô hình thường gọi đúng phần tử bằng tên khác hoặc xác định một vùng cách xa phần tử mục tiêu, còn lỗi nhầm giữa hai nút lân cận xuất hiện ít hơn giả định ban đầu. Với mục tiêu tạo đủ cặp lân cận để huấn luyện, nguồn cặp cố định phù hợp hơn trong thiết lập hiện tại.

A.2.3 Phân tích cơ chế mô tả phần tử

Cách chia nhóm dựa trên hành vi của chính mô hình đang được đánh giá. Hai nhóm khác nhau nhiều về độ khó, nên chỉ phép so sánh ghép cặp bên trong một nhóm là hợp lệ. Bảng A.8 chia 3.473 bước có tên đúng để đối chiếu theo việc dòng mô tả của MIN-DESC trỏ đúng phần tử (tên khớp và tọa độ nằm trong dung sai 14%) hay trỏ sai.

Bảng A.8: Điểm của mô hình sau giai đoạn học theo cặp ưu tiên (MIN-DESC) và mô hình tinh chỉnh có giám sát (S1) trên 3.473 bước có tên đúng để đối chiếu, chia theo việc dòng mô tả của MIN-DESC trỏ đúng hay trỏ sai phần tử. Dòng mô tả được xem là trỏ đúng khi tên trong đó trùng hoặc chứa tên của phần tử mục tiêu (hay ngược lại) và tọa độ lệch không quá 14% theo mỗi chiều. Cột Câu chuẩn là điểm của câu chuẩn trên chính nhóm đó.

Nhóm	n	MIN-DESC	S1	Δ ghép cặp	Câu chuẩn
Trỏ đúng phần tử	2.106 (60,6%)	87,1	78,3	+8,83	86,3
Trỏ sai phần tử	1.367 (39,4%)	21,8	32,9	−11,12	61,4

Khi dòng mô tả xác định đúng phần tử, MIN-DESC đạt 87,1%, cao hơn S1 8,83

điểm và vượt cả điểm của câu chuẩn trên chính nhóm đó. Khi dòng mô tả xác định sai, MIN-DESC thấp hơn S1 11,12 điểm. Chênh lệch giữa hai nhóm gắn chặt lợi ích của nhánh này với độ chính xác của biểu diễn trung gian. Trên toàn bộ tập, MIN-DESC cao hơn S1/101 0,94 điểm với KTC chứa 0 (Mục A.2.2).

Ngưỡng tối đa lý thuyết khi bù được phần thiệt ở các bước mô tả sai. Giả sử ở mỗi bước mà dòng mô tả xác định sai, MIN-DESC cho đúng kết quả của mô hình tinh chỉnh có giám sát. Khi đó điểm trên 3.473 bước có tên đúng để đối chiếu sẽ là 65,8% thay vì 61,4% thực đo, tức cao hơn mô hình tinh chỉnh có giám sát 5,4 điểm. Mức này không đạt được ở khâu suy luận bằng một cách chọn câu ở từng bước, tức quyết định lấy câu của MIN-DESC hay câu của mô hình tinh chỉnh có giám sát. Một cách chọn hoàn hảo, biết trước dòng mô tả xác định đúng hay sai, cho 63,5% trên toàn bộ 4.463 bước, nhưng bảy cách chọn thực tế đã thử chỉ cho 60,0 đến 60,3%, không khác biệt rõ so với mức 60,0% của MIN-DESC. Các phép chọn câu thực tế chưa đạt mức của cách chọn biết trước, nên nếu tiếp tục hướng này, can thiệp phù hợp hơn nằm ở khâu huấn luyện thay vì hậu xử lý.

Bảng A.9: Phân rã toàn bộ 4.463 bước theo trạng thái dòng mô tả của MIN-DESC (cột MIN). Tên đúng và tọa độ đúng được xét theo cùng định nghĩa với Bảng A.8. Cột cuối là phần dư địa tới mức câu chuẩn mà mỗi nhóm đóng góp, tính bằng điểm trên toàn bộ các bước được đánh giá.

Nhóm	n	%	MIN	S1	Câu chuẩn	Dư địa
tên đúng, tọa độ đúng	2.106	47,2	87,1	78,3	86,3	−0,40
tên đúng, tọa độ sai	220	4,9	26,4	27,7	32,3	+0,29
tên sai, tọa độ đúng	387	8,7	55,0	50,9	72,4	+1,50
không sinh dòng mô tả	15	0,3	0,0	0,0	60,0	+0,20
tên sai, tọa độ sai	745	16,7	3,6	25,8	64,4	+10,15
không có tên để đối chiếu	990	22,2	55,3	54,4	73,0	+3,94
Tổng	**4.463**	**100,0**	**60,0**	**59,1**	**75,7**	**+15,7**

Nhóm đúng cả tên lẫn tọa độ chiếm 47,2% số bước và MIN-DESC đạt 87,1%, cao hơn mức 86,3% của câu chuẩn trên chính nhóm này. Phần lớn khoảng cách còn lại tập trung ở nhóm sai cả tên lẫn tọa độ: nhóm này đóng góp 10,15 trong tổng 16,08 điểm khoảng cách dương, tương ứng khoảng 63%. Nếu tiếp tục phát triển nhánh biểu diễn

trung gian, cải thiện độ chính xác của biểu diễn phần tử là hướng tác động trực tiếp nhất vào phần dư địa này.

A.3 Chọn phần tử trong danh sách ứng viên

A.3.1 Thiết kế

Ở Mục A.2.3, phần lớn dư địa còn lại của MIN-DESC tập trung ở những bước mà dòng mô tả sai cả tên lẫn tọa độ. Vì vậy, thay vì để mô hình tự viết dòng mô tả, phương án chuyển sang cho mô hình chọn phần tử trong danh sách lấy từ chính màn hình. Mô hình huấn luyện theo cách này được gọi là mô hình chọn ứng viên. Căn cứ là ba con số đo được trước khi huấn luyện. Nếu lấy toàn bộ bước chạm của tập kiểm tra làm mẫu số, 99,7% bước có tên mục tiêu lấy được từ OCR hoặc cây trợ năng và 80,2% bước có một ứng viên vừa khớp tên vừa nằm trong dung sai. Tỉ lệ tương ứng của dòng mô tả tự sinh là 59,9%. Ngoài ra, ở 67,7% số bước mà MIN-DESC gọi sai tên, tên đúng đã nằm sẵn trong 24 dòng OCR của prompt nhưng không kèm vị trí.

Cách làm. Prompt thay 24 dòng OCR bằng một danh sách phần tử có tên và vị trí. Chuỗi đích mở đầu bằng một thẻ chọn, là bản chép nguyên văn một dòng trong danh sách hoặc thẻ `none`, rồi mới tới câu. Thẻ này được cắt bỏ trước khi đánh giá. Danh sách phần tử có cấu trúc đã được sử dụng trong các công trình trước (Chương 1). Trong phương án này, thành phần được khảo sát là cơ chế chọn tường minh, tức mô hình ghi rõ ứng viên được chọn ngay trong chuỗi đích.

A.3.1.1 Xây dựng danh sách ứng viên và chuỗi đích

Mỗi màn hình được chuyển thành danh sách tối đa 40 ứng viên, mỗi ứng viên gồm tên phần tử và tọa độ trên lưới [0, 1000]. Danh sách dùng cùng cách đặt tên với nhãn mô tả phần tử ở Mục A.1.1.1 và được sắp theo thứ tự đọc tự nhiên trên màn hình.

Tên trong nhãn mô tả của một bước được xem là tên mục tiêu của bước đó. Một ứng viên được xem là đúng khi có cùng tên mục tiêu và cách điểm chạm không quá 140 đơn vị lưới trên mỗi trục, tương đương 14% kích thước tương ứng của màn hình.

Nếu có nhiều ứng viên thỏa điều kiện, ứng viên gần điểm chạm nhất được chọn. Trên tập kiểm tra, trong số các bước có tên mục tiêu, 96,7% có tên đó xuất hiện trong danh sách. Trong chính nhóm bước có tên mục tiêu, 91,2% có ít nhất một ứng viên vừa trùng tên vừa nằm trong dung sai vị trí. Trên mẫu 300 bước có ứng viên đúng, vị trí của ứng viên đúng sau khi chuẩn hóa về [0,1] có giá trị trung bình 0,481 và ứng viên đúng đứng đầu danh sách ở 5,0% số mẫu. Vì vậy, vị trí trong danh sách không tạo thành một dấu hiệu thứ tự hiển nhiên của đáp án. Mẫu dài nhất vẫn dưới giới hạn ngữ cảnh 3.072 token nên không mẫu nào bị cắt vì danh sách ứng viên.

Từ cùng một prompt, hai cấu hình dữ liệu được dựng với chuỗi đích khác nhau. Cấu hình chọn ứng viên sinh thêm thẻ lựa chọn phần tử trước câu hướng dẫn. Cấu hình chỉ sinh câu hướng dẫn vẫn nhận cùng danh sách ứng viên ở đầu vào nhưng chuỗi đích chỉ gồm câu hướng dẫn.

Mô hình chọn ứng viên	`<sel>`tên `<point>`x, y`</point></sel>` + `\n` + câu hoặc `<sel>none</sel>` + `\n` + câu
Chỉ sinh câu hướng dẫn	câu

Nội dung thẻ chọn là phần sao chép nguyên văn thông tin của ứng viên đúng từ danh sách. Thẻ `none` được dùng cho bước không chạm, bước chạm không có tên mục tiêu hoặc bước chạm có tên nhưng danh sách không chứa ứng viên khớp. Câu hướng dẫn ở cả hai cấu hình là câu chuẩn nguyên bản. Prompt và ảnh cũng được giữ giống nhau. Do mọi bước không chạm đều sử dụng thẻ `none`, 54,78% toàn bộ mẫu huấn luyện mang nhãn này. Nếu chỉ xét 41.191 bước chạm, tỉ lệ là 29,12%. Hai tỉ lệ được dùng để phân tích hành vi từ chối chọn ở Mục A.3.2.3.

A.3.1.2 Điều kiện thí nghiệm

Mô hình chọn ứng viên khác S1 và MIN-DESC ở ba yếu tố của thiết lập: ngữ cảnh dài 3.072 thay vì 2.560 token để chứa danh sách ứng viên, một lượt duyệt (4.036 bước), và đầu vào có thêm danh sách ứng viên. Vì vậy, phép so trực tiếp dùng để đánh giá cơ chế chọn là $\Delta_{\text{chọn}}$ giữa cấu hình chọn ứng viên và cấu hình chỉ sinh câu hướng dẫn với cùng đầu vào. Thiết kế ban đầu đặt một cổng thực nghiệm: chỉ tiếp tục năm lượt còn

lại nếu lượt đầu vượt mức 60,6% về độ chính xác chọn, là tỉ lệ dòng mô tả xác định đúng phần tử của MIN-DESC. Độ chính xác chọn được tính trên 1.400 bước chạm đầu của tập kiểm tra và chỉ xét các bước có ứng viên đúng.

A.3.2 Kết quả

Mô hình chọn ứng viên được huấn luyện với seed 101 trên 64.567 mẫu của Mục A.3.1.1.

A.3.2.1 Độ chính xác chọn và executability

Trên 1.400 bước của mẫu phát triển, 1.008 bước có ứng viên đúng và mô hình chọn đúng ở 580 bước, tương ứng 57,54%. Mức này chưa vượt cổng 60,6% đã đặt trước, nên phạm vi thí nghiệm được giữ ở lượt đầu. 3.063 bước còn lại chỉ được dùng để đọc kết quả, trong đó 3.062 bước thuộc các tác vụ không xuất hiện trong mẫu phát triển. Độ chính xác chọn riêng lẻ không phản ánh đầy đủ cơ chế: khi ép mô hình luôn chọn, độ chính xác trên các bước có ứng viên đúng tăng lên 69,05%, nhưng tỉ lệ thẻ đúng trên toàn mẫu phát triển giảm từ 63,43% xuống 49,71%.

Trên 4.463 bước chạm, mô hình chọn ứng viên đạt 56,1% executability [54,2; 58,0] và cao hơn mô hình gốc 8,54 điểm, với 731 bước chỉ mô hình chọn ứng viên đạt so với 350 bước theo chiều ngược lại ($p < 0{,}001$). Điểm trên mẫu phát triển (55,4%) và phần còn lại (56,5%) gần nhau. Do cấu hình đối ứng chỉ sinh câu nhưng nhận cùng danh sách ứng viên không được chạy sau cổng thực nghiệm, $\Delta_{\text{chọn}}$ không được ước lượng. Vì vậy, phần này được dùng để phân tích hành vi của cơ chế chọn và so sánh trực tiếp với Base, là mốc có cùng mô hình nền chưa tinh chỉnh.

A.3.2.2 Hành vi chọn và từ chối chọn

Khi danh sách chứa ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4% (Bảng A.10), chỉ cách câu chuẩn 4,3 điểm. Nhóm này chiếm 52,1% toàn bộ tập kiểm tra. Phần lớn cơ hội cải thiện nằm ở 872 bước có ứng viên đúng nhưng mô hình phát thẻ từ chối chọn, với executability 23,7%. Tỉ lệ từ chối nhầm gần bằng mức 27,1%

Bảng A.10: Mô hình chọn ứng viên, chia theo việc danh sách có ứng viên đúng và việc mô hình có đưa ra lựa chọn hay không. Hàng đầu và hàng cuối là hành vi đúng, hai hàng giữa là hai dạng lỗi. Khoảng tin cậy 95% chỉ được tính cho hai nhóm có ứng viên đúng.

Có ứng viên đúng	Mô hình	n	% tập	Exec.	Khớp thao tác
có	chọn	2.326	52,1	71,4 [69,5; 73,2]	99,1
có	từ chối (sai)	872	19,5	23,7 [21,0; 26,7]	71,2
không	chọn (sai)	264	5,9	37,5	99,6
không	từ chối (đúng)	1.001	22,4	53,8	86,6

trên mẫu phát triển. Khả năng chọn khi mô hình đã quyết định đưa ra lựa chọn vì vậy tốt hơn rõ rệt so với khâu quyết định có chọn hay không.

Dấu hiệu đi kèm việc từ chối chọn. Câu mang động từ không phải chạm chiếm 28,3% số bước từ chối chọn, so với 0,97% ở bước đưa ra lựa chọn, tương tự hiện tượng lẫn loại thao tác ở Mục A.1.3.1. Sai số của mô hình định vị ở nhóm từ chối chọn có trung vị 19,9% bề ngang màn, so với 0,78% ở nhóm còn lại, tức mô hình xác định một vùng khác của màn như dạng lỗi lưỡng cực ở Mục A.2.2.3. Tỉ lệ từ chối chọn tăng theo độ dài danh sách (Bảng A.11), nhưng các màn hình có nhiều phần tử cũng thường khó hơn, nên quan sát này chỉ phản ánh tương quan.

Bảng A.11: Tỉ lệ từ chối chọn và executability theo số dòng trong danh sách, chỉ tính bước có ứng viên đúng.

Số dòng trong danh sách	n	Từ chối chọn	Exec.
1 đến 5	178	18,5%	70,8
6 đến 10	363	15,7%	70,5
11 đến 20	826	25,9%	60,3
21 đến 39	1.036	29,3%	55,6
40 (mức tối đa)	795	33,2%	51,8

Tỉ lệ từ chối chọn cũng cao hơn khi ứng viên đúng nằm giữa danh sách (31,4%, so với 27,2% ở phần đầu và 24,3% ở phần cuối), tương tự hiện tượng Liu và cộng sự [40] mô tả cho ngữ cảnh dài. Đây là quan sát chưa qua kiểm định, và vị trí trong danh sách có tương quan với độ dài danh sách.

A.3.2.3 Phân bố nhãn từ chối chọn trong tập huấn luyện

Bảng A.12: Tỉ lệ thẻ `none` theo bốn mẫu số. Mô hình phát `none` nhiều hơn tỉ lệ đúng trên loại bước bị đánh giá, và ít hơn tỉ lệ gặp trên toàn tập huấn luyện.

Mẫu số	**Tỉ lệ none**
Toàn bộ tập huấn luyện (64.567 mẫu)	54,78%
Chỉ bước chạm của tập huấn luyện (41.191)	29,12%
Bước chạm của tập kiểm tra, tỉ lệ đúng (4.463)	28,34%
Tỉ lệ mô hình phát ra trên tập kiểm tra	41,97%

Theo Bảng A.12, tỉ lệ mô hình phát ra nằm giữa tỉ lệ đúng trên bước chạm và tỉ lệ trên toàn tập huấn luyện, và gần tỉ lệ toàn tập hơn. Vì mọi bước không chạm đều mang thẻ `none` (Mục A.3.1.1), thẻ này chiếm hơn một nửa số mẫu huấn luyện. Một cách giải thích phù hợp với quan sát là mô hình học tiên nghiệm của nhãn này trên toàn bộ tập huấn luyện rồi duy trì xu hướng đó khi xử lý bước chạm, là loại bước duy nhất được đánh giá. Rajpurkar và cộng sự [38] nêu hiện tượng tương tự cho SQuAD 2.0, còn Menon và cộng sự [39] chứng minh rằng dưới dạng lệch phân bố nhãn, sửa tiên nghiệm lúc huấn luyện tương đương với sửa sau huấn luyện. Tỉ lệ đúng trên bước chạm của tập huấn luyện (29,12%) và của tập kiểm tra (28,34%) chỉ chênh 0,8 điểm, nên phân bố nhãn trên riêng nhóm bước chạm gần như không thay đổi giữa hai tập. Phân tích này được dùng để giải thích hành vi quan sát được, không được diễn giải như một kết luận nhân quả.

Ba phương án hiệu chỉnh khác được dùng để xác định nguồn cải thiện khả thi. Sửa toàn bộ lỗi loại thao tác thêm 1,21 điểm. Rút danh sách còn mười dòng làm độ phủ ứng viên đúng giảm từ 71,7% xuống tối đa 51,7%, còn nới dung sai tọa độ nâng độ phủ lên 76,0% nhưng đồng thời thay đổi nhãn huấn luyện. Ba phép thử tiếp tục hướng phân tích về tiên nghiệm của thẻ `none` và quyết định từ chối chọn.

A.3.2.4 Ghép với giai đoạn học theo cặp ưu tiên và hiệu chỉnh mức từ chối chọn

Khi ghép mô hình chọn ứng viên với MIN-DESC theo quy tắc “nếu từ chối chọn thì dùng câu của MIN-DESC”, executability tăng từ 60,0% của MIN-DESC lên 60,7%.

Mức tăng +0,67 điểm gần với chênh lệch giữa hai lượt S1, nên phép ghép này được xem như một kết quả thăm dò hơn là bằng chứng riêng cho cơ chế chọn. Một cách chọn biết trước ở từng bước mô hình nào đúng cho mức 66,1%, cho thấy vẫn còn khoảng cải thiện nếu quyết định kết hợp được học tốt hơn.

Trước khi huấn luyện lại, mức từ chối chọn được hiệu chỉnh thử sau huấn luyện. Theo Menon và cộng sự, nếu hiệu chỉnh hậu xử lý không khắc phục được các bước từ chối nhầm thì khả năng huấn luyện lại chỉ để sửa tiên nghiệm nhãn cũng bị hạn chế. Thủ tục này chọn ứng viên có log-xác suất cao nhất khi điểm ấy hơn điểm của thẻ `none` quá một ngưỡng τ, với ngưỡng và ba biến thể cách xếp hạng được quét trên mẫu phát triển. So với hành vi hiện tại (888 trên 1.400 bước đúng), biến thể tốt nhất chỉ thêm +8 bước (khoảng tin cậy từ -11 đến +27), tức +0,6 điểm.

Theo tổng log-xác suất, ứng viên đúng đứng đầu ở 67,5% số bước có ứng viên đúng. Trong khi đó, điểm của thẻ `none` chỉ phân tách ở mức AUC 0,69–0,72 giữa bước có và không có ứng viên đúng. Hai con số củng cố phân tích ở Bảng A.10: khả năng xếp hạng ứng viên đã có tín hiệu tốt, còn quyết định từ chối chọn là phần cần cải thiện. Quét ngưỡng hậu xử lý làm tăng số bước được sửa nhưng đồng thời tạo số bước đổi theo chiều ngược lại gần tương đương, nên phần này được giữ ở mức phân tích cơ chế.

A.4 Huấn luyện tăng cường với phần thưởng tọa độ

A.4.1 Thiết kế

Căn cứ và phần thưởng. Hai giai đoạn trước tối ưu trên các chuỗi mục tiêu có sẵn. Giai đoạn huấn luyện tăng cường với phần thưởng tọa độ tiếp tục từ MIN-DESC bằng GRPO (Mục 2.3). Với mỗi prompt, mô hình sinh nhiều đầu ra và nhận phần thưởng dựa trên ba thành phần: 1,0 nếu tọa độ trong thẻ `<point>` nằm trong cửa sổ $\pm$14% quanh tọa độ tham chiếu, 0,2 nếu dòng mô tả đủ trường và đúng thứ tự, và 0,1 nếu tên phần tử khớp nhãn. Mô hình định vị không tham gia vào phần thưởng.

Cấu hình. Giai đoạn này học tiếp từ trọng số MIN-DESC với cùng lượng tử hoá bốn bit và phần thị giác đóng băng. Mỗi prompt sinh bốn câu trả lời ở nhiệt độ 1,0,

còn mô hình tham chiếu cho số hạng ràng buộc độ lệch là bản sao đóng băng của mô hình xuất phát. Tập thưởng gồm 2.000 bước chạm của tập huấn luyện, duyệt một lượt (500 bước cập nhật). Tập này chỉ gồm bước chạm vì chỉ bước chạm có tọa độ chuẩn.

A.4.2 Kết quả

Giai đoạn thưởng tọa độ cải thiện trực tiếp đại lượng được tối ưu: độ chính xác của dòng mô tả tăng 2,56 điểm với $p = 1{,}3 \times 10^{-8}$. Trên 4.463 bước chạm, executability của MIN-DESC và mô hình sau giai đoạn này lần lượt là 60,05% và 60,07%, tương ứng chênh +0,02 điểm [−0,59; +0,64]. Tiêu chí hộp phần tử tăng từ 66,55 lên 67,04. Trước khi đánh giá trên tập kiểm tra, mức tăng executability từng được ước lượng từ hệ số chuyển đổi của giai đoạn hai là +1,10 điểm [+0,59; +1,49]. Mức thực đo +0,02 điểm thấp hơn nhiều ước lượng này, nên hệ số chuyển đổi không được xem là cố định giữa các dạng can thiệp.

Phân rã thay đổi theo từng bước. Ở 164 bước mà giai đoạn ba sửa dòng mô tả từ sai thành đúng, executability tăng từ 32,9 lên 70,7. Ở 75 bước mà dòng mô tả chuyển từ đúng thành sai, executability giảm từ 69,3 xuống 29,3. Khi đếm chuyển đổi đạt/không đạt, bốn nhóm sửa đúng, làm sai, giữ nguyên và không có tên đối chiếu đóng góp lần lượt +62, −30, −14 và −17 bước, cho tổng ròng +1. Trong 1.950 bước có dòng mô tả thay đổi, 1.300 bước (66,7%) giữ nguyên câu, và toàn bộ 197 lần đổi kết quả đánh giá nằm trong 961 bước có câu thay đổi.

Diễn giải. Phần thưởng tọa độ đã cải thiện rõ biểu diễn trung gian, nhưng hàm thưởng không có số hạng trực tiếp cho câu hướng dẫn. Vì vậy, thay đổi trọng số có thể sửa tọa độ mà không tạo thay đổi tương ứng ở câu, hoặc làm câu đổi ở những bước không nhận tín hiệu trực tiếp. Quan sát này dẫn các thiết kế sau chuyển trọng tâm từ tối ưu biểu diễn trung gian sang tối ưu trực tiếp câu đầu ra.

A.4.3 Nội suy trọng số giữa hai mô hình

Giai đoạn ba nối tiếp giai đoạn hai, nên hai bộ trọng số chỉ khác nhau tương đối ít. Phép thử này xây dựng năm điểm trên đoạn nối hai bộ trọng số (kể cả hai đầu mút), bằng cách ghép các ma trận hạng thấp của hai bộ chuyển đổi LoRA ở từng mô-đun

theo tỉ lệ pha trộn, rồi đánh giá trên tập kiểm định nội bộ. Giả thuyết là một điểm ở giữa có thể giữ phần sửa của giai đoạn ba mà tránh bớt phần làm sai. Đường cong đơn điệu, với cực đại tại đầu mút giai đoạn ba. Điểm giữa tốt nhất thấp hơn đầu mút 0,38 điểm, mọi phép so sánh ghép cặp giữa các mức đều có khoảng tin cậy phủ 0, nên không cấu hình mới nào được đánh giá trên tập kiểm tra. Số bước có câu khác đầu mút giai đoạn hai tăng đều theo mức pha trộn (53, 95, 127 rồi 155 trên 407 bước), cho thấy phép ghép hoạt động đúng. Dư địa vốn hẹp, vì giai đoạn ba chỉ dịch hai ma trận hạng thấp 1,39% và 6,87% so với giai đoạn hai.

Vai trò của tập kiểm định nội bộ. Cả hai mô hình đều đã tiếp xúc với tập này trong các giai đoạn trước (Mục 3.3), nên tập chỉ được dùng để xếp hạng các biến thể trong cùng một họ. Trên tập kiểm tra độc lập, mọi kết luận định lượng vẫn dựa trên 4.463 bước chạm.

A.5 Phân rã lỗi giữa nhận diện phần tử và sinh câu hướng dẫn

Các phương án từ Mục A.1.3 đến đây cho thấy biểu diễn phần tử và câu đầu ra có liên hệ chặt, nhưng mức tăng ở biểu diễn trung gian không tự động chuyển thành executability. Mục này tách quá trình thành hai khâu: nhận diện phần tử, đo bằng tọa độ mô hình ghi trong dòng mô tả, và sinh câu hướng dẫn, đo bằng tọa độ mà mô hình định vị suy ra từ câu. Trên 4.442 bước có dòng mô tả hợp lệ, MIN-DESC đạt 70,10% ở khâu nhận diện phần tử và 69,36% ở khâu sinh câu.

Bảng A.13: Executability chia theo việc MIN-DESC có nhận ra đúng phần tử hay không. Cột câu chuẩn là điểm của câu do người chú thích viết, đo trên cùng nhóm bước.

Nhóm	n	MIN-DESC	S1	Câu chuẩn
Nhận ra đúng phần tử	3.114 (70,1%)	82,37	74,18	84,36
Nhận ra sai phần tử	1.328 (29,9%)	8,43	24,47	55,72

Vai trò của nhóm nhận diện sai phần tử. Trên toàn bộ các bước được đánh giá, câu chuẩn hơn MIN-DESC 15,53 điểm. Nhóm mà mô hình nhận ra đúng phần

tử chiếm 70,1% số bước và chỉ đóng góp 1,40 điểm, tương ứng 9,0% khoảng cách. Nhóm nhận ra sai chiếm 29,9% nhưng đóng góp 14,14 điểm, tương ứng 91,0%. Nếu tiếp tục phát triển biểu diễn trung gian, phần dư địa lớn nhất nằm ở khâu nhận diện phần tử của nhóm này.

Chênh lệch theo trạng thái nhận diện phần tử. Nhóm mà mô hình nhận diện sai phần tử cũng khó hơn đối với câu chuẩn. Tuy nhiên, mức giảm của MIN-DESC lớn hơn đáng kể: từ 82,37 xuống 8,43, trong khi câu chuẩn giảm từ 84,36 xuống 55,72. Lỗi nhận diện phần tử vì vậy đi cùng mức giảm mạnh hơn ở câu hướng dẫn của MIN-DESC, dù cách chia nhóm chưa cho phép diễn giải hoàn toàn theo quan hệ nhân quả.

Quan hệ giữa cải thiện nhận diện và executability. Giai đoạn thưởng tọa độ là can thiệp đặt phần thưởng trực tiếp lên tọa độ trong dòng mô tả. Trên 4.437 bước ghép cặp, tỉ lệ nhận diện đúng phần tử tăng 1,60 điểm trong khi executability tăng 0,045 điểm, tương ứng 0,028 điểm executability cho mỗi điểm tăng ở tỉ lệ nhận diện. Hai đại lượng có liên hệ, nhưng mức chuyển đổi đo được ở can thiệp này không thể dùng như một hệ số cố định cho các thiết kế khác.

Bảng A.14: Bảng chéo việc nhận ra đúng hay sai phần tử giữa giai đoạn hai (MIN-DESC) và giai đoạn ba, kèm executability của mỗi mô hình trên từng nhóm.

Nhóm	n	MIN-DESC	Giai đoạn ba	Chênh
giữ đúng	2.997	83,08	82,95	−0,13
giữ sai	1.143	6,91	6,30	−0,61
sai chuyển thành đúng	184	17,93	58,15	+40,22
đúng chuyển thành sai	113	62,83	8,85	−53,98

Bảng A.14 phân rã mức thay đổi này. Giai đoạn ba sửa được 184 bước, với executability tăng 40,22 điểm trong nhóm, đồng thời 113 bước chuyển theo chiều ngược lại với mức giảm 53,98 điểm. Hai chiều thay đổi giải thích vì sao mức tăng tổng thể nhỏ dù số bước được sửa có cải thiện rõ.

Tương quan giữa các mô hình không phản ánh hệ số quy đổi giữa hai đại lượng. Giữa các mô hình đã huấn luyện, tỉ lệ nhận diện đúng phần tử và executability tương quan ở mức 0,739, nhưng tỉ số đo được trong can thiệp thực nghiệm chỉ là 0,028, nhỏ hơn 26 lần. Tương quan này phản ánh việc mô hình mạnh thường mạnh ở cả hai

khâu, nhưng không cho biết mức thay đổi của executability khi chỉ can thiệp vào khâu nhận diện phần tử.

Phạm vi diễn giải. Cách chia nhóm dựa trên hành vi của chính mô hình đang được đánh giá, nên chỉ phép so sánh giữa hai mô hình bên trong một nhóm là hợp lệ. Mẫu số 4.442 nhỏ hơn 4.463 vì 21 bước có dòng mô tả thiếu hoặc sai định dạng.

A.5.1 Độ ổn định của ước lượng trên nhóm con

Bảng A.13 gợi ý rằng việc thay câu ở nhóm nhận diện sai có thể đem lại mức tăng đáng kể. Nếu thay câu của MIN-DESC bằng câu của S1 trên nhóm do chính MIN-DESC xác định là nhận diện sai, điểm toàn tập tăng 4,80. Tuy nhiên, ước lượng này phụ thuộc mạnh vào cách định nghĩa nhóm vì tọa độ và câu của MIN-DESC đến từ cùng một lượt sinh. Mục này kiểm tra lại con số 4,80 dưới các cách chia độc lập hơn trước khi dùng làm căn cứ thiết kế.

Bảng A.15: Ước lượng lợi ích của can thiệp chỉ thay câu dưới bốn cách định nghĩa nhóm trên 4.437 bước ghép cặp. Cột cuối là mức thay đổi trên toàn bộ các bước khi thay câu của MIN-DESC trong nhóm đó bằng câu của S1.

Cách định nghĩa nhóm	n	MIN	S1	Câu chuẩn	Mức tăng khi thay câu
MIN-DESC nhận ra sai phần tử	1.327	8,44	24,49	55,69	+4,80
giai đoạn ba nhận ra sai phần tử	1.256	11,94	22,13	54,70	+2,88
giai đoạn ba sai mà MIN-DESC đúng	113	62,83	34,51	60,18	−0,72
30% màn hình có nhiều phần tử có thể chạm nhất	1.331	58,53	56,35	73,55	−0,65

Bảng A.15 đổi cách định nghĩa nhóm ba lần. Khi nhóm được định nghĩa bằng tọa độ của mô hình sau giai đoạn thưởng tọa độ, tức hành vi của một mô hình khác, ngưỡng tối đa còn 2,88. Khi lấy phần giai đoạn ba sai còn MIN-DESC đúng, ngưỡng tối đa đổi dấu. Khi dùng số phần tử có thể chạm trên màn, không dựa vào hành vi của mô hình nào, ngưỡng tối đa là $-0{,}65$. Trong khi đó, cột câu chuẩn tương đối ổn định ở ba hàng đầu (55,69, 54,70 và 60,18) và chỉ cao hơn ở hàng cuối, vốn là nhóm dễ hơn. Ưu thế giữa hai mô hình cùng họ thay đổi theo cách chia nhóm trong khi khoảng cách tới câu chuẩn tương đối ổn định, và đây là dấu hiệu của hiệu ứng chọn nhóm.

Nguyên tắc sử dụng phân tích nhóm. Một ước lượng lấy nhóm được định nghĩa bằng chính hành vi của mô hình cần được kiểm tra lại với ít nhất một cách chia độc lập trước khi dùng làm căn cứ thiết kế. Quy tắc này cũng được áp dụng cho các con số thuận lợi ở Mục A.2.3, giúp tránh lựa chọn phương án chỉ dựa trên hiệu ứng của cách chia nhóm.

A.6 Tích hợp thông tin vị trí vào mô hình sinh câu

Ở Mục A.5, độ chính xác nhận diện phần tử thay đổi cùng chất lượng câu hướng dẫn, nhưng cải thiện biểu diễn trung gian chưa chuyển trực tiếp thành executability. Từ đó, chúng tôi khảo sát bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc ý tưởng không cần GPU (Bảng A.16). Phần lớn phép đo được thực hiện trên tập kiểm định nội bộ để so sánh tương đối giữa các biến thể trước khi quyết định có mở rộng thí nghiệm.

Điều rút ra từ chuỗi phép thử. Thông tin vị trí có thể được giải mã từ trạng thái ẩn và mô hình có phản ứng với thay đổi hình ảnh, nhưng việc bổ sung đường tín hiệu vị trí sau khi mô hình sinh câu đã được huấn luyện chỉ tạo thay đổi nhỏ ở đầu ra. Ở phép tích hợp vai trò, vùng và thao tác, hệ số trộn tự giảm về gần 0. Ở các phép biến đổi ảnh, mô hình phản ứng với vùng được nhấn mạnh nhưng chưa phân biệt ổn định phần tử mục tiêu với phần tử lân cận. Hai hướng phù hợp hơn là tích hợp tín hiệu vị trí sớm hơn trong quá trình học hoặc tối ưu trực tiếp câu đầu ra, thay vì chỉ bổ sung một mô-đun hậu kỳ.

A.7 Hiệu chỉnh câu dựa trên vùng ảnh cục bộ (TAGE)

A.7.1 Thiết kế

Căn cứ. TAGE (*Type-Aware Grounded Editor*) được xây dựng để kiểm tra khả năng hiệu chỉnh câu sau khi tập trung vào một vùng ảnh cục bộ quanh phần tử dự đoán. Mô-đun nhận câu hướng dẫn ban đầu từ mô hình học tăng cường với phần thưởng SPICE, định vị vùng cần xem và sinh lại câu từ ảnh gốc cùng ô cắt. TAGE nằm ở

Bảng A.16: Bốn cách đưa thông tin vị trí vào mô hình sinh câu và hai phép sàng lọc không cần GPU. Dấu * chỉ phép đo trên tập kiểm định nội bộ.

Hướng	Cách làm	Kết quả
Mô-đun định vị và cầu nối*	một bộ chú ý học vị trí phần tử trên các mảnh ảnh, rồi cộng đặc trưng vùng đó vào trạng thái ẩn ở tầng giữa của mô hình	bộ chú ý học được vị trí (trùng hộp 52,0% so với 5,3% của tiên nghiệm), nhưng các cấu hình cầu nối chỉ làm thay đổi 15% số câu và executability chỉ lệch +0,17 điểm [−1,03; +1,33]
Vùng cắt làm ảnh thứ hai*	đo xác suất câu chuẩn khi cho thêm ảnh cắt quanh phần tử đúng, quanh phần tử lân cận cùng loại, hoặc quanh một vùng ngẫu nhiên	tách được vùng đúng khỏi vùng ngẫu nhiên, nhưng gần như không tách được khỏi phần tử lân cận (+0,004 nat mỗi token)
Tích hợp vai trò, vùng, thao tác*	đọc vai trò, vùng màn và loại thao tác từ trạng thái ẩn, rồi tích hợp lại qua một hệ số trộn học được	các thông tin này có thể được giải mã từ trạng thái ẩn (vai trò 51,5%, thao tác 82,8%), nhưng hệ số trộn giảm về gần không, chỉ 4% số câu thay đổi, và hoán vị thông tin giữa các bước không làm điểm giảm
Làm nét ảnh quanh phần tử cần chạm*	giữ S1 đóng băng, đưa ảnh được làm nét quanh phần tử cần chạm, quanh vùng đối diện, hoặc quanh tâm màn	S1 đổi câu ở 16,9% số bước, nhưng làm nét đúng phần tử cần chạm không tốt hơn làm nét vùng đối diện
Hai lượt viết lại có chọn lọc	sàng lọc trên tập kiểm tra: trong 958 câu của S1 chỉ khác câu chuẩn ở một cụm từ, đếm số câu làm mô hình định vị trỏ sai	147/958 (15,3%), tức phần lớn trường hợp gần nghĩa chỉ khác cách diễn đạt, không phải lỗi quy chiếu sang phần tử khác
Bộ xếp hạng câu biết màn sau*	học chọn một trong chín câu do S1 sinh, dùng đặc trưng tính nhanh, có một biến thể học theo mô hình thầy được xem màn kế tiếp	chưa vượt câu giải mã tham lam ở BLEU-4, CIDEr-D và SPICE, kể cả biến thể học theo mô hình thầy được xem màn kế tiếp

cùng vị trí hậu xử lý với ACE, nên mốc so sánh trực tiếp là câu hướng dẫn ban đầu của thành phần thứ nhất.

Ba thành phần. TAGE gồm ba thành phần, và Hình A.1 vẽ đường đi của một bước qua cả ba.

1. Bộ định vị nhận ảnh và mục tiêu rồi viết ra một điểm (x, y) trên thang 0 đến 1000. Quanh điểm ấy, một ô vuông có cạnh bằng 40% bề ngang màn hình được cắt ra và phóng lên 448 × 448 điểm ảnh.

2. Bộ biên tập nhận ảnh gốc, ô cắt và câu hướng dẫn ban đầu rồi viết lại câu. Lúc huấn luyện, ô cắt đặt quanh điểm chạm thật, và hàm mất mát gồm entropy chéo của câu chuẩn cộng một số hạng lề

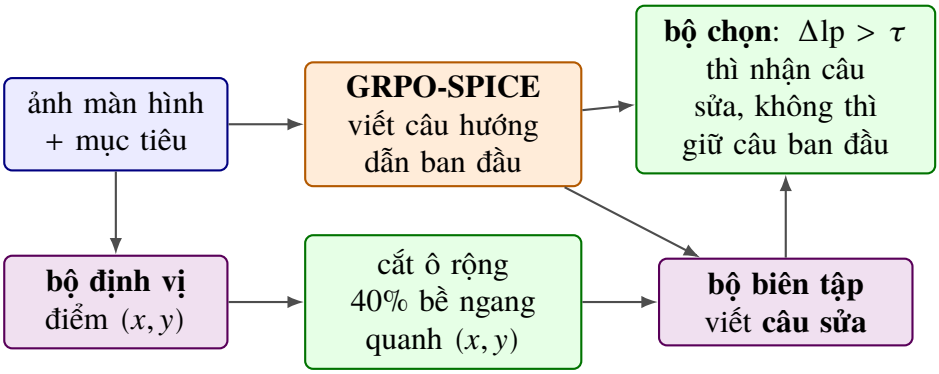
$$\mathscr{L} = \mathrm{CE}(g \mid \text{ô đúng}) + 0{,}5 \cdot \max\bigl(0,\ 0{,}2 - (\mathrm{nll}_{\text{lân cận}} - \mathrm{nll}_{\text{đúng}})\bigr), \qquad \text{(A.1)}$$

trong đó $\mathrm{nll}_{\text{đúng}}$ và $\mathrm{nll}_{\text{lân cận}}$ là log-xác suất âm của câu chuẩn khi ô cắt đặt quanh phần tử đúng và quanh một phần tử lân cận cùng vai trò. Số hạng này buộc bộ biên tập dựa vào nội dung ô cắt thay vì chép lại câu hướng dẫn ban đầu. Câu hướng dẫn ban đầu lúc huấn luyện lấy từ mô hình học tăng cường với phần thưởng SPICE, và 30% số câu hướng dẫn ban đầu này bị thay tên phần tử bằng tên phần tử lân cận.

3. Bộ chọn nhận câu sửa khi $\Delta\mathrm{lp} = \mathrm{lp}(\text{sửa}) - \mathrm{lp}(\text{ban đầu})$, tức hiệu log-xác suất trung bình theo token do bộ biên tập tính, lớn hơn một hằng số τ. Ngược lại, bộ chọn giữ câu hướng dẫn ban đầu. Giá trị $\tau = 0{,}738$ được chọn chéo trên tập kiểm định nội bộ, bằng cách chọn trên một nửa số tác vụ rồi áp lên nửa kia.

Bộ định vị và bộ biên tập là hai bộ chuyển đổi LoRA hạng 16 ở phần ngôn ngữ, gắn trên mô hình tinh chỉnh có giám sát (S1) sau khi đã cộng hẳn trọng số bộ chuyển đổi của S1 vào mô hình gốc. Mỗi bộ học một lượt trên 2.554 bước chạm của tập huấn luyện không chứa tác vụ nào của tập kiểm định nội bộ.

Cỡ mẫu khi chọn τ. Trên tập kiểm định nội bộ, bộ chọn nhận 11 câu sửa trong 249 bước chạm. Vì vậy, ngưỡng τ được xem là một lựa chọn thăm dò và được kiểm tra lại qua hành vi trên tập kiểm tra ở Mục A.7.2.



Hình A.1: Đường đi của một bước trong mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE). Hai khối tím là hai bộ chuyển đổi được huấn luyện, khối cam là GRPO-SPICE, các khối xanh lá là bước xử lý không học. Δlp là hiệu log-xác suất trung bình theo token giữa câu sửa và câu hướng dẫn ban đầu, $\tau = 0{,}738$. Đầu ra của bộ chọn là câu được dùng để đánh giá.

A.7.2 Kết quả

Trên tập kiểm định nội bộ, câu sửa tốt hơn câu hướng dẫn ban đầu rõ rệt khi ô cắt đặt quanh điểm chạm đúng và kém đi rõ khi ô cắt cố ý đặt quanh một phần tử lân cận. Bộ biên tập vì vậy có phản ứng với nội dung ô cắt. Mô-đun hiệu chỉnh câu hoàn chỉnh cũng cao hơn nhẹ so với câu hướng dẫn ban đầu trên tập ấy, nên được đánh giá một lần trên tập kiểm tra.

Bảng A.17: Mô-đun hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE) trên 4.463 bước có thao tác chạm của tập kiểm tra, so với câu hướng dẫn ban đầu của GRPO-SPICE và với S1/101. Tiêu chí hộp phần tử lấy từ AndroidControl, AitW đầy đủ lấy từ AndroidInTheWild. Các chênh lệch được tính ghép cặp theo bước.

Độ đo	S1	Câu ban đầu	TAGE	TAGE – câu ban đầu	p
Executability	59,11	60,65	60,23	−0,43 [−0,87; +0,02]	0,093
Tiêu chí hộp phần tử	65,49	67,02	66,44	−0,58 [−1,07; −0,09]	0,027
AitW đầy đủ	74,37	76,25	76,07	−0,18 [−0,66; +0,32]	0,55
Đúng loại thao tác	94,35	95,97	96,64	+0,67 [+0,44; +0,92]	<0,001
SPICE	44,37	45,79	45,74	−0,05 [−0,38; +0,27]	-

Kết quả trên tập kiểm tra. TAGE đạt 60,23% executability, cao hơn S1/101 1,12 điểm [+0,31; +1,94] và gần với mức 60,65% của câu hướng dẫn ban đầu từ GRPO-

SPICE. So trực tiếp với câu ban đầu, chênh lệch executability là −0,43 điểm [−0,87; +0,02], còn tiêu chí hộp phần tử giảm 0,58 điểm. Cấu hình TAGE hiện tại vì vậy không được chọn thay ACE. Khi vùng đầu vào chứa đúng phần tử mục tiêu, câu sửa vẫn tạo mức cải thiện rõ ở các phép phân rã theo bước.

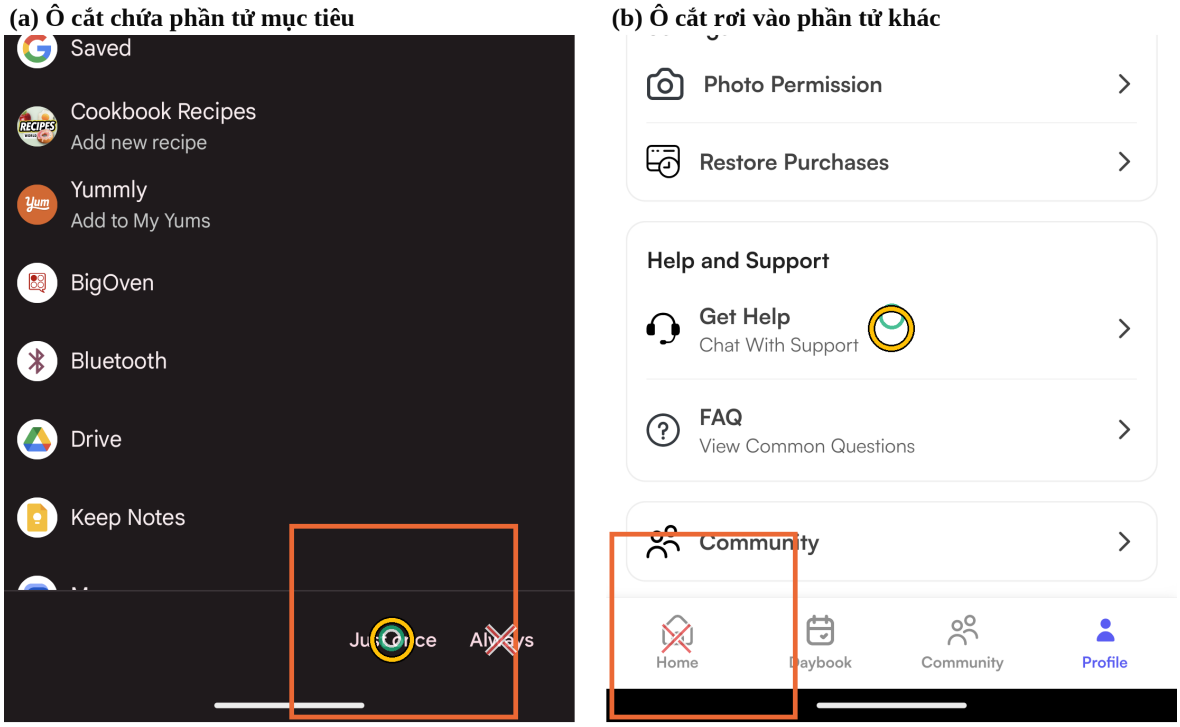
Ảnh hưởng của độ chính xác ô cắt. Mô hình định vị xác định đúng phần tử ở 69,5% số bước, bộ biên tập đổi câu ở 70,8%, và bộ chọn nhận 219 câu sửa. Trong 80 bước mà ô cắt đặt đúng chỗ, câu sửa chuyển 46 bước từ sai sang đúng và chỉ 7 bước theo chiều ngược lại, tương ứng ròng +39 bước. Ngược lại, trong 139 bước ô cắt đặt sai, câu sửa chỉ cứu 2 bước nhưng làm 60 bước chuyển từ đạt sang không đạt. Lợi ích của bộ biên tập vì vậy tập trung ở các trường hợp vùng đầu vào đúng, còn sai số định vị vùng làm đảo chiều tác động của TAGE.

Tín hiệu của bộ chọn. Theo Hình A.3, tỉ lệ ô cắt đặt đúng chỗ giảm đều khi Δlp tăng, từ 74,0% ở nhóm thấp nhất xuống 36,5% ở nhóm được nhận. Một cách giải thích phù hợp với quan sát này là khi ô cắt rơi vào phần tử khác, mô-đun biên tập tạo câu có xác suất cao đối với nội dung trong ô, trong khi câu hướng dẫn ban đầu mô tả phần tử ngoài ô nên nhận log-xác suất thấp. Hiệu Δlp vì vậy đo mức lệch giữa câu hướng dẫn ban đầu và ô cắt, và không cho biết câu nào đúng hơn. Trên tập kiểm định nội bộ, nhóm trên cùng chỉ có 11 câu, trong đó 8 câu có ô cắt đặt đúng chỗ, và τ lại được chọn từ chính 11 câu ấy.

Hướng cải thiện. Bộ chọn hiện dùng xác suất do chính bộ biên tập tính, nên tín hiệu lựa chọn phụ thuộc trực tiếp vào nội dung ô cắt. Một hướng phù hợp hơn là dùng tín hiệu độc lập để xác nhận ô cắt trước khi nhận câu sửa. Nếu chỉ nhận các câu sửa trong 80 bước có ô cắt đúng, số bước đạt tăng ròng 39, tương ứng khoảng +0,87 điểm trên toàn tập. Đây là ước lượng dựa trên điểm chạm thật để xác định ô cắt đúng, không phải kết quả của một cấu hình đã chạy. Giá trị +0,87 điểm chỉ được dùng để định lượng phần dư địa của bộ biên tập nếu khâu xác nhận vùng được cải thiện.

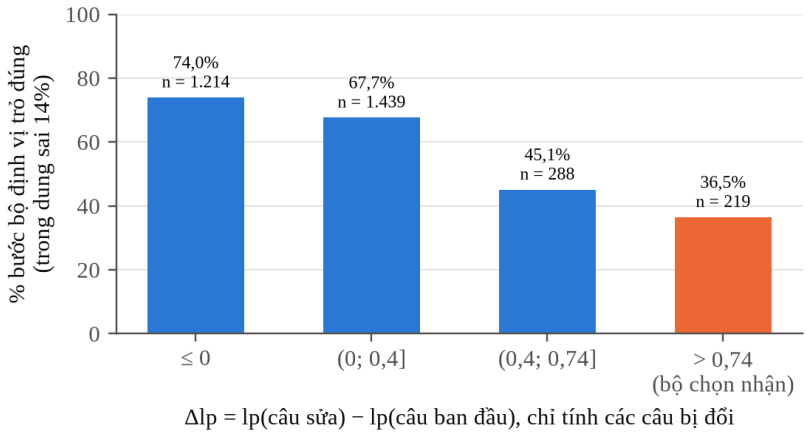
A.8 Trạng thái các cấu hình đã khảo sát

Bảng A.18 tổng hợp trạng thái cuối của các cấu hình đã khảo sát, đồng thời ghi lý do đối với những cấu hình không được tiếp tục hoặc dừng trước khi hoàn tất.



Khung cam: ô cắt rộng 40% bề ngang quanh điểm mà bộ định vị dự đoán
Vòng vàng: điểm người dùng đã chạm
Vòng xanh lá: điểm định vị cho câu đạt, (a) câu sửa, (b) câu ban đầu
Dấu X đỏ: điểm định vị cho câu không đạt, (a) câu ban đầu, (b) câu sửa
(a) câu ban đầu: "Click on the always button"
câu sửa: "Click on the just once option"
(b) câu ban đầu: "click on the Get help option"
câu sửa: "click on the home tab at the bottom left corner of the screen"

Hình A.2: Hai bước mà bộ chọn của TAGE nhận câu sửa (ảnh chỉ giữ phần dưới màn hình). (a) Ô cắt chứa đúng phần tử mục tiêu: câu hướng dẫn ban đầu gọi nút *Always*, câu sửa gọi đúng *Just once*. (b) Ô cắt rơi vào thanh điều hướng ở góc dưới bên trái: câu hướng dẫn ban đầu *Get help* vốn đúng bị thay bằng câu về thẻ *Home* nằm trong ô cắt. Khung cam là ô cắt rộng 40% bề ngang quanh điểm mà bộ định vị dự đoán, vòng vàng là điểm người dùng chạm. Vòng xanh lá và dấu X đỏ là điểm mô hình định vị trả về cho câu đạt và câu không đạt, ở (a) là câu sửa và câu ban đầu, ở (b) thì ngược lại.



Hình A.3: Tỉ lệ bước mà bộ định vị của TAGE trỏ trong dung sai 14% quanh điểm chạm thật, tức ô cắt được đặt đúng chỗ, theo nhóm Δlp, trên các câu mà bộ biên tập đã đổi ở tập kiểm tra. Δlp là hiệu log-xác suất trung bình theo token giữa câu sửa và câu hướng dẫn ban đầu, n là số câu trong mỗi nhóm. Cột cam là nhóm bộ chọn nhận ($\Delta\text{lp} > \tau$). Tỉ lệ này giảm khi Δlp tăng.

Bảng A.18: Trạng thái cuối của các cấu hình đã khảo sát. Điểm trong cột ghi chú là executability trên tập kiểm tra, trừ khi ghi khác.

Mô hình hoặc cấu hình	**Trạng thái**	**Ghi chú**
Phương pháp đề xuất (GRPO-SPICE + ACE)	Hoàn tất, đã đánh giá	60,7, hơn S1/101 +1,57 có ý nghĩa thống kê. Cả bảy thước dựa trên câu chuẩn đều tăng so với GRPO-SPICE và cả sáu thước có KTC đều loại 0, Mục 6.4
GRPO-SPICE (thành phần thứ nhất)	Hoàn tất, đã đánh giá hai lượt	60,7 và 59,9. Lượt 1 hơn S1/101 +1,55, cao hơn ở cả 13 độ đo và cả 12 độ đo có KTC đều loại 0. Lượt 2 hơn S1/101 +0,83, Mục 6.3, Mục 6.7.2
Mô hình tinh chỉnh có giám sát (S1), hai seed	Hoàn tất, đã đánh giá	59,1 và 59,6, chênh lệch giữa hai seed +0,52 điểm, Mục 6.7
Mô tả phần tử (S2), seed 101	Hoàn tất, đã đánh giá	57,2, cao hơn Base 9,59 điểm. Trên nhóm mô tả đúng tên và tọa độ đạt 87,1, Mục A.1.3

Mô hình hoặc cấu hình	Trạng thái	Ghi chú
Mô tả phần tử (S2), seed 202	Không tiếp tục	giới hạn tài nguyên tính toán
Mô tả giả (S2r) và mô tả không có tọa độ (S2-nopoint)	Không tiếp tục	phân tích theo nhóm của S2 cho mức +1,12 điểm gắn với tọa độ, nhưng S2-nopoint không được chạy
Đưa danh sách phần tử vào S1 lúc suy luận	Không thực hiện	không được yêu cầu bởi các cấu hình đã đánh giá
Học thêm có giám sát (CE2-S2) và giai đoạn học theo cặp ưu tiên (MIN-DESC)	Hoàn tất, đã đánh giá	59,4 và 60,0. MIN-DESC hơn CE2-S2 +0,63 [+0,16; +1,09], p=0,011, Mục A.2.2
Học ưu tiên với vế sai lấy từ lỗi của chính mô hình	Dừng ở khâu tạo dữ liệu	chỉ 3,3% cặp hợp lệ, Mục A.2.2.3
Giai đoạn thưởng tọa độ	Hoàn tất, đã đánh giá	60,1. Độ chính xác dòng mô tả tăng +2,56 điểm, còn executability giữ gần mức MIN-DESC, Mục A.4.2
Nội suy trọng số giữa hai giai đoạn trên	Hoàn tất	điểm thay đổi đơn điệu, không đánh giá thêm cấu hình mới trên tập kiểm tra, Mục A.4.3
Huấn luyện thêm có giám sát trên cùng 2.000 bước của giai đoạn thưởng tọa độ	Không thực hiện	mức chênh gần bằng không
Chọn ứng viên, seed 101	Hoàn tất, đã đánh giá	56,1, cao hơn Base +8,54. Khi có ứng viên đúng và mô hình đưa ra lựa chọn, executability đạt 71,4, Mục A.3.2
Năm lượt còn lại của mô hình chọn ứng viên	Không tiếp tục	độ chính xác chọn không vượt dòng mô tả tự viết
Hiệu chỉnh ngưỡng từ chối chọn	Hoàn tất	tốt nhất thêm 8 bước đúng trên 1.400 bước
Mở khoá phần thị giác để cùng huấn luyện	Dừng trước khi hoàn tất	bản lưu trung gian thấp hơn rõ rệt giai đoạn học theo cặp ưu tiên trên tập kiểm định nội bộ

Mô hình hoặc cấu hình	Trạng thái	Ghi chú
Mô-đun định vị và cầu nối	Dừng sau một lượt	cầu nối không làm câu thay đổi, Mục A.6
Vùng cắt làm ảnh thứ hai	Dừng ở khâu đánh giá	không phân biệt phần tử đúng với phần tử lân cận
Đưa thêm vai trò, vùng và loại thao tác vào mô hình	Dừng sau một lượt	hệ số trộn tự giảm về gần không, chỉ 4% số câu đổi
Làm nét ảnh quanh phần tử	Dừng ở khâu đánh giá	không cải thiện so với làm nét ở vị trí đối diện
Hai lượt viết lại có chọn lọc và bộ xếp hạng câu dùng màn kế tiếp	Dừng ở khâu sàng lọc	số câu lỗi đủ điều kiện hiệu chỉnh còn ít, bộ xếp hạng cho kết quả thấp hơn giải mã tham lam
Hiệu chỉnh câu theo vùng ảnh cục bộ (TAGE)	Hoàn tất, đã đánh giá	60,2, cao hơn S1 +1,12. Khi ô cắt đúng, câu sửa cứu ròng 39 bước, Mục A.7.2
Mô hình định vị thứ hai (UI-Venus)	Hoàn tất	chênh lệch S1 với mô hình gốc giữ 94%, phương pháp đề xuất hơn cả hai seed của S1, Mục 5.9
Phi-Ground, bộ trỏ ngoài họ Qwen	Hoàn tất	GRPO-SPICE hơn S1/101 +0,78 [+0,05; +1,51], ACE hơn +0,76 [+0,02; +1,49]. Theo báo cáo kỹ thuật, Phi-Ground không dùng AndroidControl để huấn luyện, Mục 5.9
Mô hình listener dạng lựa chọn (Phi-4)	Hoàn tất	đã đánh giá mô hình gốc, hai lượt S1, GRPO-SPICE, ACE và câu chuẩn. GRPO-SPICE hơn S1/101 +0,69 [+0,02; +1,40], còn ACE ngang GRPO-SPICE, Mục 5.10
Đánh giá thủ công 100 câu bởi hai người	Hướng mở rộng	được đề xuất như một bước đối chiếu bổ sung, Mục 7.2